05 機率分析與隨機演算法

Part I Foundations

本章定位

機率分析先固定樣本空間與依賴條件；本章從雇用指示與均勻洗牌的一般證明，推到生日碰撞、桶等待、重疊streak與線上遴選，再以隨機遞迴及Quicksort區分期望、事件機率、最壞與尾界。

前置知識

離散機率、期望值、隨機排列與基本界限。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

本章路線

學習目標

- 區分輸入分布假設與演算法內部隨機性。
- 用指示隨機變數與期望線性性避免錯誤的獨立性假設。
- 分析隨機排列與隨機化演算法的期望成本。
- 從隨機分割與比較指示變數完整推導期望值及資料結構成本。
- 5.1 The hiring problem
- 5.2 Indicator random variables
- 5.3 Randomized algorithms
- 5.4 Probabilistic analysis and further uses of indicator random variables

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

5.1 The hiring problem

n位候選人的能力有相異且可比較的排名，較大較好。每次面試後若比目前雇員更好，立即替換；先用比任何人都差的虛擬候選人初始化。這個問題計的是替換成本，不是只有比較次數。

```
HIRE(A):
    best = dummy; hires = 0
    for i = 1 to n:
        interview A[i]
        if rank(A[i]) > rank(best):
            best = A[i]; hire best; hires += 1
    return (best, hires)
```

第i輪後best是已面試i人的最大者，歸納立即成立。每人面試費ci、每次雇用費ch時，總費用為 $n \cdot ci + X \cdot ch$，其中X是雇用次數。n=0回dummy、X=0；$n \geq 1$時$1 \leq X \leq n$。

最壞輸入、輸入分布與內部亂數

排名[1,2,⋯,n]每次刷新紀錄，X=n；[n,n−1,⋯,1]只有第一次，X=1。確定性HIRE在固定輸入上的成本也是固定的。

平均情形分析必須明列輸入分布。本章先假設相異排名的n!種順序等機率；這是比「每個位置有相同邊際分布」更強的聯合假設。若先由演算法自己均勻洗牌，則任意固定排名輸入都被轉成此分布，期望改為對內部亂數取，不依賴未知的輸入分布。

這不表示每次都快或從此沒有壞執行：洗牌仍可能產生遞增順序。隨機化保證的是每個固定輸入的期望費用，不是所有亂數結果的最壞費用。

5.2 Indicator random variables

事件E的指示變數 I_E 在事件成立時為1，否則0。因此 $E[I_E] = 1P(E) + 0P(E^c) = P(E)$。若 $X = \sum_{i=1}^{m} X_i$，有限樣本空間中交換兩個有限和得

$$E[X] = \sum_{\omega} P(\omega) \sum_{i} X_i(\omega) = \sum_{i} \sum_{\omega} P(\omega) X_i(\omega) = \sum_{i} E[X_i].$$

這是期望線性性，不需Xi獨立。獨立性可能在「算出每個事件機率」或把交集機率相乘時需要。若X1=X2是同一次公平硬幣的正面指示，E[X1+X2]=1仍成立，但P(X1=X2=1)=1/2不是1/4。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

雇用次數的調和和證明

Xi表示第i位是否被雇用。固定前i位的候選人集合後，其i!種相對順序等機率，最大者落在第i位的機率1/i；這正是Xi=1的條件。因此

$$E[X] = \sum_{i=1}^{n} P(X_i = 1) = \sum_{i=1}^{n} \frac{1}{i} = H_n.$$

不需先求X的整個分布，也不需假設各次刷新事件互相獨立。由遞減函數1/x的積分比較，$\ln(n+1) \le H_n \le 1 + \ln n$，所以E[X]=Θ(ln n)，期望總費用nci+chHn；面試費沒有變成對數。

排名[2,5,1,4,6,3]依序刷新於位置1、2、5，X=3；同一n=6的均勻平均為H6=49/20=2.45，單一trace不必恰等於平均。只有一次雇用若且唯若最佳者第一個，機率1/n；每人都雇用只有唯一遞增排列，機率1/n!。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

指示變數也能數成對事件

均勻排列n個相異鍵，每對位置i<j的逆序指示Iij有機率1/2，因交換這兩個位置給大於、小於的雙射。逆序數V=Σi<j Iij，故 $E[V] = \binom{n}{2}/2 = n(n-1)/4$。各對共享位置造成相依，並不妨礙期望線性性。

均勻把n頂帽子一對一還給n人，每人拿回自己的機率1/n，所以固定點數的期望為1（n≥1）。這個期望不是「一定有一人拿對」；n=2時可能0或2，各半。n=0則固定點數0，不能再用1/n。

這兩例的共同方法是先證明每個物件的指示和恰為目標計數，再計單項機率；不要把不相交事件的機率加法，和可相依變數的期望加法混為一談。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

5.3 Randomized algorithms

假設RANDOM(a,b)回傳包含兩端的整數，每個機率1/(b−a+1)，不同呼叫相互獨立。實作的有限狀態偽亂數產生器只是此機率模型的近似來源；分析中仍須明列均勻及獨立假設。

若只有公平獨立bits，可用拒絕抽樣產生m=b−a+1種等機率結果。m=1直接回a；否則取k=⌈lg m⌉個bits形成z∈[0,2^k−1]，z<m便回a+z，否則重抽整組。每次接受率m/2^k>1/2，條件於接受後各合法z等機率；重試輪數期望<2，期望bit成本O(lg m)。

不能直接用z mod m消除超出範圍：當m不整除2^k，各餘數的前像數不同。例如3個bits mod3的0、1各有3個前像，2只有2個，不均勻。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

原地均勻洗牌：完整程序與聯合不變量

```
SHUFFLE(A):
    for i = 1 to n:
        j = RANDOM(i,n)
        swap A[i],A[j]
```

把元素視為相異身分，即使其鍵值相同也分別標記。第i輪前，任何指定的i−1個不同元素序列，成為A[1..i−1]的機率是(n−i+1)!/n!。初始空序列唯一，機率1；固定此前綴後，每個剩餘身分恰在suffix一個位置，本輪以1/(n−i+1)機率選到指定第i個元素。

故指定長i前綴的機率為(n−i)!/n!，不變量保持。終止時每個完整排列機率0!/n!=1/n!，是完整聯合均勻性證明。n=0迴圈不執行、唯一空排列機率1。單位成本亂數模型下Θ(n)時間、O(1)額外空間；用bits實作亂數時另計其成本。

同一個洗牌逐輪狀態

A=[A,B,C,D]，依序抽j=3、4、3、4。

i	可抽索引	本輪j	swap後全陣列	已固定前綴
1	1..4	3	[C,B,A,D]	C
2	2..4	4	[C,D,A,B]	C,D
3	3..4	3	[C,D,A,B]	C,D,A
4	4	4	[C,D,A,B]	C,D,A,B

這條亂數路徑的機率為1/4・1/3・1/2・1=1/24。任意目標排列也對應唯一一組合法j序列：依次找到目標第i個身分在剩餘suffix的位置，交換並繼續，所以共有4!=24條等機率路徑。

同一個洗牌逐輪狀態 （續）

從 [A,B,C,D] 開始：每輪只從尚未固定的 suffix 選一個

	位置1	位置2	位置3	位置4	本輪機率
i=1, j=3	C	B	A	D	1/4
i=2, j=4	C	D	A	B	1/3
i=3, j=3	C	D	A	B	1/2
i=4, j=4	C	D	A	B	1

綠格已固定、不再改動；這條路徑機率 1/4·1/3·1/2·1=1/24。

均勻邊際不足：兩種錯誤洗牌

只隨機選一個循環平移，確實讓每個元素以1/n機率到每個位置；但n≥3時只有n種輸出，不是n!種。聯合排列不均勻。

另一種程序讓i=1..n、每次j均勻抽整個1..n再swap。n=3時有3^3=27條等機率路徑；若六種排列均勻，每種必對應27/6條路徑，不是整數，故不可能。錯在後面步驟會再次移動先前位置，原地洗牌的不變量已不成立。

若只洗前m輪再取前m個，得到每個長m有序樣本機率$(n-m)!/n!$；忽略順序，每個m子集有m!種排序，機率$1/\binom{n}{m}$。這需要suffix仍可隨機索引；若原始n元素必先建成陣列，建表成本不能漏算。

隨機優先值排序：條件與碰撞

給每個元素獨立均勻優先值Pi∈{1,⋯,M}，再依Pi排序。條件於所有Pi不同，由標籤交換對稱性，n!種相對順序等機率；排序可用Θ(n lg n)比較時間與O(n)儲存優先值。

每對碰撞機率1/M，union bound給 $P(\exists i<j: P_i=P_j)\le \binom{n}{2}/M$。取M=$n^3$、n≥2時≤(n−1)/(2$n^2$)<1/(2n)。這使碰撞很少，沒有使它不可能。

若平手保留原順序，無條件分布仍有偏差。n=2時，第一元素先出的機率P(P1≤P2)=(M+1)/(2M)>1/2。可遇任何碰撞就整組重抽，接受事件的標籤對稱性保證均勻；此M下期望重抽輪數有常數界。也可對每個平手群再作均勻洗牌。原地SHUFFLE則一開始就避免這個條件缺口。

隨機化把期望保證移到每個固定輸入

RANDOMIZED-HIRE先SHUFFLE，再執行HIRE。對任何固定的相異排名輸入，洗牌輸出是均勻排名排列，故期望雇用數Hn，期望費用nci+chHn；另有Θ(n)洗牌操作，不能把時間與雇用費混成同一單位。

若候選人只能依外部到達順序面試、不能重新安排，則無法執行這個洗牌步驟。此時Hn仍需輸入順序的分布假設，不能假裝內部亂數已控制外部到達。

本章的隨機洗牌、隨機pivot在每條亂數路徑都維持答案正確，隨機的是成本；這類通常稱Las Vegas。容許小機率錯答的Monte Carlo需另給錯誤機率及其量詞，期望時間本身不會提供正確率。

5.4 Probabilistic analysis and further uses of indicator random variables

本節四種模型各有不同隨機變數：生日問題數碰撞對或碰撞是否存在；balls and bins數負載及等待時間；streak數視窗及最長長度；線上遴選數選到最佳者的成功機率。期望、機率與最大值不可互換。

會用三個可自足推出的工具：事件聯集的指示至多等於各事件指示之和，所以P(∪Ei)≤ΣP(Ei)；非負X滿足X≥tI(X≥t)，所以Markov界P(X≥t)≤E[X]/t；非負整數L恰為Σj≥1 I(L≥j)，所以 $E[L]=\sum_{j\ge 1}P(L\ge j)$。本章有限和情況可直接交換；幾何等待的無限和由非負部分和單調極限得到。

使用獨立性時會明指哪組試驗互相獨立，不把相鄰且重疊的視窗誤乘。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

生日問題：碰撞事件的精確機率

k個人各自獨立均勻抽n種日期，n≥1。k≤n時，前j人皆不同的條件下，第j+1人有n−j個可選不碰撞日，所以

$$P(\text{皆不同})=\prod_{j=0}^{k-1}(1-j/n),\qquad P(\text{有碰撞})=1-\prod_{j=0}^{k-1}(1-j/n).$$

k=0、1時無碰撞；k>n由鴿籠原理必碰撞，直接為1，不延伸乘出負因子。對2≤k≤n，1−x≤e^(−x)給P(皆不同)≤e^(−k(k−1)/(2n))，故k(k−1)≥2n ln2是碰撞機率至少1/2的一個充分條件。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

生日問題：對數的期望不是事件機率

對每對i<j，Iij表示日期相同。獨立且均勻使P(Iij=1)=Σr (1/n)²=1/n，故碰撞對數X的期望為 $E[X] = \binom{k}{2}/n$ 。不需要各個Iij互相獨立。

事件有碰撞是X≥1，Markov僅給P(X≥1)≤E[X]；E[X]≥1不能一般推出P(X≥1)≥1/2。例X以1/M機率等於M²，否則0，則期望M很大，正值機率卻很小。

獨立均勻日期模型同時有精確補集公式與此期望。取k=o(√n)，由union bound機率趨0；取k≥C√n、C足夠大，指數補集界給固定正的碰撞機率。這才把事件門檻證成√n量級。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

十六種日期的完整數例

n=16、k=5時，皆不同機率為15・14・13・12/16⁴=4095/8192，碰撞機率4097/8192≈0.500122；碰撞對數的期望卻是10/16=5/8。兩個值回答不同問題。

指數補集上界在k=5只給e^(−10/16)>1/2，尚不能證明超過半數；k=6時才給e^(−15/16)<1/2。充分上界不必恰好找出精確門檻。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

十六種日期的完整數例 (續)

同一日期樣本與整個機率模型：樣本計數和期望要分開



本次唯一碰撞對：(2,4)

模型：16日 · 5人。P(有碰撞)=4097/8192≈0.500122。

E[碰撞對數]=10/16=5/8；這個期望不是上面的事件機率。

若只有均勻邊際，日期可全等於同一隨機Z，碰撞機率是1，單對也不是1/n。若只有兩兩獨立，單對期望仍成立，但不能直接乘出全體無碰撞機率。

兩兩獨立與完全獨立的差異

令U,V獨立均勻於{0,1,2}，三人的日期為B1=U、B2=V、B3=2U−V mod3。任取兩個日期都能唯一還原U,V，所以各對均勻於9種有序組合，兩兩獨立。

但U=V時三人同日，共3種；U≠V時三個日期皆不同，共6種。因此有碰撞的機率1/3，與三個完全獨立日期的1−3・2・$1/3^3$=7/9不同。兩個模型的碰撞對期望都為3・(1/3)=1：前者以1/3機率出現3對，後者則有不同分布。

此反例顯示：計E[X]用兩兩獨立已足夠；精確無碰撞連乘是更強的聯合資訊。不能由相同的期望反推相同分布。

Balls and bins：負載、空桶與單球桶

t顆球各自獨立均勻投入b≥1個桶。固定桶負載N是t個落入該桶的指示和，E[N]=t/b；且

$$P(N=r)=\binom{t}{r}(1/b)^r(1-1/b)^{t-r}.$$

令Z0為空桶數，Z1為恰有一球的桶數，則E[Z0]=b(1−1/b)^t、E[Z1]=t(1−1/b)^(t−1)，後者t≥1。t=0直接Z0=b、Z1=0；b=1的退化情況依直接事件判斷，或採0^0=1的有限乘積慣例。

t=b=4時E[N]=1，E[Z0]=4(3/4)^4=81/64，E[Z1]=4(3/4)^3=27/16。各桶負載不獨立，因總和固定t；平均一球也不表示每桶各一球。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

幾何等待與收集所有桶的期望

固定桶每次命中率1/b，等待T至少t次才命中的尾式為P(T>t)=(1−1/b)^t，因此E[T]=Σt≥0 P(T>t)=b。這需要各次投球獨立。

收集所有桶時，已見i個不同桶後，下一顆命中新桶的機率(b−i)/b，等待時間Ti的期望b/(b−i)。不論各階段如何相關，線性性給

$$E[C]=\sum_{i=0}^{b-1}E[T_i]=b\sum_{j=1}^{b}1/j=bH_b=\Theta(b\ln b)\quad(b\geq 2).$$

b=1時C=1。b=4各階段期望1、4/3、2、4，總25/3。這是等待時間的期望，不是到第25/3球才一次全部出現。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

幾何等待與收集所有桶的期望 (續)

四桶的收集過程：同一桶重複命中會留在原狀態

狀態 = 已見不同桶數；每次命中新桶才前進。



一次實際投球：2,2,4,1,4,3；新增桶在第1,3,4,6球。
各階段期望相加：1+4/3+2+4=25/3；不是固定停止時刻。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

覆蓋機率與第一次碰撞是不同時間尺度

投完整數t球，任一指定桶仍空的機率(1−1/b)^t≤e^(−t/b)。union bound給 $P(C > t) \leq be^{-t/b}$。因此t≥b(ln b+c)時未集滿機率≤e^(−c)，不需空桶事件獨立。

若改問首次有桶收到第二球的時間D，則P(D>k)正是前k球皆不同，回到生日問題。上界P(D>k)≤e^(−k(k−1)/(2b))。k≥2時k(k−1)≥k²/2，因此尾和E[D]≤2+Σk≥2 e^(−k²/(4b))≤2+∫0^∞ e^(−x²/(4b))dx=2+√(πb)。對k≤√b/2，union bound給碰撞率≤k(k−1)/(2b)≤1/8，因此前Θ(√b)個尾機率至少7/8，給Ω(√b)。

所以第一次碰撞期望Θ(√b)，集滿期望Θ(b ln b)。這兩個停止條件不同，不能把同一個balls/bins名稱當成同一個答案。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Streak：視窗次數與最長長度

獨立公平擲硬幣n次，L為最長連續H長度；無H時L=0。對$1 \le k \le n$，令Aik表示從i開始的k格全H，合法起點1..n−k+1。P(Aik)=2^(−k)，所以k視窗數Xk的期望為(n−k+1)/2^k。

相鄰視窗可重疊，並不獨立。例如A1,3與A2,3同時成立需前4格H，機率1/16，不是$(1/8)^2$。E[Xk]仍可相加；但P(L≥k)=P(∪i Aik)只能由聯集或其他聯合分析求。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Streak：視窗次數與最長長度 （續）

同一段四連 H 會包含兩個長3視窗，不能當成獨立事件



長3全H視窗：起點1、5、6，共3個。

最長run：5..8，長度4。

重疊視窗可同時成立；第5與第6視窗共享兩次擲幣。

這個實際序列在i=1、5、6各有長3全H視窗，共3個；第二段四連H會貢獻兩個視窗，不是兩段互不相交的run。最長L=4，不是視窗數3。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

最長 streak 的一般上界與尾界

union bound給P(L≥k)≤min(1,n・2^(−k))。令k0=⌈lg n⌉，利用整數尾和，n≥1時

$$E[L] = \sum_{k=1}^{n} P(L \ge k) \le k_0 + \sum_{k=k_0+1}^{\infty} n2^{-k} = k_0 + n2^{-k_0} \le \lceil \lg n \rceil + 1.$$

對任何r≥1，門檻k=⌈r lg n⌉給P(L≥k)≤n^(1−r)。例如n=1000、k=20時精細union bound是981/2^{20}<1/1000；k=30時≤1000/2^{30}<10^(−6)。這是單次執行的尾機率保證，比只給期望更有資訊。

n=0直接L=0，不在lg n式中代0；若k>n則事件不可能、機率0。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

下界要利用不重疊的獨立區塊

對充分大n，取s=⌊(lg n)/2⌋≥1，m=⌊n/s⌋，切出m個互不重疊的長s區塊，剩餘不足s格不使用。每塊全H機率2^(−s)≥1/√n，且不同塊用到不同的獨立硬幣，事件互相獨立。

$$P(L < s) \le (1 - 2^{-s})^m \le e^{-m2^{-s}} \le e^{-m/\sqrt{n}} \longrightarrow 0,$$

因m=Θ(n/lg n)，m/√n→∞。因此E[L]≥sP(L≥s)=Ω(lg n)。與前頁上界合併得Θ(lg n)。只有「重疊視窗期望很多」不足以證這個下界；本證明真正取得至少一塊成功的高機率。

例n=16，取s=2、m=8，至少一個獨立二格區塊全H的機率1−(3/4)^8=58975/65536，因此E[L]≥2・58975/65536。這只是可核對的有限下界，不是L的精確期望。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

線上遴選的完整模型與程序

n≥2位候選人能力相異，順序均勻隨機；每次只能比較已見者，拒絕後不能召回，只能雇用一次。選定整數1≤k<n，先拒絕前k位並記其最高分M；之後第一位超過M者就雇用；若始終沒有，雇用最後一位。

```
ONLINE-SELECT(n,k):
    M = -infinity
    for i = 1 to k: M = max(M, score(i))
    for i = k+1 to n:
        if score(i) > M: return i
    return n
```

這個M不必在第二個迴圈更新：在第一次超過M前，所有已見分數皆≤M；第一次超過時立即返回。已知n、均勻順序、相異分數與無召回是分析前提，不是在任意到達分布下都保證1/e。

選到最佳者的成功機率：以條件機率證明

設最佳者在位置i。i≤k一定失敗；i>k時，它能被選到若且唯若前i−1人的最高者在前k位：若最高者在後段較早位置，就早已觸發返回；反之在i前都不會超過M。

P(最佳者在i)=1/n。條件於此事，前i−1人的相對順序仍均勻，最大者位置均勻，所以成功條件機率k/(i−1)。不同i互斥，得

$$P_k = \sum_{i=k+1}^{n} \frac{1}{n}\frac{k}{i-1} = \frac{k}{n}\sum_{j=k}^{n-1}\frac{1}{j}.$$

這個條件式已完整證明，不需未經證明便斷言兩事件獨立。n=1直接選唯一者、成功率1；k=0另定義為直接選第一人、成功率1/n，不把0乘未定義的調和項。

有限 n 的最佳門檻與 1/e 極限

令qk=Σj=k..n−1 1/j。精確差分為 $P_{k+1}-P_k=(q_{k+1}-1)/n$。qk嚴格下降，因此最佳門檻在qk≥1、q(k+1)≤1的位置；若恰等1可能有相鄰並列最大，不是每個n都恰好n/e。

對k≥1，積分夾界給 $\ln(n/k)\le q_k\le \ln(n/k)+1/k$，所以

$$\frac{k}{n}\ln\frac{n}{k}\le P_k\le \frac{k}{n}\ln\frac{n}{k}+\frac{1}{n}.$$

令x=k/n，f(x)=x ln(1/x)，f'=ln(1/x)−1，f''=−1/x<0，最大在x=1/e。取k在n/e附近的整數，f(k/n)=1/e−O(1/n)，成功率至少1/e−O(1/n)，且最優成功率≤1/e+1/n，故極限1/e。此界無多餘的1/k因子。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

六人的門檻與逐人選取都算出來

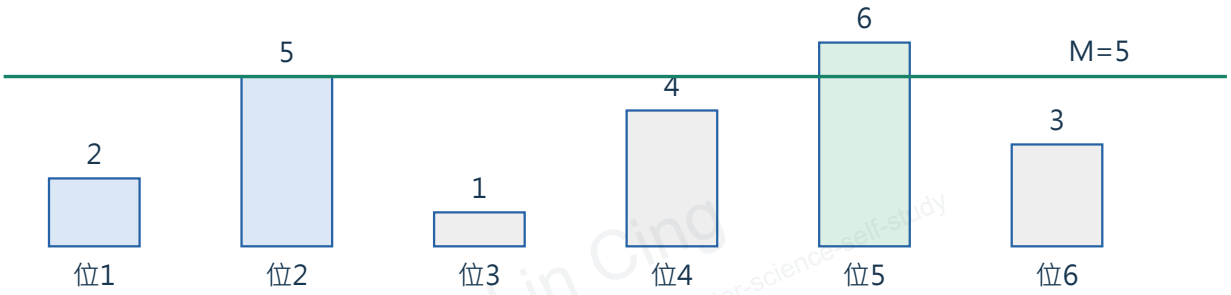
n=6，各門檻精確成功率：k=1為137/360，k=2為77/180，k=3為47/120，k=4為3/10，k=5為1/6。q2=77/60>1、q3=47/60<1，故k=2最優。

排名[2,5,1,4,6,3]，前兩人拒絕並得到M=5；位置3的1、位置4的4都未過門檻；位置5的6過門檻，立即選取，位置6不必面試。這次選到全域最佳，但換一個排列可能失敗。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

六人的門檻與逐人選取都算出來 （續）

排名 [2,5,1,4,6,3]：取樣最高5，第5人首次超越門檻



失敗例[5,6,1,2,3,4]的最佳6在取樣段已拒絕，後段無人超過M=6，最後依規則選4；此例說明正確執行策略不等於每次都成功。

延伸：隨機遞迴分割的條件式

大小n≥2的工作先輸出n個星號，均勻選p∈{1,⋯,n−1}，遞迴處理p與n−p；大小1輸出一個驚嘆號後停止。令Ln、Sn分別為驚嘆號與星號的期望，L1=1、S1=0。

固定p後，兩段成本相加；再對所有p取條件期望，得到

$$L_n = \frac{2}{n-1}\sum_{j=1}^{n-1} L_j, \qquad S_n = n + \frac{2}{n-1}\sum_{j=1}^{n-1} S_j.$$

每次分割保存大小總和，終止葉的大小都是1，因此每一棵執行樹恰有n葉，Ln=n不只是均值。高度與星號數仍可能隨p變；把「極端pivot可成鏈」誤當葉數也變動，混淆了不同樹量。

隨機分割的完整封閉式

Ln的強歸納：假設j<n皆Lj=j，代入得2/(n−1)・n(n−1)/2=n。對Sn，寫成(n−1)Sn=n(n−1)+2Σj<n Sj，再將n+1式減去此式，得到

$$S_{n+1} = 2 + \frac{n+1}{n} S_n.$$

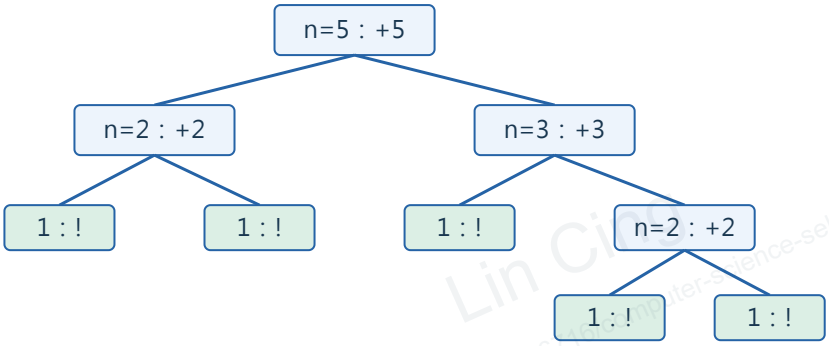
令Qn=Sn/n，則Q(n+1)=Qn+2/(n+1)。由Q1=0，累加得Qn=2Hn−2，故Sn=2n(Hn−1)=Θ(n ln n)。這是期望，不是每條路徑的固定成本。

n	每次執行葉數	E[星號數]
2	2	2
3	3	5
4	4	26/3
5	5	77/6
6	6	87/5

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

隨機分割的完整封閉式 (續)

五個單位葉完整展開：守恆的是葉數，不是星號成本



本次葉數=5

本次星號=12

E[星號]=77/6

+數字：本輪星號

! : 一個驚嘆號

圖示 p=2、之後 3=1+2；葉數始終5，但星號總數會隨分割而變。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

延伸：隨機 Quicksort 的期望比較數

鍵相異時，對每個大小≥2的子問題，獨立均勻選一個元素作pivot，將其餘元素各與pivot比較一次，分入小於與大於兩組，遞迴排序兩組後串接。基例大小0、1直接回傳。兩組的鍵序與遞迴歸納保證排序正確；此處分析鍵比較數，不含複製、配置及亂數成本。

把鍵按值記z1<⋯<zn，Iij表示zi,zj是否直接比較。每對最多比較一次：只有其中一個作pivot時可能比較，之後pivot被移出。可等價地先均勻產生所有鍵的優先順序，每個子問題選其中最早者為pivot；剩餘鍵的相對順序仍均勻，故等價於各子問題均勻抽pivot。區間zi..zj中最早者因此均勻於該區間；區間外的pivot只會把此整段完整留在同一child，不會先分開這對。

若第一個是兩端便比較；若是中間便永遠分開。因此P(Iij=1)=2/(j−i+1)，總比較數X=Σi<j Iij。

Quicksort 的和式、數值與邊界

按距離d=j−i分組，距離d共有n−d對，得到

$$E[X] = 2\sum_{d=1}^{n-1} \frac{n-d}{d+1} = 2\sum_{r=2}^{n} \left(\frac{n+1}{r} - 1 \right) = 2(n+1)H_n - 4n.$$

n=5時2(4/2+3/3+2/4+1/5)=37/5；n=2,3,4,6則依序1、8/3、29/6、103/10。若分割每個元素僅作常數工作，總時間Θ(n+X)，期望Θ(n lg n)。極端pivot序列仍需n(n−1)/2次比較；高機率時間界還需要另外證明，不能由期望自動推出。

相異鍵或明確的重複鍵處理是必要條件。二路Lomuto把所有相等鍵送到同一側時，隨機pivot也不能避免全等輸入的平方退化；第7、9章的三路分割另處理此問題。本節不能把相異鍵的成對機率直接移植過去。

資料來源

書目

章節來源

Cormen, Leiserson, Rivest, Stein. *Introduction to Algorithms*, 3rd ed., MIT Press, 2009，Chapter 05。

Cormen et al., *Introduction to Algorithms*, 3rd ed., §§5.1-5.4 and 7.1.

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

參考資料與署名

Thomas H. Cormen, Charles E. Leiserson, Ronald L. Rivest, Clifford Stein. Introduction to Algorithms, 3rd Edition.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study