09 中位數與次序統計量

Part II Sorting and Order Statistics

本章定位

選擇問題只需找特定秩，不必先把全部資料排序。本章從極值的精確比較帳出發，統一三路分割與局部秩，完整證明隨機選擇的期望線性時間，再以五元素組的實際排除證據推導最壞線性保證。

前置知識

選擇問題、partition 與機率分析。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

本章路線

學習目標

- 以 ceil(3n/2)-2 次比較同時找最小與最大並證明最壞下界。
- 分析隨機 select 的期望線性時間。
- 用分組中位數建立最壞情況線性選擇。
- 9.1 Minimum and maximum
- 9.2 Selection in expected linear time
- 9.3 Selection in worst-case linear time

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

9.1 Minimum and maximum

第k小指把輸入多重集合排序後第k個值，k採1-index、1≤k≤n。重複鍵佔不同位置但可回傳相同值；偶數n的lower median採k=⌊n/2⌋，不必是中間兩值的算術平均。本章鍵必須可全序比較，空輸入或非法k應在入口拒絕。

找minimum的線性掃描維持「目前min是已讀前綴的最小值」，每讀一筆只與min比，共n−1次。下界：除真正minimum外，每個identity都必須至少在一次比較中被證明大於別人；一次比較至多使一個identity首次失去minimum資格，故至少n−1次。Maximum對稱。

同時找兩者不必分開花2n−2次。每對先比出小者和大者，小者只挑戰min，大者只挑戰max。偶數n先用一次比較初始化前兩筆；奇數n先把第一筆同時設為min/max。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

成對處理的完整比較帳

例[14,3,9,1,8,5,12,6]。首對14與3用1次，min3/max14。之後每對用「組內1次、min1次、max1次」。

新的一對	組內結果	min比較後	max比較後	累積次數
14,3	小3、大14	3	14	1
9,1	小1、大9	1	14	4
8,5	小5、大8	1	14	7
12,6	小6、大12	1	14	10

偶數n：1+3(n−2)/2=3n/2−2。奇數n：3(n−1)/2。統一為⌈3n/2⌉−2，n=1時0次。每對處理後min/max涵蓋更長前綴，初始化、保持與終止證明和單掃描相同，但比較資訊被兩個目標共用。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

同時找極值的最壞下界

以下對相異鍵使用可維持一致全序的adversary（對手）回答。每筆初有minimum與maximum兩個候選資格；結束只剩真正min的min資格與真正max的max資格，要消去2n−2個資格。

兩個從未比較的鍵相遇時，可一次消去兩個資格：較大者失去min、較小者失去max。這種比較至多⌊n/2⌋次。其餘比較，對手可讓至多一個新資格消失：

比較前狀態	回答規則
兩者都只可能是max	比出一個較大，消去另一個max資格
兩者都只可能是min	比出一個較小，消去另一個min資格
一個只可能max、一個只可能min	回答前者較大，兩者都不失去資格
有一個從未比較	選結果只消去它的一個資格；另一個至多不新增損失

已失去兩種資格的鍵不可能再造成雙重消去。規則相容於目前比較的偏序：仍可能max的鍵從未輸過，仍可能min的鍵從未贏過，讓前者大於後者不會造成有向循環；未比較鍵沒有既有約束。

若共做c次，最多消去c+⌊n/2⌋個資格，故c≥2n−2−⌊n/2⌋=⌈3n/2⌉−2，成對法達到最壞比較數下界。

Tournament還保留了第二小的候選

找minimum的比較可組成平衡淘汰賽，並保存每個winner直接打敗的鍵。第二小只可能在minimum直接打敗的清單中：任何未直接輸給minimum的鍵，都輸給了另一個比它小的非minimum鍵，不能是第二小。

8鍵例的第一輪winner為3、1、5、6，第二輪1、5，第三輪1。冠軍1直接打敗9、3、5，故第二小為這三者的minimum=3。淘汰賽7次、清單再2次，共9次。

一般$n \geq 2$用平衡賽程（不足可安排bye，不與虛構值比較），總比$n-1$次；冠軍實際對手$d \leq \lceil \log_2 n \rceil$，清單再$d-1$次，所以最壞至多$n+\lceil \log_2 n \rceil-2$。這裡鍵相異，或用(key,identity)打破平手來定義第二個identity。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

9.2 Selection in expected linear time

Select只遞迴含答案的一側，而quicksort遞迴兩側。要處理重複鍵，本章統一使用三路partition；陣列索引p..r採0-index，但傳入k永遠是「目前子陣列內第k小」的1-index局部秩。

```
partition3(A,p,r,x):
    lt=p; i=p; gt=r
    while i<=gt:
        if A[i]<x: swap(A[lt],A[i]); lt++; i++
        elif A[i]>x: swap(A[i],A[gt]); gt--
        else: i++
    return lt,gt
```

迴圈前A[p..lt−1]<x、A[lt..i−1]=x、A[i..gt]未知、A[gt+1..r]>x。小鍵交換後擴小區與等值區；大鍵從gt換來的是未知鍵，所以i不能前進；等鍵只擴等區。未知區長gt−i+1每輪減1，必終止，且交換保留多重集合。結束得到完整三區，區內未必排序。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

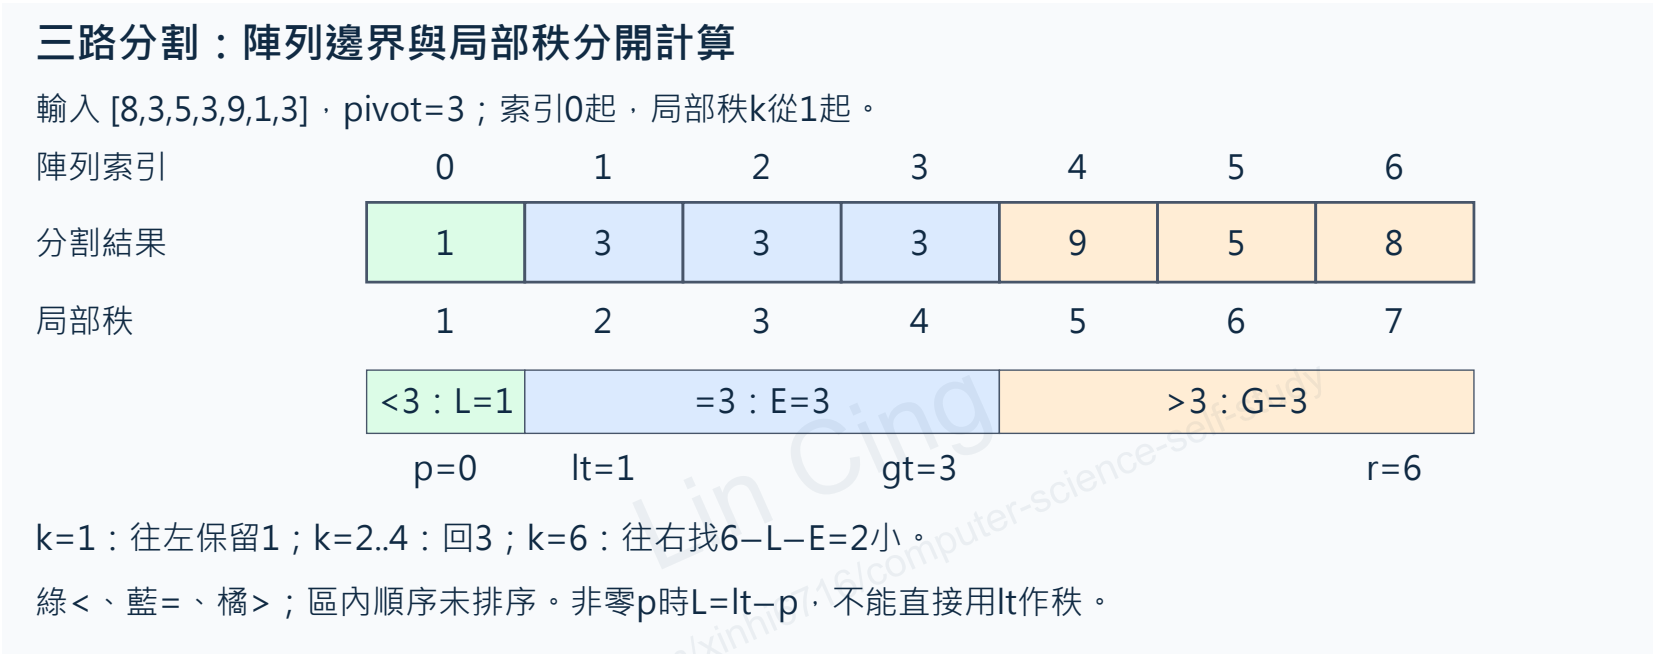
局部秩只在往右時扣除兩個區

```
select-random(A,p,r,k):
    assert 1<=k<=r-p+1
    while p<r:
        x=A[uniform-integer(p,r)]
        lt,gt=partition3(A,p,r,x)
        L=lt-p; E=gt-lt+1
        if k<=L: r=lt-1
        elif k<=L+E: return x
        else: k-=L+E; p=gt+1
    return A[p]
```

選pivot是目前某個實際鍵，所以$E \geq 1$。左分支有$k \leq L$，右分支有$1 \leq k-L-E \leq r-gt$，遞迴不可能落空區；各次規模至少少E筆。回傳等值區時，排序後的局部秩$L+1..L+E$全是x。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

局部秩只在往右時扣除兩個區 （續）



此圖A=[8,3,5,3,9,1,3]、x=3得到L=1、E=3、G=3。k=4落等值區直接回3；k=1進左側仍找第1小；k=6進右側找第6−1−3=2小。不要將「原陣列絕對位置」與「目前子區間的局部秩」混用。另一例[3,3,1,3,2,3]可得[1,2,3,3,3,3]，等值閉區間(lt,gt)=(2,5)。

一個需要繼續往右的數例

A=[7,2,9,4,5]找第3小。若先取x=2，分成小區空、等值[2]、大區含[7,9,4,5]，L=0、E=1；往右必須改找第3−1=2小，不能仍找第3小。

若下一次選x=5，右側大區再分成小區[4]、等值[5]、大區[7,9]，局部L=1、E=1，k=2落等值區，回5。每輪只保留含答案的區塊，無須把被丟棄區內部排好。

全等[5,5,5,5,5]只掃一次、等值區涵蓋全部，Θ(n)結束。若改回二路Lomuto的≤版本、找最小秩，每次q=r，正好做4+3+2+1=10次pivot鍵比較；隨機挑哪個5都不能改變這個$\Theta(n^2)$退化。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

期望線性的完整代入證明

每次條件於目前陣列，pivot均勻取自各identity，未來選取亦保持條件均勻。先用相異鍵看pivot秩R：R均勻1..n，下一個子問題長度至多m_R=max(R−1,n−R)。

令F(A,k)是該狀態剩餘的期望時間。歸納假設所有較短狀態F(B,j)≤a|B|，本層掃描與固定開銷≤cn。條件於pivot後套歸納，不必假設未知T(n)單調或拆開相依隨機變數：

`F(A,k) ≤ cn+(a/n)Σ_(r=1)^n max(r−1,n−r)`。

n=2h時，此和/n=(3h²−h)/(2h)=3n/4−1/2；n=2h+1時為(3h²+2h)/(2h+1)≤3n/4。因此F≤(c+3a/4)n≤an，只需a≥4c並涵蓋n=1基例，O(n)歸納成立。初次必掃n筆給Ω(n)，故期望Θ(n)。

不能直接寫E[T(n)]≤E[T(3n/4)]+cn當成已證事實；單次pivot可能極差，這裡是對所有可能秩的後續成本平均。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

重複鍵與最壞情形的界線

三路版本的同一證明可包含重複鍵：只為分析替相等鍵附上固定identity次序，建立唯一秩R，實際partition仍只比較鍵。若答案在<x側，其長度≤R−1；若在>x側，其長度≤n−R；若在=x側立刻終止。因此每種pivot identity仍有同一個m_R上界，平均歸納照用，不需要真的排序identity。

最壞執行仍可$\Theta(n^2)$：相異鍵、找minimum、每次剛好抽到最大鍵，規模依序n,n−1,⋯。這事件雖小但可能，不能以期望線性取代最壞保證。迭代式不保留遞迴frame；原地partition加固定變數只需O(1)額外空間。

研究中位數或Top-k時，排序是可行的O(n log n)方法，但不是必要成本。Select回傳一個次序統計量不會同時交付完整排序，故不受排序Ω(n log n)下界限制。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

9.3 Selection in worst-case linear time

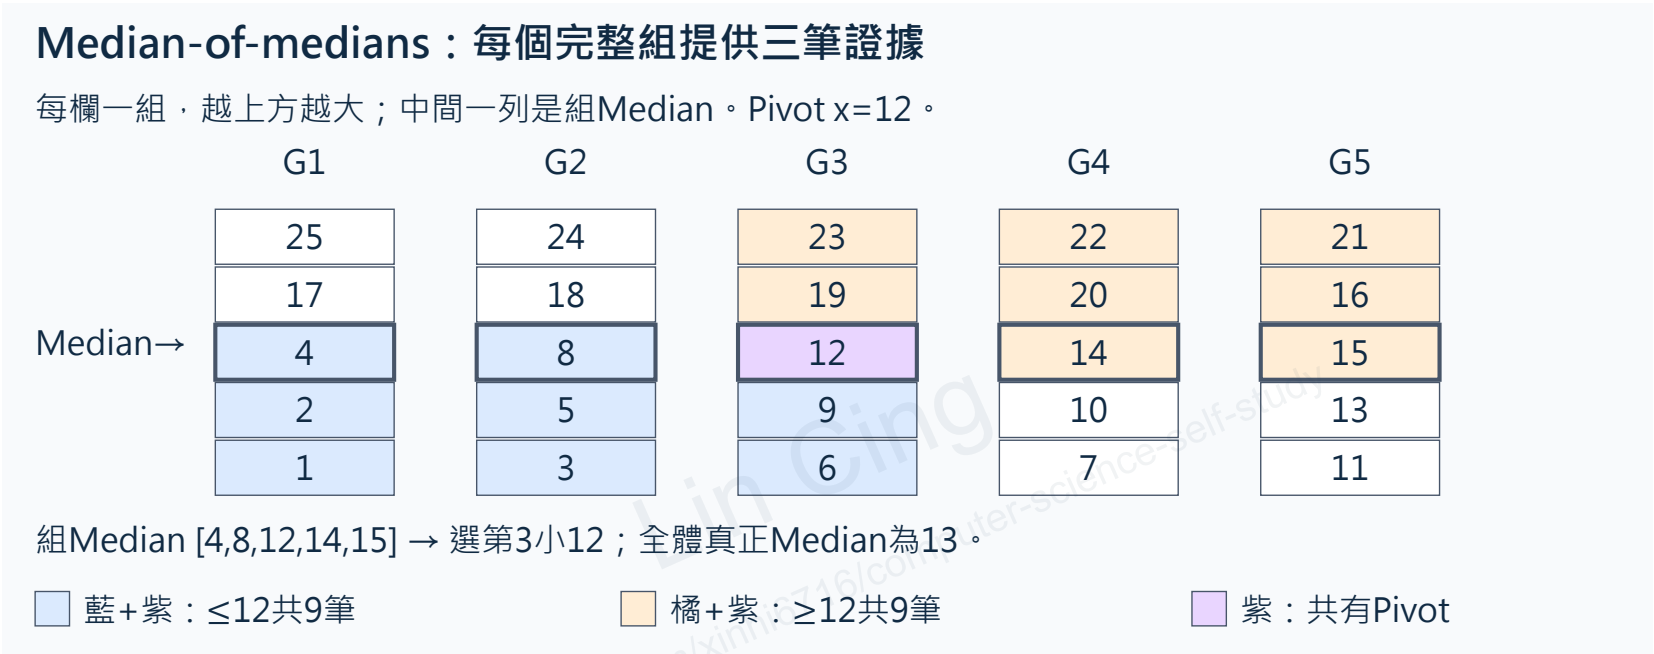
Deterministic select以median-of-medians挑pivot：n≤5時直接排序回第k小；否則按目前位置每5筆一組，最後可不足5筆。各組排序取lower median，再遞迴select這g=⌈n/5⌉個median的第⌈g/2⌉小作x。

以x做同樣的三路partition，若k落等值區回x，否則只遞迴嚴格小側或大側、依前頁規則換算局部秩。這次用來挑pivot的遞迴與用來找答案的遞迴，都必須納入成本。

各組至多5筆，排序每組O(1)，全部O(n)。x必是原輸入中的值，E≥1，故演算法正確與終止仍由相同分割不變量和長度歸納保證；效率另靠以下排除數量證明。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

五元素組如何提供排除證據



原創25筆的五組排序後如圖，組median為[4,8,12,14,15]，median-of-medians是12，不是全體真正median=13。它只需讓兩側足夠小，不必一次找到目標。

圖中m≤12的前三組，每組下面三個值都≤12；m≥12的後三組，每組上面三個值都≥12。這些是可逐格核對的9筆證據，兩組證據在pivot處重疊沒有問題，因分析的是兩個互斥遞迴分支。

五元素組如何提供排除證據 （續）

若值有重複，保證是≤x/≥x，不一定嚴格；三路版本遞迴嚴格區時，整個等值區一併排除，所以此非嚴格證據仍能控制子問題大小。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

取整、殘組與線性時間歸納

至少[g/2]個組median≥x，也至少[g/2]個≤x（g偶數採lower median仍滿足）。保守扣掉可能不足5筆的殘組、以及含所選pivot identity的那組，剩至少[g/2]−2個完整組，每組提供3筆對應的非嚴格大小證據。

因此每一側能被排除至少$3([g/2]-2) \ge 3n/10-6$筆；嚴格遞迴區至多7n/10+6筆。當右式排除下界為負時只是無資訊的保守界，不代表演算法真的擴大問題。

令非遞迴工作≤cn。歸納假設較短輸入時間≤an，對n≥140有

$T(n) \le a\lceil n/5\rceil + a(7n/10+6) + cn \le (9a/10+c)n + 7a$。

若a≥20c，則a/10−c≥a/20，而n≥140給(a/10−c)n≥7a，故T(n)≤an。有限的1≤n<140狀態可藉增大a涵蓋；140是證明門檻，不要求實作真的把140筆全部當base排序。兩個遞迴的規模都小於n，歸納有效。初次處理n筆又給Ω(n)，合為最壞Θ(n)。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

同一個第16小的完整選擇路徑

本例用保留掃描順序的L/E/G列表呈現，方便讀者核對；原地三路交換可有不同區內排列，但區長與rank換算相同。

當前n,k	分組median→所選x	L,E,G大小	下一步
25,16	[4,8,12,14,15]→12	11,1,13	大區找第4小
13,4	[19,20,16]→19	6,1,6	小區找第4小
6,4	[15,16]→lower median15	2,1,3	大區找第1小
3,1	base排序[16,17,18]	—	回16

第一次大區依序[17,25,18,24,19,23,14,20,22,13,15,16,21]，分5、5、3筆得到median19、20、16。接著小區[17,18,14,13,15,16]，前5筆median15、殘組median16；x=15之後大區為[17,18,16]。最後得到16，與完整排序只作驗算的第16格一致。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

組大小改變時，證明也要改

若用固定奇數組大小s=2t+1，理想化大n時每半組median提供t+1筆排除證據，兩個遞迴的規模比例和約 `1/s + (1−(t+1)/(2s)) = 1+(1−t)/(2s)`。

s=5時t=2，和9/10<1，才有線性代入的餘裕；s=7時和6/7<1也可線性，但常數與殘組需重算。s=3時和1，只由這個粗界得到T(n)≤T(n/3)+T(2n/3+O(1))+O(n)，可證O(n log n)，卻不能單憑上界遞迴式斷言實際演算法必然Ω(n log n)。若主張非線性，需要能讓壞分割跨遞迴層持續發生的額外達界證明。

基礎實作用列表保存分組、median與L/E/G，峰值額外空間O(n)，因沿任一尚未返回的遞迴路徑規模幾何縮小；要宣稱原地O(1)空間，還需另設計median搬移與遞迴stack管理，本章不把這項額外保證混入時間定理。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

資料來源

書目

章節來源

Cormen, Leiserson, Rivest, Stein. *Introduction to Algorithms*, 3rd ed., MIT Press, 2009，Chapter 09。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

參考資料與署名

Thomas H. Cormen, Charles E. Leiserson, Ronald L. Rivest, Clifford Stein. Introduction to Algorithms, 3rd Edition.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study