C 計數與機率

Part VIII Appendix

本章定位

從sample object與統一分母建立計數、條件機率、Bayes及指標分析，再推完整geometric/binomial矩與尾界；明定獨立層級、零機率/支撐邊界及中心化r和總門檻t的區別。

前置知識

排列組合、機率公理與隨機變數。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

本章路線

學習目標

- 用乘法、加法與補集計數。
- 計算期望與變異數，處理幾何與二項分布。
- 以 Chernoff bound 約束二項尾機率。
- C.1 Counting
- C.2 Probability
- C.3 Discrete random variables
- C.4 The geometric and binomial distributions
- C.5 The tails of the binomial distribution

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

C.1 Counting

先定「一個結果」包含哪些資訊，再計數。sum rule要求互斥分類；product rule要求每個prefix後的選擇數已知。選擇集合可依先前結果改變，只要每層分支數固定，仍可相乘；若分支數不固定就逐branch加總，不能硬乘平均。

原創例：從6名學生選兩個不同職位，第一職6選、第二職5選，共30；若只是兩人committee、不分職位，每組被計兩個先後，除2得15。若允許同一人兼任，則變6^2=36。三個答案對應三種不同sample object。

長m、alphabet大小q的strings有q^m，允許重複且保位置。substring須連續，subsequence可跳位置；同一內容在不同起點是否算不同，必先約定。長n字串的長k≥1位置型substrings有max(0,n−k+1)個，不等於不同內容種類數。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Permutations、combinations與不重複計數

相異n筆全部排列有n!；ordered選k筆無重複有P(n,k)=n!/(n−k)!，0≤k≤n。unordered k-subset每組恰對應k!個ordered結果，故$\binom{n}{k}$=n!/[k!(n−k)!]。k0唯一空選擇，$\binom{n}{0}$=1；k<0或k>n可擴充定為0。

若records可區分但keys重複，排列records仍n!；若只看key字串、各multiplicity為$m_1, \ldots, m_s$，則每key字串對應$\prod m_i!$種identity排列，故有$n!/\prod m_i!$個不同key字串。除法前須證每個結果被重複相同次數。

$\binom{n}{k}$=$\binom{n}{n-k}$由取補集bijection得。Pascal identity $\binom{n}{k}$=$\binom{n-1}{k}$+$\binom{n-1}{k-1}$，依某個指定元素不在／在subset分為兩個互斥且完備的類別。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study/

二項式展開與entropy界的來源

展開$(x+y)^n$時，每個factor選x或y；恰k個位置選x共有$\binom{n}{k}$種，故$(x+y)^n=\sum_{k=0}^{n}\binom{n}{k}x^k y^{n-k}$。x=y=1得$\sum\binom{n}{k}=2^n$，這也是按subset大小分類的計數。

對1≤k≤n，$\binom{n}{k}=\prod_{j=0}^{k-1}(n-j)/(k-j)\geq(n/k)^k$，因n≥k使每個factor≥n/k。上界$\binom{n}{k}\leq n^k/k!\leq(en/k)^k$，最後用$k!\geq(k/e)^k$。

另令α=k/n∈(0,1)，展開$(\alpha+1-\alpha)^n=1$，其中一項非負且≤1，故$\binom{n}{k}\leq\alpha^{-k}(1-\alpha)^{-(n-k)}=2^{nH(\alpha)}$，H(α)=−α lgα−(1−α)lg(1−α)。端點以0lg0=0連續延伸，$\binom{n}{0}=\binom{n}{n}=1$。H′=lg((1−α)/α)，最大在1/2，值1。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

C.2 Probability

sample space S的elementary outcome是一個完整可區分結果，event是合法可測子集。有限／可數離散情況本章取所有subsets為events；不可數情況須指定對補集與可數聯集封閉的event族，不能無條件把每個subset都當event。

機率滿足P(A)≥0、P(S)=1，以及對兩兩互斥的有限／可數events，有$P(\cup A_i) = \sum P(A_i)$。因此P(∅)=0、P($A^c$)=1−P(A)、A⊆B⇒P(A)≤P(B)。離散時$P(A) = \sum_{s \in A} P(s)$。

有限S只有在每個outcome等機率時才可P(A)=|A|/|S|。例如丟兩個公平且獨立的0/1 bits，四個ordered結果各1/4；把它們壓成「0、1、2個1」後三種計數不是等機率，而是1/4、1/2、1/4。

Lin Cing
https://github.com/xinhi6716/computer-scie

聯集、union bound與不需要的獨立性

由互斥分解A∪B=(A\B)⊔(A∩B)⊔(B\A)，P(A∪B)=P(A)+P(B)−P(A∩B)≤P(A)+P(B)。多事件定$B_1=A_1$、$B_i = A_i \setminus (\bigcup_{j<i} A_j)$，$B_i$互斥、聯集相同且$B_i \subseteq A_i$，故$P(\cup A_i) = \sum P(B_i) \le \sum P(A_i)$，可數版本也成立。

此union bound不需獨立；右側可大於1，實用時再取min(1,右側)。相反若要把$P(\cap A_i)$寫成$\prod P(A_i)$，必須有mutual independence，不能因為union bound不需獨立就混用。

例三個failure events各≤0.01，不論相關性，至少一個失敗機率≤0.03。若三個事件其實完全相同，聯集機率0.01而不是$1-0.99^3$；後式需要獨立前提。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Conditional probability與chain rule

P(A|B)=P(A∩B)/P(B)，要求P(B)>0；這是在保留B內outcomes後重新normalize。P(A∩B)=P(B)P(A|B)。反覆應用得$P(\cap_{i=1}^{n} A_i) = P(A_1)\prod_{i=2}^{n} P(A_i|A_1 \cap \ldots \cap A_{i-1})$，各conditional使用時須分母正；若某prefix機率0，整交集已為0，不能再寫未定義的比值乘積。

原創抽樣：袋中3藍2紅，無放回連抽兩球，P(兩藍)=(3/5)(2/4)=3/10；第二次藍的邊際仍3/5，但在第一次藍的條件下只有1/2，故兩次不獨立。若放回並重新均勻抽取，才是$(3/5)^2$。

知道「至少一事件發生」與知道「指定那一次發生」通常不同。描述觀測或篩選規則是機率模型的一部分，不可只看到剩兩種文字敘述就自動各給1/2。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Independence、互斥與pairwise的差異

A,B獨立指$P(A\cap B)=P(A)P(B)$，這個定義也涵蓋機率0 events；若$P(B)>0$才可等價寫$P(A|B)=P(A)$。互斥指交集空，若兩者機率皆正則不獨立。空event則與任意event獨立。

mutual independence要求每個有限子集合的交集機率都等於邊際乘積；pairwise只核每一對，不足以乘三個以上。

取U,V為公平獨立bits，W=U XOR V，outcomes(0,0,0),(0,1,1),(1,0,1),(1,1,0)各1/4。U,V,W每對的四種組合都各1/4，故pairwise independent；但$P(U=V=W=1)=0$，而三邊際乘積=1/8，非mutual。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Independence、互斥與pairwise的差異 (續)

同一張完整表：pairwise independent，非mutually independent

U	V	W=U XOR V	P(outcome)
0	0	0	1/4
0	1	1	1/4
1	0	1	1/4
1	1	0	1/4

任一對：00/01/10/11各1/4

三個邊際P(=1)都為1/2

但111根本不在sample space

$0 \neq (1/2)^3 = 1/8$

每對核對成立，不代表三者交集可直接乘邊際；這裡variance可加，三重乘積不可分。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Total probability與Bayes的分母

若B_i形成S的可數partition且$P(B_i)>0$，由$A=\sqcup(A\cap B_i)$，$P(A)=\sum P(B_i)P(A|B_i)$。Bayes再給$P(B_j|A)=P(B_j)P(A|B_j)/P(A)$，須P(A)>0。

原創監測器模型：故障prior P(F)=0.02；有故障時發alarm機率0.9，無故障時誤報0.1。則P(alarm)=0.02・0.9+0.98・0.1=0.116；posterior P(F|alarm)=0.018/0.116=9/58≈0.155172。

alarm的高sensitivity0.9不等於posterior0.9；大量正常樣本提供0.098誤報分母。兩次測試若只在給定F／F^c後獨立，雙alarm機率=0.02・0.9^2+0.98・0.1^2=0.026，posterior=0.0162/0.026=81/130≈0.623077；沒有先給條件獨立，不能平方likelihood。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

Continuous uniform不給每點正機率

X在[a,b]連續uniform、a<b時，P(c≤X≤d)=(d−c)/(b−a)，a≤c≤d≤b。單點c=d機率0，但整區間機率1；可數可加性不要求對不可數個單點直接相加。

例[a,b]=[2,8]，P(3≤X≤5)=2/6=1/3，去掉兩端點結果相同。若Z=floor X，Z的值2..7各機率1/6，而Z=8只在單點X8出現，機率0；不得把七種整數標籤平均分配。

接下來主講離散random variables及pmf。離散機率質量P(X=x)與連續density不同：density可大於1，單點機率仍0。對連續分布應積分區間，不能把density當成每點機率。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

C.3 Discrete random variables

random variable X:S→R是outcome的數值函數，event{X=x}是其preimage。pmf $p_X(x) = P(X = x)$，非負且$\sum_x p_X(x) = 1$；本章用「probability mass function」，避免把離散質量與連續density混淆。

joint pmf p(x,y)=P(X=x,Y=y)，marginals為$p_X(x) = \sum_y p(x, y)$、$p_Y(y) = \sum_x p(x, y)$。給$p_Y(y) > 0$，conditional pmf為$p(x, y)/p_Y(y)$。X,Y獨立當且僅當所有x,y都有$p(x, y) = p_X(x)p_Y(y)$。

原創：兩個獨立公平四面骰A,B∈{1,2,3,4}，令M=max(A,B)。P(M≤m)=$m^2/16$，P(M=m)=[m^2−$(m-1)^2$]/16=(2m−1)/16，m1..4質量1,3,5,7除16；不同M值不是等機率。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Expectation是加權和，不必是可能結果

$E[X] = \sum_x x p_X(x)$。有限支撐必可算；可數支撐要E|X|<∞才有有限且可重排的有號期望。非負X允許E[X]=∞；不能把∞−∞當合法期望運算。

對四面骰最大值M，E[M]=(1・1+2・3+3・5+4・7)/16=50/16=25/8；E[M^2]=(1+12+45+112)/16=170/16=85/8。期望3.125不在整數支撐，仍是正確平均。

任意g，只要E|g(X)|<∞，按每個X值的preimage分類得到$E[g(X)] = \sum_x g(x) p_X(x)$，不用先重新列g(X)的所有不同值。非線性時一般E[g(X)]≠g(E[X])；平方的差就是variance。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

線性期望的完整推導與indicator

若X,Y可積，從joint pmf有$E[X+Y]=\sum_x\sum_y(x+y)p(x,y)=\sum_x x\sum_y p(x,y)+\sum_y y\sum_x p(x,y)=E[X]+E[Y]$；絕對可積允許拆與換序，沒有使用獨立。E[aX+b]=aE[X]+b。有限多變數逐次套用。

indicator I_A在A發生為1，否則0，$E[I_A]=P(A)$。若X計某些events發生次數，$X=\sum I_i$，故$E[X]=\sum P(A_i)$，即使相依也成立。例uniform排列n個相異keys，inversion指標每對期望1/2，總n(n−1)/4。

若X,Y獨立且可積，joint分解後$E[XY]=(\sum xp_X)(\sum yp_Y)=E[X]E[Y]$。這次用到獨立；若X=Y是公平bit，E[XY]=E[X]=1/2≠1/4。多項乘積通常需mutual independence，而非只pairwise。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

Tail-sum與Jensen的理由

非負整數X逐outcome有$X = \sum_{i \geq 1} IX \geq i$。有限截尾先求期望再單調取極限（每項非負），得$E[X] = \sum_{i \geq 1} P(X \geq i)$，可含∞。若X可以負值，不能直接用這個式子。

convex f滿足f(λx+(1−λ)y)≤λf(x)+(1−λ)f(y)，0≤λ≤1。有限支撐以此二點定義歸納：把前m−1個權重normalize成一點，與最後一點再套凸性，得到f(E[X])≤E[f(X)]。

一般可積情況，若f在包含支撐及μ=E[X]的區間凸，μ有supporting line f(x)≥f(μ)+a(x−μ)，取期望即E[f(X)]≥f(μ)；端點退化情況X必集中該端點。需兩側期望有定義；這不是任意函數都可把f移入／移出E的規則。

Lin Cing
https://github.com/xinhi6716/computer-science-self-s

Variance、covariance與相依成本

若$E[X^2]<\infty$，$\mu=E[X]$，$Var(X)=E[(X-\mu)^2]=E[X^2]-\mu^2\geq 0$；$\sigma=\sqrt{Var}$為standard deviation。$Var(aX+b)=a^2Var(X)$，不是乘a。前例M的$Var=85/8-(25/8)^2=55/64$，$\sigma=\sqrt{55/8}$。

$Cov(X,Y)=E[XY]-E[X]E[Y]$，展開平方得$Var(X+Y)=VarX+VarY+2Cov$。n項時$Var(\sum X_i)=\sum VarX_i+2\sum_{i<j}Cov(X_i,X_j)$。pairwise independent且二次矩有限足以使covariances全0；不需mutual independent。

但只同分布不足。若$X_1=\ldots=X_n=$同一公平bit，sum只有0或n，各1/2，$variance=n^2/4$；逐項variance相加只有n/4。缺少covariance會把不確定性嚴重低估。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Markov與Chebyshev：各自的適用條件

若$X \geq 0$且$E[X] < \infty$，對$t > 0$逐點有$X \geq t\, I\{X \geq t\}$，取期望得$P(X \geq t) \leq E[X]/t$（Markov）。不需獨立，但不能套負值變數；有正負抵消時平均小不表示正尾小。

對二次矩有限Y，取非負$X = (Y-\mu)^2$與$t = a^2$，$a > 0$，得到$P(|Y-\mu| \geq a) \leq \mathrm{Var}(Y)/a^2$（Chebyshev）。它控制雙尾；若只要一側也可用同上界，但可能寬鬆。

例如四面骰最大值M的$\mu 25/8$、variance55/64，$a = 2$，雙尾$\leq 55/256 \approx 0.214844$；真事件只有M1，機率1/16。上界不是宣稱真機率等於bound；超過1的界可取1。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

C.4 The geometric and binomial distributions

Bernoulli(p)取1（success）機率p、0機率q=1−p。$X^2=X$，故E[X]=p，Var=$p-p^2=pq$。說一串Bernoulli trials時，以下另要求mutual independence與相同p；只有各次邊際p不夠。

geometric本章與CLRS採**包含首次成功那次的trial數**G∈{1,2,⋯}，0<p≤1。G=k要求先k−1次失敗、再成功，$P(G=k)=q^{k-1}p$；p0沒有成功，G=∞，不是這個有限值geometric分布。

若別處採「成功前失敗次數」F=G−1，支撐從0開始、pmf為$q^f p$、E[F]=q/p；不能把兩種mean都寫1/p。p1時G≡1、F≡0，公式與variance0仍成立。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Geometric的和、期望與variance

$\sum_{k\ge 1} q^{k-1}p = p/(1-q) = 1$。$P(G > t) = q^t$（整數t≥0），所以$P(G \ge i) = q^{i-1}$；tail-sum得E[G]=1/(1−q)=1/p。

由加權等比公式可得$E[G^2]=(1+q)/p^2$：例如$\sum_{k\ge 1} k^2 q^{k-1} = (1+q)/(1-q)^3$，乘p即得。$Var=(1+q)/p^2-1/p^2=q/p^2$。q0情況直接由G1處理，不做除q。

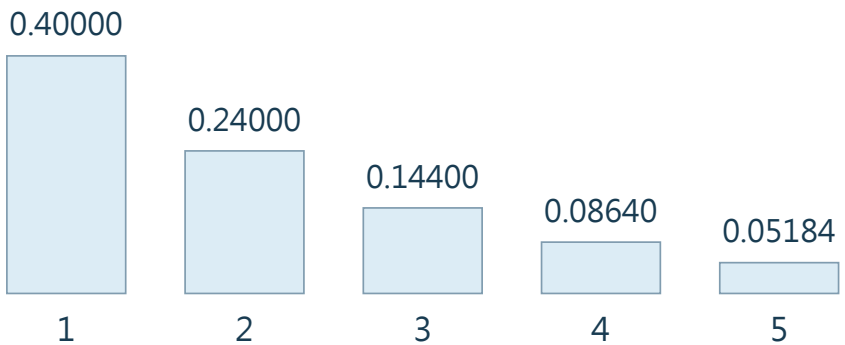
原創p=2/5，k1..5的pmf依次2/5、6/25、18/125、54/625、162/3125；總2882/3125，剩尾$P(G > 5) = (3/5)^5 = 243/3125$。E[G]=5/2、Var=15/4。期望不是「第2.5次真的成功」，而是多次重做此完整實驗的平均。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study/

Geometric的和、期望與variance （續）

先固定計數慣例，再計pmf、尾端與期望

P(G=k)，p=2/5



一個實現：F → F → F → S

G=4：包含最後成功trial

F=G−1=3：只數失敗

五次仍未成功：$q^5=243/3125$

此尾端沒有被前五根柱吃掉

橫軸是包含首次成功的trial index；E[G]=2.5，E[F]=1.5，兩種計數不可交換。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Memoryless與重試的模型邊界

對0<p<1、整數s,t≥0，$P(G > s+t | G > s) = q^{s+t}/q^s = q^t = P(G > t)$。已失敗s次不改未來的success率，因各trial獨立且同p；不是「已經失敗很久，下一次更容易成功」。

若retry成功率隨次數改、系統有同一持續故障、或抽樣無放回，都不符合相同獨立trials。此時尾端可能是$\prod_{i=1}^{t}(1-p_i)$（獨立但不同p），或需要conditional probabilities，不能硬寫q^t。

若每trial固定成本c，總成本cG期望c/p；若成本依成功／失敗不同，總成本是$c_{\text{fail}}(G-1)+c_{\text{success}}$，期望$c_{\text{fail}}q/p + c_{\text{success}}$。先定成本與trial的關係，再套線性期望。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Binomial的pmf、mean與variance

互相獨立同p的n次trial，$X = \sum_{i=1}^{n} I_i \in 0, \ldots, n$。固定一組k個成功位置，其機率$p^k q^{n-k}$；$\binom{n}{k}$個互斥位置集合給$b(k; n, p) = \binom{n}{k} p^k q^{n-k}$。總和$(p+q)^n = 1$。

線性期望給μ=np，不需獨立；variance要各對covariance0才可Σpq=npq。完整binomial pmf則用了mutual independence，pairwise只夠mean／variance，不保整個分布。n0退化X0；p0退化0、p1退化n，0⁰在pmf端點依空乘積視為1。

不同p_i但mutually independent時是Poisson-binomial，mean為$\sum_i p_i$、variance為$\sum_i p_i(1-p_i)$，不應把平均p塞進binomial pmf就說相同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

一張能逐項核對的binomial表

n=8,p=1/4,q=3/4，各pmf的共同分母4^8=65536；分子$\binom{8}{k}3^{8-k}$如下。

k	0	1	2	3	4	5	6	7	8
分子	6561	17496	20412	13608	5670	1512	252	24	1

分子總65536，Σk・分子=131072給E[X]=2；Σk^2・分子=360448給E[X^2]=11/2，所以Var=11/2−4=3/2。

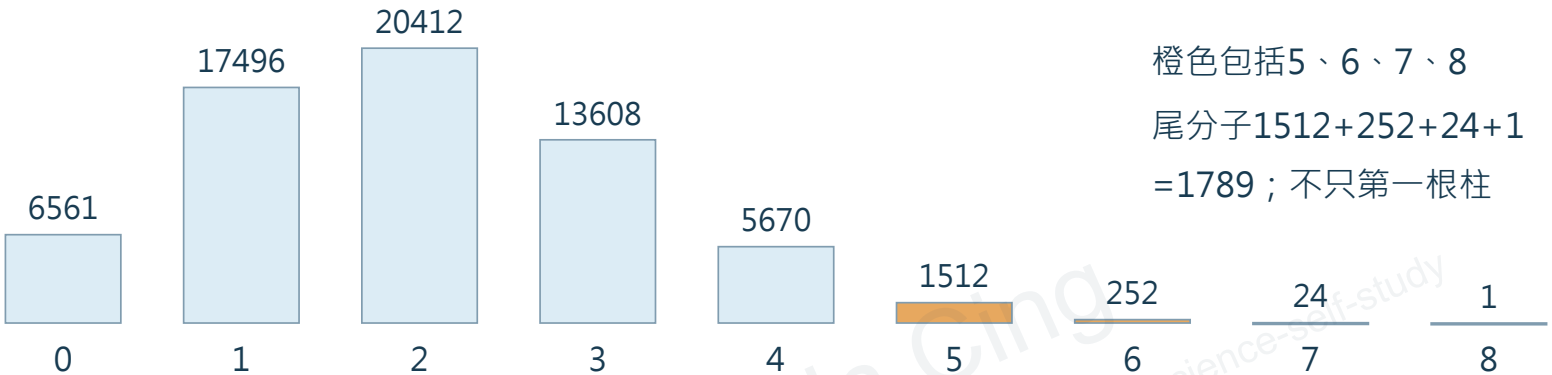
精確尾P(X≥5)=(1512+252+24+1)/65536=1789/65536≈0.027298。不是只算b(5)=1512/65536，也不是把「五次以上」漏掉k8。

Lin Cing
https://github.com/xinhi6716/computer-science-self-s

一張能逐項核對的binomial表 (續)

單一機率柱與尾端總和不同：門檻5含5

每柱高度 = 分子 / 65536；n8、p1/4



橙色包括5、6、7、8

尾分子1512+252+24+1

=1789；不只第一根柱

Σ分子=65536；mean2、variance1.5；P(X≥5)=1789/65536≈0.027298。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Mode由相鄰比率定，不能直接當mean

對0<p<1、1≤k≤n，有b(k)/b(k−1)=[(n−k+1)p]/(kq)。比率>1 iff k<(n+1)p；等於1 iff k=(n+1)p。

若(n+1)p不是整數，唯一mode=floor((n+1)p)；若是整數m，m−1與m都是modes。n8,p1/4時(n+1)p=2.25，mode2，mean2恰巧相同；n4,p1/2時m=2.5，mode2；n3,p1/2時m2，modes1,2，mean1.5沒有整數機率柱。

對0≤k≤n，前述entropy/binomial coefficient界給$b(k) \leq (np/k)^k (nq/(n-k))^{n-k}$，端點以連續或0⁰慣例處理。這是單一pmf上界，不是整個tail上界。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

C.5 The tails of the binomial distribution

先對齊嚴格／非嚴格尾：整數X的P(X≥a)從ceil(a)加到n；P(X>a)從floor(a)+1起。P(X<k)（整數k）只加0..k−1，別和P(X≤k)混用。

對X~Bin(n,p)，事件X≥k意味存在一組k個指定trials全部success。每組機率p^k，共$\binom{n}{k}$組；用union bound（組與組不必互斥）得$P(X \geq k) \leq \binom{n}{k} p^k$。k0界1，k>n真事件空。左尾用failures Y=n−X~Bin(n,q)：$P(X \leq k) \leq \binom{n}{k} q^{n-k}$。

數例n8,p1/4,k5，右尾≤56/1024=7/128≈0.054688，真尾1789/65536≈0.027298。重複計入同一次出現6個以上success的outcomes，正是上界通常不相等的原因。

Lin Ching https://github.com/xinhi6716/computer-science-self-study

左尾的geometric比率界：推導而非背公式

假設0<p<1、整數0<k<np，q=1−p。對1≤i≤k，b(i−1)/b(i)=iq/[(n−i+1)p]<kq/[(n−k)p]=ρ；因k<np，ρ<1。

由後往前，$b(k-j)<\rho^{j}b(k)$，j1..k。因此$P(X<k)<b(k)\sum_{j\ge 1}\rho^{j}=[\rho/(1-\rho)]b(k)=[kq/(np-k)]b(k)$。分母為正是前提，不可在k=np直接代入。

若0<k≤np/2，係數kq/(np−k)≤q≤1，故$L_k=P(X<k)<b(k)$，於是$L_k/L_{k+1}=L_k/(L_k+b(k))<1/2$。這說遠左尾再往左縮一個整數門檻時，機率至少減半。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

右尾由failures換元，門檻也要換

令Y=n−X~Bin(n,q)。當np<k<n，n−k<nq，將左尾界套到整數門檻n−k：

P(X>k)=P(Y<n−k)<[(n−k)p/(nq−(n−k))]b(n−k;n,q)=[(n−k)p/(k−np)]b(k;n,p)。

若k>(np+n)/2，則n−k<nq/2，左尾減半性給P(X>k)<(1/2)P(X>k−1)。success與failure的角色互換，不能只把原公式中的<改成>。

n8,p1/4,k4：係數(8−4)(1/4)/(4−2)=1/2，故P(X>4)<2835/65536≈0.043259；真尾1789/65536。它比本例union界7/128小，但不同參數時不必總是較緊。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Exponential moment把尾事件轉成非負量

令I_i為mutually independent Bernoulli trials（參數p_i），$X = \sum I_i$，$\mu = \sum p_i$。對任意λ>0及t，exp單調與Markov給$P(X \geq t) \leq e^{-\lambda t} E[e^{\lambda X}]$。獨立性在下一步不可省：

$E[e^{\lambda X}] = \prod E[e^{\lambda I_i}] = \prod [1 + p_i(e^{\lambda} - 1)] \leq \exp[\mu(e^{\lambda} - 1)]$，因$1 + z \leq e^{z}$。故$P(X \geq t) \leq \exp[\mu(e^{\lambda} - 1) - \lambda t]$。

若μ>0、t>μ，對λ微分$\mu e^{\lambda} - t = 0$，最小在λ=ln(t/μ)>0，二階$\mu e^{\lambda} > 0$。代入得$P(X \geq t) \leq e^{-\mu}(e\mu/t)^{t}$。此界允許各$p_i$不同；不需同分布，但需mutual independence。μ0時全部$I_i = 0$幾乎必然，正尾直接0，不代ln(t/0)。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

原書中心化r界與較精細的t界不能混用

CLRS所列較鬆形式：對r>μ>0，$P(X-\mu \geq r) \leq (e\mu/r)^r$。可直接證：$E[e^{\lambda(I_i-p_i)}] = p_i e^{\lambda(1-p_i)} + (1-p_i)e^{-\lambda p_i} \leq p_i e^{\lambda} + 1 \leq \exp(p_i e^{\lambda})$。相乘再用Markov，得$P(X-\mu \geq r) \leq \exp(\mu e^{\lambda} - \lambda r)$；取λ=ln(r/μ)即得。

本式r是**超過mean的幅度**，事件門檻是t=μ+r；前頁t則是**總success門檻**。若μ10,r40，中心化事件X≥50，較鬆bound為$(e/4)^{40} \approx 1.947 \times 10^{-7}$；精細t界則$e^{-10}(e/5)^{50} \approx 2.650 \times 10^{-18}$。兩者都是上界，不能把40與50交換後仍稱同一推導。

r只略大μ時$(e\mu/r)^r$可超1，仍合法卻無資訊，需取min(1,bound)。若是整數binomial，真sum起點為ceil(μ+r)；不把非整數門檻向下捨。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

同一binomial尾端比較不同保證

原創X~Bin(1000,0.01)，μ10，關心X≥50：Markov≤10/50=0.2；Chebyshev以Var9.9及偏差40給≤9.9/1600=0.0061875；中心化r40界約1.947e−7；精細t50界約2.650e−18。

精確值仍是$\sum_{k=50}^{1000}\binom{1000}{k}0.01^k0.99^{1000-k}$，可用相鄰比率遞推或log-pmf避免直接算大factorial後浮點溢出。這些界用到的條件不同：Markov只需非負與mean；Chebyshev需variance；最後兩個用mutual independent indicators。

若所有I_i共用一個Bernoulli(.01)，X只可能0或1000，P(X≥50)=.01，仍符合Markov，但原variance與exponential-moment乘積均不適用。相同marginals不是使用binomial／Chernoff的充分理由。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

資料來源

書目

章節來源

Cormen, Leiserson, Rivest, Stein. *Introduction to Algorithms*, 3rd ed., MIT Press, 2009，Appendix C。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

參考資料與署名

Thomas H. Cormen, Charles E. Leiserson, Ronald L. Rivest, Clifford Stein. Introduction to Algorithms, 3rd Edition.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study