# 第 3 章 練習

作答時請標示位元寬度、有號／無號解讀、捨入模式及輪次。浮點題未另行指定時，採 binary32，並寫出此假設。

## CH03-Q01 加減與溢出

> 以 八位元二補數 計算。
>
> 1. `0x7f + 0x01` 的 結果位元、有號值與溢位狀態。
> 2. `0x80 + 0xff` 的 結果位元、有號值與溢位狀態。
> 3. `0x80 - 0x01` 的 結果位元與有號溢位狀態。
> 4. 以進位觀點寫出 八位元有號溢位 判定的等價式。

## CH03-Q02 循序乘法

> 使用 四位元無號移位加法。每回合保留四位元 $A$ 與四位元 $Q$；加法產生一個暫時進位 $C$，因此當回合的加法是 $C:A=A+M$。接著把 `(C,A,Q)` 當成九位元串接值右移一位，C 進入新 A 的最高位，舊 $Q_0$ 移出，右移後的 C 不再保留。初始 $A=0000_2$、$M=1101_2=13$、$Q=1011_2=11$。
>
> 1. 列出 $Q_0$、每回合的 $C:A$、右移後 $A$ 與 $Q$。
> 2. 由最後的 `(A,Q)` 求八位元乘積，並驗證十進位乘法。
> 3. 由 $\sum q_k(M2^k)$ 說明演算法為何正確，不能只列四回合就代替一般 $n$-bit 證明。
> 4. 在 32 位元系統中，加法與移位各需一週期，另有三週期準備、兩週期收尾，求單筆循序延遲。另假設以足夠的硬體或交錯執行狀態，讓整個系統每四週期接受一筆新乘法，求穩態吞吐量；說明此假設為何不能由單一未管線化的迭代單元直接得到。

## CH03-Q03 恢復式除法（restoring division）

使用 四位元無號恢復式除法器。狀態包括五位元餘數 $A$、四位元商暫存器 $Q$，除數 $M = 0101_2$。被除數 為 $1101_2$。每回合把 $A$ 與 $Q$ 一起左移，做 $A - M$；若結果非負，保留差並使新商位 為 1，否則恢復原餘數，並使新商位為 0。

1. 完成四回合的完整追蹤。
2. 求出 商與餘數。
3. 用等式 $D = QM + R$ 驗證。
4. 若 被除數 為 `0x80000000`，除數 為 `0xffffffff`，32 位元有號除法 可能遇到哪個邊界情況？
5. 另外追蹤 11÷3，列出每輪已讀前綴 $P_k$、試算 T、已產生商 $q_k$ 與餘數 $A_k$；區分 $q_k$ 與整個 Q 暫存器。由 $P_k = q_k M + A_k$ 與 $0 \le A_k < M$ 證明一般更新正確。
6. 商向零截斷時，求 −11÷3 與 −11÷(−3) 的商餘數；若 −11÷3 改採向下取整，結果如何改變？逐一驗算等式與餘數範圍。

## CH03-Q04 Binary32 編碼

指定 IEEE 754 binary32。

1. 將 十進位 `-12.5` 編成 32 位元十六進位編碼。
2. 解碼 `0x3f000000`。
3. 寫出 最小正規正數與最小次正規正數 的 指數欄、尾數欄，以及用 2 的冪表示的數值。
4. `0x7f800000` 與 `0x7fc00001` 各是何種類型？

## CH03-Q05 最近值、同距取偶數（RNE）

在 binary32、預設最近值、同距取偶數模式 下計算 `1.0 + 2^-24`。

1. 寫出兩個相鄰的 binary32 候選值。
2. 決定 捨入位置、同距時的選擇與最低保留位。
3. 說明結果。
4. 若只延後這次加法的捨入，最後仍存成 binary32，結果會改變嗎？若在存回前再減 1，較寬中間精度又可能造成什麼差異？

## CH03-Q06 浮點乘法

令 binary32 $a = 1.5$、$b = 2^{-126}$。

1. 以 有效數與指數形式寫出兩個運算元。
2. 計算 有效數的精確乘積與尚未加偏移量的指數。
3. 正規化需要左移幾次？
4. 為何不能直接把兩個指數欄直接相加就當成結果的指數欄？

## CH03-Q07 非結合性

在 binary32 最近值、同距取偶數模式 下考慮 $x = 2^{24}$、$y = 1$。

1. 依序計算 $(x + y) - x$。
2. 依序計算 $(x - x) + y$。
3. 比較兩者，指出逐步捨入為何不能保證結合律。
4. 假設某機器在 x87 延伸精度 中保留 $1 + 2^{-24}$，而 SSE2 每一步都捨入成 binary32，再計算 $(1 + 2^{-24}) - 1$。兩者可能得到什麼結果？

## CH03-Q08 算術時序

循序乘法器執行 32 輪，每輪一週期，另有三週期準備、兩週期收尾。Radix-4 乘法器執行 16 輪，每輪平均 1.5 個週期等價時間單位（抽象平均值，不是普通同步時脈的半個週期完成一輪），準備與收尾共六週期。題目另假設兩個系統都配有足夠的複製單元或交錯執行狀態，每八週期可接受一筆新運算；單個未管線化的迭代單元並不自然具備此能力。

1. 分別計算單筆延遲。
2. 分別計算穩態吞吐量。
3. 說明 延遲與吞吐量 在何時各自重要。
4. 為什麼 16 輪不能直接推論除法器 一定快兩倍？若改為除法器，還需考慮什麼？

Lin Cing https://github.com/xinhi6716/computer-science-self-study

## CH03-Q09 捨入與例外

> 採 binary32、最近值同距取偶數模式。第 3 小題是把給定精確實數轉換並捨入到 binary32；這兩個值不是預先可表示的 binary32 運算元。
>
> 1. 將 `1.0 + 2^-24` 的 丟棄位元 寫成 $G, R, S$，判斷結果與 `inexact` 旗標。
> 2. 將 `1.0 + 3×2^-25` 的 丟棄位元 寫成 $G, R, S$，求結果。
> 3. 計算 $2^{-151}$ 與 $2^{-150}$。前者如何捨入？後者面對哪兩個候選值、選哪個、會設哪些旗標？
> 4. 最大有限 binary32 值 加自身，以及 `0 × ∞` 的 預設結果與例外旗標 分別為何？

## CH03-Q10 單次捨入、分開捨入與非結合性

> 令 binary32 $a = b = 1 + 2^{-23}$、$c = -(1 + 2^{-22})$。
>
> 1. 寫出 $a$、$c$ 的 32 位元十六進位編碼。
> 2. 先算 `mul.s a,b` 再 `add.s c`。逐步保留 乘積的精確值、捨入值與最後位元。
> 3. 若 `fma.rn.s` 直接計算 $ab + c$ 並只捨入一次，求 精確結果與最後位元。
> 4. 用 $x = 2^{24}$ 解釋 `(x+1)-x` 與 `(x-x)+1` 為何不同。指出改變的是哪一次捨入，以及 binary32 逐步捨入與精確算術結合律的差別。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

## CH03-Q11 對齊、相消與捨入進位

> 使用 p=4 個有效位（含首位 1）、RNE、指數範圍不設限的二進位模型。
> (1) 對 a=1、b=9/128，列共同指數下的所有非零位、L/G/R/S、兩個候選、選擇與絕對誤差。若忽略 sticky，錯誤結果為何？
> (2) 計算 0.75−0.6875，列相減後與每次左移後的有效數、指數，判斷 inexact。
> (3) 捨入精確值 $1.1111_2$ 與 $-1.0011_2$；列候選與奇偶，說明何者須再正規化，以及負數的加一方向。

## CH03-Q12 Subnormal 與例外旗標

> 使用 binary32、RNE、gradual underflow、停用 trap、捨入後判定 tininess，所有旗標初值為 0；停用 FTZ，也不把次正規輸入視為 0。令 $\delta = 2^{-149}$。
>
> 1. 對 $2^{-126}/2$、$\delta/2$、$(3\delta)/2$，各列精確值、相鄰候選（需要捨入時）、結果位元、underflow 與 inexact。
> 2. 求最小正規正數減最大次正規正數 的精確值與位元；結果是否設定 underflow？
> 3. 用 尾數欄整數 F 解釋 次正規數的間距，及它與最小正規正數相接處是否有缺口。

## CH03-Q13 Booth 的位元、寬度與正確性

使用講義的 radix-2 模型，$n = 4$、五位元 $A, M$、四位元 $Q$、一位歷史位，每輪先加減再聯合算術右移。

1. 對 $M = -8, Q = -3$，從初始狀態開始，逐輪列操作前的位元對、加減後與右移後的全部位元，解讀最後八位元乘積。
2. 若錯把 $A, M$ 限為四位元，指出第一個錯誤；以位元追蹤核對最後的錯誤乘積。為何五位元不是可有可無？
3. 對乘數 `0101`，列 radix-2 係數與加減次數，和無號移位加法 的加法次數比較。四輪是否可直接換成四個時脈週期？
4. 另以六位元 radix-4 計算 $M = -5, Q = -13$。列三個重疊群組、係數、十二位元部分乘積與總和，並由 $c_j = d_{2j} + 2d_{2j+1}$ 解釋查表規則。

## CH03-Q14 壓縮列數，保留數值

1. 以四位元無號 M=11、Q=15 產生四列八位元部分乘積。第一層壓縮 $P_0$,$P_1$,$P_2$，第二層壓縮 $S_1$,$C_1$,$P_3$；每層列出 S、已左移的 C、十進位總和及完整位元。
2. 最後以普通加法求八位元結果，從最低位開始列每欄的輸入進位與輸出進位。若忘記將 majority 列左移，兩層錯誤流程最後得到多少？
3. 對任意 W 位元 X,Y,Z，從全加器的一欄恆等式證明 X+Y+Z=S+C。W=4、X=Y=Z=15 時，分別列精確結果與只取低四位的結果，說明所需寬度。
4. 沿用三列分組的模型，從九列壓到兩列需要幾層？若 t_PP=40 ps、t_CSA=60 ps、t_CPA=180 ps、額外 t_wire=20 ps，求延遲上界模型的值；是否已證明它比其他乘法器快？
5. 三階段管線 共同週期 T=250 ps，無停頓，連續送入五筆獨立交易。列每筆接受與完成的邊緣及時間、第一筆延遲、啟動間隔、最後完成時間。若第二筆依賴第一筆結果，原排程哪裡不成立？

### 參考資料與署名

Lin Cing，《計算機組織》手寫筆記。 Patterson and Hennessy, Computer Organization and Design, revised fourth edition, Chapter 3. CSO course slides, arithmetic.

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。
https://github.com/xinhi6716/computer-science-self-study