第 3 章 練習

作答時標示 bit width、signed/unsigned interpretation、rounding mode 與 iteration 編號。浮點題若未指定格式，先選 binary32 並明說。

CH03-Q01 加減與溢出

以 8-bit two's complement 計算。

1. `0x7f + 0x01` 的 result bits、signed value 與 overflow 狀態。
2. `0x80 + 0xff` 的 result bits、signed value 與 overflow 狀態。
3. `0x80 - 0x01` 的 result bits 與 signed overflow 狀態。
4. 以 carry 觀點寫出 8-bit signed overflow 判定的等價式。

CH03-Q02 循序乘法

使用 4-bit unsigned shift-and-add。每一回合保留 4-bit A 與 4-bit Q；加法產生一個暫時 carry C，因此當回合的加法是 $C:A = A + M$。接著把 `(C,A,Q)` 當成 9-bit 串接值右移一位，C 進入新 A 的 MSB，舊 Q_0 移出，最高移出 bit 丟棄。初始 $A = 0000_2$、$M = 1101_2 = 13$、$Q = 1011_2 = 11$。

1. 列出 Q_0、每回合的 $C:A$、shift 後 A 與 Q。
2. 由 final `(A,Q)` 求 8-bit product，並驗證十進位乘法。
3. 由 $\sum q_k(M2^k)$ 說明 algorithm 為何正確，不能只列四回合就代替一般 n-bit 證明。
4. 在 32-bit 系統，若 add 與 shift 各需一個 cycle、另有 3-cycle setup 與 2-cycle finalize，求 serial latency。若再把同一個 32-iteration unit 包成 initiation interval 4 cycles 的 pipeline，求 steady-state throughput；指出這個 throughput 需要哪些額外硬體或 context。

CH03-Q03 Restoring division

使用 4-bit unsigned restoring divider。State 為 5-bit remainder A、4-bit quotient Q，divisor $M = 0101_2$。Dividend 為 1101_2。每回合把 A 與 Q 一起左移，做 $A - M$；若結果非負，保留差並使 new quotient bit 為 1，否則 restore 並使 bit 為 0。

1. 完成四回合 trace。
2. 求出 quotient 與 remainder。
3. 用等式 $D = QM + R$ 驗證。
4. 若 dividend 為 `0x80000000`，divisor 為 `0xffffffff`，signed 32-bit division 可能遇到哪個 boundary？

第 3 章 練習 （續）

CH03-Q04 Binary32 編碼

指定 IEEE 754 binary32。

1. 將 decimal `-12.5` 編成 32-bit hexadecimal。
2. 解碼 `0x3f000000`。
3. 寫出 smallest positive normal 與 smallest positive subnormal 的 exponent field、fraction field 及 decimal power-of-two value。
4. `0x7f800000` 與 `0x7fc00001` 各是何種類型？

CH03-Q05 Round-to-nearest-even

在 binary32、default round-to-nearest-even 下計算 `1.0 + 2^-24`。

1. 寫出兩個相鄰的 binary32 candidates。
2. 決定 rounding position、tie decision 與最低保留 bit。
3. 說明 result。
4. 如果在每一步都保留更多 precision 後才 round，結果是否可能不同？舉出這個例子中的作用。

CH03-Q06 浮點乘法

令 binary32 $a = 1.5$、$b = 2^{-126}$。

1. 以 significand 與 exponent 形式寫出兩個 operands。
2. 計算 exact significand product 與未 bias 的 exponent。
3. Normalize 後需要幾次 left shift？
4. 為何不能直接把兩欄位 exponent bits 相加就當成最終 exponent field？

CH03-Q07 非結合性

在 binary32 round-to-nearest-even 下考慮 $x = 2^{24}$、$y = 1$。

1. 依序計算 $(x + y) - x$。
2. 依序計算 $(x - x) + y$。
3. 比較兩者，說明 associativity 在哪裡失效。
4. 假設某 machine 在 x87 extended precision 中保留 $1 + 2^{-24}$，而 SSE2 每一步都 round 到 binary32，再計算 $(1 + 2^{-24}) - 1$。兩者可能得到什麼結果？

Lin Cing https://github.com/xinhi6716/computer-science-self-study

第 3 章 練習 （續）

CH03-Q08 算術時序

一個 sequential multiplier 的模型是 32 iterations，每 iteration 1 cycle，另有 3 cycles setup 與 2 cycles finalize。Radix-4 multiplier 模型是 16 iterations，每 iteration 1.5 cycles，另有 6 cycles setup/finalize。另明定兩個系統均有足夠複製單元或交錯 context，能每 8 cycles 接受一個新 operation；這不是單個未管線化迭代單元能自然提供的能力。

1. 分別計算單次 latency。
2. 分別計算穩定 pipeline 下的 throughput。
3. 說明 latency 與 throughput 在何時各自重要。
4. 為什麼 16 次 iteration 不能直接推論 divider 一定快兩倍？若改為 divider，還需考慮什麼？

CH03-Q09 Rounding 與例外

所有運算均在 binary32、round-to-nearest-even 下完成；小於最小的正 subnormal 依 exact value 判斷。

1. 將 `1.0 + 2^-24` 的 discarded bits 寫成 G, R, S，判斷 result 與 `inexact` flag。
2. 將 `1.0 + 3×2^-25` 的 discarded bits 寫成 G, R, S，求 result。
3. 計算 2^{-151} 與 2^{-150}。前者如何 round？後者面對哪兩個 candidates、選哪個、會設哪些 flags？
4. 最大 finite binary32 加自身，以及 `0 × ∞` 的 default result 與 exception 分別為何？

CH03-Q10 單次 rounding、分開 rounding 與非結合

令 binary32 $a = b = 1 + 2^{-23}$、$c = -(1 + 2^{-22})$。

1. 寫出 a、c 的 32-bit hexadecimal。
2. 先算 `mul.s a,b` 再 `add.s c`。逐步保留 product 的 exact value、rounded value 與 final bits。
3. 若 `fma.rn.s` 直接計算 $ab + c$ 並只 round 一次，求 exact result 與 final bits。
4. 用 $x = 2^{24}$ 解釋 `(x+1)-x` 與 `(x-x)+1` 為何不同。指出改變的是哪一次 rounding point，以及 binary32 每輪精度與 exact-arithmetic associativity 的差別。

第 3 章 練習 （續）

CH03-Q11 對齊、相消與捨入進位

使用 p=4 個有效位（含首位 1）、RNE、指數範圍不設限的二進位模型。
(1) 對 a=1、b=9/128，列共同指數下的所有非零位、L/G/R/S、兩個候選、選擇與絕對誤差。若忽略 sticky，錯誤結果為何？
(2) 計算 0.75−0.6875，列相減後與每次左移後的有效數、指數，判斷 inexact。
(3) 捨入精確值 1.1111_2 與 -1.0011_2；列候選與奇偶，說明何者須再正規化，以及負數的加一方向。

CH03-Q12 Subnormal 與例外旗標

使用 binary32、RNE、gradual underflow、停用 trap、捨入後判定 tininess，所有旗標初值為 0；不使用 FTZ 或把 subnormal 輸入視為 0。令 $\delta = 2^{-149}$。

1. 對 $2^{-126}/2$、$\delta/2$、$(3\delta)/2$，各列精確值、相鄰候選（需要捨入時）、結果 bits、underflow 與 inexact。
2. 求最小 normal 減最大 subnormal 的精確值與 bits；結果是否設定 underflow？
3. 用 fraction 整數 F 解釋 subnormal 間距，及它與最小 normal 相接處是否有缺口。

CH03-Q13 Booth 的位元、寬度與正確性

使用講義的 radix-2 模型，$n = 4$、五位元 A, M、四位元 Q、一位歷史位，每輪先加減再聯合算術右移。

1. 對 $M = -8, Q = -3$，從初始狀態開始，逐輪列舊 pair、加減後與右移後的全部位元，解讀最後八位元乘積。
2. 若錯把 A, M 限為四位元，指出第一個錯誤；以位元追蹤核對最後的錯誤乘積。為何五位元不是可有可無？
3. 對乘數 `0101`，列 radix-2 係數與加減次數，和無號 shift-add 的加法次數比較。四輪是否可直接換成四個時脈週期？
4. 另以六位元 radix-4 計算 $M = -5, Q = -13$。列三個重疊群組、係數、十二位元部分乘積與總和，並由 $c_j = d_{2j} + 2d_{2j+1}$ 解釋查表規則。

參考資料與署名

David A. Patterson, John L. Hennessy. Computer Organization and Design: The Hardware/Software Interface, Revised Fourth Edition.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study