平行處理的目標與形式

為何需要平行處理

單核心的時脈頻率不能無限制地提高：功率密度、時脈分配、指令層平行能力與記憶體延遲都會形成限制。平行處理把工作分配給多個執行單元，可用來提高單位時間完成的工作量（throughput），或縮短一項大型工作的完成時間。

多核心處理器在同一晶片上放置多個核心；多處理器系統也可能跨越多個插槽；叢集（cluster）則以網路連接多台電腦。它們的通訊延遲、快取一致性與故障範圍並不相同。

本章的加速比（speedup）比較同一問題或同一服務需求下的經過時間；若未交代工作負載與基準，單說「快 N 倍」沒有足夠意義。

Parallelism 的種類

工作層級的平行（job-level parallelism）是同時處理多個互不相依的工作，例如多個網頁請求；它能提高整體吞吐量，但不要求把每個請求拆開。

平行程式也可以把同一問題分給多個工作者（workers），例如矩陣乘法與影像處理；程式中哪些運算相依，決定哪些工作可以同時執行。

指令層平行（ILP）在單一指令流中重疊相互獨立的運算；資料平行對多筆資料執行相同操作；任務平行則讓不同任務或功能同時執行。這些形式可以在同一系統中共存。

7.1 功耗與平行設計

降低供應電壓與頻率通常能減少動態能耗，但也會降低單核心效能。若在相同功率預算內配置多個較慢的核心，程式又有足夠的平行工作，就可能提高每瓦完成的工作量；靜態功耗與通訊成本仍須納入比較。

平行處理的目標與形式 （續）

平行系統也能利用服務複本提高可用性：一個節點失效時，其他節點接手。但這需要冗餘、故障偵測與復原機制；多核心本身不會自動提供這些能力。

可擴充軟體在不同核心數、快取容量與網路拓撲下仍須保持正確，並維持合理效率。判斷小核心是否更省電，必須先指定工作負載、電壓與頻率，以及功率計量範圍。

7.2 Amdahl 的固定工作模型

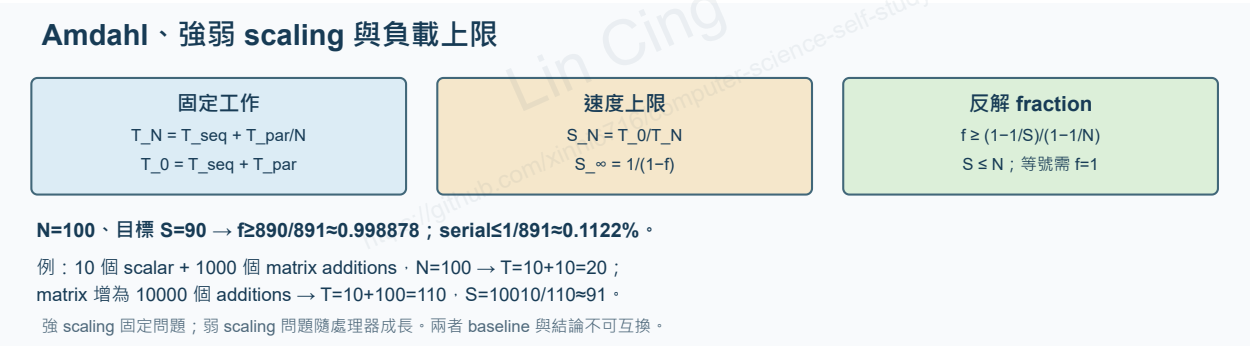
令固定工作的單執行緒 baseline 為 T_0。若其中比例 f 為可平行部分，$(1-f)$ 為序列部分，且 N 個 workers 完美分擔平行部分、沒有額外成本：

$$T_N = T_0(1-f) + \frac{T_0 f}{N}.$$

這個式子把「序列部分不縮小」直接寫進時間分解。Speedup 是 baseline time 除以新 elapsed time：

$$S_N = \frac{T_0}{T_N} = \frac{1}{1 - f + f/N}.$$

Efficiency 定義為 $E_N = S_N/N$，單位不是 occupancy。若 $S_N = 4.70588, N = 8$，則 $E_N = 0.588235 = 58.8235\%$。



7.2 Amdahl 的固定工作模型 （續）

當 $N \to \infty$：

$$S_\infty = \frac{1}{1-f}.$$

此公式假設 0≤f<1；f=1 時理想加速比隨 N 無界。這個上界只有在 workload、baseline 時間比例與成本定義固定時成立。它是 asymptote，不是某一台機器的 measured speedup。

從目標 speedup 反解

若處理器數 $N > 1$，目標加速比滿足 $1 \le S \le N$，可得到必要的平行比例：

$$f \ge \frac{N(S-1)}{S(N-1)}.$$

例如 $N = 100, S = 90$，必要 $f \ge 8900/8910 = 0.998878$，序列比例不得超過約 0.1122%。把這個門檻誤解成「90% 可平行」會得到完全不同的答案。

模型沒有包含 synchronization、load imbalance、launch 或 shared-bandwidth contention。實際時間可以寫成

$$T_{N,\text{observed}} = T_N + T_{\text{critical}} + T_{\text{sync}} + T_{\text{contention}},$$

上述加總只適用於各項額外成本互不重疊，且基準計算時間未改變的簡化模型；若成本重疊或快取、時脈改變，應沿執行時間線與關鍵路徑分析。Measured speedup 通常低於 ideal Amdahl 模型。只有先驗證這些成本近似可忽略，才能把差值歸因於單一原因。

從整體目標反推局部加速



目標 4 倍：需要局部改善 16 倍；5 倍只是極限

基準總時間為 100 ms，其中 80 ms 可改善、20 ms 不變。令局部加速倍數為 k，則整體加速為 $S = 100/(20 + 80/k)$。

目標 $S = 4$ 時，新時間必須是 25 ms；因此 $20 + 80/k = 25$，解得 $k = 16$。即使可改善部分趨近零，總時間仍趨近 20 ms，所以整體加速趨近 5 倍；對有限的 k，5 倍無法剛好達成，更高目標也不可能。這個上限依賴工作量與不變部分固定。

同時改善兩個部分

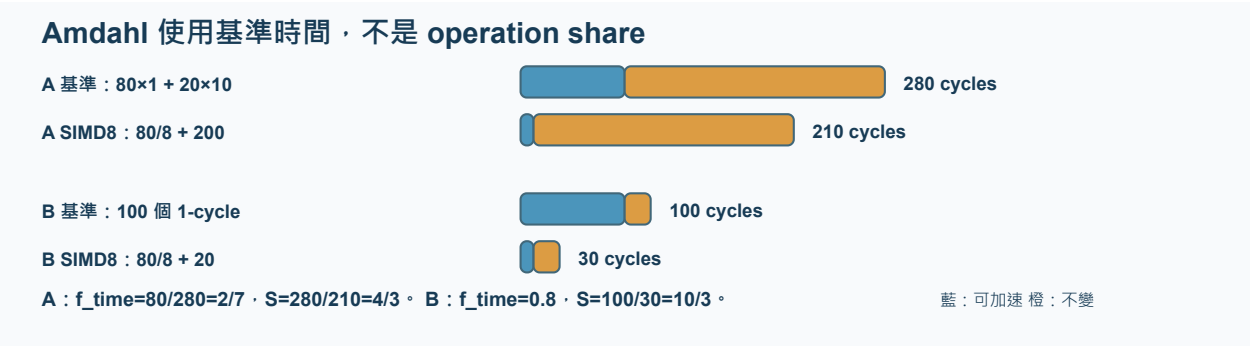
以同一基準時間為分母：乘法占 20%、記憶體存取占 50%、其餘占 30%。假設三段時間互斥，且改善彼此沒有交互作用。

乘法加速 4 倍、記憶體存取加速 2 倍時，新時間為

$$T_{new}/T_0 = 0.20/4 + 0.50/2 + 0.30 = 0.60, \qquad S = 1/0.60 = 5/3 \approx 1.667.$$

如果只改善乘法，新時間為 0.85 倍、加速約 1.176 倍；只改善記憶體則為 0.75 倍、加速約 1.333 倍。不能把兩個單項 speedup 相加，因為每項改善都以同一份基準時間為起點。

操作比例不等於時間比例



先看100個操作中的80個一cycle操作可向量化，另20個各花10 cycles。基準時間為$80 + 200 = 280$ cycles。8倍向量化後為$10 + 200 = 210$ cycles，故$S = 4/3$，可加速時間比例只有$80/280 = 2/7$。

模型	基準可加速時間	基準其餘時間	8倍加速後總時間	整體加速
不等成本A	80	200	10+200=210	280/210=1.3333
等成本B，100個操作各1 cycle	80	20	10+20=30	100/30=3.3333

相同80%操作比例可以對應不同時間比例。只有等成本或另外量到80%基準時間時，才可將0.8直接代入Amdahl。

Strong scaling、weak scaling 與效率

Strong scaling 固定 problem size W，增加 processors P，問同一工作最快能多快完成。若理想時間是 T_1/P，則

$$S_{\text{strong}}(P) = \frac{T_1}{T_P}, \qquad E(P) = \frac{S_{\text{strong}}(P)}{P}.$$

Weak scaling 讓總 problem size 從 W 成長為 PW，使每 processor 的工作量固定。弱擴展效率定義為

$$E_{\text{weak}}(P) = \frac{T_1(W)}{T_P(PW)}.$$

理想弱擴展保持相同完成時間，因此效率為1；此時間比不是固定問題的 speedup，也不應再除一次 P。若另外假設同一問題的單核成本隨工作量線性，$T_1(PW) = PT_1(W)$，才可寫

$$S_{\text{scaled}}(P) = \frac{T_1(PW)}{T_P(PW)} = \frac{PT_1(W)}{T_P(PW)} = PE_{\text{weak}}(P).$$

若缺少較大問題的單核時間或線性成本假設，不能僅從兩個不同規模的時間推出這個同規模 speedup。若資料量 M 固定，strong scaling 的每處理器記憶體約 M/P；若 weak scaling 讓 M 隨 P 成長，每處理器記憶體約維持 M。

固定規模與弱擴展：數值比較

假設每次 addition 成本為 t，序列工作為 10 次 additions。

問題	$P = 10$	$P = 100$
small：10 serial + 100 parallel	$T = 10t + 100t/10 = 20t$，$S = 110/20 = 5.5$	$T = 10t + 100t/100 = 11t$，$S = 110/11 = 10$
large：10 serial + 10,000 parallel	$T = 10t + 10,000t/10 = 1010t$，$S = 10010/1010 \approx 9.91$	$T = 10t + 10,000t/100 = 110t$，$S = 10010/110 = 91$

上述兩個固定規模的比較並不是 weak scaling：從 10 增到 100 cores 的同時，工作量增加了 100 倍，每 core 工作量並未固定。真正的弱擴展示例可取 P=10、平行工作 100 次，及 P=100、平行工作 1,000 次；序列部分均為 10 次。兩者皆需 20t，因此相對 P=10 的弱擴展效率為 20t/20t=1。較大問題的單核時間為 1010t，故其同規模 speedup 為 1010/20=50.5，並非 100。

報告至少記錄 problem size、per-core work、worker count、baseline、communication bytes、memory footprint、clock/power policy 與 measured wall time。只寫「99% 效率」而沒有 growth rule，無法重現。

Load balance 與 parallel critical path

令總 parallel work 為 W、最重 worker 的工作量為 $W_{\max}$、processor 數為 $P \geq 2$、固定 overhead 為 C，且每個 worker 以每單位時間處理一單位工作。若工作可任意分割，其他 workers 平均分擔剩餘工作時，parallel phase 的 completion time 為

$$T_{\text{parallel}} = \max\left(W_{\max}, \frac{W - W_{\max}}{P - 1}\right),$$

$$T_{\text{total}} = T_{\text{parallel}} + C.$$

一般 worker 的平均工作量不能預測完成時間；最慢 worker 與 dependency chain 都可能成為 critical path。Work stealing 可動態搬移 tasks，但每次 steal 需要 queue/atomic metadata，搬移資料又增加 cache 與 network traffic。Task 太細時，coordination 成本可能超過負載改善。

完整算例

令 $W = 10{,}000$、$C = 10$、$P = 100$。若一個 worker 分到 2%，即 200 units，其他 99 workers 共 9,800 units：若單位不可分，98 人各得 99、1 人得 98；平均 98.99 不是個別工作量。即使採離散分配，最重者仍為 200，因此結果相同：

$$T = \max\left(200, \frac{9800}{99}\right) + 10 = \max(200, 98.99) + 10 = 210.$$

Sequential baseline 是 $10{,}000 + 10 = 10{,}010$：

$$S = 10{,}010/210 \approx 47.67, \qquad E = 47.67/100 \approx 47.7\%.$$

Load balance 與 parallel critical path （續）

若重 worker 分到 5%（500 units）：

$$T = \max\left(500, \frac{9500}{99}\right) + 10 = 500 + 10 = 510,$$

$$S = 10{,}010/510 \approx 19.63, \qquad E \approx 19.6\%.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

7.3 Shared-memory multiprocessors

SMP（shared-memory multiprocessor，共享記憶體多處理器）給所有 processors 一個 common physical address space。Programs 用 shared loads/stores 溝通，硬體以 cache coherence 維持同一位置的 visible order。

UMA（uniform memory access）模型中，各 processor 到 memory 的 access time 近乎相同。NUMA（nonuniform memory access）中，local memory 比 remote memory 快；program page placement 與 data affinity 會改變效能。

NUMA 系統仍共用同一個 physical address space。NUMA 描述 memory latency 與 bandwidth 的拓樸差異，不是彼此分離的 address spaces。

Directory-based coherence 常用於較大的 SMP/NUMA，snooping 在 broadcast domain 小時較直接。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

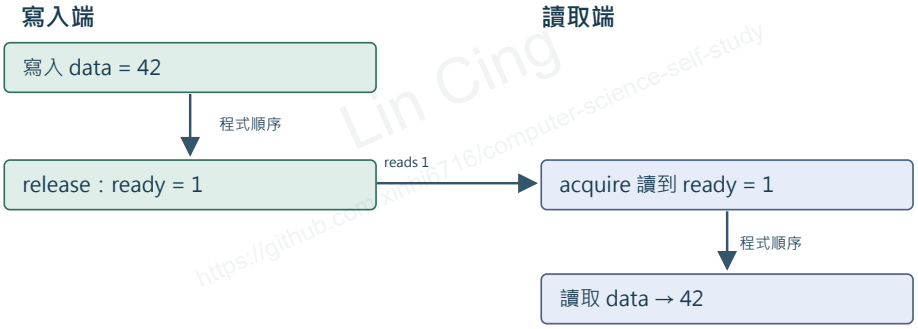
同步與訊息傳遞

Shared-memory synchronization

同步必須同時處理三件事：

1. **Atomicity**：read-modify-write 不可被拆成其他人可觀察的中間狀態。
2. **Ordering**：哪些 memory operations 必須排在另一個 operation 前後。
3. **Visibility**：建立 ordering 後，consumer 讀到 producer 寫入的值。

Coherence 只保證同一位置的 cached copies 與 write serialization。跨不同位置的 publication 仍需要 memory consistency model 所定義的 synchronization。



happens-before：寫入 data 先於讀取 data

至少一方非 atomic 的衝突存取未被排序，才構成 data race

同步與訊息傳遞 （續）

Publication worked example

```
int data = 0;                // shared object
atomic_int ready = 0;

// Writer
data = 42;
atomic_store_explicit(&ready, 1, memory_order_release);

// Reader
while (!atomic_load_explicit(&ready, memory_order_acquire))
    yield();
int observed = data;
```

當 reader 的 acquire load **實際讀到** writer 的 release store 所寫入的 `1` 時，release 與 acquire 建立 synchronizes-with，再透過 program order 建立跨 thread happens-before。`data=42` 必須先於 `data` load 可見，所以 `observed=42`。

作為可合法討論讀值的錯誤版本，改令 `data` 與 `ready` 都是 atomic，兩者的 store/load 全採 `memory_order_relaxed`。Writer 依序寫 data=42、ready=1；reader 讀到 ready=1 後仍可讀到 data=0，因為不同 atomic objects 之間沒有 synchronizes-with，coherence 只約束各自的 modification order。若兩者改成 plain non-atomic 且沒有其他同步，則形成 C/C++ data race、行為未定義；此時不能宣稱只會得到0或42。

同步只排除它涵蓋的衝突 accesses。若程式另有第三個 thread 在 lock 外修改同一資料，該 race 不會被修好。`atomic` 也不自動讓多個位置的 transaction 原子化。

Spinlock 以 atomic read-modify-write 嘗試取得 lock；contended spin 消耗 interconnect 與 power。Blocking mutex 將 waiting thread 交給 OS，代價是 context switch。Barrier 要所有 participating threads 到達後才釋放；tree barrier 以 $O(\log P)$ 深度換取較小 fan-out，但節點同步與喚醒成本仍存在。

7.4 Clusters 與 message passing

Cluster 由多台 commodity nodes 透過 network 連接，每個 node 有自己的 OS 與 physical address space。Communication 由 explicit send/receive 或 RPC/queue 完成，不使用 ordinary shared load/store。

Message passing 讓 sender/receiver ordering 較明確，但需要 serialize data、copy 到 network buffer、route、receive 與 possibly ACK。Failure isolation 較好，recovery 仍要 application framework。

MPP（massively parallel processor）類歷史上使用 specialized network；modern clusters 以 commodity switch 與 software stack 為主，取決於 latency/bandwidth/price。

Cluster 不是免費的 shared memory；distributed shared-memory layer 也建立在 message passing 之上。

7.5 Hardware multithreading

Hardware thread 是 CPU 可快速切換的 execution state，分開 PC、register file 與一些 control state；functional units、caches 與 memory 可以共享。它是處理 memory/instruction latency 的 microarchitecture 方法。

Fine-grained multithreading 每 cycle 輪流選 thread，ready thread 也可能被別 thread 分享 issue slots；適合隱藏長短 stalls，但單 thread latency 可能增加。

Coarse-grained multithreading 在 long stall 時才切換 thread；單 thread normal execution 較少被打斷，但可能無法隱藏短 dependency。

Simultaneous multithreading（SMT）在同 cycle 的 superscalar issue slots 中混合多 threads，對 ILP 不足有幫助；代價是 register storage、scheduler、cache pressure。

每個 core 執行兩個 threads 不代表 throughput 加倍；實際結果取決於 issue width、cache 與 workload。

7.6 SISD、MIMD、SIMD、SPMD 與 vector

SISD 是一個 instruction stream 作用於一個 data stream；MIMD 是多 processors 各有 independent instruction/data streams。SIMD 讓 one instruction 同時處理多個 data elements；SPMD 是 programming model，由多個 threads 執行同一 program、不同 data。

SPMD 可在 MIMD cluster 或 SIMT GPU 上實作。SPMD 不是固定硬體 classification，不能和 SIMD 當成同一層概念。

SIMD 擴充適合 regular contiguous data：array add、image filter、packed integer。Control flow 複雜或 data dependencies 不規則時，lane utilization 下降。

先列 software model 與 hardware execution model，再談 classification。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Vector architecture

Vector ISA 使用 vector registers 與 vector length。對 L 個 elements，一條 vector instruction 描述整個 vector operation；硬體以 lanes、chaining 或 pipelining 執行。

Vector code 通常用 vector length 表示 semantic，讓編譯器與硬體處理 tails 和不同 hardware widths。Multimedia SIMD 常固定 128/256 bits，software 要自行處理 padding/tail 與 narrower hardware。

令每個element做k operations，硬體有L lanes且每lane每cycle可完成一個element，frequency為f cycles/s、有效利用率為η。此模型的throughput為

$$\mathrm{OP/s} = kLf\eta$$

此處完成一個 element 包含其全部 k 次操作。若每 lane 每 cycle 僅做一次基本操作且 k 次操作無法重疊，initiation interval 至少為 k；不能再將每 cycle 的吞吐乘 k。

量綱為operations/element × lanes × elements/(lane • cycle) × cycles/s。若每lane initiation interval是q cycles/element，則再除以q。另一個等價描述是每條vector instruction處理W elements、每cycle可啟動r條，則上限為$kWrf$；vector length W不是physical lane數，兩者不可重複相乘。

Vector 的增益來自 amortize control/fetch 與 regular lane usage，不是 lane 數必然等於 real speedup。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

7.7 GPU 的定位

GPU 有大量較 simple cores、高 memory bandwidth 與 many warps。CPU 偏向少量 latency-sensitive threads；GPU 以 massive multithreading 隱藏 memory latency，適合 high arithmetic/data parallelism。

GPU 的效能來自 throughput，而非 single-thread latency。Host-device transfer、kernel launch、divergence、coalescing 與 occupancy 都會影響 end-to-end time。

本節只建立比較框架；SIMT warp、CUDA memory spaces 與應用 mapping 在 Appendix A 展開。

不要把「GPU core 數量較多」直接解讀為單一 scalar program 較快。

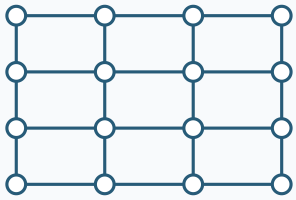
Lin Cing
https://github.com/xinhi6716/computer-science-self-study

7.8 Multiprocessor network topologies

把 network 寫成 graph $G = (V, E)$。Node 可代表 processor-memory endpoint，link 可有 bandwidth 與 hop latency。以下都把 full-duplex physical link 計為一條 edge；若報 bisection bandwidth，必須先說每次 link 是只計單向頻寬或雙向加總。

7.8(a) 4×4 mesh

4×4 mesh：24 條 local links，無 wrap



Mesh 指標

horizontal = 4×(4−1) = 12
vertical = 4×(4−1) = 12
edges = 24；average degree = 48/16 = 3
corners degree 2；interior degree 4
diameter = (4−1)+(4−1) = 6
bisection links = 4

沒有第 4 欄→第 0 欄或第 4 列→第 0 列的 link，所以不是 torus。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

四列各有 $4 - 1 = 3$ 條 horizontal links，合計 12；四欄各有 $4 - 1 = 3$ 條 vertical links，合計 12：

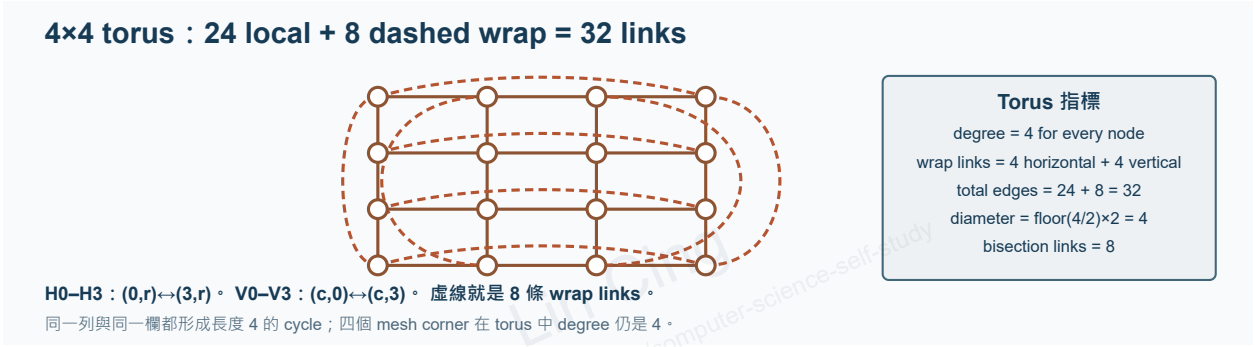
$$|E_{\text{mesh}}| = 12 + 12 = 24.$$

Degree 總和是 $2|E| = 48$，所以平均 degree 是 $48/16 = 3$。角落 degree=2、邊上 degree=3、內部 degree=4。任兩點最遠需水平 3 hops 加垂直 3 hops：

$$D_{\text{mesh}} = 3 + 3 = 6.$$

把四欄切成左 2 欄與右 2 欄時，跨越切面的只有 4 條 horizontal links；其他 balanced cuts 不會更少，因此 bisection links=4。

7.8(b) 4×4 torus



Torus 保留 mesh 的 24 條 local links，再把每一列的右端連回左端（4 條），並把每一欄的下端連回上端（4 條）：

$$|E_{\text{torus}}| = 24 + 4 + 4 = 32.$$

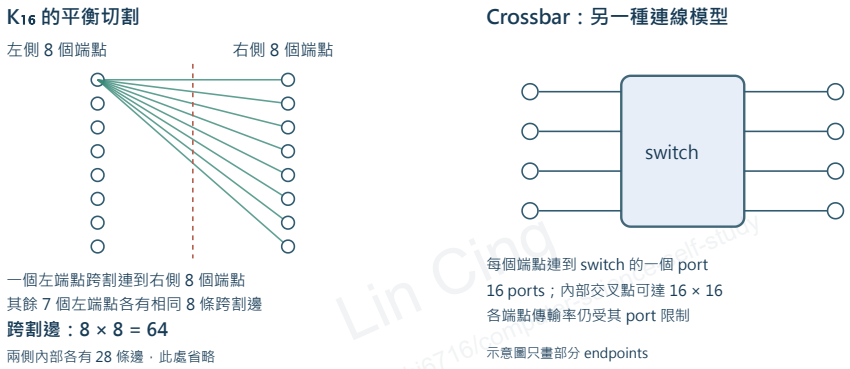
每個 node 都有左右上下四條 links，所以 degree=4。任兩 node 在每一維最多繞行 $\lfloor 4/2 \rfloor = 2$ hops：

$$D_{\text{torus}} = 2 + 2 = 4.$$

把 columns 0–1 與 columns 2–3 分開，跨切面是 4 條 local horizontal links 加上 4 條 wrap links，共 8。程式對全部 balanced cuts 取最小，得到 bisection links=8。

圖中的虛線不是裝飾：$H0$–$H3$ 是四列各自的 $(0, r) \leftrightarrow (3, r)$，$V0$–$V3$ 是四欄各自的 $(c, 0) \leftrightarrow (c, 3)$。少了這 8 條，圖就只是 mesh，degree 與 diameter 都不再符合 torus。

7.8(c) K16 與 crossbar 的模型差異



K_{16} 是完全圖：

$$|E| = \frac{16(15)}{2} = 120, \quad \deg(v) = 15, \quad D = 1.$$

任一 balanced cut 有 $8 \times 8 = 64$ 條跨越 links；若 link 的單向頻寬是 b，單向 cut capacity 是 $64b$。

Central crossbar 不是 K_{16}。N-port crossbar 的 endpoint 通常各接一個 switch port，內部有 $O(N^2)$ crosspoints；它的 endpoint degree、線路長度、仲裁成本與 cut bandwidth 必須用 switch 模型另算。

7.9 Multiprocessor benchmarks

Total network bandwidth 是「每條 link 頻寬 × link 數」的上界；bisection bandwidth 則取所有 balanced cuts 的最小 cut bandwidth，較接近 worst-case pattern。兩者都不足以單獨預測 application latency；hotspot、routing、message size 與 flow control 都會改變結果。

Parallel benchmark 要固定程式、data set、validation、compiler flags 與 processor count。Weak scaling benchmark 可讓 problem size grow，但要記錄 growth rule。

Linpack 是 dense linear algebra 與弱 scaling 常見例；SPECrate 適合 independent job throughput；SPLASH 類 benchmark 研究 shared-memory application patterns。

Peak performance 與 measured application performance 常不同。Memory bandwidth、load imbalance、communication 與 synchronization 可能占主要時間。

對 parallel systems 要看 per-core efficiency、scaling curve、tail latency、energy 與 fault tolerance，不只 single FLOPS。

7.10 Roofline 的推導與數值工作點

令某 kernel 一個 phase 執行 F 次 floating-point operations，跨 memory 介面實際搬移 Q bytes。Arithmetic intensity 定義為

$$I = \frac{F}{Q} \quad (\text{FLOP/byte}).$$

若 compute 的 sustained peak 是 P_C，該 memory 介面的持續 bandwidth 是 B，同一 phase 的 compute 與 memory times 分別是

$$T_{\text{compute}} = \frac{F}{P_C}, \qquad T_{\text{memory}} = \frac{Q}{B} = \frac{F}{IB}.$$

若 compute 與 traffic 可以完全重疊，elapsed time 不可能小於兩者的最大值：

$$T \geq \max\left(\frac{F}{P_C}, \frac{Q}{B}\right),$$

所以 throughput 上界為

$$P \leq \frac{F}{T} \leq \min(P_C, IB).$$

令 $IB = P_C$ 可求兩條 roof 的折點：

$$I_{\text{ridge}} = \frac{P_C}{B} \quad (\text{FLOP/byte}).$$

$I < I_{\text{ridge}}$ 時，模型中的頻寬上界較緊；$I > I_{\text{ridge}}$ 時，計算上界較緊。這只是 roofline 的界線，實際瓶頸仍需量測 dependencies、instruction mix、load imbalance 與 memory transaction efficiency。

7.10 Roofline 的推導與數值工作點 （續）

單層工作點

取 $P_C = 100$ GFLOP/s、$B = 50$ GB/s，ridge 是

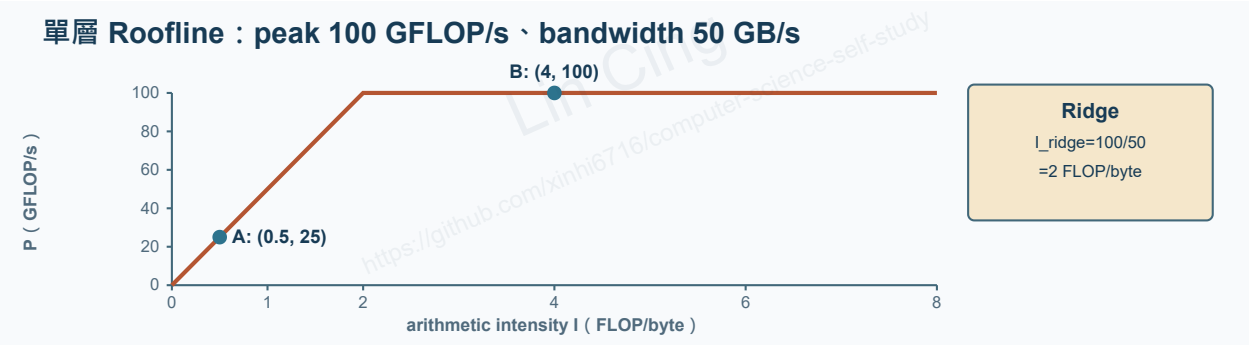
$$I_{\text{ridge}} = 100/50 = 2.$$

Kernel A：$I = 0.5$，memory roof $IB = 25$，compute roof 100：

$$P_A \le \min(100, 25) = 25 \text{ GFLOP/s}.$$

Kernel B：$I = 4$，memory roof $IB = 200$，但 compute cap 100：

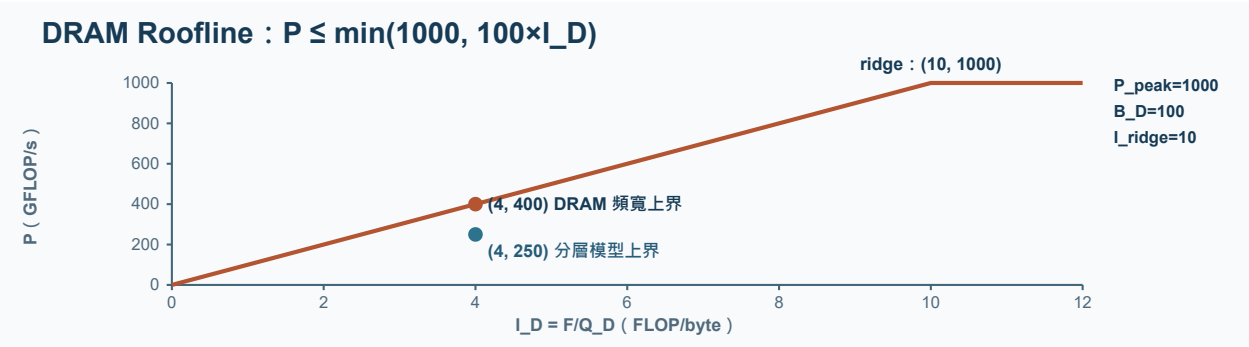
$$P_B \le \min(100, 200) = 100 \text{ GFLOP/s}.$$



階層 Roofline 的同一組數字

固定一階段 $F = 10^9$ FLOPs、$P_C = 1000$ GFLOP/s。DRAM 的 $Q_D = 0.25 \times 10^9$ bytes、$B_D = 100$ GB/s；shared memory 的 $Q_S = 4 \times 10^9$ bytes、$B_S = 1000$ GB/s。

7.10 Roofline 的推導與數值工作點 （續）

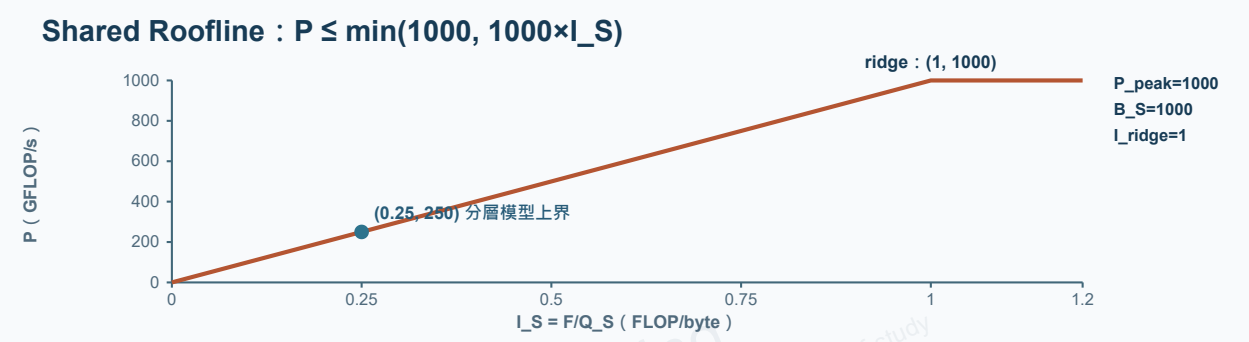


DRAM 層：

$$I_D = \frac{10^9}{0.25 \times 10^9} = 4, \qquad \min(1000, 100 \cdot 4) = 400 \text{ GFLOP/s}.$$

7.10 Roofline 的推導與數值工作點 （續）

shared 層：



$$I_S = \frac{10^9}{4 \times 10^9} = 0.25, \qquad \min(1000, 1000 \cdot 0.25) = 250 \text{ GFLOP/s}.$$

把三層限制合併：

$$P \le \min(1000, 400, 250) = 250 \text{ GFLOP/s}.$$

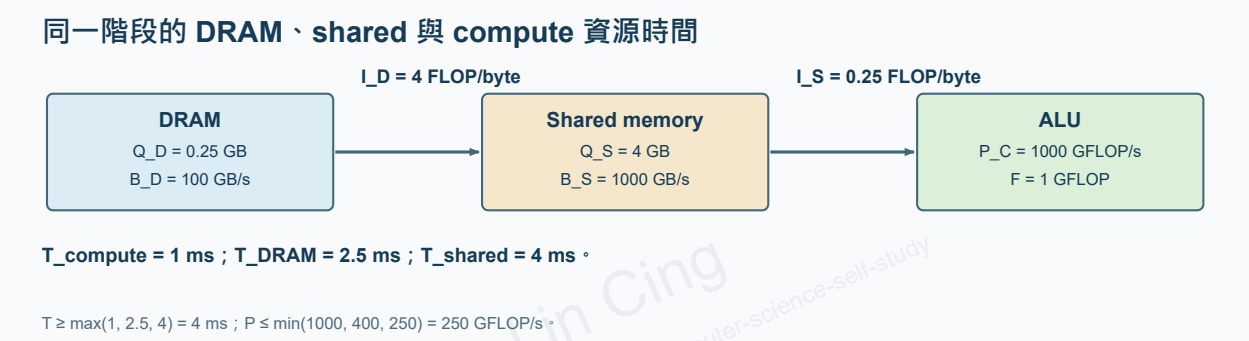
或等價地比較時間：

$$T \ge \max\left(\frac{10^9}{10^{12}}, \frac{0.25 \times 10^9}{100 \times 10^9}, \frac{4 \times 10^9}{1000 \times 10^9}\right) = \max(0.001, 0.0025, 0.004) = 0.004 \text{ s}.$$

也就是 time lower bound 是 4 ms。

7.10 Roofline 的推導與數值工作點 （續）

因此在這個明定模型中，DRAM 的工作點是 $(4, 400)$，但 shared 層把跨層上界壓到 $(4, 250)$。250 是模型上界，不是 measured performance；shared roof 本身仍以 1000 GFLOP/s 為 plateau，不能把 250 誤畫成整個 plateau。



若資料已被 cache 命中，就必須用該 cache 介面的 bytes 與 bandwidth 重算，不能把 DRAM 的 Q_D 和 cache bandwidth 混用。多層 roof 的圖可以分開畫，但最終 bound 要取同一 phase 各資源的最小值。

7.11 實際多核心系統比較

固定同一 kernel 與資料流量，假設 arithmetic intensity 為 1 FLOP/byte：系統 A 的 peak 為 1000 GFLOP/s、頻寬 100 GB/s；系統 B 分別為 500 GFLOP/s、200 GB/s。Roofline 上限各為 min(1000,100×1)=100 與 min(500,200×1)=200 GFLOP/s。

假設實測 A=80、B=90 GFLOP/s，兩者達到各自上限的 80% 與 45%；B 的上限雖高一倍，實際只快 90/80=1.125 倍。這組數字是模型範例，不能當成實機 benchmark。

Sparse matrix 的 indirect access 與 structured grid 的 stencil access 具有不同 locality；即使 intensity 相近，pipeline、coalescing 與 compiler quality 也可能影響測量。比較時必須固定工作負載、正確性、計時範圍與傳輸介面。

7.12 Parallel fallacies

「Amdahl's law 不適用」常源於拿 weak scaling 去反駁 strong-scaling claim；fixed-work model 沒有規定無限 speedup forever。

「peak FLOPS 決定最快系統」忽略 memory bound、load imbalance、communication 與 software stack。

「more threads 必然更快」忽略 synchronization, oversubscription, cache thrashing 與 power。

「coherent shared memory 讓 race-free」不成立；data races 仍需要 synchronization 與 memory model。

前述80/20不等成本例否定「operation share等於time share」；單一worker分到5%的例把100核 speedup壓到19.63；publication trace則指出coherence無法替代跨位置同步。這些都是明定模型的反例，不冒充實機量測。

7.13 Concluding remarks

Parallel hardware 提供 resources；parallel software 把它們轉成具體 speedup。Strong/weak scaling、load balance、communication、synchronization、coherence 與 benchmark 設計共同決定結果。

Shared-memory 與 message-passing 是 different address-space models。Multithreading、SIMD、GPU 與 clusters 各以不同成本隱藏 latency 或增加 throughput。

Roofline 比較 compute roof 與 memory roof，指出模型中較緊的上界；實際瓶頸還可能是相依性或指令吞吐。它只給 upper bound，實測仍需 performance counter 與 end-to-end benchmark。

若 DRAM roof 是最低上限，且工作集、資料流量與其他限制固定，提高 compute peak 不會提高該上限。可用相同完整工作階段的 DRAM bytes、持續 bandwidth 與執行時間檢查此預測；若資料重用改變，須先重算 intensity。

章末驗收

應能：

1. 給定 parallel fraction、worker count 與 overhead，計算 speedup/efficiency。
2. 分開 strong/weak scaling 的 problem-size 假設與 conclusion。
3. 說明 SMP、NUMA、cluster 的 address space 與 communication cost。
4. 比較 fine/coarse multithreading 與 SMT 的 stall hiding。
5. 計算 mesh 的 degree、diameter、bisection links。
6. 從 peak FLOPS、DRAM bandwidth 與 arithmetic intensity 判定 roofline bound。

先完成本章獨立練習題 PDF，再由詳解 PDF 檢查假設與推導。

7.14 平行架構的歷史視角

向量處理器用少量vector instructions描述大量規則運算，攤薄fetch與控制成本；shared-memory multiprocessors讓既有load/store程式模型延伸到多個processors，但需coherence及同步。Clusters以獨立節點和明確訊息傳遞換取可擴充資源與失效邊界，通信成本則直接進入演算法設計。

晶片整合增加後，multicore、SMT與GPU分別利用task、thread與data parallelism。它們沒有消除serial critical path，也沒有讓所有通信變成本地。比較歷史設計時應固定問題規模、數值驗證、記憶體容量、通信模式及power budget，才能分辨技術進步與工作負載改變。

完全連接graph與crossbar不同。K16每個endpoint連15條直接links，balanced cut有8×8=64條links；16-port crossbar通常每endpoint只連一個switch port，內部有$O(N^2)$crosspoints，其吞吐還受endpoint port rate限制，不能把兩者degree與cut-link數混成同一表。

參考資料

Patterson 與 Hennessy，*Computer Organization and Design: The Hardware/Software Interface*，Revised Fourth Edition，7.2、7.8–7.10，印刷頁 635–674（PDF 頁 662–701）。

Williams、Waterman 與 Patterson，〈Roofline: An Insightful Visual Performance Model for Multicore Architectures〉，*Communications of the ACM* 52(4), 2009，DOI。

分層流量定義另參照 NERSC Roofline 文件；每個層級以該介面的 bytes 計算自己的 intensity。本文數字是明定模型的代入與推導。

參考資料與署名

David A. Patterson、John L. Hennessy，Computer Organization and Design，Revised Fourth Edition，第 7 章。Lin Cing，《計算機組織》手寫筆記；計算機組織與結構（CSO）課程投影片。

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study