參考用書：Computer Organization and Design, Revised Fourth Edition
David A. Patterson, John L. Hennessy

計算機組織

完整版講義

A4 直式 · 上下兩張 · Lin Cing

目錄

一、電腦抽象、指令與算術

Chapter 1 電腦抽象與技術 2

Chapter 2 指令：電腦的語言 22

第 3 章 電腦算術 49

二、處理器與記憶體階層

Chapter 4 處理器 84

Chapter 5 大型且快速的記憶體階層 111

三、儲存、I/O 與平行系統

Chapter 6 儲存與 I/O 145

Chapter 7 多核、多處理器與叢集 165

延伸查閱：GPU 與程式工具鏈

Appendix A 圖形與運算 GPU 182

Appendix B 組譯器、連結器與執行環境 200

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

電腦抽象、ISA 與可量化效能

從一個 `sum += a[i]` 到電晶體切換，中間隔著多層契約。本章的目標是讓每一層都有可量化的邊界。

本課以 MIPS32 作為教學 ISA。MIPS 是本書選用的指令集範例，不代表所有現代處理器都直接執行 MIPS。ARM 與 x86 會在需要比較時出現。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

前置知識與學習成果

必備工具包括二進位、科學記號、比率與加權平均。課程結束時，學生應能以單位完整的式子預測程式執行時間，並說明預測在哪些條件下失效。

本課所稱「電腦效能」必須附上工作負載。沒有工作負載的「處理器很快」是測量條件不完整的句子。

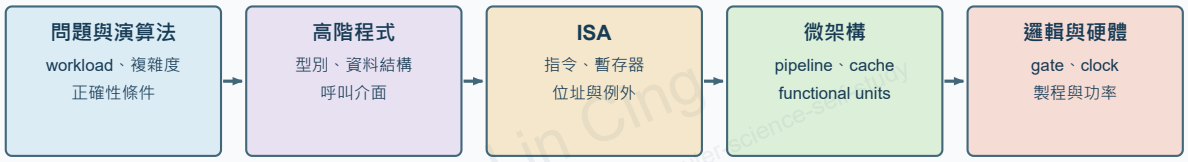
Lin Cing
https://github.com/xinhi6716/computer-science-self-study

1.1 電腦抽象層

電腦系統用分層管理複雜度。應用軟體使用系統呼叫與函式庫，編譯器產生 ISA 指令，微架構把指令展開為資料路徑操作，邏輯與實體層實現暫存器、加法器與記憶體。

相鄰層透過介面交換可觀察行為。介面讓上層不必知道下層每個電晶體，但最佳化會跨層傳遞資訊，例如資料局部性影響編譯器排程與快取命中。

抽象堆疊以介面承接上下層契約



上層提出可觀察契約，下層提供實作；最佳化資訊可跨層傳遞，但不可破壞介面。

抽象不是隱藏一切。軟體可透過指令、位址、例外與效能計數器觀察下層的部分行為。

ISA 與 microarchitecture

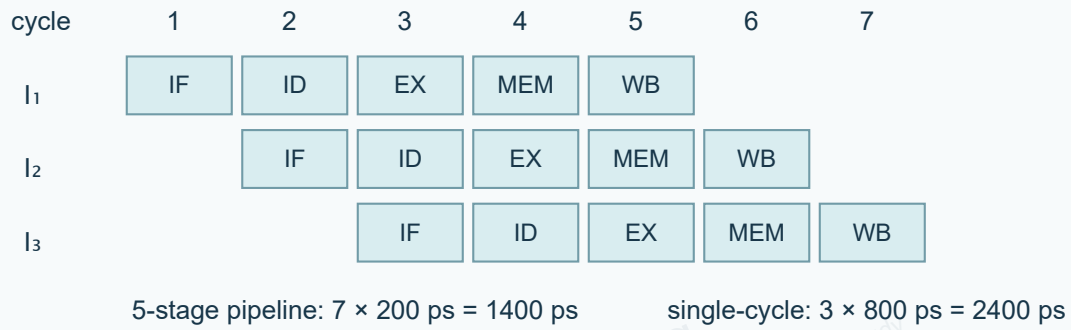
Instruction set architecture，中文為指令集架構，定義軟體可見的指令、暫存器、資料型別、定址、權限與例外。兩臺處理器可以有相同 ISA，卻有不同 pipeline 深度、cache 大小與執行單元。

Microarchitecture，中文為微架構，定義如何實作 ISA。它決定某條指令在各時鐘週期走到哪個階段，以及處理器能否同時維持多個 in-flight instructions。

若程式結果與 ISA 契約一致，微架構可以自由重排、預測與快取。若重排讓程式觀察到不同記憶體結果，必須由同步規則約束。

ISA 像函式介面，微架構像函式內部的資料結構與演算法。API 相同，成本與並行度可以不同。

同一 ISA，不同實作：三條指令的時間



假設同一執行檔、相同輸入、三條互不相依的指令，兩台機器都正確執行 ISA，且沒有停滯或例外；非記憶體指令也占用圖中的 MEM 階段。單週期機每條指令用 1 個 800 ps cycle，完成時間 $3 \times 800 = 2400$ ps。

五階管線每階 1 個 200 ps cycle，從第一個 IF 到最後一個 WB 共 7 cycles，完成時間 $7 \times 200 = 1400$ ps；加速比為 $2400/1400 = 12/7$。指令結果相同，不代表執行時間相同。

應用類別與設計取捨

個人電腦、伺服器、嵌入式與 mobile 系統有不同的限制。伺服器最佳化總吞吐量與 availability，mobile 系統受到 energy 與 thermal envelope 限制，嵌入式控制則重視 worst-case response。

同一項技術在不同市場的價值不同。有大容量 cache 可改善一般負載，但會占面積與增加 static power。低功耗休眠可延長電池壽命，卻可能提高喚醒延遲。

設計取捨至少包含效能、成本、功率、可靠度與可程式性五個量，不能只報告其中一項。

課程地圖

第 2 章建立 ISA，第 3 章處理整數與浮點算術，第 4 章把 ISA 變成 datapath 與 pipeline。第 5 章處理 cache 與 virtual memory，第 6 章處理 storage 與 I/O，第 7 章討論 multicore、multiprocessor 與 cluster。

後面的章節反覆使用本章三個工具：單位分析、局部化比較、以 workload 驗證。看到新的架構名詞時，先問它改變了哪個資源與哪個時間分量。

主線	本章建立的模型	後續機制
資料	operands、結果與 IC	第2章暫存器/位址 → 第3章算術 → 第4章 datapath → 第5章 cache
控制	ISA 的可觀察狀態與時間	第2章 branch/call → 第4章 hazard/exception → 第6章 I/O completion
通訊	搬移 bytes 與共享資源	第5章 coherence → 第6章 DMA/links → 第7章 synchronization/networks

1.2 程式如何落到硬體

高階語言先經 compiler 產生 assembly，assembler 再產生 machine instructions。Static linker 合併 object files，loader 建立 process 可用的位址空間，處理器最後依 ISA 解碼並執行。

每一步都產生可檢查內容。編譯器可改變指令數與暫存器使用；assembler 決定 encoding；linker 解決符號與 relocation；loader 建立初始記憶體映射。

效能分析不能只比較 C 原始碼行數，因為最佳化層級、資料型別與編譯器輸出會改變 instruction count。

請區分 source code、assembly 與 machine code。本課的 ISA 圖都畫在 assembly 與機器碼之間。

抽象介面與可攜性

ISA 讓同一個 executable 能在實作相同 ISA 的處理器上執行。作業系統還要提供 system call 與 binary interface，程式才完整可攜。

應用 binary interface，簡稱 ABI，規定暫存器保存方式、呼叫慣例、資料對齊與 executable 格式。它比 ISA 更接近程式工具鏈。

一個處理器可能維持舊 ISA 以執行既有程式，同時在內部把舊指令解譯成新的 micro-operations。這是實作選擇，不表示 ISA 消失。

區分 compatibility、portability 與 equivalence。能執行不代表得到相同效能。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

1.3 開啟電腦外殼

系統由 processor、volatile memory、nonvolatile storage、I/O 與 interconnect 構成。輸入裝置把外部狀態轉成資料，輸出裝置把資料轉成可觀察效果。

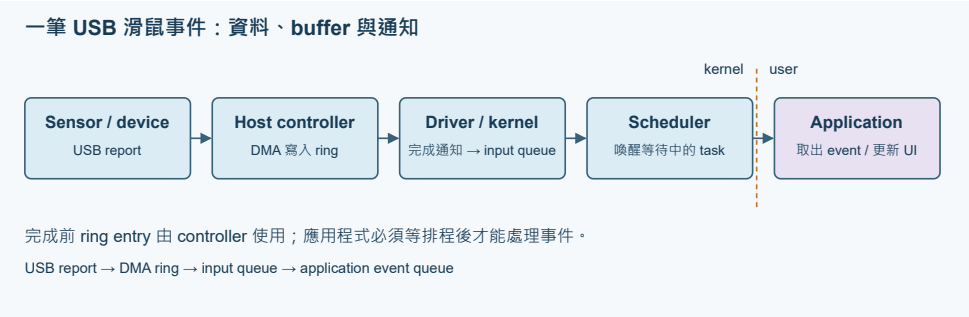
處理器內有 datapath 與 control，外部有 DRAM 與 persistent storage。匯流排或點對點 interconnect 傳遞位址、資料與控制訊息。

周邊裝置不是「電腦之外」的附屬品。鍵盤、滑鼠、顯示器與網路都會透過 interrupt、DMA 或 memory-mapped I/O 影響系統效能。

以下固定 USB 滑鼠、host-controller DMA ring 與一個等待輸入的應用程式。圖中的 buffer 是不同責任邊界，不假設每個箭頭都複製整份資料。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

USB 輸入事件的路徑



Controller 先將 report 寫入 driver 配置的 ring，完成通知讓 driver 取得已完成項，再交給 input queue；scheduler 喚醒應用後，應用才取走事件。DMA 完成前不能回收 ring slot；應用醒來時間也不等於封包抵達時間。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

從滑鼠看周邊介面

滑鼠感測器產生位移資訊。裝置控制器把它整理成封包，透過 USB 或 Bluetooth 等介面傳給 host controller。驅動程式與作業系統再交給 input subsystem。

每次移動不一定立即喚醒應用程式。系統會批次處理事件以降低 CPU 喚醒成本，這形成 latency 與 energy 的取捨。

測量「滑鼠反應慢」時要分清楚裝置取樣率、匯流排傳輸、作業系統排程、應用程式 frame rate 與顯示器更新率。

這個例子用來練習端到端延遲分解，數字未指定時不可假設由單一元件的速度決定。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

從平板看系統組成

Tablet 使用 system on chip，簡稱 SoC，把多個 CPU cores、GPU、media processor、memory controller 與 I/O controller 放在同一晶片。整合降低封裝與通訊成本，也提高 power density 與 thermal 管理難度。

使用者感受的 response time 包含 touch sampling、GUI composition、computation 與 display scan-out。處理器 burst 很快完成時，仍需等待顯示 pipeline。

Mobile workload 常見短暫 burst 與長時間 idle。平均值會掩蓋 tail latency 與 energy state transition。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

主機板與資料路徑

主機板提供芯片與周邊的實體連接。現代系統多採 point-to-point link，不再把所有裝置接在同一條共享 bus，因為共享 bus 的 contention 與電氣負載會限制頻寬。

晶片內的 interconnect 連接 cores、last-level cache 與 memory controller。Cache coherence 維持共享資料的可觀察一致性。

拓樸決定 traffic hop count 與 contention。頻寬峰值不能直接當成應用程式可得到的持續 bandwidth。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

資料保存層級

Register 與 cache 屬 volatile storage，斷電後資料消失。DRAM 也是 volatile。Flash、magnetic disk 與 optical media 屬 nonvolatile storage。

可靠性與備份是不同問題。RAID 可容忍某些裝置故障，但無法取代異地備份。檔案系統 crash consistency 也不能只靠平均值中的 MTBF 保證。

Temporary copy 必須和 authoritative copy 區分。Cache line 與 write-back dirty bit 改變資料在哪裡最新，但不改變程式的 logical data model。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

網路為何屬於系統組織

現代電腦的效能與可用性受 network latency、bandwidth 與 protocol overhead 影響。機架內與跨資料中心的距離不同，光速、交換器佇列與 congestion control 共同決定端到端時間。

資料可能先從 storage 進入 memory，再由 DMA engine 送到 network interface。CPU 不必逐 byte 搬移，但仍需設定 descriptor 與處理完成事件。

系統設計需一起考慮 computation、storage 與 network，否則算得再快的服務可能等待 I/O。

在無重疊、連線已建立的教學模型，固定 request encoding 0.2 ms、等待 0.3 ms、去程傳輸與傳播 2.0 ms、server computation 1.5 ms、回程 2.0 ms。總 latency 為 0.2+0.3+2.0+1.5+2.0=6.0 ms。只把 server computation 加速3倍，總時間為5.0 ms，整體 speedup=6/5=1.2。各數字是明定模型輸入，若網路傳輸與計算重疊，必須改以 dependency critical path 計算。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

製程與成本

IC 技術以 transistor integration 與 feature size 描述。較小元件通常降低每單位功能的面積與動態能量，但 leakage、變異與製造成本會使成本下降不再自動持續。

晶圓良率使每顆可用晶片成本不是裸晶面積的線性函數。大晶片能整合更多功能，也承受較高 defective die 比率。

成本要指定範圍。單顆晶片製造、封裝、電源、冷卻、伺服器機架與營運 energy 的成本不同。

不要把「電晶體更多」當成「每個程式更快」。這個結論需要 parallel 或 architectural 利用。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Die 面積、良率與成本

固定wafer diameter $D = 200$ mm、每片成本1000成本單位、每die面積 A（mm²）。邊緣損失的幾何近似採

$$N_{\text{die}} = \left\lfloor \frac{\pi (D/2)^2}{A} - \frac{\pi D}{\sqrt{2A}} \right\rfloor .$$

另明定負二項良率模型 $Y = (1 + dA_c/\alpha)^{-\alpha}$，$d = 0.5$ defects/cm²、clustering參數 $\alpha = 2$、$A_c = A/100$ cm²。此處100 mm²=1 cm²，不能直接把mm²代入defects/cm²。忽略封裝、測試、備援及其他成本，平均good-die成本為 $1000/(N_{\text{die}}Y)$。

Die面積	幾何項與邊緣項	Gross dies	Yield	預期good dies	每good die成本
100 mm²	floor(314.159−44.429)	269	(1+0.5/2)⁻²=0.64	172.16	5.8086
200 mm²	floor(157.080−31.416)	125	(1+1/2)⁻²=4/9	55.5556	18.0000

面積加倍同時降低gross dies及yield，本模型成本比為18/5.8086≈3.10，並非2。Good dies為期望值，實際產出為整數；本例的幾何/良率與成本數字皆為教學假設，非製造報價。

1.4 效能的定義

Response time，中文為回應時間，是單一工作從開始到完成經過的時間。Throughput，中文為吞吐量，是單位時間完成的工作數。

若最佳化縮短 critical path，可能改善 response time。若增加流水線、batch 或多核心，可能主要改善 throughput。

任何延遲改善百分比都要用同一 baseline。$T_{\text{new}} = T_{\text{old}}/S$，其中 speedup $S > 0$。若時間減半，$S = 2$，時間節省比例是 50%。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

延遲與吞吐量

以輸送帶為例，單筆 work 經過五個 stations 的總時間是 latency。穩定狀態下每週期離開一筆，是 throughput。Pipelining 通常降低平均完成間隔，舊工作的 latency 未必等比例降低。

Batch processing 可攤薄 setup 成本，提高 throughput，但第一筆結果可能更晚。多核心能並行不同工作，卻受 shared resources 與 synchronization 限制。

公平比較要固定 workload、輸入大小、warm-up、軟體版本與量測視窗。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

基準、比率與幾何平均

Benchmark 必須指定 workload、輸入大小、系統配置、compiler flags、warm-up 與量測視窗。這些條件不同時，兩個「SPEC 分數」不是同一個實驗。

以 reference machine 的程式 i 執行時間 $T_{\text{ref},i}$ 除以受測機器的 $T_{X,i}$，得到

$$r_{X,i} = \frac{T_{\text{ref},i}}{T_{X,i}}.$$

分數愈大表示受測時間愈短。單一程式可以直接比較；多個程式若要形成摘要，通常取幾何平均

$$GM_X = \left(\prod_{i=1}^{n} r_{X,i}\right)^{1/n}.$$

幾何平均適合比率的原因可以直接證明。兩台機器 X、Y 的幾何平均比值為

$$\frac{GM_X}{GM_Y} = \left(\prod_{i=1}^{n} \frac{r_{X,i}}{r_{Y,i}}\right)^{1/n} = \left(\prod_{i=1}^{n} \frac{T_{Y,i}}{T_{X,i}}\right)^{1/n}.$$

每個程式的 $T_{\text{ref},i}$ 都在 X/Y 的比值中成對抵銷。因此 reference machine 換成另一台、各程式 reference time 各自不同時，X 對 Y 的幾何平均比值仍不變；算術平均沒有這個性質。

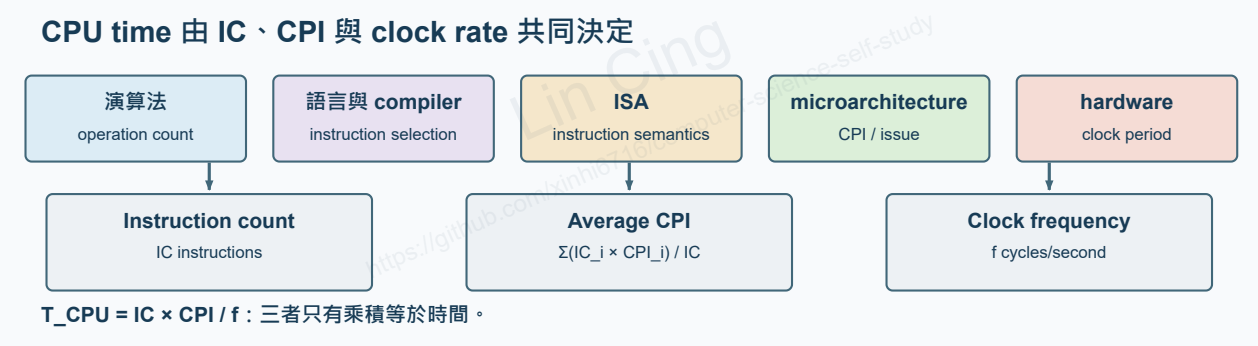
摘要分數仍不代表所有 workload。若某使用者的工作有 90% 時間落在單一 kernel，應以該 workload 重新加權或直接比較那支程式；不能只用幾何平均宣告普遍最快。

CPU time 的可重建模型

CPU time 計算CPU替程式執行的時間；以下不等式限定單執行緒、同一量測視窗，且 user/system accounting不重複：

$$T_{\text{elapsed}} \geq T_{\text{CPU}} = T_{\text{user}} + T_{\text{system}}.$$

I/O等待、被排程器換出與OS替其他工作執行仍消耗elapsed time。多執行緒process若將各 thread CPU time相加，總CPU-seconds可以超過elapsed seconds：4cores各工作1秒，總CPU time為4 CPU-s，elapsed為1 s。比較效能時必須明列thread/process accounting與使用的時間分母。



先從 cycle 數開始：

$$C = IC \times CPI.$$

CPU time 的可重建模型 （續）

每個 cycle 長 T_c 秒，所以

$$T_{\text{CPU}} = C\,T_c = IC \times CPI \times T_c = \frac{IC \times CPI}{f}.$$

量綱是

$$\text{instructions} \times \frac{\text{cycles}}{\text{instruction}} \times \frac{\text{seconds}}{\text{cycle}} = \text{seconds}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

完整比較例

同一程式在 A、B 上都執行 $I = 10^9$ 條 ISA instructions。A 的 CPI=2.0、clock period=250 ps；B 的 CPI=1.2、clock period=500 ps。

$$C_A = 10^9(2.0) = 2.0 \times 10^9, \qquad T_A = 2.0 \times 10^9(250\,\text{ps}) = 0.500\ \text{s}.$$
$$C_B = 10^9(1.2) = 1.2 \times 10^9, \qquad T_B = 1.2 \times 10^9(500\,\text{ps}) = 0.600\ \text{s}.$$

因此

$$S_{A/B} = \frac{T_B}{T_A} = \frac{0.600}{0.500} = 1.2.$$

A 比 B 快 1.2 倍。B 的 CPI 較低，但每個 cycle 較長，所以仍較慢。只比較 CPI、頻率或 instruction count 都會漏掉另外兩項。

本例直接假設兩者實際動態 IC 相同。同一執行檔與輸入若產生相同指令追蹤，就有相同指令數；同一 ISA 與高階程式本身不保證如此，不同 compiler、設定或執行環境都可能改變指令數。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

加權 CPI 與「少一條指令未必較快」

若類別 i 有 IC_i 條 instruction，並採用可加總且不重複計算的 cycles 攤計 CPI_i，總 cycles 與 CPI 是

$$C = \sum_i IC_i\,CPI_i, \qquad CPI_{\text{avg}} = \frac{\sum_i IC_i\,CPI_i}{\sum_i IC_i}.$$

分母必須是全部執行過的 instructions，不是類別數，也不是 source line 數。流水線或多發射處理器可重疊指令執行：單條延遲不能直接相加。下例的類別 CPI 是已依題設加總的週期成本；若頻率隨時間變動，則依區間累加時間，或用同一活躍區間的有效平均頻率 C/T。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

完整反例

硬體有三類 instruction：

類別	CPI
A	1
B	2
C	3

兩個 compiler 對同一高階語句產生：

序列	A 條數	B 條數	C 條數	總 instruction
1	2	1	2	5
2	4	1	1	6

序列 1：

$$C_1 = 2(1) + 1(2) + 2(3) = 10, \qquad CPI_1 = 10/5 = 2.0.$$

序列 2：

$$C_2 = 4(1) + 1(2) + 1(3) = 9, \qquad CPI_2 = 9/6 = 1.5.$$

在相同 frequency 下，

$$T_1 = 10T_c, \quad T_2 = 9T_c, \quad S_{2/1} = 10/9 \approx 1.111.$$

完整反例 （續）

序列 2 多一條 instruction，卻少一個 cycle。原因不是「instruction 較少一定快」，而是總 cycle 數才決定 CPU time。這個結果也提醒我們：instruction mix 改變時，不能把單一 CPI 當常數。

量測時可用 profiler、ISA simulator 或 hardware performance counters 取得 IC_i 與 cycle 來源；三種方法的覆蓋範圍與額外 overhead 必須另外記錄。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

經典效能方程式的邊界

效能方程式是 accounting identity，不是保證任何局部改動會改善總時間。它假設 IC、CPI 與 f 能被合理量測且 workload 固定。

CPU time 也不等於 wall-clock response time。若程式等待 I/O、作業系統排程或網路，必須把等待時間納入。

對多核平行程式，還需考慮使用 core 數 p、平行比例、負載不平衡與 synchronization overhead。第 7 章會用 Amdahl 與 Roofline 延伸本章。

若處理器頻率不變、CPI 降低，但 compiler 產生更多指令，總結果取決於兩個乘數的競賽。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

完整效能預算例

甲程式執行 2.0×10^8 條 instructions，CPI=1.25，頻率 2.0 GHz。

1. cycles：$2.0 \times 10^8 \cdot 1.25 = 2.5 \times 10^8$。
2. cycle time：$1/(2.0 \times 10^9) = 0.5$ ns。
3. CPU time：$2.5 \times 10^8 \cdot 0.5\ \text{ns} = 0.125$ s。

$$T_{\text{A}} = \frac{(2.0 \times 10^8)(1.25)}{2.0 \times 10^9} = 0.125\ \text{s}.$$

新 compiler 把 instruction count 降至 1.6×10^8，但 CPI 升為 1.40，frequency 仍為 2.0 GHz：

$$C_{\text{B}} = 1.6 \times 10^8 (1.40) = 2.24 \times 10^8,$$

$$T_{\text{B}} = \frac{2.24 \times 10^8}{2.0 \times 10^9} = 0.112\ \text{s}, \qquad S = \frac{0.125}{0.112} = 1.1161.$$

Instruction count 降低 20%，但 CPI 上升 12%，所以時間只降低

$$(0.125 - 0.112)/0.125 = 10.4\%.$$

如果把 B 的 CPI 誤用成 A 的 1.25，會得到 $T = 0.100$ s、speedup 1.25；這個答案忽略 instruction mix 已改變。

1.5 功耗牆

Dynamic power 的簡化式是

$$P_{\text{dyn}} = C V^2 f\, \alpha,$$

其中 C 為被切換電容，V 為電壓，f 為頻率，α 為 activity factor。提高頻率通常也要提高 voltage，因此 voltage-frequency scaling 會使 power 成長快於線性。

晶片還有 leakage power。降低供應電壓本身通常會降低漏電，但也會降低速度；若為了在低電壓維持速度而同時降低臨界電壓，次臨界漏電可能增加，製程變異的相對影響也可能變大。

散熱限制決定可持續的 power density。接近或超過平台的溫度、電流或功率限制時，時脈可能降低或部分資源停用；TDP是散熱設計參數，不是所有處理器固定且唯一的throttling門檻。

單核到多核與 Amdahl 的完整推導

功率密度、clock distribution、可用的 instruction-level parallelism 與記憶體延遲共同使提高單核頻率不再是永續的效能來源。多核提高 aggregate throughput，並可能縮短能把工作切成獨立部分的大型問題 elapsed time。

令固定工作的 baseline time 為 T_0，其中 fT_0 可由 N 個 worker 分擔，$(1-f)T_0$ 必須序列執行。假設工作均分且沒有新增成本：

$$T_N = (1-f)T_0 + \frac{fT_0}{N} = T_0\left(1 - f + \frac{f}{N}\right).$$

$$S_N = \frac{T_0}{T_N} = \frac{1}{1 - f + f/N}.$$

當 $N \to \infty$，平行部分趨近 0，但序列部分仍在：

$$S_\infty = \frac{1}{1-f}.$$

反解所需平行比例

若要達到指定的 finite-N speedup S，必須

$$\frac{1}{S} = 1 - f + \frac{f}{N} = 1 - f\left(1 - \frac{1}{N}\right),$$

因此

$$f \geq \frac{N(S-1)}{S(N-1)}, \qquad 1 < S < N.$$

例如 $N = 100, S = 90$：

$$f \geq \frac{100(89)}{90(99)} \approx 0.998878,$$

序列比例只能約 0.1122%。若 $S > N$，此理想模型不可達；$S = N$ 在 $f = 1$ 且新增成本為零時可達。只要 $f < 1$，有限 $N > 1$ 才有嚴格的 $S_N < N$。

原書型反例

程式 baseline 為 100 s，其中乘法占 80 s、其他運算占 20 s。若目標是總時間 20 s，即 5 倍速度，則

$$20 = \frac{80}{s_{\text{mul}}} + 20.$$

移項後 $80/s_{\text{mul}} = 0$，只有 $s_{\text{mul}} \to \infty$ 才趨近，因此有限加速不可能達到 5 倍。若只要求 2 倍，$T_{\text{new}} = 50$ s：

$$50 = \frac{80}{s_{\text{mul}}} + 20 \Rightarrow s_{\text{mul}} = 80/30 = 2.667.$$

這就是 Amdahl 的實作意義：先量「受改善部分占 baseline elapsed time 多少」，再問局部加速能否覆蓋其餘固定成本；不能把 operation count 或 source-line 比例直接當時間比例。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

製造與 AMD Opteron 案例

製造流程包含 wafer fabrication、測試、封裝與 system integration。Yield learning 與 design-for-test 會影響可用晶片數。效能 benchmark 只描述已配置的機器，不能單獨代表製造成本。

本章案例 AMD Opteron X4 是 2000 年代末的案例。閱讀時要保留年代，不能把它與今天的 core、cache、memory bandwidth 直接比較。

技術案例的用途是理解設計取捨。設計細節應回到當時的 ISA、製程、workload 與 server configuration。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

SPEC CPU 基準

SPEC CPU 的指標包含 single-thread 與 throughput 類。Single-thread 指標描述一個程式執行速度，throughput 指標描述指定並行配置下完成的 work。

Reference score 不是秒數。它是相對於 reference machine 的標準化結果，所以不能把兩個 ratio 直接相加成「總效能」。

最佳實務是保留每個 benchmark 的 ratio、硬體配置、compiler flags 與輸入。幾何平均可作摘要，但不取代個別結果。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

SPEC power 基準

Power benchmark 把 performance 與 active-idle energy 一起衡量。常見思維是指定工作負載下，每秒工作的總能源成本。

尖峰效能與 idle power 都會影響資料中心。若伺服器大部分時間低負載，idle 與 power-state transition 的成本會顯著。

Energy 與 power 要分清楚。$E = \int P(t)\,dt$。Power 的單位是 watt，energy 的單位是 joule。完成相同工作時比較 energy 才有意義。

不要用瓦數直接除以秒。先確認資料是平均功率還是累積能量。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

1.8 謬誤與陷阱

第一個謬誤是局部加速比例等於整體加速比例。若該部分只占 baseline 的 10%，即使無限加速，總時間最多只降低 10%。

第二個陷阱是不管 workload。處理器在某個 benchmark 強，不代表在 database、compiler 或數值程式也強。

第三個陷阱是忽略利用率與成本。購買更多資源若不能提高完成工作數，可能只增加 energy 與管理成本。

三個可核對反例分別是：baseline 100 ms 中10 ms加速無限倍，仍需90 ms，speedup上限100/90；系統X在R1花1 ms、R2花10 ms，Y分別花2 ms、5 ms，所以優勝者隨workload改變；若單一link最多100 requests/s，增加CPU而不改link不能把持續完成率推過100。三例分別違反「局部等於整體」、「單一benchmark代表所有負載」及「資源數等於可交付吞吐」的假設。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

抽象與介面小結

抽象將複雜度分層，ISA 是最重要的硬軟體介面之一。效能來自 workload、ISA、compiler、microarchitecture、memory 與 I/O 的共同結果。

本章的四個檢查問題是：

1. 比較的是 latency 還是 throughput？
2. 指令數、CPI、frequency 哪一項改變？
3. 哪些資源是共享的，是否已飽和？
4. benchmark 與系統配置能否重現？

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

歷史視角

電晶體整合提升可放在晶片上的功能，也讓設計從手工邏輯轉向 HDL 與合成。Pipeline、cache 與 out-of-order execution 逐步提高單核 ILP，但 power 與 complexity 設下限制。

2000 年代後，多核、hardware multithreading、SIMD 與 GPU 把平行度帶入主流。Compiler、runtime 與作業系統必須共同利用這些資源。

歷史比較要固定 ISA 與 workload，否則容易把世代、實作與應用變化混在一起。

電晶體與架構提供可用資源；只有 workload 的 critical path、指令工作量或資料搬移成本實際下降，才形成可量到的 application speedup。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

本章重點

- ISA 規定軟硬體介面；不同微架構可有相同可觀察結果與不同時間。
- CPU 時間以動態指令數、平均 CPI 與同區間有效頻率共同決定。
- 比較效能必須明定基準、單位與工作負載；延遲與吞吐量分開量。
- Amdahl 定律以基準時間比例計算，固定部分決定整體加速上限。

參考資料與署名

Lin Cing，《計算機組織》手寫筆記。 Patterson and Hennessy, Computer Organization and Design, revised fourth edition, Chapter 1. CSO course slides, 2026, Chapter 1.

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study

從程式語意到 MIPS 指令

Compiler 不必直接知道電晶體如何切換，它只需產生符合 ISA 契約的指令。Microarchitecture 不必理解 `if` 或函式，它只需正確完成 commands、位址計算、例外與記憶體效果。

本章用 MIPS32 建立完整的軟硬體介面，之後再以 ARM 與 x86 對照。學習重點是可追蹤的資料流與位址，不是背誦所有指令。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

學習路線與必要符號

本章使用下列符號。

- $R[x]$ 表示 index 為 x 的 32-bit register。
- $M[a]$ 表示 byte-addressable memory 中由位址 a 開始的資料。
- PC 是目前討論指令的位址；定址公式中的 $PC_{\text{next}} = PC + 4$。
- $I[k:j]$ 是 instruction I 的第 k 至第 j 個 bit。

本章採傳統 pre-Release-6 MIPS32，保留一個 branch/jump delay slot；所有控制轉移範例以 `nop` 明示延遲槽。`jal` 寫入 `$ra=PC+8`，不是 `PC+4`。本章不模擬早期 R2000 的 load delay。所有 MIPS core instructions 在案例中長度固定為 32 bits。Alignment 假設是 instruction address 為 4-byte aligned，word load/store 位址也為 4-byte aligned。

若實際 assembler 會重排指令，須使用其對應的順序控制（例如支援時使用 `.set noreorder`）並檢查 pseudo-instruction 展開，才能保證本文的 delay-slot 追蹤。

先固定 alignment 與 endianness 假設，否則同樣位址會得到不同 byte interpretation。

2.1 ISA 是軟硬體契約

ISA 描述 programmer-visible state 與 operations。MIPS32 的可見狀態包括 32 個 general-purpose registers、program counter、floating-point registers、HI/LO、status 與 exception-related registers。

程式可依 instruction semantics 依賴某些結果，但不能依賴 pipeline 有幾階或 cache 放哪裡。Timing 可以由 microarchitecture 改變，architectural result 必須維持。

ISA 也定義哪些 situations 必須產生 exception，例如 arithmetic overflow 或 address fault。精確例外的條件由 architecture 與特權規格確定。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

2.2 MIPS 運算指令

Arithmetic instruction 採三-operand形式。例如

```
add  $t0, $t1, $t2
```

語意是

$$R[t0] \leftarrow R[t1] + R[t2].$$

`sub` 做二補數減法。`add` 與 `addi` 在 signed overflow 時依規格產生 exception，`addu` 與 `addiu` 則不因 signed overflow 產生同樣例外。選擇哪個 instruction 會改變 architecturally visible trap。

`addiu` 的名稱不代表只有 unsigned operands。它是 immediate arithmetic without signed-overflow trap，負 immediate 仍經 sign extension。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

指令與語言的表達力

ISA 的核心運算數量可以很少，compiler 用組合完成高階語言 semantics。乘法可由 iteration、shift-and-add 或乘法單元實作，但 ISA 是否提供 `mult` 會影響 instruction count。

固定長度 encoding 使 decode 位置穩定，卻限制單一 instruction 能容納的 immediate bits。複雜 instruction 可減少 instruction count，也可能拉長 critical path。

比較 ISA 時要同時看 instruction count、每 instruction work、encoding 複雜度與 compiler 能否有效使用。

不要用 RISC 或 CISC 標籤直接預測效能。第 4 章會看到 microarchitecture 可以縮小兩者差異。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

2.3 運算元與暫存器

MIPS32 有 32 個 32-bit general-purpose registers。C 的 scalar 變數通常先放入 registers，load/store instructions 才處理 memory。

這形成 load-store architecture。Arithmetic 指令的 operands 是 registers 或 encoded immediate，不直接指定兩個 memory locations。

Register file 的讀取埠、write port 與 bypass 路徑屬 microarchitecture。ISA 只保證寫入後的 architectural value，不保證在 pipeline 哪一 cycle 可見。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

記憶體運算元

典型 MIPS load/store 的 effective address 是

$$EA = GPR[base] + sign_extend(imm16).$$

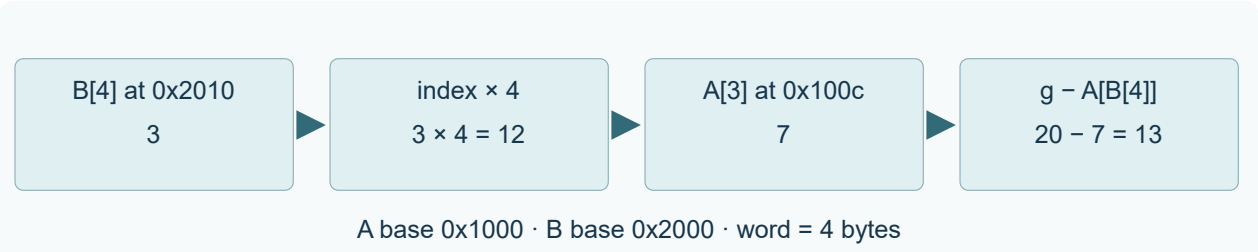
`lw $t0, 12($s0)` 把 $M[EA]$ 起算的 32-bit word 載入 register。`sw` 則把 register 值寫到 memory。

Immediate 是有號 16-bit displacement，範圍 -32768 到 32767 bytes。大型 offset 或不規則位址需先計算 base register。

若 base 是 32-bit，加法在 modulo 2^{32} 位址空間中發生。Instruction memory alignment 另行限制。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

間接索引：逐步追蹤兩次讀取



假設兩個陣列的 word 均為 4 bytes，base $A = 0x1000$、$B = 0x2000$，$B[4] = 3$、$A[3] = 7$、$g = 20$。所有索引、位址與讀取均有效且對齊；範例不發生算術例外。

```
lw   $t0, 16($s7)   # B[4] = 3
sll  $t0, $t0, 2    # 3 × 4 = 12 bytes
addu $t0, $t0, $s6  # address A[3] = 0x100c
lw   $s0, 0($t0)    # A[3] = 7
sub  $s0, $s1, $s0  # f = 20 − 7 = 13
```

其中 `$s6=0x1000`、`$s7=0x2000`、`$s1=20`；$B[4]$ 的 16 是 byte offset，不是元素索引本身。

立即值

`addi $t0, $t0, -7` 把 encoded 16-bit 欄位 sign-extend 後加到 register。`lui` 把 16-bit immediate 放入 upper half，常用兩條 instruction 合成 32-bit constant。

對 $0x12345678$，可概念化為 `lui $t0, 0x1234` 後再接 `ori $t0, $t0, 0x5678`。`lui` 不用 sign extension 的方式形成常數，而是把 lower 16 bits 清零。

ISA 是否提供 single-instruction 32-bit literal 是 encoding 取捨。固定 32-bit instruction 不可能同時保留五個 register fields 與任意 32-bit immediate。

`lui` 加 `ori` 組合立即值；load 則讀取當時的記憶體，可能遭遇位址、權限或頁面例外。只有常數內容固定、位址有效且沒有額外可觀察副作用時，兩者的載入值才可相同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

2.4 整數表示與溢位

Unsigned n-bit integer 的範圍是 0 到 $2^n - 1$。Two's complement 將最高位權重設為 -2^{n-1}，範圍是

$$-2^{n-1} \le x \le 2^{n-1} - 1.$$

對 32 bits，範圍是 -2147483648 到 2147483647。負數的 bit pattern 可由 complement 加 1 得到。

Signed operation 與 unsigned operation 可使用相同加法器，差別在 overflow interpretation、comparison 與乘除法處理。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

溢位與比較

Signed addition overflow 不是 carry-out 的別名。兩個同號 operands 相加得到異號結果時，結果越界。

溢位判斷可用 sign bits。令 operands 的 sign 為 s_a, s_b，result 為 s_r：

$$overflow = \overline{s_a \oplus s_b} \wedge (s_a \oplus s_r).$$

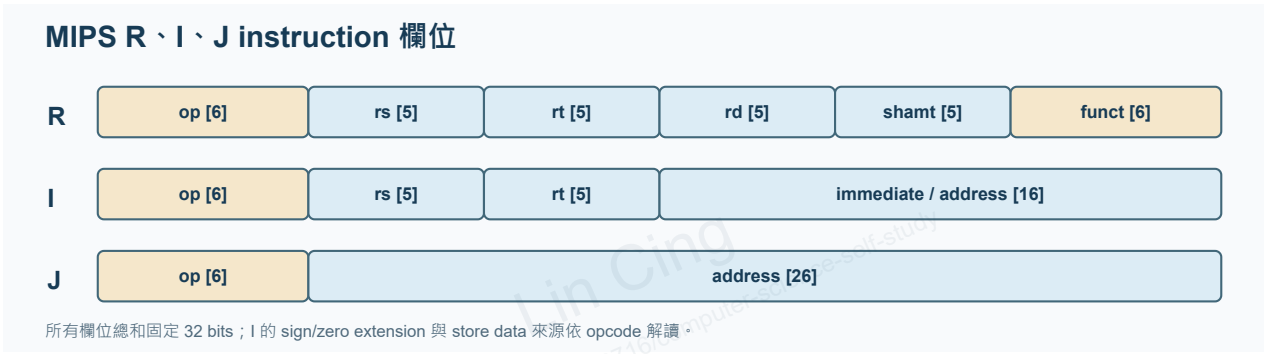
Unsigned addition 的 overflow 看 carry-out。比較也有 signed 與 unsigned 版本，所以 MIPS 提供 `slt` 與 `sltu`。

`0xffffffff + 1` 在 unsigned 是 overflow，在 two's complement 是 0 且無 signed overflow。必須先指定 interpretation。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

2.5 MIPS 指令格式

MIPS core instruction 一律 32 bits。R-type 用 opcode 000000 加 `funct` 區分 ALU operation；I-type 用 opcode 選擇 operation 與 16-bit immediate；算術及位址 displacement 做 sign extension，邏輯立即值做 zero extension；J-type 提供 26-bit jump index。



固定欄位位置使 fetch 後可並行讀取 opcode、registers 與 immediate。Encoding 的精簡會把更多 decision 推到 compiler 與多 instruction sequence。

欄位圖是概念示意，不代表實際晶片佈局。Bit order 從 MSB 31 往 LSB 0。

R、I、J 三種格式

R-type 的 MSB 到 LSB 欄位是 `op[31:26]`、`rs[25:21]`、`rt[20:16]`、`rd[15:11]`、`shamt[10:6]`、`funct[5:0]`。

I-type 是 `op`、`rs`、`rt`、`imm16`。Branch 使用 immediate 計算 offset；load/store 使用 immediate 計算有效位址；store data 來自 `rt`，不是 immediate。

J-type 是 `op` 與 `target26`。它不能任意指定 32-bit absolute address，因此要和程式所在 region 的 upper PC bits 合併。

I-type 的 `rt` 在 `addi` 常作 destination，在 store 作 source。欄位名稱相同，角色由 opcode 決定。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

2.6 邏輯與移位

Bitwise operations 是 `and`、`or`、`nor` 與 `xor`。Immediate forms 用 zero-extended 16-bit immediate，因為遮罩通常是 bit pattern。

Logical shift 補 zero。Arithmetic right shift 補 sign bit。MIPS 以 `srl`、`sra`、`sll` 操作 registers，shift amount 可為 `shamt`。

例如要取出 word 的 bits 11 到 8：

```
srl $t1, $t0, 8
andi $t1, $t1, 0x000f
```

`and` 常用於清零不需要的 bit；`or` 用於設定 bit；`xor` 可切換 bit。Mask 必須配合 shift amount。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

2.7 條件分支與迴圈

`beq rs, rt, label` 在 equality 成立時改變 control flow。若不成立，architecture-visible next PC 是 sequential instruction。

本章的傳統 MIPS32 模型有一個 branch delay slot，緊接 branch 的指令無論分支是否成立都會執行。例子以 `nop` 避免把不安全操作放入延遲槽；Release 6 的無延遲槽控制轉移不在本章模型內。

Branch 型態通常包括 equal、not equal、less-than 等比較。組合語言 pseudo-instruction 可由 branch 與 `slt` 展開。

必須宣告使用 classic MIPS 還是 MIPS32 release 的 ISA。不同版本對 branch delay、pseudo-instructions 與 instruction availability 可能不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

將迴圈翻成指令

C 片段：

```
int sum = 0;
for (int i = 0; i < n; ++i)
    sum += a[i];
```

令 `$a0` 指向 `a`、`$a1` 為 `n`、`$v0` 為 sum：

```
move $v0, $zero
move $t0, $zero
beq  $t0, $a1, done
nop
loop:
sll  $t1, $t0, 2
addu $t1, $t1, $a0
lw   $t2, 0($t1)
addu $v0, $v0, $t2
addiu $t0, $t0, 1
bne  $t0, $a1, loop
nop
done:
```

將迴圈翻成指令 （續）

前提是signed `n >= 0`、array位址有效且不wrap，並限定signed C sum不溢位，才與上面C語意等價；MIPS `addu`本身仍採modulo 2^32。`sll` 將 index 乘 4，因為 word 是 4 bytes。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Switch 的策略

密而集中的 case labels 可用 jump table。先檢查 index 是否在 table 範圍，再以 `sll` 與 `lw` 取得 target address，最後 `jr`。

稀疏或數目很少的 labels 可編成 compare-and-branch chain。Jump table 常降低決策鏈長度，但增加 table 空間、indirect jump 與 cache footprint。

編譯器還可能反向排列 cases、用 binary search tree 或 range checks。策略依 label distribution、安全性與 microarchitecture 選擇。

Direct branch的target由PC與immediate固定；jump table的同一個indirect-jump PC可隨index指向多個targets，需預測的不只有taken方向。Table若不在cache，還會先等target-address load；因此決策鏈較短不保證elapsed time較短。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

從 bit field 到 control flow 的完整追蹤

解碼不能只查 mnemonic。以下三個 word 分別覆蓋 I、R 與 J 格式的關鍵差異。

32-bit word	欄位拆解	執行語意
`0x8fa8000c`	`op=0x23`、`rs=29`、`rt=8`、`imm16=12`	`lw $t0, 12($sp)`；`EA=R[sp]+12`
`0x012a4020`	`op=0`、`rs=9`、`rt=10`、`rd=8`、`shamt=0`、`funct=0x20`	`add $t0,$t1,$t2`
`0x0c100140`	`op=3`、`target26=0x100140`	`jal` 至同一個 256-MiB region 的 `0x00400500`

I-format 的 `imm16` 並非一律 signed。`lw` 與 `addi/addiu` 做 sign extension；`andi/ori/xori` 做 zero extension；store 的 `rt` 是資料來源。opcode 先決定格式與欄位角色，不能先假定 `rt` 一定是 destination。

ISA 結果與高階語言語意也要分開。MIPS `addu/addiu` 的 32-bit result 是 modulo 2^{32}；C 的 unsigned arithmetic 也是 modulo 2^N，但 signed overflow 在 C 標準中屬於 undefined behavior。Compiler 不能只因兩個 operands 是 signed 就把任意越界程式翻譯成有保證的 modulo 結果；原始程式需先證明不越界，或改用 unsigned／更寬型別。

令 `beq` word 是 `0x1109fffc`，且 instruction 位於 `0x00400020`。`imm16=0xfffc=-4`，因此

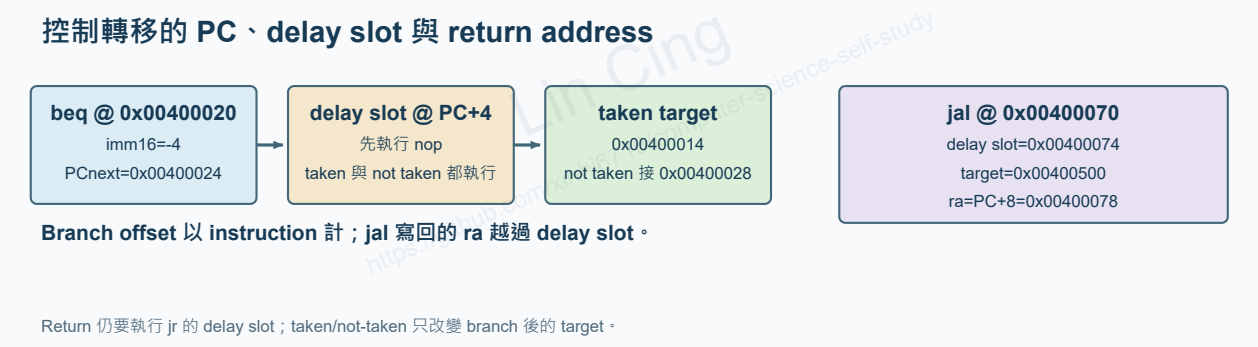
$$PC_{\text{next}} = 0x00400020 + 4 = 0x00400024,$$

從 bit field 到 control flow 的完整追蹤 （續）

$$target = PC_{\text{next}} + (\text{sign_extend}(0xfffc) \ll 2) = 0x00400024 - 16 = 0x00400014.$$

在 classic MIPS32 的一個 delay slot 模型下，branch taken 的 execution sequence 是 `0x00400020 → 0x00400024 → 0x00400014`；not taken 是 `0x00400020 → 0x00400024 → 0x00400028`。`0x00400024` 無論條件為何都執行，因此不能把它誤當成只在 taken 時執行。

對 `jal` 位於 `0x00400070` 的例子，delay slot 在 `0x00400074`，target 是 `0x00400500`，`$ra=0x00400070+8=0x00400078`。Return sequence `jr $ra; nop` 會先執行 return 的 delay slot，才到 `0x00400078`。



三個必要邊界是 instruction address 必須 word aligned、branch offset 以 instruction 為單位、J-type target 只能沿用 PC+4 的高四位。任一把 byte offset、word offset 或目前 PC 的高四位混用，換一組輸入就會得到錯的 target。

2.8 程序呼叫契約

`jal target` 把 return address 放入 `$ra`，再跳到 target。本章傳統 MIPS32 明定 `$ra = PC+8`，返回位置越過 call 的一個 delay-slot instruction。

`jr $ra` 跳回 caller。被呼叫程序若要呼叫其他程序，必須先保存 caller 的 `$ra`，否則 nested call 會覆寫。

Calling convention 是 ABI 的一部分，不是 processor 硬體自動完成的全部工作。Register allocation、stack layout 與保存順序由規格約定。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

暫存器分工

教材案例中的 MIPS convention 通常是：

- `$zero` 固定為 0。
- `$a0` 至 `$a3` 傳 arguments。
- `$v0`、`$v1` 傳 return values。
- `$t0` 至 `$t9` 由 caller 保存。
- `$s0` 至 `$s7` 由 callee 保存。
- `$sp` 是 stack pointer，`$ra` 是 return address。

Caller-saved 的意思是 caller 若要在 call 後繼續依賴該 register，就要自己保存。Callee-saved 則表示 callee 有義務在 return 前恢復原值。

這些名稱是 convention 與 ABI 的責任，硬體不會依 `$t` 或 `$s` 名稱自動保存 register。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

巢狀呼叫與 $ra

假設 `main` 呼叫 `f`，`f` 再呼叫 `g`。`jal g` 會覆寫 `f` return 到 `main` 所需的 `$ra`。

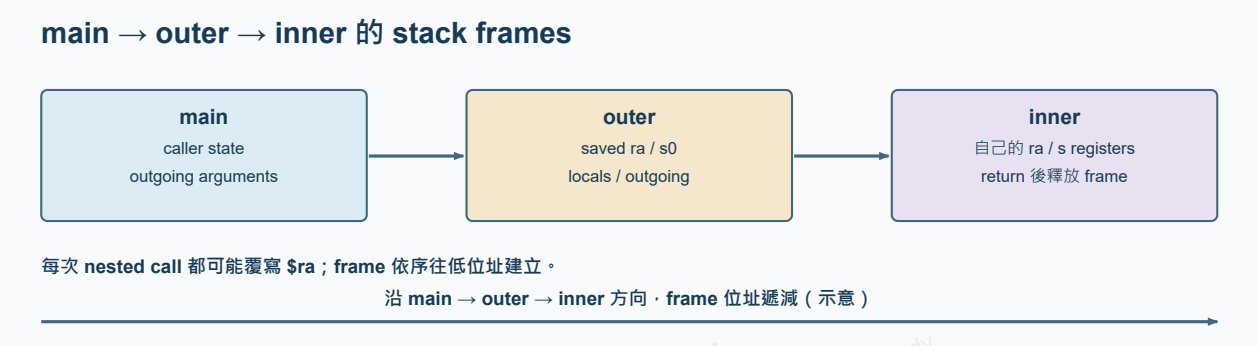
因此 `f` 在第一次 call 之前保存 `$ra` 到自己的 frame，等 `g` 返回後再 restore。

以下8-byte frame只示範return-address保存，不宣稱完整o32 outgoing-argument配置。最小sequence可概念化為：

```
addiu $sp, $sp, -8
sw    $ra, 4($sp)
jal   g
nop
lw    $ra, 4($sp)
addiu $sp, $sp, 8
jr    $ra
nop
```

Frame size 保持 alignment 是 ABI 要求，本例以 8 bytes 為例。實際 frame 還要保存 arguments、locals 與 callee-saved registers。

堆疊框



Call frame 通常包含 saved `$ra`、saved `$s` registers、local arrays、spill registers 與 outgoing argument area。Frame size必須容納同時存活的slots，offset需落在frame內且滿足各slot alignment，不能以offset大小代替所需空間。

Stack pointer 在 entry 減去 frame size，在 exit 前恢復。每個 stack slot 的 alignment 與 argument area 由 ABI 決定。

若 pointer 指向已釋放 frame，後面 call 可能覆寫它。Lifetime 錯誤是語意問題，編譯器未必能自動修正。

Heap 記憶體

Stack 隨 procedure lifetime 成長與縮回。Heap 用 `malloc` 或 `new` 配置，lifetime 由 program 控制，直到 `free` 或 garbage collection。

Allocator 管理 free blocks、metadata 與 fragmentation。Allocation 可能失敗，也可能觸發 page fault 與作業系統擴張 virtual address space。

Heap 的 logical allocation 與實際 physical residency 不同。成功取得 virtual memory 不代表每頁已載入 DRAM。

若函式回傳指向local int的pointer，return後該物件生命期已結束，後續dereference不是合法存取；stack bytes暫未覆寫也不延長其生命期。Heap leak則是在配置後失去最後一個可釋放的pointer，例如反覆malloc再覆寫唯一pointer；物件仍占配置空間，與dangling pointer的「存取已失效物件」不同。

2.9 字元、字串與位元組

ASCII 定義 7-bit 碼位，通常存於一個 8-bit byte；Unicode 則透過 UTF-8、UTF-16 等編碼表示。C 字串以終止 byte 表示長度；其他語言可能同時保存 length metadata。

MIPS 以 `lb`、`lbu`、`sb` 存取 byte。`lb` 做 sign extension，`lbu` 做 zero extension。String copy 要維持 destination capacity、alignment policy 與終止符。

Byte order 會影響 multi-byte word 在 memory 中的排列。Endianness 必須在 data exchange 與 binary format 邊界明確。

同一組 bytes `41 42 43 00` 作 NUL-terminated ASCII string 是 "ABC"；作32-bit integer，big-endian 是 `0x41424300`，little-endian 是 `0x00434241`。讀到同樣 bits 並未決定其型別語意。

2.10 大型立即值

Fix-width instruction 的 immediate field 有限。要把 arbitrary 32-bit constant 放入 register，需要多 instruction。

`lui rt, imm16` 將 `imm16` 放到 bits 31 至 16，low half 清零。接著 `ori rt, rt, imm16` 填 low half。

若 compiler 能在 symbol relocation 時直接填入 address，`lui` 與 `addiu` 也可能形成 address sequence。Effective address 最終仍是 32-bit modulo address space。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

分支與跳躍定址

PC-relative branch 的 target 為

$$target = (PC_{\text{next}}) + (sign_extend(imm16) \ll 2).$$

Offset 的單位是 instructions，不是 bytes。16-bit signed offset 可表示的 byte 範圍約為 $\pm 2^{17}$，且 instruction target 必須 4-byte aligned。

J-type 的 target 為

$$target = (PC_{\text{next}}[31:28] \parallel target26 \parallel 00_2).$$

它保留 PC+4 的高四位，所以目標限於 PC+4 所屬的 256-MiB region；當指令位於 region 末尾時，不應直接改用目前 PC 的高四位。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

定址模式總覽

教材包含 register、immediate、base-plus-displacement 與 PC-relative addressing。`lw $t0, 0($sp)` 使用執行該指令時的 architectural base value 加 displacement；資料相依由實作的前送或停頓處理，branch delay slot 並不是保存 base 的機制。

Addressing mode 不是越多越好。每增加一個模式，就增加 decode、exception priority 與編碼複雜度。

Pseudo-direct jump 用小 target field 換取固定 encoding，代價是 region 限制。Compiler 與 linker 若把 target 放錯 region，可能需要 trampoline 或 indirect jump。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

解碼機器碼

以 `0x012a4020` 為例，依序拆欄位：

```
op       = 000000
rs       = 01001  ($t1)
rt       = 01010  ($t2)
rd       = 01000  ($t0)
shamt    = 00000
funct    = 100000 (add)
```

所以它是 `add $t0, $t1, $t2`。decoder 先看 opcode，再依 format 選 `funct` 或 immediate。

解碼必須先確認 ISA、register naming 與 instruction length。若把 x86 variable-length bytes 當成 MIPS 固定欄位，會得到沒有意義的結果。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

2.11 同步與原子操作

多個 cores 共享 memory 時，單純 `lw`、`addiu`、`sw` 會形成 read-modify-write race。兩個 cores 可能都讀到舊值，再各自寫入新值。

MIPS 的 `ll` 與 `sc` 提供 atomic pair。`ll` 讀取並建立 reservation；`sc rt, offset(base)` 以 `rt` 的舊值作 store data，成功則原子寫入並把 `rt` 改為 1，失敗則不寫入並把 `rt` 改為 0。

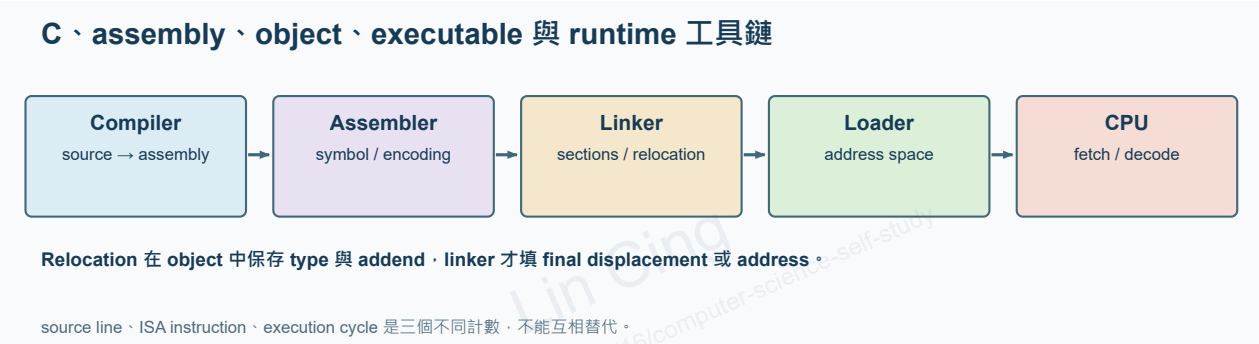
失敗時常見策略是 retry loop：

```
loop:
ll   $t0, 0($s0)
addiu $t0, $t0, 1
sc   $t0, 0($s0)
beq  $t0, $zero, loop
nop
```

具體 retry 次數與 fairness 不是 ISA 保證。若 reservation 被另一個 store 或例外中斷，`sc` 可能失敗。

2.12 從 C 到執行檔

Compiler 做型別檢查、最佳化與 instruction selection。Assembler 把 symbols 與 pseudo-instructions 轉成 machine instructions 與 relocation records。Linker 合併 object files、解析 external references、配置 sections。Loader 建立 process address space 與初始 registers。



每個階段都可能失敗。Compiler 的 undefined behavior、assembler 的 invalid operand、linker 的 undefined symbol、loader 的 permission 或 mapping 問題必須分開診斷。

以外部 `printf` 為例，object 留下 undefined symbol 與 call relocation；靜態連結器產生可執行檔；選擇動態連結時，可依 ABI 建立 stub、間接表或重定位，再由 dynamic loader 映入提供者並解析 runtime address。完全靜態連結則不需要動態載入器解析該符號。若採 lazy binding，首次經 resolver 更新表項，後續走已解析的間接路徑。實際 stub 與暫存器規則依 ABI，不能把此跨階段流程當作固定 MIPS 指令序列。

工具鏈的地址語意

Assembler 第一次看到 local label 時可計算 section-relative address，但 external symbol 尚未確定。Object file 保存 relocation type 與 addend，讓 linker 填入最終 displacement 或 address。

Static linking 在 executable 內解析 references。Dynamic shared library 可能用 position-independent code 與 runtime resolver，降低 multi-process physical memory duplication。

Debug 時要分清楚 virtual address、file offset、load segment offset 與 physical page。它們不是同一個數字。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

呼叫慣例案例

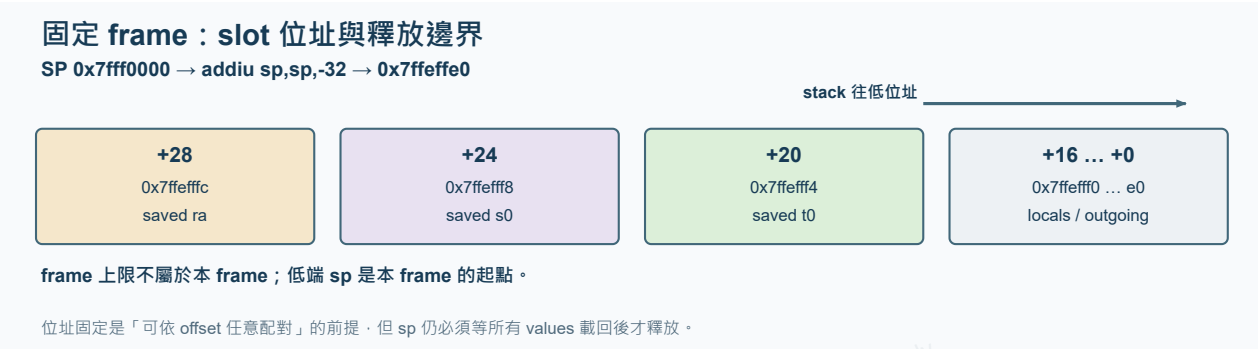
```
int twice_sum(int x, int y) {
    int s = x + y;
    return s * 2;
}
```

假設 signed 加法與乘 2 的 mathematical result 都可表示，概念序列如下：

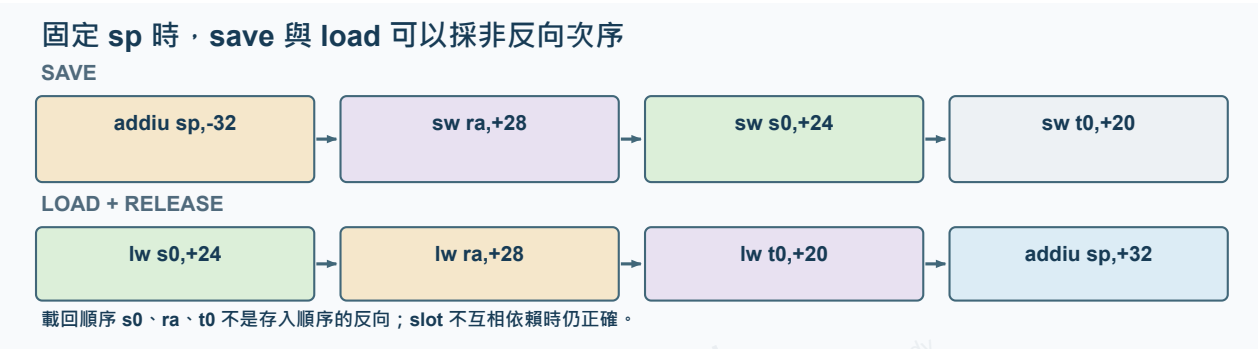
```
twice_sum:
addu $v0, $a0, $a1
sll  $v0, $v0, 1
jr   $ra
nop
```

這個 leaf function 沒有 call，不必保存 `$ra`；它只寫 `$v0`，也不破壞 caller 依賴的 `$s` registers。

固定 frame 的 slot 位址



固定 frame 的 save、load 與 release 時序



令進入函式前 `sp=0x7fff0000`，frame 為 32 bytes。`addiu sp,sp,-32` 後 `sp=0x7ffeffe0`，三個獨立 slot 的位址固定如下。

Slot	位址	存入	載回
`28(sp)`	`0x7ffefffc`	`ra`	`ra`
`24(sp)`	`0x7ffefff8`	`s0`	`s0`
`20(sp)`	`0x7ffefff4`	`t0`	`t0`

一個有效序列是依序存 `ra`、`s0`、`t0`，再依序載回 `s0`、`ra`、`t0`，最後才 `addiu sp,sp,32`。載回次序並非存入次序的反向，結果仍正確，因為 `sp` 在載回期間不變，三個 offset 指向不同 slots，且 load destinations 不互相依賴。

固定 frame 的 save、load 與 release 時序 （續）

「save 與 restore 必須反向」只適用於 push/pop 會改變 `sp` 的 LIFO 序列，或 slot/register 之間存在依賴。固定 frame 的釋放時機則是硬性條件：所有需要的 values 都載回後，才可增加 `sp`；先用新的 `sp` 讀取舊 frame 會錯位。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

遞迴呼叫的 frame trace

令 `main` 在 `0x00400010` 執行 `jal f`，`f` 的回傳位址是 `0x00400018`。`f` 進入時先令 `$sp=0x7fff0000`，配置 32-byte frame 後 `$sp=0x7ffeffe0`：

寫入	位址	值
`sw $ra,28($sp)`	`0x7ffefffc`	`0x00400018`
`sw $s0,24($sp)`	`0x7ffefff8`	caller 的 `$s0`

`f` 在 `0x00400120` 再執行 `jal f`，新的 `$ra` 是 `0x00400128`。inner activation 令 `$sp=0x7ffeffc0`，並把 `0x00400128` 存到 `0x7ffeffdc`。此時兩個 frames 同時存活，任何 `$sp+28` 都指向目前 activation 的 slot，不能拿 inner 的 `$sp` 讀 outer frame。

Base case 返回時，inner 依序載回自己的 `$ra` 與 `$s0`，把 `$sp` 加回 `0x7ffeffe0`，再 `jr` 到 `0x00400128`。Outer activation 繼續執行，最後從 `0x7ffefffc` 載回 `0x00400018`、釋放 32 bytes，再回到 `main`。每個 `jal` 與 `jr` 後都保留 `nop` 作為本章模型的 delay slot；移除它會改變實際執行的 instruction。

這個 trace 同時驗證三件事。第一，`$ra` 必須在 nested call 前保存；第二，frame 的 slot 位址由目前 `$sp` 與固定 offset 決定；第三，release 必須等所有需要的 loads 完成後才增加 `$sp`。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

陣列與指標的指令差異

Array indexing 的位址通常是

$$address = base + i \times element_size.$$

Pointer traversal 每次增加 `element_size`，迴圈中少一次 index scaling，但 compiler 可能在 array 版本做相同 strength reduction。

指標本身可以是 64-bit，也可以指向 invalid 或 one-past-end 之外的位址。C/C++ 的 pointer arithmetic 有 language-level 邊界，超過有效物件範圍即使 machine 能形成 bit pattern，也不保證合法。

索引版本每次可包含 `sll index,2` 與 base addition；pointer版本把位址保存在暫存器、每次加4。下方 clear 範例將兩種穩態序列完整展開為7與5個指令位置；此差距包含 loop test 與 delay slot，但不含 prologue、exit 或 memory stalls。Compiler strength reduction 可把前者改成後者。

C 排序的完整資料流與成本

以下用插入式相鄰交換排序，展示 C 控制流、陣列定址與程序呼叫：

```
for (int i = 0; i < n; i += 1)
  for (int j = i - 1; j >= 0 && v[j] > v[j + 1]; j -= 1)
    swap(v, j);
```

取 `v=[3,1,2]`、`n=3`。`i=0` 時 inner loop 不安裝；`i=1` 時 `j=0`，因 `v[0]=3>v[1]=1` 呼叫 `swap(v,0)`，陣列變成 `[1,3,2]`；`i=2` 時先比較 `v[1]=3>v[2]=2`，交換成 `[1,2,3]`，再比較 `v[0]=1≤v[1]=2` 而停止。此時 sorted invariant 成立。

以下把完整控制流寫成 classic MIPS32；每個 branch 與 `jal` 後的 `nop` 都是本章模型的 delay slot。 此處sort與所附leaf swap採精簡教學呼叫契約；24-byte frame不保留o32要求的16-byte outgoing argument home area，因此只保證與本例leaf callee搭配，不能直接與任意o32編譯的callee互換。若要求完整o32互通，需另為outgoing area保留0..15 offsets並移動saved slots。前置條件是 `n>=0`、`v` 指向 `n` 個 aligned words，且 index calculation 不讓有效位址越界。

C 排序的完整資料流與成本 （續）

```
sort:
addiu $sp, $sp, -24
sw    $ra, 20($sp)
sw    $s3, 16($sp)
sw    $s2, 12($sp)
sw    $s1, 8($sp)
sw    $s0, 4($sp)
addu  $s2, $a0, $zero
addu  $s3, $a1, $zero
addu  $s0, $zero, $zero
for1:
slt   $t0, $s0, $s3
```

https://github.com/xinhi6716/com

C 排序的完整資料流與成本 （續）

```
beq   $t0, $zero, exit1
nop
addiu $s1, $s0, -1
for2:
slti  $t0, $s1, 0
bne   $t0, $zero, exit2
nop
sll   $t1, $s1, 2
addu  $t2, $s2, $t1
lw    $t3, 0($t2)
lw    $t4, 4($t2)
slt   $t0, $t4, $t3
```

https://github.com/xinhi6716/com

C 排序的完整資料流與成本 （續）

```
beq   $t0, $zero, exit2
nop
addu  $a0, $s2, $zero
addu  $a1, $s1, $zero
jal   swap
nop
addiu $s1, $s1, -1
j     for2
nop
exit2:
addiu $s0, $s0, 1
j     for1
```


C 排序的完整資料流與成本 （續）

```
nop
exit1:
lw    $s0, 4($sp)
lw    $s1, 8($sp)
lw    $s2, 12($sp)
lw    $s3, 16($sp)
lw    $ra, 20($sp)
addiu $sp, $sp, 24
jr    $ra
nop
```

令 `v=0x10010000`、`k=1`。`swap` 先算 `k*4=4`，兩元素位址是 `0x10010004` 與 `0x10010008`；它載入兩個 word，再以一個暫存 register 完成 store。Leaf procedure 只使用 caller-saved temporaries，不改用 `$ra` 以外的 saved state，因此不必配置 frame，但 `jr` 在本章 classic MIPS 模型仍需要 delay slot：

C 排序的完整資料流與成本 （續）

```
swap:
sll  $t1, $a1, 2
addu $t1, $t1, $a0
lw   $t0, 0($t1)
lw   $t2, 4($t1)
sw   $t2, 0($t1)
sw   $t0, 4($t1)
jr   $ra
nop
```

只用一個迴圈 iteration 的穩態成本比較 array index 與 pointer clear。Array 版是 `sll+addu+sw+addiu+slt+bne+nop` 共 7 個指令位置；pointer 版是 `sw+addiu+slt+bne+nop` 共 5 個。省下的 2 個是 index scaling 與 base addition，不包括 prologue、初始 guard 或 exit。現代 compiler 可用 strength reduction 與 induction-variable elimination 把 index 版轉成 pointer-like code，所以不能從原始碼寫法直接斷言效能。

這個成本模型要求兩版使用相同 word size、相同 memory traffic、沒有 page fault 或 trap、branch delay slot 固定存在，且比較範圍只含穩態迴圈。對 `n=100` 的指定模型，array body 是 `7×100=700` 個指令位置，optimized pointer body 是 `5×100=500` 個；兩者的初始化與最後 exit check 另計。

編譯與解譯路徑

C compiler 通常先產生 target-specific assembly。Java bytecode 不直接等於 MIPS machine code，JVM 依平台實作可 interpretation、JIT compile 或二者混合。

Interpretation 每次執行 bytecode 都付出 dispatch overhead。JIT 累積 profile 後生成 native code，改善 hot path；warm-up 與 code generation 會增加 startup latency。

ISA 相似不代表語意相同。Integer overflow、unaligned access、atomic operations 與 memory model 都可能不同。

比較 C 與 Java 時要把 type semantics、runtime 與 engine 分開，不能只看一道算術 instruction。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

ARM 比較

ARM 是 load/store RISC 家族，透過 conditional execution、operand shifts 與多種 addressing 設計減少 branches。不同 ARM architecture version 的功能差異很大，不能把一個版本的 instruction 套用到全部 ARM 裝置。

與 MIPS 相同的是 registers、load/store 邊界與 procedure convention 的重要性。不同之處在 encoding、conditional flags 與 ISA extensions。

本章只讀教材版本的 ARM 案例，不把它當成所有現代 ARM64 的規格。

指出 chapter 的 ARM 例子接近 32-bit ARM 時代，與 AArch64 不可混用。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

x86 比較

x86 採 variable-length instructions，encoding 可包含 prefixes、ModR/M、SIB 與 displacement。相同 instruction 可由一至多 bytes 表示。

有利於 code density 與 backward compatibility，代價是 fetch/decode alignment 複雜、instruction boundary 不一定可在固定位置找到。

Intel 與 AMD 實作會把 x86 instructions 解成 internal micro-operations，再用 superscalar pipeline 執行。ISA instruction 數不等於 microarchitecture 的 µops 數。

解釋為什麼 micro-op cache 可隱藏 variable-length decode 的成本，但不能讓 ISA 變成 MIPS。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

x86-64 的 LEA、struct layout 與可變指令長度

採 System V AMD64 ABI 的預設對齊、沒有 packing，且存取的 row 存在、$0 \le j < 4$。考慮 `struct row { int64_t id; int32_t vals[4]; int64_t sum; };`。`id` 在 offset 0，`vals` 在 offset 8、佔 16 bytes，`sum` 在 offset 24，整個 struct 對齊 8 bytes，因此 `sizeof(struct row)=32`。

對 `rows[i].vals[j]`，byte address 是

$$address = base + 32i + 8 + 4j.$$

若 `base=0x3000`、`i=5`、`j=3`，地址是 `0x3000+160+8+12=0x30b4`。假設 `i` 已擴成64-bit並放在 `%rdi`、有號 `int j` 在 `%esi`，而 `base` 在 `%rdx`，可先 sign-extend `j`、把 `i` 乘 32，再使用 SIB 的 scale 4：

```
movslq %esi, %rsi
salq   $5, %rdi
leaq   8(%rdi,%rsi,4), %rax
leaq   (%rdx,%rax), %rax
```

`lea` 只計算 address，不讀 memory；`movslq` 則把 32-bit signed index 擴成 64-bit address arithmetic。x86 instruction 是 variable length，branch displacement 以 byte 計，instruction boundary 也不固定在相同 modulo；這些規則與 fixed-width MIPS 不可互換。

ISA 常見誤解

第一個誤解是「more powerful instruction 一定更快」。一個 instruction 可能只用 decoder 較少精力，但執行 latency 很長，或阻擋 parallel issue。

第二個誤解是「register 多，編譯器一定用得更好」。Register pressure、calling convention 與 spilling 仍決定實際效果。

第三個誤解是「pseudo-instruction 是硬體指令」。Assembler expansion 的 sequence 可能因 register 或 immediate 條件不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

ISA 設計小結

良好 ISA 要在 encoding、compiler、例外、virtual memory、同步與 backward compatibility 之間取捨。固定格式降低 decode 成本，但需要 multi-instruction constants；variable format 增加密度，代價是複雜 decode。

Program correctness 要求 architecture-visible result 一致。Performance 則依 instruction mix、CPI、microarchitecture 與 memory path。

本章所有 address 與 condition 都要交代位元寬、alignment 與 sign/zero extension。

本章lw/sw的base及displacement以bytes計；branch immediate則以4-byte instruction為單位。ADDIU會sign-extend而ORI會zero-extend；相同16-bit欄位必須先依opcode決定解釋。

指令集歷史

早期處理器為少量、固定欄位與簡單指令，便於實現與 compiler 產生程式。之後 CISC 加入複雜 addressing 與較高 code density；RISC 把操作規則化，將複雜工作交給 compiler。

現代處理器界線模糊。RISC instruction 可以 decode 成 µops，CISC instruction 也可以在內部拆成規則化操作。

歷史閱讀重點是設計限制，而不是把某個時代的口號當成永恆定理。

面向	機制與必須一併檢查的成本
Code size	密集encoding可減fetch bytes；複雜指令仍可能需多個內部operations
Decode	固定欄位可平行讀取；變長encoding需先辨識邊界
Memory traffic	Load/store數、寬度、locality與cache miss決定bytes，不能只看mnemonic
Parallel issue	真資料相依及functional-unit可用性限制重疊；單條做更多工作未必更易並行
Compatibility	保留舊binary需維持ISA/ABI語意；內部decode與execution可重新實作

本章重點

- ISA 版本、delay slot 與 assembler 指令順序決定控制流程。
- 位址由 base 加 byte offset；載入前先檢查元素大小、範圍與對齊。
- signed overflow 會否 trap 取決於指令；ABI 規定保存義務與 layout。
- LL/SC 的成功、記憶體排序與公平性是不同保證。

參考資料與署名

Lin Cing，《計算機組織》手寫筆記。 Patterson and Hennessy, Computer Organization and Design, revised fourth edition, Chapter 2. CSO course slides, Chapter 2.

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study

同一串位元，先問它代表什麼

硬體只收到有限長度的位元；**位元如何解讀、結果保留幾位、超出範圍如何處理**，才決定運算的意義。

問題	必須先固定	本章追蹤的結果
整數加減	位寬、有號或無號、溢位政策	結果位元、進位與溢位
整數乘除	暫存器寬度、每輪操作、商的取整方式	逐輪狀態、最後乘積或商餘數
浮點運算	格式、有效精度、捨入模式、例外環境	編碼、捨入結果與旗標

例如 `11111111` 可代表無號的 255，也可代表八位元二補數的 −1。位元沒有改變，解讀不同；後續的比較、除法與高位擴充也就不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

三種結果規則：截低位、飽和、捨入

固定寬度無法表示所有整數與實數。先算出數學上的精確值，再看指定的格式如何保存它。

八位元輸入 100+100	保存的結果	解讀
保留低八位	`11001000`	無號為 200；二補數為 −56
有號飽和	`01111111`	夾到有號上界 127
有號且檢查溢位	依指令處理例外	數學和 200 超出 [−128,127]

浮點數則依捨入模式選可表示的候選值，不是把整個實數當成整數直接截低位。格式、運算規則與時序是三個問題：**得到正確結果，不代表只需一個週期。**

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.1 先寫清楚運算模型

無號 n 位元數的範圍是 $[0, 2^n - 1]$；n 位元二補數的範圍是 $[-2^{n-1}, 2^{n-1} - 1]$。加減若只保留低 n 位，位元結果等於模 2^n 運算；有號的數學結果是否可表示，仍要另外判斷。

有限浮點輸入的基本運算則先求精確值，再依目標格式與捨入模式映回可表示集合：

$$y = \mathrm{round}(x \circ z).$$

此式描述一般有限值路徑；NaN、無窮大、除以零與超出範圍要套用另外的規則。整數 `0/0` 的行為依指令或語言而定；IEEE 浮點 `0/0` 屬 invalid，停用 trap 時通常回傳 quiet NaN。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.2 二補數：相同加法器，不同範圍判斷

n 位元二補數中，最高位帶負權重：

$$x = -b_{n-1}2^{n-1} + \sum_{i=0}^{n-2} b_i 2^i.$$

加法器逐位相加的規則與無號加法相同。減法利用 $a - b = a + \bar{b} + 1$，把 b 的每位反相、最低位帶入進位 1，就能共用加法器。

例如四位元 `0101+0011=1000`。無號解讀是 5+3=8；二補數解讀時，5 和 3 均合法，但數學和 8 超出上界 7，`1000` 反而表示 −8。**低位結果正確與有號結果可表示，必須分開檢查。**

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

有號溢位：為什麼要比較符號？

一正一負相加，和介於兩個輸入之間，因此不會超出有號範圍。同號相加才可能超界；超界後保留低 n 位，結果符號翻轉。令輸入與結果的符號位為 s_a, s_b, s_r，則

$$ov = \overline{s_a \oplus s_b} \wedge (s_a \oplus s_r).$$

減法的對應條件為 $ov = (s_a \oplus s_b) \wedge (s_a \oplus s_r)$：異號相減才可能超界，且結果符號與 a 相反。

八位元 `0x7f+1` 有有號溢位卻沒有最高位進位；`0xff+1` 有最高位進位卻沒有有號溢位。進位離開最高位判斷的是**無號加法是否超界**，不能直接當成有號溢位。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

逐位核對：進入與離開符號位的進位

對八位元加法，令 c_7 進入符號位、c_8 離開符號位。有號溢位等價於 $ov = c_7 \oplus c_8$。

運算	低八位結果	c_7	c_8	有號溢位
`0x7f+0x01`	`10000000`	1	0	1
`0x80+0xff`	`01111111`	0	1	1
`0x80-0x01`	`01111111`	0	1	1
`0xff+0x01`	`00000000`	1	1	0

第三列實作為 `10000000+11111110+1`，最低位輸入進位為 1。符號位滿足 $s_r = s_a \oplus s_b \oplus c_7$，而其進位輸出為三輸入的多數決；代入同號與異號兩種情況，即得上述 XOR 判定。減法表中的 c_8 是加法器輸出，**不是一律等於 borrow（借位）**。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

加法器的等待時間與指令例外是兩件事

漣波進位加法器（ripple-carry adder）的高位結果要等低位進位，最長路徑隨位寬成長。前瞻進位或平行前綴結構，用更多邏輯與連線縮短依賴鏈；實際時脈仍須容納最慢可成立路徑及暫存器成本。

在本章傳統 MIPS32 案例，`add` 檢查有號溢位；發生例外時不能把錯誤結果當成正常寫回。`addu` 則保留模 2^{32} 的結果，不因有號超界而 trap。名稱中的 u 不表示加法器只能接收正數。

因此要分別回答：位元結果是什麼、指令允許它寫回嗎、硬體多久能產生結果。只看運算元的平均情況，不能證明最壞時序。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

飽和與 SIMD：每個 lane 都有自己的邊界

飽和運算（saturating arithmetic）超界時夾到端點。例如有號八位元 100+100 得 127；保留低八位則得到 −56。音訊振幅可能需要飽和，雜湊或校驗碼的模運算則不能任意改用它。

SIMD 將一個暫存器切成多個 lane，分別做短整數運算。**進位不跨 lane 傳遞。** 例如兩個八位元無號 lane 各自計算 `(255,1)+(1,2)`，截低位結果是 `(0,3)`，不是把整串十六位元當成一個整數相加。

飽和會失去可逆性：127 可由許多超界和得到，無法只靠結果還原輸入。選指令前要確認 lane 寬度、有號解讀與飽和政策。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.3 乘法：把乘數的每一位變成一列

兩個 n 位元無號數的完整乘積最多需要 2n 位，因為 $(2^n-1)^2 < 2^{2n}$。32 位元輸入的完整乘積最多需 64 位；若只需要低 32 位，也可直接計算模 2^{32} 的結果，硬體不必先形成高半部。

把乘數展開為 $Q=\sum_{k=0}^{n-1} q_k 2^k$，便得到

$$MQ=\sum_{k=0}^{n-1} q_k (M \ll k).$$

q_k=1 就加上左移 k 位的 M，q_k=0 就加零。這些列稱為部分乘積（partial products）。循序硬體逐輪累加，平行硬體先同時生成再壓縮；兩者都要保留各列的位權。

先固定無號或二補數解讀。相同位元在有號乘法中的高位權重不同，不能直接照搬無號部分乘積。

循序乘法：13×11 的四輪狀態

M=`1101`、Q=`1011`、A=0。每輪讀 Q_0，為 1 就做 $C:A=A+M$，否則 C=0、A 不變；再將完整的 (C,A,Q) 邏輯右移一位，C 進入 A 的最高位。

輪次	Q_0	加法結果 $C:A$	右移後 A	右移後 Q
0			`0000`	`1011`
1	1	`0:1101`	`0110`	`1101`
2	1	`1:0011`	`1001`	`1110`
3	0	`0:1001`	`0100`	`1111`
4	1	`1:0001`	`1000`	`1111`

最終 `(A,Q)=10001111`$_2$`=143=13×11`。C 保存當輪加法的第五位；不能在右移之前把它丟掉。

循序乘法：用不變量連起每輪狀態

固定初始乘數為 q，完成 k 回合的暫存器為 A_k, Q_k，定義 $R_k = 2^n A_k + Q_k$。精確不變量是

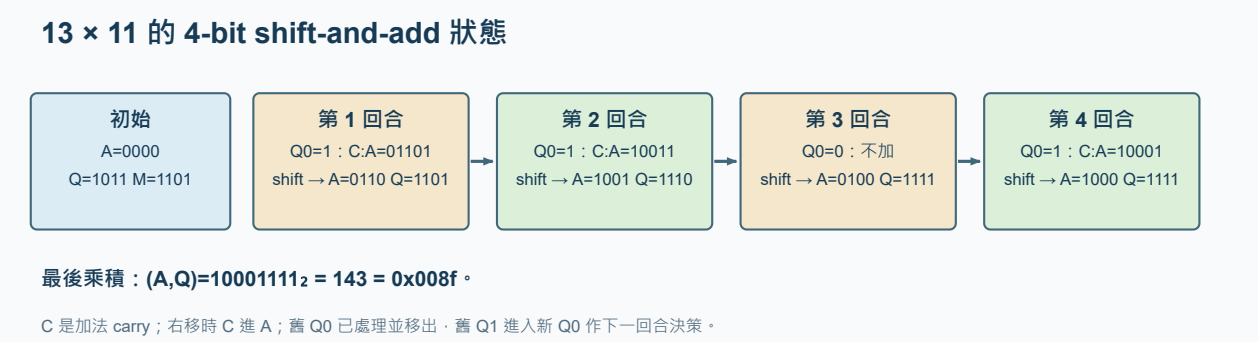
$$R_k = \left\lfloor \frac{q}{2^k} \right\rfloor + M(q \bmod 2^k)\, 2^{n-k}, \qquad 0 \le k \le n.$$

$k = 0$ 時 $R_0 = q$，成立。若 $k < n$，右項第二項為偶數，所以當前 Q_k 的最低位恰為原乘數第 k 位 q_k。依此位決定加法後，完整 $C : A : Q$ 的值為 $R_k + q_k M 2^n$；右移得到

$$R_{k+1} = \left\lfloor \frac{R_k + q_k M 2^n}{2} \right\rfloor = \left\lfloor \frac{q}{2^{k+1}} \right\rfloor + M(q \bmod 2^{k+1}) 2^{n-k-1}.$$

這使用 $q \bmod 2^{k+1} = (q \bmod 2^k) + q_k 2^k$，因此歸納延續。$k = n$ 時因 $q < 2^n$，有 $R_n = Mq$；A 為乘積高半部，Q 為低半部。進位 C 保留本回合加法的溢位並隨右移進入 A，沒有遺失該位。13×11的實際 R_k 依序為11、109、158、79、143。

循序乘法：跨暫存器的位元如何移動？



成本模型先寫清楚才可比較：

$$T_{\text{serial}} = t_{\text{setup}} + n\, t_{\text{iter}} + t_{\text{finalize}}.$$

每輪加法與移位若可同週期完成，32 輪才對應 32 個運算週期；若分別占一週期，就需另算。管線化可縮短啟動間隔，單筆延遲仍須依階段數與時脈週期計算。

有號乘法：先決定位元寬度

對兩個 n-bit 二補數輸入，完整乘積放在 $2n$ 個有號位元中。可以先處理大小、最後套用符號，也可以直接用 Booth 重編碼產生帶正負號的部分乘積。

不能在原本的有號寬度內，直接對最小負數取絕對值。 例如四位元二補數的範圍是 $[-8, 7]$，-8 的正大小 8 需要五個有號位元；若改用四位元無號容器，`1000` 才能代表大小 8。

以下先固定 radix-2 Booth：輸入 M, Q 各為 n-bit 有號數；M 稱被乘數，Q 稱乘數。內部將 M 符號擴充至 $n+1$ 位，累加器 A 也用 $n+1$ 位，並額外保存一位 q_{-1}。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Booth 的兩個位元在判斷什麼？

把原乘數的位元寫成 $q_{n-1} \cdots q_0$，補 $q_{-1} = 0$。第 i 個重編碼係數為 $d_i = q_{i-1} - q_i$。本輪讀取順序固定是 **目前最低位在前、上一位在後**：

$Q_0\, q_{-1}$	d	右移前的操作
`00`	0	A 不變
`01`	+1	A ← A + M
`10`	−1	A ← A − M
`11`	0	A 不變

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

為什麼重編碼保留二補數的值？

把每個原位元分別收集。最低位之外的正項來自下一個係數，負項來自目前係數；最高位沒有下一項抵消，留下二補數的負權重。

重編碼確實保留二補數的值，因為

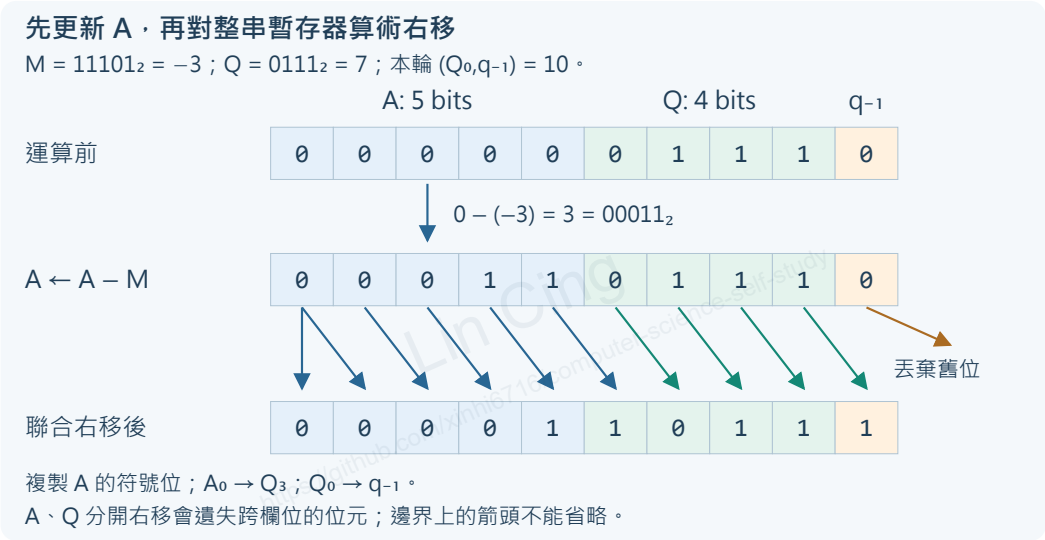
$$\begin{aligned}\sum_{i=0}^{n-1}(q_{i-1}-q_i)2^i &= \sum_{i=0}^{n-2} q_i 2^i - q_{n-1}2^{n-1} \\ &= Q_{\text{signed}}.\end{aligned}$$

中間位元的兩項合成 $(2^{i+1}-2^i)q_i = 2^i q_i$；最高位只留下負權重。這是規則對負乘數也成立的理由。

例如 `0111` 得到低位至高位的係數 −1、0、0、+1，因此值是 −1+8=7；`1101` 得到 −1、+1、−1、0，因此值是 −1+2−4=−3。係數可為負，總和仍是原乘數。

一輪先加減，再聯合算術右移

初始化 $A=0$、$Q=$ 輸入乘數位元、$q_{-1}=0$。每輪先依表更新 A，再將串接的 (A,Q,q_{-1}) **整串算術右移一位**，共做 n 輪。



符號擴充只複製最左端 A 的符號位；A_0 進入 Q 的最高位，舊 Q_0 進入 q_{-1}。結束後丟掉 q_{-1}，(A,Q) 多出的一個最左符號位也是冗餘位；剩下 $2n$ 位就是完整乘積。

−3 乘 7：四輪暫存器追蹤

取 $n=4$，$M=-3$ 擴位為 `11101`；起始 $(A,Q,q_{-1})=$`00000 0111 0`。每列最後才右移，不能用右移後的 pair 決定同一列操作。

輪次	舊 Q_0q_{-1}	A 的操作	加減後 A Q q_{-1}	右移後 A Q q_{-1}
1	`10`	−M	`00011 0111 0`	`00001 1011 1`
2	`11`	0	`00001 1011 1`	`00000 1101 1`
3	`11`	0	`00000 1101 1`	`00000 0110 1`
4	`01`	+M	`11101 0110 1`	`11110 1011 0`

最後 $(A,Q)=$`11110 1011`，是九位元二補數的 -21；移除冗餘符號位得到 `11101011`，八位元值仍為 -21。

原乘數 `0111` 的係數由低位到高位是 $(-1,0,0,+1)$，所以 $7=-1+8$，$(-3)\cdot 7=3-24=-21$。四輪中只有兩次加減，另外兩輪仍須移位。

Booth 數例：正被乘數與負乘數

M = 00010 (+2) Q = 1101 (−3) A = 00000 q_{-1} = 0

輪次	舊 Q_0q_{-1}	操作	算術右移後：A Q q_{-1}
1	10	A − M	11111 0110 1
2	01	A + M	00000 1011 0
3	10	A − M	11111 0101 1
4	11	不變	11111 1010 1

令 $n=4$、$M=2$、$Q=-3$。圖中 A,M 均擴為 5 bits，Q 保持 4 bits；每輪先依舊的 Q_0q_{-1} 選操作，再將整個 (A,Q,q_{-1}) 算術右移。

四輪後 $(A,Q)=$ `11111 1010` 是 9-bit 的 −6；移除冗餘符號位得 8-bit `11111010`，與 $2\times(-3)=-6$ 一致。

多留一個符號位，才能涵蓋最小負數

對 $M=-8, Q=-3$，第一個 pair 是 `10`，必須計算 $A-M=+8$。若 A, M 都只用四位元，`1000` 被解讀成 -8，第一輪便錯了。

−8 × (−3)：取負數之前，先擴充符號位

只用 4-bit A、M：失敗

M = 1000_2 = −8

−M = 1000_2，仍被解讀為 −8

第一次 A−M：1000，不是 +8

右移後：1100 0110 1

四輪結果：11101000_2 = −24

使用 5-bit A、M：正確

M = 11000_2 = −8

−M = 01000_2 = +8

第一次 A−M：01000 = +8

右移後：00100 0110 1

四輪結果：00011000_2 = +24

兩邊都從 A=0、Q=1101_2、q_{-1}=0 開始；差異是加減器與 A 的寬度。

先用五位元精確保存 +8，右移才會得到正確的 +4；四位元路徑卻從 −8 移到 −4。下一頁證明多留一位對所有輸入都足夠。

加減與右移的範圍證明

五位元不是任意補救：每次移位後，A 都落在 $[-2^{n-1}, 2^{n-1}-1]$。加減 n-bit 的 M 後，範圍包含於 $[-2^n, 2^n-1]$，可由 $n+1$ 位精確表示；再右移，便回到前述範圍。因此本模型不依賴中間溢位碰巧抵消。

起始 A=0 符合上述範圍。若某輪開始時 A 已在此範圍，A+M 的最小值是 -2^n，最大值是 2^n-2；A−M 的範圍則是 $[-2^n+1, 2^n-1]$。不操作時也包含於同一個 n+1 位範圍。

算術右移後的新 A，是加減結果除以 2 並向下取整，因此又落回 $[-2^{n-1}, 2^{n-1}-1]$。由歸納法，每輪的加減都能精確執行，包含被乘數等於最小負數的情況。

把暫存器狀態寫成可追蹤的不變量

令 u 是原乘數位元的**無號值**，$d_i = q_{i-1} - q_i$ 仍從原乘數位元定義。做完 k 輪後，令

$$R_k = 2^n \,\mathrm{signed}(A_k) + \mathrm{unsigned}(Q_k), \quad D_k = \sum_{i=0}^{k-1} d_i 2^i.$$

不變量是

$$R_k = \left\lfloor \frac{u}{2^k} \right\rfloor + M 2^{n-k} D_k, \qquad 0 \le k \le n.$$

起始 $R_0 = u$、$D_0 = 0$。對 $k < n$，Q_k 的低 $n-k$ 位尚未被來自 A 的位元覆蓋，故 Q_0 正是原來的 q_k，歷史位則是 q_{k-1}。因此硬體讀到的 pair 確實選出 d_k。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

一輪更新保留不變量，最後就是乘積

更新 A 相當於把 $d_k M 2^n$ 加進 R_k；整串算術右移使

$$R_{k+1} = \left\lfloor \frac{R_k + d_k M 2^n}{2} \right\rfloor.$$

代入不變量。當 $k < n$，含 M 的項可被 2 整除，即使它是負數也一樣，因此

$$R_{k+1} = \left\lfloor \frac{u}{2^{k+1}} \right\rfloor + M 2^{n-k-1}(D_k + d_k 2^k).$$

這就是下一輪的形式。做完 n 輪，$0 \le u < 2^n$ 使第一項為零；由重編碼恆等式，

$$R_n = M D_n = M Q_{\mathrm{signed}}.$$

算術右移對負整數相當於向負無窮方向取整，不是向零截斷；這個差別已包含在上面的 floor 中。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

減少加減次數，不等於一定減少週期

`0111` 只在 1 的連續區段兩端運算；`0101` 則四個 pair 都是 `10` 或 `01`，需要四次加減。後者的無號 shift-add 只需兩次加法，故 radix-2 Booth 並不對每個輸入都較省。

在本文每輪固定一次控制與移位的模型，兩者都執行 n 輪。是否略過零區段、加減與移位是否同週期、是否管線化，必須另給硬體時序才能換算 latency（單次延遲）或 throughput（吞吐量）。不能直接把「少兩次加法」寫成「快兩倍」。

Radix-4 是另一種重編碼：每次處理兩個新位元，搭配一個重疊的歷史位。它改變部分乘積數量與選取電路，不能只把上圖的右移改成兩位就當作完整規格。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Radix-4：三位元決定一個帶符號的係數

對偶數 n，第 j 組讀 $(q_{2j+1}, q_{2j}, q_{2j-1})$，其中 $q_{-1} = 0$。相鄰組重疊一位；奇數寬度須先補足符號位。

三位元	係數 c_j	部分乘積的倍數
`000`	0	0
`001`	+1	+M
`010`	+1	+M
`011`	+2	+2M
`100`	−2	−2M
`101`	−1	−M
`110`	−1	−M
`111`	0	0

Radix-4 的係數從哪裡來？

把相鄰兩個 radix-2 係數併為一組，保留低位的權重：

$$\begin{aligned} c_j &= d_{2j} + 2d_{2j+1} \\ &= (q_{2j-1} - q_{2j}) + 2(q_{2j} - q_{2j+1}) \\ &= -2q_{2j+1} + q_{2j} + q_{2j-1}. \end{aligned}$$

所以 $Q = \sum_j c_j 4^j$。三個位元都取 0 或 1，係數只能是 −2、−1、0、1、2。例如 `011` 給 0+1+1=2；`100` 給 −2+0+0=−2；`111` 給 −2+1+1=0。

每往高位移一組，基礎權重乘 4，而非乘 2。最低組補歷史位 0；之後每組共用前一組的最高位。例如 `001111` 由低至高讀成 `110`、`111`、`001`，得到 −1、0、1，因此 15=−1+0×4+1×16。

Radix-4 數例：−7 乘 15

用六位元輸入 $M = -7$、$Q =$`001111`。本頁生成完整十二位元部分乘積；先符號擴充，再依 4^j 左移。

j	位元位置	讀到的三位元	c_j	$c_j \cdot 4^j$	十二位元部分乘積
0	$q_1\ q_0\ q_{-1}$	`110`	−1	+7	`000000000111`
1	$q_3\ q_2\ q_1$	`111`	0	0	`000000000000`
2	$q_5\ q_4\ q_3$	`001`	+1	−112	`111110010000`

$15 = -1 + 0 \cdot 4 + 1 \cdot 16$，所以乘積為 $7 - 112 = -105$，十二位元結果是 `111110010111`。加法在十二位元容器中進行，最高位外的 carry 不屬於結果；其有號值仍是 -105。

Radix-4 的內部寬度要重新分析。 若被乘數是最小負數，$-2M = 2^n$ 需要 $n+2$ 個有號位元。本文先在 $2n$ 位形成部分乘積；沒有宣稱 radix-2 的 $n+1$-bit 累加器可直接套用於所有 radix-4 設計。

乘法加速：先把部分乘積排成同一欄位

以下只處理四位元**無號乘法**：M=13、Q=15。先產生四列部分乘積，每列已依乘數位元的位置左移，全部放在八位元容器中。

列	來源	八位元內容	無號值
P_0	$M \cdot q_0$	00001101	13
P_1	$M \cdot q_1 \cdot 2$	00011010	26
P_2	$M \cdot q_2 \cdot 4$	00110100	52
P_3	$M \cdot q_3 \cdot 8$	01101000	104

目標是把四列的總和 195 算出來。若逐次把兩列加成一個普通二進位數，每次加法都可能等待跨欄進位。Carry-save 的做法是：**中途先保留兩列，最後才把它們加成單一結果**。

三個同權重位元，改存成兩個位元

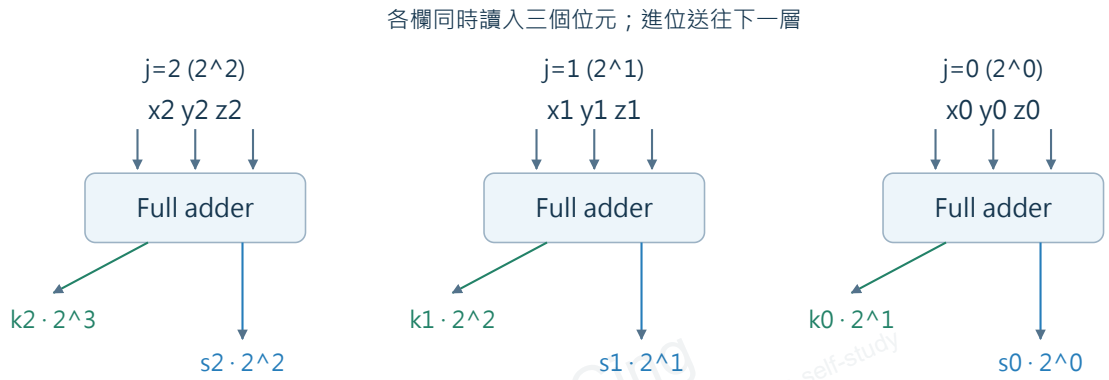
第 j 欄的 x_j、y_j、z_j 都帶權重 2^j。全加器（full adder）只看這三個輸入，輸出同欄的 s_j 與下一欄的 k_j：

$$s_j = x_j \oplus y_j \oplus z_j, \qquad k_j = (x_j y_j) \vee (y_j z_j) \vee (z_j x_j).$$

$x_j+y_j+z_j$	對應輸入	s_j	k_j	恆等式
0	000	0	0	0=0+2・0
1	001、010、100	1	0	1=1+2・0
2	011、101、110	0	1	2=0+2・1
3	111	1	1	3=1+2・1

將各欄恆等式乘上 2^j 再相加，得到 X+Y+Z=S+C，其中 $S = \sum_j s_j 2^j$、$C = \sum_j k_j 2^{j+1}$。**C 已經包含左移一位**，後面不可再移一次。此處的乘法 $x_j y_j$ 是位元 AND，$\vee$ 是 OR。

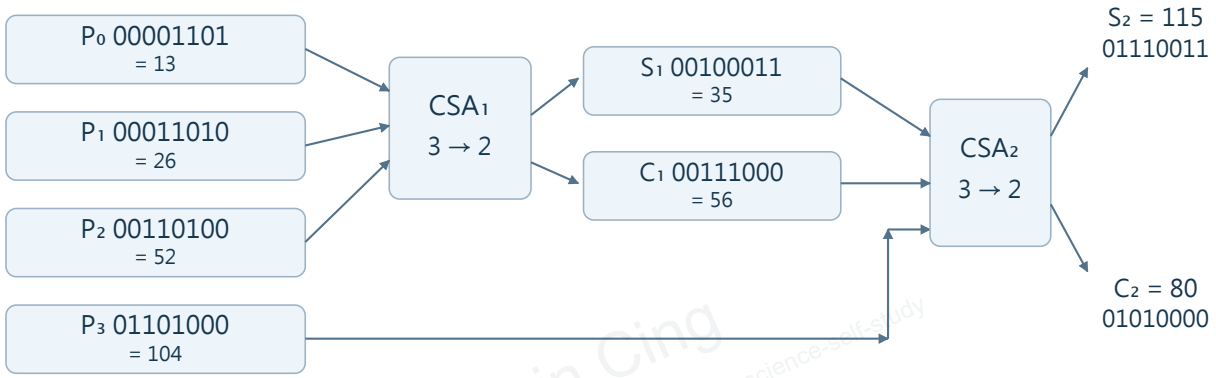
Carry-save 省下的是「同一層等待進位」



每個全加器都只讀**本層輸入的三列**；它產生的進位寫入下一層的 C 列，不拿來驅動本層左鄰的全加器。圖中 x、y、z 的三個位元可同時備妥，三欄也可並行計算。

這不代表進位消失：它成了另一列資料。S 與 C 各自都還不是總和；只有 S+C 才代表原三列。若每層都立即把 S+C 算完，就重新引入了完整進位傳播。

13×15：四列經兩層壓縮，再相加



第一層壓縮 P_0、P_1、P_2，得到 S_1=35、C_1=56，並直接保留 P_3=104；總和仍為 35+56+104=195。第二層得到 S_2=115、C_2=80；兩列相加才得到 195。

圖中的 C_1、C_2 都已按實際權重左移。每一層只壓縮列數，沒有把數值除以 2，也沒有把尚未計入的進位丟掉。

最後的加法，確實還要處理進位

現在做普通加法 $01110011_2 + 01010000_2$。令 c_j 是進入第 j 欄的進位，初始 $c_0=0$；由最低位開始：

j，由低到高	0	1	2	3	4	5	6	7
$S_2[j]$	1	1	0	0	1	1	1	0
$C_2[j]$	0	0	0	0	1	0	1	0
輸入進位 c_j	0	0	0	0	0	1	1	1
結果位	1	1	0	0	0	0	1	1
輸出進位 c_{j+1}	0	0	0	0	1	1	1	0

反向讀結果欄得到 $11000011_2 = 195$。第 4 欄產生的進位一路影響到第 7 欄；這就是最後的 carry-propagate adder（CPA）需要解決的相依。CPA 可用 ripple-carry 或更快的 prefix 結構，不能視為零延遲。

何時可以丟掉最高位外的進位？

對任意三個 W 位元無號數，精確 S 需要 W 位，C 可能需要 W+1 位，而精確總和可能需要 W+2 位。例：W=4、X=Y=Z=15，S=15、C=30，所以總和為 45，不能放進四位元。

若明定只取低 W 位，則可計算

$$X + Y + Z \equiv S + (C \bmod 2^W) \pmod{2^W}.$$

上例四位元 C 只剩 14；15+14=29，再取低四位得到 13，恰等於 45 mod 16。**模數結果正確，不等於精確總和沒有溢位**。

本節無號乘法不同：輸入小於 2^n，所有非負部分乘積的總和小於 2^{2n}。因此每層保存的非負列也不會超過此總和，2n 位足以容納。若使用 Booth 負部分乘積，則須先在指定寬度做二補數與符號擴充；例如前節十二位元的 7+0+3984=3991，低十二位解讀為 −105。此時不能把各列當成原本的無號部分乘積來證明範圍。

列數變少，不等於每一層都是一次完整加法

採用「每層將三列分組壓成兩列，剩餘列直接往下傳」的模型，列數滿足

$$R_{\ell+1} = 2\lfloor R_\ell/3 \rfloor + (R_\ell \bmod 3).$$

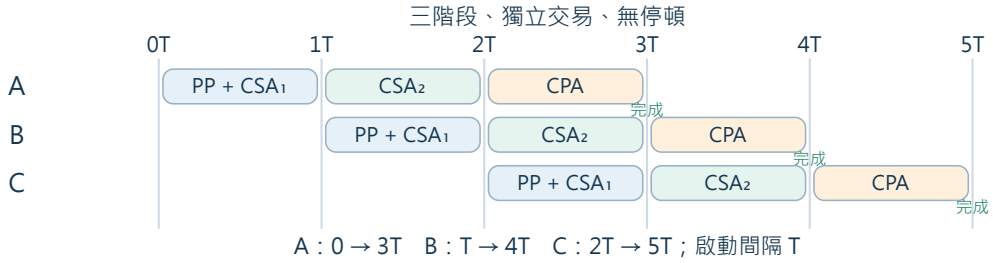
32 列依序變成 22、15、10、7、5、4、3、2，共八層壓縮。這是指定分組模型的層數；實際 Wallace／Dadda 位元堆可逐欄安排全加器與半加器，不能只憑名稱套用此精確數字。

對每個 CSA 層的延遲上界 t_CSA，最長路徑可估為

$$T \le t_{\mathrm{PP}} + 8t_{\mathrm{CSA}} + t_{\mathrm{CPA}} + t_{\mathrm{wire}}.$$

其中 t_PP 包含部分乘積生成；t_wire 明列額外布線成本。八層 CSA 不是八次 W 位 CPA。平衡的二輸入普通加法樹，32 列只需五層，卻每層都可能有進位傳播。兩者延遲要代入電路與負載資料，不能用 8 和 5 直接比快慢。

Pipeline：較常接受新輸入，不代表較早得到同一筆結果



假設把前述四列數例切成三個暫存器階段：①生成部分乘積並完成 CSA₁，②完成 CSA₂，③完成 CPA。每階段都能在共同時脈週期 T 內完成，沒有停頓，且相鄰交易彼此獨立。

交易 A 在邊緣 0 接受、邊緣 3 完成；B 在邊緣 1 接受、邊緣 4 完成。單筆延遲是 3T，啟動間隔（initiation interval）是 T。N≥1 筆獨立交易的最後一筆於 $(N+2)T$ 完成。

若 B 必須使用 A 的乘積，就不能在邊緣 1 當作已取得結果。T 還須容納最慢階段、暫存器與時脈相關成本；未切 pipeline 的電路沒有相同的 T 定義，不能由這張表推論固定三倍加速。

MIPS 乘法：HI 與 LO 分別保存哪一半？

傳統 MIPS32 的 `mult` 以有號方式解讀兩個輸入，`multu` 以無號方式解讀；兩者都產生完整 64 位元乘積，HI 保存高 32 位、LO 保存低 32 位。`mfhi`、`mflo` 再將指定半部搬到一般暫存器。

例如 `0xffffffff×2`：有號解讀為 −1×2，完整結果為 `0xfffffffffffffffe`；無號解讀為 4294967295×2，結果為 `0x00000001fffffffe`。**低半部相同，高半部不同。**

這兩條指令不因乘積超出 32 位元而自動產生有號溢位 trap。若程式要求結果可放入某種 32 位元型別，還須檢查高半部是否符合該型別的延伸規則。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.4 除法：先固定商與餘數的規則

無號被除數 D、非零除數 M 要求

$$D = QM + R, \qquad 0 \le R < M.$$

等式與餘數範圍一起決定唯一的 Q、R。只有等式仍不夠，例如 13=2・5+3，也等於 1・5+8；後者不符合餘數範圍。

本節先用恢復餘數除法（restoring division）處理無號輸入，再處理有號的取整規則。除數為零須先排除；有號最小負數除以 −1 則另有可表示範圍問題。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

每輪先帶下一位進來，再試減一次

每輪處理一個被除數位元 d。假設原餘數為 A，先形成 $T = 2A + d$，試算 $T - M$。

試減結果	新商位 b	新餘數 A′
$T - M \geq 0$	1	$T - M$
$T - M < 0$	0	T；若已做減法，就加回 M

已知 $0 \leq A < M$、$d \in \{0, 1\}$，所以 $0 \leq T < 2M$。一次減法就足夠：減或不減之後，兩個分支都回到 $0 \leq A' < M$。這正是每輪只產生一個商位的原因。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

13÷5：分開看已讀前綴、商與餘數

由左至右讀取 D=1101。表中的商只包含已產生的位元，不是後面硬體圖的整個 Q 暫存器。

k	新位 d	已讀前綴 P_k	試算 T	T−5	已產生商	新餘數
0	—	0	—	—	空	0
1	1	1	1	−4	0	1
2	1	3	3	−2	00	3
3	0	6	6	1	001	1
4	1	13	3	−2	0010	3

每列都可核對 $P_k = q_k M + A_k$。例如第三列是 6=1・5+1；最後得到 13=2・5+3，且餘數 3 小於除數 5。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Q 暫存器同時裝著未讀輸入與已產生的商

硬體初值是 A=`00000`、Q=`1101`、M=`00101`。每輪先將 A、Q 合併左移；舊 Q 的最高位進入 A，Q 的最低位空出來存新商位。

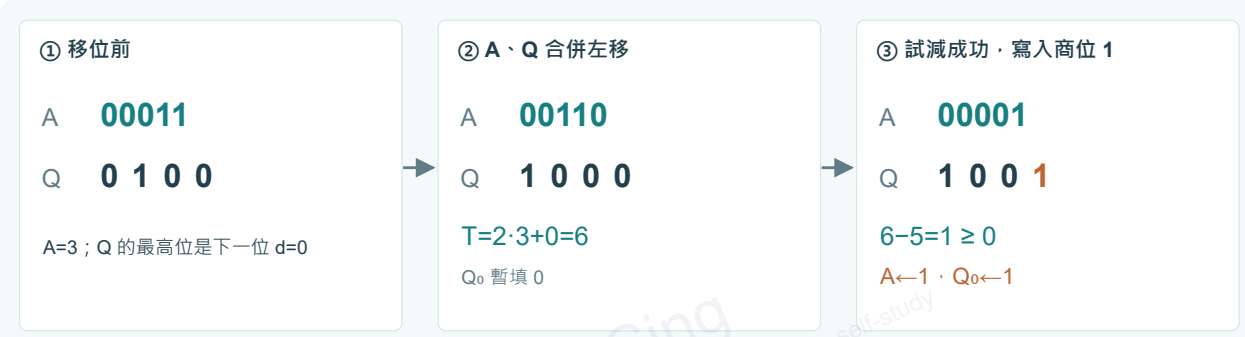
輪次 k	餘數 A（5 位）		Q：未讀輸入 → 已產生商	商 q_k	$P_k=q_k\cdot5+A$
0	00000	= 0	1 1 0 1	0	0
1	00001	= 1	1 0 1 | 0	0	1
2	00011	= 3	0 1 | 0 0	0	3
3	00001	= 1	1 | 0 0 1	1	6
4	00011	= 3	0 0 1 0	2	13

綠：未讀的被除數位元　橘：商位　|　只有 k=4 時，整個 Q 才是商 2。

前 k 輪的數學商 q_k，不等於同一時刻整個 Q 的無號值。 前者只含圖中的商區；後者還混有未讀的被除數位元。到第 n 輪，未讀區才完全消失，Q 才是最終商。

第三輪：跨暫存器移位後，才決定新商位

第二輪結束時 A=3、Q=`0100`。接下來讀的是原被除數第三位 0，故左移形成 T=6，再試減 M=5。



舊 Q_3 進入 A_0；其餘 Q 位元左移。最後一個空位保存本輪商位，不是另一個輸入位元。

圖中試減結果為 +1，寫回 A=`00001`，並把 Q_0 設為 1，得到 Q=`1001`。這個 Q 尚不是最終商 9；最高位的 1 仍是最後一個未讀被除數位元。

一般證明：前綴不變量與餘數範圍

起始 $P_0 = q_0 = A_0 = 0$。假設 $P_k = q_k M + A_k$ 且 $0 \le A_k < M$。下一位為 d，令 $T = 2A_k + d$，選 b=1 當且僅當 T≥M，則

$$P_{k+1} = 2P_k + d = (2q_k + b)M + (T - bM).$$

因此 $q_{k+1} = 2q_k + b$、$A_{k+1} = T - bM$，等式持續成立；由 T<2M，餘數也保持在 [0,M)。做完 n 輪後 P_n=D，恰得到要求的商餘數。

本教學實作以 n+1 位保存 T 與試減差：T≤2^n−1，且 −(2^n−1)≤T−M≤2^n−1，皆可精確表示。T 的上界也可由「已讀前綴最多 n 位」與餘數不大於此前綴推出，不能只靠 T<2M 就把任意 T 當成 n+1 位有號數。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

有號除法：向零截斷與餘數符號

本節固定商向零截斷（truncate toward zero）。先以無號容器計算兩輸入的大小，再依符號還原；非零餘數的符號與被除數相同。

D	M	商 Q	餘數 R	驗算 D=QM+R
7	2	3	1	7=3・2+1
−7	2	−3	−1	−7=(−3)・2−1
7	−2	−3	1	7=(−3)・(−2)+1
−7	−2	3	−1	−7=3・(−2)−1

此時 $|R| < |M|$，但 R 不必非負。若規定商向下取整，−7÷2 改得商 −4、餘數 +1；等式仍成立，規則已不同。零餘數不需要附加正負號條件。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

邊界與時序：不能只把每輪位數換成倍速

n 位元最小負數的大小 2^{n-1} 可放入 n 位元無號容器，卻不能放入 n 位元正有號數。最小負數除以 −1 的正商超出有號上界，還原符號前就要檢查。

傳統 MIPS32 的 `div`、`divu` 以 LO 保存商、HI 保存餘數；本章版本不因除以零或有號除法溢位自動產生算術 trap，這些輸入下的 HI/LO 結果不可依賴，程式須先檢查。

本節組合暫存器演算法每輪讀一位，共 n 輪；原書先移動寬除數的初版演算法使用 n+1 次，不能混用迴圈數。SRT 等設計每輪可選多位商，但選位、正規化與修正都有成本；每輪兩位不直接證明快兩倍。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

算術右移不一定等於有號除法

二補數算術右移一位等於除以 2 後向下取整；本節有號除法則向零截斷。以 −7 為例：

操作	結果	原因
`sra` 一位	−4	$\lfloor -7/2 \rfloor$
向零截斷的除以 2	−3	丟棄小數部分
負數先加 1，再算術右移一位	−3	$\lfloor (-7+1)/2 \rfloor$

一般除以 2^k 可對負數先加 $2^k - 1$ 再算術右移，但必須固定 $1 \le k < n$、輸入型別與不溢位的運算方式。編譯器用移位或倒數乘法替換除法，也必須維持原本的取整規則。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.5 浮點格式：範圍與精度分開看

IEEE 二進位浮點格式包含符號、偏移指數與 fraction 欄位。正常值（normal）的有效數首位 1 不存入欄位，因此有效精度比 fraction 多一位。

格式	符號位	指數位	fraction 位	有效精度 p	指數偏移 bias
binary32	1	8	23	24	127
binary64	1	11	52	53	1023

增加指數位主要擴大動態範圍；增加 fraction 位才增加有效精度。欄位指數全零或全一時須改用特殊規則，不能一律補上隱含的 1。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

浮點欄位：先找到符號、指數與 fraction



圖中的 fraction 不包含正常值隱含的首位 1；欄位位數與有效精度不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

欄位解碼：先分類，再代公式

對 binary32，令 E 是指數欄的無號整數、F 是 23 位 fraction 的無號整數：

E	F	數值或類型
1⋯254	任意	$(-1)^s(1+F/2^{23})2^{E-127}$
0	非零	subnormal：$(-1)^s F 2^{-149}$
0	0	帶符號的零
255	0／非零	無窮大／NaN

subnormal 把正常值的首位 1 改成 0，靠近零的間距固定為 2^{-149}。這是 gradual underflow（漸進下溢），不是把所有過小數直接變成零。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

浮點例外：旗標記錄了什麼？

旗標	典型觸發條件	停用 trap 時的例子
invalid	沒有定義的數值操作	0/0、0 • ∞ → quiet NaN
divide-by-zero	有限非零數除以零	1/(+0) → +∞
overflow	以目標精度、無界指數先捨入後超出最大指數	RNE 下最大有限值加自身 → +∞
underflow	本節環境中 tiny 且 inexact	最小正 subnormal 除以 2 → +0
inexact	結果不等於精確值	$1+2^{-24}$ 捨成 binary32 的 1

旗標與程式語言拋出的 exception 不是同一層。是否啟用 trap，以及如何讀取或清除旗標，要由浮點環境指定。後面的數例固定 RNE、停用 trap 與漸進下溢，並另說明 tininess 的判定時點。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

浮點加法：先對齊，再決定捨入

有限正常值相加時，先比較指數，把指數較小的有效數（significand）右移到共同尺度；異號輸入改作大小相減，絕對值不同時由較大絕對值的輸入決定符號；大小相等而精確相消時，零的符號依捨入方向決定，例如 RNE 得 +0、朝負無窮方向捨入得 −0。移出的低位仍須保留資訊，不能先截斷。

完成加減後，先正規化，再依目標精度捨入；若捨入產生新的進位，還要再正規化並調整指數。特殊值、零、溢位與 subnormal 路徑須另外處理。

以下使用 **p=4 個有效位（含首位 1）、RNE、指數範圍不設限** 的縮小模型，讓所有中間位元可見；它不是 binary32 格式。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

對齊數例：sticky bit 如何改變結果

令 a=1、b=9/128=0.0703125。b 原為 $1.001_2 \times 2^{-4}$，對齊到 2^0 後為 0.0001001_2；兩個輸入在 p=4 都是精確值。

p=4（含首位 1），RNE；指數範圍不設限

×2^0	保留 4 bits	G	R	其餘 bits
a = 1	1.000	0	0	00
b = 9/128	0.000	1	0	01
a + b	**1.000**	**1**	**0**	**01**

$b = 1.001_2 \times 2^{-4} = 0.0001001_2 \times 2^0$

S = OR(0,1) = 1 → GRS = 101 → 1.001_2 = 1.125

若把 tail 當 00，會誤判為 tie，得到 1.000_2。

精確和為 137/128；相鄰候選是 1 與 9/8，中點為 17/16=136/128。精確和大於中點，故選 9/8，誤差 7/128。若先丟棄低位而回傳 1，誤差是 9/128，已大於半個 ULP=1/16。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

相消後的正規化：先找回首位 1

同一個 p=4 模型計算 0.75−0.6875。輸入指數相同，不必先移位；相減後卻要左移三位，才能恢復 normal 的首位 1。

p=4、RNE：0.75 − 0.6875，兩個輸入皆可精確表示

a	1.100 000	× 2^{-1}
− b	1.011 000	× 2^{-1}
相減	0.001 000	× 2^{-1}
左移 3 位	1.000 000	× 2^{-4}

每左移一位，指數減一；數值維持不變。

GRS=000，結果 1/16=0.0625 是精確值，inexact=0。

本例的輸入與差都精確，沒有捨入誤差。相消可能放大**輸入先前已有的相對誤差**，不代表每一次相減本身都不精確。若左移時已碰到最小 normal 指數，必須改走 subnormal 路徑，不能無限降低指數。

Guard、round、sticky：從距離推導 RNE

先看結果的大小。最低保留位記為 L；其後第一位為 guard G，第二位為 round R，更右所有位元取 OR 得 sticky S。S 是「後方是否有非零位」的摘要，不是單一位元的位置。

相對一個保留單位 ULP，G 的權重是 1/2，R 是 1/4，其餘尾端小於 1/4。故 G=0 時低於中點；G=1、R=S=0 時恰在中點；G=1 且 R 或 S 非零時高於中點。中點選最低保留位為 0 的候選，於是

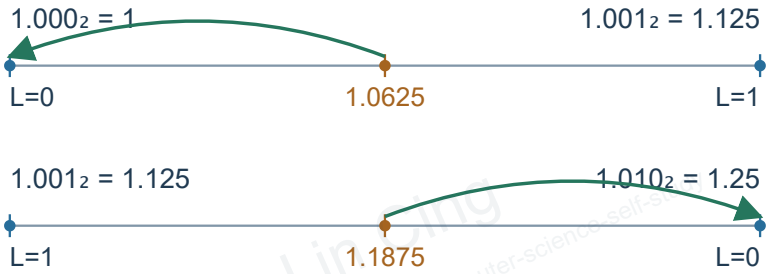
$$\mathrm{inc} = G \wedge (R \vee S \vee L).$$

inc=1 時對**保留的大小**加一個 ULP，之後加回符號。這對負數可能使數值更負，因此不能一律稱為「向上捨入」。只要丟棄部分非零，結果就不等於精確值，須記錄 inexact。

同樣是中點，為何有時保留、有時加一？

下圖仍用 p=4。第一個區間左端為偶，第二個區間右端為偶；even 指有效數整數編碼的最低位是 0，不是十進位值是否為偶數。

p=4、RNE；每條數線只畫一個相鄰區間



inc = G ∧ (R ∨ S ∨ L)

負數先捨入大小，再加回符號：−1.1875 → −1.25。

捨入也可能產生進位。例如 1.1111_2 截成 p=4 後 L=1、GRS=100，須加一：$1.111_2+0.001_2=10.000_2$，再正規化為 $1.000_2\times2^1$。不能只修改 fraction 欄而漏掉指數增加。

Binary32 的兩個捨入檢查點

binary32 在 [1,2) 的間距為 2^{-23}，精度 p=24。對 $1+2^{-24}$，L=0、GRS=100，故選 1（0x3f800000）；對 $1+3\cdot2^{-25}$，GRS=110，故選 $1+2^{-23}$（0x3f800001）。兩次皆不精確，inexact=1。

Binary32 round-to-nearest-even 與五種 FP 例外

Tie：$1+2^{-24}$	Above half：$1+3\cdot2^{-25}$	Underflow tie：2^{-150}	Overflow：max+max
GRS=100，保留 LSB=0	GRS=110	0 與 2^{-149} 的中點	exact result > max finite
candidate：1.0	round up：$1+2^{-23}$	even→+0	rounded→+∞
inexact	inexact	underflow + inexact	overflow + inexact

Invalid：0×∞、∞−∞、0/0 → quiet NaN；1/±0 → signed infinity。

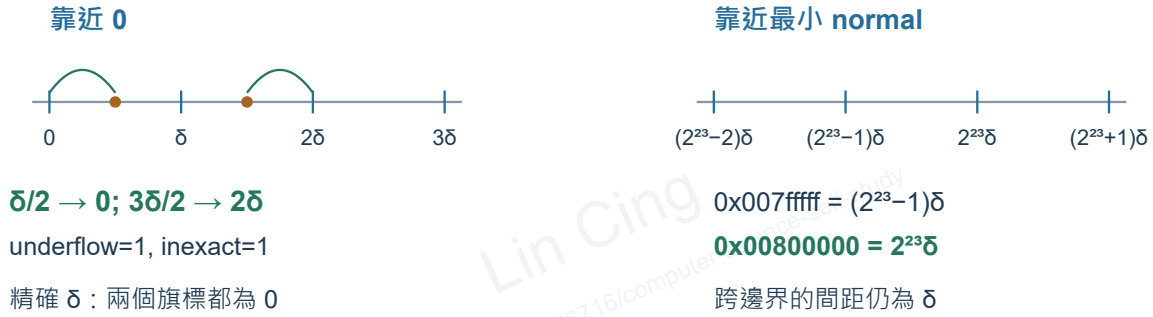
G/R/S 是 guard、round、sticky；tie 選最低保留 bit 為 0，NaN 依 payload 與 comparison 規則傳播。

這裡的 2^{-24} 是相鄰值間距的一半；不是「精確和的一半」。FMA 對精確 ab+c 只捨入一次，分開的乘法與加法各自捨入，結果可能不同；本章稍後給出可核對的位元數例。

Subnormal：範圍延伸與旗標要分開判斷

令 $\delta = 2^{-149}$。binary32 的正 subnormal 為 $F\delta$，其中 fraction 整數 $1 \le F \le 2^{23}-1$；最小 normal 為 $2^{23}\delta = 2^{-126}$。接近零的間距固定為 δ，跨到最小 normal 時仍連續。

binary32: $\delta = 2^{-149}$; RNE; gradual underflow



$\delta/2 \to 0$; $3\delta/2 \to 2\delta$

underflow=1, inexact=1

精確 δ：兩個旗標都為 0

0x007fffff = $(2^{23}-1)\delta$

0x00800000 = $2^{23}\delta$

跨邊界的間距仍為 δ

右圖第一點的 index 是 $2^{23}-2$；兩個視窗之間不採共同原點。

Subnormal 不等於一定設定 underflow 旗標。 精確的 $2^{-126}/2$ 得 0x00400000，沒有誤差；圖中兩個中點則因 tiny 且 inexact，同時設定兩個旗標。下一頁明定浮點環境並列出比較。

用同一張表核對 subnormal 的精確性

本表固定 RNE、gradual underflow、停用 trap、旗標初值為 0，並在捨入後判定 tininess。所有輸入皆能以 binary32 精確表示；UF、NX 分別代表 underflow 與 inexact 旗標。

運算	精確值	RNE 結果 bits	UF	NX
$2^{-126} / 2$	2^{-127}	0x00400000	0	0
$\delta / 2$	$\delta/2$	0x00000000	1	1
$(3\delta) / 2$	$3\delta/2$	0x00000002	1	1
最小 normal − 最大 subnormal	δ	0x00000001	0	0

前兩個中點以 fraction 整數的奇偶選擇：0 與 1 之間選 0；1 與 2 之間選 2。旗標不儲存誤差大小；通常新觸發的旗標會累積，直到明確清除。若要判斷單次運算是否觸發，應先清除舊旗標。若開啟 flush-to-zero（FTZ）或把 subnormal 輸入當成 0，已改變本節模型，不能直接套用此表。

表示法與 gradual underflow 可參照 Oracle Numerical Computation Guide § 2.3。

特殊值：同時寫出結果與例外

最大有限值加自身在 RNE 下得 +∞，設定 overflow 與 inexact。0×∞、∞−∞、0/0 為 invalid，停用 trap 時回傳 quiet NaN。

有限非零數除以 ±0 得帶符號的 infinity，符號由兩輸入的 sign bits XOR 決定，設定 divide-by-zero；∞/+0 則仍為 infinity，不因這次運算設定 divide-by-zero。詳見 Oracle Numerical Computation Guide 的例外表。

NaN 的比較須依 predicate 判斷：普通相等比較即使兩邊都是同一個 NaN 也為 false，不等比較為 true；ordered 與 unordered 不能混用。+0 與 −0 比較相等，但倒數與 signbit 可區分。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

浮點乘法：符號、指數、有效數各做什麼？

先限於有限正常輸入 $a = (-1)^{s_a} m_a 2^{e_a}$、$b = (-1)^{s_b} m_b 2^{e_b}$，其中 $1 \le m_a, m_b < 2$。符號為 $s_a \oplus s_b$，精確有效數乘積在 [1,4)，未正規化指數為 $e_a + e_\beta$。

若乘積≥2，右移一位並把指數加一；再依目標精度捨入，必要時再次處理進位。例 $1.5 \times 1.5 = 10.01_2 = 1.001_2 \times 2^1$，正規化需要右移一位，不能寫成固定左移。

儲存的指數有 bias，兩個指數欄相加時要扣回一次 bias，再加入正規化調整。subnormal、零與無窮大另外分類；0 • ∞ 屬 invalid，不能走一般「零乘任何數得零」路徑。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

MIPS 浮點：資料格式也寫在指令中

本章傳統 MIPS 的浮點暫存器位於 coprocessor 1，與一般整數暫存器分開。`lwc1`、`swc1` 搬移一個浮點 word 的位元；`add.s` 與 `add.d` 則選擇不同浮點格式的加法。

浮點比較設定條件碼，再由 `bc1t`、`bc1f` 分支。遇到 NaN 時，必須確認使用的是哪種 ordered／unordered 判斷，不能把它當成普通整數比較。

同一串位元可被搬移而不做數值轉換；要改變格式或轉成整數，須使用相應轉換指令。暫存器配置與保存區大小也要配合格式及 ABI，不能只看變數名稱。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

捨入方向與誤差尺度

RNE（round to nearest, ties to even）選最近值，中點才看最低保留位。方向性捨入則可朝 $+\infty$、$-\infty$ 或零；它們回答不同需求，例如區間上下界不能任意用 RNE 代替。

ULP 描述某個尺度附近相鄰可表示值的間距。binary32 在 [1,2) 的間距為 2^{-23}，在 [2,4) 則為 2^{-22}。同一個絕對誤差，在接近零與遠離零時的相對大小不同。

有效精度 p 控制可保留的有效二進位位數，指數範圍控制能表示多大或多小。兩者分別限制細節與尺度，不能用「位元更多」概括。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

NaN 與帶符號的零：不能照整數排序

普通相等比較中，NaN 與任何值都不相等，包括自身；不等比較則為真。要辨識 NaN，使用 `isnan` 或指定的 unordered 判斷，並確認比較指令的例外規則。

IEEE 相等比較中 +0=−0，但符號位不同。倒數可分成 +∞、−∞，`signbit` 也能區分，因此相等不代表編碼相同。

浮點負數的編碼順序、帶符號的零與 NaN 都使「把位元當有號整數直接比較」失去一般正確性。應使用對應格式的浮點比較規則。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.6 平行求和：結果為什麼會隨順序改變？

精確整數加法，以及固定模數的加法，都有結合律；逐步捨入的浮點加法則可能使 $(a+b)+c \neq a+(b+c)$。平行歸約（parallel reduction）改變求和樹，也就可能改變中間捨入。

若要求位元完全重現，須固定求和次序，以及格式、捨入模式、中間精度與 FMA 收縮等環境；或採用有明確順序無關保證的累加器。補償求和與提高精度主要改善誤差，本身不保證換序後位元相同。

因此結果略有差異時，先核對運算順序與浮點環境；不能只憑差異就判定有資料競爭，也不能因此排除真的競爭問題。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

補償求和也不是順序無關的保證

固定標準 Kahan 的每次基本運算均以 binary32、RNE 執行。其更新為 y=a−c、t=s+y、c=(t−s)−y、s=t；起始 s=c=0。

讀入順序	關鍵中間步驟	最後 s
$[2^{25}, 1, -2^{25}]$	加 1 時 s 不變，c=−1；下一步 $-2^{25}+1$ 又在中點捨回 -2^{25}	0
$[2^{25}, -2^{25}, 1]$	前兩項先精確抵銷，再加 1	1

補償變數能保存某些丟失資訊，但後續計算它或使用它時仍會捨入。這個數例否定「補償求和一律能保證換序結果相同」，不否定它在許多資料上改善誤差的價值。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

換結合順序，就換了捨入時點

運算順序的影響可用確切位元驗證。以 binary32 $x = 2^{24}$ 為例，x 的 ULP 是 2。x+1 恰好落在 x 與 x+2 的中點，最低保留 bit 要求選 even，所以先 round 成 x：

$$((x+1)-x) = 0, \qquad (x-x)+1 = 1.$$

兩式在實數算術中相等，逐次 binary32 捨入卻不同；差異來自捨入時點。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

FMA：精確乘加後只捨入一次

取 $a = b = 1 + 2^{-23}$（`0x3f800001`）、$c = -(1 + 2^{-22})$（`0xbf800002`），皆能以 binary32 精確表示。

$$ab = 1 + 2^{-22} + 2^{-46}, \qquad ab + c = 2^{-46}.$$

計算路徑	中間捨入	最終結果
先乘再加	乘積先捨成 $1 + 2^{-22}$，小項消失	+0
FMA	精確形成 ab+c 後只捨入一次	2^{-46}，`0x28800000`

差別來自捨入時點，不是實數乘法規則改變。本章傳統 MIPS 核心不保證提供 FMA；使用相應擴充時，仍要指定運算元格式與捨入模式。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.7 中間精度：暫存器裡算完，存回後可能不同

本章歷史案例比較 x87 的延伸精度堆疊暫存器與 SSE2 的 XMM 暫存器。若中間值先留在較寬格式，與每步都捨入到 binary32，最後結果可能不同。

例如 binary32 的 $1 + 2^{-24}$ 恰為中點，RNE 先捨成 1，再減 1 得 0；若中間格式能精確保留該和，再減 1，可得 2^{-24}。若較早存回 binary32，差異又會消失。

重現數值結果須記錄格式、捨入模式、中間精度、存回時點與編譯選項。此歷史比較不代表所有 x86 程式都固定使用同一種中間精度。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.8 三個常見推論，如何用反例檢查？

常見推論	本章反例或缺少的條件
有進位就有有號溢位	`0xff+1` 有進位，二補數 −1+1 卻精確為 0
每輪處理兩位就一定快兩倍	每輪延遲、前置處理及修正次數可能增加
浮點是近似，所以順序不重要	binary32 的 $(2^{24}+1)-2^{24}=0$，換序可得 1

編譯器的 fast-math 選項可能允許重排、改變結合順序或假設沒有特殊值。若程式依賴特定旗標、NaN 或逐步捨入結果，就要先確認允許的轉換。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.9 一個結果，至少要留下三種證據

檢查層次	應留下的證據	常見漏項
表示	輸入寬度、型別與解碼值	把二補數當無號數
運算	中間狀態、範圍與一般不變量	只有最後答案，沒有進位或餘數
交付結果	截取／捨入、例外、寫回政策	精確數學值不在輸出格式中

乘除法另須區分回合數、單筆延遲與啟動間隔。浮點數另須檢查正常值、零、subnormal、無窮大、NaN 及中點；只測普通正數不足以驗收。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

格式標準化之後，仍有哪些問題？

IEEE 浮點格式讓位元解碼、捨入與特殊值有共同規則；乘法器的重編碼、部分乘積壓縮、管線化與 SIMD 則改善不同層次的硬體成本。

格式標準不能替代演算法的數值分析。病態問題可能放大輸入誤差，求和樹改變可能改變捨入結果，多執行緒也可能改變運算順序。

因此閱讀硬體效能宣稱時，分別問：使用什麼格式、每次運算遵守什麼規則、單筆與連續多筆花多少時間、整個演算法的誤差如何累積。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

讀完後，試著完成這些檢查

1. 從輸入符號與進位，分別判斷有號及無號加法溢位。
2. 逐輪追蹤乘除法，說明暫存器寬度與一般不變量。
3. 編碼、解碼 binary32，區分正常值、subnormal、無窮大、NaN 與帶符號的零。
4. 從對齊後的 guard、round、sticky 位元推導 RNE 結果。
5. 對五種浮點例外分別寫出結果與旗標，包含精確 subnormal 的反例。
6. 用確切數值說明換結合順序及 FMA 如何改變逐步捨入結果。
7. 在指定時序模型下，分別計算單筆延遲與穩定吞吐量。

參考資料與署名

Lin Cing，《計算機組織》手寫筆記。 Patterson and Hennessy, Computer Organization and Design, revised fourth edition, Chapter 3. CSO course slides, arithmetic.

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study

從 ISA 契約到資料路徑與控制

Processor implementation 把 ISA 的抽象契約變成 bit-level state transition。ISA 規定指令看到什麼，microarchitecture（微架構）決定用多少 cycles、多少 functional units 與多少 power 達成它。

本章依序建立單週期 MIPS subset、五階 pipeline、hazard control、exception，最後擴到 multiple issue 與 speculative execution。每一步都要能說出資料由哪個 register 送到哪個 unit，以及錯誤的代價是什麼。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

4.1 設計問題與範圍

`datapath` 是搬運與運算資料的元件集合，`control` 依 instruction、ALU flags 與外部 request 產生 selector 和 enable signals。state 由 PC（program counter，目前指令位址）、register file 與 memory 等 clocked elements 保存。

本章教學 subset 包含：

1. memory reference：`lw`、`sw`。
2. arithmetic/logical：`add`、`sub`、`and`、`or`、`slt`。
3. control transfer：`beq`、`j`。

一般五階時序題採沒有 architectural delay slot 的簡化 subset，taken/misprediction 直接 squash 所有較年輕錯路徑指令；control hazard 小節另以 classic pre-Release-6 MIPS 的 one-delay-slot ISA 作對照。兩者的 flush 數、`$ra=PC+8` 與 wrong-path instruction count 不可互套。本章仍不是完整 MIPS；`addi`、byte load/store、multiply、floating point 與更完整 exception support 需要更多欄位、單元或狀態。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

從功能性到可實作契約

一個 instruction 的實作必須指定：

- source operands 與 destination architectural state。
- instruction 執行時 memory read/write 的數量。
- branch/jump target 的計算方式。
- exception 發生時哪些 register 或 memory write 可以保留。
- back-to-back instructions 對同一 register 的 read/write 關係。

例如 `lw rt, imm(rs)` 先以 `rs + sign_extend(imm)` 算 address，再於 MEM 取得 data，最後在 WB 寫 `rt`。若後一條指令立即讀 `rt`，硬體必須等 data 回來或使用正確的 forwarding path。

把 correctness 寫成 architectural state 的最終可見結果，而不是只看某張 waveform 是否看起來合理。

4.2 Clocking 與 edge-triggered state

Combinational logic 沒有內部 clocked state；它的 output 會隨 input 傳播。Edge-triggered register 只在指定 clock edge 取樣，所以一個 cycle 的邏輯不得靠 feedback 穿過多個 state updates。

簡化週期約束可寫成

$$T_{\text{clk}} \geq T_{\text{cq}} + T_{\text{logic,max}} + T_{\text{setup}} + T_{\text{skew}}.$$

`T_cq` 是 clock edge 到 register output 有效的延遲，`T_logic,max` 是最長 combinational path，`T_setup` 是下一 register 的要求，`T_skew` 捕捉 clock 到達差異。hold constraint 由最快路徑限制，不能只用最慢路徑證明正確。

教材若寫「一個 gate 等於 1 cycle」是把時間抽象掉；實體電路驗證要看 process、voltage、temperature corner。

4.3 Datapath 的積木

基本 datapath elements 包括 instruction memory、data memory、PC、adder、ALU、register file 與 multiplexor（多工選擇器）。

Register file 可同時讀兩個 registers、寫一個 register。Read 是 combinational；write 在 clock edge 發生。Separate instruction/data memories 讓 IF 與 MEM 在同一個 cycle 發生，但這是教學上的 Harvard-style model。真實 unified cache 可用更多 ports 或拆分 pipeline stages。

32-bit register file 有 32 個 architectural registers。`$zero` 的 read value 固定為 0，對它的 write 被忽略。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

ALU 與控制的分層

Main control 解讀 opcode，產生 `RegDst`、`ALUSrc`、`MemtoReg`、`RegWrite`、`MemRead`、`MemWrite`、`Branch`、`Jump` 等 signals。ALU control 再依 instruction class 與 R-type `funct` 欄位選 ALU operation。

以簡化 encoding 為例：

ALUOp	instruction class	ALU action
`00`	`lw/sw`	address addition
`01`	`beq`	subtraction
`10`	R-type	decode `funct`

控制輸出可由 truth table 或 ROM 實作。Decoder 的 propagation delay 也是 critical path 的一部分。

例如 R-type 使用 MemtoReg=0、RegDst=1、RegWrite=1，將 ALU 結果寫入 rd；sw 也用 ALU 算位址，但 RegWrite=0，結果送到資料記憶體位址端，由 MemWrite 啟用寫入。ALU operation 相同不代表目的地相同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

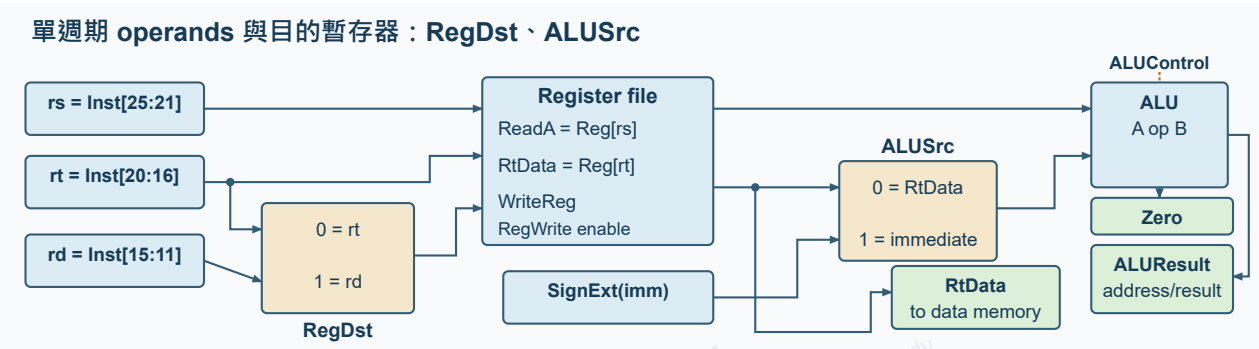
Single-cycle 的資料流

本節是無architectural delay slot的教學subset，支援R-type ALU、lw、sw、beq、j，獨立instruction memory與data memory；讀取為cycle內組合運算，PC與register writes、store在時脈邊緣提交。它沒有多週期的IR/A/B/MDR state，也沒有共用memory所需的IorD selector。

Cycle開始由PC.Q提供instruction address，instruction memory輸出opcode、rs、rt、rd、immediate與jump target fields。Control依opcode與funct產生select/enables；多條路徑同時運算，最後只有被enable的state更新，不是所有instruction都沿PC→IM→Reg→ALU→DM→WB一條直鏈走到底。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

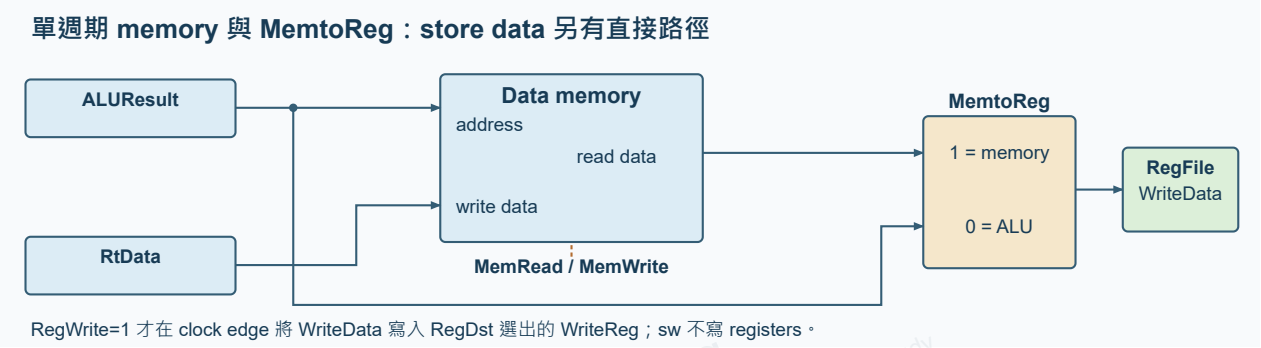
Single-cycle 的資料流 （續）



RegDst=0選Instruction[20:16]的rt作WriteReg，RegDst=1選Instruction[15:11]的rd。ReadA=Reg[rs]、RtData=Reg[rt]。ALUSrc=0把RtData送進ALU第二輸入，=1改送sign-extended immediate；第一輸入是ReadA。RtData另外直接供sw的memory write data，不能因ALUSrc=1就把immediate當作要儲存的資料。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

單週期 memory 與 write-back 的分支

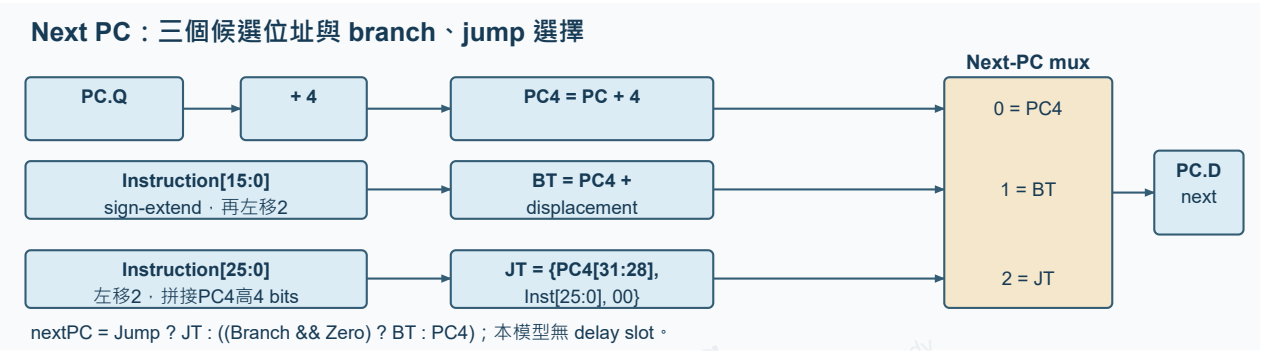


ALUResult對lw/sw是有效位址，對R-type是運算結果。Data memory的write data來自RtData，只有MemWrite=1才在本cycle的提交邊緣寫入。MemRead=1時提供該位址資料給MemtoReg的memory輸入。

MemtoReg=0選ALUResult，=1選memory read data，形成WriteData。只有RegWrite=1，才把WriteData寫入上一圖RegDst選出的WriteReg；目的為$zero時依ISA不改其固定值。圖中相同名稱是同一組資料wire的跨圖端點，不代表額外pipeline registers。

例如 `sw $t2,-4($s0)`，Reg[s0]=0x1000、Reg[t2]=0x12345678，immediate=-4。ALUSrc=1得到address0x0ffc，但store data仍為0x12345678，MemWrite=1、RegWrite=0。若誤把ALU的第二輸入當store data，就會把−4寫入memory。

單週期 next-PC 的三個候選



PC4=(PC+4) mod2^32。Branch displacement=(signext(imm)<<2) mod2^32，BT=PC4+displacement；beq以ALU做ReadA−RtData，Zero表示兩個32-bit值相等。Jump的JT拼接PC4[31:28]、Instruction[25:0]、00，不使用PC原值的高4 bits。

選擇函數為 `nextPC = Jump ? JT : ((Branch && Zero) ? BT : PC4)`，可實作成先branch/seq、再jump的兩個2-input mux。下個edge把nextPC提交到PC；本模型不先執行delay slot。圖把相同PC4用名稱接到各計算式，所有計算都屬同一cycle的組合邏輯。

PC=0x00400020、beq immediate=-2時，PC4=0x00400024、BT=0x0040001c；相等則選BT，否則PC4。PC=0x0ffffffc且jump field=0時，PC4=0x10000000，所以JT=0x10000000；若錯用PC高bits會跳到0。

Control table 與每個 mux 的選擇

Signal	lw	sw	R-type	beq	j
RegDst	0	X	1	X	X
ALUSrc	1	1	0	0	X
MemtoReg	1	X	0	X	X
RegWrite	1	0	1	0	0
MemRead	1	0	0	0	0
MemWrite	0	1	0	0	0
Branch	0	0	0	1	0
Jump	0	0	0	0	1
ALUOp	00	00	10	01	X

ALUOp=00選add用於address，01選subtract以產生Zero，10再由R-type funct選add/sub/and/or/slt等。X是don't-care，只在結果不會被提交的欄位使用；RegWrite/MemWrite不能因其他欄位不用而隨意assert。非法opcode與例外還需額外控制，本subset不假裝已涵蓋完整MIPS。

五類 instruction 的完整 state effects

取每一列獨立的cycle，PC=0x00400020、Reg[s0]=0x1000、Reg[s1]=7、Reg[s2]=5、Reg[t2]=0x12345678，Mem[0x100c]=0xabcdef01。Word accesses對齊，運算不產生本subset未處理的overflow。

Instruction	關鍵資料路徑	本cycle提交
addu t0,s1,s2	ReadA7、RtData5；ALUSrc0；ALU12；MemtoReg0；RegDst1	t0=12，PC=0x00400024
lw t1,12(s0)	ReadA0x1000、imm12；ALU0x100c；MemtoReg1；RegDst0	t1=0xabcdef01，PC=0x00400024
sw t2,-4(s0)	ALU0x0ffc；RtData0x12345678直入memory	Mem[0x0ffc]=0x12345678，PC=0x00400024
beq s1,s2,-2	ALU7−5=2，Zero0；Branch1，Jump0	無register/memory writes；PC=0x00400024
j 0x00401000	field0x00100400；Jump1	無register/memory writes；PC=0x00401000

若只把beq輸入改成兩者皆5，Zero=1，PC改為0x0040001c。Lw的rt欄位是目的暫存器，sw/beq的rt則是來源；不能把相同欄位名稱當作永遠同一讀寫用途。

單週期最慢路徑決定共同時脈

lw通常走PC clock-to-Q、instruction read、register read、ALU address、data-memory read、MemtoReg及register setup，因此

$$T_{clk} \geq T_{PCQ} + T_{IM} + T_{regread} + T_{ALU} + T_{DM} + T_{mux} + T_{setup}.$$

明定這些已合併的delay項為30+200+120+180+250+20+40 ps，得到840 ps。R-type的此模型路徑30+200+120+180+40=570 ps，仍需等待同一840 ps clock。這個簡化delay預算忽略的wire/control/mux成本必須已可被所用項目涵蓋，不能再聲稱是某個實際晶片的完整timing closure。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

單週期效能與限制

以下是與前頁 840 ps 延遲預算不同的獨立模型，假設 clock period 為 800 ps，程式有 60% R-type、25% load/store、15% branch/jump，且 single-cycle CPI 對每條 instruction 都是 1。CPU time 為

$$T = IC \times CPI \times T_{\text{clk}} = IC \times 1 \times 800\,\text{ps}.$$

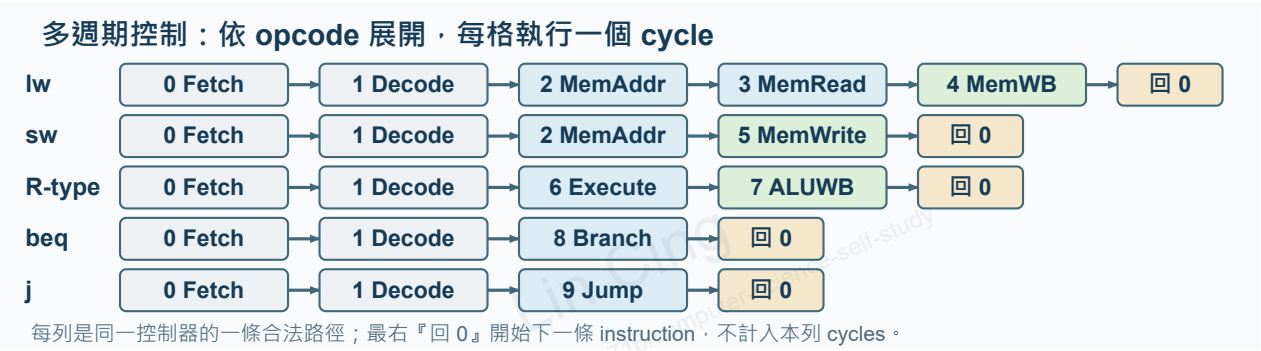
最佳化只縮短 R-type path 不會降低 clock period，因為 `lw` 仍決定週期。反之，任何只增加 `lw` path 的 feature 會拖慢所有 instructions。

Single-cycle 適合小教學 ISA，實際處理器常用 pipelining、multi-cycle control 或 asynchronous/clock-gated 方法控制資源與時序。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

多週期資料路徑與控制

多週期設計把 instruction 拆成若干 state，每個 clock edge 只讓一組資料動作的結果進入暫存 state。暫存器 `IR`、`A`、`B`、`ALUOut` 與 `MDR` 分別保存 instruction、兩個 register operands、ALU result 與 memory data；`PC` 仍然保存 architectural instruction address。



Instruction	State path	Cycles
R-type	Fetch → Decode → Execute → ALUWB → Fetch	4
`lw`	Fetch → Decode → MemAddr → MemRead → MemWB → Fetch	5
`sw`	Fetch → Decode → MemAddr → MemWrite → Fetch	4
`beq`	Fetch → Decode → Branch → Fetch	3
`j`	Fetch → Decode → Jump → Fetch	3

多週期資料路徑與控制 （續）

表中每一個 state 各占一個 cycle；最後的 Fetch 是下一條 instruction 的第一個 cycle。`sw` 從 MemAddr 直接到 MemWrite，不經 MemRead。

State	本次 clock edge 保存的資料或提交的效果	關鍵 write enable／選擇
0 Fetch	IR←Memory[oldPC]；PC←oldPC+4	IorD=0；MemRead=1；IRWrite=1；PCWrite=1
1 Decode	A←Reg[rs]；B←Reg[rt]；ALUOut←PC+branch displacement	不寫 architectural registers／memory
2 MemAddr	ALUOut←A+signext(imm)	ALU 選 base 與 immediate
3 MemRead	MDR←Memory[ALUOut]	IorD=1；MemRead=1
4 MemWB	Reg[rt]←MDR	RegDst=0；MemtoReg=1；RegWrite=1
5 MemWrite	Memory[ALUOut]←B	IorD=1；MemWrite=1
6 Execute	ALUOut←A op B，op 由 funct 決定	ALUOp 選 R-type 解碼

多週期資料路徑與控制 （續）

State	本次 clock edge 保存的資料或提交的效果	關鍵 write enable／選擇
7 ALUWB	Reg[rd]←ALUOut	RegDst=1；MemtoReg=0；RegWrite=1
8 Branch	A=B 時 PC←先前保存的 branch target	PCWriteCond=1；PCSrc=branch；ALU 比較 A−B
9 Jump	PC←{當前PC[31:28],IR[25:0],00}	PCWrite=1；PCSrc=jump

未列出的 architectural write enable 均為0；內部暫存器的寫入依本表模型。Decode 的 opcode 分流為 lw/sw→2、R-type→6、beq→8、j→9，其他 opcode 進入明定的 error transition。狀態3只通往4，不通往5；兩條 memory 路徑分別是讀取後寫回暫存器，或直接寫入記憶體。

關鍵 enable 不是裝飾文字。Fetch state 可 asserted `IRWrite`、`PCWrite`、`IorD=0`；Memory state asserted `IorD=1` 與 `MemRead` 或 `MemWrite`；Write-back state 才 asserted `RegWrite`。Fetch 開始令 oldPC=PC；Fetch 的同一時脈邊緣寫入 IR=Memory[oldPC] 與 PC=oldPC+4。Decode 讀 rs、rt 到 A/B，以已增加的當前 PC 計算 ALUOut=PC+(signext(imm)<<2)，不再把 PC 加4。Branch 相等時才令 PC=ALUOut，不相等保留循序 PC。例 oldPC=0x00400008、imm=-2，Fetch 後 PC=0x0040000c，target=0x00400004；重複加4會錯成0x00400008。Branch/Jump state 選 next-PC source，不能和一般 `PC+4` update 同時無條件 asserted。

多週期資料路徑與控制 （續）

逐週期 CPI 必須由 instruction mix 計算。以 45% R-type、20% branch、20% load、15% store 為例：

$$\mathrm{CPI} = 0.45(4) + 0.20(3) + 0.20(5) + 0.15(4) = 4.0.$$

若每 cycle 300 ps，執行 10^9 instructions 的時間是

$$T = 10^9 \times 4.0 \times 300\,\mathrm{ps} = 1.2\ \mathrm{s}.$$

同一個假設下，single-cycle 用 800 ps 且 CPI=1，時間是 0.8 s。多週期雖可使用較短 clock，但本題的額外 cycles 超過 clock 縮短比例，因此不一定較快。這個結論只在題目給的元件延遲與 instruction mix 成立；不能把多週期或 pipeline 當成無條件加速器。

FSM 正確性的兩個不變量是：一個 instruction 在同一個 state 不會重複提交 `RegWrite` 或 `MemWrite`；從任何 completion state 回到 Fetch 前，該 instruction 所需的 operand/result state 都已保存。未定義 opcode 要有明確 error transition，不能默默走 default path 並執行任意 memory write。

4.5 五階管線模型

五階 pipeline 為：

1. IF：以 `PC` 取 instruction，並計算 `PC+4`。
2. ID：decode、讀 register file，產生 immediate 與 hazard/control 所需欄位。
3. EX：ALU 計算、load/store effective address 或 branch comparison。
4. MEM：執行 data-memory read/write。
5. WB：依 `RegWrite` 寫回 register。

每個 pipeline register 是 clock edge 更新的 state snapshot，不是單純導線：

Register	必要 state
`IF/ID`	`valid`、該 instruction 的 `PC`、fetched instruction、`PC4=PC+4`
`ID/EX`	`valid`、該 instruction 的 `PC/PC4`、`rs/rt/rd`、A/B values、sign-extended immediate、control bits
`EX/MEM`	`valid`、該 instruction 的 `PC`、ALU result、store data、destination、`MemRead/MemWrite/RegWrite/MemtoReg`
`MEM/WB`	`valid`、該 instruction 的 `PC`、memory read data 或 pass-through ALU result、destination、`RegWrite/MemtoReg`

4.5 五階管線模型 （續）

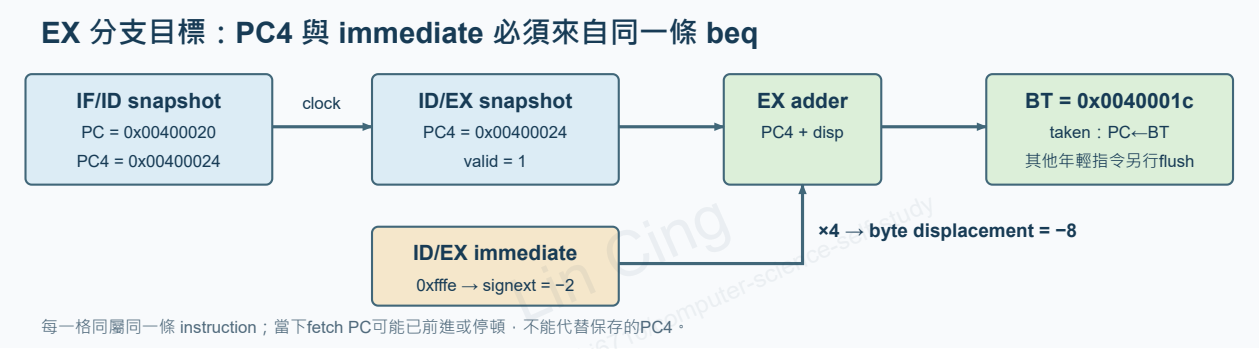
`EX/MEM` 若漏帶 `RegWrite` 或 destination register，後面的 WB 就無法知道誰要寫哪個 register。`MemRead` 也不是立即完成：load 在 EX 只產生 address，value 要等 MEM 尾端。這個資料相依是 load-use hazard 的來源。

`PC/valid` 與 operand/control 同屬一條 instruction 的 state，必須一起保持或前進；bubble/flush 令被清除項的 `valid=0`，所有 register/memory writes 都須受 `valid` 門控。Stall 保持 PC 與 IF/ID，在 ID/EX 插入無效項，較舊的有效項仍前進。每階保留自己的 instruction PC，才可在 EX arithmetic fault 或 MEM access fault 記錄正確 EPC；此處顯式存 PC 與 PC4 是教學選擇，也可保存 PC4 並以減4還原 PC。

EX 的 branch target 從哪裡來

本模型在 EX 判斷 beq，所以 IF 算出的 PC4 必須先經 IF/ID、再經 ID/EX，不能用當下已在 fetch 年輕指令的全域 PC。32-bit 位址運算為

$$BT = \left(\mathrm{ID/EX.PC4} + 4\,\mathrm{signext}_{16\to32}(imm_{16})\right) \bmod 2^{32}.$$



例 beq 位於 `0x00400020`、immediate bits=`0xfffe`。該指令的 PC4=`0x00400024`，signed immediate=−2、byte displacement=−8，故 BT=`0x0040001c`。Taken 時下一個 PC 選 BT；not-taken 繼續既定順序路徑。保存的 PC4 不因較年輕指令的 stall/flush 改變，不能以「目前 fetch PC 減固定常數」替代。

無 hazard 時的理想時間

若 stage 完全平衡且 latency 為 t，沒有 hazard 的 n 條 instructions 完成時間為

$$C_{\mathrm{ideal}} = k + (n-1), \qquad k = 5.$$

Steady state 每個 cycle 完成一條 instruction，但單筆 latency 仍是 $5t$。例如 $n = 100$ 時是 104 cycles，理想 IPC 接近 1。以下長程穩態模型以退休指令數為分母，且各 penalty 是不重疊、不重複計數的實際額外週期：

$$\mathrm{CPI}_{\mathrm{pipe}} = 1 + \mathrm{stall}_{\mathrm{loaduse}} + \mathrm{mispredict_cycles} + \mathrm{structural_bubbles}.$$

Pipeline 的理想時間

若 stages 完全平衡，stage latency 是 t，執行 n 條 instructions 的理想 cycles 為

$$k + (n - 1),$$

其中 $k = 5$。Steady-state throughput 是每個 cycle 完成一條 instruction，但單筆 latency 仍是五個 stages。

以 $n = 100$：理想 cycles 為 $5 + 99 = 104$。加速比相對於 ideal single-cycle 為

$$\frac{500}{104} \approx 4.81.$$

實際 single-cycle 的 stage delay 不一定可比，因此這只是相同 stage 假設下的比較。

在本例五級等延遲且忽略 pipeline-register overhead 的模型中，指令數趨於無窮時 speedup 接近 5；單一指令仍依序通過五級，其 latency 並未縮短。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Structural hazard

Structural hazard 發生於兩個同時活躍的 instructions 競爭同一個硬體資源。

五階設計通常把 instruction memory 與 data memory 分開，避免 IF 與 MEM 共用單一 memory port。Register file 的 write 在 cycle 前半或後半、read 在 cycle 前半或後半，可讓同一 cycle 的不同 instructions 合法共享；這需要明確 timing convention。

Register file 通常支援兩個 reads 與一個 write；需要第四個 operand 的 instruction 或更多 concurrent accesses 會增加 ports 與面積。

改 higher associativity、更多 ALUs 或更多 register ports 不是免費；先找出 resource conflict 的頻率。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Data dependence

Data dependence 是程式資料流，例如

```
add $8, $9, $10
sub $11, $8, $12
```

`sub` 需要 `add` 產生的 `$8`。True dependence（真相依）不可消除；可透過 forwarding、scheduling 或更多 state 隱藏。

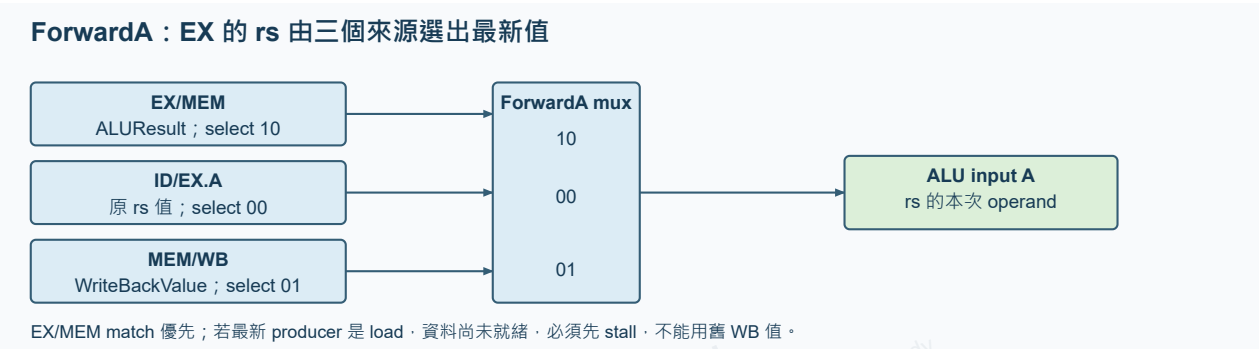
Anti-dependence 與 output dependence 是名稱重用造成的 ordering constraint，例如

```
add $8, $9, $10
sub $8, $11, $12
```

Register renaming 可把兩個 `$8` 映射到不同 physical registers，消除名稱衝突。

ISA-visible register 名稱相同不等於真資料依賴的 value 是由哪個 instruction 產生。

Forwarding 的 correct path



Forwarding（前送）把 EX/MEM 或 MEM/WB 的 produced value 繞回 ALU input，避免等 WB。

對 `add $8, $9, $10` 後接 `and $4, $8, $5`，EX/MEM 在下一 cycle 已持有 `$8` result，可用 `ForwardA=EX/MEM`。

判定必須檢查：

- producer 的 `RegWrite` 已 asserted。
- producer destination 非 `$zero`。
- consumer 的 `rs` 或 `rt` match 該 destination。
- 對 load，EX stage 只有 address，沒有 data；不能把 address 當 loaded value 前送。

Forwarding 的 correct path （續）

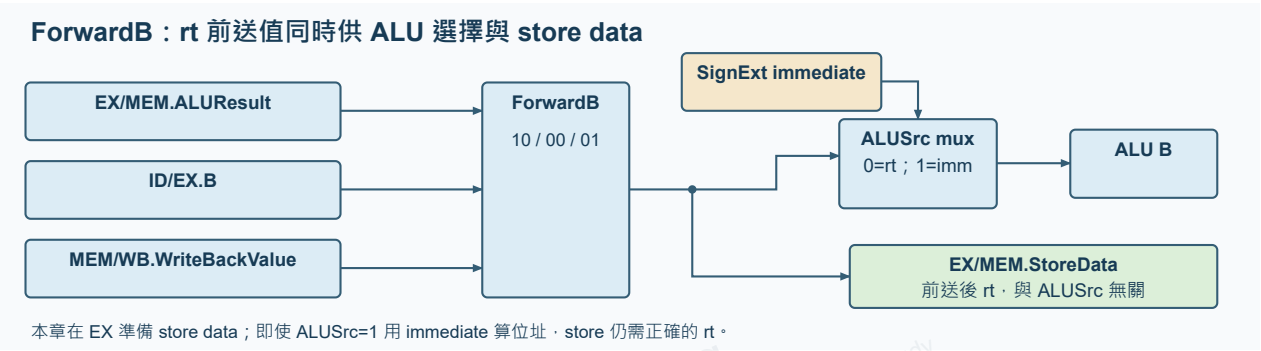
對每個在EX使用的source register s，令 E 表示 `EX/MEM.RegWrite && EX/MEM.rd!=0 && EX/MEM.rd==s`，W 表示 `MEM/WB.RegWrite && MEM/WB.rd!=0 && MEM/WB.rd==s`。Mux有三個實際輸入：ID/EX保存的register值、EX/MEM的ALU結果、MEM/WB最終write-back值。選取規則如下。

條件	選入ALU的值
E且producer不是load	EX/MEM.ALUResult，編碼10
非E且W	MEM/WB.WriteBackValue，編碼01
非E且非W	ID/EX原值，編碼00
E且producer是load	資料尚未產生，consumer必須先stall，不能前送address或較舊WB值

ForwardA對rs套此規則。ForwardB對作為register operand的rt套此規則，再由ALUSrc mux決定ALU的B輸入是此前送值或sign-extended immediate。Store data也要保存/前送正確rt值。本模型在EX準備store data，所以把緊接load的store-data consumer也保守stall一cycle；另設MEM-stage store forwarding可省此stall，但須另外給路徑與條件。

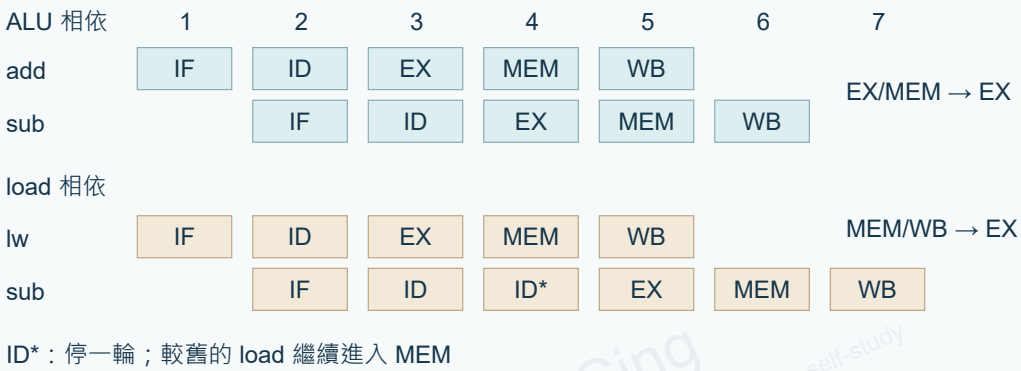
當連續兩個producer都寫s，EX/MEM是較新的定義，必須優先於MEM/WB。例如 `add $1,...; sub $1,...; and $2,$1,$3`，and需要sub結果，不能使用add的舊結果。

Store data 的前送與 ALUSrc



ALUSrc只選擇ALU第二輸入，不決定store寫入memory的資料。Store的address採base加immediate，仍需以最新rt值作data。圖中的分叉點同時送往ALUSrc的register輸入與EX/MEM.StoreData；兩個用途不能混成同一個mux選擇。

兩種相依：為何一個要停、一個不用？



假設五階單發射、單週期記憶體、EX/MEM 與 MEM/WB 可前送到 EX，沒有其他 hazard。上例 `add $s0,$t0,$t1; sub $t2,$s0,$t3`：加法在 C3 EX 結束產生結果，C4 從 EX/MEM 前送至 sub 的 EX，無須 stall。

下例 `lw $t0,4($s0); sub $t2,$t0,$s1`：資料在 C4 MEM 結束才就緒，不能在同一 cycle 一開始供 EX。凍結 PC 與 IF/ID 一輪並插入 bubble，sub 在 C5 EX 從 MEM/WB 取得資料。

Load-use stall

```
lw  $2, 20($1)
and $4, $2, $5
```

`lw` 在 MEM 才取得 data，`and` 下一 cycle 就要在 EX 使用 `$2`。僅有 EX/MEM forwarding 仍沒有 loaded data，因此必須 stall 一 cycle。

Stall 時應：

1. PC 保持原值。
2. IF/ID 保持原值。
3. ID/EX control 清成 no-op，插入 bubble。
4. 讓 `lw` 繼續進 MEM/WB，下一 cycle 前送 loaded value。

若下一條 instruction 不讀 `$2`，不必 stall。比對 `rt` 只適用於會讀 `rt` 的 instruction；`lw` 的 `rt` 是 destination，不能一律當 consumer。

令 `use_rs/use_rt` 表示IF/ID指令是否在EX需要該source，包括本模型在EX準備的store data。R-type與beq兩者皆1；lw只有use_rs=1；sw兩者皆1；j兩者皆0。對這個subset，load目的暫存器是ID/EX.rt。完整停頓條件為：

Load-use stall （續）

```
stall = ID/EX.MemRead && ID/EX.rt != 0 &&
        ((use_rs && ID/EX.rt == IF/ID.rs) ||
         (use_rt && ID/EX.rt == IF/ID.rt))
PCWrite = !stall
IFIDWrite = !stall
IDEXControls = stall ? all_zero : decoded_controls
```

`lw $2,0($1); lw $2,4($3)`不需要stall，因為第二個lw不讀rt。`lw $0,0($1)`不產生可見register結果，所以不因目的為0形成data hazard；memory fault仍須依例外規則處理。一般ISA還需對每個opcode定義source用途與使用stage，不能直接把全部instruction fields都當sources。

逐 cycle 數例：舊值不能代替尚未就緒的新值

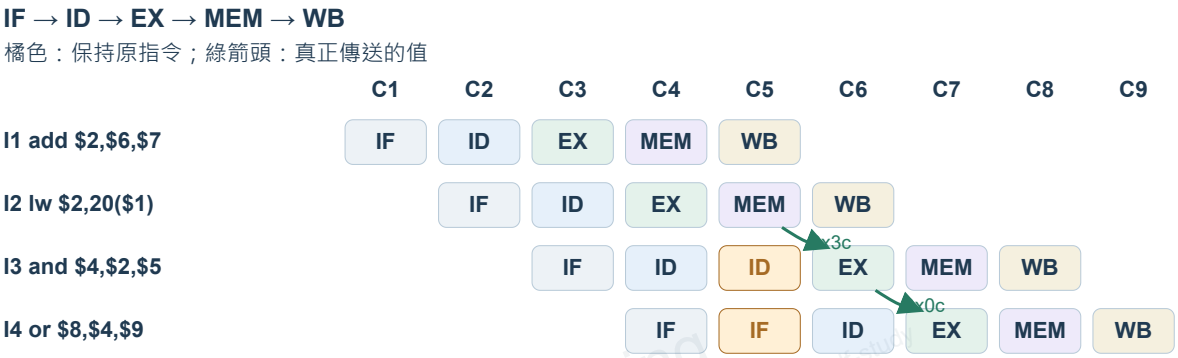
沿用五階、單發射、順序執行的模型；無 cache miss、分支或結構衝突。ALU 結果可由 EX/MEM 或 MEM/WB 前送至 EX；load 資料在 MEM 結束才可供下一 cycle 使用。Register file 在 WB 的前半個 cycle 寫入，ID 後半個 cycle 讀取。

初值：`$1=0x1000`、`$6=0x30`、`$7=0x03`、`$5=0x0f`、`$9=0x80`，且 `Mem[0x1014]=0x3c`；其餘相關暫存器為 0。所有存取對齊且無例外。

```
I1  add $2,$6,$7     # $2 ← 0x33
I2  lw  $2,20($1)    # $2 ← 0x3c，覆寫 I1 的值
I3  and $4,$2,$5     # $4 ← 0x0c
I4  or  $8,$4,$9     # $8 ← 0x8c
```

`I3` 必須讀到最近一次寫入 `$2` 的 `I2`，不是更早的 `I1`。相依關係是 `I2 → I3 → I4`；`I1` 與 `I2` 的目的暫存器相同，但 `I2` 不讀 `$2`，不構成兩者之間的 RAW 相依。

九個 cycles：停住前端，較舊指令繼續前進



C4：偵測相依 → C5：EX bubble（valid=0）；I3 留在 ID；I4 留在 IF。
C6：MEM/WB → I3.EX；C7：EX/MEM → I4.EX。I4 在 C9 完成。

每格表示該 cycle 內所處的 stage，cycle 結束才跨越 pipeline register。C4 偵測到 `I2.EX` 的 load 與 `I3.ID` 相依；在 C4 結束的 edge 保持 PC、IF/ID，並向 ID/EX 寫入無效項。因此 C5 沒有有效指令在 EX，並非把 load 停在原處。

從時序圖核對控制訊號與數值

Cycle	指令位置與可用值	控制或運算結果
C4	I2.EX 算出位址 `0x1014`；I3.ID 需要 `$2`	`PCWrite=0`、`IFIDWrite=0`；下一個 ID/EX 為無效項
C5	I1.WB 寫 `$2=0x33`；I2.MEM 在末端取得 `0x3c`；I3 仍在 ID	I3 讀到並暫存舊值 `0x33`；此時 hazard 已解除，前端可在 edge 前進
C6	I2.WB 的值為 `0x3c`；I3.EX	`ForwardA=01` 選 MEM/WB，覆蓋暫存舊值；`0x3c AND 0x0f=0x0c`
C7	I3.MEM 帶著 ALU 結果 `0x0c`；I4.EX	`ForwardA=10` 選 EX/MEM；`0x0c OR 0x80=0x8c`

若略過 C5 的 bubble，I3 會在 C5 的 EX 過早取值：最新 producer 的 EX/MEM 只有 load **位址** `0x1014`，MEM/WB 的 `0x33` 則是舊版本。兩者都不能代替尚未產生的 load 資料；錯用舊值會得到 `$4=0x03`。

有、無 forwarding：比較的是同一段程式

模型	I3 的 EX	I4 的 EX	最後 WB	額外停頓
有 EX/MEM 與 MEM/WB 前送	C6	C7	C9	1 cycle
完全無前送，只能從 register file 讀	C7	C10	C12	4 cycles

無前送時，I3 在 C4、C5 的 ID 被擋住，直到 C6 的 WB 寫入新 $2 後才能讀取；I4 則在 C7、C8 的 ID 等待，直到 C9 的 WB 寫入 $4。由於允許同 cycle 先寫後讀，不再額外等待一個 cycle。

四條有效指令的理想完成時間為 4+4=8 cycles；上述兩模型分別為 8+1=9 與 8+4=12。有限序列的 CPI 為 9/4 與 12/4，包含填滿與排空成本，不能把它直接當成長程式穩態 CPI。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Control hazard、branch delay 與 flush

Branch 改變 fetch path。五階 pipeline 在 branch 尚未到 EX 前，IF/ID 已抓入較年輕 instructions；若 taken 且 prediction 是 not taken，就必須丟棄 wrong-path instructions。

branch penalty 由 resolve stage 與 predictor 決定，不等於 architectural delay slot。若要估計 per-instruction cycle cost，可寫成

$$\text{mispredict_cycles} = f_{\text{branch}} \sum_{r} P(\text{wrong}_r \mid r) C_r.$$

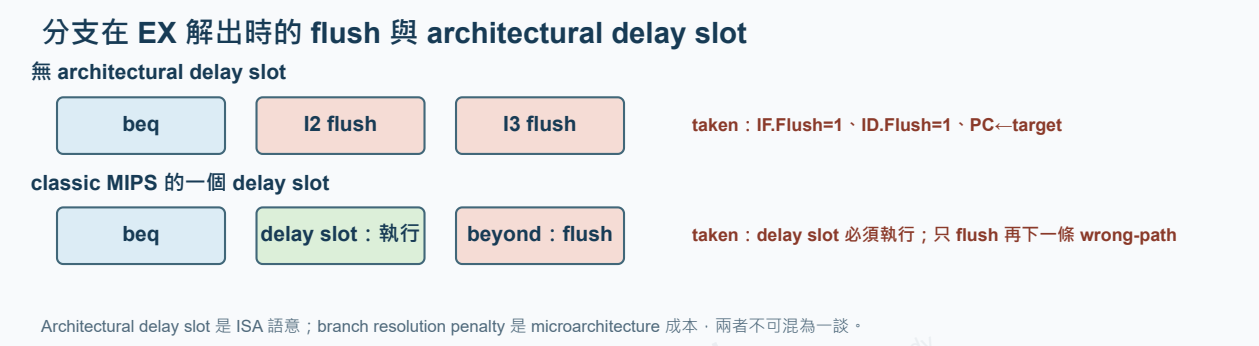
例如 20% instructions 是 branches，其中 60% taken，predictor 一律 not taken，且 taken 在 EX 解出後 flush 兩個 younger instructions：

$$0.20 \times 0.60 \times 2 = 0.24 \,\text{cycles/instruction}.$$

Classic MIPS 的架構另有一個 branch delay slot。beq 後緊接的 instruction 無論 taken 與否都屬於 architectural execution；taken 時只 flush delay slot *之後* 的 wrong path。若在 EX 解出時，delay slot 在 ID，下一條在 IF：

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Control hazard、branch delay 與 flush （續）



No-delay-slot model 需 flush ID 與 IF 的兩個 younger instructions；one-delay-slot model 只 flush delay slot 之後的 IF instruction，slot 必須照 ISA 語意執行。不能把「flush 幾個 stages」和「delay slot 是否執行」混成同一條規則。

預測器可以早於 EX 做 direction guess，但事件順序仍是 prediction、fetch、resolve、misprediction recovery。BTB hit 只表示有 target 可用，不表示 direction 一定正確。

Pipelined CPI 的完整邊界

以同樣 20% branch、60% taken、one-cycle load-use bubble 出現於 10% instructions 的模型：

$$\mathrm{CPI} = 1 + 0.20(0.60)(2) + 0.10 = 1.34.$$

這個 1.34 只描述題目明確列出的 penalties。Structural hazard、cache miss、branch target miss、long-latency functional unit 與 front-end limit 都必須各自加入，不能以「五階所以 CPI=1」抹去。

Dynamic branch prediction

2-bit saturating counter 可抵抗單次雜訊。狀態例如 strongly not taken、weakly not taken、weakly taken、strongly taken；實際 outcome 為 taken 時向 strongly taken 更新，not taken 時向 strongly not taken 更新；更新方向不由本次預測正確或錯誤單獨決定。

Correlating predictor 以 global history 預測具相關性的 branches。Tournament predictor 依不同 predictor 的歷史表現選擇。

Branch target buffer（BTB，分支目標緩衝）快取 target；prediction 仍要同時判斷是不是 branch 以及 taken direction。BTB miss 不等於 direction prediction 錯。

測試需覆蓋 cold start、alternating pattern、correlated branches 與 alias。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

4.9 Exception 與 interrupt

Exception 是由目前 instruction 引起的同步事件，例如 overflow 或 undefined instruction。Interrupt 常指外部非同步事件，例如 I/O request。不同 ISA 的命名不盡相同。

Pipeline exception handling 要保存 faulting PC、cause 與必要 address，跳至 handler。Handler 修復或終止 process 後，若可恢復則由 exception return instruction 回到 architecture-defined PC。

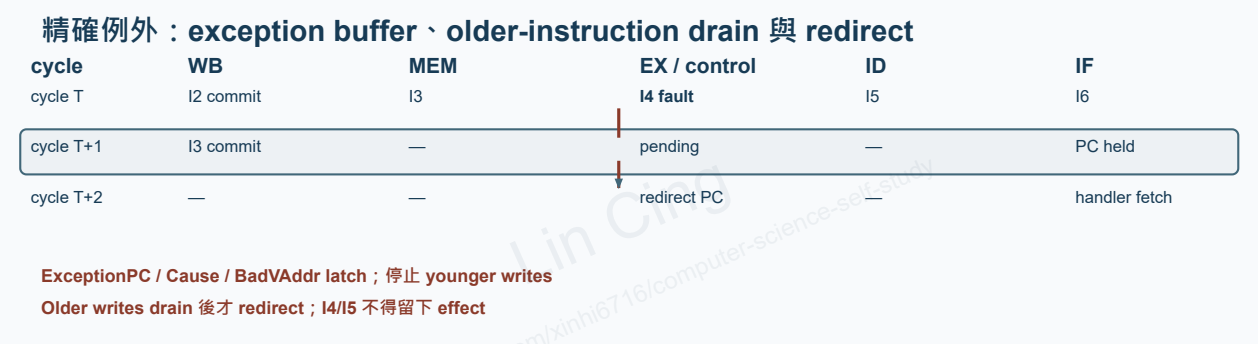
Handler 執行前的 architectural state 必須符合 ISA 規定。若較早 instruction 已 commit、較晚 instruction 被 flush，程式仍可建立單一一致的 interrupted state。

先分清 precise exception 與只保證 imprecise machine check 的差異。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Precise exception 的週期與狀態

在單發射五階 pipeline，令 faulting I4 在 EX 發現 arithmetic overflow。此 cycle 的合法 stage snapshot 是 I2 在 WB、I3 在 MEM、I4 在 EX、I5 在 ID、I6 在 IF；I1 已在更早 cycle commit。I2、I3 沒有 exception；本例的 I3 是在 WB 提交暫存器結果的非 store 指令；I4 與較年輕的 I5、I6 必須阻止 architectural writes。



Cycle	WB	MEM	EX / control	ID	IF
T	I2 commit	I3	I4 arithmetic fault	I5	I6
T+1	I3 commit	—	exception pending	—	PC held
T+2	—	—	PC←handler，送出保存的 cause	—	handler fetch

Precise exception 的週期與狀態 （續）

本表以每 cycle 開始後的 stage 活動為準，commit 在該 cycle 尾完成：I3 在 T+1 尾提交後，controller 在 T+2 開始選 handler PC，首條 handler 指令於 T+2 的 IF 取得，尚未進入 ID。

在 T 的同 cycle control 中，硬體記下 ExceptionPC=I4.PC、cause 與依例外類型必要的位址（算術 overflow 不一定有 bad address），deassert I4 與 younger writes，並 flush I5、I6。Precise exception 的契約是 handler 看到的所有 architectural effects 等於依序執行完 I1、I2、I3，且 I4 與更晚的 register/memory writes 完全不出現。為了讓較舊的 I2、I3 先完成，controller 可先把 exception 放進 exception buffer，停止 fetch 並 drain older stages；I3 在 T+1 commit 前，handler 不能先看到它的 effects。

若有多個 exceptions 同 cycle，必須由 spec 指定 priority。通常採用最舊 instruction 的 synchronous exception；但 asynchronous interrupt、machine check 與 precise/imprecise policy 可能不同。Handler 入口前也要保存/切換 privilege、status、EPC、cause；僅在例外類型需要時保存 bad-address registers。

Out-of-order execution 可用 ROB 完成相同效果：年輕 instruction 可先執行，但 commit 必須依 program order。I4 成為 ROB head 且之前 I1 至 I3 都 commit 後，才丟棄 I4 與所有較年輕 entries，再清空 speculative rename mapping 並 redirect。

4.10 ILP 與 multiple issue

Instruction-level parallelism（ILP，指令層平行）是同一執行流中可重疊的 independent instructions。Pipeline 在 stages 間重疊 instruction；multiple issue 在同一 cycle 啟動多條。

Static multiple issue 由 compiler 把 instructions 排成 issue packets。VLIW（very long instruction word，超長指令字）把多個 operations 編碼在 fixed packet，硬體控制較簡單，binary portability 取決於 ISA/model。

Dynamic multiple-issue 由硬體在 runtime 從 instruction window 選 ready instructions。它可跨越 compiler 未預期的 latency，但需要 scoreboard、wakeup/select、ROB 等大量狀態。

峰值 IPC 4 表示理想寬度，不等於所有程式都能維持 4。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Superscalar 與 dynamic scheduling

Superscalar（超純量）在一個 cycle 嘗試 fetch/decode/issue 多條 instructions。Issue logic 檢查 operand readiness 與 functional-unit availability；out-of-order execution 可讓後續 ready instruction 先執行。

Speculation 在 branch outcome 未知時沿預測路徑執行。錯誤預測時，ROB 或 checkpoint 丟棄 younger results，register mapping 回到正確狀態。

Register renaming 把 ISA registers 映射到更多 physical registers，消除 false dependencies。它不改變 architectural register 的可見數量。

OoO execution 不等於 OoO commit。很多處理器以 in-order commit 保存 precise exception。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

亂序執行、rename 與 ROB 的逐 cycle 追蹤

固定單一 dispatch/cycle、單一 commit/cycle，依 program order 配置 ROB 與新 physical destination；每條指令最早在 dispatch 的下一 cycle 開始執行。獨立 load unit latency=4 cycles，pipelined integer ALU latency=1 cycle。結果在 cycle 結束可用，只能從下一 cycle 供 consumer 或 commit。無 cache miss、branch、fault 與其他 structural hazard；ALU 不溢位。

```
I1: lw  r1,0(r2)
I2: add r3,r1,r4
I3: add r5,r6,r7
I4: add r1,r8,r9
```

初始 r1/r2/... 對應 p1/p2/...。Rename 逐條配置 I1→p11、I2→p12、I3→p13、I4→p14。I2 在 dispatch 時已把 r1 source 綁為 p11；I4 雖把 speculative r1 mapping 改成 p14，也不能改寫 I2 保存的 source tag。RAW I1→I2 仍存在；I1/I4 的同名 destination 與 I2/I4 的名稱衝突由不同 physical registers 分開。

亂序執行、rename 與 ROB 的逐 cycle 追蹤 （續）

執行結果可亂序，commit 仍依 I1 → I2 → I3 → I4

	1	2	3	4	5	6	7	8	9
I1: lw → p11	D	LD1	LD2	LD3	LD4	C			
I2: add → p12		D	wait	wait	wait	EX	C		
I3: add → p13			D	EX	ready	ready	ready	C	
I4: add → p14				D	EX	ready	ready	ready	C

D：dispatch；EX/LD：執行；wait：等operand；ready：等ROB head；C：commit

I2 source = p11 (I1); I4 destination = p14. Result end of cycle → use next cycle.

指令	Dispatch	執行	結果 ready（cycle 尾）	Commit	原因
I1	1	load cycles2–5	5	6	ROB head ready後才能提交
I2	2	EX cycle6	6	7	讀 p11，必須等 I1 結果
I3	3	EX cycle4	4	8	ready仍等較舊I1/I2提交
I4	4	EX cycle5	5	9	新p14不覆寫I1的p11

亂序執行、rename 與 ROB 的逐 cycle 追蹤 （續）

例如取 memory[0(r2)]=10、r4=1、r6=2、r7=3、r8=4、r9=5，I3先算得p13=5，I4算p14=9，I1算p11=10，I2最後讀p11得p12=11。最終 architectural r1=9、r3=11、r5=5，等同程式順序；若I2錯讀p14，r3會錯成10。Ready、executed與committed是三種不同狀態。

另取 r4=2147483647、保持 I1 的 load 值10，I2 的 signed add 在 EX cycle6 發現 overflow；cycle6仍可先commit較舊I1，I2記下fault但不commit。輪到I2為ROB head時，捨棄I2/I3/I4，恢復到committed rename map，r1對應p11而非p14；handler看到r1=10，r3/r5仍是執行本段前的architectural值。已算出的p13/p14沒有對程式提交，不能以「先執行完」為由保留。

這個模型未處理 speculative stores、memory disambiguation或分支checkpoint；加入它們時還需 store queue、例外與恢復規則。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

多發射資源邊界

設理想每 cycle 可 issue 4 instructions，但程式中只有 20% 的相鄰指令 independent，其他時刻只能 issue 1。若 workload 的 instruction energy 與 fetch bandwidth 不變，平均 IPC 應以動態 issue 分布計算，不能把峰值直接乘上 4。

限制可能來自：

- data/branch dependencies。
- instruction and data cache bandwidth。
- branch predictor accuracy。
- functional-unit mix 與 register ports。
- reorder buffer size。
- power density 與 thermal constraint。

分析 workload 的 IPC histogram，比只報 peak IPC 更能解釋真實效能。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

4.11 Opteron X4 案例

Opteron X4（Barcelona）fetch x86 instructions，decode/translate 成 AMD 所稱的 RISC operations（Rops），再由 dynamic scheduled speculative pipeline 執行。本章案例模型描述最多每 cycle issue 3 Rops，整數 pipeline 約 12 stages，浮點 execution queue 更長。

可能瓶頸包括：

- complex x86 instruction 拆成多個 Rops。
- hard-to-predict branches 造成 restart。
- 長依存或 cache misses。
- translation/rename/ROB 等 front-end 資源。

這些歷史數字用於理解 microarchitecture，不能當成 2026 年任何現行 CPU 的規格。

此案例的 issue 寬度及 pipeline 深度只適用於上述 Barcelona 模型；換架構時需重新取得前端、執行端與記憶體限制，不能由歷史峰值推算現代程式時間。

4.12 HDL 與模擬

Hardware description language（HDL，硬體描述語言）描述 module 的 ports、state、combinational equations 與 clocked behavior。Verilog 的 `always @(posedge clk)` block 表示 clocked process；blocking 與 nonblocking assignment 的語意不能混用而不檢查。

HDL 模擬只能證明 testbench 覆蓋範圍內的行為。Synthesis、timing analysis、formal assertion 與實機測試回答不同問題。

以時序 assertion 可以檢查 hazard、flush 與 commit order。Simulation 覆蓋到的 testbench 案例、synthesis 結構、static timing 與實機量測各自回答不同問題，不能互相取代。

可檢查的時序條件包括：stall 且沒有 redirect 時，下一個 edge 的 PC 與 IF/ID 必須保持；valid=0 的指令不得寫 architectural state；faulting instruction 與其後的指令不得 commit；ROB commit 的指令序號必須依 program order 遞增。這些條件分別對應停頓、bubble 與 precise exception 的正確性。

4.13 設計誤解

「Pipeline 能降低每條 instruction latency」不成立。Balance 的五階 pipeline 讓每條 instruction 經五個 stages；收益來自許多 instructions 重疊。

「Forwarding 可解決所有 data hazards」忽略 load-use、long-latency units 與真資料依賴。

「Pipeline 設計與 technology 無關」忽略邏輯深度、clock distribution、power 與 memory latency 的變化。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

4.14 章末模型收束

設計一個 processor 的核心檢查是：

1. 逐段驗證每條 instruction 完成後的 architectural state。
2. 列出每個 stage 的資源與結構衝突。
3. 證明 branch 與 exception 能恢復正確狀態。
4. 在相同 workload 下報告 latency、throughput、IPC、frequency 與 energy。
5. 測試資料依賴、memory access、wrong-path behavior 與邊界案例。

Single-cycle 易理解但 clock 被最長 path 支配；五階 pipeline 改善 throughput；forwarding、stall、prediction、precise state 與 dynamic scheduling 處理重疊帶來的代價。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

4.15 處理器技術演進

從單週期到多週期與管線，主要改變是把長組合路徑分配給不同時段或不同指令，並用暫存狀態追蹤尚未完成的工作。管線重疊引入資料與控制危害；前送和停頓維持值的正確性，分支預測則用恢復成本換取前端不中斷。

動態排程及暫存器重新命名讓後續就緒指令繞過尚未完成的運算，但真正資料相依仍須等待。亂序執行配合依序提交，把執行效率與精確例外的程式順序契約分離。更寬發射與更大視窗也增加選擇邏輯、線路、能耗與驗證成本，所以歷史進展不能只用管線階數或峰值IPC排序。

比較每個時代採用技術所解決的限制、增加的狀態，以及出錯時必須恢復的狀態，避免把歷史案例當成現行處理器規格。

參考資料與署名

Lin Cing，《計算機組織》手寫筆記。 Patterson and Hennessy, Computer Organization and Design, revised fourth edition, Chapter 4. CSO course slides, processor datapaths and pipelines.

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study

高速處理器為何需要記憶體階層

Processor 每 cycle 可以執行運算，DRAM 存取卻可能需要數百個 processor cycles。若每次 load/store 都直接等待 DRAM，快速 datapath 會長時間閒置。

Memory hierarchy 用不同容量、成本與延遲的儲存層共同提供「近似快速且近似無限」的記憶體幻象。它依賴 locality（局部性），並不保證任意程式都得到相同效能。

本章依序建立 cache、virtual memory、TLB、virtual machine 與 coherence。每個結論都必須附上容量、block/page、miss penalty 與 write policy。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

位址、page 與 cache block 的單位

本章會重複使用四種位址：

1. VA（virtual address，虛擬位址），process 執行 load/store 時使用。
2. VPN（virtual page number，虛擬頁號），VA 去掉 page offset。
3. PA（physical address，實體位址），page translation 後存取 main memory 或 physically addressed cache。
4. Cache block address，PA 去掉 block offset。

Byte address 的最小單位是 1 byte。以本章 4-byte word 為例，word index 乘 4 才轉成 byte offset；byte address 除以 block size 才得到 block number。手算若混用單位，看似相同的低位元會得到錯誤 mapping。

本章的 B 表示 block size bytes，P 表示 page size bytes。公式會在首次使用時重新定義。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

5.1 局部性與記憶體階層成本

Storage hierarchy 通常由上到下為 registers、L1 cache、L2/L3 cache、main memory、flash/disk 與遠端儲存。越上層越快、每 byte 越貴且容量越小；越下層越慢、越便宜且容量越大。

理想是讓常用資料靠近 processor，低頻資料留在下層。Locality 是此設計成立的經驗前提，不是硬體能對任意程式保證的定理。

Temporal locality（時間局部性）表示近期用過的位置很可能近期再用。Spatial locality（空間局部性）表示使用某位置後，附近位置很可能很快被使用。

以連續 4-byte 整數陣列為例，依序讀取 byte addresses 0、4、8、12、16。假設 cache 原本為空、block 為 16 bytes、沒有 prefetch 且過程中不發生 eviction：前五次依序是 miss、hit、hit、hit、miss；前三個 hit 利用同一 block 的空間局部性。若隨後再次讀位址 16 且該 block 仍在，這次 hit 則是時間局部性的例子。

為何 cache 能改善平均時間

設上層 hit time 為 H，miss rate 為 m，miss penalty 為 P_m（在已付 hit lookup 時間後額外等待的時間）。平均記憶體存取時間（AMAT）為

$$\text{AMAT} = H + mP_m.$$

若 $H = 1$ cycle、$m = 0.05$、$P_m = 80$ cycles，則

$$\text{AMAT} = 1 + 0.05 \times 80 = 5 \text{ cycles}.$$

即使 miss 很慢，95% 的 accesses 可以由 1-cycle cache 滿足。若 hit rate 降至 80%，AMAT 變為 17 cycles，顯示 low hit rate 如何吞掉 cache 的價值。

Miss rate 的分母必須一致。Instruction miss rate 常以 instruction 為分母，data cache miss rate 常以 data references 為分母。

Memory wall 與資源取捨

Processor performance 與 DRAM latency 的改善速度不一致，形成 memory wall。提高 capacity、associativity 或 block size 可能降低某些 misses，但也可能增加 hit time、miss penalty、面積與 power。

一個 hierarchy 設計是多目標最佳化：

- L1 優先降低 hit time，並避免 drag critical path。
- 下層 cache 承受較大容量與較高 associativity。
- Main memory 提供容量與 bandwidth。
- Disk/remote storage 處理容量與持久性，但 miss cost 遠高於 cache。

「增加 cache 一定更快」缺少 workload 與 hit-time 條件；容量增加可能使 index/select path 變慢。

5.2 Cache 的基本模型

Cache block（或 line）是 cache 與下層之間傳輸的單位，通常包含多個 words。Cache entry 至少保存 data、tag 與 valid bit；write-back cache 另外保存 dirty bit。

一次 reference 的步驟是：

1. 用 address 的 index 選 set。
2. 比較 set 內各 way 的 tag 與 valid。
3. 若 match，回傳 block 內由 offset 指到的 byte/word。
4. Read miss 或採 write-allocate 的 store miss 需向下層取得 block、選擇 victim 並寫入 cache；no-write-allocate 的 store miss 則將寫入轉送下層，不分配該 block。

Valid 防止未初始化 bits 因 tag 恰好相同而被誤認為 hit。

Tag 相同但 valid 為 0 仍是 miss；dirty bit 只表示是否需 write-back，不用來判斷 hit。

Direct-mapped 映射

Direct-mapped cache 的每個 block 只能放在唯一位置：

$$\text{cache block index} = \text{memory block number} \bmod N_{\text{blocks}}.$$

若 cache 有 2^q blocks，index 是 block number 的低 q bits。Offset 選擇 block 內位置，tag 保存剩餘高位。

若兩個 frequently used blocks 映射到同一 index，即使 cache 其他位置空著，也會互相 evict。這是 conflict miss 的典型來源。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Accessing a cache：一個具體 trace

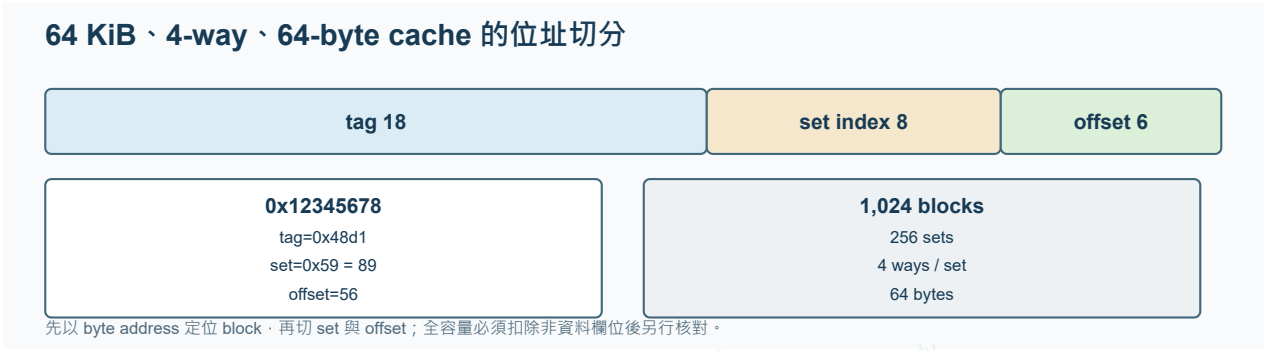
假設 4-block direct-mapped word cache，block size 與 word 相同。Block addresses `0,1,2,3,0,4,0` 的存取為：

Access	Block	Index	結果	原因
1	0	0	miss	valid=0
2	1	1	miss	valid=0
3	2	2	miss	valid=0
4	3	3	miss	valid=0
5	0	0	hit	tag/valid match
6	4	0	miss	evict block 0
7	0	0	miss	conflict with block 4

七次有六次 miss，miss rate 為 $6/7$。前四次與第一次碰到block 4的第六次屬compulsory；第七次對block 0的重訪是conflict，因同容量fully associative LRU在第六次會淘汰block 1而保留剛用過的block 0。

每次 miss 都要列 victim 與 valid/tag/dirty 更新，不能只算 hit count。

Address decode：64 KiB、4-way、64-byte block



$$N_{\text{blocks}} = 2^{16}/2^{6} = 1024, \quad N_{\text{sets}} = 1024/4 = 256.$$

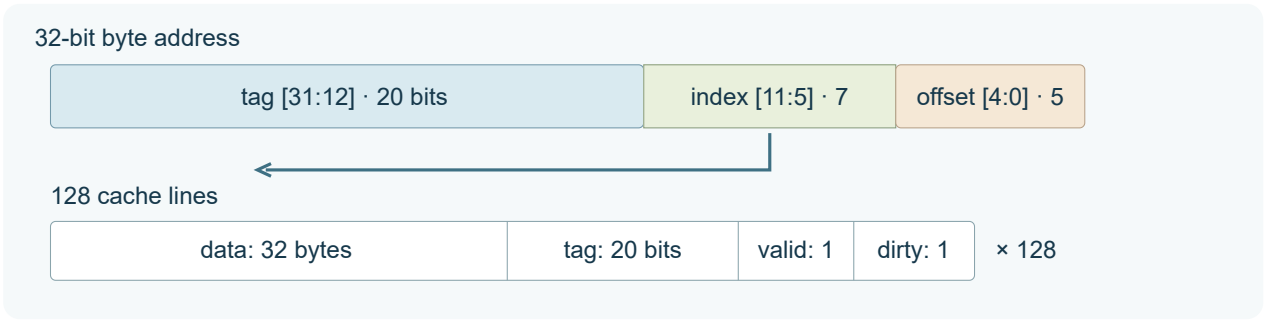
因此：

- block offset bits：$\log_2 64 = 6$。
- set index bits：$\log_2 256 = 8$。
- tag bits：$32 - 6 - 8 = 18$。

Address `0x12345678` 的低 6 bits 是 `111000`，偏移 56 bytes；接著 8 bits 是 `01011001`，index 為 89；高位是 tag `0x48d1`。

同樣 block 內的 `0x12345658` 有相同 tag/index、不同 offset，所以前 block 若仍 valid，這次應為 hit。

從位址欄位反推容量與額外成本



以 32-bit byte address 的 direct-mapped write-back cache 為例：offset 5 bits 表示每 line 有 32 bytes；index 7 bits 表示共有 128 lines，故資料容量為 128 × 32 = 4096 bytes。

每列還存 20-bit tag、1 個 valid 與 1 個 dirty，共 22 bits；全 cache 的額外成本為 128 × 22 = 2816 bits = 352 bytes。只計上述欄位時，總儲存為 4448 bytes，是 data capacity 的 1.0859375 倍；ECC 與其他控制電路另計。

Handling cache misses

Simplified in-order processor 的 read miss 通常會 stall。Controller 要保存 miss address、送 read request、等待下層、選 victim、更新 data/tag/valid，再讓 instruction 重試。

Instruction miss 的重試 PC 是發出 request 的 instruction address，不是 PC 已被更新後的值。Data miss 要保存 load/store 所需 address 與 store data。

Write-back dirty victim 必須先 write-back 或放入 write-back buffer，再 fetch new block。Critical-word-first 可以先把 requested word 送回 processor，再完成 block fill。

Cache miss 通常是 pipeline stall 與 controller transaction；page fault 會經 exception 進入 OS，恢復成本與 state 處理不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Memory system 如何支撐 cache

Block fill 的 miss penalty 可拆成 address transfer、DRAM latency、burst transfer 與 cache update。以 four-word block、one-word-wide memory 為例，若 address 1 cycle、每次 DRAM access 15 cycles、每 word transfer 1 cycle：

$$1 + 4(15) + 4(1) = 65 \text{ bus cycles.}$$

Wider memory/bus 可平行取兩個 words，總時間可降為

$$1 + 2(15) + 2(1) = 33 \text{ cycles.}$$

這個例子假設 burst 次數依 memory width 減少，且 transfer 花費依 bus width 降低；不同 interconnect 要重新建模。

Block size 增加可提高 spatial locality 利用，卻也可能放大 miss penalty 與污染 cache。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

交錯式記憶體：讓不同 bank 同時工作

四個連續 words 分別放在四個獨立 bank；假設一個共用地址操作在 cycle 1 同時啟動四個 bank，各 bank 延遲 15 cycles，而匯流排每 cycle 傳一個 word。資料都就緒後，再依序傳四個 words：總 fill time = 1 + 15 + 4 = 20 bus cycles。

比較同一模型下單 bank 的 65 cycles：收益來自重疊 bank latency，而不是一次在窄 bus 上傳四個 words。若位址無法同時發出、連續資料映到同一 bank，或 bank 回應有額外間距，20 cycles 就不成立。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Handling writes

Write-through 同時更新 cache 與下層。它簡化 coherence 與 recovery，但每次 store 都消耗 lower-level bandwidth；write buffer 可讓 processor 不必逐筆等 memory。

Write-back 先更新 cache 並設 dirty bit；dirty block 被 evict 或一致性協定要求交付資料時，才將最新內容送往下層或其他 owner。它降低連續寫入的 traffic，但 eviction、coherence 與 recovery 更複雜。

Write-allocate 在 write miss 時先 fetch entire block；no-write-allocate 直接把 write 傳給下層。Policy 可以依 workload、頁面或 instruction 改變，例如整頁清零時不必先 fetch。

小於 cache line 的 store 只更新指定 byte；實作可使用 byte enable 或其他等效機制，不必然執行 read-modify-write，也不必然讀取 main memory。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Write policy 的邊界案例

策略	Write miss 行為	優點	主要代價
write-through + no-allocate	直接寫下層	邏輯簡單	下層 traffic 高
write-through + allocate	fetch block，之後同步寫下層	後續 reads 可能 hit	write bandwidth 高
write-back + allocate	fetch block、修改資料並標 dirty	連續 writes 省 traffic	dirty eviction
write-back + no-allocate	直接寫下層	避免無用 allocation	仍失去後續 write hit

表中「allocate」是 placement policy，「through/back」是 lower-level update policy，兩者不可混為一組。

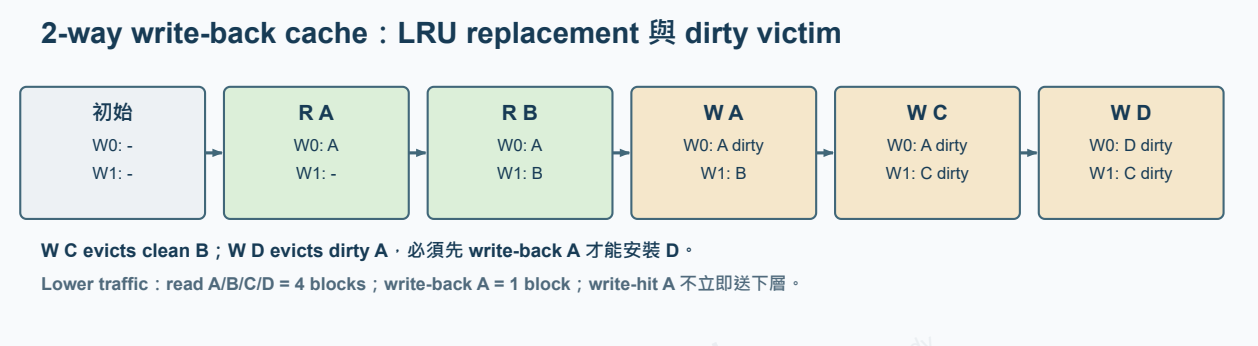
Store buffer 若保存未完成 writes，read-after-write 要看該 address 是否被 buffer 遮住，不能盲目由 cache 回舊值。

Write-back、write-allocate 與 dirty victim trace

考慮 2-way set-associative，64-byte blocks，每次 store 只改4 bytes，LRU replacement，write-back、write-allocate。每個 set 初始沒有 valid entry，空 way 選編號較小者。Way 是固定實體槽位，更新 LRU 不搬動其他 line。以下 `A/B/C/D` 均映射同一 set；`dirty` 表示 cache 可能有尚未傳播的寫入。

Step	Access	Way 0	Way 1	Victim 與 lower-level action
0	initial	invalid	invalid	無
1	read A	A clean	invalid	miss；read A 一個 block
2	read B	A clean	B clean	miss；read B
3	write A	A dirty（MRU）	B clean	write hit；不下層
4	write C	A dirty	C dirty（MRU）	miss；B clean 可丟；read C 後寫 C
5	write D	D dirty（MRU）	C dirty	miss；A 是 LRU 且 dirty，先 write-back A，再 read D

Write-back、write-allocate 與 dirty victim trace （續）



這個 trace 下層共讀 4 blocks（A、B、C、D），共寫 1 個舊 block A。若控制錯誤地在 `Allocate D` 時先覆寫 A，A 的最新值只存在 cache，之後無法恢復；dirty bit 不影響 hit detection，卻決定淘汰前是否必須保存最新資料。Cache 與 DRAM 仍可能在斷電時失去內容；正確 write-back 不等於持久化保證。

換成 write-through、no-write-allocate：

1. Step 3 的 write A 立即送往下層。
2. Step 4 的 write C 不配置 cache，直接送下層，B 不會被 eviction。
3. Step 5 的 write D 也直接送下層。
4. Set 仍只保留 A、B；下層 reads 是 A、B，writes 是 A、C、D。

Write-back、write-allocate 與 dirty victim trace （續）

只計 payload bytes，不含 headers/acknowledgments，也不在序列末尾強制 flush。WB/WA 的4個64-byte fill加1個64-byte write-back為320 bytes；WT/NA的2個64-byte fill加3個4-byte stores為140 bytes。兩者都有5次下層動作，卻不是相同大小的5個block transfers。WB最終C、D仍dirty，若要求再寫回下層，需另加128 bytes；持久性仍需平台的flush及ordering承諾。

在 write-invalidate coherence 模型下，cache 必須取得獨占寫入權限才能完成該 block 的 store；write-back 延後下層更新，但處理器仍須依記憶體模型取得正確的讀寫結果。其他協定可能採不同的共享及更新規則。Dirty victim 的最新資料必須先送往 memory、可靠的 write buffer 或有完成保證的 other owner，才能重用其 storage；clean victim 可依協定直接丟棄。

FastMATH cache 案例

本章案例的 Intrinsity FastMATH 是 MIPS embedded processor 教學案例。它使用 separate instruction and data caches，讓 pipeline 在同一 cycle 取 instruction 與存取 data；每個 cache 為 16 KiB、4K words、16-word blocks。

以 4K words 且每 block 16 words 計算，共有 256 blocks。若 architecture 的 cache 是 direct-mapped，index 有 8 bits、offset 有 6 bits；詳細實作仍以該處理器圖與規格為準，不能只由容量猜出全部 timing。

Separate caches 消除 instruction fetch 與 data access 的 structural conflict，但 instruction/data traffic 不再共享同一 capacity。

歷史實例的 cycle numbers 是模型輸入，換到今日 processor 必須重測。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

5.3 Cache performance

Processor time 可寫成

$$\text{CPU time} = (CPU_{\text{exec}} + CPU_{\text{stall}}) \times T_{\text{clock}}.$$

若每次 L1 miss 固定 penalty P_m，instruction miss rate 為 m_i，data references per instruction 為 f_d，data miss rate 為 m_d：

$$\text{CPI} = \text{CPI}_{\text{base}} + m_i P_m + f_d m_d P_m.$$

這是 in-order、每次 miss 全 stall 的簡化模型。Out-of-order processor 可重疊部分 misses，需用 stall distribution 或模擬。

不要先把 instruction 與 data miss rate 平均成單一 miss rate；兩類 request 的分母不同。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

分離式與合併式 cache：先對齊分母

考慮 100 條退休指令，每條恰好一次 instruction fetch，另有 30 次 data references；不計投機取指或額外訪存。分離式的 I-cache 有 2 次 miss、D-cache 有 3 次 miss，故 miss rates 分別為 `2/100=2%` 與 `3/30=10%`。

若每次 miss 均造成互不重疊的額外 80 cycles，且 base CPI 不含這些停頓，追加 CPI 為 `(2 + 3)×80/100 = 4`。以每條指令計，也可寫成 `1×0.02×80 + 0.3×0.10×80 = 4`。

若另一個合併式 cache 在此 trace **也恰好**有 5 次 miss，則其 miss rate 以全部 130 次 references 為分母：`5/130`；每條指令有 `1.3` 次 references，追加 CPI 是 `1.3×(5/130)×80 = 4`。這只是分母換算，並不保證兩種配置的 miss 數相同；單埠合併式 cache 的取指／資料競爭也須另計，且不可重複計數。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

AMAT 的數字例

令 L1 hit time 為 1 cycle、miss rate 為 6%、main-memory miss penalty 為 80 cycles：

$$\text{AMAT} = 1 + 0.06 \times 80 = 5.8 \text{ cycles}.$$

若 base CPI 是 1.4，instruction miss rate 2%，每 instruction 有 0.25 次 data references，data miss rate 8%，則 memory stalls 對 CPI 的追加為

$$0.02(80) + 0.25(0.08)(80) = 1.6 + 1.6 = 3.2,$$

總 CPI 是 4.6。若 clock 為 2 GHz，10 億 instructions 的 CPU time 是

$$10^9 \times 4.6 / (2 \times 10^9) = 2.3 \text{ s}.$$

Data misses 只在 data reference 發生，不能對所有 instructions 直接乘 data miss rate。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

更靈活的 block placement

Associativity 把 cache blocks 分成 sets：

$$N_{\text{sets}} = \frac{N_{\text{blocks}}}{E},$$

其中 E 是 way count。Direct-mapped 等於 $E = 1$；fully associative 只有 1 set；set-associative 是兩者之間。

若總 data capacity 不變，associativity 每加倍一次，set 數減半、index 少 1 bit、tag 多 1 bit、comparators 約加倍。較多 ways 可降低 conflict misses，但可能拉長 tag compare 與 output select path。

Tag storage 也增加。64 KiB 例子中 direct-mapped 與 4-way 的 tag 陣列不同，不能說資料容量相同就硬體相同。

Locating a block 與 replacement

Set-associative hit 的步驟是：

1. Index 選 set。
2. 同時比較該 set 所有 ways 的 valid 與 tag。
3. 以 match/way select 讀出對應 data。
4. 若多個 match，表示 cache state 或協議錯誤，而不是任選一個。

Replacement choices 包含 random、LRU 與近似 LRU。2-way LRU 只需一個 recency bit；高 associativity 的 exact LRU state 快速成長，實作常改為 pseudo-LRU。

```
2-way set:  [A, B], recent=A
access B  -> recent=B
miss      -> victim A
```

Victim selection 不影響 architectural correctness，但可明顯改變 miss rate。Coherence cache 的 replacement 還要處理資料 owner 與 invalidation。

Multilevel caches 與 AMAT 的分母

令 T_ℓ 是第 ℓ 層被存取時的 hit time（L1 miss 後才付 L2 hit time），M_ℓ^{local} 是送到該層的 references 中未在此層命中的比例，P_{mem} 是最後仍 miss 後額外付出的 memory penalty。兩層模型是

$$\text{AMAT}_1 = T_1 + M_1 T_2 + M_1 M_2^{\text{local}} P_{\text{mem}}.$$

代入 $T_1 = 1$、$M_1 = 0.04$、$T_2 = 8$、$M_2^{\text{local}} = 0.25$、$P_{\text{mem}} = 100$：

$$\text{AMAT} = 1 + 0.04(8) + 0.04(0.25)(100) = 1 + 0.32 + 1.00 = 2.32.$$

Quantity	分母	本例
M_1	所有 L1 references	0.04
L2 local miss M_2^{local}	只算 L1 misses	0.25
L2 global miss $M_1 M_2^{\text{local}}$	所有 L1 references	0.01
L2 hit service fraction	只算 L1 misses	0.75

若 L1 misses 中有 75% 由 L2 命中，其成本是 8 cycles；剩下 1% 的全部 references 再付 100 cycles。把 25% 直接乘 100 會把 local denominator 當 global denominator，得到錯誤的 26.32 cycles。

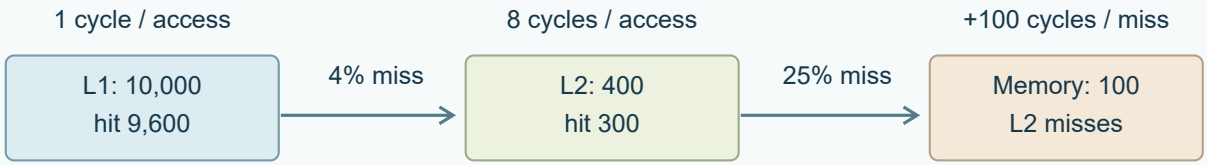
若另定 $P_{2,\text{miss,total}} = T_2 + P_{\text{mem}} = 108$，它是「已知 L2 也 miss」時，從開始 L2 access 到 memory 回覆的總服務時間；L2 hit 仍只需8。因此必須條件平均：

Multilevel caches 與 AMAT 的分母 （續）

$$\text{AMAT}_1 = T_1 + M_1\left[(1 - M_2^{\text{local}})T_2 + M_2^{\text{local}} P_{2,\text{miss,total}}\right] = 1 + 0.04[0.75(8) + 0.25(108)] = 2.32.$$

只有把 $\overline{P}_{1,\text{miss}}$ 明定為「每次 L1 miss 的期望服務成本」，即 $T_2 + M_2^{\text{local}} P_{\text{mem}} = 33$，才可簡寫 $\text{AMAT}_1 = T_1 + M_1 \overline{P}_{1,\text{miss}} = 1 + 0.04(33)$。把條件於 L2 miss 的108直接乘 L1 miss rate會錯得 5.32；penalty 是否包含L2時間，不能取代對L2 hit/miss的條件區分。

用 10,000 次存取看懂多層 AMAT



(10,000×1 + 400×8 + 100×100) / 10,000 = 2.32 cycles

Each L2 lookup is paid once; main-memory penalty is additional.

假設這 10,000 次存取符合前頁比例：L1 miss `10,000×0.04=400` 次；其中 25% 即 100 次也 miss L2，剩下 300 次在 L2 命中。

每次都付 L1 的 1 cycle，400 次付 L2 的 8 cycles，100 次再付額外 100 cycles。總成本為 `10,000+3,200+10,000=23,200` cycles，平均 `23,200/10,000=2.32` cycles。這裡 100 cycles 是 L2 lookup 之後新增的 penalty，不可把已計入的 8 cycles 再算一次。

5.4 Virtual memory 的兩個目的

Virtual memory 將 process 的 virtual address space 映射到 physical memory。它讓每個 process 可以在一致的虛擬位址配置下執行程式，同時由 page table 與 privilege 控制避免任意互相讀寫。

第二個目的是擴大可用容量。Main memory 像 disk-backed storage 的 cache，只保存活躍 pages；page fault 時再把需要的 page 載入。

Modern systems 最關鍵的價值通常是 protected sharing 與簡化 allocation。歷史上手動 overlay 由 programmer 安排程式片段，virtual memory 把大部分搬移工作交給 OS 與硬體。

Virtual memory 不等於「把資料無限加速」。它提供位址空間與保護；真正效能仍取決於 page residency 與 locality。

Page table 與位址翻譯

設 page size 是 4 KiB，則 page offset 有 12 bits。32-bit VA 的 top 20 bits 是 VPN；32-bit PA 的 top bits 是 physical page number（PPN）。

Page table 的 index 是 VPN，entry（PTE）通常包含：

- valid/present。
- PPN 或 disk location。
- read、write、execute 與 user/kernel permission。
- dirty 與 reference bits。
- 可能包含 cacheability/coherence 屬性。

Translation 是

$$\mathrm{PA} = \mathrm{PTE.PPN} \parallel \mathrm{VA.page\ offset}.$$

Offset 不翻譯，因為 page 與 frame 內部配置相同。

Page table entry 的完整欄位依 ISA/OS 而異；本表是教學共同模型。

Page fault 不只是一種 miss

TLB miss 表示硬體 translation cache 找不到 entry，page 可能仍在 memory。Page fault 則表示所需 page 不在 memory，或 access 不符合權限，OS 需要介入。

以下僅示範合法且可恢復的 not-present fault；權限違規須先判斷是否存在合法修復方式，不能直接照此載入：

1. 保存 faulting VA、access type 與可恢復 state。
2. OS 找到 free frame 或選 victim。
3. 若 victim dirty，先依其 backing 與同步規則保存內容，再重用 frame。
4. 依 mapping 從 backing storage 讀入、建立 zero-filled page，或以其他合法方式提供內容。
5. 更新 page table，必要時 invalidate stale TLB entries。
6. 重新執行 faulting load/store。

需要從backing storage調入的major page fault以儲存I/O時間計，遠高於cache miss；demand-zero、copy-on-write等minor fault可能只配置或複製memory，不一定做disk I/O。OS 優先降低 fault frequency，而不是只追求 perfect replacement。

Store page fault 不得在 page 保護或 space 確認前留下 partial architectural write。

Virtual memory 的 writes

Virtual memory 幾乎使用 write-back。若每次 store 都等 backing storage，成本會達數百萬 cycles；write buffer 無法吸收這種延遲。

在此簡化模型中，對 page 的 write 會設 dirty bit，表示內容可能有尚未保存的修改；寫入相同值也可能設 dirty，因此 dirty 不證明資料必然不同。Eviction 時依 backing 與 OS policy 保存 dirty page；clean page 在有可重建的 backing 時可丟棄。

Invalid PTE 可能代表 page 未配置、已 swap、保護違規或 file mapping 的特殊狀態。OS 以 fault address、error code 與 VMA/page-table 狀態決定處理方式。

Dirty 是保守的修改紀錄，不是最後寫入的時間戳；清除時須配合 writeback 與並行寫入的同步，避免漏記後續修改。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Making translation fast：TLB

TLB（translation-lookaside buffer，位址翻譯旁看緩衝）是 page-table entries 的小型 cache。Entry 可包含 VPN tag、PPN、valid、dirty、access permissions 與 ASID。

TLB hit 可由 VPN 快速得到 PPN。TLB miss 不一定表示 page fault：page 可能已在 memory，只需 page walk 並 install TLB entry。

TLB 通常 fully associative 或高 set-associative，因為容量小而 miss cost 重要。TLB entries 的總數遠少於 page-table entries，所以需要 tag；page table 則由 VPN 完整索引。

TLB dirty bit 要隨 PTE 更新同步；context switch 可能 flush TLB，或用 ASID 區分不同 process。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

TLB miss、兩層 page walk 與 cache 查詢

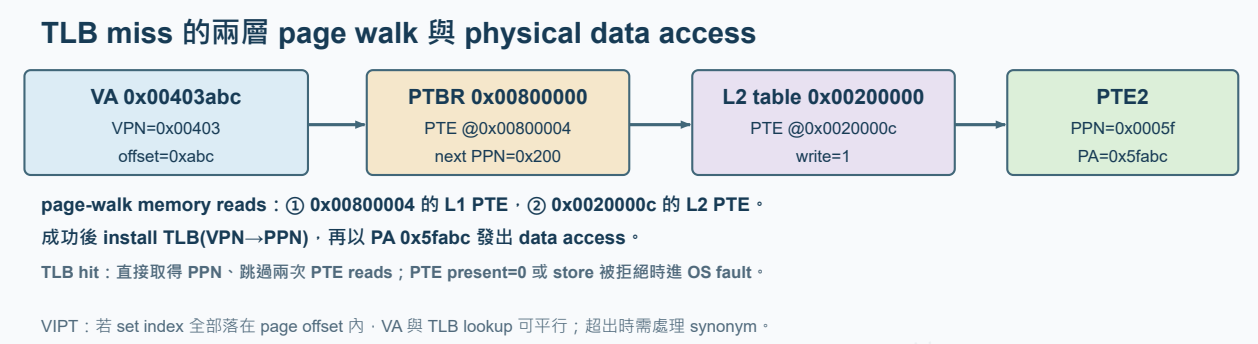
沿用 32-bit VA、4 KiB pages、PTE 4 bytes、每層 1024 entries。令 `VA=0x00403abc`：

$$\mathrm{VPN} = 0x00403, \qquad \mathrm{offset} = 0xabc.$$

兩層各 10 bits，所以 level-1 index 是 `0x001`、level-2 index 是 `0x003`。以下 PTE contents 是明定的教學輸入：

Walk step	Address calculation	Read/decision
1	PTBR `0x00800000` + `0x001×4`	read L1 PTE at `0x00800004`
2	L1 PTE PPN `0x00200` forms table base `0x00200000`	read L2 PTE at `0x00200000 + 0x003×4 = 0x0020000c`
3	L2 PTE has `present=1`、`write=1`、`PPN=0x0005f`	install TLB mapping `0x00403→0x0005f`
4	`PA=(0x0005f<<12)|0xabc=0x5fabc`	data access at `0x5fabc`

TLB miss、兩層 page walk 與 cache 查詢 （續）



TLB miss 的成本不是一個抽象常數。在本例沒有 page-walk cache、需要走完兩層的假設下，須讀取兩個 PTE，再加上資料 cache 查詢與可能的 fill；這些 PTE 存取仍可能 hit 或 miss 一般 cache。若 page-table walk 的 intermediate PTE 有專用 cache，實際 access count 必須重新數。

TLB hit 的 VA `0x00403abc` 直接得到 PPN `0x0005f`，跳過 L1/L2 PTE reads。TLB miss 但兩個 PTEs 都 valid 是 translation miss；若 walk 遇到 PTE `present=0`，則是 not-present page fault。若 `present=1`、`write=0` 而 access 是 store，結果是 protection fault。三者的 hardware path 與 recovery 不同。

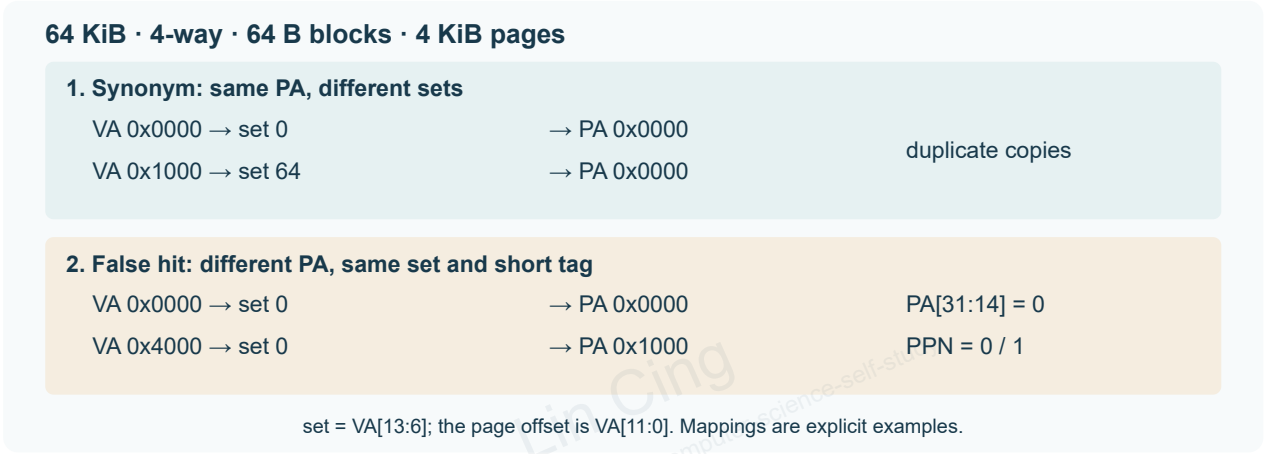
TLB miss、兩層 page walk 與 cache 查詢 （續）

對 VIPT（virtually indexed, physically tagged）cache，未翻譯的 page offset 可在 TLB 查詢時提供 set index。簡單安全配置要求 **block-offset bits + index bits <= page-offset bits**。令 block 大小 B、sets 數 S、page 大小 P，條件 BS<=P，等價於 `data capacity / ways <= page size`。只比較 index 欄位寬度與 page-offset 寬度會漏算 block offset。

64 KiB、4-way、64-byte blocks 有256 sets。Block offset佔bits5:0，index佔bits13:6；6+8=14>12，不符合4 KiB page的條件。VA `0` 與 `0x1000` 若映到同一實體頁的相同offset，分別選set0與64，可能形成同一PA的兩份synonyms（別名）副本。改成16-way，則64sets且6+6=12，別名會選同一set。

允許index超出page offset時，須另有page coloring、synonym偵測/維護，或改用PIPT。若set由VA[13:6]選取，卻只比PIPT式的PA[31:14]，就漏比physical bits13:12，可能把不同PA誤認為hit。比較完整20-bit PPN可避免此false hit，卻仍不能單靠tag comparison消除同一PA在不同sets的重複副本。18-bit PIPT tag不能直接當作此VIPT的完整physical識別條件。

VIPT 的兩種風險：用位址逐一核對



沿用 64 KiB、4-way、64-byte blocks 與 4 KiB pages。若 `VA 0x0000` 與 `VA 0x1000` 都映到 `PA 0x0000`，它們分別選 set 0 與 64：同一 block 可能出現在兩個 sets。比較完整 PPN 能辨認各自的物件，卻不能單靠 tag 比較消除跨 set 副本。

另一個獨立例子中，`VA 0x0000 → PA 0x0000`，`VA 0x4000 → PA 0x1000`。兩個 VA 都選 set 0，兩個 PA 的 `[31:14]` 也都是 0；若只比較這個短 tag，第二次可能誤認第一個 block 為 hit。完整 PPN 分別是 0 與 1，能排除此 false hit。

Protection 與 context switch

Page translation 同時提供 protection。PTE 的 user/supervisor、read/write/execute 權限決定 access 是否合法。權限必須出現在 PTE 與 TLB entry；否則 TLB hit 可能繞過正確檢查。

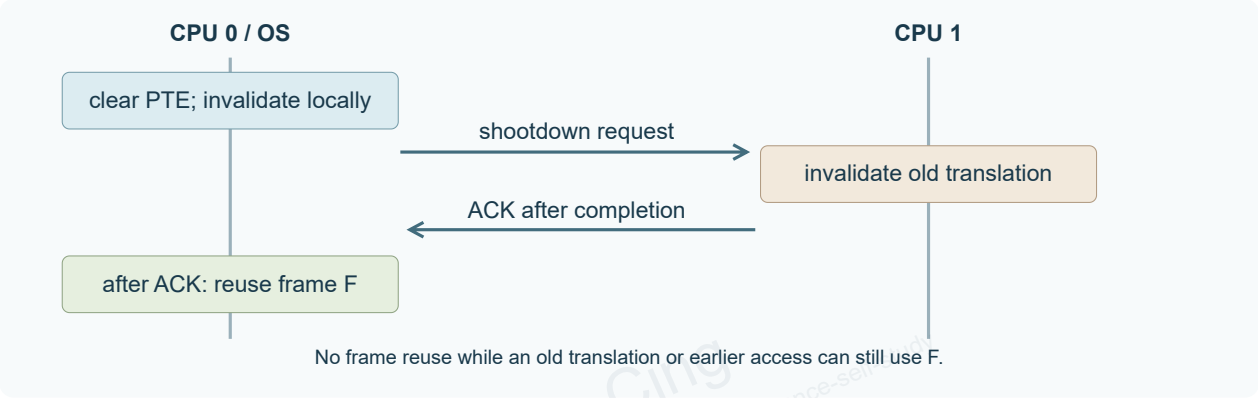
Context switch 時若新 process 使用相同 virtual page number，舊 TLB entry 可能被誤用。解法包括：

- context switch 時 flush TLB。
- TLB tag 加入 ASID（address-space identifier，位址空間識別碼）。

ASID 讓不同 processes 的 translations 共存，降低 switch 後的 TLB misses。OS 仍需管理 ASID 重用與 invalidation。

Cache 若以 physical address 索引，通常不會因相同 VA、不同 PPN 產生同名問題；虛擬定址 cache 還需 alias/context 處理。

多核心 TLB shootdown：何時能重用 frame？



假設 CPU 0 與 CPU 1 正執行同一 address space，兩者的 TLB 都可能保有 V → F。OS 撤銷此映射並準備把 F 給另一頁。先更新 PTE、依架構要求排序並失效本核心舊翻譯，再通知 CPU 1 失效對應 translation。

CPU 1 完成必要的失效與同步後回覆 ACK；OS 在所有可能持有舊翻譯的核心確認，且先前存取已依平台規則安全結束後，才重用 F。若提前重用，CPU 1 仍可能透過舊 TLB 把 V 指到已重新分配的 F。ASID 可以區分位址空間，但同一 ASID 的映射改變或 ASID 重用仍需失效或等效機制；DMA 與 pinned page 須另行管理。

TLB miss、page fault 與恢復

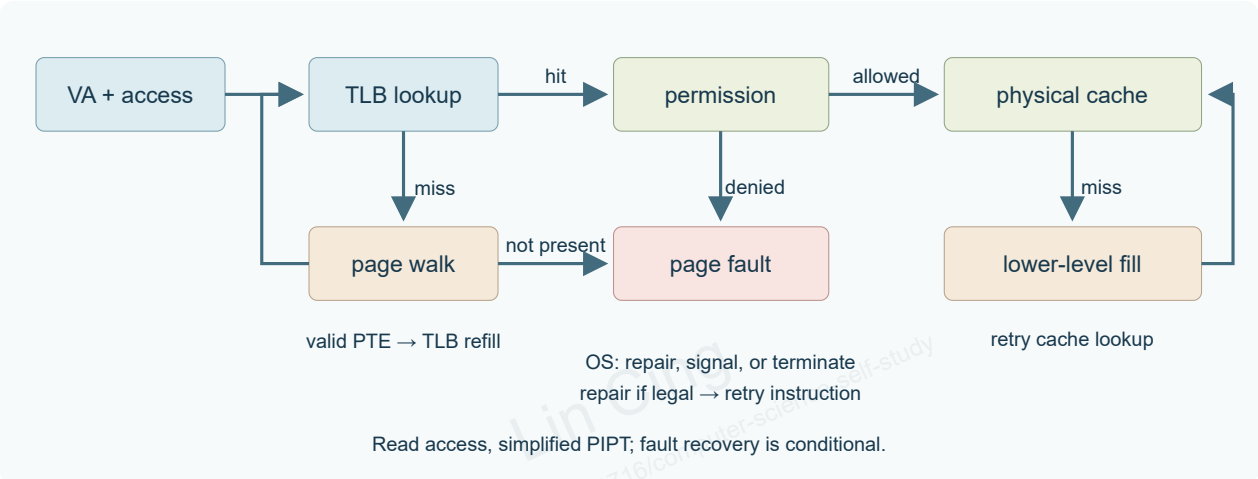
下表中「層級」描述事件來源，不是所有系統都用相同 exception code：

事件	硬體發現	下一步	是否重新執行 instruction
Cache miss	無有效且匹配的 tag	Read／write-allocate：取得 block；no-write-allocate store：轉送寫入	完成原請求或重試
TLB miss，PTE valid	TLB 無 match	hardware/OS page walk、檢查權限	完成或重試
Not-present fault	PTE not present	OS 判斷；合法時配置或載入	依處理結果
Protection fault	permission 不符	終止、signal 或 OS 處理	依語意
Undefined VA	page table 無 mapping	OS fault	依語意

若 instruction 已修改 register 或部分 memory 才 fault，pipeline 需要 precise exception 或可恢復 state。

TLB miss 與 page fault 共用 address register 不表示同一個 exception。必須追查 PTE 結果。

一次存取：三種事件走不同路徑



以簡化的 physically indexed、physically tagged（PIPT）cache 為例：TLB miss 先查 page table；有效映射可回填 TLB，不等於 page fault。無映射或權限不符會交給 OS 判斷：合法時可能修復並重試，否則送出錯誤或終止。

圖中限定 read access：翻譯與權限檢查通過後才查 physical cache；read miss 向下層取 block，再完成或重試。Store miss 若採 write-allocate 也載入 block；no-write-allocate 則將寫入轉送下層，不分配該 block。這只是教學路徑：VIPT 等設計可並行部分查詢，實際 fault 與 refill 機制也依 ISA／OS 而異。

5.5 四個共同問題

Cache、TLB 與 virtual memory 都可以用四個問題描述：

1. Block/page 可以放在哪裡？direct、set-associative 或 fully associative。
2. 如何找到？index、parallel tag search 或 lookup table。
3. Miss 時替換誰？random、LRU、pseudo-LRU 或 OS policy。
4. Write 如何傳播？write-through、write-back、allocate policy。

Table lookup 可以減少 comparison hardware，但需要額外 memory access。Virtual memory 接受 page-table overhead，因為 miss cost 極高，且完全關聯式 placement 給 OS 最大配置彈性。

「fully associative 最好」缺少 hit-latency 與 comparator 成本；以下以 fully associative LRU 作 shadow 定義 3C，因此該基準本身沒有這個定義下的 conflict miss，仍可能有 compulsory 與 capacity misses。

同一組問題，三種不同的物件

結構	保存／尋找的物件	Miss 的處理	更新時的重點
Data cache	實體資料 block；以 tag 和 set 找	Read／write-allocate：取得 block；no-write-allocate store：轉送寫入	依 write-through 或 write-back 傳播資料
TLB	虛擬頁到實體頁的翻譯與權限	查 page table 或交由軟體 refill	mapping 或權限變更時處理失效與同步
Virtual memory	virtual page 對應的 frame 及其 backing	OS 檢查是否合法，必要時配置或載入	對須保留的 dirty page 執行適當 writeback

TLB entry 保存的是翻譯資訊，不是 data cache 的資料 block。更新 PTE 後可能還需要 TLB invalidation；是否需要 writeback 則是頁面資料與其 backing 的問題。兩者可同時發生，但不能混為一次操作。

三類 miss：先固定比較基準

以下以相同 block size、相同 data capacity、每筆存取都更新的 fully associative LRU shadow 為基準。先確認實際 cache 發生 miss，再分類：

類型	這次 miss 的判定條件	常見改善方向	可能代價
Compulsory（首次存取）	這個 block 從未被存取	較大 block、prefetch	流量、pollution
Capacity（容量）	已存取過，shadow 也 miss	增大容量、改善 locality	hit time、成本
Conflict（映射衝突）	已存取過，shadow hit	增加 associativity	比較與選取成本

這是對指定 trace 與比較基準的逐筆分類。第一次碰到 block 的 miss 優先列為 compulsory；「工作集大於容量」或「本次換掉同一 line」都不足以判定其餘每一筆 miss。

用同一串存取區分三類 miss

固定 32-bit byte addresses、64 B data capacity、16 B blocks，cache 初始為空，只有 read、無 prefetch 或 coherence invalidation。實際 cache 是 4-line direct-mapped；比較基準是同樣容納 4 blocks 的 fully associative **LRU shadow cache**。

```
block sequence: 0, 4, 0, 1, 2, 3, 4, 0, 1
byte addresses: 0x0000, 0x0040, 0x0000, 0x0010, 0x0020,
                0x0030, 0x0040, 0x0000, 0x0010
```

每次都讀 block 內 offset 0。DM 的 offset 為 4 bits、index 為 2 bits、tag 為 26 bits；`line=block mod 4`、`tag=floor(block/4)`。Block 0 與 4 分別具有 tag 0 與 1，卻同樣競爭 line 0。Shadow 的索引不採此規則，四個位置可放任意 blocks。

先查 actual cache：若 hit 就不屬於 3C；若 miss，第一次碰到此 block 是 compulsory，其餘才以 shadow 的 hit/miss 判為 conflict/capacity。**兩個 cache 都處理每一筆存取，包括 actual hit**，且 LRU hit 也會更新最近使用次序。

第三次讀取：容量還有空位，卻已發生衝突

同容量：**4 blocks × 16 B = 64 B**；初始皆空

#1 block 0 (0x0000)

Direct-mapped：line = block mod 4

line 0	block 0
line 1	—
line 2	—
line 3	—

FA shadow：LRU → MRU

0	—	—	—

DM miss / FA miss

首次碰到此 block

#2 block 4 (0x0040)

Direct-mapped：line = block mod 4

line 0	block 4
line 1	—
line 2	—
line 3	—

FA shadow：LRU → MRU

0	4	—	—

DM miss / FA miss

首次碰到此 block

#3 block 0 (0x0000)

Direct-mapped：line = block mod 4

line 0	block 0
line 1	—
line 2	—
line 3	—

FA shadow：LRU → MRU

4	0	—	—

DM miss / FA hit

conflict：0 曾被 4 淘汰

DM 的四列是固定 line 編號；FA 圖的四格則依 LRU → MRU 排列，不是固定 way 編號。第 2 次讀 block 4 時，DM 必須淘汰 line 0 的 block 0；FA 尚有空位，因此兩者可同時保留。第 3 次重訪 block 0，DM miss、shadow hit，這一次才是 conflict miss。

第 1–5 次：先看 compulsory 與 conflict

表內為存取**後**的狀態，– 表示 invalid。H/M 是本次 hit/miss；FA 格內依 LRU → MRU 排列。

#	block	DM [line 0,1,2,3]	DM	FA LRU → MRU	FA	DM 分類
1	0	`[0,–,–,–]`	M	`[0]`	M	compulsory
2	4	`[4,–,–,–]`	M	`[0,4]`	M	compulsory
3	0	`[0,–,–,–]`	M	`[4,0]`	H	conflict
4	1	`[0,1,–,–]`	M	`[4,0,1]`	M	compulsory
5	2	`[0,1,2,–]`	M	`[4,0,1,2]`	M	compulsory

第 6–9 次：分清 capacity 與 hit

第 6 次後 shadow 含 4 個 blocks；繼續逐筆更新，而不是重新從 empty 開始。

#	block	DM [line 0,1,2,3]	DM	FA LRU → MRU	FA	DM 分類
6	3	`[0,1,2,3]`	M	`[0,1,2,3]`	M	compulsory
7	4	`[4,1,2,3]`	M	`[1,2,3,4]`	M	capacity
8	0	`[0,1,2,3]`	M	`[2,3,4,0]`	M	capacity
9	1	`[0,1,2,3]`	H	`[3,4,0,1]`	M	hit

DM 共 8 misses：5 compulsory、1 conflict、2 capacity。第 7、8 次是重訪且 shadow 也 miss；不能只因 DM 在 line 0 發生替換，就把它們都列為 conflict。

Shadow 的 miss 不一定是 actual 的 miss

#9 讀 block 1（byte address 0x0010）

Direct-mapped
固定 line 0 / 1 / 2 / 3

block 0	**block 1**	block 2	block 3

HIT：block 1 一直保留在 line 1
狀態不變；不是任何一種 miss。
#7、#8 只替換 line 0。

Fully associative LRU shadow
存取前：LRU → MRU

block 2	block 3	block 4	block 0

MISS：#8 已淘汰 block 1
淘汰 2 → 新次序 [3, 4, 0, 1]
shadow 仍須更新，但 actual 不計 miss。

第 9 次是 **actual hit、shadow miss**，不計入實際 cache 的任何 miss 類別。全段 DM 與 FA 各有 8 misses：第 3 次的 DM miss／FA hit，恰與第 9 次的 DM hit／FA miss 抵銷。總數相減雖為 0，仍有一次 conflict；必須逐筆判定。

改成 2-way：同容量不等於同樣的替換結果

仍為 64 B、每 block 16 B，2-way 時有 2 sets，`set=block mod 2`，各 set 各自維護 LRU。全段 hit/miss 為 `M M H M M M M M H`，共 7 misses。第 9 次前 set 0 為 `[4,0]`、set 1 為 `[1,3]`（皆由 LRU 排至 MRU），所以 block 1 仍 hit。

設計	hit 次數	miss 次數	hit time H	總存取時間（額外 miss penalty = 20 cycles）
DM	1	8	1 cycle	`9×1+8×20=169 cycles`
2-way LRU	2	7	1.25 cycles	`9×1.25+7×20=151.25 cycles`

此表假設每次存取皆付 H，miss 再額外付 penalty，且全部序列化、沒有重疊。本例中 2-way 較快的條件是 `9×1.25+7P < 9×1+8P`，即 `P>2.25 cycles`。

FA 允許的 placement 更多，但 **LRU 不是最少 miss 的最佳替換演算法**。本例 2-way 反而少一次 miss；不能把「可放的位置更多」誤解成「任意替換策略對每一串存取都較好」。

5.6 Virtual machines

System virtual machine 提供一個 guest 可執行完整 OS 的 ISA-level 環境。VMM（virtual machine monitor，虛擬機器監控器）隔離 guests，並控制 privileged state、translation、interrupts 與 I/O。

Guest 以為自己掌握 machine，實際上 privileged operations 必須由 VMM 介入或安全地直接執行。Virtualizability 取決於 ISA 是否讓 sensitive privileged state 都能被 trap 或由硬體管理。

Virtual memory 在 VM 中可能有三層：guest virtual memory、guest physical/real memory 與 host physical machine memory。

Java VM 之類的 process-level VM 不提供完整系統 ISA 與 device 隔離；不要和 system VM 混為一談。

VM 的 translation 與 I/O

沒有硬體 nested paging 時，VMM 可用 shadow page table 把 guest VA 直接映射到 host PA，並保護/追蹤 guest 對其 page tables 的修改。Shadow update 與 TLB invalidation 是 overhead。

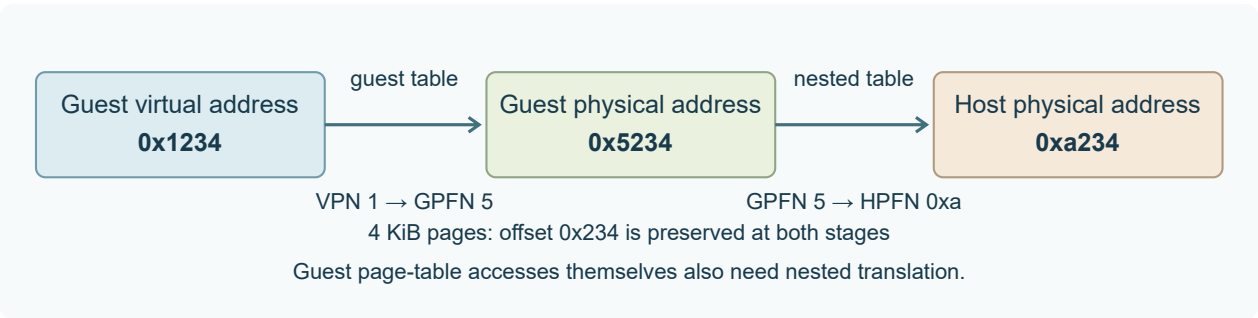
有 nested paging 時，硬體可執行兩層 walk，減少 VMM traps，但每次 TLB miss 可能多層存取。

I/O virtualization 特別複雜，因為 device、DMA、interrupt、queue 與 driver 都要隔離。VMM 可用 emulated device、passthrough 或硬體 I/O MMU。

本例的 x86/MIPS 歷史實作是本章案例範圍；今日硬體支援更豐富，結論仍以可 trap、可隔離與成本判斷。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

雙層分頁：一次位址翻譯的實例



假設兩層皆用 4 KiB page，權限允許且所有映射有效。Guest 程式發出 GVA `0x1234`：guest VPN 為 `1`，offset 為 `0x234`。Guest page table 把 VPN `1` 映射到 guest physical frame `5`，得到 GPA `0x5234`。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

巢狀翻譯的額外查表

Nested page table 再把 guest frame `5` 映射到 host frame `a`，得到 host PA `0xa234`；兩次翻譯均保留 offset。Guest page table 自身位於 guest physical memory，因此讀取 guest PTE 時，也要把該 PTE 的 guest physical address 經 nested table 翻譯。TLB 或 walk cache 若命中，實際讀取次數會減少，不能一律假設固定成本。

5.7 Cache FSM 控制



本章案例簡化 write-back cache controller 有四個 states：

1. Idle：等待 processor request。
2. Compare Tag：判斷 hit 或 miss；write hit 設 dirty。
3. Write-Back：dirty victim 寫回 memory，等待 `Ready`。
4. Allocate：fetch requested block，等待 `Ready`，完成後重查 tag。

5.7 Cache FSM 控制 （續）

Memory latency 可變，因此 FSM 以 `Ready` 而非固定 cycles 等待。未 assert 的 control signal 預設 deasserted；multiplexer select 仍要指定有效 value。

Write-back 與 Allocate 的 ordering 必須保證 dirty victim 在 frame 被覆寫前保存。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

FSM transition trace

以下 trace 對應 clean read miss 後 hit：

```
cycle 1: Idle + request -> Compare Tag
cycle 2: miss + victim clean -> Allocate
cycle N: memory !Ready -> stay Allocate
cycle N+1: Ready -> Compare Tag
cycle N+2: valid && tag hit -> set cache-ready -> Idle
```

Dirty write miss：

```
Compare Tag -> Write-Back -> Allocate -> Compare Tag -> Idle
```

Controller 也需要保存原 request type 與 store data；Allocate 完成後不能把 write 誤當成 read。

Early restart、critical-word-first 或 write buffer 會增加 concurrency，也增加 state 與 correctness obligations。

5.8 Cache coherence

共享記憶體多處理器使用 private caches，因此同一 physical address 可能有多份 cached copies。Coherence 規定已排序的 read 可看到哪個 value，以及同一位置的 writes 如何被序列化。硬體層未排序的存取可能依 execution order 得到不同結果；read 看到舊值本身不證明 coherence protocol 壞掉，仍需看 consistency model 的排序。在 C++ 等語言中，非 atomic 的 data race 可能是 undefined behavior，不能直接把硬體層觀察當成語言保證。

Coherence 至少保證：

1. 同一 processor 在 program order 先寫同一位置，且其間沒有其他 processor 對同址的有效 write 時，後續 read 看到自己的 write。
2. 對同一位置的 writes 被所有 processors 以相同順序觀察。
3. 若 synchronization 已把 read 排在某個 write 之後，且其間沒有更晚的同址 write，該 read 回傳該 write 的 value。

第三點需要 memory consistency model 才能精確定義跨 thread 的「後續」。Coherence 管同一位置及其可見 value，consistency 管跨位置與 synchronization 的 ordering。只有當 atomic operation 依規格建立 synchronization，而且該關係涵蓋相互衝突的 accesses 時，才排除那一組 data race；它不會修正其他未排序存取，也不會把任意舊值讀取自動變成違規。

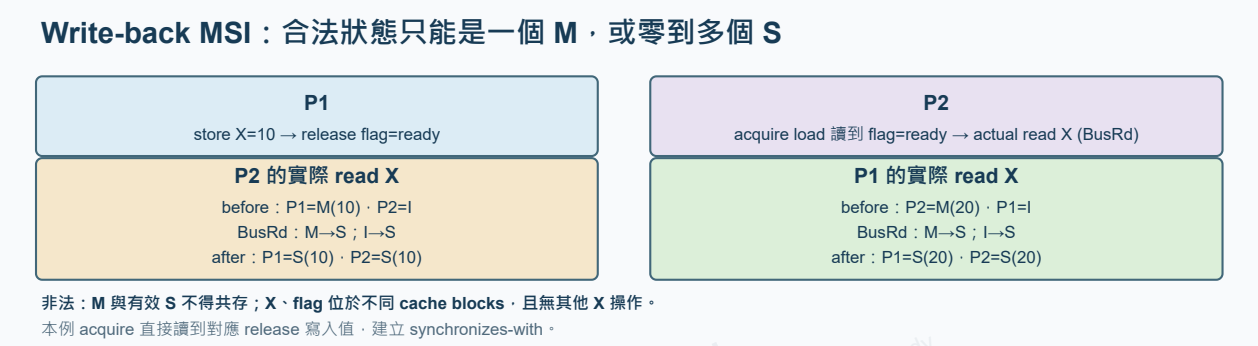
其他 write 介入後的 Write-back MSI 時序



先看 P1 寫入 10，再發布 `ready`；P2 的 acquire 必須讀到這個 release 值，才能把先前的寫入排序在 P2 後續讀取之前。Acquire 本身不讀 X；P2 之後的 X read miss 才發出 BusRd，由 P1 的 M owner 提供 10。

P2 隨後寫入 20 並發布 `two`；P1 成功 acquire 後再讀 X，才能沿相同推理取得 20。本圖假設旗標與 X 位於不同 block，且兩段之間沒有其他 X 存取；共享 block 仍可同步，但會有額外的 coherence traffic。

MSI 狀態不變量與 acquire/read 的差別



工作例明定 x 與 atomic `flag` 位於不同 cache blocks，且兩段程式之間沒有其他 X 操作。P1 store `X=10`，再以 release store 寫 `flag=ready`；在本例中 P2 的 acquire load 直接讀到這個 release 寫入值，兩者建立 synchronizes-with，接著**實際 read X**。P2 store `X=20`，再 release `flag=two`；P1 的 acquire load 實際讀到 `two` 後，才再次**實際 read X**。

事件（program order）	P1 X	P2 X	flag 與 ordering 關係
初始	X:I	X:I	X 未 cached；flag 尚無 release/acquire 關係
P1 store X=10；write miss / BusRdX	X:M(10)	X:I	P1 在自身 cache 完成 write；尚未建立與 P2 的跨 thread happens-before

MSI 狀態不變量與 acquire/read 的差別 （續）

事件（program order）	P1 X	P2 X	flag 與 ordering 關係
P1 release flag=ready	X:M(10)	X:I	release 排序 P1 先前的 X store 與 atomic flag write；不要求把 dirty X flush 到 memory
P2 acquire flag=ready	X:M(10)	X:I	acquire load 實際讀到該 released value 才 synchronize-with；**不讀 X，也不改變 X cache state**
P2 acquire flag=ready 後，實際 read X；read miss / BusRd	X:S(10)	X:S(10)	P1 的 M owner 供給 10；P1 M→S，P2 I→S，memory 更新為 10
P2 store X=20；BusRdX/upgrade	X:I	X:M(20)	P2 取得 exclusive permission，P1 的有效 copy 失效
P2 release flag=two	X:I	X:M(20)	release 排序 X=20 與 atomic flag=two
P1 acquire flag=two	X:I	X:M(20)	acquire load 實際讀到 `two` 後才 synchronize-with；**P1 尚未讀 X**
P1 acquire flag=two 後，實際 read X；read miss / BusRd	X:S(20)	X:S(20)	P2 的 M owner 供給 20；P2 M→S，P1 I→S，memory 更新為 20

MSI 狀態不變量與 acquire/read 的差別 （續）

Write-back MSI 的不變量是同一 block 最多只有一個 M；M 存在時，任何其他 cache 都不能保有有效 S。本表的合法 read miss 都由原 M owner 提供資料，並同時把 owner 降為 S。`acquire flag` 不是 `load x`；真正讀 X 的 load 才觸發 BusRd 與上述狀態轉移。若 x 與 `flag` 共用 cache block，false sharing 另會觸發該 block 的 coherence traffic；本表不把那個額外效果混入 X 的狀態。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Snooping 與 write-invalidate

Snooping protocol 讓每個 cache 觀察 shared interconnect 的 block request，沒有 central directory。它適合 broadcast 可負擔的系統，processor 數增加後 traffic 與 scalability 成問題。

Write-invalidate protocol 在寫入前取得 exclusivity，使其他 cached copies invalid。常見簡化 state：

- I：Invalid。
- S：Shared，可讀且可能有多份。
- M：Modified，只有此 cache 有有效 copy，main memory 可能 stale。

Read miss 可能在 S 或 M 找到 supplier；write hit 在 S 需發 invalidate；M owner 被另一 read 觀察時須提供最新 data 並調整 state/write-back policy。

BusRd/BusRdX、cache-to-cache transfer 與 writeback 的行為依 protocol；state table 必須完整指定。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

5.9 Cache controller 的設計

Cache controller 是處理 variable-latency memory 的狀態機。`Idle` 接收 request，`Compare Tag` 判定 hit/miss，`Write-Back` 保存 dirty victim，`Allocate` 等待 lower-level block。Memory 尚未回應時 `Ready=0`，完成時安裝 block、更新 valid/tag 並清除新 block 的 dirty，再回 `Compare Tag` 重查。只有重查命中並完成原 read 或 write 後，才 assert `Cache Ready`；原 request 是 write 時還要寫入保存的 store data 並設 dirty。

Controller 必須保存 request type、store data、fault/retry 所需的 state，以及 victim ownership。`Write-Back` 必須在 victim slot 被覆寫前完成，或先把 victim 安全放入有完成保證的 buffer；`Allocate` 不可越過這個 ordering condition。

可檢查的設計不變量包括：任何 valid cache line 的 tag 唯一指向其 data、dirty line 在被無備份覆寫前已保存、response 只在 block/data ready 後產生，以及 reset/error 不得留下半完成 transaction。這些 invariants 可用 assertion 或 model checker 測試。

5.10 Real systems

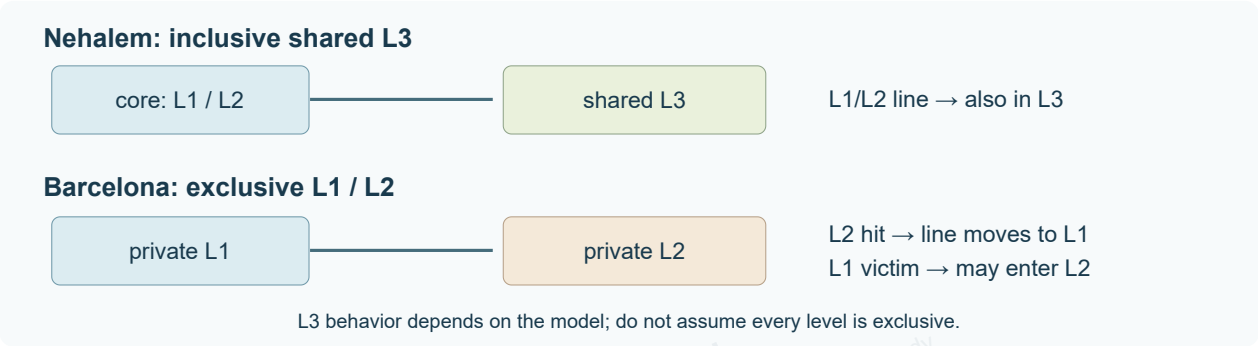
本章案例 AMD Opteron X4（Barcelona）與 Intel Nehalem 案例都把 larger caches、TLB 與 memory controller 放在 die 上。Dies 有私人 L1/L2、shared L3 與多層 TLB，降低 off-chip communication，但增加 area、power 與 coherence 複雜度。

Nehalem 案例的公開教材數據是每 core 私人 instruction/data cache、L2，以及四 cores 共享 L3。本章案例另一個關鍵是 lower-level caches 可由 data outside this core fill，並可採 victim cache 式關係。

這些 2008 年尺寸用來理解 cache sharing、inclusion 與 on-die traffic tradeoff，不是今日 purchase benchmark。

若 L3 non-inclusive，L2 miss 仍可能由 L3 hit；不能假設上層缺失一定能由直接下層找到。

歷史案例：inclusive 與 exclusive 的差別



Intel 的 Nehalem 白皮書描述每核心 32 KiB I-cache、32 KiB D-cache 與 256 KiB unified L2，並有最多 8 MiB 的共享 inclusive L3。Inclusive 的意思是：核心 L1／L2 的有效 block 也有對應 L3 copy；L3 miss 因此可協助排除其他核心私有 cache 命中。

Patterson 與 Hennessy 的 Opteron X4 2356（Barcelona）案例則描述 L1 與 L2 為 exclusive：L2 hit 的 block 可移到 L1，被替換的 L1 block 再進 L2。其共享 L3 對多核心共享 block 不一律維持 exclusive；不能把 L1／L2 規則直接套到所有層。不同協定的 eviction、dirty data 與 coherence 處理仍須個別確認。

5.11 Fallacies and pitfalls

第一類錯誤是忽略 byte addressing。32-byte data cache、4-byte blocks 有 8 blocks；byte address 36 先整除 4 得到 block 9，再 mod 8 得到 block index 1。

第二類錯誤是把 block size 當成 block count。容量除以 block size 才是 blocks，不是把 address 除以 cache capacity。

第三類錯誤是把 local/global miss rates、instruction/data references 或 ns/cycle 混用。

第四類錯誤是只看 hit rate。更大的 L1 可能 miss rate 較低，但 clock path 變長，整體 AMAT 反而上升。

每題先寫單位與分母，通常可避免大半的手算錯誤。

記憶體階層與架構契約

Cache 與 virtual memory 都要決定物件如何放置、尋找、替換與更新，但 block、page 與 miss cost 的尺度不同。Locality 讓常用資料留在較快的層級；多層設計則在容量、延遲與資料搬移成本間取捨。

Paging 與 TLB 提供可轉換、受保護的位址空間；coherence 與 consistency 規範共享資料可見性。實作可以改變，但仍須遵守 ISA 與記憶體模型的架構契約。

軟體可用 blocking、loop ordering 或 prefetch 改善 locality，效果須依工作負載量測；單純增加 L3 容量不一定解決頻寬、coherence 或排程瓶頸。歷史案例的數值反映當時設計，不是永恆比例。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

章末驗收

完成本章後，應能：

1. 由 byte address 手工切出 tag/index/offset。
2. 對任意 trace 列 hit/miss、victim、dirty/write-back。
3. 從 AMAT 推到 CPI 與 elapsed time，並說明 stall 假設。
4. 畫出 page walk、TLB hit、TLB miss 與 page fault 的分支。
5. 對 write-invalidate protocol 寫出 state transition。
6. 說明 3Cs、local/global miss 與 consistency model 的邊界。

先完成本章獨立練習題 PDF，再以詳解 PDF 核對單位、假設與每一步。

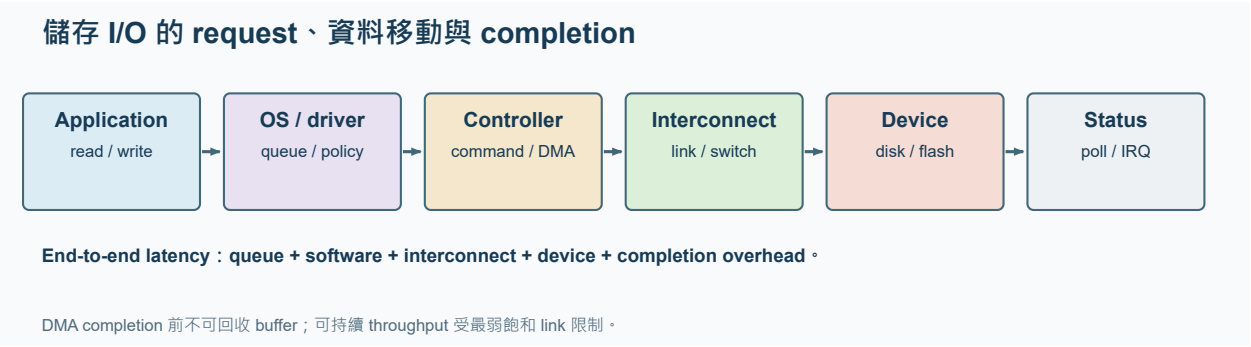
參考資料與署名

Lin Cing，《計算機組織》手寫筆記。 Patterson and Hennessy, Computer Organization and Design, revised fourth edition, Chapter 5. CSO course slides, memory hierarchy. Intel, Next Generation Microarchitecture (Nehalem), 2008, https://www.intel.com/pressroom/archive/reference/whitepaper_Nehalem.pdf

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study

從一筆 request 看完整系統



讀檔會經過檔案系統、driver、controller 與儲存媒體；發出命令、資料抵達記憶體及應用程式可使用 buffer，是不同事件。分析效能時，先固定 request 大小、讀寫比例、queue depth、cache 狀態與完成的語意。揮發性 cache 回報寫入完成，不等於斷電後資料仍存在。

容量、頻寬與 IOPS 的分母

本章 GB、TB 分別採 $10^9, 10^{12}$ bytes；GiB、TiB 分別採 $2^{30}, 2^{40}$ bytes。Link 的 bit/s 須除以8才變成 byte/s，還需扣除協定額外流量。

若每個完成的request都是4 KiB，100,000 IOPS的payload頻寬是

$$100000 \times 4096 = 409600000\ \mathrm{B/s} = 0.4096\ \mathrm{GB/s}.$$

若改成64 KiB而IOPS不變，則是6.5536 GB/s，但裝置與link未必能承受。IOPS不是與request大小無關的常數。Response time從提交到完成；throughput是穩定狀態每秒完成數，不能取任意一筆latency的倒數代表並行系統吞吐量。

6.1 依工作負載選設計目標

互動式查詢重視尾端延遲；連續備份重視持續頻寬與恢復能力；交易系統還要求commit後的持久性與失敗原子性。相同SSD數量可以因request pattern與完成條件不同而產生不同瓶頸。

設計的限制包括裝置、controller、interconnect、記憶體及CPU處理命令的能力。擴充裝置還會消耗電力、queue entries、interrupt資源及故障恢復時間。高峰值頻寬無法單獨保證低延遲或高可用度。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.2 Failure、reliability 與 availability

服務規格先定義可接受行為。實際服務偏離規格是failure（失效）；由失效狀態恢復符合規格是restoration（恢復）。元件fault可能被冗餘遮蔽，未必成為使用者看見的服務failure。

Reliability $R(t)$ 是從正常狀態起，至時間t仍連續正常的機率。Availability是觀察時刻服務正常的機率，或長期正常時間比例，允許中途失效後修復。修得很快可提高availability，卻不會把中途曾失效的歷史改成連續可靠。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

從更新週期推導可用度

假設系統反覆經歷正常時間U與修復時間D，各週期的(U_i,D_i)獨立同分布、非負，且0<E[U]+E[D]<∞。由大數法則，經歷k個完整週期後，正常比例為

$$A_k = \frac{\sum_{i=1}^{k} U_i}{\sum_{i=1}^{k} (U_i + D_i)} \longrightarrow \frac{E[U]}{E[U] + E[D]}.$$

因此 $A = MTTF/(MTTF + MTTR)$。這個長期比率不要求每次正常與修復時間都剛好等於平均值，也不給出每年最大停機次數。

MTTF=100,000小時、MTTR=4小時時，A=0.9999600016。8,760小時的長期平均停機量約為 $8760(1 - A) \times 60 = 21.02$ 分鐘。MTTR降到0.5小時後約2.63分鐘，減少18.39分鐘。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

平均失效時間不等於故障期限

只有另假設固定hazard λ 的指數壽命，才有

$$R(t) = e^{-\lambda t}, \qquad MTTF = 1/\lambda, \qquad P(T \le t) = 1 - e^{-t/MTTF}.$$

MTTF=100,000小時時，一年內失效機率在此模型下是 $1 - e^{-8760/100000} \approx 8.39\%$，不是保證可用100,000小時，也不是「一年最多一次」。元件老化、共同供電與環境損壞會破壞固定hazard或獨立性假設，不能只憑平均值外推實際風險。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.3 磁碟幾何與邏輯容量

磁碟由盤面、磁軌及sector（扇區）組成，同一磁頭半徑的各盤面磁軌稱cylinder。舊式固定幾何模型的payload容量為

$$C = \text{cylinders} \times \text{surfaces} \times \text{sectors/track} \times \text{bytes/sector}.$$

10,000 cylinders、4 surfaces、500 sectors/track、512 bytes/sector得到10,240,000,000 bytes，即10.24 GB或約9.5367 GiB。若這些已是可定址的logical sectors，不能再把raw媒體的gap/ECC比例任意扣一次。現代裝置使用LBA與控制器轉換，不把這個固定幾何公式當作實際物理配置。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

一筆 random read 的各段時間

忽略排隊時，存取時間為

$$T_s = T_{seek} + T_{rotation} + T_{transfer} + T_{controller}.$$

在12,000 RPM且每track500 sectors的模型，轉一圈 $60/12000 = 5$ ms；均勻隨機到達角度的平均旋轉等待2.5 ms；一sector佔 $5/500 = 0.01$ ms。平均seek4.5 ms、controller0.10 ms，得到

$$T_s = 4.5 + 2.5 + 0.01 + 0.10 = 7.11 \text{ ms}.$$

只有一筆outstanding且不重排時，長期完成率約 $1/0.00711 = 140.65$ IOPS。這不是「提高queue depth後吞吐量永遠不變」的定理，因為排程與locality可能改變平均service time。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Sequential request 如何攤提固定成本

同一磁軌上100個相鄰sectors合併成一筆request，明定不跨track、不另付setup及rotation。Transfer為 $100 \times 0.01 = 1$ ms，總時間

$$4.5 + 2.5 + 1 + 0.10 = 8.10 \text{ ms}.$$

Payload為51,200 bytes，平均6.321 MB/s。若拆成100筆互不相關random requests，模型時間是711 ms。差異來自只付一次定位成本，不是把媒體旋轉速度提高100倍。真實連續讀還要明定track crossing、預讀cache與controller pipeline。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.4 NAND 的 page 與 erase block

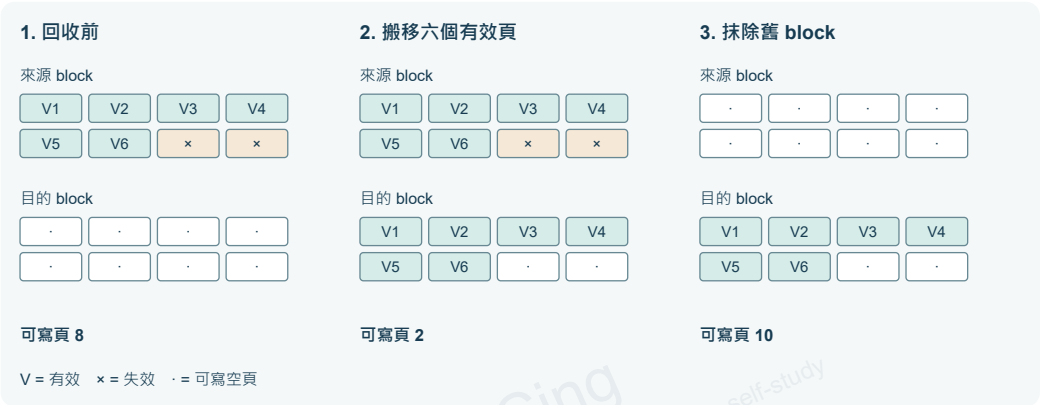
NOR適合較細粒度讀取與部分直接執行的firmware用途；NAND以較高密度支援大量儲存，通常按page讀寫、按較大的erase block抹除。兩者皆非揮發性，但介面、成本與更新粒度不同。已寫入NAND page不能像DRAM word一樣任意原地重寫；FTL（flash translation layer）將logical page映到新physical page，使舊page失效，再由garbage collection回收erase block。

設一個erase block有8個pages，其中6個有效、2個失效。回收時先把6個有效pages複製到其他空間，再erase舊block，產生8個可寫pages；扣掉保存舊資料所需的6個位置，本輪只淨增加2個可供host更新的位置。

若本輪2個新host pages加上6個搬移pages，NAND共program8 pages，則WA=8/2=4。只計這個循環，不把erase次數直接加成寫入bytes。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Garbage collection：逐頁追蹤



假設目的 block 原有 8 個可寫空頁，且不考慮其他 block 的變化。搬移前有 8 個空頁；複製六個有效頁後剩 2 個；抹除來源 block 後增加 8 個，合計 10 個。因此 GC 使系統的可寫空頁淨增加 2 個。

若接著 host 寫入 2 個同大小的新頁，這一輪共 program 6 個搬移頁與 2 個 host 頁，write amplification 為 $8/2 = 4$。這是特定批次的資料寫入比例；實際 WA 還受工作負載、有效頁比例及 metadata 影響。

Endurance 的粗估與限制

Write amplification定義為 $WA = \text{media寫入bytes}/\text{host寫入bytes}$。Host一天120 GB、media384 GB，WA=3.2。

若physical NAND400 GB、可用P/E預算3000 cycles，且均勻磨耗、WA固定、無其他保留預算，host總寫入量粗估

$$\frac{400 \times 3000}{3.2} = 375000\ \text{GB} = 375\ \text{TB}.$$

這不是產品保固。Wear leveling、壞block備援、溫度、retention與metadata都有額外影響。Overprovisioning增加可搬移空間，通常有助GC；若同時改變working set，觀察到的WA不能全歸因於保留比例。

6.5 Link、bus 與端到端瓶頸

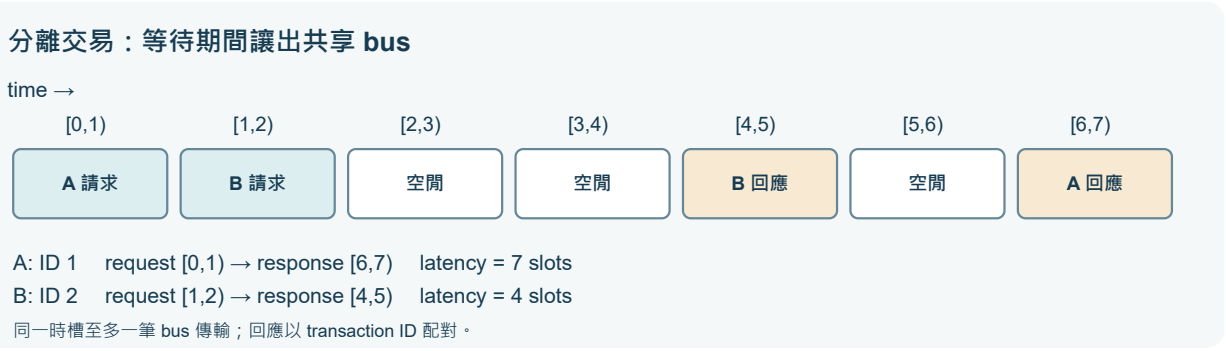
Shared bus的多個裝置競爭同一傳輸資源；point-to-point link與switch可平行不同路徑，但仍可能共用上游link、controller與memory channel。裝置總峰值不能直接相加成應用吞吐量。

例如6個SSD各80,000 IOPS、HBA120,000、memory path300,000、CPU/driver150,000 IOPS，穩態上界為

$$\min(6 \times 80000, 120000, 300000, 150000) = 120000.$$

再加兩個SSD仍受HBA限制。若HBA升到240,000，下一個上界變成CPU的150,000。這些是固定同一request大小與讀寫mix的容量上界，排隊、lock與error recovery可讓實測更低。

分離交易：等待時釋放 bus



假設每個 request／response 占一個時槽；目標裝置可同時處理兩筆請求，且 bus 每次只能傳一筆。A 先發出、B 後發出，但 B 先完成；transaction ID 讓回應即使重排也能送回正確的 requester。

圖中 7 個時槽有 4 個用於傳輸；A 的端到端延遲是 7，B 是 4。釋放 bus 讓等待與其他工作重疊，**不保證單筆延遲降低**；競爭、仲裁與裝置是否支援多筆未完成交易都會改變結果。

6.6 命令、通知與資料搬移彼此獨立

MMIO（memory-mapped I/O）把裝置register映到位址空間，由具適當權限的load/store存取。特定ISA也有獨立I/O指令。裝置register的cacheability與ordering由平台規格決定，不能當作普通可快取RAM。

Polling與interrupt回答「如何得知狀態」；programmed I/O與DMA回答「誰搬資料」。DMA可搭配poll completion，也可搭配interrupt completion。使用interrupt不表示每個data word都由CPU搬移。

Doorbell store只是通知裝置有新descriptor。若descriptor資料尚未對裝置可見，裝置可能讀到舊位址或舊長度；正確順序須依OS DMA與I/O API建立，不是只加一條任意store即可。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Polling 與 interrupt 的實算

3 GHz CPU，每秒20,000筆I/O。若每筆恰好一次poll、每poll100 cycles，成本為2,000,000 cycles/s，即0.0667% CPU。每筆interrupt handler1500 cycles時，成本30,000,000 cycles/s，即1% CPU。

這個一次poll的模型中，增加runnable threads數不會改變上述算式。若每次提交後忙等50 µs，且不與其他requests共用等待，20,000筆已需要整個core的1秒等待時間；不能沿用「只一次poll」的0.0667%結論。

Hybrid可先短暫poll再sleep，completion queue也可批次處理多筆。比較時需計setup、忙等、context switch、completion批次大小及延遲分布，不能先假設interrupt永遠較快。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

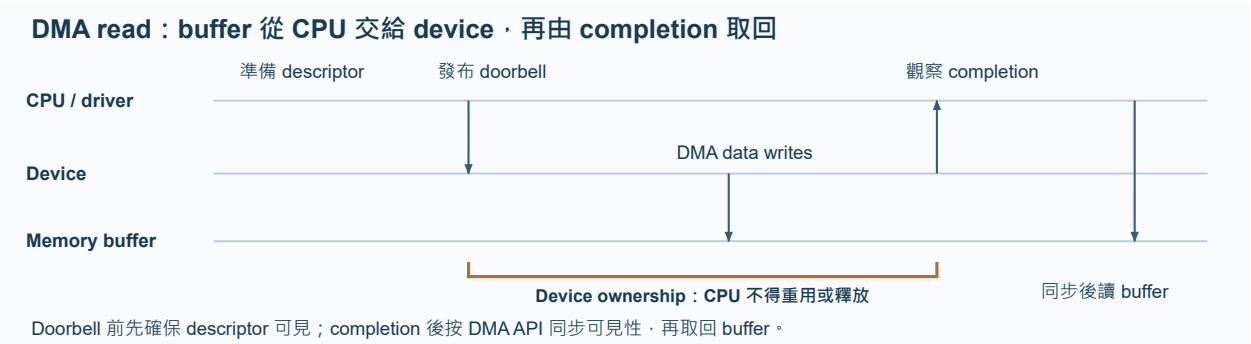
Interrupt priority 與完成處理

Device設pending狀態，controller/CPU依enable與priority決定是否接受interrupt。進入handler後，driver讀status、確認來源、處理completion/error、按裝置規則清除或acknowledge來源，再喚醒等待工作。若一個shared interrupt有多個可能來源，不能無條件假設每次都是自己的device。

假設低priority handler關閉全部interrupt共8 μs，高priority事件在關閉後1 μs到達，則單是masking便使它至少等7 μs；「它priority較高」不能消除這段等待。允許nested interrupts可減少某些等待，但需保存獨立context、保護共享driver狀態並界定最大巢狀深度。Coalescing合併多個completion可降低每秒handler次數，也可能增加第一個completion的通知等待。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

DMA 的 buffer ownership 狀態



裝置寫入記憶體前，CPU 配置 buffer 並發布 descriptor；裝置持有期間，CPU 不可釋放、重用或讀取未完成內容。完成後 CPU 依 DMA API 同步可見性，再取回 buffer。

非一致性平台須在正確時點 clean／invalidate：DMA 寫完後才寫回舊的 dirty cache line，可能覆蓋新資料。Timeout 不代表裝置已停止；解除映射前須確認不會再有 DMA 寫入。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

DMA 節省的是 core 搬移成本

64 MiB在20 ms完成，payload頻寬為

$$64 \times 2^{20} / 0.020 = 3.3554432\ \mathrm{GB/s}.$$

CPU setup500 cycles在3 GHz需0.1667 µs。相較之下，programmed I/O每16 bytes需16搬移cycles加10 transaction cycles，共

$$(64 \times 2^{20}/16) \times 26 = 109051904\ \text{cycles},$$

約36.35 ms CPU時間，尚不含等待。DMA仍消耗interconnect、memory bandwidth、IOMMU查詢與completion處理，不能把0.1667 µs誤當完整端到端時間。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.7 Little 定律連結 concurrency 與 latency

穩定、無持續累積工作的系統，平均系統內requests數 L、完成率 λ、平均response time W 滿足

$$L = \lambda W.$$

理由是觀察區間內「系統內人數對時間的面積」等於各request逗留時間之和；除以觀察長度，再讓起終邊界殘留的影響消失，即得此式。L含正在服務與排隊者；若只算queue，應使用Lq與Wq。

100,000 IOPS且平均response80 µs時，L=8。這不是保證把queue depth設8便達到該吞吐量，因為調整concurrency本身可能改變response time；它是同一穩態量測的必須一致關係。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

M/M/1 模型為何接近滿載就變慢

本頁另明定Poisson到達率λ、獨立指數service rate μ、單一server、FCFS、無限等待區，且ρ=λ/μ<1。這是分析模型，不宣稱磁碟實際service distribution一定指數。

平衡方程 $p_n\lambda = p_{n+1}\mu$ 給 $p_n = p_0\rho^n$。用機率和為1得 $p_0 = 1-\rho$。微分幾何級數可得

$$L = (1-\rho)\sum_{n\ge 0} n\rho^n = \frac{\rho}{1-\rho}, \quad W = L/\lambda = \frac{1}{\mu-\lambda}.$$

因此平均service time $1/\mu$ 不變時，queueing也能讓response暴增。ρ>=1不存在上述有限穩態平均，不能把負值或無窮級數公式硬套成正常latency。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

同一裝置兩個負載的排隊成本

取μ=200 IOPS，平均service5 ms。

λ	ρ	W=1/(μ−λ)	Wq=W−5 ms	L=λW
100 IOPS	0.5	10 ms	5 ms	1
160 IOPS	0.8	25 ms	20 ms	4
190 IOPS	0.95	100 ms	95 ms	19

從160增至190 IOPS只多18.75%完成量，平均response卻由25變100 ms。這是此模型的計算結果，不是所有實機固定倍數。只報最高IOPS會隱藏滿載附近的延遲代價；應同時固定平均/尾端latency限制。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.8 固定成本與持久性納入設計

總latency在無重疊串行路徑可相加；不同資源的持續吞吐上界取最小值。CPU與裝置可重疊時，不能把全部CPU時間和全部I/O時間無條件相加，也不能假設完全重疊。

Write-back cache可縮短回報時間，但若應用要求斷電後保留，就須把持久媒體、保護的cache或明確flush completion納入終點。兩個系統若一個回報「已入RAM」、另一個回報「已持久」，不能直接以latency比較相同服務。

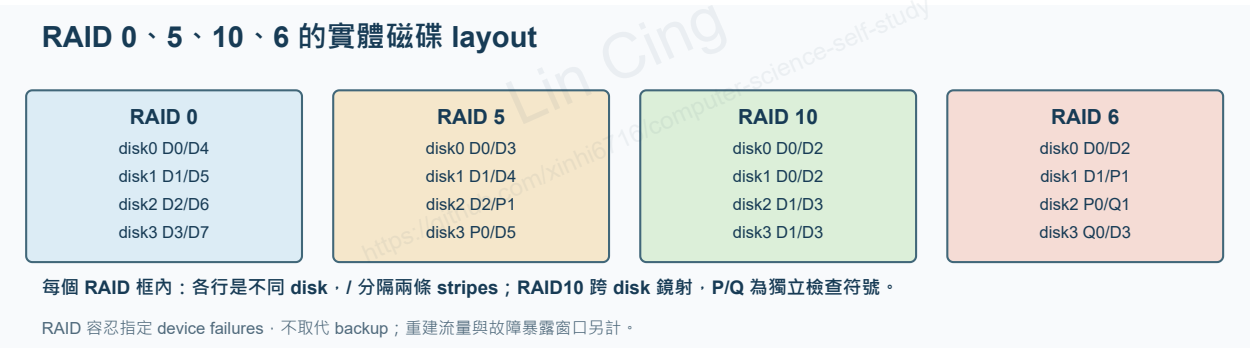
錯誤重試需辨識命令是否已部分完成。重送write可能安全，重送「增加counter」卻可能執行兩次；controller/driver與上層交易協定共同決定恢復語意。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.9 RAID 的容量與容錯模型

本章以n顆等容量C的disks，不含spare、metadata及保留空間。Failure指可識別的整顆disk erasure，假設survivors資料正確、controller與供電正常。

配置	Usable容量	可恢復的整顆失效
RAID0 striping	nC	無冗餘
RAID1配對/RAID10	nC/2，n為偶數	每組mirror最多失一顆
RAID4/5	(n−1)C	任一顆
RAID6 P+Q	(n−2)C	任意兩顆，編碼及前提成立時



RAID3以細粒度bit/byte條帶配合同步存取，RAID4以block條帶讓小讀取分散，但集中parity造成寫入瓶頸。RAID5輪替parity位置，只消除固定單顆parity disk的瓶頸，並未消除parity更新成本。

XOR parity 的恢復證明與數值

以bitwise XOR定義 $P = D_0 \oplus D_1 \oplus D_2$。因為 $x \oplus x = 0$、$x \oplus 0 = x$ 且可交換結合，遺失 D_1 時

$$P \oplus D_0 \oplus D_2 = D_1.$$

取4-bit資料D0=1010、D1=1100、D2=0110，P=0000。遺失D1時，0000 XOR 1010 XOR 0110=1100，還原原值。

只有一個parity時，兩個未知data blocks只給一條XOR方程，因此通常不唯一。若disk回傳未被發現的錯誤值，甚至無法只由parity判定哪顆壞；「可恢復一個已知遺失」與「定位任意silent corruption」是不同保證。

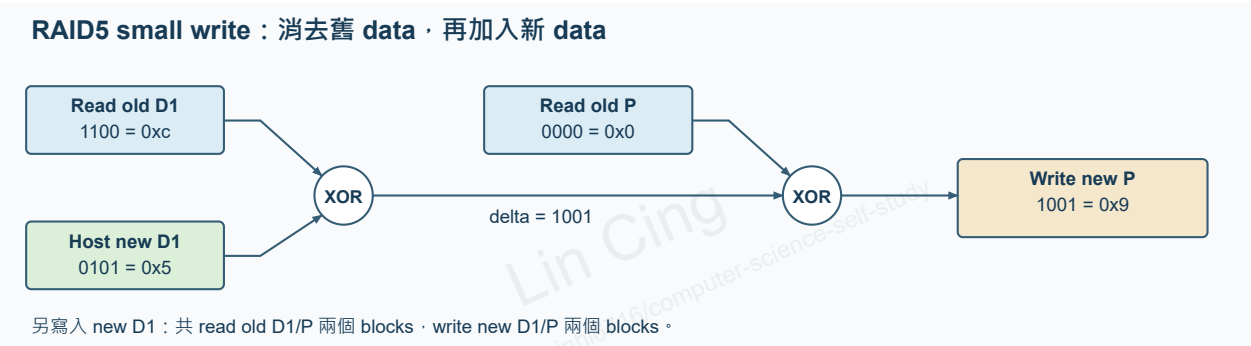
Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Small write 與 full-stripe write

更新一個data block時，利用

$$P' = P \oplus D_{old} \oplus D_{new}$$

可讀old data、old parity，再寫new data、new parity，共2讀2寫。若上述D1由1100改成0101，P'=0000 XOR 1100 XOR 0101=1001。



若一次覆寫整條stripe的m個data blocks，全部new data都由host提供，可以直接算new parity，不需讀old blocks，只寫m個data加1個parity。若只更新k個data，reconstruct-write可讀其餘m−k個舊data再寫k個new data與parity；需比較 $2k + 2$ 與 $(m - k) + (k + 1) = m + 1$ 次block I/O，並考慮cache及並行瓶頸。

RAID5 讀寫 mix 的容量上界

假設8顆disk，每顆持續100個block I/O/s；小讀只占1次disk I/O，小寫採2讀2寫，所有parity/data流量均衡，沒有cache合併或rebuild。令host中讀比例r，則每host request平均需要

$$r + 4(1 - r) = 4 - 3r$$

個disk I/O，因此host完成率 $X \le 800/(4 - 3r)$。r=0.75時，平均1.75個，X<=457.14 IOPS。

這是aggregate工作量上界，並未保證每次small write四個操作可完全平行。若某顆disk、stripe lock或controller已先飽和，實測更低。RAID4另有集中parity disk：每small write該disk要一讀一寫，寫入率先受其能力除以2限制。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

兩份相同 parity 為何不是 RAID6

若Q只是P的另一份copy，遺失兩個data時，兩條方程完全相同，仍無法唯一恢復。RAID6需要獨立的檢查資訊。

一種P+Q模型是在有限域GF(2^w)逐symbol計算

$$P = \sum_i D_i, \qquad Q = \sum_i a_i D_i,$$

其中加法是XOR，非零係數a_i互異。遺失Di、Dj時，扣掉已知survivors得到 $X = D_i + D_j$、$Y = a_i D_i + a_j D_j$。因 $a_i + a_j \neq 0$ 有乘法逆元素，

$$D_j = (Y + a_i X)/(a_i + a_j), \qquad D_i = X + D_j.$$

這說明兩條獨立方程如何解出兩個erasure；不是把一般整數乘除直接套進bitwise XOR。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

P+Q 的一個可重算例子

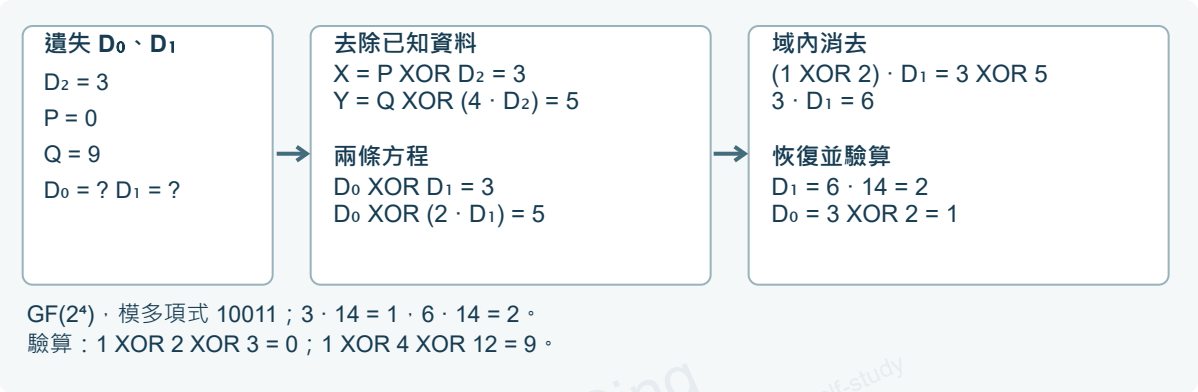
採GF(2^4)，模多項式 $x^4 + x + 1$（binary10011），symbol以4-bit多項式表示。乘2是左移；若原最高bit為1，截成4 bits後XOR0011。係數a0=1、a1=2、a2=4。

取D0=1、D1=2、D2=3。P=1 XOR 2 XOR 3=0；Q=(1・1) XOR (2・2) XOR (4・3)=1 XOR 4 XOR 12=9。

若D0、D1同時遺失，X=P XOR D2=3；Y=Q XOR(4・D2)=9 XOR 12=5。故3・D1=Y XOR X=6。域內3的逆為14，因對多項式模10011運算可得3・14=1；6・14=2，得D1=2、D0=3 XOR 2=1。實際RAID採用的symbol大小、係數與layout可不同，本例只證明明定編碼的恢復步驟。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

P+Q：兩個遺失值如何解出



已知 D₂、P、Q，先從兩個 parity 扣除 D₂ 的貢獻，再將兩條方程 XOR，消去 D₀。所有加法是 XOR，乘法及逆元素都在指定的有限域中；一般整數除法不能替代域運算。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Parity write hole 與一致性

Small write的data與parity是兩個實體寫入，若電源在兩者之間中斷，survivors可能各自讀取正常卻不屬於同一版本。例如old D1=1100、P=0000，先寫new D1=0101後中斷，parity仍0000，已不等於全部data的XOR。

這稱write hole。單靠parity公式無法保證更新原子性。受保護write cache、journal、完整stripe交易與恢復協定可保存重作資訊；各自需定義寫入順序、持久點及開機恢復規則。RAID也不能恢復合法指令造成的誤刪，因此不能取代獨立備份。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Rebuild 的流量分母

12顆10 TB的RAID5，明定每顆有效9 TB，controller只重建有效區域。重建每個遺失block要讀11個surviving blocks，因此讀99 TB、寫replacement9 TB。

若所有讀與寫共用aggregate1 GB/s路徑，時間下界

$$T \geq (99+9)10^{12}/10^{9} = 108000\ \mathrm{s} = 30\ \mathrm{h}.$$

若「1 GB/s」改指replacement輸出速率，則9 TB/1 GB/s=2.5小時，但surviving讀取路徑需同時支援11 GB/s。兩個分母不能混用。若全盤重建而不辨識有效區域，讀110 TB加寫10 TB，在aggregate路徑需至少33.33小時。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Rebuild：流量與頻寬要配對



每寫回一個遺失 block，就要讀取其餘 11 個 block，因此重建 9 TB 需要讀 99 TB、寫 9 TB。若同一條路徑承擔讀寫，分子是兩者的總流量；若 1 GB/s 專指 replacement 的寫入，分子只有 9 TB，但同時需要足夠的讀取頻寬。

以上都是理想化的下界，忽略競爭、故障處理與額外開銷；不能用單一鏈路數值代替整條路徑的容量。

重建期間的第二顆失效機率

明定n=8的RAID5已失去一顆，修復時間固定r=10小時，其餘7顆獨立、每顆固定hazardλ=10^−5/小時。剩餘disk全部活過r的機率為

$$(e^{-\lambda r})^7 = e^{-7\lambda r},$$

所以這段時間至少再失去一顆的機率

$$1 - e^{-7\times 10^{-5}\times 10} \approx 0.000699755,$$

約0.06998%。這是已進入降級狀態後的條件機率，不是array每年資料遺失率。讀取不可校正錯誤、共同故障、修復時間分布與再次故障需另建模，不能把此值稱完整RAID可靠度。

6.10 Sun Fire 歷史案例與功耗邊界

原書Sun Fire x4150是2008年前後的1U server案例，列出的最大配置有兩個four-core Xeon sockets、64 GB DRAM、8顆15,000 RPM SAS disks及RAID controller。這些是原書的歷史配置，不代表當代產品。19-inch rack的1U高度為1.75 inches，42U為73.5 inches，還需留供電與散熱能力。

以明定的教學配置而非產品實測，設server idle200 W、滿載400 W、完成2000 transactions/s。滿載每transaction能耗400/2000=0.2 J。若半載仍耗300 W、只完成1000/s，則0.3 J/transaction。把兩部半載整合到一部滿載，只有在容量、尾延遲、容錯與遷移成本可接受時才可能減少總能耗。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

同一歷史配置，不同 workload 的瓶頸

以下另定義教學workload，並非原書效能量測。8個cores各持續10^9 instructions/s，每筆I/O需250,000 user加150,000 OS instructions；每筆64 KiB。CPU上界為8×10^9/400000=20000 IOPS。

假設每disk的random-read平均service4 ms，8顆合計2000 IOPS；sequential每disk持續112 MB/s，合計 $8 \times 112 \times 10^6 / 65536 = 13671.875$ IOPS。單一RAID card的payload link若2 GB/s，則 $2 \times 10^9 / 65536 = 30517.578$ IOPS。

在忽略其他限制、無disk conflict的模型，random上界min(20000,2000,30517.578)=2000，sequential上界13671.875，兩者皆disk先限制。若把裝置換成更快SSD超過20000 IOPS，CPU便可能先限制；歷史配置的圖與新模型的workload不能混成同一份產品benchmark。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.11 Network 的傳輸與等待

10 Gbit/s link、payload efficiency80%，有效頻寬8 Gbit/s=1 GB/s。傳64 MiB需

$$64 \times 2^{20}/10^{9} = 67.108864\ \text{ms}.$$

若每4 MiB為一batch，16 batches之間各需0.20 ms gap，且連線已建立，則15 gaps共3 ms，總70.108864 ms。100條streams可以重疊某些等待，卻不能把共用link的總payload能力變成100 GB/s。

Propagation（訊號傳播）、serialization（把bits送入link）、queueing與protocol setup是不同項。Bandwidth-delay product為頻寬乘RTT，表示維持某速率所需的在途資料量，而不是每筆request自動增加的固定資料量。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.12 用反例檢查常見推論

「DMA不耗CPU」漏掉setup與completion，且資料仍占memory bandwidth。「RAID6有兩個parity blocks就安全」漏掉獨立編碼與write hole。「MTTF高就一年不會壞」把平均值誤當期限。

「IOPS相同所以效能相同」可由4 KiB與64 KiB反例推翻。「提高queue depth一定降低response time」可由M/M/1表推翻。「RAID就是backup」則無法處理誤刪及攻擊者同步改寫所有copies。

每個反例指出失效的前提，不把特定workload的結論外推成所有裝置或所有版本。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.13 從觀測值回推限制

若吞吐不再上升而response增加，先檢查各資源利用率、queue length與per-I/O成本。Little定律可檢查三個量是否來自同一穩態，但不能單獨定位哪一段飽和。

若寫入回報很快卻在斷電後遺失，應檢查完成語意與持久路徑；若RAID重建超時，應分開計surviving讀、replacement寫與共用link。故障與效能分析都從清楚的端到端服務規格開始。

6.14 技術演進與不變的分析方法

磁碟的機械定位、NAND的out-of-place更新與互連的共享資源不同，但都需分開容量、service rate、queueing與failure model。由bus轉向switch、由HDD轉向SSD，只改變主要成本，不消除buffer ownership、completion及持久性問題。

原書的歷史數據適合觀察設計取捨；比較新系統時必須重新取得相同workload與完成條件的數據，不把2008年的裝置峰值當作現代通用常數。

參考資料與署名

David A. Patterson、John L. Hennessy，《Computer Organization and Design: The Hardware/Software Interface》，Revised Fourth Edition，第 6 章。Lin Cing，《計算機組織》手寫筆記；計算機組織與結構（CSO）課程投影片。

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study

平行處理的目標與形式

為何需要平行處理

單核心的時脈頻率不能無限制地提高：功率密度、時脈分配、指令層平行能力與記憶體延遲都會形成限制。平行處理把工作分配給多個執行單元，可用來提高單位時間完成的工作量（throughput），或縮短一項大型工作的完成時間。

多核心處理器在同一晶片上放置多個核心；多處理器系統也可能跨越多個插槽；叢集（cluster）則以網路連接多台電腦。它們的通訊延遲、快取一致性與故障範圍並不相同。

本章的加速比（speedup）比較同一問題或同一服務需求下的經過時間；若未交代工作負載與基準，單說「快 N 倍」沒有足夠意義。

Parallelism 的種類

工作層級的平行（job-level parallelism）是同時處理多個互不相依的工作，例如多個網頁請求；它能提高整體吞吐量，但不要求把每個請求拆開。

平行程式也可以把同一問題分給多個工作者（workers），例如矩陣乘法與影像處理；程式中哪些運算相依，決定哪些工作可以同時執行。

指令層平行（ILP）在單一指令流中重疊相互獨立的運算；資料平行對多筆資料執行相同操作；任務平行則讓不同任務或功能同時執行。這些形式可以在同一系統中共存。

7.1 功耗與平行設計

降低供應電壓與頻率通常能減少動態能耗，但也會降低單核心效能。若在相同功率預算內配置多個較慢的核心，程式又有足夠的平行工作，就可能提高每瓦完成的工作量；靜態功耗與通訊成本仍須納入比較。

平行處理的目標與形式 （續）

平行系統也能利用服務複本提高可用性：一個節點失效時，其他節點接手。但這需要冗餘、故障偵測與復原機制；多核心本身不會自動提供這些能力。

可擴充軟體在不同核心數、快取容量與網路拓撲下仍須保持正確，並維持合理效率。判斷小核心是否更省電，必須先指定工作負載、電壓與頻率，以及功率計量範圍。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

7.2 Amdahl 的固定工作模型

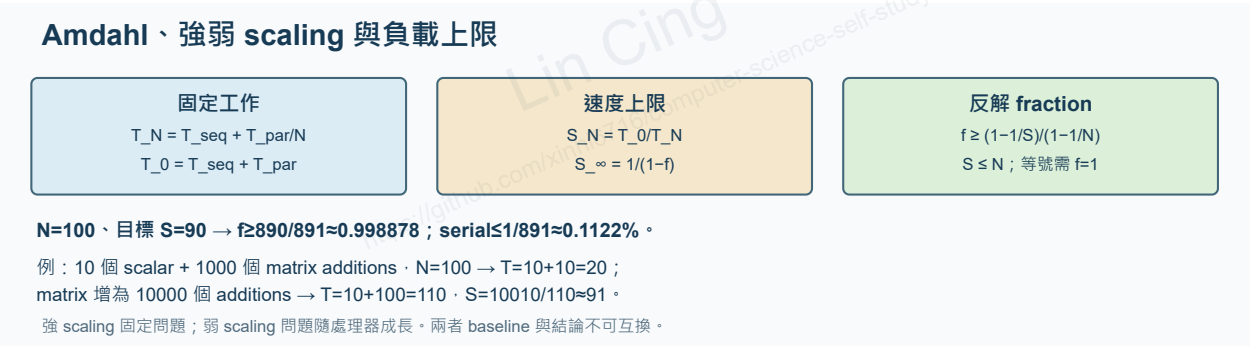
令固定工作的單執行緒 baseline 為 T_0。若其中比例 f 為可平行部分，$(1-f)$ 為序列部分，且 N 個 workers 完美分擔平行部分、沒有額外成本：

$$T_N = T_0(1-f) + \frac{T_0 f}{N}.$$

這個式子把「序列部分不縮小」直接寫進時間分解。Speedup 是 baseline time 除以新 elapsed time：

$$S_N = \frac{T_0}{T_N} = \frac{1}{1 - f + f/N}.$$

Efficiency 定義為 $E_N = S_N/N$，單位不是 occupancy。若 $S_N = 4.70588, N = 8$，則 $E_N = 0.588235 = 58.8235\%$。



7.2 Amdahl 的固定工作模型 （續）

當 $N \to \infty$：

$$S_\infty = \frac{1}{1-f}.$$

此公式假設 0≤f<1；f=1 時理想加速比隨 N 無界。這個上界只有在 workload、baseline 時間比例與成本定義固定時成立。它是 asymptote，不是某一台機器的 measured speedup。

從目標 speedup 反解

若處理器數 $N > 1$，目標加速比滿足 $1 \le S \le N$，可得到必要的平行比例：

$$f \ge \frac{N(S-1)}{S(N-1)}.$$

例如 $N = 100, S = 90$，必要 $f \ge 8900/8910 = 0.998878$，序列比例不得超過約 0.1122%。把這個門檻誤解成「90% 可平行」會得到完全不同的答案。

模型沒有包含 synchronization、load imbalance、launch 或 shared-bandwidth contention。實際時間可以寫成

$$T_{N,\text{observed}} = T_N + T_{\text{critical}} + T_{\text{sync}} + T_{\text{contention}},$$

上述加總只適用於各項額外成本互不重疊，且基準計算時間未改變的簡化模型；若成本重疊或快取、時脈改變，應沿執行時間線與關鍵路徑分析。Measured speedup 通常低於 ideal Amdahl 模型。只有先驗證這些成本近似可忽略，才能把差值歸因於單一原因。

從整體目標反推局部加速



目標 4 倍：需要局部改善 16 倍；5 倍只是極限

基準總時間為 100 ms，其中 80 ms 可改善、20 ms 不變。令局部加速倍數為 k，則整體加速為 $S = 100/(20 + 80/k)$。

目標 $S = 4$ 時，新時間必須是 25 ms；因此 $20 + 80/k = 25$，解得 $k = 16$。即使可改善部分趨近零，總時間仍趨近 20 ms，所以整體加速趨近 5 倍；對有限的 k，5 倍無法剛好達成，更高目標也不可能。這個上限依賴工作量與不變部分固定。

同時改善兩個部分

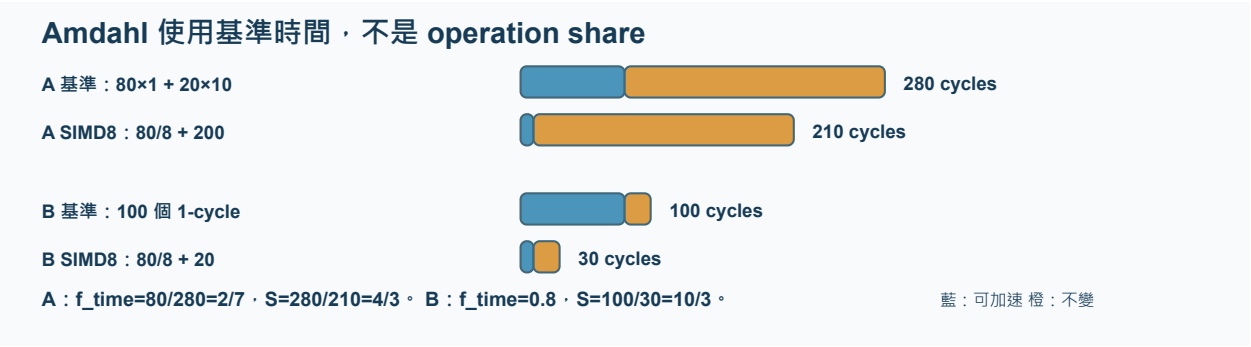
以同一基準時間為分母：乘法占 20%、記憶體存取占 50%、其餘占 30%。假設三段時間互斥，且改善彼此沒有交互作用。

乘法加速 4 倍、記憶體存取加速 2 倍時，新時間為

$$T_{new}/T_0 = 0.20/4 + 0.50/2 + 0.30 = 0.60, \qquad S = 1/0.60 = 5/3 \approx 1.667.$$

如果只改善乘法，新時間為 0.85 倍、加速約 1.176 倍；只改善記憶體則為 0.75 倍、加速約 1.333 倍。不能把兩個單項 speedup 相加，因為每項改善都以同一份基準時間為起點。

操作比例不等於時間比例



先看100個操作中的80個一cycle操作可向量化，另20個各花10 cycles。基準時間為$80 + 200 = 280$ cycles。8倍向量化後為$10 + 200 = 210$ cycles，故$S = 4/3$，可加速時間比例只有$80/280 = 2/7$。

模型	基準可加速時間	基準其餘時間	8倍加速後總時間	整體加速
不等成本A	80	200	10+200=210	280/210=1.3333
等成本B，100個操作各1 cycle	80	20	10+20=30	100/30=3.3333

相同80%操作比例可以對應不同時間比例。只有等成本或另外量到80%基準時間時，才可將0.8直接代入Amdahl。

Strong scaling、weak scaling 與效率

Strong scaling 固定 problem size W，增加 processors P，問同一工作最快能多快完成。若理想時間是 T_1/P，則

$$S_{\text{strong}}(P) = \frac{T_1}{T_P}, \qquad E(P) = \frac{S_{\text{strong}}(P)}{P}.$$

Weak scaling 讓總 problem size 從 W 成長為 PW，使每 processor 的工作量固定。弱擴展效率定義為

$$E_{\text{weak}}(P) = \frac{T_1(W)}{T_P(PW)}.$$

理想弱擴展保持相同完成時間，因此效率為1；此時間比不是固定問題的 speedup，也不應再除一次 P。若另外假設同一問題的單核成本隨工作量線性，$T_1(PW) = PT_1(W)$，才可寫

$$S_{\text{scaled}}(P) = \frac{T_1(PW)}{T_P(PW)} = \frac{PT_1(W)}{T_P(PW)} = PE_{\text{weak}}(P).$$

若缺少較大問題的單核時間或線性成本假設，不能僅從兩個不同規模的時間推出這個同規模 speedup。若資料量 M 固定，strong scaling 的每處理器記憶體約 M/P；若 weak scaling 讓 M 隨 P 成長，每處理器記憶體約維持 M。

固定規模與弱擴展：數值比較

假設每次 addition 成本為 t，序列工作為 10 次 additions。

問題	$P = 10$	$P = 100$
small：10 serial + 100 parallel	$T = 10t + 100t/10 = 20t$，$S = 110/20 = 5.5$	$T = 10t + 100t/100 = 11t$，$S = 110/11 = 10$
large：10 serial + 10,000 parallel	$T = 10t + 10,000t/10 = 1010t$，$S = 10010/1010 \approx 9.91$	$T = 10t + 10,000t/100 = 110t$，$S = 10010/110 = 91$

上述兩個固定規模的比較並不是 weak scaling：從 10 增到 100 cores 的同時，工作量增加了 100 倍，每 core 工作量並未固定。真正的弱擴展示例可取 P=10、平行工作 100 次，及 P=100、平行工作 1,000 次；序列部分均為 10 次。兩者皆需 20t，因此相對 P=10 的弱擴展效率為 20t/20t=1。較大問題的單核時間為 1010t，故其同規模 speedup 為 1010/20=50.5，並非 100。

報告至少記錄 problem size、per-core work、worker count、baseline、communication bytes、memory footprint、clock/power policy 與 measured wall time。只寫「99% 效率」而沒有 growth rule，無法重現。

Load balance 與 parallel critical path

令總 parallel work 為 W、最重 worker 的工作量為 $W_{\max}$、processor 數為 $P \geq 2$、固定 overhead 為 C，且每個 worker 以每單位時間處理一單位工作。若工作可任意分割，其他 workers 平均分擔剩餘工作時，parallel phase 的 completion time 為

$$T_{\text{parallel}} = \max\left(W_{\max}, \frac{W - W_{\max}}{P - 1}\right),$$

$$T_{\text{total}} = T_{\text{parallel}} + C.$$

一般 worker 的平均工作量不能預測完成時間；最慢 worker 與 dependency chain 都可能成為 critical path。Work stealing 可動態搬移 tasks，但每次 steal 需要 queue/atomic metadata，搬移資料又增加 cache 與 network traffic。Task 太細時，coordination 成本可能超過負載改善。

完整算例

令 $W = 10{,}000$、$C = 10$、$P = 100$。若一個 worker 分到 2%，即 200 units，其他 99 workers 共 9,800 units：若單位不可分，98 人各得 99、1 人得 98；平均 98.99 不是個別工作量。即使採離散分配，最重者仍為 200，因此結果相同：

$$T = \max\left(200, \frac{9800}{99}\right) + 10 = \max(200, 98.99) + 10 = 210.$$

Sequential baseline 是 $10{,}000 + 10 = 10{,}010$：

$$S = 10{,}010/210 \approx 47.67, \qquad E = 47.67/100 \approx 47.7\%.$$

Load balance 與 parallel critical path （續）

若重 worker 分到 5%（500 units）：

$$T = \max\left(500, \frac{9500}{99}\right) + 10 = 500 + 10 = 510,$$

$$S = 10{,}010/510 \approx 19.63, \qquad E \approx 19.6\%.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

7.3 Shared-memory multiprocessors

SMP（shared-memory multiprocessor，共享記憶體多處理器）給所有 processors 一個 common physical address space。Programs 用 shared loads/stores 溝通，硬體以 cache coherence 維持同一位置的 visible order。

UMA（uniform memory access）模型中，各 processor 到 memory 的 access time 近乎相同。NUMA（nonuniform memory access）中，local memory 比 remote memory 快；program page placement 與 data affinity 會改變效能。

NUMA 系統仍共用同一個 physical address space。NUMA 描述 memory latency 與 bandwidth 的拓樸差異，不是彼此分離的 address spaces。

Directory-based coherence 常用於較大的 SMP/NUMA，snooping 在 broadcast domain 小時較直接。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

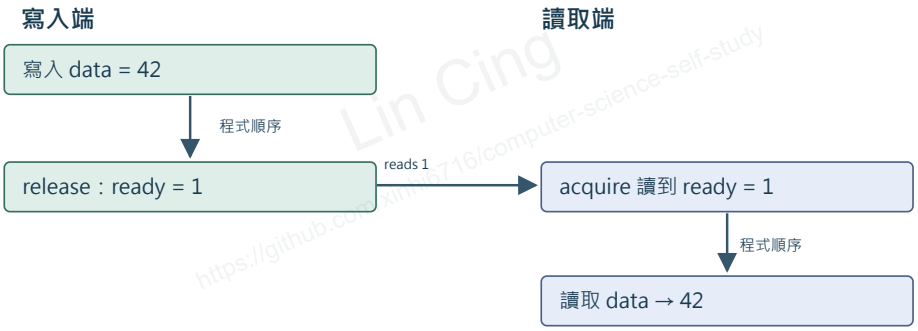
同步與訊息傳遞

Shared-memory synchronization

同步必須同時處理三件事：

1. **Atomicity**：read-modify-write 不可被拆成其他人可觀察的中間狀態。
2. **Ordering**：哪些 memory operations 必須排在另一個 operation 前後。
3. **Visibility**：建立 ordering 後，consumer 讀到 producer 寫入的值。

Coherence 只保證同一位置的 cached copies 與 write serialization。跨不同位置的 publication 仍需要 memory consistency model 所定義的 synchronization。



happens-before：寫入 data 先於讀取 data

至少一方非 atomic 的衝突存取未被排序，才構成 data race

同步與訊息傳遞 （續）

Publication worked example

```
int data = 0;                 // shared object
atomic_int ready = 0;

// Writer
data = 42;
atomic_store_explicit(&ready, 1, memory_order_release);

// Reader
while (!atomic_load_explicit(&ready, memory_order_acquire))
    yield();
int observed = data;
```

當 reader 的 acquire load **實際讀到** writer 的 release store 所寫入的 `1` 時，release 與 acquire 建立 synchronizes-with，再透過 program order 建立跨 thread happens-before。`data=42` 必須先於 `data` load 可見，所以 `observed=42`。

作為可合法討論讀值的錯誤版本，改令 `data` 與 `ready` 都是 atomic，兩者的 store/load 全採 `memory_order_relaxed`。Writer 依序寫 data=42、ready=1；reader 讀到 ready=1 後仍可讀到 data=0，因為不同 atomic objects 之間沒有 synchronizes-with，coherence 只約束各自的 modification order。若兩者改成 plain non-atomic 且沒有其他同步，則形成 C/C++ data race、行為未定義；此時不能宣稱只會得到0或42。

同步只排除它涵蓋的衝突 accesses。若程式另有第三個 thread 在 lock 外修改同一資料，該 race 不會被修好。`atomic` 也不自動讓多個位置的 transaction 原子化。

同步與訊息傳遞 （續）

Spinlock 以 atomic read-modify-write 嘗試取得 lock；contended spin 消耗 interconnect 與 power。Blocking mutex 將 waiting thread 交給 OS，代價是 context switch。Barrier 要所有 participating threads 到達後才釋放；tree barrier 以 $O(\log P)$ 深度換取較小 fan-out，但節點同步與喚醒成本仍存在。

7.4 Clusters 與 message passing

Cluster 由多台 commodity nodes 透過 network 連接，每個 node 有自己的 OS 與 physical address space。Communication 由 explicit send/receive 或 RPC/queue 完成，不使用 ordinary shared load/store。

Message passing 讓 sender/receiver ordering 較明確，但需要 serialize data、copy 到 network buffer、route、receive 與 possibly ACK。Failure isolation 較好，recovery 仍要 application framework。

MPP（massively parallel processor）類歷史上使用 specialized network；modern clusters 以 commodity switch 與 software stack 為主，取決於 latency/bandwidth/price。

Cluster 不是免費的 shared memory；distributed shared-memory layer 也建立在 message passing 之上。

7.5 Hardware multithreading

Hardware thread 是 CPU 可快速切換的 execution state，分開 PC、register file 與一些 control state；functional units、caches 與 memory 可以共享。它是處理 memory/instruction latency 的 microarchitecture 方法。

Fine-grained multithreading 每 cycle 輪流選 thread，ready thread 也可能被別 thread 分享 issue slots；適合隱藏長短 stalls，但單 thread latency 可能增加。

Coarse-grained multithreading 在 long stall 時才切換 thread；單 thread normal execution 較少被打斷，但可能無法隱藏短 dependency。

Simultaneous multithreading（SMT）在同 cycle 的 superscalar issue slots 中混合多 threads，對 ILP 不足有幫助；代價是 register storage、scheduler、cache pressure。

每個 core 執行兩個 threads 不代表 throughput 加倍；實際結果取決於 issue width、cache 與 workload。

7.6 SISD、MIMD、SIMD、SPMD 與 vector

SISD 是一個 instruction stream 作用於一個 data stream；MIMD 是多 processors 各有 independent instruction/data streams。SIMD 讓 one instruction 同時處理多個 data elements；SPMD 是 programming model，由多個 threads 執行同一 program、不同 data。

SPMD 可在 MIMD cluster 或 SIMT GPU 上實作。SPMD 不是固定硬體 classification，不能和 SIMD 當成同一層概念。

SIMD 擴充適合 regular contiguous data：array add、image filter、packed integer。Control flow 複雜或 data dependencies 不規則時，lane utilization 下降。

先列 software model 與 hardware execution model，再談 classification。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Vector architecture

Vector ISA 使用 vector registers 與 vector length。對 L 個 elements，一條 vector instruction 描述整個 vector operation；硬體以 lanes、chaining 或 pipelining 執行。

Vector code 通常用 vector length 表示 semantic，讓編譯器與硬體處理 tails 和不同 hardware widths。Multimedia SIMD 常固定 128/256 bits，software 要自行處理 padding/tail 與 narrower hardware。

令每個element做k operations，硬體有L lanes且每lane每cycle可完成一個element，frequency為f cycles/s、有效利用率為η。此模型的throughput為

$$\mathrm{OP/s} = kLf\eta$$

此處完成一個 element 包含其全部 k 次操作。若每 lane 每 cycle 僅做一次基本操作且 k 次操作無法重疊，initiation interval 至少為 k；不能再將每 cycle 的吞吐乘 k。

量綱為operations/element × lanes × elements/(lane • cycle) × cycles/s。若每lane initiation interval是q cycles/element，則再除以q。另一個等價描述是每條vector instruction處理W elements、每cycle可啟動r條，則上限為$kWrf$；vector length W不是physical lane數，兩者不可重複相乘。

Vector 的增益來自 amortize control/fetch 與 regular lane usage，不是 lane 數必然等於 real speedup。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

7.7 GPU 的定位

GPU 有大量較 simple cores、高 memory bandwidth 與 many warps。CPU 偏向少量 latency-sensitive threads；GPU 以 massive multithreading 隱藏 memory latency，適合 high arithmetic/data parallelism。

GPU 的效能來自 throughput，而非 single-thread latency。Host-device transfer、kernel launch、divergence、coalescing 與 occupancy 都會影響 end-to-end time。

本節只建立比較框架；SIMT warp、CUDA memory spaces 與應用 mapping 在 Appendix A 展開。

不要把「GPU core 數量較多」直接解讀為單一 scalar program 較快。

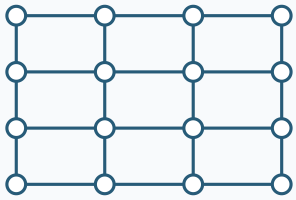
Lin Cing
https://github.com/xinhi6716/computer-science-self-study

7.8 Multiprocessor network topologies

把 network 寫成 graph $G = (V, E)$。Node 可代表 processor-memory endpoint，link 可有 bandwidth 與 hop latency。以下都把 full-duplex physical link 計為一條 edge；若報 bisection bandwidth，必須先說每次 link 是只計單向頻寬或雙向加總。

7.8(a) 4×4 mesh

4×4 mesh：24 條 local links，無 wrap



Mesh 指標

horizontal = 4×(4−1) = 12
vertical = 4×(4−1) = 12
edges = 24；average degree = 48/16 = 3
corners degree 2；interior degree 4
diameter = (4−1)+(4−1) = 6
bisection links = 4

沒有第 4 欄→第 0 欄或第 4 列→第 0 列的 link，所以不是 torus。

四列各有 $4 - 1 = 3$ 條 horizontal links，合計 12；四欄各有 $4 - 1 = 3$ 條 vertical links，合計 12：

$$|E_{\text{mesh}}| = 12 + 12 = 24.$$

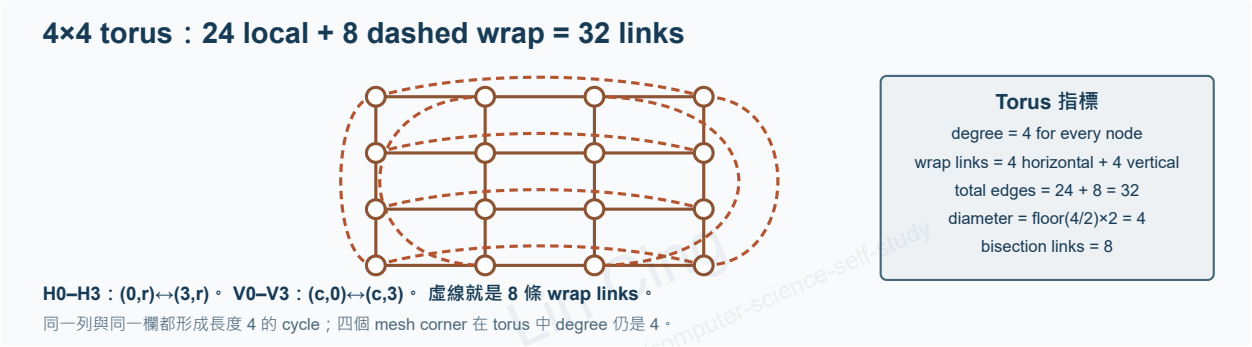
Degree 總和是 $2|E| = 48$，所以平均 degree 是 $48/16 = 3$。角落 degree=2、邊上 degree=3、內部 degree=4。任兩點最遠需水平 3 hops 加垂直 3 hops：

$$D_{\text{mesh}} = 3 + 3 = 6.$$

7.8 Multiprocessor network topologies （續）

把四欄切成左 2 欄與右 2 欄時，跨越切面的只有 4 條 horizontal links；其他 balanced cuts 不會更少，因此 bisection links=4。

7.8(b) 4×4 torus



Torus 保留 mesh 的 24 條 local links，再把每一列的右端連回左端（4 條），並把每一欄的下端連回上端（4 條）：

$$|E_{\text{torus}}| = 24 + 4 + 4 = 32.$$

每個 node 都有左右上下四條 links，所以 degree=4。任兩 node 在每一維最多繞行 $\lfloor 4/2 \rfloor = 2$ hops：

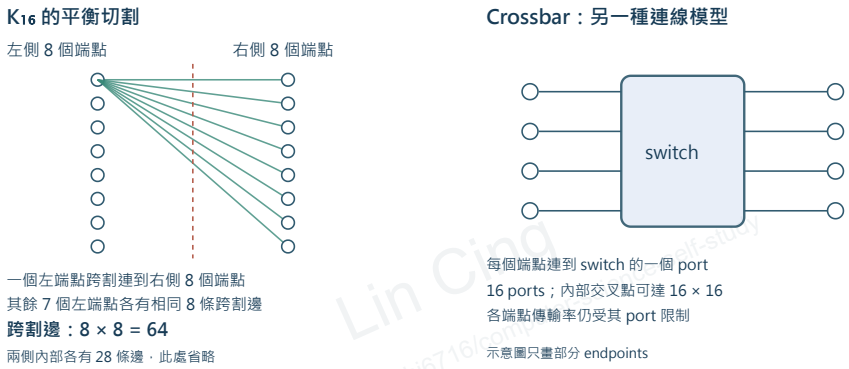
$$D_{\text{torus}} = 2 + 2 = 4.$$

把 columns 0–1 與 columns 2–3 分開，跨切面是 4 條 local horizontal links 加上 4 條 wrap links，共 8。程式對全部 balanced cuts 取最小，得到 bisection links=8。

7.8 Multiprocessor network topologies （續）

圖中的虛線不是裝飾：$H0$–$H3$ 是四列各自的 $(0, r) \leftrightarrow (3, r)$，$V0$–$V3$ 是四欄各自的 $(c, 0) \leftrightarrow (c, 3)$。少了這 8 條，圖就只是 mesh，degree 與 diameter 都不再符合 torus。

7.8(c) K16 與 crossbar 的模型差異



K_{16} 是完全圖：

$$|E| = \frac{16(15)}{2} = 120, \quad \deg(v) = 15, \quad D = 1.$$

任一 balanced cut 有 $8 \times 8 = 64$ 條跨越 links；若 link 的單向頻寬是 b，單向 cut capacity 是 $64b$。

Central crossbar 不是 K_{16}。N-port crossbar 的 endpoint 通常各接一個 switch port，內部有 $O(N^2)$ crosspoints；它的 endpoint degree、線路長度、仲裁成本與 cut bandwidth 必須用 switch 模型另算。

7.9 Multiprocessor benchmarks

Total network bandwidth 是「每條 link 頻寬 × link 數」的上界；bisection bandwidth 則取所有 balanced cuts 的最小 cut bandwidth，較接近 worst-case pattern。兩者都不足以單獨預測 application latency；hotspot、routing、message size 與 flow control 都會改變結果。

Parallel benchmark 要固定程式、data set、validation、compiler flags 與 processor count。Weak scaling benchmark 可讓 problem size grow，但要記錄 growth rule。

Linpack 是 dense linear algebra 與弱 scaling 常見例；SPECrate 適合 independent job throughput；SPLASH 類 benchmark 研究 shared-memory application patterns。

Peak performance 與 measured application performance 常不同。Memory bandwidth、load imbalance、communication 與 synchronization 可能占主要時間。

對 parallel systems 要看 per-core efficiency、scaling curve、tail latency、energy 與 fault tolerance，不只 single FLOPS。

7.10 Roofline 的推導與數值工作點

令某 kernel 一個 phase 執行 F 次 floating-point operations，跨 memory 介面實際搬移 Q bytes。Arithmetic intensity 定義為

$$I = \frac{F}{Q} \quad (\text{FLOP/byte}).$$

若 compute 的 sustained peak 是 P_C，該 memory 介面的持續 bandwidth 是 B，同一 phase 的 compute 與 memory times 分別是

$$T_{\text{compute}} = \frac{F}{P_C}, \qquad T_{\text{memory}} = \frac{Q}{B} = \frac{F}{IB}.$$

若 compute 與 traffic 可以完全重疊，elapsed time 不可能小於兩者的最大值：

$$T \geq \max\left(\frac{F}{P_C}, \frac{Q}{B}\right),$$

所以 throughput 上界為

$$P \leq \frac{F}{T} \leq \min(P_C, IB).$$

令 $IB = P_C$ 可求兩條 roof 的折點：

$$I_{\text{ridge}} = \frac{P_C}{B} \quad (\text{FLOP/byte}).$$

$I < I_{\text{ridge}}$ 時，模型中的頻寬上界較緊；$I > I_{\text{ridge}}$ 時，計算上界較緊。這只是 roofline 的界線，實際瓶頸仍需量測 dependencies、instruction mix、load imbalance 與 memory transaction efficiency。

7.10 Roofline 的推導與數值工作點 （續）

單層工作點

取 $P_C = 100$ GFLOP/s、$B = 50$ GB/s，ridge 是

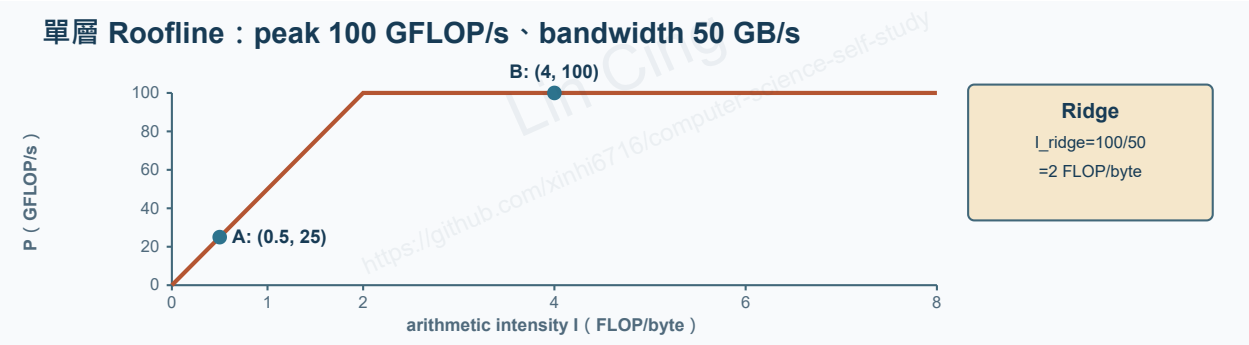
$$I_{\text{ridge}} = 100/50 = 2.$$

Kernel A：$I = 0.5$，memory roof $IB = 25$，compute roof 100：

$$P_A \le \min(100, 25) = 25 \text{ GFLOP/s}.$$

Kernel B：$I = 4$，memory roof $IB = 200$，但 compute cap 100：

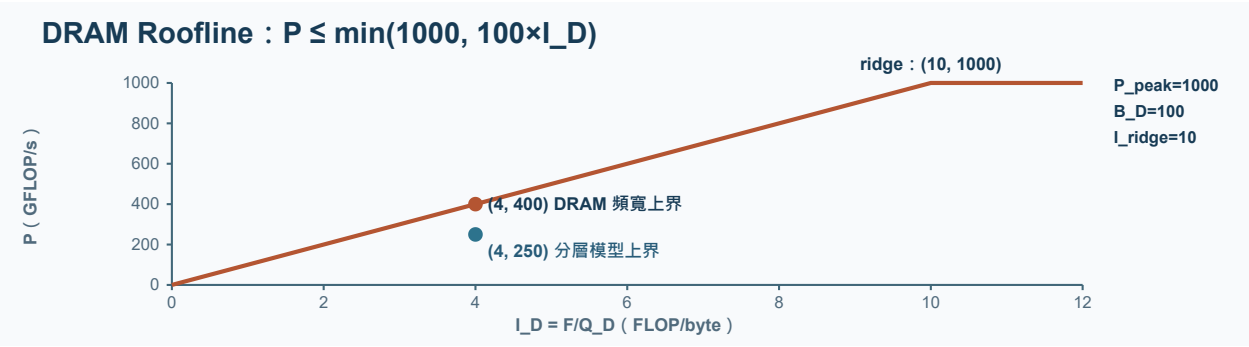
$$P_B \le \min(100, 200) = 100 \text{ GFLOP/s}.$$



階層 Roofline 的同一組數字

固定一階段 $F = 10^9$ FLOPs、$P_C = 1000$ GFLOP/s。DRAM 的 $Q_D = 0.25 \times 10^9$ bytes、$B_D = 100$ GB/s；shared memory 的 $Q_S = 4 \times 10^9$ bytes、$B_S = 1000$ GB/s。

7.10 Roofline 的推導與數值工作點 （續）

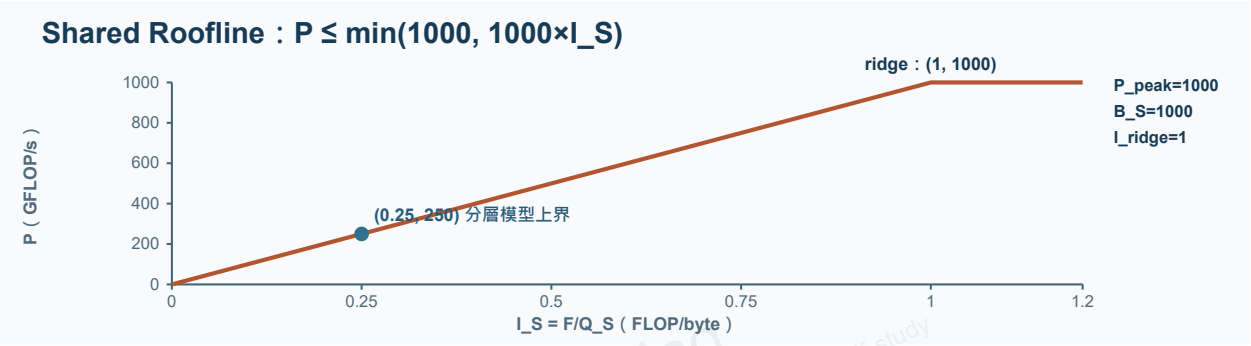


DRAM 層：

$$I_D = \frac{10^9}{0.25 \times 10^9} = 4, \qquad \min(1000, 100 \cdot 4) = 400 \text{ GFLOP/s}.$$

7.10 Roofline 的推導與數值工作點 （續）

shared 層：



$$I_S = \frac{10^9}{4 \times 10^9} = 0.25, \qquad \min(1000, 1000 \cdot 0.25) = 250 \text{ GFLOP/s}.$$

把三層限制合併：

$$P \le \min(1000, 400, 250) = 250 \text{ GFLOP/s}.$$

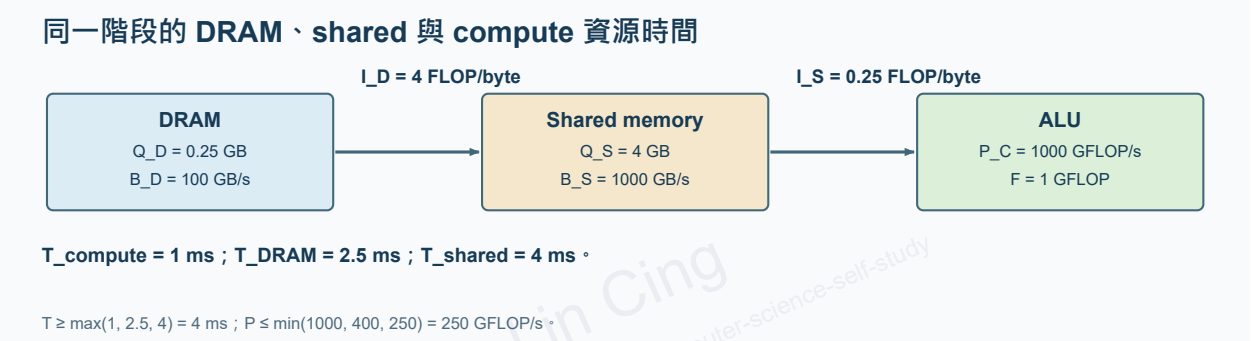
或等價地比較時間：

$$T \ge \max\left(\frac{10^9}{10^{12}}, \frac{0.25 \times 10^9}{100 \times 10^9}, \frac{4 \times 10^9}{1000 \times 10^9}\right) = \max(0.001, 0.0025, 0.004) = 0.004 \text{ s}.$$

也就是 time lower bound 是 4 ms。

7.10 Roofline 的推導與數值工作點 （續）

因此在這個明定模型中，DRAM 的工作點是 $(4, 400)$，但 shared 層把跨層上界壓到 $(4, 250)$。250 是模型上界，不是 measured performance；shared roof 本身仍以 1000 GFLOP/s 為 plateau，不能把 250 誤畫成整個 plateau。



若資料已被 cache 命中，就必須用該 cache 介面的 bytes 與 bandwidth 重算，不能把 DRAM 的 Q_D 和 cache bandwidth 混用。多層 roof 的圖可以分開畫，但最終 bound 要取同一 phase 各資源的最小值。

平行系統的比較與整理

7.11 實際多核心系統比較

固定同一 kernel 與資料流量，假設 arithmetic intensity 為 1 FLOP/byte：系統 A 的 peak 為 1000 GFLOP/s、頻寬 100 GB/s；系統 B 分別為 500 GFLOP/s、200 GB/s。Roofline 上限各為 min(1000,100×1)=100 與 min(500,200×1)=200 GFLOP/s。

假設實測 A=80、B=90 GFLOP/s，兩者達到各自上限的 80% 與 45%；B 的上限雖高一倍，實際只快 90/80=1.125 倍。這組數字是模型範例，不能當成實機 benchmark。

Sparse matrix 的 indirect access 與 structured grid 的 stencil access 具有不同 locality；即使 intensity 相近，pipeline、coalescing 與 compiler quality 也可能影響測量。比較時必須固定工作負載、正確性、計時範圍與傳輸介面。

7.12 Parallel fallacies

「Amdahl's law 不適用」常源於拿 weak scaling 去反駁 strong-scaling claim；fixed-work model 沒有規定無限 speedup forever。

「peak FLOPS 決定最快系統」忽略 memory bound、load imbalance、communication 與 software stack。

「more threads 必然更快」忽略 synchronization, oversubscription, cache thrashing 與 power。

「coherent shared memory 讓 race-free」不成立；data races 仍需要 synchronization 與 memory model。

平行系統的比較與整理 （續）

前述80/20不等成本例否定「operation share等於time share」；單一worker分到5%的例把100核speedup壓到19.63；publication trace則指出coherence無法替代跨位置同步。這些都是明定模型的反例，不冒充實機量測。

7.13 Concluding remarks

Parallel hardware 提供 resources；parallel software 把它們轉成具體 speedup。Strong/weak scaling、load balance、communication、synchronization、coherence 與 benchmark 設計共同決定結果。

Shared-memory 與 message-passing 是 different address-space models。Multithreading、SIMD、GPU 與 clusters 各以不同成本隱藏 latency 或增加 throughput。

Roofline 比較 compute roof 與 memory roof，指出模型中較緊的上界；實際瓶頸還可能是相依性或指令吞吐。它只給 upper bound，實測仍需 performance counter 與 end-to-end benchmark。

若 DRAM roof 是最低上限，且工作集、資料流量與其他限制固定，提高 compute peak 不會提高該上限。可用相同完整工作階段的 DRAM bytes、持續 bandwidth 與執行時間檢查此預測；若資料重用改變，須先重算 intensity。

平行系統的比較與整理 （續）

章末驗收

應能：

1. 給定 parallel fraction、worker count 與 overhead，計算 speedup/efficiency。
2. 分開 strong/weak scaling 的 problem-size 假設與 conclusion。
3. 說明 SMP、NUMA、cluster 的 address space 與 communication cost。
4. 比較 fine/coarse multithreading 與 SMT 的 stall hiding。
5. 計算 mesh 的 degree、diameter、bisection links。
6. 從 peak FLOPS、DRAM bandwidth 與 arithmetic intensity 判定 roofline bound。

先完成本章獨立練習題 PDF，再由詳解 PDF 檢查假設與推導。

7.14 平行架構的歷史視角

向量處理器用少量vector instructions描述大量規則運算，攤薄fetch與控制成本；shared-memory multiprocessors讓既有load/store程式模型延伸到多個processors，但需coherence及同步。Clusters以獨立節點和明確訊息傳遞換取可擴充資源與失效邊界，通信成本則直接進入演算法設計。

晶片整合增加後，multicore、SMT與GPU分別利用task、thread與data parallelism。它們沒有消除serial critical path，也沒有讓所有通信變成本地。比較歷史設計時應固定問題規模、數值驗證、記憶體容量、通信模式及power budget，才能分辨技術進步與工作負載改變。

平行系統的比較與整理 （續）

完全連接graph與crossbar不同。K16每個endpoint連15條直接links，balanced cut有8×8=64條links；16-port crossbar通常每endpoint只連一個switch port，內部有$O(N^2)$crosspoints，其吞吐還受endpoint port rate限制，不能把兩者degree與cut-link數混成同一表。

參考資料

Patterson 與 Hennessy，*Computer Organization and Design: The Hardware/Software Interface*，Revised Fourth Edition，7.2、7.8–7.10，印刷頁 635–674（PDF 頁 662–701）。

Williams、Waterman 與 Patterson，〈Roofline: An Insightful Visual Performance Model for Multicore Architectures〉，*Communications of the ACM* 52(4), 2009，DOI。

分層流量定義另參照 NERSC Roofline 文件；每個層級以該介面的 bytes 計算自己的 intensity。本文數字是明定模型的代入與推導。

參考資料與署名

David A. Patterson、John L. Hennessy，Computer Organization and Design，Revised Fourth Edition，第 7 章。Lin Cing，《計算機組織》手寫筆記；計算機組織與結構（CSO）課程投影片。

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study

A.1 大量平行工作如何對應到 GPU

GPU 使用大量執行單元與高記憶體頻寬處理許多相似工作；CPU 則通常在複雜控制與單一工作的低延遲上投入更多資源。這並不代表每個 GPU 執行緒都比 CPU 執行緒快：資料量太小時，啟動與傳輸成本可能抵消計算收益。

圖形處理與通用運算共用可程式化處理器；圖形管線還有光柵化、紋理取樣與輸出合成等專用功能。應用程式看到的管線階段，不一定各有一批專屬的實體 SM 核心。

本附錄以 CUDA 與 Tesla 的歷史架構建立背景；32-byte sector、32-bank 和 occupancy 算例則各自明列抽象假設，不能合併當成 GeForce 8800 的硬體規格。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

圖形管線與插值

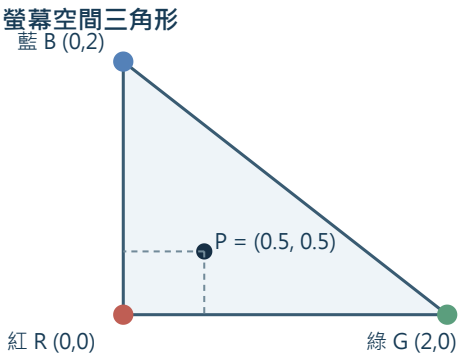
頂點著色器產生頂點位置與屬性；三角形經裁切與光柵化後形成片段（fragment），再由片段著色器計算顏色，並依深度、模板與混色規則更新畫面。片段可能因深度測試失敗而不成為最終可見的像素。

螢幕上的三角形頂點為 (0,0)、(2,0)、(0,2)，且三個頂點的 clip-space w 都是 1。點 (0.5,0.5) 的重心權重為 (1/2,1/4,1/4)；若三個頂點分別是純紅、綠、藍，插值結果為 (0.5,0.25,0.25)。

若頂點的 w 不同，須先以 $(\lambda_i/w_i)/\sum_j(\lambda_j/w_j)$ 計算透視校正後的屬性權重。紋理濾波可能讀取多個鄰近 texels；輸出合成也可能讀取既有的顏色或深度，因此流量不只有最後一次寫入。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

用頂點權重計算插值



P = ½R + ¼G + ¼B

權重和 = 1，均非負 → P 在三角形內

假設各頂點 clip w = 1

插值色 (R,G,B) = (0.5, 0.25, 0.25)

點的座標滿足 $P = \frac{1}{2}(0,0) + \frac{1}{4}(2,0) + \frac{1}{4}(0,2) = (0.5, 0.5)$。權重和為 1 且皆非負，因此 P 位於三角形內。三個頂點的純紅、綠、藍屬性以相同權重相加，得到 $(0.5, 0.25, 0.25)$。此例三個 clip w 相同。若沿用螢幕權重而改取 $w = (1, 2, 4)$，校正前權重為 $(1/2, 1/8, 1/16)$，總和 $11/16$；正規化後為 $(8/11, 2/11, 1/11)$。以原螢幕權重直接插值，會得到不同結果。

A.2 主機、裝置與端到端成本

獨立 GPU 透過 I/O 連線與主機相接，並有自己的裝置記憶體；驅動程式管理命令、映射與完成通知。整合式 GPU 或共享記憶體設計可能減少複製，但仍要考慮資料可見性與共享頻寬。統一位址不代表資料移動完全沒有成本。

假設各階段依序執行，資料複製與計算不重疊：輸入和輸出各 64 MiB，連線每方向有效頻寬為 8 GB/s，啟動需 20 µs，kernel 執行需 2 ms。兩次傳輸合計

$$2 \times 64 \times 2^{20} / (8 \times 10^{9}) = 16.777216 \text{ ms}.$$

加上啟動與計算，總時間為 18.797216 ms。若 CPU 完成同一工作需 25 ms，端到端加速比約為 1.330；只比較 25/2=12.5 會漏掉傳輸與啟動。若資料留在裝置上連續執行 10 次相同 kernel，只需一次輸入與輸出，總時間為 36.977216 ms；能否這樣攤提取決於實際資料依賴與使用情境。

A.3 Grid、block 與 thread 的索引

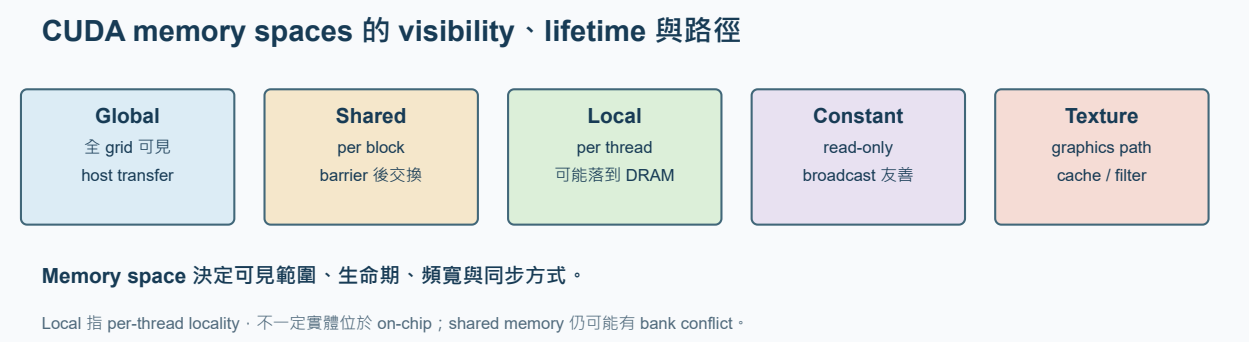
一維kernel以 $i = blockIdx.x \cdot blockDim.x + threadIdx.x$ 對應輸出。N=1000、block=256需ceil(1000/256)=4 blocks；前三個處理0–767，最後block的threads0–231處理768–999，其餘24個不得訪問越界資料。

```
i = block_id * B + thread_id
if i < N:
    y[i] = f(x[i])
```

每個有效i唯一對應(⌊i/B⌋, i mod B)，所以覆蓋所有輸出且不重複寫。這段可直接跳過無效threads，因為沒有block barrier。若後續有共同barrier，不能照抄early return，必須讓需參與的threads一致到達。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Memory space 的 visibility 與 lifetime



Registers與local memory都是per-thread private，但local通常位於device DRAM，例如register spill或可動態索引的private array。Shared memory是per-block scratchpad，block結束後生命期結束。Global memory可跨blocks使用，但資料可見性需同步規則。

Constant memory是device程式讀取的常數空間；同一warp讀相同位址可利用broadcast。Texture path提供特定格式、filtering與cache語意，不等於任意load都自動有相同性能。空間名稱描述程式模型，不單獨保證實體延遲。

Barrier 不只是等待計時器

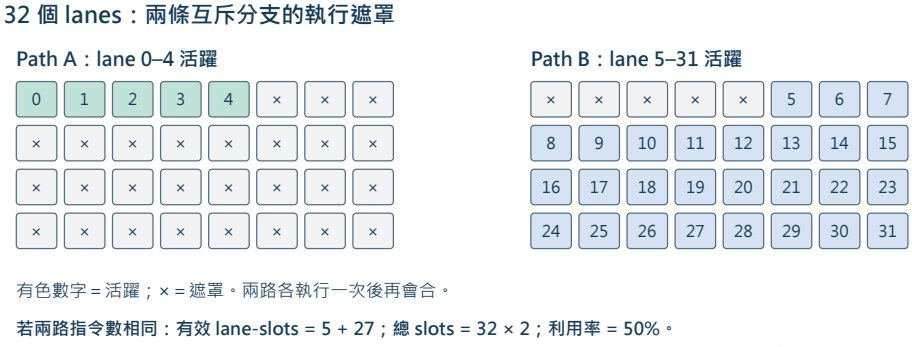
Block barrier要求參與群組按規格到達，並建立對應記憶體操作的可見性。它不能替代跨block的全域同步，也不能假設「warp內看起來同時執行」就不需規格要求的同步。

對N不是block size倍數的tile，正確形式是所有threads先以predicate載入有效值或identity，全部到barrier，只有有效輸出thread計算，然後再次全部到barrier。第二次barrier防止快thread覆寫shared tile，而慢thread仍在讀上一輪。

不同blocks的執行順序與同時resident數不保證。若resident block spin等尚未排入的block，可能占滿所有資源而永遠無法前進；多kernel phases用前一kernel完成作全域邊界，比無條件跨block忙等更容易建立正確性。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

A.4 SM、warp 與 scoreboard



Warp是共同issue的一組threads，threads保有自己的register與logical狀態。歷史Tesla例warp32 threads、8個SP cores，以4個core cycles服務一個warp的32 lanes；這是吞吐寬度，不代表所有指令的result latency都是4 cycles。

Scoreboard追蹤operand相依，scheduler只issue已ready的warp。某warp等待memory或相依結果時，可選另一個ready warp。Resident warps只是已配置資源的集合；若全部都在等barrier或同一memory事件，occupancy高仍可能無指令可issue。

PTX是virtual ISA，還需對目標架構編譯/JIT成實際machine code。PTX一條指令不必等於一個cycle或一條相同長度的SASS，故性能分析需分清模型層級。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Latency hiding 的有限模型

假設每4 cycles可issue一個warp instruction，每個warp只有一條長度32 cycles的dependent chain，無其他瓶頸。Round-robin選8個ready warps時，同warp相隔8×4=32 cycles，剛好可等前一結果；只有4個warps則相隔16 cycles，還需等16 cycles。

若依賴延遲增加到400 cycles，這個「每warp僅一個outstanding依賴」模型需要100個warps才能完全遮蔽，可能超過硬體容量。增加ILP、同時發出多個獨立load、改善cache與memory並行度，會改變所需warps數；不能只靠把occupancy填滿保證無stall。

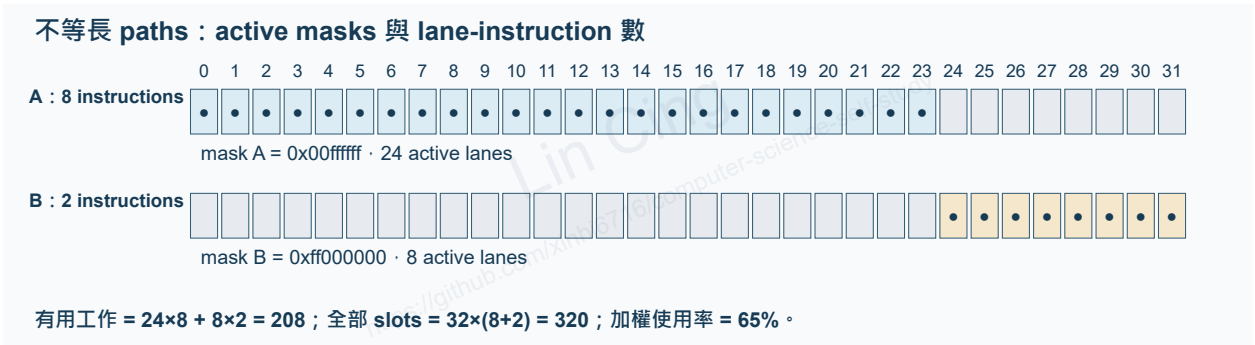
Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Divergence 的加權 lane-slot 計算

兩個互斥paths各有a、b個active lanes，a+b=W；path長度LA、LB指令。忽略branch與reconvergence額外成本，若兩條皆需執行，

$$\eta = \frac{aL_A + bL_B}{W(L_A + L_B)}.$$

只有LA=LB時才可簡化成1/2。取W=32、a=24、b=8、LA=8、LB=2，有效lane-instructions=24×8+8×2=208，issue capacity=32×10=320，所以η=65%。這是指令lane使用率，不直接等於整個kernel speedup或DRAM效率。



若某path完全無active lane，就不需執行該path，分母不能仍無條件加其指令數。Predication也需issue受predicate控制的指令，inactive memory操作是否形成transaction須依ISA語意，不能把false lane當成一定讀取DRAM。

Occupancy 是資源限制的整數問題

採抽象SM上限768 threads、24 warps、8 blocks、32768個32-bit registers、48 KiB shared memory，warp32。忽略allocation granularity。每block256 threads、每thread32 registers、每block16 KiB shared。

$$blocks \le \min\left(\left\lfloor \frac{768}{256} \right\rfloor, 8, \left\lfloor \frac{32768}{256 \times 32} \right\rfloor, \left\lfloor \frac{48}{16} \right\rfloor\right) = 3.$$

Active warps=3×8=24，occupancy100%。若block改128但shared仍16 KiB，shared只允許3 blocks，active warps12，occupancy50%。若shared也降8 KiB，可放6 blocks，回到24 warps。若原256-thread版register提高到64/thread，則register只允許2 blocks，occupancy16/24=2/3。

這些是resident上界，非實測利用率。Register減少若引起spill，可能增加DRAM流量，使較高occupancy反而更慢。

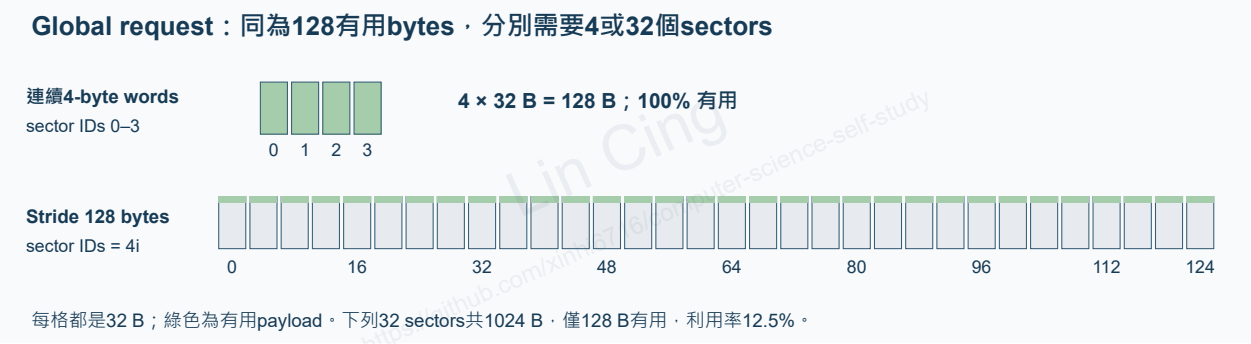
Lin Cing
https://github.com/xinhi6716/computer-science-self-study

A.5 Coalescing 的可重算交易模型

本節另採32-byte sector、32 lanes、每lane一個4-byte aligned word，只計一次warp request觸及的不同sectors，忽略cache命中與跨層合併；不是GeForce 8800的完整coalescing規則。

對byte address ai，需要sector集合 $\{\lfloor a_i/32 \rfloor\}$。連續words且base32-byte aligned時，128 bytes恰占4 sectors；base偏4 bytes時占5 sectors，讀取160 bytes但有用128，利用率80%。

Stride32 bytes或128 bytes時，每lane落在不同sector，都是32 sectors、1024 bytes，有用128 bytes，利用率12.5%；不同stride雖sector數相同，channel/row locality仍可不同。

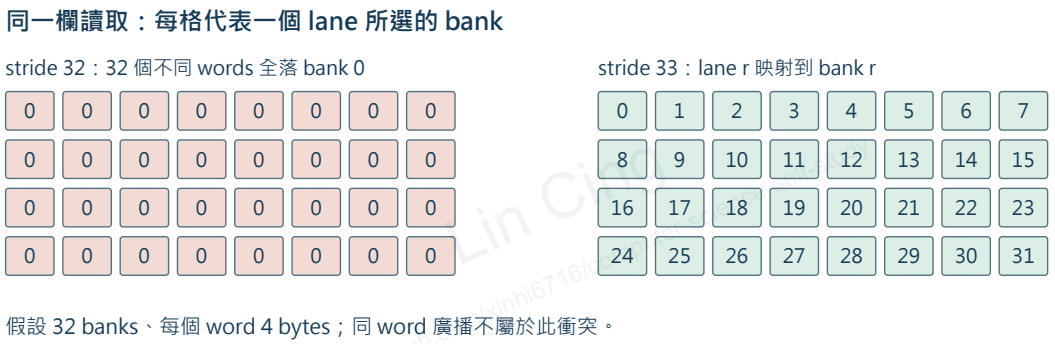


若全部lanes讀同一word，unique requested bytes只有4，可能由一個sector供應再broadcast；不能把32次邏輯使用誤算成128個不同payload bytes。

Shared banks、broadcast 與 padding

採32個banks，每bank word4 bytes，bank=word index mod32。同一request內不同banks可並行；同bank不同word需多次服務。本模型對同一word的多lane read可broadcast，不把它當成不同word的衝突。

32×32 row-major array，column c=0的lane r讀index=32r，32個不同words都在bank0，形成32-way conflict。改成leading dimension33，index=33r，bank=r，分散到32個banks。



Padding把shared用量由4096增至4224 bytes，可能使每SM可容納的blocks數跨過整數門檻。歷史Tesla用16-bank/half-warp服務規則，應以16個同時requests重算；不能把本節32-way結果直接標成該晶片實測。

A.6 浮點運算的次序也是模型

IEEE binary32有24-bit有效精度。取a=1+2^−23、b=1−2^−23、c=−1，三者可表示。精確ab=1−2^−46，若先捨入binary32 product，得到1，再加c得0。

若採一次捨入的IEEE FMA，先在精確乘加層計算ab+c=−2^−46，再捨入；此值可精確表示，所以結果是−2^−46，與兩次捨入不同。歷史G80 MAD不能無條件當成這種FMA，其subnormal、近似函數與例外支援也有版本限制。

Reduction改變加法樹也可能改變結果。例如binary32的(10^8+1)+(−10^8)得到0，而(10^8−10^8)+1得到1。平行演算法的整數正確性證明若依結合律，不能直接推出浮點bitwise相同；需另外指定誤差與可重現性要求。

A.7 GeForce 8800 的歷史結構

以 GeForce 8800 的歷史架構為例：8 個 TPC，每TPC兩個SM，每SM8個SP，因此8×2×8=128 SP；記憶體端有6個64-bit DRAM partitions，合計384-bit介面。SM另有shared memory、constant cache及SFU；texture與ROP負責不同資料路徑。

這個乘積是該圖的結構核對，不是今日GPU效能預測。不同世代可改變cache、warp排程、FP支援及memory transaction規則；core數相同也可能因clock、instruction mix與資料流不同而有不同throughput。SFU與ALU的peak只有在規格允許相應並行且workload真的使用時才可共同計數，不能把所有峰值直接相加。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

A.8 CSR SpMV 的矩陣與 arrays

取

$$A=\begin{bmatrix}2&0&-1&0\\0&3&0&4\\5&0&0&6\end{bmatrix},\qquad x=(1,2,3,4)^T.$$

CSR使用Ap=[0,2,4,6]、Aj=[0,2,1,3,0,3]、Av=[2,−1,3,4,5,6]。Row i的非零項位於[Ap[i],Ap[i+1])，所以y0=2・1−1・3=−1，y1=3・2+4・4=22，y2=5・1+6・4=29。

Ap長度rows+1，最後值等於nnz；Aj皆在[0,columns)。矩陣可為非方形，不能把rows當作x的合法長度。本例x長4，輸出y長3。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Row-per-thread 的正確性與不均衡

```
row = block_id * B + thread_id
if row < rows:
    total = 0
    for k = Ap[row] .. Ap[row+1]-1:
        total += Av[k] * x[Aj[k]]
    y[row] = total
```

每個row只有一個writer，loop invariant是total等於本row已處理非零項的乘積和；讀完區間即得該row點積。Empty row的區間長0，輸出0。

若同warp的31個rows各1項，另一row有64項，依masked loop的簡化模型要64輪，active lane-iterations=31+64=95，capacity=32×64=2048，利用率約4.64%。Warp-per-row可把長row的entries分給lanes再reduction，但短row可能浪費更多lanes；shared cache x也只在重用超過載入/同步成本時才有利。

Inclusive 與 exclusive scan

對a=[3,1,7,0,4,1,6,3]，inclusive scan包含當前元素，結果[3,4,11,11,15,16,22,25]；exclusive scan只含之前元素，結果[0,3,4,11,11,15,16,22]。

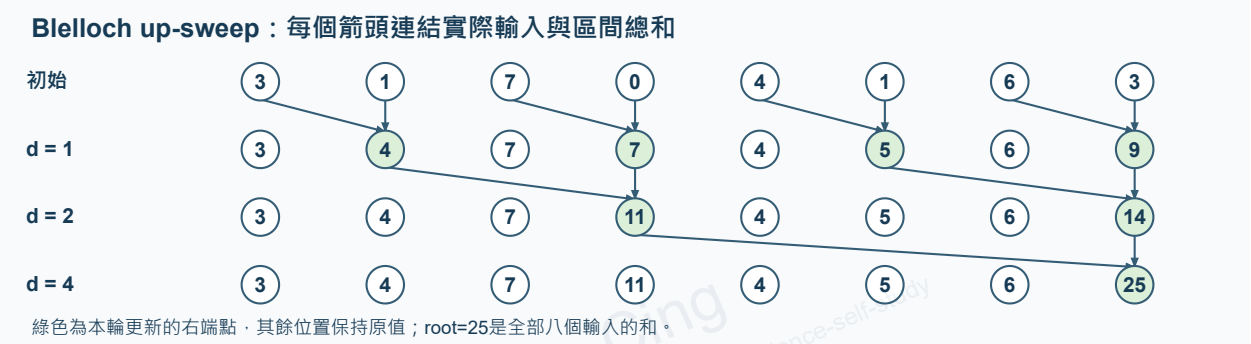
Hillis–Steele每輪從上一輪snapshot讀取i−d，d=1,2,4。實際狀態為

d	輪結束的array
初始	[3,1,7,0,4,1,6,3]
1	[3,4,8,7,4,5,7,9]
2	[3,4,11,11,12,12,11,14]
4	[3,4,11,11,15,16,22,25]

不使用snapshot或正確同步就直接原地改寫，可能讀到本輪已更新的值。此例加法數7+6+4=17；一般work Θ(n log n)，span Θ(log n)，不能只因depth小就稱work-efficient。

Work-efficient scan 的 up-sweep

Blelloch scan在完全二元樹先建立各區間總和。對n=8，d=1時把每對左值加到右端；d=2時合併兩對；d=4時得到整體總和。



合併距離d	更新後array
1	[3,4,7,7,4,5,6,9]
2	[3,4,7,11,4,5,6,14]
4	[3,4,7,11,4,5,6,25]

每個internal node恰算兩個互不相交子區間之和，依樹高歸納得到該node的區間總和；共n−1次加法，depth log2 n。

Down-sweep 傳遞區間之前的總和

將root總和25另存，再把root設0。若parent持有其區間之前的prefix p，left subtree總和為t，則left child獲得p，right child獲得p+t。這兩個prefix分別恰為左右子區間之前的總和。

步驟	array
root設0	[3,4,7,11,4,5,6,0]
d=4	[3,4,7,0,4,5,6,11]
d=2	[3,0,7,4,4,11,6,16]
d=1	[0,3,4,11,11,15,16,22]

沿樹向下歸納，leaf i取得全部先前元素的和，故輸出exclusive scan。Down-sweep每internal node一次加法，共n−1；總work2(n−1)、span2log2 n，另計swap與root初始化。對非2次方n，以identity 0補到下一個2次方；n=0直接回傳空輸出。

可重建的 shared-memory scan 偽碼

以下n為2次方，所有參與threads執行相同輪數；每輪互不重疊的k可平行。

```
for d = 1, 2, 4, ..., n/2:
    parallel for k = 0, 2*d, 4*d, ...:
        x[k+2*d-1] += x[k+d-1]
    block_barrier()
if thread_id == 0:
    total = x[n-1]
    x[n-1] = 0
block_barrier()
for d = n/2, ..., 2, 1:
    parallel for k = 0, 2*d, 4*d, ...:
        t = x[k+d-1]
        p = x[k+2*d-1]
        x[k+d-1] = p
        x[k+2*d-1] = p + t
    block_barrier()
```

`total`只需一個指定thread保存，再依需要發布。這個原地scan不需要double buffer；Hillis–Steele的snapshot需求與此演算法不同，不能混用其同步規則。

多 blocks 的 scan 與全域邊界

N=10、每block4個數，輸入[3,1,7,0,4,1,6,3,2,5]。各block補0做local exclusive scan，block sums為[11,14,7]；對block sums再做exclusive scan得offsets[0,11,25]。

各local結果加自己的offset後，完整輸出為[0,3,4,11,11,15,16,22,25,27]，總和32。Phases依序為local scan與sums、scan sums、加offset；sums很多時可遞迴分層。Kernel邊界建立跨block完成順序，不要求所有blocks同時resident。

固定block size下，各層資料量形成幾何級數，所以總work O(N)；抽象平行模型的tree span為O(log N)，實際時間還含每層launch、memory traffic與有限SM排程。

Reduction 的不變量與數值

同一個8元素array，可用stride4、2、1，把後半加到前半。每輪前半各位置代表互不重疊子集合的和，合併保持此性質，最後x0為全部總和25。

stride	本輪有效partial sums
4	[3+4,1+1,7+6,0+3]=[7,2,13,3]
2	[7+13,2+3]=[20,5]
1	[20+5]=[25]

總加法4+2+1=7。多block可先輸出block sums再reduction，或用規格支援的atomic操作合併。Atomic保證單次更新不互相遺失，不保證不同blocks的浮點相加順序固定。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Stable radix partition 的每個目的位址

採3-bit unsigned keys [7,2,5,0,3,4,1,6]。處理bit0時，定義z_i=1表示該bit為0；z=[0,1,0,1,0,1,0,1]，exclusive zero-prefix Z_i=[0,0,1,1,2,2,3,3]，總zeros Z=4。

Zero的目的位置是Z_i；one的目的位置是Z+(i−Z_i)。因此dest=[4,0,5,1,6,2,7,3]，scatter後為[2,0,4,6,7,5,3,1]。兩區內prefix都嚴格按原相對順序增加，所以partition stable、目的位置不重複，覆蓋0–7。

逐欄對照輸入位置、zero flag、先前 zero 數與目的位置：

i	0	1	2	3	4	5	6	7
key	7	2	5	0	3	4	1	6
z_i	0	1	0	1	0	1	0	1
Z_i	0	0	1	1	2	2	3	3
dest	4	0	5	1	6	2	7	3

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

LSD radix sort 的歸納與完整結果

在前一輪stable結果上處理下一個bit，實際三輪為

已處理bits	結果
bit0	[2,0,4,6,7,5,3,1]
bit0–1	[0,4,5,1,2,6,7,3]
bit0–2	[0,1,2,3,4,5,6,7]

歸納假設前b個低bits已排序。新partition按bit b分區，同區保留前一輪低bits順序，因此前b+1 bits有序。k-bit keys共k輪，每輪scan與scatter工作O(N)，總O(kN)，需可避免讀寫互相覆蓋的輸入/輸出storage。

這裡明定unsigned keys；signed或floating-point keys須先定義可保持所需順序的bit transform，不能直接把原始encoding當作相同unsigned順序。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

N-body 的 force 與 acceleration

對target i，softened acceleration為

$$\mathbf{a}_i = G \sum_{j \neq i} \frac{m_j (\mathbf{x}_j - \mathbf{x}_i)}{(\|\mathbf{x}_j - \mathbf{x}_i\|^2 + \varepsilon^2)^{3/2}}.$$

目標粒子的質量不在加速度公式的分子中；若要求力，還要乘上該粒子的質量，即 $\mathbf{F}_i = m_i \mathbf{a}_i$。軟化參數 ε 可避免極近距離的奇異行為，但也改變了物理模型。

在一維例子中，四個位置依序為 [0,1,3,4]，質量和 G 都是 1；令 ε=0，並略過粒子對自己的作用。計算得到 $a_0 = 1 + 1/9 + 1/16 = 169/144$，$a_1 = -1 + 1/4 + 1/9 = -23/36$，另外 $a_2 = 23/36$、$a_3 = -169/144$。各粒子質量相同，因此總力為 0；這也能檢查成對作用的方向。有限精度及不同累加順序仍可能造成小誤差。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

N-body tile 的資料重用與兩道 barrier

每個 block 有 B 個目標執行緒，合作把 B 個來源粒子載入 shared memory，再由每個有效的目標執行緒累加該區塊的作用。以下偽碼中的 body 包含位置與質量。

```
i = block_id * B + thread_id
my = (i < N) ? body[i] : zero_body
acc = 0
for base = 0; base < N; base += B:
    j = base + thread_id
    sh[thread_id] = (j < N) ? body[j] : zero_body
    block_barrier()
    if i < N:
        for k = 0 .. min(B,N-base)-1:
            if base+k != i:
                acc += acceleration(my, sh[k])
    block_barrier()
if i < N:
    output[i] = acc
```

第一道 barrier 確保所有來源資料載入完成；第二道防止較快的執行緒在其他人讀完之前覆寫資料。超出範圍的目標執行緒仍協助載入並參與兩道同步。每個有效目標都恰好處理每個不同於自身的有效來源一次，計算項與直接雙迴圈相同，因此仍需 $\Theta(N^2)$ 對粒子的運算。

Tile 減少哪一層流量

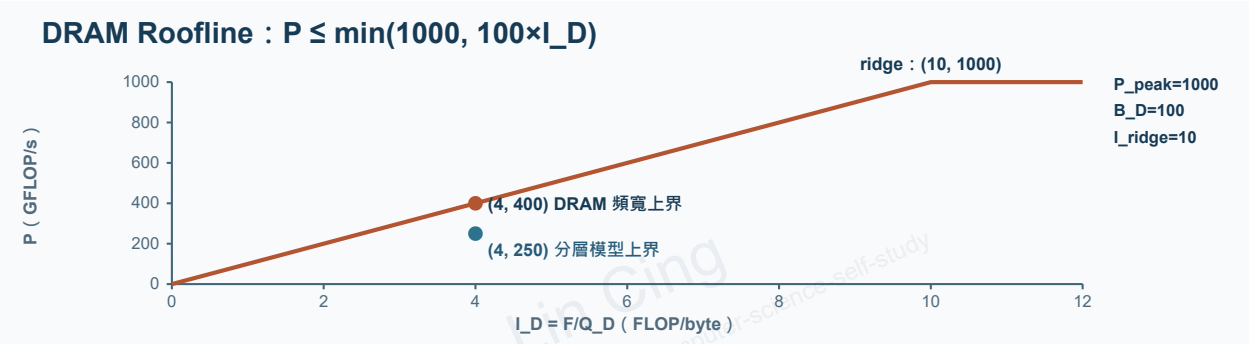
明定N為B倍數、無cache重用，naive每個target另載入一次my，並讀N個source（包括self，讀入後才跳過其計算）。Source reads=N^2；tiled有N/B個blocks，每block讀N個sources，為N^2/B。

N=4、B=2時，source reads由16減到8；另加4個my loads，總position loads由20減到12，總流量只降為原本60%，不能宣稱所有流量恰減半。若compiler/cache重用self或其他sources，或body欄位寬度不同，需按實際介面bytes重算。

Shared內每個source仍可能被B個targets讀取，因此DRAM bytes降低不等於shared bytes也以相同比例降低。下一節以每個介面自己的Q計算Roofline限制。

分層流量的限制不能混乘

固定同一 phase $F = 10^9$ FLOPs、$P_C = 1000$ GFLOP/s。DRAM 實際讀寫 $Q_D = 0.25 \times 10^9$ bytes，持續頻寬 $B_D = 100$ GB/s；shared memory 實際讀寫 $Q_S = 4 \times 10^9$ bytes，持續頻寬 $B_S = 1000$ GB/s。這些是明定模型輸入，不是某張 GPU 的實測規格。



DRAM 層的橫座標是

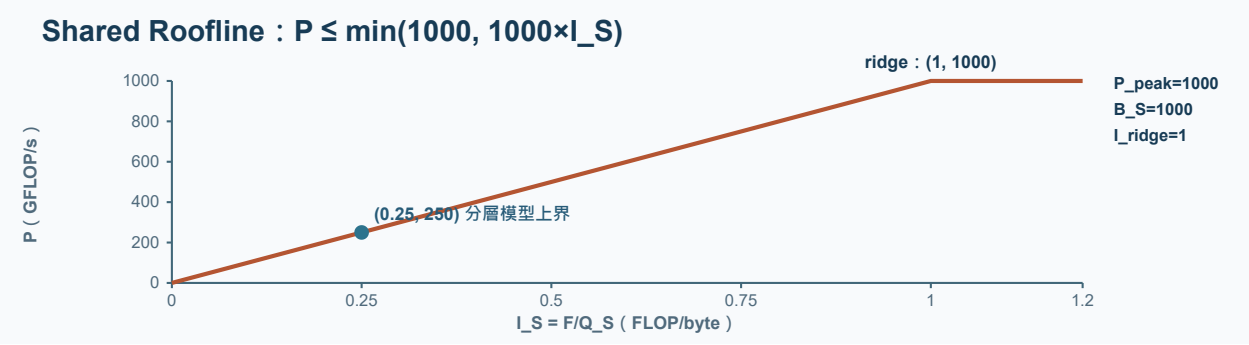
$$I_D = F/Q_D = 10^9/(0.25 \times 10^9) = 4 \ \text{FLOP/byte}.$$

其 throughput 上界為

$$\min(P_C, I_D B_D) = \min(1000, 4 \cdot 100) = 400 \ \text{GFLOP/s}.$$

DRAM roof 的折點是 $P_C/B_D = 10$；$(4, 400)$ 在斜線的 bandwidth 部分。

分層流量的限制不能混乘 （續）



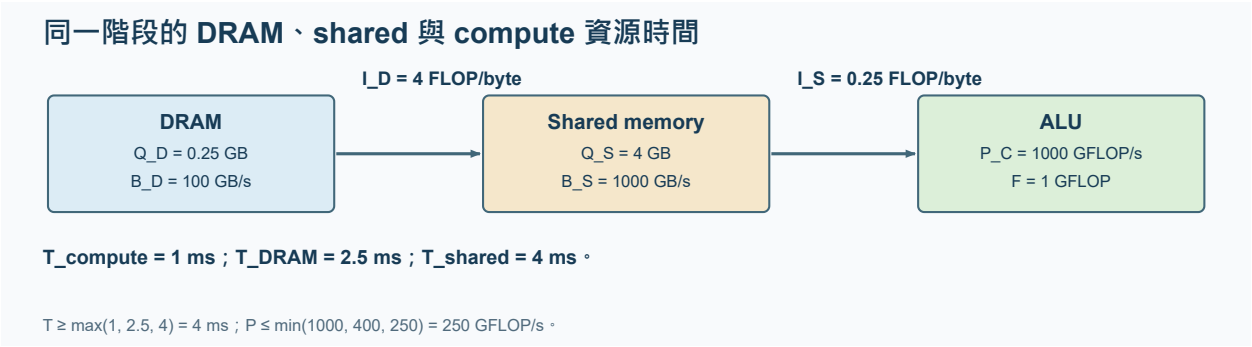
Shared 層要重新計算

$$I_S = F/Q_S = 10^9/(4 \times 10^9) = 0.25 \ \text{FLOP/byte}.$$

$$\min(P_C, I_S B_S) = \min(1000, 0.25 \cdot 1000) = 250 \ \text{GFLOP/s}.$$

Shared roof 的折點是 1；1000 GFLOP/s 才是 plateau，$(0.25, 250)$ 位於斜線。250 不能畫成 shared roof 的水平上限。

分層流量的限制不能混乘 （續）



三個 resource times 是

$$T_{\text{compute}} = 10^9/(1000 \times 10^9) = 0.001 \text{ s},$$

$$T_D = 0.25 \times 10^9/(100 \times 10^9) = 0.0025 \text{ s}, \qquad T_S = 4 \times 10^9/(1000 \times 10^9) = 0.004 \text{ s}.$$

若各資源 traffic 可以重疊，

$$T \geq \max(1, 2.5, 4) = 4 \text{ ms},$$

$$P \leq F/T = 10^9/0.004 = 250 \text{ GFLOP/s}.$$

最終 $(I_D, I_S) = (4, 0.25)$ 對應的跨層上界是 250 GFLOP/s。它是 declared model bound，不是 measured throughput；實際 kernel 還可能因 bank replay、同步、occupancy 或額外 traffic 低於此值。

分層流量的限制不能混乘 （續）

層級	bytes	強度	可持續頻寬	該層上限
compute	不適用	不適用	$P_C = 1000$ GFLOP/s	1000 GFLOP/s
DRAM	0.25×10^9	4 FLOP/byte	100 GB/s	400 GFLOP/s
shared	4×10^9	0.25 FLOP/byte	1000 GB/s	250 GFLOP/s
合併	各層獨立	各層獨立	各層獨立	250 GFLOP/s

A.9 用明確反例檢查性能推論

高occupancy未必快，因為減register引起spill可增加memory traffic。連續access未必滿DRAM頻寬，因為outstanding requests、channel分配或依賴鏈仍可限制；shared memory也可能因bank conflicts與barriers而變慢。

單一kernel的peak不能當作應用speedup。相同FLOP數而含不同精度、近似函數、FMA計數或transfer邊界，也不可直接比較。若量測P超過由同phase之F/Q與有效頻寬得到的roof，先核對FLOP計數、cache/interface bytes、時間範圍及頻寬假設，而非立即宣稱推翻資源上界。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

A.10 正確性先於 mapping 選擇

CSR需保持每row完整點積與唯一writer；scan需保留prefix不變量與同步順序；radix需stable partition；N-body需覆蓋全部pair並正確管理tile生命期。以上契約成立後，才比較row-per-thread、warp-per-row、tile size或register使用量。

圖、trace與有限模型核對可定位錯誤，但一般性正確性分別依賴唯一索引、loop/tree invariant與歸納。GPU世代改變不會讓不正確的同步或越界程式因「通常同時執行」而變得合法。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

A.11 歷史架構與可遷移方法

GPU由固定graphics pipeline演進為unified processors，CUDA/PTX把大量thread程式映到可伸縮的硬體。Warp寬度、banks、cache與精度支援可變，仍需分清latency、throughput、resource capacity與資料交換的語意。

本章歷史GeForce 8800的結構來自原書，sector/bank/occupancy數例則明定為獨立抽象模型。把模型的參數與推導分開，讀者才可替換成新硬體的真規格重新分析，而不是背一組過時常數。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

參考資料

Patterson與Hennessy，*Computer Organization and Design: The Hardware/Software Interface*，Revised Fourth Edition，Appendix A，A.1–A.11，印刷A-3–A-77（PDF實體732–806）。Warp排程與divergence見A-28–A-30（PDF757–759）；16-bank模型見A-40（PDF769）；GeForce結構FigA.7.1見A-47（PDF776）；scan/reduction/radix與N-body見A-60–A-69（PDF789–798）。

Williams、Waterman與Patterson，〈Roofline: An Insightful Visual Performance Model for Multicore Architectures〉，*Communications of the ACM*52(4)，2009，DOI。

分層bytes定義另見NERSC Roofline文件。本文的32-bank、32-byte sectors、occupancy及計算數據是各頁明定的教學模型，未冒充同一款GPU的實測。

參考資料與署名

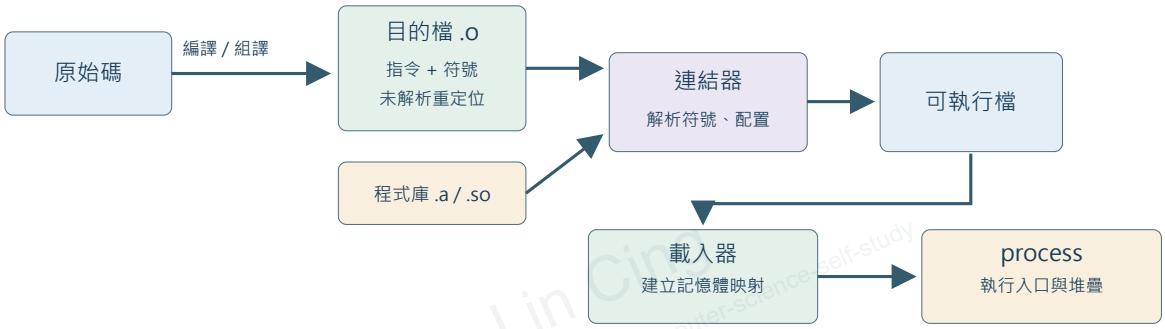
David A. Patterson、John L. Hennessy，Computer Organization and Design，Revised Fourth Edition，附錄 A；計算機組織與結構（CSO）課程投影片。

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study

原始碼到機器狀態的五個邊界

編譯器將高階程式轉成組合語言或直接產生目的檔。組譯器（assembler）處理指令、標籤與組譯指示，產生機器碼、符號與重定位資訊。連結器（linker）解析跨檔案的名稱並配置位址；載入器建立行程的記憶體映射，CPU 再依指令集執行。



目的檔格式正確不代表程式能正確執行，連結成功也不代表呼叫慣例正確。仍須檢查指令欄位、符號綁定、重定位位址、記憶體區段權限，以及呼叫雙方約定的暫存器保存責任。

本章 MIPS 模型

採傳統 pre-Release-6 MIPS32：每條機器指令 4 bytes，branch／jump 有一個 delay slot，`jal` 把呼叫指令位址加 8 寫入 `$ra`。若教材採沒有 delay slot 的簡化模型，返回位址可能是 PC+4；兩種慣例不能混用。範例以nop明示slot，不假設load delay。SPIM需選相容的delayed-branch設定；它的syscall是教學介面，不是Linux MIPS syscall ABI。

位址運算採32-bit，整數結果需要時按mod2^32解讀。一般branch immediate先sign-extend再乘4，J-format target則由PC+4高4 bits拼接26-bit field與兩個0。本文簡化object與relocation模型會明示addend，不能當作完整ELF parser。

B.1 Assembly 每一行的不同意義

`addu $t0,$t1,$t2`是machine instruction。`.text`切換section、`.word`配置資料、`.align n`在本章assembler語法對齊到2^n bytes，這些directives不由CPU逐行執行。

`move $s0,$s1`可展開為`addu $s0,$s1,$zero`；`la $t0,label`可能展開成兩條甚至不同位址取得序列。Macro是文字/語法層展開，不建立runtime call frame。程式大小必須由展開後的指令、資料及padding計算，不能按source行數乘4。

直接用assembly適合boot、exception entry或需要精確ABI的低階邊界；效能優勢須依實際編碼與模型量測，不能由「較低階」推論一定較快。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

B.2 兩遍組譯的資料結構

第一遍維護每個section自己的location counter，並記錄symbol的section與offset。遇到label就綁定當前counter；遇到指令或資料就增加確切size；遇到alignment就向上取到合法邊界。

第二遍依相同展開與size規則編碼。已知同section的PC-relative reference可解出差值；仍需最終section base或外部symbol者產生relocation。兩遍若對pseudoinstruction長度的判斷不同，所有後續label都會錯；實作可先建立已展開的中間表示，避免各遍各猜一次。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Location counter 的實際追蹤

本例.text offset從0開始，每條顯示的指令均已是4-byte machine instruction。

```
.text
main: addiu $t0,$zero,0
loop: addiu $t0,$t0,1
      bne   $t0,$a0,loop
      nop
done: jr    $ra
      nop
.data
msg:  .asciiz "Hi"
.align 2
value: .word 0x1234abcd
```

事件	section offset之前	配置/對齊後
main指令	text0	text4
loop指令	text4	text8
bne、nop	text8	text16
done: jr、nop	text16	text24
msg及NUL	data0	data3
.align 2	data3	data4，補1 byte
value	data4	data8

Location counter 的實際追蹤 (續)

因此symbols為main=(text,0)、loop=(text,4)、done=(text,16)、msg=(data,0)、value=(data,4)。
Section base直到link才決定。

Branch encoding 與 relocation invariance

若text base=0x00400000，bne在0x00400008，loop在0x00400004。Immediate為

$$\frac{target-(PC+4)}{4}=\frac{0x00400004-0x0040000c}{4}=-2=0xfffe.$$

bne opcode5、rs=$t0=8$、$rt=$a0=4，完整word為

$$(5\ll 26)|(8\ll 21)|(4\ll 16)|0xfffe=0x1504fffe.$$

整個text搬移δ時，target與PC同加δ，差值不變。因此已知同section、相對位置不變的branch通常不需為單純整段搬移而修改。若linker改寫layout或target在其他section，就要重算並檢查signed16-bit範圍及4-byte對齊。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

超出分支範圍時如何改寫

在本章有 delay slot 的模型中，假設 `beq $s0,$s1,far` 位於 0x00400000，且原 delay slot 為 `nop`；遠端標籤 `far=0x00430000`。分支位移是 (0x00430000−0x00400004)/4=49151，超過 signed 16-bit 的最大值 32767。

```
0x00400000  bne  $s0,$s1,skip
0x00400004  nop                 # branch delay slot
0x00400008  j    far
0x0040000c  nop                 # jump delay slot
0x00400010  skip:  ...          # 原來不跳轉的後續程式
```

相等時 bne 不成立，執行 slot 後由 j 到 far；不相等時執行 slot 後直接到 skip。bne 的位移是 (0x10−0x04)/4=3。此例要求遠端與 j 的 PC+4 在同一 256 MiB 區域；否則還須使用可達的跳板或間接跳躍。改寫後程式變長，後續位址與其他 reference 必須重新配置。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

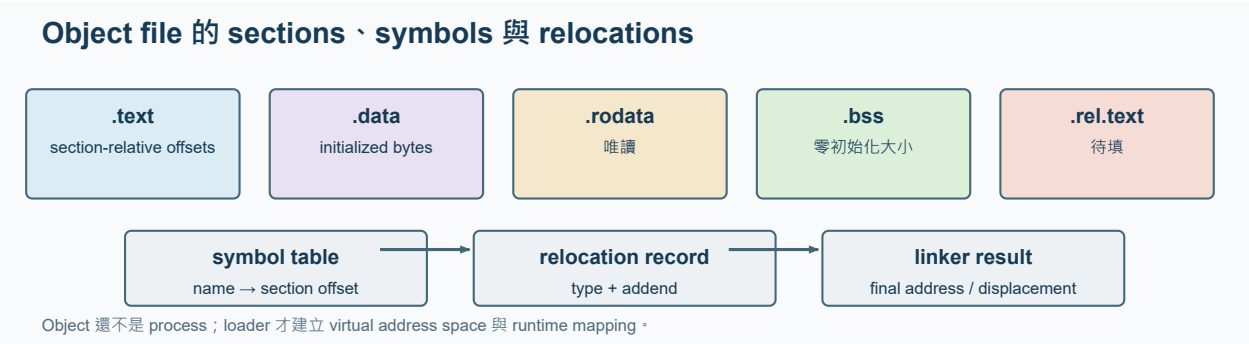
Macro 展開也可能改變輸入

假設一個不安全的macro要把argument乘3，展開成 `addiu $t0,$zero,3; mult $arg,$t0; mflo $v0`。若呼叫的argument正是t0，且原值7，展開後第一條已把7覆寫成3，結果為9而非21。Macro作者必須明定clobbers，保證讀取原argument前不覆寫它，或使用不與arguments衝突的暫存策略。

重複展開內部label也需產生唯一名稱，否則可能重複定義或跳到另一份macro。Conditional assembly在組譯時選擇要輸出的code，不是CPU執行期的conditional branch；未輸出的分支沒有runtime成本，但配置與symbol table會隨條件改變。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Object file 不是記憶體快照



`.text`保存指令，`.data`保存有初值的可寫資料，`.rodata`保存唯讀常數，`.bss`描述應配置並清零的大小，通常不需在檔案中放同量的0 bytes。Symbol除了名稱還有section、value、binding與type。

Relocation record至少要指出site、symbol、type及addend的取得方式。有的格式把addend放在record，有的編在原欄位；不能只看欄位0就猜「不需要修補」。Debug資訊也不是執行時一般load/store的資料。

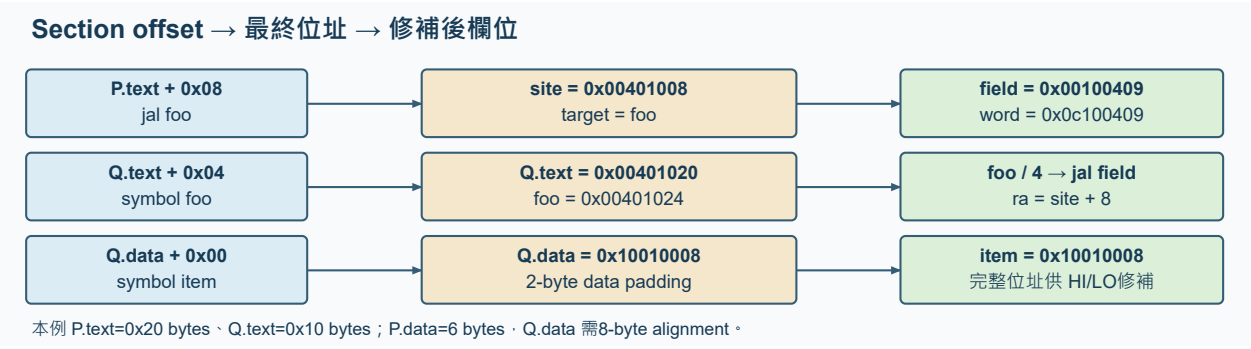
Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Symbol resolution 的範圍

Local symbols只在各自object有效，所以兩個object可各有名為loop的local label。兩個同名strong global definitions通常是錯誤；undefined reference必須由合法definition、library或執行期綁定機制滿足。

Weak/common與symbol visibility依格式及工具鏈規則處理，不能泛稱linker任選一個。以下例子只用唯一strong definition，使每個reference有明確target；若不唯一，就先報錯，不能靠relocation補救名稱歧義。

B.3 合併兩個 objects 的 sections



明定P.text大小0x20、Q.text大小0x10；P.data大小6 bytes、Q.data大小4 bytes且需8-byte alignment。Text base=0x00401000，data base=0x10010000，按P、Q順序合併。

輸入section	最終base	範圍，含首不含尾
P.text	0x00401000	[0x00401000,0x00401020)
Q.text	0x00401020	[0x00401020,0x00401030)
P.data	0x10010000	[0x10010000,0x10010006)
padding	0x10010006	2 bytes
Q.data	0x10010008	[0x10010008,0x1001000c)

一個 jal relocation 的全部欄位

若Q中foo=(text,4)、item=(data,0)，則最終foo=0x00401024、item=0x10010008。每個symbol的offset加的是**自己輸入section的最終base**，不是一律加整個executable base。

P.text offset8有`jal foo`，site=0x00401008。Foo=0x00401024且aligned，PC+4=0x0040100c的高4 bits與target相同，所以可用J-format。

$$field = (0x00401024 \gg 2)\ \&\ 0x03ffffff = 0x00100409,$$

$$word = (3 \ll 26) | field = 0x0c100409.$$

CPU重建target為 $\{(PC+4)[31:28], field, 00\} = 0x00401024$。`jal`另把return address 0x00401010寫入ra，並先執行site+4的delay-slot nop。若target跨256 MiB區域，截26 bits不能修好；需合法的veneer或間接跳躍序列，不能默默截斷。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

High/low relocation 與 sign extension

對V=0x1234abcd，`lui/ori`採零延伸low：high=0x1234、low=0xabcd，$(high \ll 16) | low = V$。

若第二條用`addiu`，low立即數sign-extend，0xabcd代表−21555。因此high必須進位：

$$H = ((V + 0x8000) \gg 16)\ \&\ 0xffff = 0x1235,$$

$$(0x1235 \ll 16) - 21555 = 0x1234abcd.$$

把0x1234直接配addiu得到0x1233abcd，差0x10000。實際MIPS HI16/LO16配對relocation還要依ABI處理addend與pair關係；本例是完整最終值V已知後的算術，不將兩個獨立截半視為所有relocation的實作。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Static archive 的一次掃描例

明定教學linker由左至右處理檔案，object必納入；遇archive時，反覆抽出能滿足當前undefined symbols的members直到該archive不再有新需求，之後不自動重掃前面的archive。

Main.o定義main、引用f；libF.a的F.o定義f、引用g；libG.a的G.o定義g。`main.o libF.a libG.a`的未解集合依序為{f}、{g}、{}，成功。

`main.o libG.a libF.a`先在libG時只有f未解，無member可抽出；libF再抽F.o後留下g，最終失敗。這不是C語言語意而是明定archive選取規則。實際工具鏈可有group/rescan選項，不能把這個單向模型當作所有linker唯一行為。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

動態連結與 GOT 間接引用

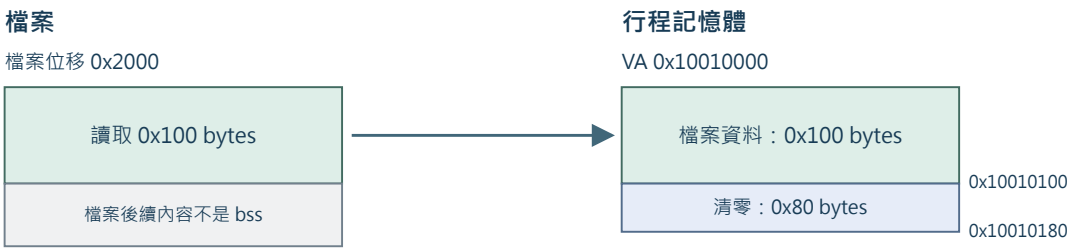
Static link把選取的library code合併進executable。Dynamic link則在process建立時或首次需要時，把reference綁到shared object的實際位址。不同process可以把同一唯讀code頁映到不同VA，共享的是physical backing，不表示可寫global data也必須共享。

用抽象GOT slot例，code從固定可達的slot讀取function pointer。Load前slot有待修補狀態；loader找到foo=0x70001234後填入slot；之後的indirect call取該值。Lazy binding可先導向resolver再更新slot，但實際stub/register規則依ABI，不把此抽象當作MIPS或x86的完整PLT指令。

ASLR讓base改變，position-independent code使用相對位址或間接表減少text修補。仍需正確symbol版本與呼叫ABI，載入相同名稱不保證介面相容。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

B.4 Loader 的 file size 與 memory size



memory size = 0x180；不代表載入器必須先逐 byte 複製。

明定一個可寫segment：file offset0x2000、VA0x10010000、file size0x100、memory size0x180，page size0x1000。Loader從檔案映入首0x100 bytes，並把後0x80 bytes清零；不把檔案後面不相關的bytes當作bss。

Segment與section不同。Linker可把多個sections合進一個具共同權限的loadable segment；loader主要依可執行格式的load資訊建立映射。Text可設R-X，data設RW-，未映射guard page捕捉部分越界。

Runtime entry先建立執行環境並呼叫main，因此main不是process的第一條instruction。實際ELF、PIE與interpreter流程依OS，不能只依section名稱推知全部runtime權限。

B.5 位址、byte order 與對齊

32-bit值0x12345678放在位址0x100：big-endian bytes為12、34、56、78；little-endian為78、56、34、12。Endianness改變byte位置，不改變register中數值，也不把指令的欄位bits左右顛倒。

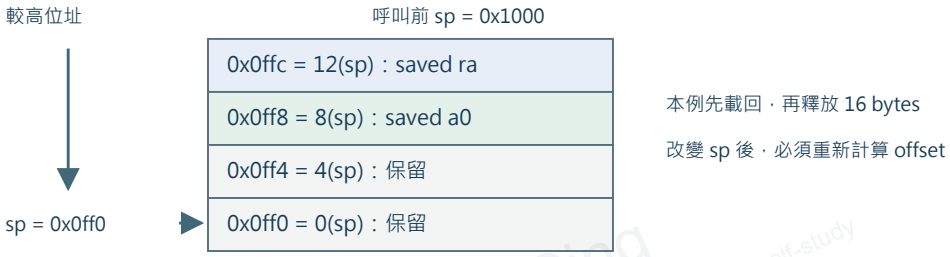
Strict-alignment MIPS的lw要求address低2 bits為0；0x102不能直接作lw。Packet序列化要固定欄位寬度、byte order及padding；native struct的memory dump不是跨機器協定。

Stack與heap的成長方向、mapping與guard由ABI/OS決定，典型示意不是所有process的唯一layout。

B.6 Caller 與 callee 保存責任

Caller把前四個整數arguments放a0–a3，常以v0/v1取結果。t-registers通常caller-saved，s-registers通常callee-saved；callee若改s0，return前須還原incoming s0。Caller若call後還要舊a0，需自己保存。

16-byte frame：地址與保存位置



本章遞迴例使用16-byte簡化教學frame，不宣稱完整o32 non-leaf frame。完整ABI還可能要求outgoing argument area、特定alignment及其他保存欄位。只符合ISA、卻不符合呼叫慣例的函式，仍可能破壞其他編譯器產生的caller。

sum_to 的完整遞迴程式

明定0<=n且和不溢出signed32-bit，sp初始aligned且空間足夠。本程式使用addu作模2^32相加，輸入界限確保同時等於數學答案。

```
sum_to:
  addiu $sp,$sp,-16
  sw    $ra,12($sp)
  sw    $a0,8($sp)
  beq   $a0,$zero,base
  nop
  addiu $a0,$a0,-1
  jal   sum_to
  nop
  lw    $t0,8($sp)
  addu  $v0,$v0,$t0
  j     done
  nop
base:
  addu  $v0,$zero,$zero
done:
  lw    $ra,12($sp)
  addiu $sp,$sp,16
  jr    $ra
  nop
```

每條控制轉移後都有slot。遞迴返回後重新從本層frame讀n，不能假設a0仍是原值，也不能把遞迴呼叫前的t0當作callee必保留值。

遞迴的實際 frames 與返回值

以初始sp=0x1000呼叫sum_to(3)，base case也建立frame。

n	本層sp	saved n位址	saved ra位址	返回v0
3	0x0ff0	0x0ff8	0x0ffc	6
2	0x0fe0	0x0fe8	0x0fec	3
1	0x0fd0	0x0fd8	0x0fdc	1
0	0x0fc0	0x0fc8	0x0fcc	0

返回由最內層依序做0、0+1=1、1+2=3、3+3=6，sp回到0x1000。最大同時4 frames，共64 bytes。本例各層先用本層sp對應的offset載回ra，再釋放frame；若先改sp，仍可用重新計算的地址讀取，但不能繼續盲用舊offset。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

遞迴正確性的歸納

令函式契約為：輸入n滿足範圍時，return有v0=n(n+1)/2、sp與callee-saved registers恢復。n=0時設定v0=0，epilogue取回ra/sp，符合契約。

對n>0，假設sum_to(n−1)符合契約。呼叫前把本層n與ra保存在自身frame，child的frame更低且不重疊；child返回後sp回到本層值，取回n並相加得(n−1)n/2+n=n(n+1)/2，最後還原ra/sp。n每次減1且有下界0，故終止。

此證明依賴stack容量與不溢出前提。無限遞迴、negative n或stack overflow不在契約內，不能只用已跑過n=3當作一般證明。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

B.7 Exception 不受一般 call ABI 限制

同步exception由當前指令引起，如overflow、address fault或syscall；interrupt來自timer或device等外部事件。Handler可在任何程式位置打斷執行，不能只保存callee-saved registers，因為被中斷程式也可能正使用caller-saved registers。

硬體保存或提供恢復所需的PC與status，軟體保存自己會改寫的registers。Handler需判斷cause、處理/清除必要pending source，再依可恢復語意返回。未清裝置原因就return，可能立即再次中斷；nested handler也需獨立保存狀態，避免覆寫outer context。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

EPC 與 branch delay 的兩種情形

非delay-slot的可恢復fault：Cause.BD=0，EPC指向faulting instruction。若修好page mapping並重試load，通常回到該EPC；若已完成一個syscall服務，則在明定政策下由下一條繼續。

若branch在0x00400020，其delay slot的lw在0x00400024發生address fault，則BD=1、EPC=0x00400020。EPC指向branch，不是lw。單純EPC+4會直接跳到slot且遺失branch語意；handler須保留/重建branch決策與slot狀態，或採可正確重新執行的處理方式。

Precise exception要求較舊指令已完成、faulting及較年輕指令未提交不應有的effects。外部interrupt優先權不能讓較年輕同步fault越過較舊指令的程式順序。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

B.8 MMIO receiver 的 polling 例

以下是明定教學device，不宣稱所有SPIM版本固定此位址。Receiver control=0xffff0000、data=0xffff0004，control bit0=ready；讀data消耗一個byte並清ready。MMIO映射uncached，平台保證本序列所需I/O順序。

```
lui   $t0,0xffff
poll:
lw    $t1,0($t0)
andi  $t1,$t1,1
beq   $t1,$zero,poll
nop
lw    $v0,4($t0)
andi  $v0,$v0,0xff
```

若control依序回傳0、0、1，loop讀control三次，只在第三次後讀data一次。把data load提前到branch delay slot會在not-ready時也讀取，改變裝置狀態，故slot保留nop。

B.9 SPIM syscall 的可執行語意

在SPIM教學服務中，print-int常用v0=1、a0=整數；print-string用v0=4、a0=NUL結尾字串位址；exit用v0=10。服務編號是simulator介面，不是ISA opcode或跨OS通用編號。

```
addiu $v0,$zero,1
addiu $a0,$zero,42
syscall
addiu $v0,$zero,10
syscall
```

此處syscall不在delay slot。Simulator可能直接實作服務，不等同真OS執行一份相同的handler。觀察到輸出42可核對此程式，不足以證明真實MIPS系統的exception vector或kernel ABI相同。

B.10 指令語意的查核表

類別/例	位元運算與重要條件
add / addu	同樣低32-bit和；add可因signed overflow trap，addu不trap
addiu	immediate sign-extend，不因signed overflow trap
andi / ori	immediate zero-extend
slt / sltu	相同比特以signed/unsigned比較，可得不同結果
lb / lbu	讀8-bit後分別sign/zero extend
lw / sw	base+signext immediate；strict model要求word對齊
beq / bne	比較GPR，target=PC+4+(signext imm<<2)，執行slot
j / jal	拼接PC+4高bits；jal另外寫ra=PC+8
jr	register target，仍有slot

例如bit pattern0xffffffff，slt把它解成−1，sltu解成4294967295。Signedness由使用的operation與資料契約決定，不是bits自己帶有signed標記。

B.11 從錯誤位址回到來源

Fault位址若落在錯誤function，先查symbol resolution與link map；若constant只差0x10000，核對low sign extension及HI/LO配對；若call返回後register錯，核對ABI與delay slot；若bytes顛倒，核對序列化及endianness。

Assembler listing可顯示source、offset與word；object dump顯示symbols/relocations；link map顯示最終section位置；execution trace顯示PC與register變化。這些證據定位不同邊界，不能用「可能compiler bug」取代具體欄位核對。

B.12 練習的模型邊界

本章的兩遍assembler、relocation、stack及MMIO例都先固定版本與語意，再推導結果。練習需要重算變更layout、低半部負值、archive相依與異常返回的影響，不能只背一組hex答案。

完整ISA還含floating-point、coprocessor與其他system instructions。查原書reference時應分清machine instruction與pseudo，並同時讀語意、例外、對齊及delay-slot限制，不能只查opcode一欄。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

參考資料

Patterson與Hennessy，*Computer Organization and Design: The Hardware/Software Interface*，Revised Fourth Edition，Appendix B。B.2–B.9印刷B-10至B-44（PDF實體815–849）；B.3.1連結圖在印刷B-19（PDF824）。B.10為指令reference，印刷B-45至B-80（PDF850–885）。

本文object layout、數值、遞迴程式與練習為明定模型的獨立例子。需要完整平台ABI時，須再查該系統規格，不能把16-byte教學frame當作完整o32 non-leaf配置。

參考資料與署名

David A. Patterson、John L. Hennessy，Computer Organization and Design，Revised Fourth Edition；Lin Cing，《計算機組織》手寫筆記；計算機組織與結構（CSO）課程投影片。

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study