前置知識與本章目標

- 前置知識為第 1 章 ADT、不變量與成本模型，以及 C++ 物件生命週期。
- 能由索引域定義 Array ADT，推導多維索引的位址式，並說明連續儲存的限制。
- 能追蹤稀疏矩陣轉置及字串匹配，辨別「字元」與編碼單位。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Array ADT 的索引契約

- 一維陣列是固定索引域 $\{0,\ldots,n-1\}$ 到元素值的映射。`get(i)`、`set(i,x)` 的前提是 $0 \le i < n$。
- 長度改變是動態序列的額外能力，不是固定長度 Array ADT 的必要操作。
- `set(i,x)` 的後置條件為索引 `i` 的值變成 `x`，其餘索引的值不變。
- 連續記憶體是常見表示，不是 ADT 的數學定義。分段儲存也能提供索引語義，但成本可能不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

C++ 表示與生命週期

- `std::array<T,N>` 的長度編譯期固定。`std::vector<T>` 的長度可在執行期改變。
- 除特化 `vector<bool>` 外，`vector` 元素連續儲存。`size()` 和 `capacity()` 分別是現有元素數與已配置容量。
- 下標 `operator[]` 不能作為一般越界檢查工具。教材範例對外部索引先檢查，再存取。
- 容量重配會使原先指向元素的指標、參照與迭代器失效。`reserve` 不會把 `size` 增加到指定容量。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

二維陣列的 row-major（逐列優先）位址

- 對 `R×C` 陣列，以固定寬度元素 `w` 位元組儲存，0 起始座標 `(i,j)` 的元素偏移為 `iC+j`。
- 若起點位址為 `b`，位址式是 `b+w(iC+j)`。此式只對同一連續區塊內的合法元素使用。
- 例子 `R=3,C=4,w=8`，座標 `(2,1)` 的元素偏移為 9，位元組偏移為 72。
- `vector<vector<T>>` 的各列可分別配置，不保證整個矩陣是一個連續區塊，不能直接套用上述整體位址式。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

索引次序與快取

- 在 row-major 儲存中，內圈沿欄索引 `j` 增加，會依序讀取相鄰元素。
- 若內圈沿列索引 `i` 增加，相鄰讀取的元素距離為 `C`，可能減少每個快取列的重用。
- 兩種走訪在 RAM 模型均為 `Θ(RC)`，實際時間仍可能不同。沒有實測前不報告快取速度比。
- 若 `R×C` 會溢位索引型別，必須在配置前檢查乘法範圍。合法的邏輯尺寸不代表機器可以配置。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

稀疏矩陣的 COO 與 CSR

- `nnz=k` 表示非零項數。COO 用三元組 `(row,column,value)`，即列索引、欄索引與值，儲存，另保留矩陣尺寸。
- 本教材 COO 採 row-major 排序、索引合法、同一座標不重複、不存明確零。輸入若不符合，先排序、合併重複座標，再移除零值。
- CSR 用 `row_ptr`、`col_idx`、`values`。第 `i` 列的非零項位於 `[row_ptr[i],row_ptr[i+1])`。
- CSR 空間為 `Θ(R+k)`。對非常多空列的矩陣，`R` 的成本不能隱藏。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

稀疏矩陣例子

矩陣有 3 列、4 欄，非零值為 `(0,1,5)`、`(1,0,-2)`、`(1,3,7)`、`(2,1,4)`。

- COO 依上述順序儲存。CSR 為 `row_ptr=[0,1,3,4]`、`col_idx=[1,0,3,1]`、`values=[5,-2,7,4]`。
- 第 1 列的區間是 `[1,3)`，因此讀出 `(-2)` 與 `7`，欄號分別為 0、3。
- 以向量 $x=[1,2,3,4]^T$ 相乘，輸出 $y=[10,26,8]^T$。



快速轉置依欄計數

1. 對原矩陣各欄計數，得到 `count[j]`。
2. 對 `count` 作前綴和，得到轉置後各列的起始位置 `start[j]`。
3. 依原 COO 順序走訪 `(i,j,v)`，把 `(j,i,v)` 寫入 `next[j]`，再增加 `next[j]`。
4. 原始 `start` 保留作為區間界線，不能被寫入游標破壞。

時間 `O(C+k)`，輔助空間 `O(C)`，輸出空間 `O(k)`。輸出若包含完整 CSR 列指標，還要保留 `C+1` 個位置。

快速轉置為何不覆寫

- 原例各欄計數為 `[1,2,0,1]`，前綴起點為 `[0,1,3,3]`。
- 各欄的輸出區間互不相交，長度恰等於該欄的非零項數，因此每個輸入項有唯一輸出位置。
- 依輸入列順序穩定散佈，使轉置後同一列的欄號維持遞增。
- 結果為 `(0,1,-2)`、`(1,0,5)`、`(1,2,4)`、`(3,1,7)`。空欄自然對應空區間。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

COO 快速轉置的完整配置與游標

```
transpose(R,C,entries):
    require sorted unique valid nonzero entries
    count=[0]*C
    for (r,c,v) in entries: count[c]+=1
    start=[0]*(C+1)
    for c=0..C-1: start[c+1]=start[c]+count[c]
    next=copy(start[0:C]); out=array(len(entries))
    for (r,c,v) in entries:
        out[next[c]]=(c,r,v); next[c]+=1
    return (C,R,out)
```

同一3×4例子的各項散佈為：i=0的(0,1,5)寫out[1]；i=1的(1,0,−2)寫out[0]；i=2的(1,3,7)寫out[3]；i=3的(2,1,4)寫out[2]。start=[0,1,3,3,4]，結束next=[1,3,3,4]，恰好等於各列右界。每個計數區間不交疊且寫入數等於長度，保證無覆寫與無遺漏；穩定按原row次序散佈，使轉置row內col有序。

空欄2的區間[3,3)長0；R=0,C=4時仍須回傳4×0尺寸與空項目。時間Θ(C+k)，輸出Θ(k)、輔助Θ(C)；若輸入未正規化，排序與座標合併成本必須另計。加法合併也需尺寸完全相同，不只是nnz相同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

稀疏加法與乘法成本

- 兩個已排序 COO 相加，可像合併排序般同時前進。相同座標相加，結果為零就不輸出。
- 輸入非零項數為 k_1,k_2 時，合併成本 $O(k_1+k_2)$，不含輸入正規化。
- 稀疏矩陣向量乘法 $y_i=\Sigma_j A_{ij} x_j$ 以 CSR 執行為 $O(R+k)$，含初始化輸出。
- 稀疏矩陣乘法成本不能只寫 $O(k_1+k_2)$。輸出可能變稠密，且累加同座標需要額外資料結構。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

稀疏加法與矩陣向量乘的完整操作

```
add_COO(A,B):
    require same dimensions and canonical row-major entries
    i=0; j=0; out=[]
    while i<len(A) and j<len(B):
        if coord(A[i])<coord(B[j]): out.append(A[i]); i+=1
        else if coord(B[j])<coord(A[i]): out.append(B[j]); j+=1
        else:
            value=A[i].value+B[j].value
            if value!=0: out.append((A[i].row,A[i].col,value))
            i+=1; j+=1
    append remaining A[i:] and B[j:]; return out
CSR_matvec(R,C,row_ptr,col_idx,values,x):
    require len(x)==C
    y=[0]*R
    for r=0..R-1:
        for p=row_ptr[r]..row_ptr[r+1]-1:
            y[r]+=values[p]*x[col_idx[p]]
    return y
```

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

稀疏加法與矩陣向量乘的完整操作 （續）

令B只有(0,1,−5),(2,0,3)，與本章A相加時，首座標(0,1)抵消；A的(1,0,−2),(1,3,7)先輸出；接著B的(2,0,3)再A的(2,1,4)，結果4項而非直接kA+kB=6項。矩陣向量乘x=[1,2,3,4]，row0累加5×2=10；row1依序−2×1=−2，再+7×4得26；row2為4×2=8。

維持每列區間端點0≤row_ptr[r]≤row_ptr[r+1]≤k，row_ptr[0]=0、row_ptr[R]=k且每個col_idx∈[0,C)。這些是CSR表示不變量，不能只驗三個array長度相同。算術成本假設固定範圍值，不替溢位或任意精度求和承諾常數時間。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

String ADT 與編碼層次

- 字串可定義為字母表 Σ 上的有限序列，基本操作有長度、連接、子字串與比較。
- `std::string` 儲存 `char` 編碼單位，可以含內嵌 `\0`。邏輯長度以 `size()` 為準，不能一律用 C 字串終止規則。
- UTF-8 中一個 Unicode 碼點可占多個位元組，一個使用者感知的字形又可能包含多個碼點。
- 本章匹配演算法預設比較固定大小的符號。若輸入採 UTF-8 位元組，回傳位置也是位元組位置。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

字串操作的複製與檢視語義

- 若用長度及連續編碼單位表示字串，讀取既有索引可為 O(1)，複製長度 k 的子字串需 Θ(k) 時間與輸出空間。
- 連接長度 N、M 的兩字串並產生獨立結果，需 Θ(N+M) 複製。反覆用新結果複製整個前綴，累積成本可能二次成長。
- 非擁有的字串 view 只保留起點與長度，可常數時間切片，但不延長原字串生命週期。來源被釋放或重配後，view 不能繼續使用。
- 字典序比較要逐符號找第一個差異，最壞成本包含共同前綴長度及結束判定，為 O(共同前綴長度 +1)。雜湊值、指標相同或長度相同都不能一般地取代內容相等判定。

直觀匹配與 KMP 前綴函數

- 文字長度 `N`、樣式長度 `M`。逐起點比對的最壞時間為 `O(NM)`，如大量重複字元在最後一位才失配。
- 定義 `π[i]` 為樣式 `P[0..i]` 的最長真前綴與後綴共同長度。
- 若目前已匹配 `q` 個字元卻失配，改以 `q=π[q-1]` 嘗試較短的已知邊界，不回退文字讀取位置。
- π 的建立和搜尋各以回退次數的總量分析，總時間 `O(N+M)`，輔助空間 `O(M)`。

回退鏈列出已匹配前綴的較短 border（同為前綴與後綴的區段）。失配後仍可能成立的匹配長度必須是該前綴的 border，因此略過其他長度不會漏解。每次成功延伸至多使 q 增加 1，每次回退嚴格減少 q；建立 π 與搜尋各自的回退總數，都由先前延伸次數支付，不會超過線性數量。

KMP 的原創追蹤

- 樣式 P=ababaca，前綴函數為 [0,0,1,2,3,0,1]。
- 已匹配 ababa 後遇到 b，樣式下一位期待 c。先從 q=5 退到 π[4]=3。
- 此時 P[3]=b 可匹配目前文字字元，得到 q=4，並未重新掃描已讀的文字。
- 在文字 abababaca 中，完整匹配的 0 起始位置是 2。空樣式在本教材定義為位置 0 的匹配，需在介面明訂。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

KMP 建表與搜尋的完整迴圈

```
prefix(P):
    pi=[0]*len(P)
    for i=1..len(P)-1:
        q=pi[i-1]
        while q>0 and P[q]!=P[i]: q=pi[q-1]
        if P[q]==P[i]: q+=1
        pi[i]=q
    return pi
first_match(T,P):
    if len(P)==0: return 0
    pi=prefix(P); q=0
    for i=0..len(T)-1:
        while q>0 and P[q]!=T[i]: q=pi[q-1]
        if P[q]==T[i]: q+=1
        if q==len(P): return i-len(P)+1
    return not_found
```

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

P=ababaca 建表各步為 i=1:b,q=0→0；i=2:a,0→1；i=3:b,1→2；i=4:a,2→3；i=5:c,3→1→0且不延伸；i=6:a,0→1，得[0,0,1,2,3,0,1]。在T=abababaca，讀每字後q為1,2,3,4,5,4,5,6,7；第5號文字b使q先5→3再增至4，完整匹配終於i=8，起點2。

KMP 建表與搜尋的完整迴圈 （續）

前綴函數建構的迴圈只在i≥1且P非空時取P[q]；搜尋先處理空樣式，且在q=M時立刻回傳，故不讀P[M]。若要列舉重疊匹配，成功後令q=pi[M−1]再繼續，而非直接清零。固定符號比較下總O(N+M)；UTF-8若以byte處理，位置仍是byte offset，不能暗稱字形索引。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

來源與延伸界線

- C++ 容器性質核對 C++ vector overview。重配失效規則見 vector capacity。
- KMP 的原始論文書目為 Knuth、Morris、Pratt, *Fast Pattern Matching in Strings*, 1977；公開出版紀錄見 SIAM DOI。本稿採獨立前綴函數推導，不重製原文。
- Unicode 層次可核對 Unicode UTF FAQ。
- KMP 與 CSR 是本教材明示的教學延伸，尚未核對它們在指定參考書的實際章節位置。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

參考資料與署名

Ellis Horowitz, Sartaj Sahni, Dinesh Mehta. Fundamentals of Data Structures in C++, 2nd Edition.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study