第 3 章：集合論與離散機率

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.1 元素、子集與外延性

集合不保留重複或排列，$\{1,2,2\}=\{2,1\}$。外延性給

$$A=B \iff \forall x\,(x\in A \leftrightarrow x\in B).$$

$A\subseteq B$ 指 $\forall x(x\in A\Rightarrow x\in B)$，而 $A\subsetneq B$ 還要求 $A\neq B$。$\varnothing\subseteq A$ 由空真成立；$\varnothing\in A$ 則需看 A 是否真的把空集當元素。

例如 $A=\{\varnothing,\{1\}\}$ 有兩個元素；$\varnothing\in A, \{1\}\in A$，但 $1\notin A$。又 $\{\varnothing\}\subseteq A$，但 $\{1\}\not\subseteq A$，因 1 不在 A。大括號會改變所談的物件，不能任意省略。

集合相等也等價於兩個包含方向；反證 $A\subseteq B$ 則只需一個 $x\in A\setminus B$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.2 Powerset 的元素是 subsets

$\mathcal{P}(A) = \{S : S \subseteq A\}$。若 $A = \{a, b\}$，

$$\mathcal{P}(A) = \{\varnothing, \{a\}, \{b\}, \{a, b\}\}.$$

有限 $|A| = n$ 時，subset 與 n-bit membership vector 雙射，所以 $|\mathcal{P}(A)| = 2^n$。特別 $\mathcal{P}(\varnothing) = \{\varnothing\}$ 有一元素，不是空集。

對任意 A, B：

$$\mathcal{P}(A \cap B) = \mathcal{P}(A) \cap \mathcal{P}(B).$$

因 S 屬左邊 iff $S \subseteq A \cap B$，iff 同時 $S \subseteq A, B$，iff 屬右邊。

但一般 $\mathcal{P}(A \cup B) \neq \mathcal{P}(A) \cup \mathcal{P}(B)$。取 $A = \{a\}, B = \{b\}, a \neq b$，mixed subset $\{a, b\}$ 在左不在右；右邊仍總是左邊的子集。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.2.1 Gray code：相鄰 subsets 只改一元素

Membership vector 也可以按 reflected Gray code 排列。從 $G_0 = (\epsilon)$ 開始，令

$$G_n = (0G_{n-1},\ 1\ \mathrm{reverse}(G_{n-1})).$$

兩半分別以前綴 0、1 區分，故不重複；由歸納，兩半各自包含所有 suffix，合起來恰好列出全部 2^n 個向量。

位置	三個元素的 membership vector	若位元對應 a, b, c，所得 subset
0、1	000、001	$\varnothing, \{c\}$
2、3	011、010	$\{b, c\}, \{b\}$
4、5	110、111	$\{a, b\}, \{a, b, c\}$
6、7	101、100	$\{a, c\}, \{a\}$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.2.1 Gray code：相鄰 subsets 只改一元素 （續）

每半內相鄰向量只差一個 suffix 位元；交界兩向量的 suffix 都是 G_{n-1} 最後一項，只差 prefix。首項為 0^n、末項為 10^{n-1}，所以 $n \geq 1$ 時末項與首項也只差一位。這是循環相鄰次序，不是二進位數值遞增次序；之後的 Karnaugh map 正利用此相鄰性。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.3 集合運算與固定論域

固定 universal set U，所有集合均為其 subsets：

$$
\begin{aligned}
A \cup B &= \{x \in U : x \in A \lor x \in B\},\\
A \cap B &= \{x \in U : x \in A \land x \in B\},\\
A \setminus B &= \{x \in U : x \in A \land x \notin B\},\\
A^c &= U \setminus A,\\
A \triangle B &= (A \setminus B) \cup (B \setminus A).
\end{aligned}
$$

Symmetric difference（對稱差）保留「恰屬一個集合」的元素，對應 XOR，不是 union 的同義詞。

Complement 依 U 改變。若 $A = \{1, 2\}$，在 $U = \{1, 2, 3\}$ 補集為 $\{3\}$，在 $V = \{1, 2, 3, 4\}$ 補集為 $\{3, 4\}$。不指定論域，補集式子便未完整。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.4 集合定律的完整對照

性質	union 形式	intersection 形式
交換	$A \cup B = B \cup A$	$A \cap B = B \cap A$
結合	$(A \cup B) \cup C = A \cup (B \cup C)$	$(A \cap B) \cap C = A \cap (B \cap C)$
冪等	$A \cup A = A$	$A \cap A = A$
恆等	$A \cup \varnothing = A$	$A \cap U = A$
界	$A \cup U = U$	$A \cap \varnothing = \varnothing$
吸收	$A \cup (A \cap B) = A$	$A \cap (A \cup B) = A$
分配	$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$	$A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
互補	$A \cup A^c = U$	$A \cap A^c = \varnothing$
De Morgan	$(A \cup B)^c = A^c \cap B^c$	$(A \cap B)^c = A^c \cup B^c$

Lin Cing https://github.com/xinhi6716/computer-science-self-study

把任意 x 的 membership 轉成第 2 章的命題等值，就可逐條證明；不是只對某幾組具體集合試算。

3.4 集合定律的完整對照 （續）

表中各對等式互為 dual：交換 $\cup, \cap$ 與 $U, \varnothing$，保留補集，即將整套公理交換成同樣成立的公理，所以由這些公理推得的普遍恆等式也有成立的 dual。這不適用於某組特殊集合碰巧相等的式子：如 $A = \{1, 2\}, B = C = \{1\}, D = \varnothing$，有 $A \cap B = C \cup D$，卻沒有 $A \cup B = C \cap D$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.5 元素法如何建立集合相等

例如對任意 $x \in U$，

$$\begin{aligned} x \in A \cap (B \cup C) &\iff (x \in A) \land [(x \in B) \lor (x \in C)] \\ &\iff [(x \in A) \land (x \in B)] \lor [(x \in A) \land (x \in C)] \\ &\iff x \in (A \cap B) \cup (A \cap C). \end{aligned}$$

第二行使用命題分配律，最後由外延性得到集合等式。

De Morgan 同理：

$$x \in (A \cup B)^c \iff \neg[(x \in A) \lor (x \in B)] \iff x \in A^c \cap B^c.$$

若用兩個包含方向證明，每個方向都須任取元素；若只畫一個具體 Venn 圖，還未交代任意集合為何成立。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.6 Indexed families 與空族

對 $A_i \subseteq U,\ i \in I$，

$$\bigcup_{i \in I} A_i = \{x \in U : \exists i \in I,\ x \in A_i\}, \quad \bigcap_{i \in I} A_i = \{x \in U : \forall i \in I,\ x \in A_i\}.$$

若 $I = \varnothing$，不存在 witness，所以空 union 是 $\varnothing$；全稱條件空真，所以相對固定 U 的空 intersection 是 U。

量詞否定直接給任意 indexed family 的 De Morgan：

$$\left(\bigcup_i A_i\right)^c = \bigcap_i A_i^c, \qquad \left(\bigcap_i A_i\right)^c = \bigcup_i A_i^c.$$

例如 $A_n = \{1, \dots, n\} \subseteq \mathbb{N}^+$，則 $\bigcup_{n \geq 1} A_n = \mathbb{N}^+$，$\bigcap_{n \geq 1} A_n = \{1\}$。這兩個量詞順序的含義不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.7 Cartesian product 與 partition

Ordered pairs 滿足 $(a,b)=(c,d) \iff a=c, b=d$。$A \times B = \{(a,b) : a \in A, b \in B\}$，有限時大小 $|A||B|$。除非具有特殊對稱，$A \times B$ 與 $B \times A$ 是不同的 sets；交換座標只是它們之間的雙射。

Partition（分割）$\{B_i\}$ 要求每個 block 非空、不同 blocks 不交，且 union 是全部 U。因此每個元素恰落在一個 block。空 U 的 partition 採空 family；不能把空 block 加進去湊數。

例如 $\{1,2,3,4,5,6\}$ 按奇偶分成兩 blocks，或按 mod 3 分成三 blocks。後面的全機率公式也使用 partition，但 additionally 要有正機率分母。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.8 Membership regions 可能為空

三個 subsets A, B, C 的 membership pattern 是三個 bits。對 $\epsilon \in \{0,1\}^3$，取每個集合或其補集的 intersection，得到八個可能 regions。

每個 x 只有一個 pattern，所以這八個 regions 兩兩不交、union 為 U；但可能為空。只有非空 regions 才構成真正的 partition blocks，也才是這個集合族所生成有限 Boolean algebra 的 atoms。

例如 $A = B = C = \varnothing$, $U \neq \varnothing$，只有 pattern 000 的 region 非空，並不是八個非空 atoms。Venn 圖的八個幾何區域可用 0 標示不存在的 membership，不能從畫面形狀推斷每區必有元素。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.9 Indicator 與 inclusion-exclusion

定 $\mathbf{1}_A(x) = 1$ 若 $x \in A$，否則 0。對任意 x：

$$\mathbf{1}_{A \cap B} = \mathbf{1}_A \mathbf{1}_B, \qquad \mathbf{1}_{A \cup B} = \mathbf{1}_A + \mathbf{1}_B - \mathbf{1}_{A \cap B}.$$

因此對有限 U 求和，得

$$|A \cup B| = |A| + |B| - |A \cap B|.$$

三集合時，若 x 恰屬 $k = 1, 2, 3$ 個集合，其係數 $k - \binom{k}{2} + \binom{k}{3} = 1$；若 $k = 0$ 則為 0。故

$$|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C|.$$

這個逐點係數證明不依任何圓的形狀；第 8 章再推廣到任意有限集合族。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.10 八個 regions 的數字逐一核對

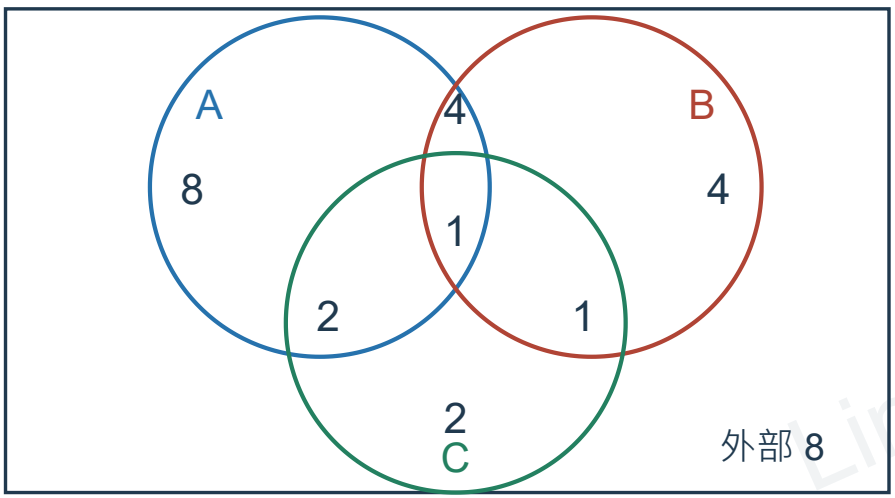
取 $U = \{1, \ldots, 30\}$，A, B, C 分別是 2、3、5 的倍數。大小為 15、10、6；兩兩交集為 5、3、2；三交集只有 30，大小 1。

先扣三交集：AB-only $= 4$、AC-only $= 2$、BC-only $= 1$。再得 A-only $= 8$、B-only $= 4$、C-only $= 2$，外部 $= 8$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.10 八個 regions 的數字逐一核對 （續）

U={1,…,30}：A 是 2 倍數、B 是 3 倍數、C 是 5 倍數



|A|=15，|B|=10，|C|=6

|A∩B|=5，|A∩C|=3，|B∩C|=2

|A∩B∩C|=1；先填最內層，再扣重疊。

聯集：8+4+2+4+2+1+1 = 22

恰一集合：8+4+2 = 14

每個數字是區域基數；圓面積不按基數比例。

聯集 $= 22$，恰屬一集合 $= 14$，恰屬兩集合 $= 7$，恰屬三集合 $= 1$。總和 $14 + 7 + 1 + 8 = 30$，全部區域非負，與論域大小一致。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.11 本章的離散機率模型

固定非空、有限或可數的樣本空間 Ω，每個 outcome 有 mass $p_\omega \geq 0$，且 $\sum_{\omega \in \Omega} p_\omega = 1$。事件取全部 subsets，定

$$P(A) = \sum_{\omega \in A} p_\omega .$$

因非負 sums 可重排，互斥事件的 union 之 mass 就是各 mass 相加。因此滿足 $P(\Omega) = 1$ 與 countable additivity。

也可反過來從這兩個機率公理與非負性出發；在可數 Ω 令 $p_\omega = P(\{\omega\})$，countable additivity 恢復上述表示。本章不需要對任意不可數空間另建事件集合。

有限且所有 outcomes 等可能時，$p_\omega = 1/|\Omega|$，才有 $P(A) = |A|/|\Omega|$。可數無限空間不存在每個 singleton 等 mass 的機率：mass 正則總和發散，mass 零則總和為 0。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.12 從公理推出的基本式

由 $P(\Omega) = P(\Omega \sqcup \varnothing) = P(\Omega) + P(\varnothing)$，得 $P(\varnothing) = 0$。又 $\Omega = A \sqcup A^c$，所以 $P(A^c) = 1 - P(A)$。

若 $A \subseteq B$，分割 $B = A \sqcup (B \setminus A)$ 給

$$P(B) - P(A) = P(B \setminus A) \geq 0.$$

故機率單調。對任意兩事件，分解成 A-only、B-only、交集三塊，得

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

由 $P(A \cup B) \leq 1$，也有下界

$$P(A \cap B) \geq P(A) + P(B) - 1,$$

與顯然的 ≥ 0 合用。例如 $P(A) = 0.7, P(B) = 0.5$，交集不可能小於 0.2，不需要假設獨立。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.13 Union bound 與連續性

令 $B_1 = A_1$, $B_i = A_i \setminus \bigcup_{j<i} A_j$。這些 B_i 兩兩不交，union 不變，且 $B_i \subseteq A_i$，所以

$$P\left(\bigcup_i A_i\right) = \sum_i P(B_i) \le \sum_i P(A_i).$$

這是 union bound，對有限或可數事件族皆成立，不需 independence。

若 $A_1 \subseteq A_2 \subseteq \cdots$，以差集 $A_i \setminus A_{i-1}$ 作同樣分割，前 n 項 partial sum 正是 $P(A_n)$，所以

$$P(\bigcup_n A_n) = \lim_n P(A_n).$$

若 A_n 遞減，對 complements 用上式，再由 $P(A_n^c) = 1 - P(A_n)$，得 $P(\bigcap_n A_n) = \lim_n P(A_n)$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.14 等可能 outcomes 不等於等可能數值

兩個公平且獨立 coin tosses 的 ordered outcomes 是 $\Omega = \{HH, HT, TH, TT\}$，各 $1/4$。令 X 是 heads 數，則

$$P(X = 0) = 1/4, \quad P(X = 1) = 1/2, \quad P(X = 2) = 1/4.$$

因數值 1 有兩個 outcome 原像，不能把三個可能值各配 $1/3$。

同樣地，兩個相互獨立的公平六面骰的 36 個 ordered pairs 等可能，但點數和 2 只有一種、和 7 有六種。不放回抽兩個不同身分物件則是 ordered distinct pairs，不能把 diagonal (i, i) 混入。

機率模型要先給 outcomes 與 masses，再把事件或隨機變數的原像加總。

Lin Cing https://github.com/xinhi6716/computer-science-self-study/

3.15 Conditional probability 重新限制樣本

對 $P(B) > 0$，定

$$P(A \mid B) = P(A \cap B)/P(B).$$

把 outcomes 限制到 B，再以 $P(B)$ normalization。此條件機率在新的樣本 B 上仍非負、總量 1、互斥可加，因原機率的分割性保留。

乘法公式為

$$P(A \cap B) = P(B)P(A \mid B).$$

反覆使用得 chain rule：

$$P(A_1 \cap \cdots \cap A_n) = P(A_1) \prod_{i=2}^{n} P(A_i \mid A_1 \cap \cdots \cap A_{i-1}),$$

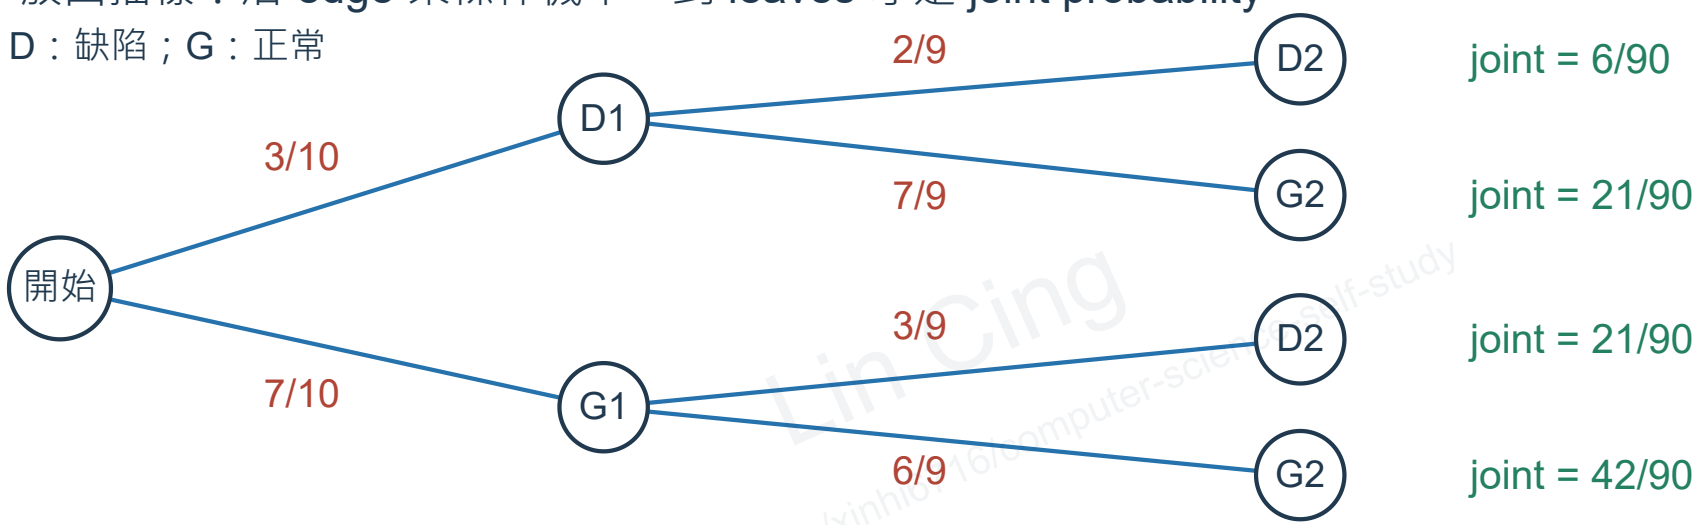
其中用到的每個 conditioning prefix 都須正機率。若某 prefix 機率為零，整個 intersection 為零，無需再乘未定義的 conditional。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.16 不放回抽樣的完整機率樹

十個有身分元件中三個缺陷、七個正常，依序不放回抽兩個。令 D_i 表第 i 個缺陷，$G_i = D_i^c$。

不放回抽樣：沿 edge 乘條件機率，到 leaves 才是 joint probability



例如 $P(D_1 \cap D_2) = \frac{3}{10}\frac{2}{9} = \frac{6}{90}$，不是 $3/10 \cdot 3/10$。第二個缺陷分成兩個互斥來源：

$$P(D_2) = \frac{3}{10}\frac{2}{9} + \frac{7}{10}\frac{3}{9} = \frac{27}{90} = \frac{3}{10}.$$

兩次邊際都為 $3/10$，但 $P(D_2 \mid D_1) = 2/9 \neq 3/10$，所以同分布不代表獨立。

3.17 全機率與 Bayes 的分割證明

設 $B_1, B_2, \dots$ partition Ω，並假設每個用於條件化的 $P(B_i) > 0$。因 $A = \bigsqcup_i (A \cap B_i)$，

$$P(A) = \sum_i P(A \mid B_i) P(B_i).$$

零機率 blocks 可從這個 sum 略去，因其交集機率也是零；不寫未定義的 $P(A \mid B_i) \cdot 0$。

若 $P(A) > 0$，對固定 j：

$$P(B_j \mid A) = \frac{P(A \cap B_j)}{P(A)} = \frac{P(A \mid B_j) P(B_j)}{\sum_i P(A \mid B_i) P(B_i)}.$$

這是 Bayes formula。分母包含所有可能產生 A 的互斥來源；只保留分子那一類，會錯把 posterior 算成 1。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.18 Bayes 數例：分母到底是哪一群

給定假設模型：$P(D)=0.02,\ P(+\mid D)=0.95,\ P(+\mid D^c)=0.10$。則

$$P(+)=0.95(0.02)+0.10(0.98)=0.117,$$

$$P(D\mid +)=0.019/0.117=19/117\approx 16.24\%.$$

把同一組機率乘 10,000，得到下圖期望頻數；不是額外觀測資料。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.18 Bayes 數例：分母到底是哪一群 （續）

Bayes：將給定的假設檢測機率換成 10,000 人的期望頻數

檢測結果	D：有病	D^c：無病	合計
陽性 +	190	980	1170
陰性 −	10	8820	8830
合計	200	9800	10000

給定陽性，限制在綠色 row：

P(D|+) = 190/1170

= 19/117 ≈ 16.24%

P(+|D) = 190/200 = 95%

分子同為 190；P(D|+) 的分母是全部陽性 1170，P(+|D) 的分母是全部有病 200。

低 prior 使 D^c 的基底很大，這個模型中 980 個假陽性的期望數大於 190 個真陽性；95% 是 $P(+ \mid D)$，不是 $P(D \mid +)$。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.19 Independence 與 disjoint 的差別

兩事件獨立 iff $P(A \cap B) = P(A)P(B)$。若 $P(B) > 0$，等價於 $P(A \mid B) = P(A)$；定義本身仍可用於零機率事件。

若兩事件 disjoint 且各有正機率，交集 0，小於乘積，因此不獨立。反過來，獨立事件可以大量重疊。

獨立也保 complements：

$$P(A \cap B^c) = P(A) - P(A \cap B) = P(A)(1 - P(B)).$$

交換角色、再取補，可得到四種補／不補組合的獨立性。

前面的 30 個整數均勻模型中，$P(A \cap B) = 5/30 = (15/30)(10/30)$，所以「2 倍數」與「3 倍數」獨立，雖然它們交集非空。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.20 Pairwise 不推出 mutual independence

事件族 $A_1, \ldots, A_n$ mutually independent，要求每個非空 index subset J 都滿足

$$P(\bigcap_{j \in J} A_j) = \prod_{j \in J} P(A_j).$$

Pairwise 只檢查 $|J| = 2$ 的項，沒有檢查三個以上。

取均勻 $\Omega = \{00, 01, 10, 11\}$。$A = \{\text{第一bit為1}\}$，$B = \{\text{第二bit為1}\}$，$C = \{\text{兩bits不同}\}$：

outcome	00	01	10	11
A	0	0	1	1
B	0	1	0	1
C	0	1	1	0

每事件機率 $1/2$，各 pair intersection 都恰一個 outcome、機率 $1/4$，所以兩兩獨立。但 triple intersection 空，$0 \neq 1/8$，不共同獨立。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.21 隨機變數與 induced distribution

離散隨機變數 $X : \Omega \to \mathbb{R}$ 是函數，事件 $\{X = x\}$ 指其原像 $\{\omega : X(\omega) = x\}$。這些非空原像 partition Ω，故

$$p_X(x) = P(X = x) \geq 0, \qquad \sum_x p_X(x) = 1.$$

不同隨機變數可能有相同 distribution，卻不是同一個函數；它們與別的變數的 joint 行為也可能不同。

例如一個公平 bit B，令 $X = B, Y = 1 - B$。兩者都以 $1/2$ 取 0 或 1，但永遠相反，不獨立；若另取獨立公平 bit Z，它與 X 的 joint distribution 又不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-stu

3.22 期望與 LOTUS 的分組推導

若 $E|X| = \sum_x |x| p_X(x) < \infty$，有限期望為

$$E[X] = \sum_x x p_X(x) = \sum_{\omega \in \Omega} X(\omega) p_\omega.$$

兩式相等是按 $X(\omega)$ 的同值 fibers 分組；絕對收斂保證可重排。非負變數的期望也可為 $+\infty$，但本章涉及相減的公式都假設所需期望有限。

對函數 g，若 $E|g(X)| < \infty$，同樣分組給

$$E[g(X)] = \sum_x g(x) p_X(x).$$

這稱 LOTUS（law of the unconscious statistician），不需先求 $g(X)$ 的新分布。

期望不是最可能值，也不一定是可取值。例如公平 $X \in \{0, 1\}$，$E[X] = 1/2$；且 $E[X^2] = 1/2 \neq (E[X])^2 = 1/4$。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.23 線性期望不需要 independence

若 $E|X|, E|Y| < \infty$，則直接在同一 Ω 上求和：

$$\begin{aligned} E[aX + bY] &= \sum_{\omega} (aX(\omega) + bY(\omega)) p_\omega \\ &= aE[X] + bE[Y]. \end{aligned}$$

沒有把 joint masses 分解成乘積，因此完全不需獨立。可歸納到有限個變數。

對 event indicator I_A，

$$E[I_A] = 1 \cdot P(A) + 0 \cdot P(A^c) = P(A).$$

所以數事件發生次數 $N = \sum_i I_{A_i}$ 時，$E[N] = \sum_i P(A_i)$，即使 events 相依也成立。

若要把 $E[XY]$ 換成 $E[X]E[Y]$，則需要額外條件；離散獨立時才可用 joint mass $p_{X,Y}(x,y) = p_X(x)p_Y(y)$ 對乘積分開求和。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.24 Variance 與 covariance

設 $E[X^2] < \infty, \mu = E[X]$，

$$\operatorname{Var}(X) = E[(X-\mu)^2] = E[X^2] - 2\mu E[X] + \mu^2 = E[X^2] - \mu^2.$$

非負來自平方；若有限離散分布各正 mass 的值都相同，variance 才為 0。縮放有 $\operatorname{Var}(aX+b) = a^2 \operatorname{Var}(X)$。

對二階動差有限的 X, Y，

$$\operatorname{Cov}(X,Y) = E[(X-EX)(Y-EY)] = E[XY] - EX\,EY.$$

展開平方得

$$\operatorname{Var}(X+Y) = \operatorname{Var}(X) + \operatorname{Var}(Y) + 2\operatorname{Cov}(X,Y).$$

獨立給 covariance 0，但一般反向不成立。只說「期望可相加」不能直接把 variance 也無條件相加。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.25 一個完整 PMF 的兩種 variance 算法

X 在 0、1、2 的 masses 為 $c, 2c, 3c$。Normalization $6c = 1$，所以

$$EX = 0(1/6) + 1(2/6) + 2(3/6) = 4/3,$$
$$E[X^2] = 0 + 1(2/6) + 4(3/6) = 7/3.$$

故 $\mathrm{Var}(X) = 7/3 - 16/9 = 5/9$。

直接中心化也得

$$\frac{1}{6}\left(-\frac{4}{3}\right)^2 + \frac{2}{6}\left(-\frac{1}{3}\right)^2 + \frac{3}{6}\left(\frac{2}{3}\right)^2 = \frac{16 + 2 + 12}{54} = \frac{5}{9}.$$

這裡 mean $4/3$ 不在 support，並不妨礙以它計算平方偏差。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.26 不放回抽樣的 hypergeometric distribution

母體 N 個可辨物件，K 個缺陷，均勻抽 n 個不放回，令 X 是缺陷數。抽出的 subset 均勻，所以

$$P(X=k)=\frac{\binom{K}{k}\binom{N-K}{n-k}}{\binom{N}{n}},\quad \max(0,n-(N-K))\le k\le \min(n,K).$$

分子是先選缺陷與正常，兩類互斥身分；總和等於 1 由 Vandermonde。假設 $0\le K\le N,\ 0\le n\le N$ 且 $N\ge 1$。

對前面的 $N=10, K=3, n=2$：

k	0	1	2
$P(X=k)$	$21/45=7/15$	$21/45=7/15$	$3/45=1/15$

所以 $EX=3/5,\ E[X^2]=11/15, \mathrm{Var}(X)=28/75$。這不是 Binomial$(2,3/10)$，因抽樣相依。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.27 Indicator 重算不放回的負 covariance

仍取十個中三個缺陷，依抽取位置定 I_1, I_2。每個 $E[I_i] = 3/10$，所以 $EX = E[I_1 + I_2] = 3/5$，不需要 independence。

但

$$E[I_1 I_2] = P(D_1 \cap D_2) = \frac{3}{10}\frac{2}{9} = \frac{1}{15},$$

$$\operatorname{Cov}(I_1, I_2) = \frac{1}{15} - \frac{9}{100} = -\frac{7}{300}.$$

每個 indicator variance 為 $(3/10)(7/10) = 21/100$。所以

$$\operatorname{Var}(X) = 2\frac{21}{100} + 2\left(-\frac{7}{300}\right) = \frac{28}{75}.$$

抽到一個缺陷後，剩餘缺陷比例下降，正是負 covariance 的機制。它降低總數 variance，卻不改變兩位置的邊際均勻性。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.28 Bernoulli 與 Binomial 的假設

Bernoulli(p) 變數 $I \in \{0,1\}$，$P(I=1)=p$，有 $EI=p, \operatorname{Var} I = p(1-p)$。

若 $I_1,\dots,I_n$ mutually independent（任意 0/1 outcome tuple 的 joint mass 等於各 marginal mass 的乘積）、各有相同 $p \in [0,1]$，令 $X=\sum I_i$。每一個恰 k successes 的位置集合，其字串機率是 $p^k(1-p)^{n-k}$，共有 $\binom{n}{k}$ 個，所以

$$P(X=k)=\binom{n}{k}p^k(1-p)^{n-k}.$$

這是 Binomial(n,p)，$n \geq 0$。在 $p=0,1$ 時直接按 deterministic 分布解讀端點。

由 indicator 線性期望與 independence 消掉 cross covariance，

$$EX=np, \qquad \operatorname{Var}(X)=np(1-p).$$

僅有相同邊際或僅兩兩獨立，都不保證完整 PMF 是這個二項式。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.29 Geometric 分布與尾機率

重複獨立 Bernoulli(p)，$0 < p \le 1$，令 T 是首次 success 的試驗次數，support 從 1 開始：

$$P(T = t) = (1-p)^{t-1}p, \quad t = 1, 2, \dots$$

因先 $t-1$ 次失敗再 success。令 $q = 1 - p < 1$，幾何級數給總 mass $p \sum_{j \ge 0} q^j = 1$。

Tail 為 $P(T > k) = q^k$，因前 k 次都失敗。對正整數值 T，逐點恆等式 $T = \sum_{k \ge 0} \mathbf{1}_{\{T > k\}}$ 給

$$ET = \sum_{k \ge 0} P(T > k) = \sum_{k \ge 0} q^k = 1/p.$$

這裡以非負項換序；若 $p = 0$，永不 success，並不是有限整數 support 上已 normalization 的幾何分布。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.30 Geometric 的二階動差

逐點 $T^2 = \sum_{k=0}^{T-1}(2k+1)$，所以

$$E[T^2] = \sum_{k \geq 0} (2k+1) q^k.$$

設 $S = \sum_{k \geq 0} k q^k$，以 $S - qS = \sum_{k \geq 1} q^k = q/(1-q)$，得 $S = q/(1-q)^2$。因此

$$E[T^2] = \frac{2q}{(1-q)^2} + \frac{1}{1-q} = \frac{2-p}{p^2},$$

$$\mathrm{Var}(T) = E[T^2] - (ET)^2 = \frac{1-p}{p^2}.$$

例如 $p = 1/4$ 時 mean 4、variance 12；$p = 1$ 時 $T = 1$，mean 1、variance 0，與公式一致。若把 support 改成「成功前的失敗次數」$T - 1$，mean 也要減 1。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.31 Markov 與 Chebyshev：由指示函數直接證明

對非負 Y、$a > 0$，逐點有 $Y \geq a\mathbf{1}_{\{Y \geq a\}}$，所以

$$P(Y \geq a) \leq E[Y]/a.$$

這是 Markov inequality；若想得到有用有限界，需 $EY < \infty$，最後也可與 1 取小者。

若 X 有有限 variance，取 $Y = (X - EX)^2$、$a = t^2, t > 0$，得

$$P(|X - EX| \geq t) \leq \mathrm{Var}(X)/t^2.$$

這是 Chebyshev。它不要求特定分布或 independence，只用非負平方與有限二階動差。若 variance 很大或 t 太小，右側可能大於 1，界仍正確但不精細。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

3.32 Joint、marginal 與 conditional PMF

對離散 X, Y，joint mass $p(x,y) = P(X=x, Y=y)$。對不相交的 fibers 求和給

$$p_X(x) = \sum_y p(x,y), \qquad p_Y(y) = \sum_x p(x,y).$$

若 $p_Y(y) > 0$，conditional mass 是 $p_{X|Y}(x|y) = p(x,y)/p_Y(y)$，並定 $E[X|Y=y] = \sum_x x\, p_{X|Y}(x|y)$，假設所需絕對和有限。

因此按 Y 的 partition 分組：

$$E[X] = \sum_y E[X|Y=y]\, p_Y(y).$$

這是 total expectation，不需要 X, Y independent。零機率的 y 不必定義這個 conditional，也不必出現在 sum 中。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.33 Total variance 的交叉項為什麼消失

設 $E[X^2] < \infty$，令 $m(y) = E[X|Y = y]$。在 $Y = y$ 下，

$$X - EX = (X - m(y)) + (m(y) - EX).$$

平方取 conditional expectation，cross term 為

$$2(m(y) - EX)\, E[X - m(y)|Y = y] = 0.$$

故 $E[(X - EX)^2|Y = y] = \mathrm{Var}(X|Y = y) + (m(y) - EX)^2$。

再依 Y 加權求和，得到

$$\mathrm{Var}(X) = E[\mathrm{Var}(X|Y)] + \mathrm{Var}(E[X|Y]).$$

右邊第一項是各群內的變異平均，第二項是群間 conditional means 的變異；不能只平均群內 variances 就當全部 variance。

公式兩側都有有限值：由 conditional variance 非負，$m(y)^2 \le E[X^2|Y = y]$，再加權給 $E[m(Y)^2] \le E[X^2] < \infty$，所以沒有以未定義的 $\infty - \infty$ 相減。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

3.34 本章推理與算例的連結

集合運算以任意元素的 predicate 證明；Venn 數值以非空 regions 分割核對。機率再給每個 outcome 質量，不能由幾何面積或可能值個數猜出等可能。

Conditional 公式先檢查正分母與 partition；independence 先寫明兩事件、pairwise 或 mutual。期望線性不要求獨立，variance 分解則要保留 covariance；每個 distribution 的 support 和生成實驗都是其前提。

獨立練習與詳解 PDF 分別提供新資料及完整推導，有限枚舉只能驗算指定模型，不能取代一般公理證明。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

參考資料與署名

Ralph P. Grimaldi. Discrete and Combinatorial Mathematics: An Applied Introduction, 5th Edition, 2004.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study