Matrix as data

灰階影像可表示成 $A \in \mathbb{R}^{m \times n}$，entry 是 pixel intensity。彩色影像通常是 tensor；處理時要明示如何拆成 matrices。

外積型矩陣的秩至多為 1；只有兩個向量皆非零時才是 rank-one matrix：

$$uv^T = \begin{bmatrix} u_1 \\ \vdots \\ u_m \end{bmatrix} \begin{bmatrix} v_1 & \cdots & v_n \end{bmatrix},$$

$$(uv^T)_{ij} = u_i v_j.$$

只需 $m + n$ 個 scalars，而不是 mn 個 entries。SVD 把一般 matrix 寫成 rank-one pieces 的加權和；大的 singular values 常攜帶主要結構。

SVD statement

任一

$$A \in \mathbb{R}^{m \times n}, \qquad \operatorname{rank} A = r,$$

皆有 full SVD：

$$A = U \Sigma V^T.$$

$$U \in \mathbb{R}^{m \times m}, \qquad V \in \mathbb{R}^{n \times n},$$

正交 columns。Σ 的 nonzero diagonals：

$$\sigma_1 \geq \cdots \geq \sigma_r > 0.$$

Reduced SVD：

$$A = U_r \Sigma_r V_r^T,$$

$$U_r \in \mathbb{R}^{m \times r}, \quad \Sigma_r \in \mathbb{R}^{r \times r}, \quad V_r \in \mathbb{R}^{n \times r}.$$

Rank deficient 時 zero singular values 補滿 full Σ。

SVD statement （續）

完整 Σ 的尺寸是 $m \times n$，共列 $q = \min(m, n)$ 個奇異值，後 $q - r$ 個為零。這裡的 reduced SVD 採秩 r 的精簡形式；另一種常見的 thin SVD 會保留 q 個方向，包括零奇異值，閱讀不同軟體介面時需辨明尺寸。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

由 $A^T A$ 建 right singular vectors

$$x^T A^T A x = \|Ax\|^2 \geq 0.$$

因此 $A^T A$ symmetric positive semidefinite。Spectral decomposition：

$$A^T A = V \Lambda V^T.$$

取

$$\lambda_1 \geq \cdots \geq \lambda_r > 0,$$

$$\sigma_i = \sqrt{\lambda_i}.$$

對 $i \leq r$：

$$\|Av_i\|^2 = v_i^T A^T A v_i = \sigma_i^2,$$

所以 $Av_i \neq 0$。

$v_1, \ldots, v_r$ 是 row space 的 orthonormal basis；$v_{r+1}, \ldots, v_n$ 是 nullspace 的 orthonormal basis。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Left singular vectors

定義

$$u_i = \frac{Av_i}{\sigma_i}.$$

對 $i \neq j$，Orthogonality：

$$\sigma_i \sigma_j u_i^T u_j = v_i^T A^T A v_j = \lambda_j v_i^T v_j = 0.$$

長度：

$$\|u_i\|^2 = \frac{\|Av_i\|^2}{\sigma_i^2} = 1.$$

因此

$$Av_i = \sigma_i u_i.$$

$u_1, \ldots, u_r$ 是 column space 的 orthonormal basis；其餘 $u_{r+1}, \ldots, u_m$ 是 left nullspace 的 orthonormal basis。

現在補齊 SVD 存在性。令 $V = [v_1, \ldots, v_n]$ 為 $A^T A$ 的完整標準正交特徵基底。對 $i > r$，

Left singular vectors (續)

$$\|Av_i\|^2 = v_i^T A^T A v_i = 0$$

故 $Av_i = 0$。再用任意標準正交基底把 $u_1, \ldots, u_r$ 補成 $\mathbb{R}^m$ 的完整基底。寫任意 $x = \sum_{j=1}^{n} c_j v_j$，得

$$Ax = \sum_{j=1}^{r} c_j Av_j = \sum_{j=1}^{r} c_j \sigma_j u_j = U \Sigma V^T x.$$

這逐個驗證了右奇異向量、左奇異向量、奇異值及分解本身，不只是宣稱存在。

A^TA 與 AA^T

$$AA^T = U\Sigma\Sigma^T U^T.$$

因此 A^TA 與 AA^T 有相同的正特徵值 σ_i^2，也有相同 rank；兩者的零特徵值重數可不同。A 本身的正奇異值是 Gram 矩陣正特徵值的平方根，不能把 σ_i^2 直接叫作 A 的奇異值。

這說明 SVD 的 universal structure：

- A^TA 給 V；
- AA^T 給 U；
- 兩個 Gram 矩陣共享正特徵值 σ_i^2，不能和 A 的奇異值混用；
- rectangular、rank-deficient matrices 都有 SVD。

實作通常不形成 A^TA，因會平方 conditioning，甚至 overflow。Stable routines 使用 bidiagonalization 與 Golub-Kahan-type methods。

Rank-one expansion

Reduced SVD：

$$A = \sum_{i=1}^{r} \sigma_i u_i v_i^T.$$

Frobenius 內積定義為 $\langle B, C\rangle_F = \operatorname{tr}(B^TC) = \sum_{ij} B_{ij}C_{ij}$，範數為 $\|B\|_F = \sqrt{\sum_{ij} B_{ij}^2}$。不同 terms 在此內積下 orthogonal：

$$\langle u_i v_i^T, u_j v_j^T\rangle_F = 0, \quad i \neq j.$$

所以

$$\|A\|_F^2 = \sum_i \sigma_i^2.$$

截斷到 k terms 保留的能量比例：

$$\frac{\sum_{i=1}^{k} \sigma_i^2}{\sum_{i=1}^{r} \sigma_i^2}.$$

Rank-one expansion （續）

此比例要求 $A \neq 0$，否則分母為零。另定義核範數 $\|A\|_* = \sum_i \sigma_i$，它與 Frobenius 範數不同。Energy fraction 只表示 squared singular values 的比例；實際影像品質仍取決於重建誤差與下游任務。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

截斷 SVD：保留哪些方向，捨棄哪些誤差？

設實矩陣 A 的秩為 r，奇異值依大小排列。限制近似矩陣的秩至多 k，先考慮 $1 \leq k < r$。截斷 SVD 保留前 k 個項：

$$A_k = \sum_{i=1}^{k} \sigma_i u_i v_i^T, \qquad E = A - A_k = \sum_{i=k+1}^{r} \sigma_i u_i v_i^T.$$

每個被保留的方向滿足 $A_k v_i = A v_i$；被刪方向則有 $A_k v_i = 0$，故誤差沿該方向為 $E v_i = \sigma_i u_i$。這給出一個候選答案，還沒有證明任意其他秩 k 矩陣都不能更好。

以下固定 $A = \mathrm{diag}(9, 4, 1)$、k=1，則 $A_1 = \mathrm{diag}(9, 0, 0)$、$E = \mathrm{diag}(0, 4, 1)$。先弄清兩種誤差怎麼量，再分別證明它們的下界。此處 $u_i = v_i = e_i$，一般矩陣的左右方向則可能不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

同一個誤差矩陣，兩種範數各在量什麼？

對 $E = \mathrm{diag}(0, 4, 1)$，三個標準單位方向的誤差如下：

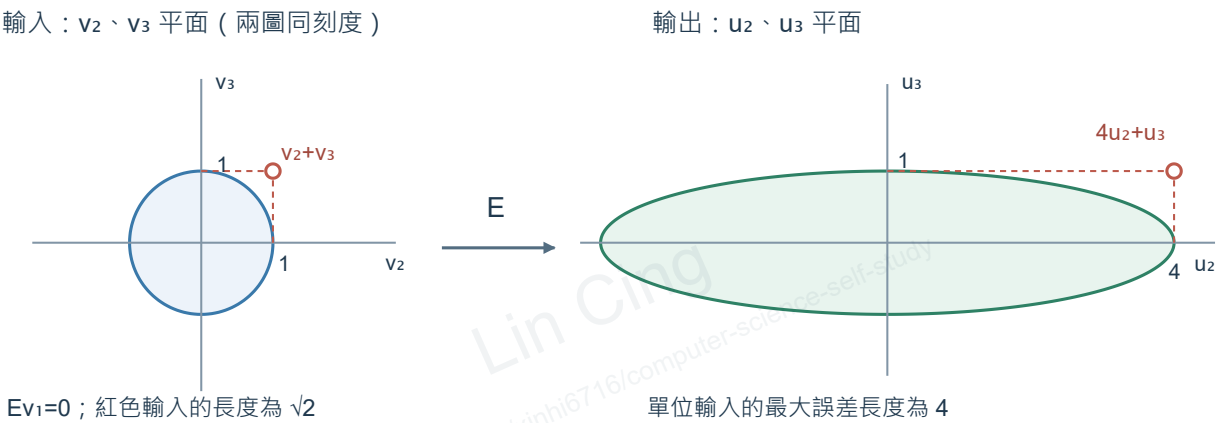
單位輸入	誤差輸出	長度平方
e_1	0	0
e_2	$4e_2$	16
e_3	e_3	1

Spectral norm（矩陣二範數）問：**所有單位輸入中，最大的誤差有多長**？若 $\|x\| = 1$，

$$\|Ex\|^2 = 16x_2^2 + x_3^2 \le 16(x_1^2 + x_2^2 + x_3^2) = 16.$$

取 $x = e_2$ 達等號，所以 $\|E\|_2 = 4$。Frobenius norm 則將各欄誤差平方相加：$\|E\|_F^2 = 0 + 16 + 1 = 17$，故 $\|E\|_F = \sqrt{17}$。它不是另一個「最大單位輸出長度」。

誤差橢圓：√17 為什麼不是最長半軸？



因 $Ev_1 = 0$，三維單位球先在 v₂、v₃ 平面投成單位圓盤，經 E 後成為圖中的橢圓盤。最長輸出半軸是 4。紅點的輸入是 $v_2 + v_3$，長度為 $\sqrt{2}$，輸出長度雖為 $\sqrt{17}$，卻不符合二範數「輸入長度為 1」的條件。正規化後的輸出長度為 $\sqrt{17/2} < 4$。

二範數下界：k 個方向，無法保住 k+1 維

讓 B 是任意秩至多 k 的近似，不要求與 A 共享奇異向量。取 $S = \operatorname{span}\{v_1, \dots, v_{k+1}\}$。B 限制在 S 上的秩至多 k，由秩與零度定理，存在單位向量 $z \in S$ 使 $Bz = 0$。

寫 $z = \sum_{i=1}^{k+1} c_i v_i$，其中 $\sum_i c_i^2 = 1$。左奇異向量正交，故

$$\|(A-B)z\|^2 = \|Az\|^2 = \sum_{i=1}^{k+1} \sigma_i^2 c_i^2 \geq \sigma_{k+1}^2.$$

因此 $\|A-B\|_2 \geq \sigma_{k+1}$。本例即使取非對角的 $B = \begin{bmatrix} 9 & 9 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$，仍可用 $z = (1,-1,0)^T/\sqrt{2}$：$Bz = 0$，而 $\|Az\|^2 = (81+16)/2 = 97/2 \geq 16$。下界不是只檢查對角候選矩陣所得。

Frobenius 下界：先把每一欄誤差拆成直角

令 P 為投影到 $C(B)$ 的正交投影。對每一欄 a_j, b_j，有 $Pb_j = b_j$，所以

$$a_j - b_j = (I-P)a_j + (Pa_j - b_j).$$

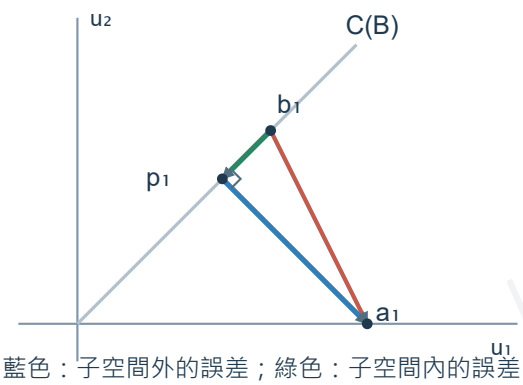
第一項垂直於 $C(B)$，第二項在 $C(B)$ 內。逐欄用畢氏定理，再相加：

$$\|A-B\|_F^2 = \|(I-P)A\|_F^2 + \|PA-B\|_F^2 \geq \|(I-P)A\|_F^2.$$

這與向量投影的道理相同：先找到最近的投影點；若還選子空間裡別的點，就會多一段平方誤差。又因 P 與 I−P 正交互補，

$$\|(I-P)A\|_F^2 = \|A\|_F^2 - \|PA\|_F^2 = \sum_{i=1}^{r} \sigma_i^2 - \operatorname{tr}(PAA^T).$$

同一欄的投影圖：45 = 81/2 + 9/2



藍色：子空間外的誤差；綠色：子空間內的誤差

同一欄，畫在前兩個座標的平面

$a_1=(9,0,0)$, $b_1=(6,6,0)$

$p_1=Pa_1=(9/2,9/2,0)$

$a_1-b_1 = (a_1-p_1) + (p_1-b_1)$

$a_1-p_1 \perp p_1-b_1$

$45 = 81/2 + 9/2$

本圖取 $C(B)=\text{span}\{(1,1,0)^T\}$，$a_1=(9,0,0)^T$、$b_1=(6,6,0)^T$，投影 $p_1=Pa_1=(9/2,9/2,0)^T$。所以 $a_1-b_1=(3,-6,0)^T$，拆成 $(9/2,-9/2,0)^T+(-3/2,-3/2,0)^T$。兩項內積為零，平方長度恰為 $45=81/2+9/2$。這只是一欄的分解；Frobenius 誤差還要對全部欄相加。

投影最多能留下多少平方和？

將左奇異向量補成 $\mathbb{R}^m$ 的正交單位基底，對 i>r 設 $\sigma_i=0$。令 $\alpha_i=u_i^TPu_i=\|Pu_i\|^2$，則

$$0\le\alpha_i\le 1,\qquad \sum_{i=1}^{m}\alpha_i=\text{tr}\,P=\text{rank}\,P\le k.$$

可把 α_i 想成分給方向 i 的投影額度：每方向至多 1，總額至多 k。較大的 σ_i^2 每單位額度貢獻較多。本例取 k=1，沿用前頁的投影：

方向	σ_i^2	額度 α_i	留下的平方和
$u_1=e_1$	81	1/2	81/2
$u_2=e_2$	16	1/2	8
$u_3=e_3$	1	0	0

總額度為 1，卻只留下 $97/2$，小於全部分給第一方向的 81。投影到任意其他一維子空間也不能超過 81；下一頁證明一般 k 的上界。

將「保留最大的 k 項」寫成完整不等式

沿用 $0 \le \alpha_i \le 1$、$\sum_i \alpha_i \le k$。前 k 項的奇異值至少為 σ_k，其餘至多為 σ_k，因此：

$$\begin{aligned}\operatorname{tr}(PAA^T) &= \sum_{i=1}^{m} \sigma_i^2 \alpha_i \\ &\le \sum_{i=1}^{k} \sigma_i^2 \alpha_i + \sigma_k^2 \sum_{i=k+1}^{m} \alpha_i \\ &\le \sum_{i=1}^{k} \left[\sigma_i^2 \alpha_i + \sigma_k^2 (1-\alpha_i)\right] \le \sum_{i=1}^{k} \sigma_i^2.\end{aligned}$$

依序使用：尾端奇異值不大於 σ_k、總額度不超過 k、以及 $\sigma_i^2 \ge \sigma_k^2$ 與 $0 \le \alpha_i \le 1$。代回逐欄畢氏下界，得到 $\|A-B\|_F^2 \ge \sum_{i=k+1}^{r} \sigma_i^2$。

Eckart–Young：截斷同時達到兩種下界

對所有秩至多 k 的 B，前兩個證明已給下界；截斷 SVD 的誤差 E 恰有被刪的奇異值，因此同時達等號：

$$\min_{\operatorname{rank} B \le k} \|A-B\|_2 = \sigma_{k+1}, \qquad \min_{\operatorname{rank} B \le k} \|A-B\|_F^2 = \sum_{i=k+1}^{r} \sigma_i^2.$$

本例 $A = \operatorname{diag}(9,4,1)$	二範數最小誤差	Frobenius 最小誤差
k=0，只能取 B=0	9	$\sqrt{98}$
k=1	4	$\sqrt{17}$
k=2	1	1
k≥3，可取 B=A	0	0

證明主體使用 $1 \le k < r$。k=0 時不用 σ_k；直接取唯一的秩零矩陣。k≥r 時誤差為零。多補一個零奇異值也不改變結果，所以原先 9、4、1、0 的例子仍有相同的 k=1、2、3 誤差。

最優矩陣是否唯一，要先說使用哪種範數

仍取 A=diag(9,4,1)，考慮 $B_c = \mathrm{diag}(c, 0, 0)$。只要 $5 \le c \le 13$，它的秩為 1，而且

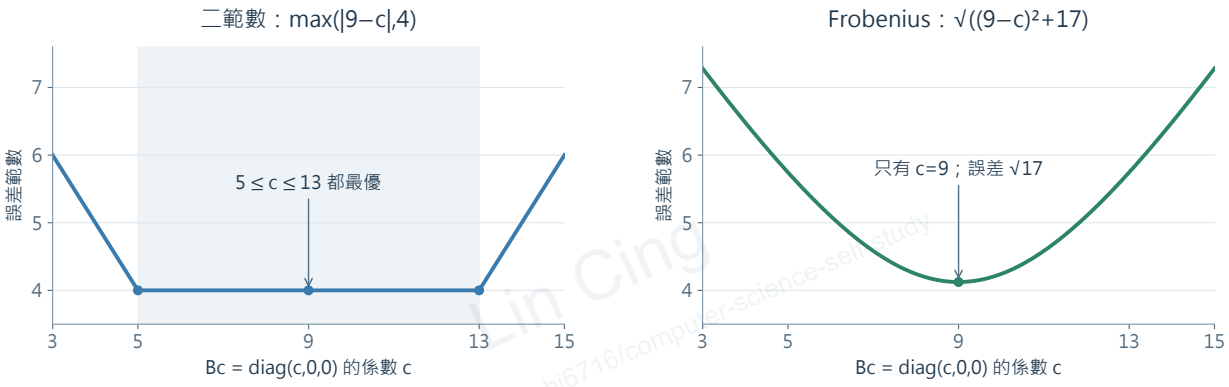
$$\|A - B_c\|_2 = \max\{|9 - c|, 4, 1\} = 4.$$

這整族都達到全域二範數下界。雖然 $9 > 4$ 有嚴格間隔，最佳矩陣仍不唯一。另一方面，

$$\|A - B_c\|_F^2 = (9 - c)^2 + 17$$

在這族中只於 c=9 最小。一般而言，$1 \le k < r$ 且 $\sigma_k > \sigma_{k+1}$ 時，Frobenius 最佳矩陣確實唯一：跡上界取等迫使前 k 個 $\alpha_i = 1$、其餘為 0；而畢氏等式也迫使 B=PA，故 B=A_k。若截斷切過正奇異值的相等區段，可在該完整奇異子空間內選不同保留方向；完整子空間固定，選入的部分可以不同。

同一族候選矩陣，兩種目標畫成曲線



兩圖使用同一組 B_c，只改變評分方式。左圖一整段水平，是因為被捨棄的第二方向已造成誤差 4；第一方向只要不超過它，就不再改變最大值。右圖仍計入第一方向的平方誤差，所以只有 c=9 最佳。圖只展示這一族，沒有宣稱列盡所有二範數最優矩陣。

Low-rank compression cost

Rank-k factors 需要：

$$mk + nk + k = k(m + n + 1)$$

個 raw scalars，加上 finite-precision metadata。只有這個 count 小於 mn 時，raw storage 才可能下降。

1000×1000 影像、rank 10 約有 2.001×10^4 個 numbers，替代 10^6 entries。實際 format 還需 quantized coefficients、headers 與 error handling。

Random full-rank data 通常不易壓縮；compressibility 是 data property，不是 SVD 自動產生的 property。

PCA 的資料方向

令

$$A_0 \in \mathbb{R}^{m \times n},$$

rows 是 variables，columns 是 samples。Row means μ_j，centered matrix：

$$A_{js} = (A_0)_{js} - \mu_j.$$

第一 principal direction u_1 最大化 scores

$$s_1 = u_1^T A$$

的 squared sum：

$$\|u_1^T A\|^2 = u_1^T A A^T u_1.$$

在 $\|u_1\| = 1$ 下，由 spectral theorem，最大值是 σ_1^2，u_1 是 AA^T 的 dominant eigenvector，也是 first left singular vector。

PCA scores 與 sign ambiguity

由

$$A = U\Sigma V^T$$

得 principal scores：

$$S = \Sigma V^T = U^T A.$$

第 i row 是 sample 在 component i 的 score；squared norm 與 σ_i^2 相關。

若同時把 u_i, v_i 都乘 -1，factorization 不變；單獨翻轉其中一個則改變重建。Individual sign 沒有 intrinsic meaning。

Repeated singular values 時，subspace 內 axes 不唯一。比較兩次 PCA 應比較 subspace angle，不能硬配 column number。

Covariance denominator

Rows 為 variables、n samples：

$$\widehat{C}_{n-1} = \frac{1}{n-1} AA^T,$$

或 population/descriptive：

$$\widehat{C}_n = \frac{1}{n} AA^T.$$

Eigenvectors 相同，eigenvalues 只差 $n/(n-1)$。$n = 1$ 時 $n - 1 = 0$，sample variance 無定義。

Variable units 不同時，raw PCA 會偏向大 variance 或大 unit 的 features。Standardization 可得到 correlation-based PCA，但會改變原始 geometry，屬 modeling decision。

二維 PCA 例子

Samples：

$$(-1,-1),\quad (0,1),\quad (1,0).$$

Centered matrix：

$$A=\begin{bmatrix}-1 & 0 & 1\\ -1 & 1 & 0\end{bmatrix}.$$

$$AA^T=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}.$$

$$u_1=(1,1)^T/\sqrt{2},\qquad u_2=(1,-1)^T/\sqrt{2}.$$

Scores：

$$s_1=\begin{bmatrix}-\sqrt{2} & 1/\sqrt{2} & 1/\sqrt{2}\end{bmatrix},$$
$$s_2=\begin{bmatrix}0 & -1/\sqrt{2} & 1/\sqrt{2}\end{bmatrix}.$$

s_1, s_2 orthogonal，squared sums 是 $3, 1$。

奇異向量如何決定橢圓的軸

輸入與輸出各用一組標準正交基底，兩組方向一般不同。取

$$V=\frac{1}{5}\begin{bmatrix}4 & -3\\ 3 & 4\end{bmatrix},\qquad U=\frac{1}{5}\begin{bmatrix}3 & -4\\ 4 & 3\end{bmatrix},\qquad \Sigma=\operatorname{diag}(3,2).$$

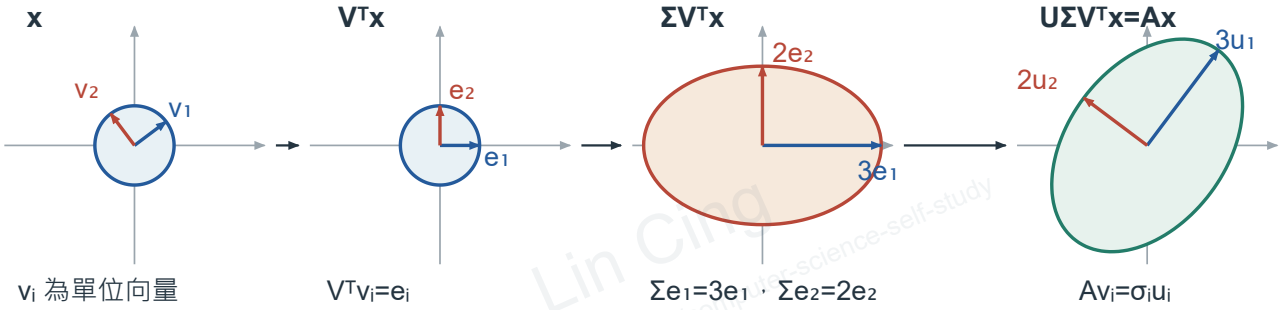
這裡 $V^TV=U^TU=I$，而

$$A=U\Sigma V^T=\frac{1}{5}\begin{bmatrix}12 & -1\\ 6 & 12\end{bmatrix}.$$

下圖所有面板使用相同座標比例。先以 V^T 把輸入方向 v_i 送到 e_i，再伸縮，最後以 U 改變輸出方向。圓集合經旋轉仍是同一個圓，但標記的向量方向確實改變；不能因圓的外觀不變就省略這一步。

奇異向量如何決定橢圓的軸 （續）

SVD：輸入方向 → 標準座標 → 伸縮 → 輸出方向



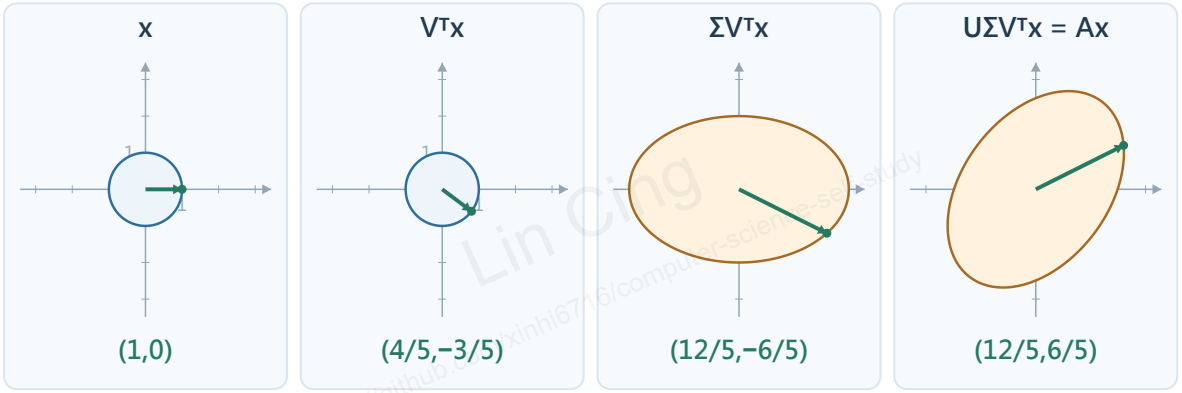
兩條軸可逐項驗算：

$$v_1 = (4/5, 3/5)^T, \quad Av_1 = (9/5, 12/5)^T = 3u_1,$$
$$v_2 = (-3/5, 4/5)^T, \quad Av_2 = (-8/5, 6/5)^T = 2u_2.$$

所以圖中的半軸向量是 $3u_1$、$2u_2$，單位向量 u_1, u_2 只決定方向。圖形以圓周映射呈現邊界；本例滿秩，單位圓盤則映成填滿的橢圓盤。

追蹤一個不沿奇異方向的單位向量

沿用前例的 U, V, Σ，取 $x = (1, 0)^T$。這個 x 不是 v_1 或 v_2。綠色箭頭追蹤同一點，背景曲線是單位圓在各步的像。



四面板同尺度；綠色向量追蹤同一個輸入的逐步變化。

算值與長度變化要分開核對

步驟	代入後的座標	範數平方
輸入 x	(1,0)	1
VTx	(4/5,−3/5)	1
ΣVTx	(12/5,−6/5)	36/5
UΣVTx=Ax	(12/5,6/5)	36/5

V^T、U 只改變方向；伸縮由 Σ 產生。本例 $\|Ax\| = 6/\sqrt{5}$，不是任何一個奇異值。

對任意單位輸入，令 $w = V^T x$，則 $w_1^2 + w_2^2 = 1$，且

$$\|Ax\|^2 = 9w_1^2 + 4w_2^2 = 4 + 5w_1^2 \in [4, 9].$$

所以 $2 \le \|Ax\| \le 3$；上界在 $x = \pm v_1$ 取到，下界在 $x = \pm v_2$ 取到。這是對所有單位輸入的證明，不是由單一數例推論。

SVD 幾何：可重算的直角旋轉例

對單位球 $\|x\| \le 1$：

$$y = Ax = U\Sigma V^T x.$$

三步對應同一組 v_i, u_i。本頁取

$$V = I, \quad \Sigma = \mathrm{diag}(3, 2), \quad U = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}, \qquad A = U\Sigma V^T = \begin{bmatrix} 0 & -2 \\ 3 & 0 \end{bmatrix}.$$

依序作用：

1. $V^T x = Ix$：輸入座標不變，圓盤與座標軸重疊；
2. $\Sigma(V^T x) = (3x_1, 2x_2)$：沿正交座標方向伸縮，圓盤成為半軸 $3, 2$ 的橢圓；
3. $U\Sigma V^T x$：把橢圓旋轉，並將標準軸送到 $u_1 = (0,1)^T, u_2 = (-1,0)^T$。

由定義可逐項核對：

$$v_1 = (1,0)^T, \quad Av_1 = (0,3)^T = 3u_1,$$
$$v_2 = (0,1)^T, \quad Av_2 = (-2,0)^T = 2u_2.$$

SVD 幾何：可重算的直角旋轉例 （續）

因此像是 $C(A)$ 內的填滿橢球，半軸長為正奇異值；二維滿秩時邊界為橢圓。單位球面在具有零空間時可能映到填滿橢球，不能一概稱為橢球面。最大 singular value：

$$\|Av_1\| = \sigma_1.$$

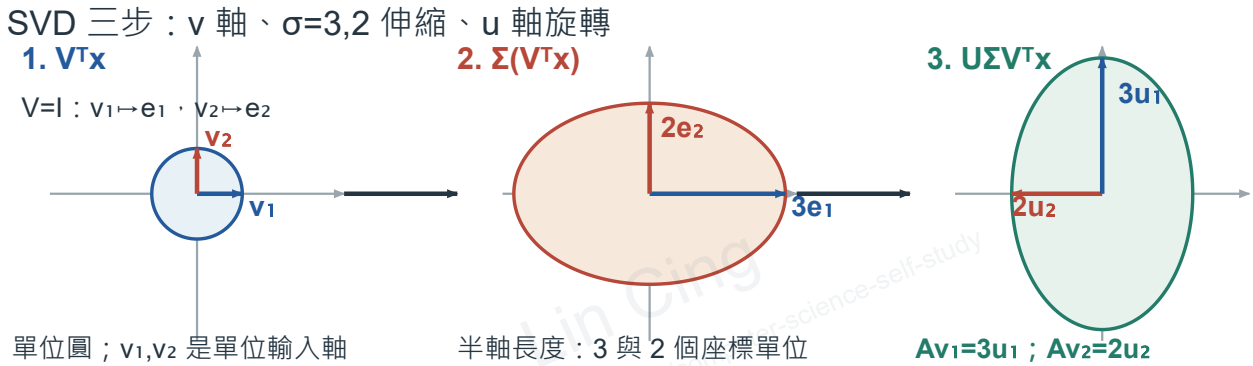
Matrix norm：

$$\|A\|_2 = \sigma_1.$$

Image ellipse 的 semi-axis lengths 是 singular values。最小 positive σ_r 控制 row space 到 column space 的最弱 growth。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

SVD 幾何：可重算的直角旋轉例 （續）



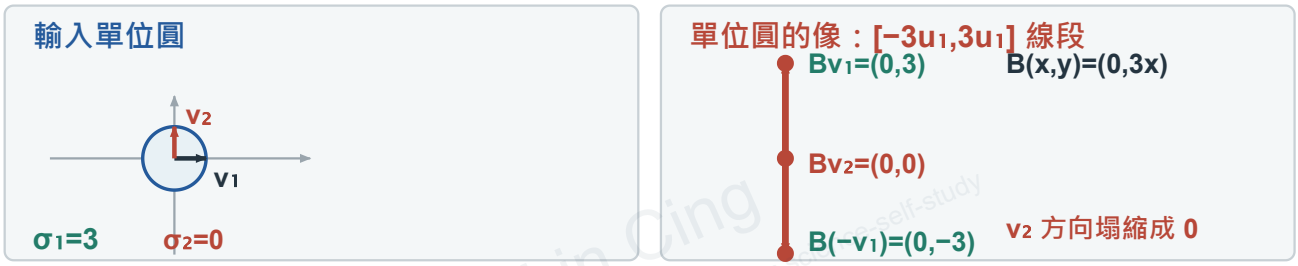
秩不足示例取

$$B = \begin{bmatrix} 0 & 0 \\ 3 & 0 \end{bmatrix} = U\,\mathrm{diag}(3,0)V^T.$$

此時 $Bv_1 = (0,3)^T$，而 $Bv_2 = 0$。單位圓盤的像不是橢圓盤；v_2 方向塌縮成原點後，其餘點落在從 $(0,-3)^T$ 到 $(0,3)^T$ 的完整線段。

SVD 幾何：可重算的直角旋轉例 （續）

秩不足 SVD：B=[[0,0],[3,0]]，$\sigma_2=0$ 塌縮



rank(B)=1；整個像為直線，單位圓的像才是線段

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Spectral norm 與 condition number

$$\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

對

$$x = \sum_i c_i v_i,$$

$$\|Ax\|^2 = \sum_i \sigma_i^2 |c_i|^2 \leq \sigma_1^2 \|x\|^2.$$

$x = v_1$ 時等號成立，所以

$$\|A\|_2 = \sigma_1.$$

對可逆方陣，或明確把長方矩陣的條件數定義為 $\|A\|_2 \|A^+\|_2$ 且 A 滿 column rank 時：

$$\kappa_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Spectral norm 與 condition number （續）

正交矩陣的奇異值全為 1，所以 $\kappa_2 = 1$。秩不足時，原來要求逆的全空間映射已非單射；不能把略去零奇異值後的有限比值當成原問題的可逆條件數。固定限制在 row space 到 column space 的可逆映射可另談正奇異值比，但那是已限制子空間的不同問題。一般最小平方解對資料的相對敏感度還受殘差與投影角度影響，不只由這個比值決定。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Distance to singularity 與 numerical rank

本頁先限定可逆方陣 $A \in \mathbb{R}^{n \times n}$。把 smallest singular value 對應的 $\sigma_n u_n v_n^T$ 刪掉：

$$\|A - A_0\|_2 = \sigma_n.$$

因此 σ_n 是 spectral norm 下到 singular matrices 的 distance。rank 至多 k 的最近 matrix 是 A_k，distance σ_{k+1}。

Numerical rank 用 tolerance τ：

$$\sigma_i > \tau \|A\|.$$

Tolerance 要反映 noise、dimension 與 downstream sensitivity。Singular values stable 不代表 close singular vectors stable；close values 附近尤需小心。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

擾動半徑如何限制數值秩

對相同尺寸矩陣 A, B，令 $\delta = \|A - B\|_2$。由前面的 Eckart–Young 定理，$\sigma_i(A) = \min_{\operatorname{rank} C < i} \|A - C\|_2$。取 B 的最佳低秩近似，三角不等式給

$$\sigma_i(A) \le \|A - B\|_2 + \sigma_i(B).$$

交換 A, B 即得 Weyl 界 $|\sigma_i(A) - \sigma_i(B)| \le \delta$。它是奇異值的絕對擾動界；極小奇異值的相對誤差仍可很大。

設資料 A 與未知真矩陣 B 的距離至多 δ，令 $r_\delta = \#\{i : \sigma_i(A) > \delta\}$。任何這樣的 B 都必有 $\operatorname{rank} B \ge r_\delta$，因前 r_δ 個奇異值仍嚴格為正；同時截斷 A_{r_δ} 的誤差 $\sigma_{r_\delta+1} \le \delta$，所以至少存在一個秩 r_δ 的相容模型。若 $r_\delta = q$，便用 $A_q = A$。

因此 r_δ 是擾動球中可保證的最小秩，不表示所有相容模型的真秩都等於它。例如 $A = \operatorname{diag}(1, 10^{-8}, 10^{-12})$、$\delta = 10^{-10}$，秩 2 的截斷模型相容，原來秩 3 的 A 也相容，資料精度不足以分辨第三個方向是否真的為零。

若應用另固定絕對門檻 t，只有 $\sigma_i(A) > t + \delta$ 或 $\sigma_i(A) < t - \delta$ 的分類才對此擾動穩健；靠近門檻的方向應列為不確定。相對門檻 $t = \tau \|A\|_2$ 還要記錄尺度與雜訊假設。

QR 的主元不是奇異值

精確算術下，$A = Q_1 R$、$Q_1^T Q_1 = I$ 給 $A^T A = R^T R$，故 A 與 R 的奇異值相同。但 R 的對角元素不是奇異值。取

$$R = \begin{bmatrix} 1 & K \\ 0 & 1 \end{bmatrix}, \qquad K \ge 1.$$

兩個對角元素都是 1，卻有 $\|R e_2\|_2 = \sqrt{K^2 + 1}$，所以 $\sigma_{\max} \ge K$。又 $\sigma_{\max}\sigma_{\min} = |\det R| = 1$，故 $\sigma_{\min} \le 1/K$、$\kappa_2(R) \ge K^2$。大非對角元素會讓普通 QR 的對角線無法單獨反映接近相依的程度。

列出 R_{ii} 的大小可作啟發式檢查，不能當成奇異值擾動定理。選 column pivot 的 QR 常用來估計數值秩，但若要保證精度，仍需其明確的秩揭露界或以 SVD 核對。也不能因某個浮點主元非零，就宣稱它代表可信的資料方向。

Polar decomposition

$$A = U\Sigma V^T = (UV^T)(V\Sigma V^T).$$

本頁限定方陣 $A \in \mathbb{R}^{n\times n}$，因此 U, V, Σ 均為 $n \times n$。令

$$Q = UV^T, \qquad S = V\Sigma V^T.$$

Q orthogonal、S symmetric positive semidefinite。所以

$$A = QS.$$

A invertible 時 Σ 全正，S positive definite。$\det Q$ 的正負反映 orientation。Q 類比 rotation 或 reflection，S 類比 stretch。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

Pseudoinverse

Reduced SVD：

$$A = U_r\Sigma_r V_r^T.$$

Moore-Penrose pseudoinverse：

$$A^+ = V_r\Sigma_r^{-1}U_r^T.$$

$$AA^+ = U_rU_r^T, \qquad A^+A = V_rV_r^T.$$

兩者分別是 column space 與 row space 的 orthogonal projection。

Full column rank：

$$A^+ = (A^TA)^{-1}A^T.$$

Full row rank：

$$A^+ = A^T(AA^T)^{-1}.$$

Lin Cing https://github.com/xinhi6716/computer-science-self-study

Pseudoinverse （續）

A^+b 是 minimum-norm least-squares solution。證明：以完整 V 展開 $x = \sum_i c_i v_i$，則 $\|b - Ax\|^2 = \sum_{i=1}^{r}(u_i^T b - \sigma_i c_i)^2 + \sum_{i=r+1}^{m}(u_i^T b)^2$。最小值要求 $c_i = u_i^T b/\sigma_i$（$i \le r$），其餘零空間係數任意；令其餘係數為零使 $\|x\|^2 = \sum_i c_i^2$ 唯一最小，即得 A^+b。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Rank-deficient least squares 結構

$$A = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix} = (1,2)^T(1,1).$$

Normalize：

$$u_1 = (1,2)^T/\sqrt{5}, \qquad v_1 = (1,1)^T/\sqrt{2}.$$
$$A = \sqrt{10}\, u_1 v_1^T.$$

u_1 是輸出方向、v_1 是輸入方向。此例兩者均以 $\mathbb{R}^2$ 座標表示，但不同數值；一般矩形矩陣甚至連所在維度也不同，不能因 rank one 就假設 $u_1 = v_1$。

對 $b = (1,3)^T$：

$$A^T A = \begin{bmatrix} 5 & 5 \\ 5 & 5 \end{bmatrix}, \qquad A^T b = \begin{bmatrix} 7 \\ 7 \end{bmatrix}.$$

所有

$$x_1 + x_2 = 7/5$$

都是 minimizers；$A^T A$ singular，不能直接 invert。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Minimum-norm 解

$$\sigma_1 u_1^T b = \sqrt{10}\frac{1+6}{\sqrt{5}} = 7\sqrt{2}.$$

$$x^+ = A^+ b = \frac{1}{\sigma_1} v_1 u_1^T b = \frac{7}{10}(1,1)^T.$$

Projection：

$$AA^+ b = u_1 u_1^T b = \frac{7}{5}(1,2)^T.$$

Residual：

$$e = b - AA^+ b = \left(-\frac{2}{5}, \frac{1}{5}\right)^T.$$

$$e^T(1,2) = 0,$$

所以 residual 與 column space 正交。

Numerical workflow

SVD workflow：

1. 檢查 shape、missing values、units；
2. PCA 要先 center，必要時 standardize；
3. 使用 stable SVD，不形成 normal equations；
4. 看 singular-value gaps 與 numerical rank；
5. 依 error budget 選 k；
6. 在 held-out data 或 downstream task 驗證。

Sign 可翻轉，repeated singular values 的 axes 可 rotate。SVD 是 linear reconstruction，不自動提供 causal importance 或 fairness guarantee。

Four subspaces

空間	Ambient space	SVD basis	Dimension
row space	$\mathbb{R}^n$	$v_1, \dots, v_r$	r
nullspace	$\mathbb{R}^n$	$v_{r+1}, \dots, v_n$	$n-r$
column space	$\mathbb{R}^m$	$u_1, \dots, u_r$	r
left nullspace	$\mathbb{R}^m$	$u_{r+1}, \dots, u_m$	$m-r$

u_i 與 v_i 位於不同 spaces，不直接比較 inner product，除非 $m = n$ 且明確做 coordinate identification。SVD 的 role 是 matched bases：

$$Av_i = \sigma_i u_i.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

章末檢查

讀者應能：

- 由 A^TA 建 v_i，令 $u_i = Av_i/\sigma_i$；
- 補齊 null directions 得到 full SVD；
- 使用 rank-one terms 計算 spectral/Frobenius errors；
- 解釋 PCA 的 center、scores、variance 與 denominator；
- 區分 input/output singular bases；
- 推導 $\|A\|_2$、condition number、distance to singularity；
- 建 polar decomposition 與 pseudoinverse；
- 處理 sign ambiguity、tied singular values 與 numerical rank。

下一章用 basis 和 coordinates 重新解釋 linear transformations。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study