Matrix as data

灰階影像可表示成 $A \in \mathbb{R}^{m \times n}$，entry 是 pixel intensity。彩色影像通常是 tensor；處理時要明示如何拆成 matrices。

外積型矩陣的秩至多為 1；只有兩個向量皆非零時才是 rank-one matrix：

$$uv^T = \begin{bmatrix} u_1 \\ \vdots \\ u_m \end{bmatrix} \begin{bmatrix} v_1 & \cdots & v_n \end{bmatrix},$$

$$(uv^T)_{ij} = u_i v_j.$$

只需 $m + n$ 個 scalars，而不是 mn 個 entries。SVD 把一般 matrix 寫成 rank-one pieces 的加權和；大的 singular values 常攜帶主要結構。

SVD statement

任一

$$A \in \mathbb{R}^{m \times n}, \qquad \operatorname{rank} A = r,$$

皆有 full SVD：

$$A = U \Sigma V^T.$$

$$U \in \mathbb{R}^{m \times m}, \qquad V \in \mathbb{R}^{n \times n},$$

正交 columns。Σ 的 nonzero diagonals：

$$\sigma_1 \geq \cdots \geq \sigma_r > 0.$$

Reduced SVD：

$$A = U_r \Sigma_r V_r^T,$$

$$U_r \in \mathbb{R}^{m \times r}, \quad \Sigma_r \in \mathbb{R}^{r \times r}, \quad V_r \in \mathbb{R}^{n \times r}.$$

Rank deficient 時 zero singular values 補滿 full Σ。

SVD statement （續）

完整 Σ 的尺寸是 $m \times n$，共列 $q = \min(m, n)$ 個奇異值，後 $q - r$ 個為零。這裡的 reduced SVD 採秩 r 的精簡形式；另一種常見的 thin SVD 會保留 q 個方向，包括零奇異值，閱讀不同軟體介面時需辨明尺寸。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

由 $A^T A$ 建 right singular vectors

$$x^T A^T A x = \|Ax\|^2 \geq 0.$$

因此 $A^T A$ symmetric positive semidefinite。Spectral decomposition：

$$A^T A = V \Lambda V^T.$$

取

$$\lambda_1 \geq \cdots \geq \lambda_r > 0,$$

$$\sigma_i = \sqrt{\lambda_i}.$$

對 $i \leq r$：

$$\|Av_i\|^2 = v_i^T A^T A v_i = \sigma_i^2,$$

所以 $Av_i \neq 0$。

$v_1, \ldots, v_r$ 是 row space 的 orthonormal basis；$v_{r+1}, \ldots, v_n$ 是 nullspace 的 orthonormal basis。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Left singular vectors

定義

$$u_i = \frac{Av_i}{\sigma_i}.$$

對 $i \neq j$，Orthogonality：

$$\sigma_i \sigma_j u_i^T u_j = v_i^T A^T A v_j = \lambda_j v_i^T v_j = 0.$$

長度：

$$\|u_i\|^2 = \frac{\|Av_i\|^2}{\sigma_i^2} = 1.$$

因此

$$Av_i = \sigma_i u_i.$$

$u_1, \ldots, u_r$ 是 column space 的 orthonormal basis；其餘 $u_{r+1}, \ldots, u_m$ 是 left nullspace 的 orthonormal basis。

現在補齊 SVD 存在性。令 $V = [v_1, \ldots, v_n]$ 為 $A^T A$ 的完整標準正交特徵基底。對 $i > r$，

Left singular vectors (續)

$$\|Av_i\|^2 = v_i^T A^T A v_i = 0$$

故 $Av_i = 0$。再用任意標準正交基底把 $u_1, \ldots, u_r$ 補成 $\mathbb{R}^m$ 的完整基底。寫任意 $x = \sum_{j=1}^{n} c_j v_j$，得

$$Ax = \sum_{j=1}^{r} c_j Av_j = \sum_{j=1}^{r} c_j \sigma_j u_j = U \Sigma V^T x.$$

這逐個驗證了右奇異向量、左奇異向量、奇異值及分解本身，不只是宣稱存在。

A^TA 與 AA^T

$$AA^T = U\Sigma\Sigma^T U^T.$$

因此 A^TA 與 AA^T 有相同的正特徵值 σ_i^2，也有相同 rank；兩者的零特徵值重數可不同。A 本身的正奇異值是 Gram 矩陣正特徵值的平方根，不能把 σ_i^2 直接叫作 A 的奇異值。

這說明 SVD 的 universal structure：

- A^TA 給 V；
- AA^T 給 U；
- 兩個 Gram 矩陣共享正特徵值 σ_i^2，不能和 A 的奇異值混用；
- rectangular、rank-deficient matrices 都有 SVD。

實作通常不形成 A^TA，因會平方 conditioning，甚至 overflow。Stable routines 使用 bidiagonalization 與 Golub-Kahan-type methods。

Rank-one expansion

Reduced SVD：

$$A = \sum_{i=1}^{r} \sigma_i u_i v_i^T.$$

Frobenius 內積定義為 $\langle B, C\rangle_F = \operatorname{tr}(B^TC) = \sum_{ij} B_{ij}C_{ij}$，範數為 $\|B\|_F = \sqrt{\sum_{ij} B_{ij}^2}$。不同 terms 在此內積下 orthogonal：

$$\langle u_i v_i^T, u_j v_j^T\rangle_F = 0, \quad i \neq j.$$

所以

$$\|A\|_F^2 = \sum_i \sigma_i^2.$$

截斷到 k terms 保留的能量比例：

$$\frac{\sum_{i=1}^{k} \sigma_i^2}{\sum_{i=1}^{r} \sigma_i^2}.$$

Rank-one expansion （續）

此比例要求 $A \neq 0$，否則分母為零。另定義核範數 $\|A\|_* = \sum_i \sigma_i$，它與 Frobenius 範數不同。Energy fraction 只表示 squared singular values 的比例；實際影像品質仍取決於重建誤差與下游任務。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Truncated SVD 與 Eckart-Young

$$A_k = \sum_{i=1}^{k} \sigma_i u_i v_i^T.$$

Remainder：

$$A - A_k = \sum_{i=k+1}^{r} \sigma_i u_i v_i^T.$$

對任何 rank 至多 k 的 B：

$$\|A - B\|_2 \geq \sigma_{k+1},$$

$$\|A - B\|_F \geq \sqrt{\sum_{i=k+1}^{r} \sigma_i^2}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Truncated SVD 與 Eckart-Young （續）

證明 spectral bound：B 在 $\operatorname{span}\{v_1, \dots, v_{k+1}\}$ 上必有非零核向量 z，取 $\|z\| = 1$，則 $\|(A-B)z\| = \|Az\| \geq \sigma_{k+1}$。證明 Frobenius bound：令 P 投影到 $C(B)$，則 $\|A-B\|_F^2 \geq \|(I-P)A\|_F^2 = \|A\|_F^2 - \operatorname{tr}(PAA^T)$。此處將左奇異向量擴充成完整的正交歸一基底 $u_1, \dots, u_m$，並對 $i > r$ 設 $\sigma_i = 0$。寫 $\alpha_i = u_i^T P u_i$，有 $0 \leq \alpha_i \leq 1$、$\sum_{i=1}^m \alpha_i = \operatorname{tr} P = \operatorname{rank} P \leq k$，故 $\operatorname{tr}(PAA^T) = \sum_{i=1}^m \sigma_i^2 \alpha_i \leq \sum_{i=1}^k \sigma_i^2$。$A_k$ 的餘項奇異值恰是尾端項，同時達到兩個下界。此處 $0 \leq k < r$；$k \geq r$ 時最佳誤差為零。

若 $\sigma_k = \sigma_{k+1}$，optimal subspace 不唯一；individual axes 可 rotate，但 tied subspace 仍 well-defined。

以奇異值 $9, 4, 1, 0$ 的矩陣為例，rank 為 3。取 $k = 1$，最佳誤差為

$$\|A - A_1\|_2 = 4, \qquad \|A - A_1\|_F = \sqrt{4^2 + 1^2} = \sqrt{17}.$$

取 $k = 2$ 後兩種誤差都變成 1，取 $k = 3$ 則為零。這個同一組數值同時核對 spectral bound 是最大被刪奇異值、Frobenius bound 是剩餘奇異值平方和開根。

Low-rank compression cost

Rank-k factors 需要：

$$mk + nk + k = k(m + n + 1)$$

個 raw scalars，加上 finite-precision metadata。只有這個 count 小於 mn 時，raw storage 才可能下降。

1000×1000 影像、rank 10 約有 2.001×10^4 個 numbers，替代 10^6 entries。實際 format 還需 quantized coefficients、headers 與 error handling。

Random full-rank data 通常不易壓縮；compressibility 是 data property，不是 SVD 自動產生的 property。

PCA 的資料方向

令

$$A_0 \in \mathbb{R}^{m \times n},$$

rows 是 variables，columns 是 samples。Row means μ_j，centered matrix：

$$A_{js} = (A_0)_{js} - \mu_j.$$

第一 principal direction u_1 最大化 scores

$$s_1 = u_1^T A$$

的 squared sum：

$$\|u_1^T A\|^2 = u_1^T A A^T u_1.$$

在 $\|u_1\| = 1$ 下，由 spectral theorem，最大值是 σ_1^2，u_1 是 AA^T 的 dominant eigenvector，也是 first left singular vector。

PCA scores 與 sign ambiguity

由

$$A = U \Sigma V^T$$

得 principal scores：

$$S = \Sigma V^T = U^T A.$$

第 i row 是 sample 在 component i 的 score；squared norm 與 σ_i^2 相關。

若同時把 u_i, v_i 都乘 -1，factorization 不變；單獨翻轉其中一個則改變重建。Individual sign 沒有 intrinsic meaning。

Repeated singular values 時，subspace 內 axes 不唯一。比較兩次 PCA 應比較 subspace angle，不能硬配 column number。

Covariance denominator

Rows 為 variables、n samples：

$$\widehat{C}_{n-1} = \frac{1}{n-1} AA^T,$$

或 population/descriptive：

$$\widehat{C}_n = \frac{1}{n} AA^T.$$

Eigenvectors 相同，eigenvalues 只差 $n/(n-1)$。$n = 1$ 時 $n - 1 = 0$，sample variance 無定義。

Variable units 不同時，raw PCA 會偏向大 variance 或大 unit 的 features。Standardization 可得到 correlation-based PCA，但會改變原始 geometry，屬 modeling decision。

二維 PCA 例子

Samples：

$$(-1, -1), \quad (0, 1), \quad (1, 0).$$

Centered matrix：

$$A = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 1 & 0 \end{bmatrix}.$$

$$AA^T = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

$$u_1 = (1, 1)^T/\sqrt{2}, \qquad u_2 = (1, -1)^T/\sqrt{2}.$$

Scores：

$$s_1 = \begin{bmatrix} -\sqrt{2} & 1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix},$$
$$s_2 = \begin{bmatrix} 0 & -1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}.$$

s_1, s_2 orthogonal，squared sums 是 $3, 1$。

奇異向量如何決定橢圓的軸

輸入與輸出各用一組標準正交基底，兩組方向一般不同。取

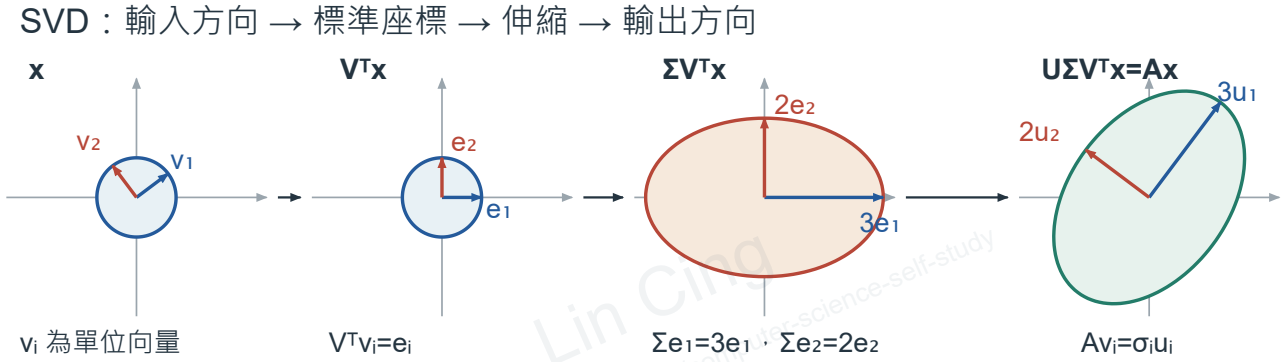
$$V = \frac{1}{5}\begin{bmatrix} 4 & -3 \\ 3 & 4 \end{bmatrix}, \qquad U = \frac{1}{5}\begin{bmatrix} 3 & -4 \\ 4 & 3 \end{bmatrix}, \qquad \Sigma = \operatorname{diag}(3, 2).$$

這裡 $V^TV = U^TU = I$，而

$$A = U\Sigma V^T = \frac{1}{5}\begin{bmatrix} 12 & -1 \\ 6 & 12 \end{bmatrix}.$$

下圖所有面板使用相同座標比例。先以 V^T 把輸入方向 v_i 送到 e_i，再伸縮，最後以 U 改變輸出方向。圓集合經旋轉仍是同一個圓，但標記的向量方向確實改變；不能因圓的外觀不變就省略這一步。

奇異向量如何決定橢圓的軸 （續）



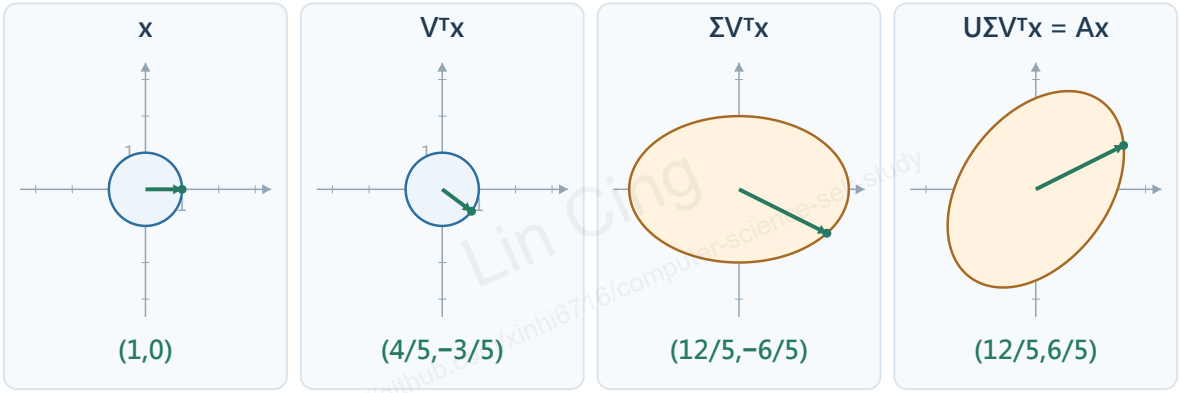
兩條軸可逐項驗算：

$$v_1 = (4/5, 3/5)^T, \quad Av_1 = (9/5, 12/5)^T = 3u_1,$$
$$v_2 = (-3/5, 4/5)^T, \quad Av_2 = (-8/5, 6/5)^T = 2u_2.$$

所以圖中的半軸向量是 $3u_1$、$2u_2$，單位向量 u_1, u_2 只決定方向。圖形以圓周映射呈現邊界；本例滿秩，單位圓盤則映成填滿的橢圓盤。

追蹤一個不沿奇異方向的單位向量

沿用前例的 U, V, Σ，取 $x = (1, 0)^T$。這個 x 不是 v_1 或 v_2。綠色箭頭追蹤同一點，背景曲線是單位圓在各步的像。



四面板同尺度；綠色向量追蹤同一個輸入的逐步變化。

算值與長度變化要分開核對

步驟	代入後的座標	範數平方
輸入 x	(1,0)	1
VᵀX	(4/5,−3/5)	1
ΣVᵀx	(12/5,−6/5)	36/5
UΣVᵀx=Ax	(12/5,6/5)	36/5

V^T、U 只改變方向；伸縮由 Σ 產生。本例 $\|Ax\| = 6/\sqrt{5}$，不是任何一個奇異值。

對任意單位輸入，令 $w = V^T x$，則 $w_1^2 + w_2^2 = 1$，且

$$\|Ax\|^2 = 9w_1^2 + 4w_2^2 = 4 + 5w_1^2 \in [4, 9].$$

所以 $2 \le \|Ax\| \le 3$；上界在 $x = \pm v_1$ 取到，下界在 $x = \pm v_2$ 取到。這是對所有單位輸入的證明，不是由單一數例推論。

SVD 幾何：可重算的直角旋轉例

對單位球 $\|x\| \le 1$：

$$y = Ax = U\Sigma V^T x.$$

三步對應同一組 v_i, u_i。本頁取

$$V = I, \quad \Sigma = \operatorname{diag}(3,2), \quad U = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}, \qquad A = U\Sigma V^T = \begin{bmatrix} 0 & -2 \\ 3 & 0 \end{bmatrix}.$$

依序作用：

1. $V^T x = Ix$：輸入座標不變，圓盤與座標軸重疊；
2. $\Sigma(V^T x) = (3x_1, 2x_2)$：沿正交座標方向伸縮，圓盤成為半軸 $3, 2$ 的橢圓；
3. $U\Sigma V^T x$：把橢圓旋轉，並將標準軸送到 $u_1 = (0,1)^T, u_2 = (-1,0)^T$。

由定義可逐項核對：

$$v_1 = (1,0)^T, \quad Av_1 = (0,3)^T = 3u_1,$$
$$v_2 = (0,1)^T, \quad Av_2 = (-2,0)^T = 2u_2.$$

SVD 幾何：可重算的直角旋轉例 （續）

因此像是 $C(A)$ 內的填滿橢球，半軸長為正奇異值；二維滿秩時邊界為橢圓。單位球面在具有零空間時可能映到填滿橢球，不能一概稱為橢球面。最大 singular value：

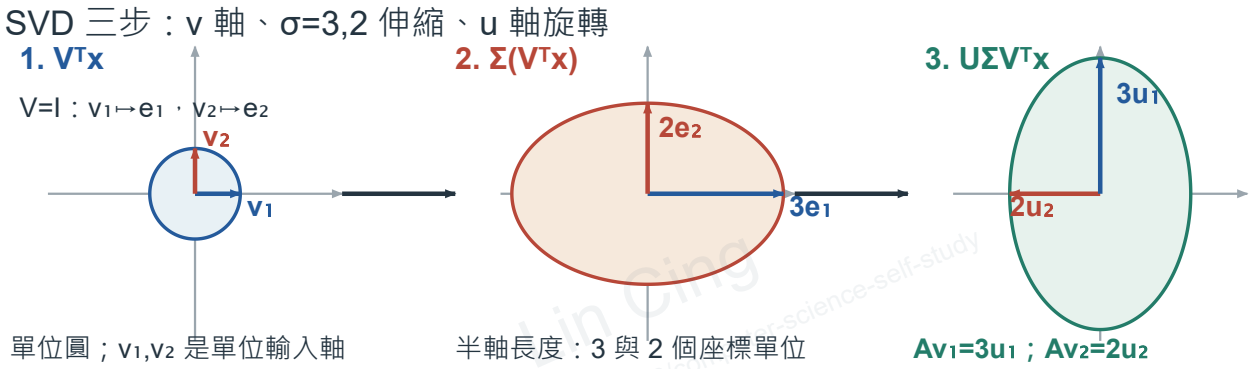
$$\|Av_1\| = \sigma_1.$$

Matrix norm：

$$\|A\|_2 = \sigma_1.$$

Image ellipse 的 semi-axis lengths 是 singular values。最小 positive σ_r 控制 row space 到 column space 的最弱 growth。

SVD 幾何：可重算的直角旋轉例 （續）



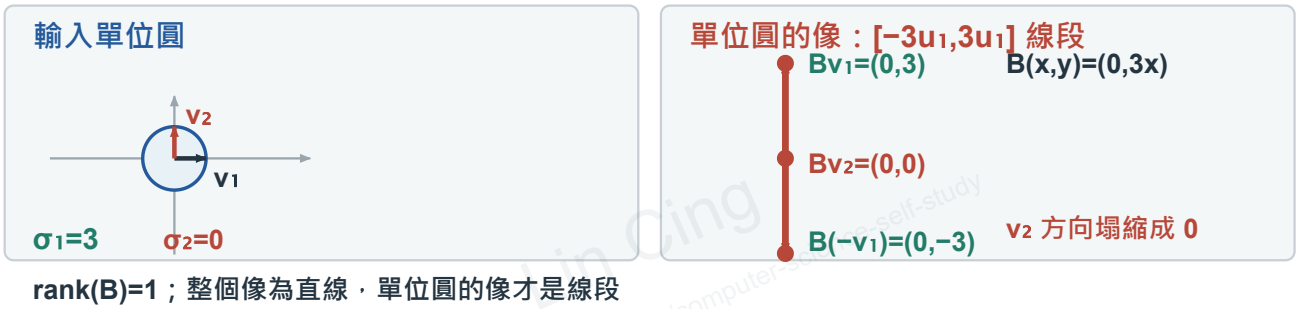
秩不足示例取

$$B = \begin{bmatrix} 0 & 0 \\ 3 & 0 \end{bmatrix} = U\,\mathrm{diag}(3,0)V^T.$$

此時 $Bv_1 = (0,3)^T$，而 $Bv_2 = 0$。單位圓盤的像不是橢圓盤；v_2 方向塌縮成原點後，其餘點落在從 $(0,-3)^T$ 到 $(0,3)^T$ 的完整線段。

SVD 幾何：可重算的直角旋轉例 （續）

秩不足 SVD：B=[[0,0],[3,0]]，σ2=0 塌縮



rank(B)=1；整個像為直線，單位圓的像才是線段

Spectral norm 與 condition number

$$\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

對

$$x = \sum_i c_i v_i,$$

$$\|Ax\|^2 = \sum_i \sigma_i^2 |c_i|^2 \leq \sigma_1^2 \|x\|^2.$$

$x = v_1$ 時等號成立，所以

$$\|A\|_2 = \sigma_1.$$

對可逆方陣，或明確把長方矩陣的條件數定義為 $\|A\|_2 \|A^+\|_2$ 且 A 滿 column rank 時：

$$\kappa_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Spectral norm 與 condition number （續）

正交矩陣的奇異值全為 1，所以 $\kappa_2 = 1$。秩不足時，原來要求逆的全空間映射已非單射；不能把略去零奇異值後的有限比值當成原問題的可逆條件數。固定限制在 row space 到 column space 的可逆映射可另談正奇異值比，但那是已限制子空間的不同問題。一般最小平方解對資料的相對敏感度還受殘差與投影角度影響，不只由這個比值決定。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Distance to singularity 與 numerical rank

本頁先限定可逆方陣 $A \in \mathbb{R}^{n\times n}$。把 smallest singular value 對應的 $\sigma_n u_n v_n^T$ 刪掉：

$$\|A - A_0\|_2 = \sigma_n.$$

因此 σ_n 是 spectral norm 下到 singular matrices 的 distance。rank 至多 k 的最近 matrix 是 A_k，distance σ_{k+1}。

Numerical rank 用 tolerance τ：

$$\sigma_i > \tau \|A\|.$$

Tolerance 要反映 noise、dimension 與 downstream sensitivity。Singular values stable 不代表 close singular vectors stable；close values 附近尤需小心。

擾動半徑如何限制數值秩

對相同尺寸矩陣 A, B，令 $\delta = \|A - B\|_2$。由前面的 Eckart–Young 定理，$\sigma_i(A) = \min_{\operatorname{rank} C < i} \|A - C\|_2$。取 B 的最佳低秩近似，三角不等式給

$$\sigma_i(A) \le \|A - B\|_2 + \sigma_i(B).$$

交換 A, B 即得 Weyl 界 $|\sigma_i(A) - \sigma_i(B)| \le \delta$。它是奇異值的絕對擾動界；極小奇異值的相對誤差仍可很大。

設資料 A 與未知真矩陣 B 的距離至多 δ，令 $r_\delta = \#\{i : \sigma_i(A) > \delta\}$。任何這樣的 B 都必有 $\operatorname{rank} B \ge r_\delta$，因前 r_δ 個奇異值仍嚴格為正；同時截斷 A_{r_δ} 的誤差 $\sigma_{r_\delta+1} \le \delta$，所以至少存在一個秩 r_δ 的相容模型。若 $r_\delta = q$，便用 $A_q = A$。

因此 r_δ 是擾動球中可保證的最小秩，不表示所有相容模型的真秩都等於它。例如 $A = \operatorname{diag}(1, 10^{-8}, 10^{-12})$、$\delta = 10^{-10}$，秩 2 的截斷模型相容，原來秩 3 的 A 也相容，資料精度不足以分辨第三個方向是否真的為零。

若應用另固定絕對門檻 t，只有 $\sigma_i(A) > t + \delta$ 或 $\sigma_i(A) < t - \delta$ 的分類才對此擾動穩健；靠近門檻的方向應列為不確定。相對門檻 $t = \tau\|A\|_2$ 還要記錄尺度與雜訊假設。

QR 的主元不是奇異值

精確算術下，$A = Q_1 R$、$Q_1^T Q_1 = I$ 給 $A^T A = R^T R$，故 A 與 R 的奇異值相同。但 R 的對角元素不是奇異值。取

$$R = \begin{bmatrix} 1 & K \\ 0 & 1 \end{bmatrix}, \qquad K \geq 1.$$

兩個對角元素都是 1，卻有 $\|Re_2\|_2 = \sqrt{K^2+1}$，所以 $\sigma_{\max} \geq K$。又 $\sigma_{\max}\sigma_{\min} = |\det R| = 1$，故 $\sigma_{\min} \leq 1/K$、$\kappa_2(R) \geq K^2$。大非對角元素會讓普通 QR 的對角線無法單獨反映接近相依的程度。

列出 R_{ii} 的大小可作啟發式檢查，不能當成奇異值擾動定理。選 column pivot 的 QR 常用來估計數值秩，但若要保證精度，仍需其明確的秩揭露界或以 SVD 核對。也不能因某個浮點主元非零，就宣稱它代表可信的資料方向。

Polar decomposition

$$A = U\Sigma V^T = (UV^T)(V\Sigma V^T).$$

本頁限定方陣 $A \in \mathbb{R}^{n\times n}$，因此 U, V, Σ 均為 $n \times n$。令

$$Q = UV^T, \qquad S = V\Sigma V^T.$$

Q orthogonal、S symmetric positive semidefinite。所以

$$A = QS.$$

A invertible 時 Σ 全正，S positive definite。$\det Q$ 的正負反映 orientation。Q 類比 rotation 或 reflection，S 類比 stretch。

Pseudoinverse

Reduced SVD：

$$A = U_r \Sigma_r V_r^T.$$

Moore-Penrose pseudoinverse：

$$A^+ = V_r \Sigma_r^{-1} U_r^T.$$

$$AA^+ = U_r U_r^T, \qquad A^+ A = V_r V_r^T.$$

兩者分別是 column space 與 row space 的 orthogonal projection。

Full column rank：

$$A^+ = (A^T A)^{-1} A^T.$$

Full row rank：

$$A^+ = A^T (AA^T)^{-1}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Pseudoinverse （續）

$A^+ b$ 是 minimum-norm least-squares solution。證明：以完整 V 展開 $x = \sum_i c_i v_i$，則 $\|b - Ax\|^2 = \sum_{i=1}^{r} (u_i^T b - \sigma_i c_i)^2 + \sum_{i=r+1}^{m} (u_i^T b)^2$。最小值要求 $c_i = u_i^T b / \sigma_i$（$i \le r$），其餘零空間係數任意；令其餘係數為零使 $\|x\|^2 = \sum_i c_i^2$ 唯一最小，即得 $A^+ b$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Rank-deficient least squares 結構

$$A = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix} = (1,2)^T (1,1).$$

Normalize：

$$u_1 = (1,2)^T/\sqrt{5}, \qquad v_1 = (1,1)^T/\sqrt{2}.$$
$$A = \sqrt{10}\, u_1 v_1^T.$$

u_1 是輸出方向、v_1 是輸入方向。此例兩者均以 $\mathbb{R}^2$ 座標表示，但不同數值；一般矩形矩陣甚至連所在維度也不同，不能因 rank one 就假設 $u_1 = v_1$。

對 $b = (1,3)^T$：

$$A^T A = \begin{bmatrix} 5 & 5 \\ 5 & 5 \end{bmatrix}, \qquad A^T b = \begin{bmatrix} 7 \\ 7 \end{bmatrix}.$$

所有

$$x_1 + x_2 = 7/5$$

都是 minimizers；$A^T A$ singular，不能直接 invert。

Minimum-norm 解

$$\sigma_1 u_1^T b = \sqrt{10}\frac{1+6}{\sqrt{5}} = 7\sqrt{2}.$$
$$x^+ = A^+ b = \frac{1}{\sigma_1} v_1 u_1^T b = \frac{7}{10}(1,1)^T.$$

Projection：

$$AA^+ b = u_1 u_1^T b = \frac{7}{5}(1,2)^T.$$

Residual：

$$e = b - AA^+ b = \left(-\frac{2}{5}, \frac{1}{5}\right)^T.$$
$$e^T(1,2) = 0,$$

所以 residual 與 column space 正交。

Numerical workflow

SVD workflow：

1. 檢查 shape、missing values、units；
2. PCA 要先 center，必要時 standardize；
3. 使用 stable SVD，不形成 normal equations；
4. 看 singular-value gaps 與 numerical rank；
5. 依 error budget 選 k；
6. 在 held-out data 或 downstream task 驗證。

Sign 可翻轉，repeated singular values 的 axes 可 rotate。SVD 是 linear reconstruction，不自動提供 causal importance 或 fairness guarantee。

Four subspaces

空間	Ambient space	SVD basis	Dimension
row space	$\mathbb{R}^n$	$v_1, \dots, v_r$	r
nullspace	$\mathbb{R}^n$	$v_{r+1}, \dots, v_n$	$n - r$
column space	$\mathbb{R}^m$	$u_1, \dots, u_r$	r
left nullspace	$\mathbb{R}^m$	$u_{r+1}, \dots, u_m$	$m - r$

u_i 與 v_i 位於不同 spaces，不直接比較 inner product，除非 $m = n$ 且明確做 coordinate identification。SVD 的 role 是 matched bases：

$$Av_i = \sigma_i u_i.$$

章末檢查

讀者應能：

- 由 A^TA 建 v_i，令 $u_i = Av_i/\sigma_i$；
- 補齊 null directions 得到 full SVD；
- 使用 rank-one terms 計算 spectral/Frobenius errors；
- 解釋 PCA 的 center、scores、variance 與 denominator；
- 區分 input/output singular bases；
- 推導 $\|A\|_2$、condition number、distance to singularity；
- 建 polar decomposition 與 pseudoinverse；
- 處理 sign ambiguity、tied singular values 與 numerical rank。

下一章用 basis 和 coordinates 重新解釋 linear transformations。

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study