SVD：替輸入與輸出各選一組好座標

矩陣不必是方陣，也不必可逆。奇異值分解（singular value decomposition, SVD）把線性映射拆成**換輸入座標、沿軸伸縮、換輸出座標**三步。

要回答的問題	本章使用的量	必須分清的對象
哪個單位方向放大最多？	最大奇異值	輸入方向與輸出方向
只保留 k 個方向會錯多少？	截斷 SVD 與兩種誤差範數	最壞方向與誤差平方和
資料最分散在哪裡？	中心化資料的 PCA	主方向、分數與變異數
方程無解或多解時選哪個？	偽逆與最小範數解	最小殘差與最小解長度

先備知識：正交投影、實對稱矩陣的譜定理、秩與零度。除另有註明，本章推導使用實數。複數版除將轉置改為共軛轉置，係數平方也要改成模平方，內積須採 Hermitian 內積。

外積：把一個輸入方向送到一個輸出方向

令非零向量 $u \in \mathbb{R}^m, v \in \mathbb{R}^n$。外積 uv^T 的第 i 個 row、第 j 個 column 元素是 $u_i v_j$，而對任意輸入 x，

$$(uv^T)x = u(v^T x).$$

先以內積 $v^T x$ 取得一個係數，再把它乘上 u。**所有輸出都落在同一條直線**，所以秩為 1；若 u 或 v 為零，秩則是 0。

例如 $u = (1,2)^T, v = (1,1)^T$，則 $uv^T = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix}$，輸入 $x = (3,-1)^T$ 得 $(2,4)^T$。輸入 $(1,-1)^T$ 的內積為零，會被送到原點。

灰階影像也可視為矩陣，元素代表像素強度。SVD 將矩陣寫成多個外積的加權和；保留少數項能否壓縮，取決於資料與容許誤差。

完整與精簡 SVD：先核對每個因子的尺寸

對 $A \in \mathbb{R}^{m\times n}$，令 $r = \operatorname{rank} A$、$q = \min(m,n)$。完整分解為 $A = U\Sigma V^T$，其中 U、V 為正交方陣。

形式	U 或 U_r	Σ 或 Σ_r	V^T 或 V_r^T
完整 full	m×m	m×n	n×n
本章精簡 reduced	m×r	r×r	r×n

Σ 僅對角線可能非零；q 個奇異值依 $\sigma_1 \geq \cdots \geq \sigma_r > 0$ 排列，其餘為零。精簡式只保留正奇異值，滿足 $U_r^T U_r = V_r^T V_r = I_r$。

不要把精簡因子當成正交方陣：$U_r U_r^T$ 通常是投影矩陣，不是 I_m。有些介面以 thin 表示保留 q 個方向，包括零奇異值；應直接核對尺寸。r=0 時 A=0，精簡式視為空和。

先找右奇異向量：對稱矩陣提供正交基底

$A^T A$ 是 n×n 的實對稱半正定矩陣，因為 $x^T A^T A x = \|Ax\|^2 \geq 0$。譜定理給一組完整標準正交特徵基底 $v_1, \ldots, v_n$：

$$A^T A v_i = \lambda_i v_i, \qquad \sigma_i = \sqrt{\lambda_i}.$$

對正特徵值，$\|Av_i\|^2 = \lambda_i = \sigma_i^2$，所以 $Av_i \neq 0$。對零特徵值，這個平方長度為零，故 $Av_i = 0$。這也證明 $N(A^T A) = N(A)$，所以正特徵值恰有 r 個。前 r 個 v_i 張成 row space $C(A^T)$，其餘張成零空間。**奇異值是 λ_i 的平方根，不是 λ_i 本身。**

再找左奇異向量：輸出除以伸縮倍率

對 $1 \le i \le r$，定義 $u_i = Av_i/\sigma_i$。它的長度是 1；任意 i、j 滿足

$$u_i^T u_j = \frac{v_i^T A^T A v_j}{\sigma_i \sigma_j} = \frac{\sigma_j^2 v_i^T v_j}{\sigma_i \sigma_j} = \delta_{ij}.$$

因此 $u_1, \dots, u_r$ 標準正交，並且 $Av_i = \sigma_i u_i$。它們都在 $C(A)$ 中，數量又等於秩，所以構成 column space 的基底。

將它們補成 $\mathbb{R}^m$ 的標準正交基底 U。補上的向量垂直於 $C(A)$，恰屬於左零空間 $N(A^T)$。

$\sigma_i = 0$ 時不能使用除法公式。**右側的零方向用 $Av_i = 0$ 處理；左側缺少的方向則用正交補齊。**

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

為何這些向量真的給出 A？

把任意輸入展開成 $x = \sum_{j=1}^{n} c_j v_j$。正奇異值方向照比例送到 u_j，零空間方向消失：

$$Ax = \sum_{j=1}^{r} c_j \sigma_j u_j = U\Sigma V^T x.$$

等式對所有 x 成立，因此 $A = U\Sigma V^T$。它不需要 A 可逆，也不需要 m=n。

兩個 Gram 矩陣由此得到 $A^T A = V\Sigma^T \Sigma V^T$、$AA^T = U\Sigma\Sigma^T U^T$。正特徵值都是 σ_i^2，零特徵值重數分別為 n−r 與 m−r。

數值計算通常直接使用穩定的 SVD 程序。明算 $A^T A$ 會使滿 column rank 問題的二範數條件數平方，也可能造成上溢；上面的構造是存在性證明，並非建議的浮點計算法。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

外積展開：誤差平方為何可以逐項相加？

精簡 SVD 等價於 $A = \sum_{i=1}^{r} \sigma_i u_i v_i^T$。Frobenius 內積與範數定義為

$$\langle B, C \rangle_F = \operatorname{tr}(B^T C) = \sum_{ij} B_{ij} C_{ij}, \qquad \|B\|_F^2 = \sum_{ij} B_{ij}^2.$$

由 $\langle u_i v_i^T, u_j v_j^T \rangle_F = (u_i^T u_j)(v_i^T v_j) = \delta_{ij}$，各外積是標準正交的「矩陣方向」，所以

$$\|A\|_F^2 = \sum_{i=1}^{r} \sigma_i^2.$$

A≠0 時，前 k 項保留的平方和比例是 $\sum_{i \le k} \sigma_i^2 / \sum_{i \le r} \sigma_i^2$。這個能量比例不是影像觀感或任務準確率。核範數 $\|A\|_* = \sum_i \sigma_i$ 使用另一種加總，不能與 Frobenius 範數混用。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

截斷 SVD：保留哪些方向，捨棄哪些誤差？

設實矩陣 A 的秩為 r，奇異值依大小排列。限制近似矩陣的秩至多 k，先考慮 $1 \le k < r$。截斷 SVD 保留前 k 個項：

$$A_k = \sum_{i=1}^{k} \sigma_i u_i v_i^T, \qquad E = A - A_k = \sum_{i=k+1}^{r} \sigma_i u_i v_i^T.$$

每個被保留的方向滿足 $A_k v_i = A v_i$；被刪方向則有 $A_k v_i = 0$，故誤差沿該方向為 $E v_i = \sigma_i u_i$。這給出一個候選答案，還沒有證明任意其他秩 k 矩陣都不能更好。

以下固定 $A = \operatorname{diag}(9, 4, 1)$、k=1，則 $A_1 = \operatorname{diag}(9, 0, 0)$、$E = \operatorname{diag}(0, 4, 1)$。先弄清兩種誤差怎麼量，再分別證明它們的下界。此處 $u_i = v_i = e_i$，一般矩陣的左右方向則可能不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

同一個誤差矩陣，兩種範數各在量什麼？

對 $E = \mathrm{diag}(0, 4, 1)$，三個標準單位方向的誤差如下：

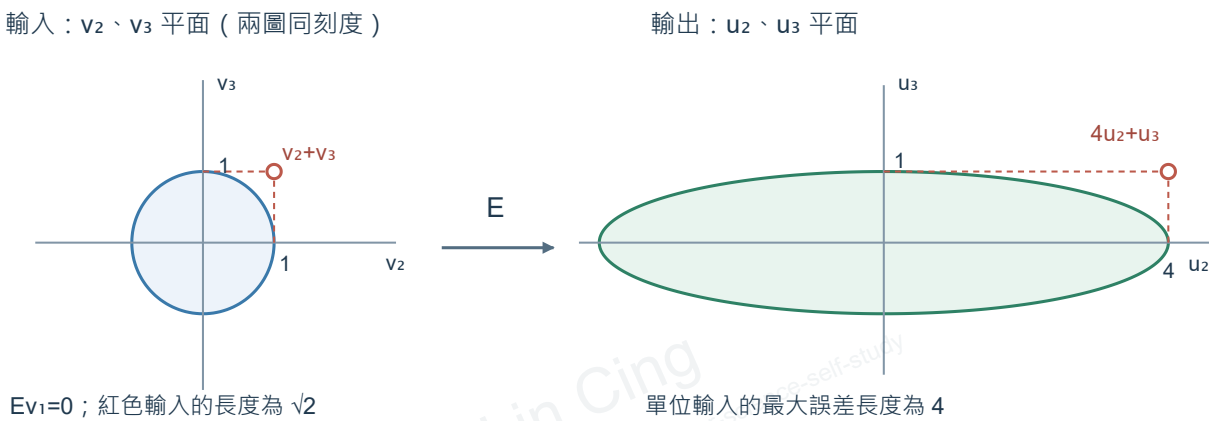
單位輸入	誤差輸出	長度平方
e_1	0	0
e_2	$4e_2$	16
e_3	e_3	1

Spectral norm（矩陣二範數）問：**所有單位輸入中，最大的誤差有多長**？若 $\|x\| = 1$，

$$\|Ex\|^2 = 16x_2^2 + x_3^2 \le 16(x_1^2 + x_2^2 + x_3^2) = 16.$$

取 $x = e_2$ 達等號，所以 $\|E\|_2 = 4$。Frobenius norm 則將各欄誤差平方相加：$\|E\|_F^2 = 0 + 16 + 1 = 17$，故 $\|E\|_F = \sqrt{17}$。它不是另一個「最大單位輸出長度」。

誤差橢圓：$\sqrt{17}$ 為什麼不是最長半軸？



因 $Ev_1 = 0$，三維單位球先在 v₂、v₃ 平面投成單位圓盤，經 E 後成為圖中的橢圓盤。最長輸出半軸是 4。紅點的輸入是 $v_2 + v_3$，長度為 $\sqrt{2}$，輸出長度雖為 $\sqrt{17}$，卻不符合二範數「輸入長度為 1」的條件。正規化後的輸出長度為 $\sqrt{17/2} < 4$。

二範數下界：k 個方向，無法保住 k+1 維

讓 B 是任意秩至多 k 的近似，不要求與 A 共享奇異向量。取 $S = \operatorname{span}\{v_1, \dots, v_{k+1}\}$。B 限制在 S 上的秩至多 k，由秩與零度定理，存在單位向量 $z \in S$ 使 $Bz = 0$。

寫 $z = \sum_{i=1}^{k+1} c_i v_i$，其中 $\sum_i c_i^2 = 1$。左奇異向量正交，故

$$\|(A - B)z\|^2 = \|Az\|^2 = \sum_{i=1}^{k+1} \sigma_i^2 c_i^2 \geq \sigma_{k+1}^2.$$

因此 $\|A - B\|_2 \geq \sigma_{k+1}$。本例即使取非對角的 $B = \begin{bmatrix} 9 & 9 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$，仍可用 $z = (1, -1, 0)^T/\sqrt{2}$：$Bz = 0$，而 $\|Az\|^2 = (81 + 16)/2 = 97/2 \geq 16$。下界不是只檢查對角候選矩陣所得。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Frobenius 下界：先把每一欄誤差拆成直角

令 P 為投影到 $C(B)$ 的正交投影。對每一欄 a_j, b_j，有 $Pb_j = b_j$，所以

$$a_j - b_j = (I - P)a_j + (Pa_j - b_j).$$

第一項垂直於 $C(B)$，第二項在 $C(B)$ 內。逐欄用畢氏定理，再相加：

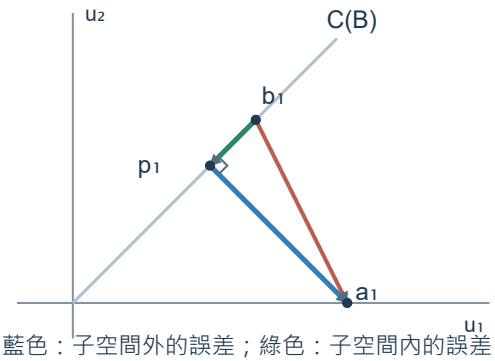
$$\|A - B\|_F^2 = \|(I - P)A\|_F^2 + \|PA - B\|_F^2 \geq \|(I - P)A\|_F^2.$$

這與向量投影的道理相同：先找到最近的投影點；若還選子空間裡別的點，就會多一段平方誤差。又因 P 與 I−P 正交互補，

$$\|(I - P)A\|_F^2 = \|A\|_F^2 - \|PA\|_F^2 = \sum_{i=1}^{r} \sigma_i^2 - \operatorname{tr}(PAA^T).$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

同一欄的投影圖：45 = 81/2 + 9/2



藍色：子空間外的誤差；綠色：子空間內的誤差

同一欄，畫在前兩個座標的平面

a₁=(9,0,0), b₁=(6,6,0)

p₁=Pa₁=(9/2,9/2,0)

a₁−b₁ = (a₁−p₁) + (p₁−b₁)

a₁−p₁ ⊥ p₁−b₁

45 = 81/2 + 9/2

本圖取 $C(B)=\operatorname{span}\{(1,1,0)^T\}$，$a_1=(9,0,0)^T$、$b_1=(6,6,0)^T$，投影 $p_1=Pa_1=(9/2,9/2,0)^T$。所以 $a_1-b_1=(3,-6,0)^T$，拆成 $(9/2,-9/2,0)^T+(-3/2,-3/2,0)^T$。兩項內積為零，平方長度恰為 $45=81/2+9/2$。這只是一欄的分解；Frobenius 誤差還要對全部欄相加。

投影最多能留下多少平方和？

將左奇異向量補成 $\mathbb{R}^m$ 的正交單位基底，對 i>r 設 $\sigma_i=0$。令 $\alpha_i=u_i^TPu_i=\|Pu_i\|^2$，則

$$0\le\alpha_i\le1,\qquad\sum_{i=1}^{m}\alpha_i=\operatorname{tr}P=\operatorname{rank}P\le k.$$

可把 α_i 想成分給方向 i 的投影額度：每方向至多 1，總額至多 k。較大的 σ_i^2 每單位額度貢獻較多。本例取 k=1，沿用前頁的投影：

方向	σ_i^2	額度 α_i	留下的平方和
$u_1=e_1$	81	1/2	81/2
$u_2=e_2$	16	1/2	8
$u_3=e_3$	1	0	0

總額度為 1，卻只留下 $97/2$，小於全部分給第一方向的 81。投影到任意其他一維子空間也不能超過 81；下一頁證明一般 k 的上界。

將「保留最大的 k 項」寫成完整不等式

沿用 $0 \le \alpha_i \le 1$、$\sum_i \alpha_i \le k$。前 k 項的奇異值至少為 σ_k，其餘至多為 σ_k，因此：

$$\begin{aligned}\operatorname{tr}(PAA^T) &= \sum_{i=1}^{m} \sigma_i^2 \alpha_i \\ &\le \sum_{i=1}^{k} \sigma_i^2 \alpha_i + \sigma_k^2 \sum_{i=k+1}^{m} \alpha_i \\ &\le \sum_{i=1}^{k} \left[\sigma_i^2 \alpha_i + \sigma_k^2 (1-\alpha_i)\right] \le \sum_{i=1}^{k} \sigma_i^2.\end{aligned}$$

依序使用：尾端奇異值不大於 σ_k、總額度不超過 k、以及 $\sigma_i^2 \ge \sigma_k^2$ 與 $0 \le \alpha_i \le 1$。代回逐欄畢氏下界，得到 $\|A-B\|_F^2 \ge \sum_{i=k+1}^{r} \sigma_i^2$。

Eckart–Young：截斷同時達到兩種下界

對所有秩至多 k 的 B，前兩個證明已給下界；截斷 SVD 的誤差 E 恰有被刪的奇異值，因此同時達等號：

$$\min_{\operatorname{rank} B \le k} \|A-B\|_2 = \sigma_{k+1}, \qquad \min_{\operatorname{rank} B \le k} \|A-B\|_F^2 = \sum_{i=k+1}^{r} \sigma_i^2.$$

本例 $A = \operatorname{diag}(9,4,1)$	二範數最小誤差	Frobenius 最小誤差
k=0，只能取 B=0	9	$\sqrt{98}$
k=1	4	$\sqrt{17}$
k=2	1	1
k≥3，可取 B=A	0	0

證明主體使用 $1 \le k < r$。k=0 時不用 σ_k；直接取唯一的秩零矩陣。k≥r 時誤差為零。多補一個零奇異值也不改變結果，所以原先 9、4、1、0 的例子仍有相同的 k=1、2、3 誤差。

最優矩陣是否唯一，要先說使用哪種範數

仍取 A=diag(9,4,1)，考慮 $B_c = \mathrm{diag}(c, 0, 0)$。只要 $5 \le c \le 13$，它的秩為 1，而且

$$\|A - B_c\|_2 = \max\{|9 - c|, 4, 1\} = 4.$$

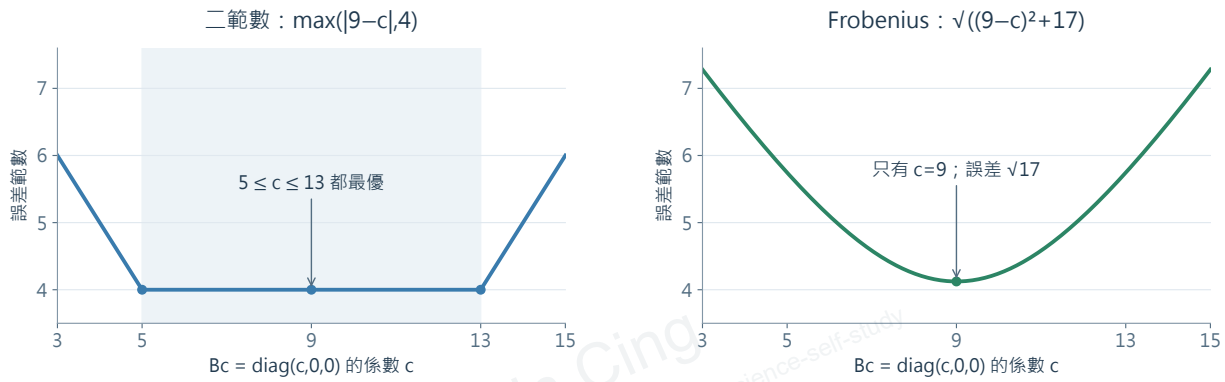
這整族都達到全域二範數下界。雖然 $9 > 4$ 有嚴格間隔，最佳矩陣仍不唯一。另一方面，

$$\|A - B_c\|_F^2 = (9 - c)^2 + 17$$

在這族中只於 c=9 最小。一般而言，$1 \le k < r$ 且 $\sigma_k > \sigma_{k+1}$ 時，Frobenius 最佳矩陣確實唯一：跡上界取等迫使前 k 個 $\alpha_i = 1$、其餘為 0；而畢氏等式也迫使 B=PA，故 B=A_k。若截斷切過正奇異值的相等區段，可在該完整奇異子空間內選不同保留方向；完整子空間固定，選入的部分可以不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

同一族候選矩陣，兩種目標畫成曲線



兩圖使用同一組 B_c，只改變評分方式。左圖一整段水平，是因為被捨棄的第二方向已造成誤差 4；第一方向只要不超過它，就不再改變最大值。右圖仍計入第一方向的平方誤差，所以只有 c=9 最佳。圖只展示這一族，沒有宣稱列盡所有二範數最優矩陣。

低秩儲存：先算清楚是否真的比較省

保留 k 個奇異值及左右向量，直接儲存需要 $mk + nk + k = k(m + n + 1)$ 個數；原矩陣需要 mn 個數。這是因子表示的儲存量，不是秩 k 矩陣的獨立自由度。

1000×1000 矩陣	數值個數	占原矩陣比例
原始元素	1,000,000	100%
k=10 因子	20,010	2.001%
k=500 因子	1,000,500	100.05%

因此只有 $k(m + n + 1) < mn$ 時，這種表示的數值個數才減少。實際檔案還有精度、標頭與索引成本；誤差則要由被捨棄的奇異值另外核對。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

PCA：先固定資料方向，再減掉平均

本章固定 $A_0 \in \mathbb{R}^{m \times n}$：**每個 row 是一項變數，每個 column 是一筆樣本**。第 j 個變數的平均為 $\mu_j = n^{-1} \sum_{s=1}^{n} (A_0)_{js}$，中心化資料為 $A = A_0 - \mu \mathbf{1}^T$。

每個 row 的和變成零，即 $A\mathbf{1} = 0$。若 n≥1，這也給 $\operatorname{rank} A \le \min(m, n-1)$。

對單位方向 u，所有樣本的投影座標為 $u^T A$，平方和是 $u^T A A^T u$。寫成左奇異向量基底後，

$$u^T A A^T u = \sum_i \sigma_i^2 c_i^2 \le \sigma_1^2 \sum_i c_i^2 = \sigma_1^2.$$

第一主方向可取 u_1。它使中心化資料的投影平方和最大；主方向的正負可以相反，所代表的直線相同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

同一組資料：主方向、分數與變異數

取三筆已中心化的樣本 $(-1,-1),(0,1),(1,0)$。令

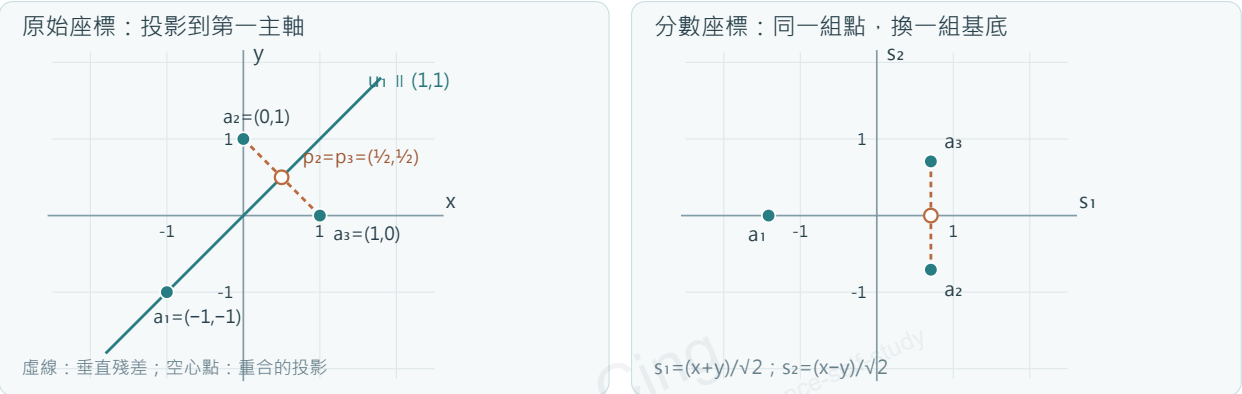
$$A=\begin{bmatrix}-1 & 0 & 1\\ -1 & 1 & 0\end{bmatrix},\qquad AA^T=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}.$$

特徵方程是 $(2-\lambda)^2-1=0$，得 3、1。對應的單位方向為 $u_1=(1,1)^T/\sqrt{2}$、$u_2=(1,-1)^T/\sqrt{2}$，奇異值為 $\sqrt{3}$、1。

樣本 a_s	分數 $u_1^Ta_s$	分數 $u_2^Ta_s$
(−1,−1)	$-\sqrt{2}$	0
(0,1)	$1/\sqrt{2}$	$-1/\sqrt{2}$
(1,0)	$1/\sqrt{2}$	$1/\sqrt{2}$

兩個分數 row 都和為零，平方和分別為 3 與 1。以 n−1=2 為分母，主成分樣本變異數是 3/2、1/2；第一方向解釋比例為 3/4。

PCA 圖解：投影點與捨棄的垂直誤差



第一主軸為 y=x。三個投影依序是 $(-1,-1),(1/2,1/2),(1/2,1/2)$；後兩筆投影重合，但殘差分別是 $(-1/2,1/2)$、$(1/2,-1/2)$。殘差平方和為 0+1/2+1/2=1。

右圖使用分數 $s_1=u_1^Ta, s_2=u_2^Ta$ 當座標，第一主軸成為水平軸。**這是整組正交換座標，不是改變點之間的距離。**

最大投影變異，等價於最小垂直誤差

任取單位方向 u。每個樣本都有正交分解 $a_s = uu^T a_s + (I - uu^T)a_s$，逐筆用畢氏定理後相加：

$$\sum_s \|(I - uu^T)a_s\|^2 = \|A\|_F^2 - \|u^T A\|^2.$$

左側是點到過原點直線 span(u) 的**垂直距離平方和**。右側第一項固定，因此最大化投影平方和就最小化殘差；本例為 4−3=1。原始資料未中心化時，最佳仿射直線可取 $\mu + \text{span}(u_1)$。

這與固定橫座標、只最小化垂直於 x 軸方向誤差的直線迴歸不同。一般而言，改用後者就改了最佳化問題，不能直接使用同一張殘差圖。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

分母與單位：哪些改變方向，哪些只改變倍率？

運算	共變異數	主方向的影響
樣本分母 n−1，n≥2	$AA^T/(n-1)$	特徵值為 $\sigma_i^2/(n-1)$
描述資料的分母 n	AA^T/n	方向相同，特徵值整體縮放
各變數除以自己的標準差	$DAA^TD/(n-1)$	通常改變主方向與幾何

若第二個變數改用小 100 倍的單位，其數值放大 100 倍，共變異數的第二對角元素放大 10,000 倍、交叉項放大 100 倍。PCA 會因此偏重第二座標。

標準化可消除單位尺度造成的差異，卻也會改變原本的距離與誤差目標。零變異數的變數不能直接除以零；n=1 時樣本共變異數亦無定義。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

分數的符號與相等奇異值

完整分數矩陣為 $S = U^T A = \Sigma V^T$，尺寸 m×n。精簡分數則是 $S_r = U_r^T A = \Sigma_r V_r^T$，尺寸 r×n。第 i 個分數 row 的平方和**恰等於** σ_i^2。

同時將 u_i, v_i 改號，外積 $\sigma_i u_i v_i^T$ 不變；分數 row 改號，重建乘回去仍相同。只改其中一個向量則會改變 A。

若某區段的奇異值相同，可在該完整奇異子空間內一起旋轉左右基底，A 仍不變。可辨識的是子空間；其中的個別軸不一定唯一。截斷切過相等區段時，選入的較小子空間也可能不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

奇異向量如何決定橢圓的軸

取 $V = \frac{1}{5}\begin{bmatrix} 4 & -3 \\ 3 & 4 \end{bmatrix}$、$U = \frac{1}{5}\begin{bmatrix} 3 & -4 \\ 4 & 3 \end{bmatrix}$、$\Sigma = \mathrm{diag}(3, 2)$。兩個正交因子給

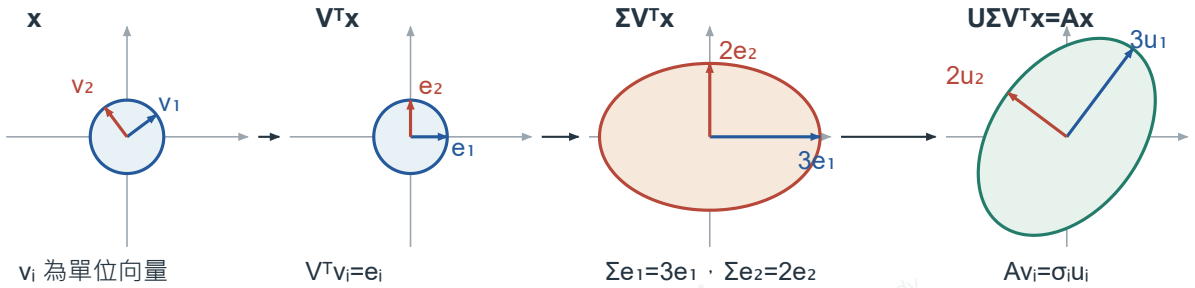
$$A = U\Sigma V^T = \frac{1}{5}\begin{bmatrix} 12 & -1 \\ 6 & 12 \end{bmatrix}.$$

先以 V^T 將 v_i 送到 e_i，再伸縮，最後以 U 改變輸出方向。圓集合旋轉後外觀相同，但標記的向量方向會變。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

同尺度對照：半軸向量是 $\sigma_i u_i$

SVD：輸入方向 → 標準座標 → 伸縮 → 輸出方向

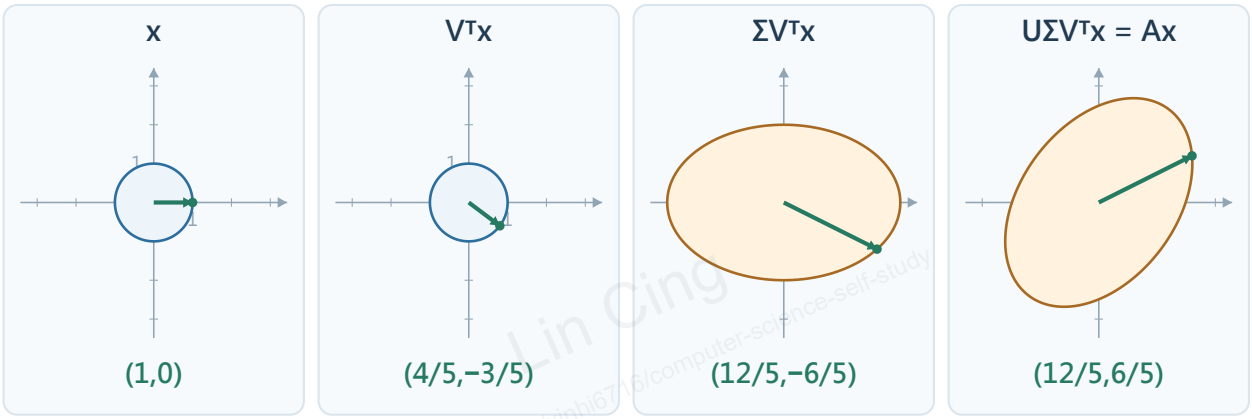


v_i 為單位向量　$V^T v_i = e_i$　$\Sigma e_1 = 3e_1$，$\Sigma e_2 = 2e_2$　$Av_i = \sigma_i u_i$

$Av_1 = (9/5, 12/5)^T = 3u_1$，$Av_2 = (-8/5, 6/5)^T = 2u_2$。圖中半軸長為 3、2；單位向量 u_i 只決定方向。本例滿秩，單位圓的像是橢圓邊界，單位圓盤的像則填滿橢圓。

追蹤一個不沿奇異方向的單位向量

沿用前例的 U, V, Σ，取 $x = (1, 0)^T$。這個 x 不是 v_1 或 v_2。綠色箭頭追蹤同一點，背景曲線是單位圓在各步的像。



四面板同尺度；綠色向量追蹤同一個輸入的逐步變化。

算值與長度變化要分開核對

步驟	代入後的座標	範數平方
輸入 x	(1,0)	1
V^Tx	(4/5,−3/5)	1
ΣV^Tx	(12/5,−6/5)	36/5
$U\Sigma V^Tx=Ax$	(12/5,6/5)	36/5

V^T、U 只改變方向；伸縮由 Σ 產生。本例 $\|Ax\| = 6/\sqrt{5}$，不是任何一個奇異值。

對任意單位輸入，令 $w = V^Tx$，則 $w_1^2 + w_2^2 = 1$，且

$$\|Ax\|^2 = 9w_1^2 + 4w_2^2 = 4 + 5w_1^2 \in [4, 9].$$

所以 $2 \le \|Ax\| \le 3$；上界在 $x = \pm v_1$ 取到，下界在 $x = \pm v_2$ 取到。這是對所有單位輸入的證明，不是由單一數例推論。

直角旋轉：把數值接回幾何

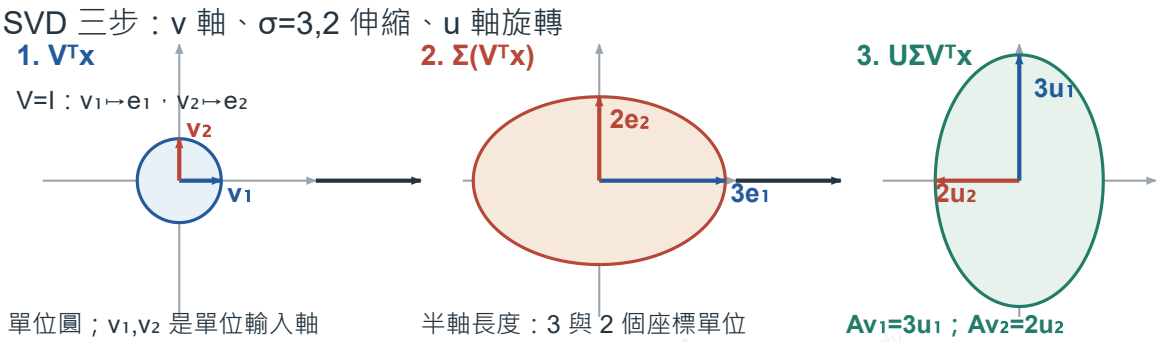
令 V=I、Σ=diag(3,2)、$U = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$，所以 $A = \begin{bmatrix} 0 & -2 \\ 3 & 0 \end{bmatrix}$。

階段	座標作用	幾何結果
V^T	(x_1,x_2) 不變	輸入方向與標準軸重疊
Σ	$(3x_1,2x_2)$	半軸長 3、2
U	$(-2x_2,3x_1)$	將橢圓旋轉 90°

此時 $v_1=e_1$、$v_2=e_2$，$Av_1 = (0,3)^T = 3u_1$、$Av_2 = (-2,0)^T = 2u_2$。對單位圓盤 $\|x\| \le 1$，其像填滿這個橢圓；若輸入只取單位圓周，才得到邊界。

一般秩不足時，單位球面也可能映到填滿的低維橢球，不能一律稱其像為橢球面。

直角旋轉：三步幾何對照



Lin Cing
https://github.com/xinhi6716/computer-science-self-study

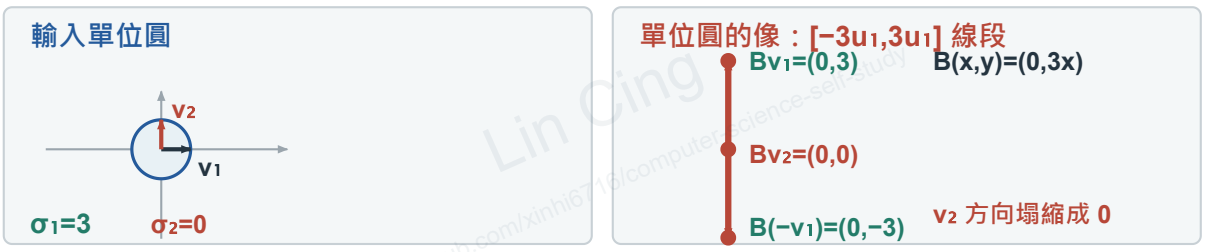
零奇異值：圓盤會塌縮成線段

秩不足示例取

$$B = \begin{bmatrix} 0 & 0 \\ 3 & 0 \end{bmatrix} = U\,\mathrm{diag}(3,0)V^T.$$

此時 $Bv_1 = (0,3)^T$，而 $Bv_2 = 0$。單位圓盤的像不是橢圓盤；v_2 方向塌縮成原點後，其餘點落在從 $(0,-3)^T$ 到 $(0,3)^T$ 的完整線段。

秩不足 SVD：B=[[0,0],[3,0]]，σ2=0 塌縮



rank(B)=1；整個像為直線，單位圓的像才是線段

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

二範數與條件數：最強與最弱的伸縮

對非零矩陣，二範數為 $\|A\|_2 = \max_{x\neq 0} \|Ax\|/\|x\|$。寫 $x = \sum_{i=1}^{n} c_i v_i$，得

$$\|Ax\|^2 = \sum_{i=1}^{r} \sigma_i^2 c_i^2 \leq \sigma_1^2 \sum_{i=1}^{n} c_i^2 = \sigma_1^2 \|x\|^2.$$

取 x=v₁ 達等號，故 ‖A‖₂=σ₁；零矩陣的二範數為零。對可逆方陣，$\|A^{-1}\|_2 = 1/\sigma_n$，所以 $\kappa_2(A) = \sigma_1/\sigma_n \geq 1$。正交矩陣的所有奇異值為 1，條件數也為 1。

滿 column rank 的長方矩陣若採 $\|A\|_2\|A^{+}\|_2$ 定義，也得到最大與最小奇異值比。秩不足時，略去零值後的有限比只描述限制在 row space 的映射，不能當成原全空間問題的可逆條件數。一般最小平方解的敏感度還受殘差與投影角度影響。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

到奇異矩陣的距離與數值秩

本頁先限定可逆方陣 $A \in \mathbb{R}^{n\times n}$。把 最小奇異值 對應的 $\sigma_n u_n v_n^T$ 刪掉：

$$\|A - A_0\|_2 = \sigma_n.$$

因此 σ_n 是 二範數下到奇異矩陣的距離。秩至多 k 的最近矩陣 是 A_k，距離 σ_{k+1}。

數值秩使用相對容許值 τ：

$$\sigma_i > \tau\|A\|.$$

容許值要反映雜訊、矩陣尺寸與解的敏感度。奇異值穩定不代表個別奇異向量穩定；相近奇異值對應的方向尤其容易受擾動改變。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

擾動半徑如何限制數值秩

對相同尺寸矩陣 A, B，令 $q = \min(m, n)$、$1 \le i \le q$，並把不足的奇異值補零；令 $\delta = \|A - B\|_2$。由前面的 Eckart–Young 定理，$\sigma_i(A) = \min_{\operatorname{rank} C < i} \|A - C\|_2$。取 B 的最佳低秩近似，三角不等式給

$$\sigma_i(A) \le \|A - B\|_2 + \sigma_i(B).$$

交換 A, B 即得 Weyl 界 $|\sigma_i(A) - \sigma_i(B)| \le \delta$。它是奇異值的絕對擾動界；極小奇異值的相對誤差仍可很大。

設資料 A 與未知真矩陣 B 的距離至多 δ，令 $r_\delta = \#\{i : \sigma_i(A) > \delta\}$。任何這樣的 B 都必有 $\operatorname{rank} B \ge r_\delta$，因前 r_δ 個奇異值仍嚴格為正；同時截斷 A_{r_δ} 的誤差 $\sigma_{r_\delta+1} \le \delta$，所以至少存在一個秩 r_δ 的相容模型。若 $r_\delta = q$，便用 $A_q = A$。

因此 r_δ 是擾動球中可保證的最小秩，不表示所有相容模型的真秩都等於它。例如 $A = \operatorname{diag}(1, 10^{-8}, 10^{-12})$、$\delta = 10^{-10}$，秩 2 的截斷模型相容，原來秩 3 的 A 也相容，資料精度不足以分辨第三個方向是否真的為零。

若應用另固定絕對門檻 t，只有 $\sigma_i(A) > t + \delta$ 或 $\sigma_i(A) < t - \delta$ 的分類才對此擾動穩健；靠近門檻的方向應列為不確定。相對門檻 $t = \tau\|A\|_2$ 還要記錄尺度與雜訊假設。

QR 的主元不是奇異值

精確算術下，$A = Q_1 R$、$Q_1^T Q_1 = I$ 給 $A^T A = R^T R$，故 A 與 R 的奇異值相同。但 R 的對角元素不是奇異值。取

$$R = \begin{bmatrix} 1 & K \\ 0 & 1 \end{bmatrix}, \qquad K \ge 1.$$

兩個對角元素都是 1，卻有 $\|Re_2\|_2 = \sqrt{K^2 + 1}$，所以 $\sigma_{\max} \ge K$。又 $\sigma_{\max}\sigma_{\min} = |\det R| = 1$，故 $\sigma_{\min} \le 1/K$、$\kappa_2(R) \ge K^2$。大非對角元素會讓普通 QR 的對角線無法單獨反映接近相依的程度。

列出 R_{ii} 的大小可作啟發式檢查，不能當成奇異值擾動定理。選 column pivot 的 QR 常用來估計數值秩，但若要保證精度，仍需其明確的秩揭露界或以 SVD 核對。也不能因某個浮點主元非零，就宣稱它代表可信的資料方向。

極分解：先對稱伸縮，再正交變換

本節限定方陣 $A \in \mathbb{R}^{n\times n}$。由完整 SVD 可寫

$$A = (UV^T)(V\Sigma V^T) = QS.$$

$Q^TQ = I$，而 $S^T = S$ 且 $x^TSx = \sum_i \sigma_i (v_i^T x)^2 \geq 0$。因此 Q 是正交因子，S 是對稱半正定因子，並滿足 $S^2 = A^TA$。

若 A 可逆，所有奇異值正，S 正定，Q=AS^{-1} 唯一。若 A 秩不足，S 仍唯一，但把 Q 延伸到零空間的方式可不同。

正交變換可能包含反射。可逆時 det S>0，所以 det A 與 det Q 同號；不能把 Q 一律稱作旋轉矩陣。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

偽逆：只對真正有作用的方向取倒數

由精簡式 $A = U_r\Sigma_r V_r^T$，定義 Moore–Penrose 偽逆

$$A^+ = V_r\Sigma_r^{-1}U_r^T \in \mathbb{R}^{n\times m}.$$

正奇異值才取倒數，零方向保持為零。若 A=0，定義 A⁺=0。兩個乘積為

$$AA^+ = U_rU_r^T = P_{C(A)}, \qquad A^+A = V_rV_r^T = P_{C(A^T)}.$$

兩者都對稱且冪等，也滿足 AA⁺A=A、A⁺AA⁺=A⁺。四個等式刻畫 Moore–Penrose 偽逆；完整行為可由正交基底逐方向核對。

A 滿 column rank 時可化為 $(A^TA)^{-1}A^T$；滿 row rank 時可化為 $A^T(AA^T)^{-1}$。這些是代數等式，數值解題不必真的形成逆矩陣。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

長方矩陣的轉置：左右奇異方向交換

取 $B=\begin{bmatrix}-1 & 0\\ 1 & -1\\ 0 & 1\end{bmatrix}$，令 $A=B^T$。

$$B^TB=\begin{bmatrix}2 & -1\\ -1 & 2\end{bmatrix},\qquad \sigma_1=\sqrt{3},\quad \sigma_2=1.$$

可取 $v_1=(1,-1)^T/\sqrt{2}$、$v_2=(1,1)^T/\sqrt{2}$，再用 $u_i=Bv_i/\sigma_i$ 得

$$u_1=(-1,2,-1)^T/\sqrt{6},\quad u_2=(-1,0,1)^T/\sqrt{2}.$$

補上 $u_3=(1,1,1)^T/\sqrt{3}\in N(B^T)$。若 $B=U\Sigma V^T$，則 $A=V\Sigma^TU^T$：左右因子與維度一起交換，零方向也要跟著核對。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

轉置前後，最小平方的問題不同

對 $Bx=b$、$b=(1,0,0)^T$，因 B 欄滿秩，正規方程給唯一最小平方解 $\hat{x}=(-2/3,-1/3)^T$。其投影與殘差為

$$B\hat{x}=(2/3,-1/3,-1/3)^T,\quad e=b-B\hat{x}=(1,1,1)^T/3.$$

驗算 $B^Te=0$，且 $\|e\|=1/\sqrt{3}$，故此方程沒有精確解。

反過來令 $A=B^T$、$c=(1,0)^T$。這次 $Ax=c$ 有解；其唯一最小範數解為 $x^+=(-2/3,1/3,1/3)^T$，全部解為 $x^++t(1,1,1)^T$。因 x^+ 垂直零空間，任加非零零空間成分都增加長度。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

偽逆的乘積不能隨意反轉

AB = [1]

A = [1 0] · B = [1; 1]

A: 1×2 B: 2×1

B⁺A⁺ = [½]

B⁺ = [½ ½] · A⁺ = [1; 0]

B⁺: 1×2 A⁺: 2×1

(AB)⁺ = 1 ≠ ½ = B⁺A⁺

此例的 $A = [1\ 0]$ 欄數多於列數且滿 row rank；$B = [1\ 1]^T$ 滿 column rank。雖然兩個因子都達各自的最大秩，$(AB)^+ = 1$ 仍不等於 $B^+A^+ = 1/2$。方陣可逆時可直接用通常的反序逆矩陣公式；矩形偽逆需另驗證所需條件。

秩不足的最小平方：殘差最小仍可能有很多解

把 b、x 分別展開成左右奇異基底。令 $\beta_i = u_i^T b$、$c_i = v_i^T x$，則

$$\|b - Ax\|^2 = \sum_{i=1}^{r} (\beta_i - \sigma_i c_i)^2 + \sum_{i=r+1}^{m} \beta_i^2.$$

後一項是 b 在左零空間的成分，任何 Ax 都無法改變它。前 r 項各令 $c_i = \beta_i/\sigma_i$，即可達到最小殘差；其餘 n−r 個係數任意。

因此所有最小平方解為 $x = A^+b + z$，其中 $z \in N(A)$。由 $A^+b \in C(A^T) = N(A)^\perp$，

$$\|A^+b + z\|^2 = \|A^+b\|^2 + \|z\|^2.$$

A^+b 是唯一的最小範數最小平方解。先最小化殘差，再於這些解之中最小化解的長度，兩個目標不能混為一談。

數例：同一個投影，對應一整條解直線

取 $A=\begin{bmatrix}1 & 1\\ 2 & 2\end{bmatrix}$、$b=(1,3)^T$。外積正規化給 $u_1=(1,2)^T/\sqrt{5}$、$v_1=(1,1)^T/\sqrt{2}$、$\sigma_1=\sqrt{10}$。

$$A^+=\frac{1}{10}\begin{bmatrix}1 & 2\\ 1 & 2\end{bmatrix},\qquad x^+=A^+b=(7/10,7/10)^T.$$

輸出投影 $p=Ax^+=(7/5,14/5)^T$，殘差 $e=b-p=(-2/5,1/5)^T$。驗算 $e^T(1,2)=0$，殘差平方為 1/5。

令 $t\in\mathbb{R}$，所有解為 $x=x^+ + t(-1,1)^T$，都滿足 $x_1+x_2=7/5$，故輸出皆為 p。它們的長度平方是 $49/50+2t^2$，只有 t=0 最小。

正規方程同樣給 $\begin{bmatrix}5 & 5\\ 5 & 5\end{bmatrix}x=(7,7)^T$，但係數矩陣不可逆；不能使用滿秩時的逆矩陣公式。

實作時的核對順序

階段	核對內容	對結果的影響
整理資料	m×n 尺寸、遺漏值、單位	決定映射與誤差的意義
PCA 前處理	減平均；是否標準化另行決定	改變原點，或進一步改變尺度
分解	使用穩定 SVD，檢查重建殘差	避免把存在性構造當數值流程
截斷	奇異值、雜訊半徑、誤差預算	決定保留的方向是否可信
解釋	基底符號、相等值區段、實際任務	避免把任意軸號當固定意義

對本章 PCA 例，k=1 的平方重建誤差為 1，保留平方和比例為 3/4。這兩個量可直接核對；對新資料的效果則需另外驗證，不能由訓練資料的重建誤差直接保證。

四個基本子空間：輸入側與輸出側分開看

空間	所在空間	標準正交基底	維度
row space $C(A^T)$	$\mathbb{R}^n$	$v_1, \dots, v_r$	r
零空間 $N(A)$	$\mathbb{R}^n$	$v_{r+1}, \dots, v_n$	n−r
column space $C(A)$	$\mathbb{R}^m$	$u_1, \dots, u_r$	r
左零空間 $N(A^T)$	$\mathbb{R}^m$	$u_{r+1}, \dots, u_m$	m−r

輸入側兩空間正交互補；輸出側也一樣。SVD 用 $Av_i = \sigma_i u_i$ 配對有效方向，並將輸入零空間送到零。u_i 與 v_i 一般不在相同維度，不能直接比較內積。

零維子空間的基底是空集；不是把零向量放進基底。

本章重點

- SVD 配對左右奇異方向；零方向不能除以零。
- 截斷 SVD 的最佳誤差與唯一性取決於所用範數。
- PCA 應先說明資料方向、中心化和共變異數分母。
- 偽逆先最小化殘差，再從所有解中選最小範數。

參考資料與署名

Lin Cing，《線性代數》手寫筆記。 Gilbert Strang, Introduction to Linear Algebra, 5th ed., Chapter 7.

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study