第 7 章練習解答

CH07-E1

1.

$$A^TA = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix}.$$

Eigenvalues $3, 2$，eigenvectors $v_1 = (1,0)^T$、$v_2 = (0,1)^T$。

2.

$$\sigma_1 = \sqrt{3}, \qquad \sigma_2 = \sqrt{2}.$$
$$u_1 = \frac{1}{\sqrt{3}}(1,1,1)^T, \qquad u_2 = \frac{1}{\sqrt{2}}(1,-1,0)^T.$$

3.

$$A = \begin{bmatrix} 1/\sqrt{3} & 1/\sqrt{2} \\ 1/\sqrt{3} & -1/\sqrt{2} \\ 1/\sqrt{3} & 0 \end{bmatrix} \begin{bmatrix} \sqrt{3} & 0 \\ 0 & \sqrt{2} \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

4. 補

$$u_3 = (1,1,-2)^T/\sqrt{6}.$$

A full column rank，所以 $N(A) = \{0\}$，但 $\dim N(A^T) = 3 - 2 = 1$，u_3 正是其單位基底。Full SVD 的 Σ 是

$$\begin{bmatrix} \sqrt{3} & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}.$$

Lin Cing https://github.com/xinhi6716/computer-science-self-study

CH07-E2

1.

$$m = 3, n = 2, r = 2.$$
$$\dim C(A^T) = 2, \quad \dim N(A) = 0,$$
$$\dim C(A) = 2, \quad \dim N(A^T) = 1.$$

2. Bases：
   - $C(A^T)$：e_1, e_2；
   - $N(A)$：零子空間，其 basis 是空集，不是含零向量的集合；
   - $C(A)$：u_1, u_2；
   - $N(A^T)$：u_3。

3.

$$Av_1 = \sqrt{3}u_1, \qquad Av_2 = \sqrt{2}u_2.$$

第 7 章練習解答 （續）

4. u_1, u_2, u_3 是 $\mathbb{R}^3$ 的 orthonormal basis，所以 span 是 whole space。$C(A^T)$ 已是 whole $\mathbb{R}^2$。

CH07-E3

1. Columns dependent，rank 1：

$$u_1 = \frac{1}{\sqrt{5}}(1,2)^T, \qquad v_1 = \frac{1}{\sqrt{5}}(1,2)^T.$$
$$A = 5u_1v_1^T, \qquad \sigma_1 = 5.$$

2.

$$5u_1v_1^T = A.$$

3.

$$\|A\|_2 = 5, \qquad \|A\|_F = 5.$$
$$A^+ = \frac{1}{5}v_1u_1^T = \frac{1}{25}\begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix}.$$

4.

$$x^+ = A^+b = \frac{7}{25}(1,2)^T.$$

Normal equation：

$$x_1 + 2x_2 = \frac{7}{5}.$$

所有 minimizers：

$$x = x^+ + t(-2,1)^T, \quad t \in \mathbb{R}.$$

$(-2,1)^T$ 在 nullspace，且與 x^+ orthogonal，所以 x^+ norm 最小。

CH07-E4

1. 任何 finite rectangular real matrix 都有 SVD。$\det A = 20 \neq 0$，rank 2，兩 singular values positive。
2. Full rank square 時

$$\kappa_2(A) = \frac{\sigma_1}{\sigma_2} \geq 1.$$

3. 若 perturbation 把一個 positive singular value 變零，matrix 降 rank 且變 singular；finite invertible condition number 不再存在。其他 singular values 是否變化取決於 perturbation。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

第 7 章練習解答 （續）

CH07-E5

1. Positive singular values 有 3 個，所以 rank 3。
2. Spectral errors：

$$k = 1 : 4, \qquad k = 2 : 1, \qquad k = 3 : 0.$$

Frobenius errors：

$$k = 1 : \sqrt{17}, \qquad k = 2 : 1, \qquad k = 3 : 0.$$

3. Retained energy：

$$\frac{\sigma_1^2 + \cdots + \sigma_k^2}{\sigma_1^2 + \cdots + \sigma_r^2}.$$

4. Spectral error 是 σ_{k+1}。要求 ≤ 4，且 $\sigma_2 = 4$，所以 $k = 1$。

CH07-E6

1. 每 row sum 都是 0，已經 centered。
2.

$$X_0 X_0^T = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

$$u_1 = (1,1)^T/\sqrt{2}, \qquad u_2 = (1,-1)^T/\sqrt{2}.$$

Scores：

$$s_1 = (-\sqrt{2}, 1/\sqrt{2}, 1/\sqrt{2}),$$
$$s_2 = (0, -1/\sqrt{2}, 1/\sqrt{2}).$$

3.

$$\widehat{C} = \frac{1}{2}\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

First component sample variance 是 $3/2$，second 是 $1/2$。

4. Second row 乘 100 後，其 variance 遠大，first PCA direction 會偏向 second coordinate。Standardization 可避免 unit domination，但也把 covariance geometry 改成 correlation geometry，是 modeling decision。

CH07-E7

1.

$$A = \sqrt{10}\, u_1 v_1^T, \quad u_1 = (1,2)^T/\sqrt{5}, \quad v_1 = (1,1)^T/\sqrt{2}.$$

2.

Lin Cing https://github.com/xinhi6716/computer-science-self-study

第 7 章練習解答 （續）

$$A^+ = \frac{1}{\sqrt{10}} v_1 u_1^T = \frac{1}{10}\begin{bmatrix}1 & 2\\ 1 & 2\end{bmatrix}.$$

$$x^+ = A^+ b = \frac{7}{10}(1,1)^T.$$

$$AA^+ b = \frac{7}{5}(1,2)^T.$$

3. Residual：

$$e = \left(-\frac{2}{5}, \frac{1}{5}\right)^T.$$

$$e^T(1,2) = 0.$$

4. All minimizers：

$$x = x^+ + t(-1,1)^T, \quad t \in \mathbb{R}.$$

x^+ 位於 row space，與 nullspace orthogonal，因此 norm 最小。

CH07-E8

1. 把 $V^T V = I$ 插入 SVD：

$$A = U\Sigma V^T = (UV^T)(V\Sigma V^T) = QS.$$

2. Orthogonal matrices 的乘積仍 orthogonal：

$$Q^T Q = I.$$

$$S^T = V\Sigma^T V^T = S.$$

對任一 x：

$$x^T S x = \sum_i \sigma_i (V^T x)_i^2 \geq 0.$$

3. A invertible 時所有 $\sigma_i > 0$，所以 S positive definite；Q 也可逆。

4.

$$\det A = \det Q \det S.$$

$\det S \geq 0$，所以 invertible 時 $\operatorname{sgn}(\det A) = \operatorname{sgn}(\det Q)$。$\det Q = -1$ 表示 orientation reversal。

CH07-E9

1.

$$AA^+ = U_r U_r^T, \qquad A^+ A = V_r V_r^T.$$

兩者 symmetric，且

第 7 章練習解答 （續）

$$(U_r U_r^T)^2 = U_r U_r^T,$$

$V_r V_r^T$ 同理，所以都是 orthogonal projections。

2.

$$AA^+A = U_r U_r^T A = A.$$
$$A^+AA^+ = V_r V_r^T A^+ = A^+.$$

3. $\sigma_k = \sigma_{k+1}$ 時，可在完整的相等奇異值子空間中改選保留方向，最佳誤差不變。完整子空間固定，選入的部分可能不唯一；第 12 題另比較兩種範數的最優矩陣。

4. 只翻轉 u_1 會使 first term 從

$$\sigma_1 u_1 v_1^T$$

變號。必須同時翻轉 v_1，兩個負號相乘才維持 factorization。

CH07-E10

1. 由 Eckart–Young 定理，對任意秩小於 i 的 C，$\sigma_i(A) \le \|A - C\|_2$。取 $C = B_{i-1}$，三角不等式給 $\sigma_i(A) \le \|A - B\|_2 + \|B - B_{i-1}\|_2 = \|A - B\|_2 + \sigma_i(B)$。交換 A, B 得反向，合併即得絕對擾動界。

2. 前兩奇異值嚴格大於 10^{-10}，所以任何相容的 B 至少有兩個正奇異值，秩至少 2。取 $B_2 = \mathrm{diag}(1, 10^{-8}, 0)$，距離為 10^{-12}，是相容的秩 2 模型；取 $B_3 = A$，距離為零，是相容的秩 3 模型。因此資料不能確定第三個方向是否真的為零。截斷偽逆對第二方向仍乘上 10^8，是否保留此方向還需應用的誤差預算。

3. $\sigma_1 \ge \|Re_2\|_2 = \sqrt{10^{12} + 1} > 10^6$，且 $\sigma_1 \sigma_2 = |\det R| = 1$，故 $\sigma_2 < 10^{-6}$。一個不必先求 SVD 的明確秩 1 模型為

$$B = \begin{bmatrix} 1 & 10^6 \\ 10^{-6} & 1 \end{bmatrix} = \begin{bmatrix} 10^6 \\ 1 \end{bmatrix} \begin{bmatrix} 10^{-6} & 1 \end{bmatrix}.$$

只有左下元素改變，故 $\|R - B\|_2 = 10^{-6}$。R 本身已是上三角，其普通 QR 可取 $Q = I$；對角元素皆 1，卻有距離至多百萬分之一的秩不足模型。QR 對角線不能代替奇異值。

4. 若 $\sigma_i(A) > t + \delta$，則 $\sigma_i(B) \ge \sigma_i(A) - \delta > t$；若 $\sigma_i(A) < t - \delta$，則 $\sigma_i(B) \le \sigma_i(A) + \delta < t$。介於兩條界線之間時，擾動可能跨過門檻；等號情形也要依門檻的嚴格或非嚴格定義處理。這是對固定絕對門檻的結論，若連門檻本身都隨矩陣尺度更新，還須計入門檻變動。

第 7 章練習解答 （續）

CH07-E11

四階段座標依序為 (1,0)、(4/5,−3/5)、(12/5,−6/5)、(12/5,6/5)。最後一步相乘為 ((36+24)/25,(48−18)/25)=(12/5,6/5)。直接計算 $A = \frac{1}{5}\begin{bmatrix} 12 & -1 \\ 6 & 12 \end{bmatrix}$，取第一個 column 得到同一結果。範數依序是 1、1、6/√5、6/√5；兩個正交因子保持長度，Σ 才產生伸縮。

任取單位 x，令 w=VᵀX，則 $w_1^2+w_2^2=1$，而且 $\|Ax\|^2 = 9w_1^2 + 4w_2^2 = 4 + 5w_1^2$。故 2≤ ‖ Ax ‖ ≤3。等於 3 恰須 $w_2=0$、$w_1=\pm1$，等價於 $x=\pm v_1$；等於 2 恰須 $w_1=0$、$w_2=\pm1$，等價於 $x=\pm v_2$。本例兩個 w 分量都非零，因此長度嚴格介於兩個奇異值之間。奇異值描述沿 right singular directions 的伸縮，不是所有可能輸出長度的清單。

CH07-E12

1. 分清單位輸入與平方和

$A_1 = \mathrm{diag}(8,0,0)$，$E = \mathrm{diag}(0,3,2)$。任取 $\|x\| = 1$，

$$\|Ex\|^2 = 9x_2^2 + 4x_3^2 \le 9(x_1^2 + x_2^2 + x_3^2) = 9.$$

取 $x=e_2$ 達等號，所以 $\|E\|_2 = 3$；另一方面 $\|E\|_F^2 = 0 + 9 + 4 = 13$。向量 e_2+e_3 長度為 √2，不是單位向量；正規化後輸出長度為 $\sqrt{13/2} < 3$，沒有違反二範數界。

2. 有間隔仍可有多個二範數最優矩陣

$$\|A - B_c\|_2 = \max\{|8-c|, 3, 2\}, \qquad \|A - B_c\|_F^2 = (8-c)^2 + 13.$$

Eckart–Young 的全域二範數下界為 3，因此此族達到最優恰須 $|8-c| \le 3$，即 $5 \le c \le 11$。這些 c 都非零，B 的秩確為 1。Frobenius 下界為 √13，此族只在 c=8 取到。這只分類了對角族 Bc；未排除其他形式的二範數最優矩陣。

3. 非對角候選矩陣的核向量

取 $z = (1,-1,0)^T/\sqrt{2}$。直接相乘得 Bz=0，而 $Az = (8,-3,0)^T/\sqrt{2}$，所以

$$\|(A-B)z\|^2 = \|Az\|^2 = 73/2 \ge 9.$$

因 z 為單位向量，$\|A-B\|_2 \ge \sqrt{73/2} > 3$，故這個 B 並非最優。一般證明只需存在一個單位核向量，就能排除小於 3 的候選誤差；不必預先知道 B 的 SVD。

第 7 章練習解答 （續）

4. Frobenius 的全域唯一性

令 P 為投影到 C(B) 的正交投影，其秩至多 1。以標準基底設 $\alpha_i = \|Pe_i\|^2$，則 $0 \le \alpha_i \le 1$、$\alpha_1 + \alpha_2 + \alpha_3 \le 1$。可保留的平方和滿足 $\operatorname{tr}(PAA^T) = 64\alpha_1 + 9\alpha_2 + 4\alpha_3 \le 64\alpha_1 + 9(1-\alpha_1) \le 64$。若要讓總誤差平方達到下界 13，保留的平方和必為 64；這迫使 α_1=1，再由總額度限制得 α_2=α_3=0，故 P 必投影到 span(e_1)。逐欄畢氏等式為 $\|A-B\|_F^2 = \|(I-P)A\|_F^2 + \|PA-B\|_F^2$。此時第一項已是 13，第二項必為 0，所以 B=PA=diag(8,0,0)。這證明最優矩陣在所有允許的矩陣中唯一，不只是在對角族內唯一。

5. 截斷切過相等奇異值

令 $w_\theta^\perp = (-\sin\theta, \cos\theta, 0)^T$。向量 $w_\theta, w_\theta^\perp, e_3$ 為正交單位基底。在這組基底下，D 的作用依序是乘 3、3、1；Cθ 的作用是乘 3、0、0，所以誤差作用是乘 0、3、1。因此

$$\|D - C_\theta\|_2 = 3, \qquad \|D - C_\theta\|_F = \sqrt{3^2 + 1^2} = \sqrt{10}.$$

兩值都達到 Eckart–Young 下界。θ=0 時保留 e_1，θ=π/2 時保留 e_2，得到不同的矩陣；同時 θ 與 θ+π 給相同的投影，不能把每個角度都算不同。奇異值 3 的完整子空間始終是 span(e_1,e_2)，改變的是其中選入的一維方向。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

第 7 章練習解答 （續）

原創驗算程式附錄: svd_and_pca.py

```
"""Recompute simple SVD, low-rank PCA and pseudoinverse checks."""

from math import sqrt


Vec = tuple[float, ...]
Mat = tuple[tuple[float, ...], ...]


def transpose(a: Mat) -> Mat:
    return tuple(zip(*a))


def matmul(a: Mat, b: Mat) -> Mat:
    return tuple(
        tuple(
            sum(a[i][k] * b[k][j] for k in range(len(b)))
            for j in range(len(b[0]))
        )
        for i in range(len(a))
    )


def fmt(value: float) -> float:
    return 0.0 if abs(value) < 1e-12 else round(value, 12)


def clean(a: Mat) -> Mat:
    return tuple(tuple(fmt(x) for x in row) for row in a)


a = ((1.0, 1.0), (1.0, -1.0), (1.0, 0.0))
u = (
    (1 / sqrt(3), 1 / sqrt(2)),
    (1 / sqrt(3), -1 / sqrt(2)),
    (1 / sqrt(3), 0.0),
)
sigma = ((sqrt(3), 0.0), (0.0, sqrt(2)))
v = ((1.0, 0.0), (0.0, 1.0))
reconstructed = matmul(matmul(u, sigma), transpose(v))
assert clean(reconstructed) == a

rank_one = ((1.0, 2.0), (2.0, 4.0))
```

Lin Cing https://github.com/xinhi6716/computer-science-self-study

第 7 章練習解答 （續）

```
u1 = (1 / sqrt(5), 2 / sqrt(5))
v1 = (1 / sqrt(5), 2 / sqrt(5))
rebuilt_rank_one = tuple(
    tuple(5.0 * u1[i] * v1[j] for j in range(2))
    for i in range(2)
)
assert clean(rebuilt_rank_one) == rank_one

centered = ((-1.0, 0.0, 1.0), (-1.0, 1.0, 0.0))
pc1 = (1 / sqrt(2), 1 / sqrt(2))
pc2 = (1 / sqrt(2), -1 / sqrt(2))
scores1 = tuple(
    sum(pc1[i] * centered[i][j] for i in range(2))
    for j in range(3)
)
scores2 = tuple(
    sum(pc2[i] * centered[i][j] for i in range(2))
    for j in range(3)
)
assert abs(sum(x * x for x in scores1) - 3.0) < 1e-12
assert abs(sum(x * x for x in scores2) - 1.0) < 1e-12

b = (1.0, 3.0)
a_plus_times_b = (7.0 / 25.0, 14.0 / 25.0)
projection = tuple((7.0 / (5.0**0.5)) * u1[i] for i in range(2))
assert clean((tuple(a_plus_times_b),))[0] == a_plus_times_b
assert clean((projection,))[0] == (7.0 / 5.0, 14.0 / 5.0)

exercise7 = ((1.0, 1.0), (2.0, 2.0))
exercise7_plus = ((0.1, 0.2), (0.1, 0.2))
exercise7_x = matmul(exercise7_plus, ((1.0,), (3.0,)))
assert clean(exercise7_x) == ((0.7,), (0.7,))
assert clean(matmul(exercise7, exercise7_x)) == ((1.4,), (2.8,))
assert clean(matmul(matmul(exercise7, exercise7_plus), exercise7)) == exercise7
u3 = (1 / sqrt(6), 1 / sqrt(6), -2 / sqrt(6))
assert all(abs(sum(a[i][j] * u3[i] for i in range(3))) < 1e-12 for j in range(2))

print("reduced SVD reconstruction =", reconstructed)
print("PCA scores =", scores1, scores2)
print("A plus b =", a_plus_times_b)
print("projection =", projection)
```

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。
https://github.com/xinhi6716/computer-science-self-study