抽象映射與座標表示

線性轉換（linear transformation）是向量空間之間的映射

$$T: V \to W,$$

本章的維度公式先限定有限維空間；線性映射的定義本身不需此限制。它保持向量加法與純量乘法。T 本身不依賴基底；選定輸入與輸出基底後，才得到矩陣。

旋轉矩陣

$$R_\theta = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$

是某組標準座標下的表示。換基底會改變矩陣元素，但不會改變旋轉本身。

核（kernel）、像（image）、秩、單射與滿射是映射本身的不變性質；矩陣元素與行列式的解讀則取決於輸入、輸出座標之間的換算。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

線性性

映射 $T : V \to W$ 線性，意指對任意向量 u, v 與純量 α, β，

$$T(\alpha u + \beta v) = \alpha T(u) + \beta T(v).$$

因此 $T(0) = 0$，且對任意有限線性組合，

$$T\left(\sum_i c_i v_i\right) = \sum_i c_i T(v_i).$$

只要知道一組基底向量的像，就能求出任何輸入的像。$T(0) = 0$ 是必要條件，單獨檢查它還不能證明線性。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

核、像與秩—零度定理

核與像定義為

$$N(T) = \{v \in V : T(v) = 0\},$$
$$C(T) = \{T(v) : v \in V\}.$$

它們分別是 V 與 W 的子空間。秩—零度定理為

$$\dim V = \dim N(T) + \dim C(T).$$

證明：取 $N(T)$ 的一組基底

$$v_1, \ldots, v_k,$$

擴充成 V 的一組基底

$$v_1, \ldots, v_k, u_1, \ldots, u_r.$$

$T(u_1), \ldots, T(u_r)$ 張成像；其線性獨立性來自：若 $\sum c_i T(u_i) = 0$，則 $\sum c_i u_i \in N(T)$，在完整基底中所有 c_i 必為零。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

單射、滿射與維度

線性映射 T 是單射，若且唯若

$$N(T) = \{0\}.$$

先證充分性：假設 $N(T) = \{0\}$。若 $T(u) = T(v)$，線性性給 $T(u - v) = 0$，故 $u - v \in N(T)$，由零核假設得 $u = v$，所以 T 單射。再證必要性：若 T 單射且 $v \in N(T)$，則 $T(v) = 0 = T(0)$，單射性推出 $v = 0$；又線性性給 $0 \in N(T)$，故核恰為 $\{0\}$。

滿射表示

$$C(T) = W.$$

對同一有限維空間上的線性映射 $T \colon V \to V$，可逆、$N(T) = \{0\}$、$\operatorname{rank} T = \dim V$ 與座標矩陣可逆四個條件等價。

定義域與對應域維度不同時，單射與滿射不必同時成立。$\mathbb{R}^2 \to \mathbb{R}^3$ 可以是單射，但像最多只有二維，不可能滿射。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

線性映射的例子

- 旋轉 $T(x, y) = (-y, x)$：核為零，像為整個平面。
- 投影 $P(x, y) = (x, 0)$：核是 y 軸，像是 x 軸。
- 對實或複係數多項式空間 $\mathcal{P}_k$，微分的核是常數；$k \geq 1$ 時像為 $\mathcal{P}_{k-1}$，$k = 0$ 時像為 $\{0\}$。
- $I(p)(t) = \int_0^t p(s)\, ds$ 的核為零，像是常數項為零、次數至多 $k + 1$ 的多項式。
- 純量伸縮 $S(x) = cx$：$c \neq 0$ 時可逆；$c = 0$ 時像只有零向量。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

線性映射與仿射映射

仿射映射：

$$T(x) = Ax + b.$$

它保持仿射組合 $T((1-t)x + ty) = (1-t)T(x) + tT(y)$。若直線方向被 A 消去，整條線可塌成一點；否則沿線比例保持。當 $b \neq 0$ 時

$$T(0) = b \neq 0,$$

所以它在向量空間意義下不是線性的。

即使圖形是一條直線，映射也不一定線性。例如

$$f(x) = 2x + 1$$

不滿足 $f(0) = 0$，也不滿足 $f(cx) = cf(x)$。

二次映射 $T(x) = x^2$ 也不是線性映射；它不保持向量加法或純量乘法。判定線性性時，先檢查 $T(0) = 0$，再檢查線性組合。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

由基底向量的像建立矩陣

給定有序輸入基底 $(v_1, \dots, v_n)$ 和輸出基底 $(w_1, \dots, w_m)$，逐個展開 $T(v_j) = \sum_i M_{ij} w_i$。矩陣的第 j 欄就是第 j 個基底向量之像的輸出座標：

$$M = \begin{bmatrix} [T(v_1)]_{\text{out}} & \cdots & [T(v_n)]_{\text{out}} \end{bmatrix}.$$

對 $x = \sum_j c_j v_j$，線性性給

$$[T(x)]_{\text{out}} = M [x]_{\text{in}}.$$

M 有 m 列、n 欄；任何座標順序都必須與基底順序一致。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

標準矩陣的完整例子

令

$$T(x, y) = (x + y, x - y, 2x).$$

標準基底的像：

$$T(e_1) = (1, 1, 2)^T, \qquad T(e_2) = (1, -1, 0)^T.$$

故

$$A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 2 & 0 \end{bmatrix}.$$

這是 3×2 矩陣。核為

$$x + y = 0, \quad x - y = 0, \quad 2x = 0$$

只得到 $x = y = 0$，所以 T 是單射。像是 $\mathbb{R}^3$ 中秩為 2 的平面，而不是整個 $\mathbb{R}^3$。

再取 $S \colon \mathbb{R}^3 \to \mathbb{R}^2$，

Lin Cing https://github.com/xinhi6716/computer-science-self-study

標準矩陣的完整例子 （續）

$$S(x,y,z)=(x+z,y-2z),\qquad N=\begin{bmatrix}1&0&1\\0&1&-2\end{bmatrix}.$$

組合映射定義為 $(S\circ T)(v)=S(T(v))$。當 T 的輸出基底與 S 的輸入基底一致，

$$[S\circ T]_{\text{std}}=NA=\begin{bmatrix}1&0&1\\0&1&-2\end{bmatrix}\begin{bmatrix}1&1\\1&-1\\2&0\end{bmatrix}=\begin{bmatrix}3&1\\-3&-1\end{bmatrix}.$$

對 $v=(1,2)^T$，$T(v)=(3,-1,2)^T$，因此

$$S(T(v))=(5,-5)^T=(NA)v.$$

先作用最右邊的 A，再作用 N；若基底不同，必須先插入座標換算。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

換基底公式

此處先取 $V = \mathbb{R}^n$、$W = \mathbb{R}^m$，A 是標準基底下的矩陣。B_{in}、B_{out} 的欄分別是新輸入、輸出基底向量的標準座標；兩者各自為可逆方陣：

$$[x]_{\text{std}} = B_{\text{in}}[x]_{B_{\text{in}}},$$
$$[y]_{B_{\text{out}}} = B_{\text{out}}^{-1} y_{\text{std}}.$$

依序：

1. 用 B_{in} 把輸入座標轉成標準座標；
2. 套用 A；
3. 用 B_{out}^{-1} 把輸出的標準座標轉成輸出基底座標。

因此

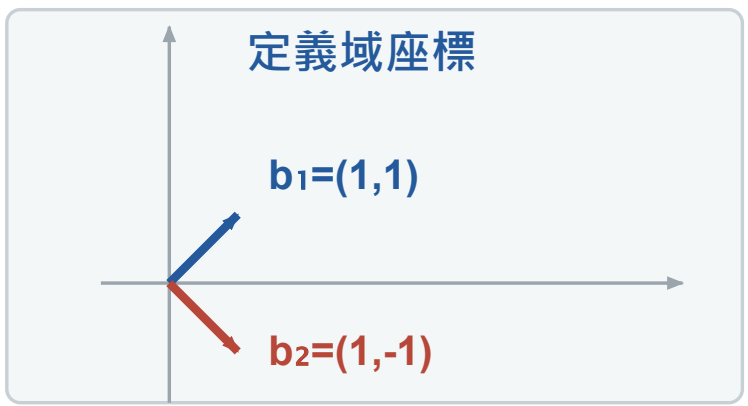
$$[T(x)]_{B_{\text{out}}} = B_{\text{out}}^{-1} A B_{\text{in}} [x]_{B_{\text{in}}},$$
$$M = B_{\text{out}}^{-1} A B_{\text{in}}.$$

B_{in} 是定義域基底，B_{out} 是對應域基底，兩者維度可以不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

換基底公式 （續）

換基底方向：Bin 輸入，Bout^{-1} 輸出



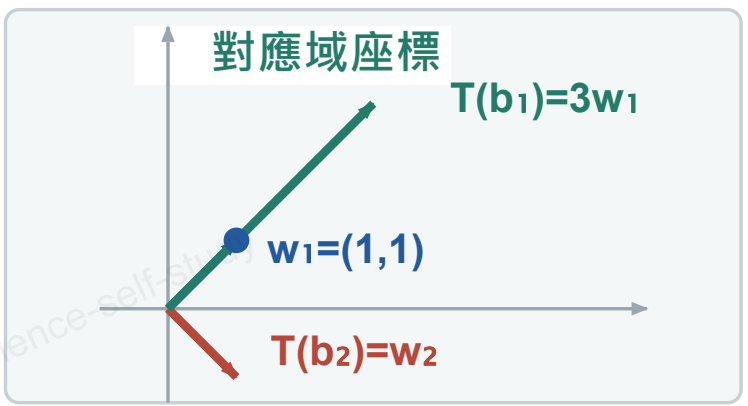
A=[[2,1],[1,2]]

Bin=[[1,1],[1,-1]]

Bout=Bin

M=[[3,0],[0,1]]

$M=\text{Bout}^{-1}\ A\ \text{Bin}$



同一個二維例子取

$$A=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix},\qquad B_{\text{in}}=B_{\text{out}}=B=\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}.$$

因 $Ab_1=(3,3)^T=3b_1$、$Ab_2=(1,-1)^T=b_2$，

換基底公式 （續）

$$M = B^{-1}AB = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

取 $x = (2,0)^T$，輸入座標是 $B^{-1}x = (1,1)^T$。先在基底座標下套用 M，得到 $(3,1)^T$，再用 B 轉回標準座標：

$$B(3,1)^T = (4,2)^T = A(2,0)^T.$$

輸入端先用 B_{in} 把基底座標轉成標準座標；輸出端再用 B_{out}^{-1} 把標準座標轉成輸出基底座標。這兩個方向不能顛倒。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

輸入與輸出維度不同，仍可換基底

沿用 $T(x,y)=(x+y,x-y,2x)$ 的標準矩陣 $A\in\mathbb{R}^{3\times 2}$。以欄向量表示兩個新基底：

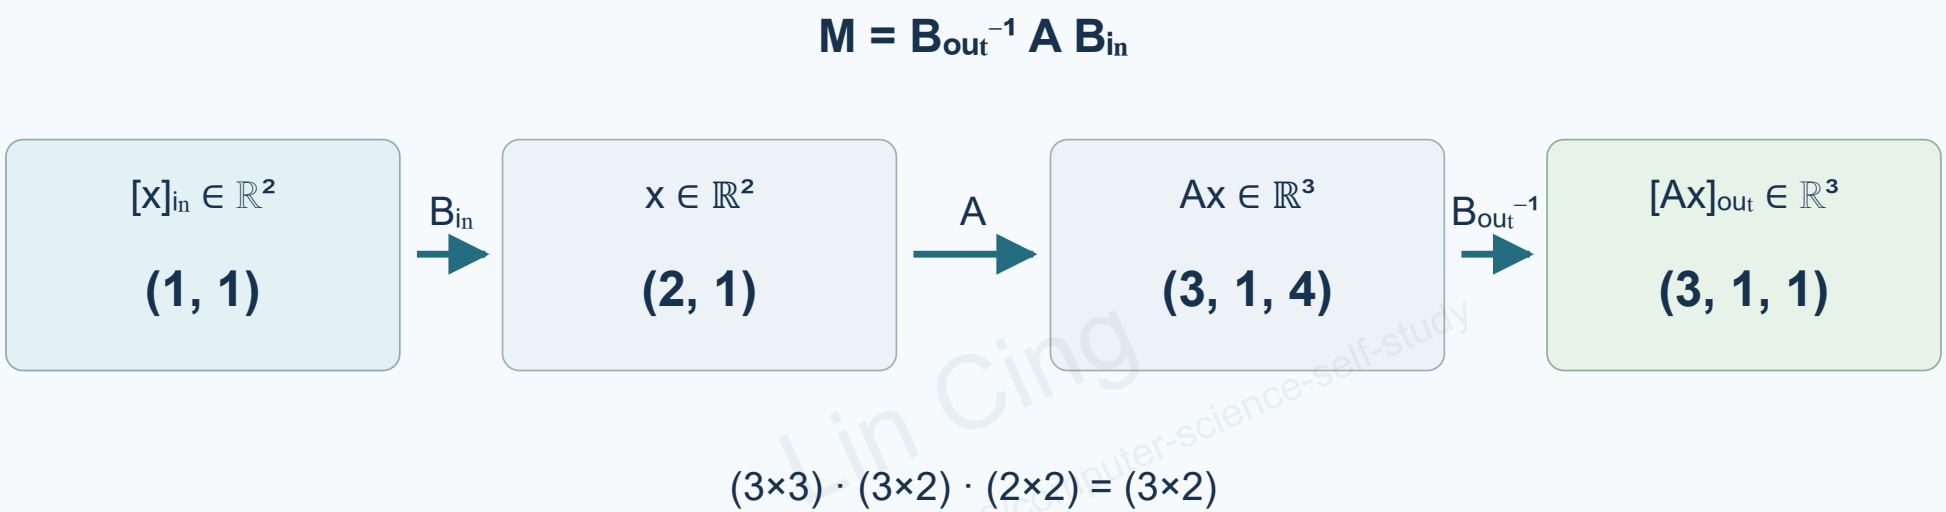
$$B_{\text{in}}=\begin{bmatrix}1 & 1\\ 0 & 1\end{bmatrix},\qquad B_{\text{out}}=\begin{bmatrix}1 & 0 & 0\\ 0 & 1 & 0\\ 1 & 0 & 1\end{bmatrix}.$$

兩者分別是 2×2、3×3 的可逆基底矩陣。由 $AB_{\text{in}}=\begin{bmatrix}1 & 2\\ 1 & 0\\ 2 & 2\end{bmatrix}$，以及

$$B_{\text{out}}^{-1}=\begin{bmatrix}1 & 0 & 0\\ 0 & 1 & 0\\ -1 & 0 & 1\end{bmatrix},\quad M=B_{\text{out}}^{-1}AB_{\text{in}}=\begin{bmatrix}1 & 2\\ 1 & 0\\ 1 & 0\end{bmatrix}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

用同一個向量核對四個座標



取 $[x]_{\text{in}} = (1, 1)^T$，左到右得到標準座標 $x = (2, 1)^T$、$Ax = (3, 1, 4)^T$、$[Ax]_{\text{out}} = (3, 1, 1)^T$。直接計算 $M[x]_{\text{in}}$ 也得到 $(3, 1, 1)^T$。矩陣乘法的尺寸與結果都一致。

同一空間上的相似變換

當 $V = W$，且輸入、輸出使用同一個基底 B：

$$[T]_B = B^{-1}AB.$$

若 $Av = \lambda v$，且 $y = B^{-1}v$：

$$B^{-1}AB\,y = B^{-1}Av = \lambda y.$$

所以 A 與 $B^{-1}AB$ 有相同的特徵多項式與特徵值；跡與行列式也不變：

$$\operatorname{tr}(B^{-1}AB) = \operatorname{tr} A,$$
$$\det(B^{-1}AB) = \det A.$$

但輸入基底與輸出基底不同時，矩陣可為長方形，不能直接稱為相似矩陣。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

方陣也不一定是相似變換

取 $T = I_2$、輸入基底矩陣 $B_{\text{in}} = I_2$、輸出基底矩陣 $B_{\text{out}} = 2I_2$。同一個向量映回自己，但新座標矩陣是

$$M = B_{\text{out}}^{-1} I_2 B_{\text{in}} = \tfrac{1}{2} I_2.$$

因此 M 的特徵值是 $1/2, 1/2$，行列式是 $1/4$；原矩陣 I_2 的特徵值都是 1，行列式是 1。它們不是相似矩陣。

相似公式要求同一個空間的輸入和輸出都使用**同一組**新基底；只有兩邊各自換基底時，矩陣尺寸相同仍不足以保證相似。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

特徵基底例子

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

特徵基底：

$$B = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

$$B^{-1} = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

因此

$$B^{-1}AB = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

同一個映射在特徵基底下只在各方向獨立伸縮。若 B 的條件數很大，座標誤差也可能被放大；理論上可對角化，不代表數值上的基底好用。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

微分映射的兩組基底

$D\colon \mathcal{P}_2 \to \mathcal{P}_1$，輸入使用單項式基底

$$(1, t, t^2),$$

輸出基底為 $(1, t)$。

$$D(1) = 0, \qquad D(t) = 1, \qquad D(t^2) = 2t.$$

所以

$$M = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix}.$$

若輸入基底改成 $1, s, s^2$、$s = t - 1$，則

$$D(s^2) = 2s = -2 + 2t,$$

新矩陣為

$$\begin{bmatrix} 0 & 1 & -2 \\ 0 & 0 & 2 \end{bmatrix}.$$

換基底只改變表示，不改變微分映射本身。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

多項式上的映射：先看基底向量的像

令 $T:\mathcal{P}_2\to\mathcal{P}_2$、$T(p)=xp'+p''$，兩組有序基底為 $\beta=(1,x,x^2)$、$\gamma=(1,1+x,1+x^2)$。

因 $T(1)=0$、$T(x)=x$、$T(x^2)=2+2x^2$，在 β 下的矩陣及換座標矩陣是

$$A=[T]_\beta=\begin{bmatrix}0&0&2\\0&1&0\\0&0&2\end{bmatrix},\quad P=\begin{bmatrix}1&1&1\\0&1&0\\0&0&1\end{bmatrix}.$$

P 的欄是 γ 向量的 β 座標，所以 $[p]_\beta=P[p]_\gamma$，方向不能顛倒。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

兩種方法算出同一個座標矩陣

$P^{-1} = \begin{bmatrix} 1 & -1 & -1 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$，因此

$$[T]_\gamma = P^{-1}AP = \begin{bmatrix} 0 & -1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix}.$$

直接逐欄核對：$T(1) = 0$、$T(1+x) = x = -1 \cdot 1 + 1(1+x)$、$T(1+x^2) = 2(1+x^2)$。

取 $[p]_\gamma = (2, -1, 3)^T$，則 $[p]_\beta = P[p]_\gamma = (4, -1, 3)^T$，也就是 $p = 4 - x + 3x^2$。計算 $T(p) = 6 - x + 6x^2$，其 γ 座標為 $(1, -1, 6)^T$，與直接乘 $[T]_\gamma [p]_\gamma$ 完全一致。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

不變子空間

子空間 $U \subseteq V$ 稱為不變子空間，若

$$T(U) \subseteq U.$$

每條特徵向量所張成的一維空間，都是最小的非零不變子空間。若

$$V = U \oplus W$$

且 U, W 都不變，則選用適當基底後，矩陣呈分塊對角。

只有 U 不變時，取 U 的基底後，可得到上三角分塊：

$$\begin{bmatrix} A_1 & B \\ 0 & A_2 \end{bmatrix}.$$

不變子空間把大型映射拆成較小的分塊；這個想法是 Schur 形式與 Jordan 形式共同的結構來源。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

特徵基底與對角化

若 $b_1, \dots, b_n$ 構成一組特徵向量基底：

$$B = [b_1 \ \cdots \ b_n],$$

則

$$B^{-1} A B = \operatorname{diag}(\lambda_1, \dots, \lambda_n).$$

特徵基底把互相耦合的系統拆成獨立模式，因此矩陣冪、指數與差分方程都能逐個模式計算。

實對稱矩陣可選用正交歸一的特徵基底 Q，使

$$Q^{-1} = Q^{T}.$$

此時基底矩陣的逆等於轉置，條件數為 1。非對稱矩陣的特徵基底可能接近線性相依，因此不能只檢查特徵值的個數。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Jordan 形式與廣義特徵向量

每個複方陣 A 都有 Jordan 形式：

$$J = B^{-1} A B.$$

其中一個分塊為

$$J_k(\lambda) = \begin{bmatrix} \lambda & 1 & & 0 \\ 0 & \lambda & \ddots & \\ & \ddots & \ddots & 1 \\ 0 & & 0 & \lambda \end{bmatrix}.$$

對角線放特徵值，上方的 1 表示廣義特徵向量鏈。非零向量 w 若滿足

$$(A - \lambda I)^m w = 0$$

對某個 $m \geq 1$ 成立，就是廣義特徵向量。Jordan 鏈滿足 $(A - \lambda I) w_1 = 0$、$(A - \lambda I) w_{j+1} = w_j$，因此其基底表示的超對角線是 1。Jordan 定理的完整一般證明不在本章範圍；本章只在練習中用二階冪零分塊實算。

Jordan 定理給出理論上的標準形式；實務演算法通常不直接計算容易不穩定的 Jordan 分解，而更常使用 Schur 形式、SVD 或具結構的方法。

循環矩陣與 Fourier 基底

$n = 4$ 時，左移一個位置的循環排列矩陣為

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

把 $(x_0, x_1, x_2, x_3)^T$ 映到 $(x_1, x_2, x_3, x_0)^T$。

取四次單位根

$$\lambda \in \{1, i, -1, -i\},$$
$$v_\lambda = (1, \lambda, \lambda^2, \lambda^3)^T.$$

最後一個座標繞回第一列時使用 $\lambda^4 = 1$，所以

$$Pv_\lambda = \lambda v_\lambda.$$

四個單位根給出四個線性獨立的特徵向量。Fourier 矩陣不僅對角化 P，也對角化所有循環矩陣

$$C = c_0 I + c_1 P + c_2 P^2 + c_3 P^3.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

有限基底與無窮展開要分清楚

在多項式空間 $\mathcal{P}_n$ 中，$(1, x, \ldots, x^n)$ 是有限基底；所有多項式的空間也有單項式的 Hamel 基底，因為每個多項式都只用有限個係數。這不代表有限個單項式能表示所有連續函數，例如 e^x。

Fourier 複指數可作為 $L^2[-\pi, \pi]$ 的完整正交展開系統：任一元素可由部分和在 L^2 範數下逼近。這是指定收斂意義的**無窮展開**，並不表示每個函數都是有限項線性組合，也不自動保證逐點收斂。Legendre 多項式亦可在 $L^2[-1, 1]$ 作正交展開；實際有限截斷只落在有限維子空間。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

先分清誤差往哪個方向傳

令 X 為可逆基底矩陣，$x = Xc$。若幾何向量有擾動 δx，由 $c = X^{-1}x$ 得

$$\delta c = X^{-1}\delta x, \qquad \|\delta c\|_2 \le \|X^{-1}\|_2 \|\delta x\|_2.$$

反過來，若先擾動座標 δc，則 $\delta x = X\delta c$，受 $\|X\|_2$ 控制。兩個方向的放大因子不同。

當 $x, c \neq 0$ 時，由 $\|x\| \le \|X\|\|c\|$ 得相對誤差界

$$\frac{\|\delta c\|_2}{\|c\|_2} \le \kappa_2(X) \frac{\|\delta x\|_2}{\|x\|_2}.$$

條件數大表示最壞情況可能敏感，不代表每個方向或每次擾動都達到上界。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

整合例子

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, \qquad B = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

$$B^{-1}AB = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

對

$$x = (2, 0)^T,$$

eigenbasis coordinates：

$$c = B^{-1}x = (1, 1)^T.$$

$$[T^5 x]_B = \begin{bmatrix} 4^5 & 0 \\ 0 & 2^5 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1024 \\ 32 \end{bmatrix}.$$

回到標準座標：

$$T^5 x = B \begin{bmatrix} 1024 \\ 32 \end{bmatrix} = \begin{bmatrix} 1056 \\ 992 \end{bmatrix}.$$

特徵基底把兩個模式分開。若 B 的條件數很差，還必須另外分析座標誤差。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

本章重點

- 核與像描述映射本身；矩陣由有序的輸入、輸出基底決定。
- 先將輸入座標轉回參照基底，作用後再轉為輸出座標。
- 同一空間、同一新基底才給相似變換；兩端獨立換基底不保證相似。
- 無窮展開必須說明函數空間與收斂方式；基底條件數影響座標敏感度。

參考資料與署名

Lin Cing，《線性代數》手寫筆記。 Gilbert Strang, Introduction to Linear Algebra, 5th ed., Chapter 8.

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study