三個不能混淆的目標

數值線性代數同時追求：

1. **速度**：flops、記憶體、communication 與 parallelism。
2. **準確度**：計算結果離精確解多遠。
3. **穩定性**：演算法的捨入誤差是否可解釋為輸入的小擾動；這要與問題本身對擾動的敏感性分開。

精確公式不等於穩定演算法；$\det A = 1$ 也不保證逆映射對擾動不敏感。數學上非奇異的矩陣仍可能有很差的數值條件。

誤差必須指定度量：

$$\text{absolute error } \|x - \widehat{x}\|, \qquad \text{relative error } \frac{\|x - \widehat{x}\|}{\|x\|},$$

$$\text{residual } \|b - A\widehat{x}\|.$$

沒有範數、尺度與容差的「誤差很小」無法驗證。

浮點運算與後向誤差

浮點運算的基本模型是

$$\mathrm{fl}(x \circ y) = (x \circ y)(1 + \delta), \qquad |\delta| \le u,$$

其中 u 是單位捨入誤差，假設輸入為已表示的數值、採正常捨入，且未溢位或進入需另處理的下溢範圍。相消不必破壞單次操作的相對模型，但會暴露輸入先前的誤差。累積誤差也受成長因子與條件數影響。

接近相等的數相減會失去有效位數：

$$1.0000001 - 1.0000000 = 1 \cdot 10^{-7}.$$

後向誤差問計算值 $\widehat{x}$ 是否精確解出附近問題：

$$(A + \Delta A)\widehat{x} = b + \Delta b.$$

後向穩定只保證 $\Delta A, \Delta b$ 小；前向誤差仍可能被條件數放大。

Gaussian elimination 與 multipliers

對 pivot d 與下方元素 a_{ik}，乘數為

$$\ell_{ik} = \frac{a_{ik}}{d}.$$

小 pivot 可能產生大乘數，放大既有的捨入誤差。部分選主元在目前 column 選絕對值最大的元素：

$$|d| = \max_{i \ge k} |a_{ik}|.$$

因此 $|\ell_{ik}| \le 1$，可控制一個常見的成長來源。部分選主元不保證所有矩陣的 growth 最小；特殊結構可能需要完整選主元或 rook pivoting。

消去結果寫成

$$PA = LU.$$

置換矩陣 P 必須與乘數一起處理。實作時只交換 U 的 rows，卻沒有同步交換下三角部分儲存的乘數，是常見錯誤。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Factorization 與 solve workflow

稠密矩陣 $A \in \mathbb{R}^{n \times n}$ 的主要成本為

- 帶選主元的 LU：$\frac{2}{3}n^3 + O(n^2)$ flops；
- 前代 $Ly = Pb$：$O(n^2)$；
- 回代 $Ux = y$：$O(n^2)$。

分解建好後，多個右端向量可重複使用，比每次重做三次方的消去便宜。

安全的求解流程：

1. 帶選主元做分解；
2. 估計範數與條件數；
3. 求解；
4. 計算真實殘差；
5. 需要時做迭代改進；
6. 記錄誤差界與尺度假設。

不要只看 $\det A$ 或 pivot 是否等於零。行列式可能溢位／下溢，且其大小本身不是尺度不變的條件數指標。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

稀疏矩陣與填入

大型工程矩陣通常稀疏。直接儲存 n^2 個零元素會浪費記憶體，乘法也浪費工作量。

消去是否能保持零元素，取決於排序。星形圖若先消除中央變數，會把所有葉節點連成稠密團；先消除 leaves 可大幅降低填入。

稀疏圖的判讀方式是

- 變數是節點；
- 非零的非對角元素是邊；
- 消除一個節點時，尚未消除的鄰居之間會產生填入邊。

最小度排序、巢狀剖分與反向 Cuthill-McKee 等方法可降低填入或頻寬。平行系統還要考慮通訊與負載平衡，填入數量不是唯一成本。

以下固定同一個小型消去例，

$$A = \begin{bmatrix} 0.001 & 1 \\ 1 & 1 \end{bmatrix}, \qquad b = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

不交換列時，第一個 multiplier 是 $1/0.001 = 1000$，消去後得到

$$U = \begin{bmatrix} 0.001 & 1 \\ 0 & -999 \end{bmatrix}.$$

交換兩列後，multiplier 只有 0.001，且

稀疏矩陣與填入 （續）

$$U = \begin{bmatrix} 1 & 1 \\ 0 & 0.999 \end{bmatrix}.$$

兩條路徑在精確算術都給同一解

$$x = \left(\frac{1000}{999}, \frac{998}{999} \right)^T, \qquad Ax - b = 0.$$

圖下半部另以 star graph 顯示 ordering 的稀疏效果。中心先消去時，三個 leaves 兩兩形成三條 fill edges；葉節點先消去時新增 fill edges 為零。數值 growth 與 sparse fill 是兩種不同成本，不能只看同一個 multiplier 或同一個 edge count。

若矩陣的上下頻寬分別為 p, q，只保存 band 內元素可用 $O(n(p+q))$ 記憶體；無 pivot 的 band elimination 約需 $O(npq)$ 工作量，三角求解約 $O(n(p+q))$。三對角矩陣是 $p = q = 1$，因此 LU 與求解都只需 $O(n)$。這些成本結果要求 pivot 不破壞頻寬；需要選主元時，必須把置換與更新後的頻寬一併分析。

稀疏矩陣與填入 （續）

Pivoting：multiplier 大小與同一解

不交換列

A=[[0.001,1],[1,1]]

ℓ_{21}=1000

U=[[0.001,1],[0,-999]]

x=(1000/999,998/999) · Ax-b=0

部分選主元

先交換兩列

ℓ_{21}=0.001

U=[[1,1],[0,0.999]]

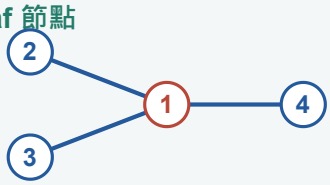
消去排序：星形稀疏圖的 fill edges

先消中心



中心消去後新增 3 條 fill edges

先消 leaf 節點



葉節點先消：新增 0 條

正定消去與 Cholesky

若 $A = A^T$ 正定，對稱消去可寫成

$$A = LDL^T,$$

其中 L 是單位下三角矩陣，D 是正對角矩陣。取

$$R = LD^{1/2}, \qquad A = RR^T$$

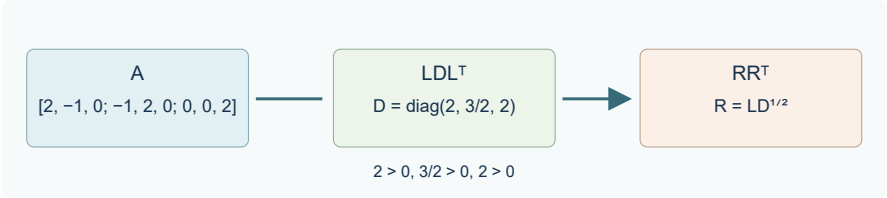
得到 Cholesky 分解。它只儲存一個三角部分，約需 $n(n+1)/2$ 個數值元素，領先項成本 $n^3/3$，是一般 LU 的一半。存在性也可由歸納證明：正定矩陣的第一主元 $a_{11} > 0$，消去後

$$S = A_{22} - \frac{1}{a_{11}} a_{21} a_{21}^T$$

仍是正定 Schur 補矩陣，因為對任意 $y \neq 0$，把 $[-(a_{21}^T y)/a_{11};\ y]$ 代入 $x^T A x > 0$ 即得 $y^T S y > 0$。歸納後所有對角 pivots 都正。

對實對稱矩陣，無需換列的消去若所有 pivots 為正，可檢查其正定性。若 A 滿 column rank，為 least squares 先形成 $A^T A$ 會使 $\kappa_2(A^T A) = \kappa_2(A)^2$，並可能造成溢位；較佳做法是直接對 A 做穩定 QR。

從消去到 Cholesky：一個完整算例



取 $A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix}$。先消去第一欄，Schur 補為 $\mathrm{diag}(3/2, 2)$，得到

$$L = \begin{bmatrix} 1 & 0 & 0 \\ -1/2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad D = \mathrm{diag}(2, 3/2, 2), \quad A = LDL^T.$$

D 的各項皆正，令 $R = LD^{1/2}$，便有 $A = RR^T$。

$$R = \begin{bmatrix} \sqrt{2} & 0 & 0 \\ -1/\sqrt{2} & \sqrt{3/2} & 0 \\ 0 & 0 & \sqrt{2} \end{bmatrix}, \quad (RR^T)_{22} = 1/2 + 3/2 = 2.$$

穩定 QR 與 Householder 反射

Householder 反射矩陣為

$$H = I - 2\frac{vv^T}{v^Tv}.$$

當 $v \neq 0$，它是對稱正交矩陣，故 $H^TH = I$。對非零 x，取 $\alpha = -\operatorname{sign}(x_1)\|x\|$（$x_1 = 0$ 時取 sign 為 1），$v = x - \alpha e_1$。由 $v^Tx = \|x\|^2 - \alpha x_1$、$v^Tv = 2(\|x\|^2 - \alpha x_1)$，得 $Hx = \alpha e_1$。此符號選擇避免 v_1 相減消去有效位數。連續反射 matrices 給

$$R = H_k \cdots H_1 A, \qquad Q = H_1 \cdots H_k,$$

所以 $A = QR$。

Householder QR 通常比古典 Gram-Schmidt 更能保持 Q 的正交性，是稠密最小平方的標準方法。

對滿 column rank 的超定系統 $A \in \mathbb{R}^{m\times n}$，$m \geq n$，rank n，使用完整正交矩陣 $Q \in \mathbb{R}^{m\times m}$：

$$Q^TA = \begin{bmatrix} R \\ 0 \end{bmatrix}, \qquad Q^Tb = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix},$$

其中 R 是 $n \times n$ 可逆上三角矩陣。最小平方解解前 n 列：

$$Rx = c_1.$$

若改用薄型分解 $A = Q_1R$，則 $Q_1 \in \mathbb{R}^{m\times n}$，此時才寫 $Rx = Q_1^Tb$。完整 Q^Tb 有 m 個分量，不能直接放在 n 個方程的右端。

穩定 QR 與 Householder 反射 （續）

最小殘差平方是 $\|c_2\|_2^2$。不要形成 A^TA 或顯式 R^{-1}。稠密 Householder QR 的領先成本約 $2mn^2 - \frac{2}{3}n^3$ flops；形成 Q 會再增加儲存與成本，若只求解則可只套用 reflectors。

Givens 旋轉 G_{ij} 除了第 i, j 列與行交叉的 2×2 區塊外都與單位矩陣相同；一次可將選定的一個元素消成零：

$$G_{ij} = \begin{bmatrix} c & s \\ -s & c \end{bmatrix}, \qquad c^2 + s^2 = 1.$$

在精確算術中它保持正交，浮點實作仍有捨入誤差；且容易局部平行化，適合 sparse 或帶狀結構；稠密矩陣通常用 Householder，因為每個反射能一次清除整段 column，成本較低。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

特徵值的冪法與 QR 迭代

稠密非對稱特徵值問題通常採 QR 迭代，不以高次特徵多項式求根。先在可得的主導特徵值上比較冪法：若

$$A = X \operatorname{diag}(\lambda_1, \ldots, \lambda_n) X^{-1}, \qquad |\lambda_1| > |\lambda_2| \geq \cdots,$$

且初始向量在 λ_1 的特徵向量方向有非零分量，則 $A^k v_0$ 的方向趨近 λ_1 的特徵向量，速度由 $|\lambda_2/\lambda_1|^k$ 控制。每一步應正規化，避免溢位或下溢。若最大模 eigenvalue 有相同大小，例如旋轉矩陣，方向不會唯一收斂。

反冪法解

$$(A - \mu I) w_{k+1} = w_k$$

再正規化，會放大最接近位移 μ 的特徵向量。Rayleigh quotient

$$\mu_k = \frac{w_k^T A w_k}{w_k^T w_k}$$

常作下一次位移；若 $A - \mu I$ 幾乎奇異，需檢查 solver 狀態，不能把 breakdown 誤當精確收斂。

反冪法的方向收斂敘述承接可對角化假設，還要求 μ 不是特徵值、唯一的 λ_j 與 μ 距離最小，且初始向量在該特徵方向的係數非零。因 $(A - \mu I)^{-1}$ 的特徵值是 $(\lambda_i - \mu)^{-1}$，條件正好化為冪法的唯一最大模條件；兩個特徵值等距時不保證收斂到唯一方向。實對稱矩陣的 Rayleigh 商可用實向量；複數問題應使用 $w^H A w / (w^H w)$。

QR 方法的 unshifted step 為

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

特徵值的冪法與 QR 迭代 （續）

$$A_k = Q_k R_k, \qquad A_{k+1} = R_k Q_k.$$

因

$$A_{k+1} = Q_k^T A_k Q_k,$$

所以每一步都是 similarity transform，eigenvalues 不變。適當 shift 與 deflation 可收斂到 Schur form。複數算術下是上三角；實算術下可能是含 2×2 共軛特徵值區塊的準上三角，不能只讀每個對角項。未位移 QR 不保證任意矩陣收斂到三角形，例如平面旋轉。

Shifted QR：

$$A_k - \mu_k I = Q_k R_k, \qquad A_{k+1} = R_k Q_k + \mu_k I$$

可加速收斂。實作常先化為 Hessenberg，再做 implicit QR；對稱矩陣則先做三對角縮減。Hessenberg 結構把每一步 QR 的領先工作從 $O(n^3)$ 降到 $O(n^2)$；對稱三對角版本更便宜。大型稀疏矩陣可能需要 Lanczos（Hermitian）或 Arnoldi（general），只保留低維投影再解小特徵值問題；若目標是少數極端特徵值，通常比形成完整分解划算。

依矩陣結構選擇演算法

演算法選擇取決於結構、條件數與所需輸出：

- 一般稠密 $Ax = b$：帶選主元的 LU；
- 對稱正定：Cholesky；
- overdetermined least squares：Householder QR；
- 大 sparse SPD：preconditioned CG；
- 大 nonsymmetric sparse：GMRES 或 BiCGStab 類方法；
- 長方形矩陣的低秩分析：SVD；
- 稠密非對稱特徵值問題：Hessenberg QR 迭代；
- 對稱特徵值問題：三對角縮減與對稱 QR；
- 奇異值：雙對角 SVD 演算法。

沒有普遍最佳的演算法。分塊與硬體會改變常數，但數學結構先決定方法。

向量與矩陣範數

常用向量範數為

$$\|x\|_1 = \sum_i |x_i|, \qquad \|x\|_2 = \left(\sum_i |x_i|^2\right)^{1/2}, \qquad \|x\|_\infty = \max_i |x_i|.$$

誘導矩陣範數定義為

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

二範數下，由 SVD $A = U\Sigma V^T$ 可知

$$\|A\|_2 = \sigma_{\max}(A).$$

其他常用形式為

$$\|A\|_1 = \max_j \sum_i |a_{ij}|, \qquad \|A\|_\infty = \max_i \sum_j |a_{ij}|.$$

Frobenius 範數為

$$\|A\|_F = \left(\sum_{ij} |a_{ij}|^2\right)^{1/2}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

向量與矩陣範數 （續）

它把矩陣視為長向量計量，通常不是誘導算子範數。所有誘導範數都滿足次乘法性 $\|AB\| \leq \|A\|\|B\|$：對每個 x，先用 $\|ABx\| \leq \|A\|\|Bx\| \leq \|A\|\|B\|\|x\|$，再對所有單位向量取最大值。Frobenius 範數也滿足此不等式，但一般不是這個誘導最大成長率。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

條件數

可逆矩陣 A 的條件數為

$$\kappa(A) = \|A\|\|A^{-1}\|.$$

右端擾動的相對誤差界為

$$\frac{\|\Delta x\|}{\|x\|} \le \kappa(A)\frac{\|\Delta b\|}{\|b\|}.$$

矩陣擾動的一階近似（精確界見下文）為

$$\frac{\|\Delta x\|}{\|x\|} \lesssim \kappa(A)\frac{\|\Delta A\|}{\|A\|}.$$

二範數下，

$$\kappa_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}}.$$

右端界由 $\Delta x = A^{-1}\Delta b$ 與 $\|b\| \le \|A\|\|x\|$ 相乘得到，要求 $b \neq 0$。若只擾動矩陣，令 $\epsilon_A = \|\Delta A\|/\|A\|$，並要求 $\kappa(A)\epsilon_A < 1$，則 $(I + A^{-1}\Delta A)\Delta x = -A^{-1}\Delta A x$，Neumann 級數給精確界 $\|\Delta x\|/\|x\| \le \kappa(A)\epsilon_A/[1-\kappa(A)\epsilon_A]$。大 condition number 表示問題本身敏感，不代表演算法一定寫錯。縮放會改變所用的擾動度量。

逆矩陣本身的條件數與精確擾動界

設 A 可逆，$B = A + E$，使用相容的誘導範數。若 $\nu = \|A^{-1}E\| < 1$，Neumann 級數給 $(I + A^{-1}E)^{-1}$，因此 B 仍可逆，且

$$B^{-1} = (I + A^{-1}E)^{-1}A^{-1}, \qquad B^{-1} - A^{-1} = -B^{-1}EA^{-1}.$$

由 $\|B^{-1}\| \le \|A^{-1}\|/(1-\nu)$，令 $\varepsilon = \|E\|/\|A\|$，在 $\kappa(A)\varepsilon < 1$ 時得到

$$\frac{\|B^{-1} - A^{-1}\|}{\|A^{-1}\|} \le \frac{\kappa(A)\varepsilon}{1 - \kappa(A)\varepsilon}.$$

逆矩陣映射的一階變化是 $D\,\mathrm{inv}_A[E] = -A^{-1}EA^{-1}$，而不是逐元素取倒數。二範數下，這個相對條件數恰為 $\kappa_2(A)$，不只是上界：寫 $A = U\Sigma V^T$，沿最小奇異值方向取 $E = -\delta u_n v_n^T$，其中 $0 < \delta < \sigma_n$。其餘奇異方向不變，最小方向由 σ_n 減為 $\sigma_n - \delta$，所以

$$\frac{\|(A+E)^{-1} - A^{-1}\|_2}{\|A^{-1}\|_2} = \frac{\delta}{\sigma_n - \delta} = \frac{\kappa_2(A)(\delta/\sigma_1)}{1 - \kappa_2(A)(\delta/\sigma_1)}.$$

這個擾動使上界取等號；$\delta \uparrow \sigma_n$ 時接近奇異邊界。固定 b 的解向量敏感度、逆矩陣整體敏感度與演算法後向穩定性，是三個不同的敘述。

殘差、誤差與可驗證檢查

令真解為 x、計算解為 $\hat{x}$：

$$e = x - \hat{x}, \qquad r = b - A\hat{x} = Ae.$$

所以

$$e = A^{-1}r, \qquad \|e\| \le \|A^{-1}\|\|r\|.$$

小殘差只有在 $\|A^{-1}\|$ 可控時，才保證小的前向誤差。

例：$A = 10^{-12}$、真解 $x = 1$、計算解 $\hat{x} = 1 + \delta$，則

$$r = -10^{-12}\delta$$

可以極小，relative error 卻仍是 δ。

這個一維例子的相對條件數其實是 1；它展示絕對殘差受尺度影響，不是展示相對病態。相對殘差 $|r|/|b| = |\delta|$ 與相對解誤差仍相同。

正規化後向誤差為

$$\eta = \frac{\|r\|}{\|A\|\|\hat{x}\| + \|b\|}.$$

η 小表示此計算結果具有小的 normwise 後向誤差，不能單憑一次結果宣稱整個演算法對所有輸入都後向穩定。此處分母使用已算出的 $\hat{x}$，不是未知真解。若分母為零，則 $b = 0$ 且殘差為零，定義 $\eta = 0$。前向誤差仍由條件數控制。

特徵值與奇異向量的條件

若矩陣可對角化：

$$A = X\Lambda X^{-1},$$

特徵值擾動可能被 $\kappa(X) = \|X\|\|X^{-1}\|$ 放大。正規矩陣有正交歸一特徵基底，特徵值的條件通常較好。

非正規矩陣可能特徵值聚在一起，卻有敏感的特徵向量與很大的暫態放大。

奇異值的擾動較穩定。Weyl 不等式為

$$|\sigma_i(A + E) - \sigma_i(A)| \le \|E\|_2.$$

但奇異值彼此很接近時，奇異向量仍可能敏感。Numerical rank 需要容差與應用背景。

數值秩與偽逆門檻

若

$$\sigma_1 \geq \cdots \geq \sigma_r \gg \sigma_{r+1} \geq \cdots,$$

常用門檻

$$\sigma_i > \tau \sigma_1$$

來判斷數值秩。τ 需考慮機器精度、維度與資料雜訊。

截斷偽逆為

$$A_\tau^+ = V_r \operatorname{diag}(\sigma_1^{-1}, \ldots, \sigma_r^{-1}) U_r^T.$$

它給出截斷模型 $A_\tau x = b$ 的最小範數最小平方解；僅當 $b \in C(A_\tau)$ 時才精確滿足方程。例如 $A_\tau = \operatorname{diag}(1, 0)$、$b = (0, 1)^T$ 時，偽逆解為零而殘差仍是 b。它不是原完整矩陣的精確逆。報告時要附 τ、rank、residual 與誤差度量。

定常迭代的分割

選定分割

$$A = S - T,$$

其中求解 S 較便宜。原方程等價於

$$Sx = Tx + b.$$

迭代為

$$Sx_{k+1} = Tx_k + b.$$

令

$$G = S^{-1}T, \qquad c = S^{-1}b,$$

則

$$x_{k+1} = Gx_k + c.$$

與精確解相減，得

$$x - x_{k+1} = G^{k+1}(x - x_0).$$

對可逆 S 且 $Ax = b$ 有唯一解時，所有初始猜測都收斂，若且唯若

$$\rho(G) < 1.$$

定常迭代的分割 （續）

證明：若所有初始誤差皆衰減，取複特徵向量可知每個特徵值模必小於 1。反之，Jordan 分塊的 G^k 項是有限次多項式乘 λ^k，$|\lambda|<1$ 使其趨零。因此 $G^k\to 0$。這是 spectral-radius 條件，不是逐元素比較 S 與 T。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Jacobi、Gauss-Seidel 與 SOR

固定 $A=D+L+U$，其中 L,U 是原矩陣的嚴格下、上三角部分，且假設所有 $a_{ii}\neq 0$。Jacobi 方法取

$$S=D,\qquad T=-(L+U),$$

$$x_i^{(k+1)}=\frac{1}{a_{ii}}\left(b_i-\sum_{j\neq i}a_{ij}x_j^{(k)}\right).$$

所有更新使用舊值，容易平行化。

Gauss-Seidel 方法取

$$S=D+L,\qquad T=-U,$$

新算出的下三角數值立即使用：

$$x_i^{(k+1)}=\frac{1}{a_{ii}}\left(b_i-\sum_{j<i}a_{ij}x_j^{(k+1)}-\sum_{j>i}a_{ij}x_j^{(k)}\right).$$

嚴格列對角優勢使 Jacobi 的 $\|G_J\|_\infty<1$，亦可保證 Gauss-Seidel 收斂。SPD 保證 Gauss-Seidel 收斂，但不保證 Jacobi；例如對角為 1、其餘項為 0.9 的 3×3 SPD 矩陣，其 Jacobi 迭代矩陣有特徵值 -1.8，故發散。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Jacobi、Gauss-Seidel 與 SOR （續）

SOR 逐分量 relaxation，必須使用本輪已更新的 relaxed lower components：

$$x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \frac{\omega}{a_{ii}}\left(b_i - \sum_{j<i} a_{ij}x_j^{(k+1)} - \sum_{j>i} a_{ij}x_j^{(k)}\right).$$

對 SPD，$0 < \omega < 2$ 保證 SOR 收斂，$\omega = 1$ 即 Gauss-Seidel。不可先完成一整輪未鬆弛的 GS 再將整個向量平均，因為那是不同的迭代矩陣。收斂可由每次座標能量改變 $\phi(x_{\text{new}}) - \phi(x_{\text{old}}) = -\omega(2-\omega)r_i^2/(2a_{ii}) \le 0$ 證明；若一輪仍有非零殘差則嚴格下降，SPD 使能量有下界，故各座標的能量下降量趨零，進而每次更新量 $\omega r_i/a_{ii}$ 趨零。固定有限個座標下，同一輪各中間點的差也趨零，故各座標更新前的殘差趨零推出輪首整個殘差向量趨零。由 $x_* - x = A^{-1}r$，迭代收斂到唯一解。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

收斂與失敗例子

對

$$A = \begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix},$$

Jacobi 矩陣

$$G_J = -D^{-1}(L+U) = \begin{bmatrix} 0 & -1/4 \\ -1/3 & 0 \end{bmatrix}.$$

因

$$G_J^2 = \begin{bmatrix} 1/12 & 0 \\ 0 & 1/12 \end{bmatrix},$$

故

$$\rho(G_J) = 1/\sqrt{12} < 1,$$

Jacobi 收斂。

對角為零的矩陣

$$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

無法直接套 Jacobi，因為會除以零。置換變數有時可修正，但非零對角線本身不保證收斂。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

對稱正定系統的共軛梯度法

實對稱正定 A 的 A-內積為

$$\langle u, v \rangle_A = u^T A v.$$

二次能量為

$$\phi(x) = \frac{1}{2} x^T A x - b^T x.$$

其唯一最小值點就是 $Ax = b$ 的解。CG 在 Krylov 子空間中選擇 A-正交搜尋方向；精確算術下最多 n 步到達精確解。

共軛梯度法（CG）要求實對稱正定 A，並指定初值 x_0（未指定時取零向量）、非負容許值 $\mathrm{atol}, \mathrm{rtol}$ 與迭代上限。令 $\tau = \max(\mathrm{atol}, \mathrm{rtol}\|b\|_2)$，先算 $r_0 = b - Ax_0$。若 $\|r_0\|_2 \le \tau$，立即回傳 x_0，不計算任何步長；否則令 $p_0 = r_0$。

第 k 輪計算 $q_k = Ap_k$、$\alpha_k = (r_k^T r_k)/(p_k^T q_k)$，再更新 $x_{k+1} = x_k + \alpha_k p_k$、$r_{k+1} = r_k - \alpha_k q_k$。新殘差達門檻時，用原方程重算 $b - Ax_{k+1}$ 確認後回傳。否則算 $\beta_k = (r_{k+1}^T r_{k+1})/(r_k^T r_k)$，令 $p_{k+1} = r_{k+1} + \beta_k p_k$。精確算術的非零搜尋方向滿足 $p_k^T A p_k > 0$；浮點計算若分母非正或非有限數，應回報數值失敗，不能當成收斂。若遞迴殘差已過門檻、真實殘差卻未過，則以真實殘差取代遞迴殘差，重新令 $p = r$ 開始新一輪方向建構，不能沿用幾乎為零的舊殘差。達迭代上限但真實殘差仍超標，回報未收斂。

對稱正定系統的共軛梯度法 （續）

CG 初始化：先算 r₀，再決定是否進入迭代



若未達門檻，才建立 $p_0 = r_0$ 並進入迭代。

CG 迭代：分母檢查、更新與真實殘差



真實殘差達標：收斂；未達且已到上限：iteration_limit

遞迴殘差達標、真實未達：r ← b−Ax，p ← r（重啟）

其餘未達標情形：計算 β、更新 p，再回到 q=Ap

對稱正定系統的共軛梯度法 （續）

基例 $A=[1], b=[0], x_0=[0]$ 的初始殘差為零，零輪返回；直接算步長會得到 $0/0$。非零例取 $A=\begin{bmatrix}4 & 1\\ 1 & 3\end{bmatrix}, b=(1,2)^T, x_0=0$。第零輪 $r_0=p_0=(1,2)^T$、$Ap_0=(6,7)^T$，故 $\alpha_0=5/20=1/4$，$x_1=(1/4,1/2)^T$、$r_1=(-1/2,1/4)^T$。再得 $\beta_0=1/16$、$p_1=(-7/16,3/8)^T$、$\alpha_1=4/11$，所以 $x_2=(1/11,7/11)^T$，直接代回得 $Ax_2=b$。

精確線搜尋與上述 β_k 使殘差兩兩正交、搜尋方向兩兩 A-共軛。非零共軛方向線性獨立，至多 n 個，故精確算術在至多 n 個非平凡步驟終止。浮點算術可能失去正交性，因此有限終止定理不能取代殘差準則。每輪一次矩陣向量乘法與常數次向量內積，時間為 $O(\mathrm{nnz}(A)+n)$，記憶體只保留固定數量的長度 n 向量，不形成逆矩陣。

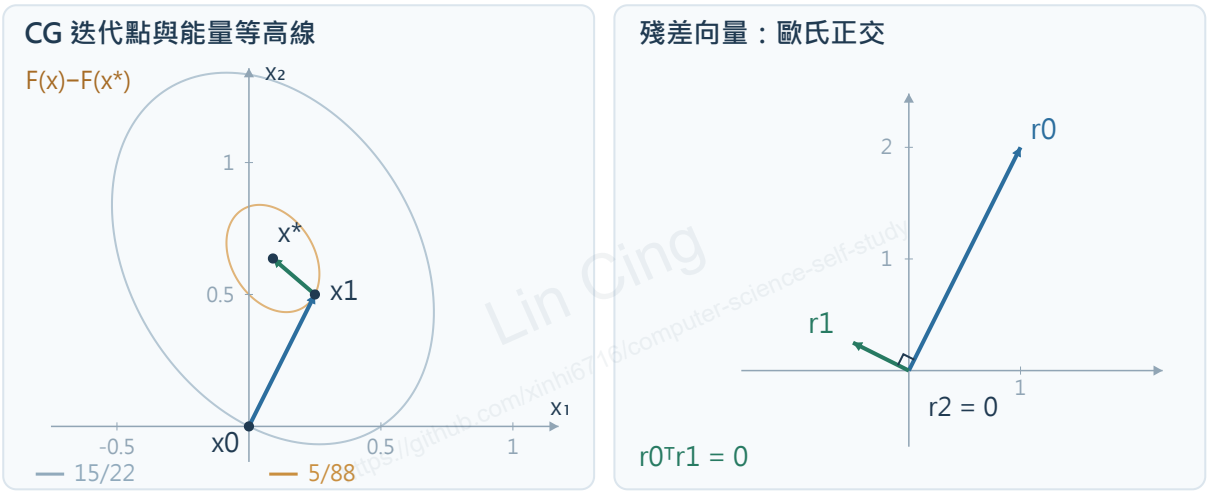
在標準誤差能量範數下，有

$$\|x-x_k\|_A \le 2\left(\frac{\sqrt{\kappa_2(A)}-1}{\sqrt{\kappa_2(A)}+1}\right)^k \|x-x_0\|_A.$$

這個界顯示 ill-conditioned 系統可能很慢，但 eigenvalue 聚集成少數群時，通常比只依 κ_2 的估計更快。CG 的標準形式要求 A 和 preconditioner 都維持 SPD。

同一個 CG 數例的兩種幾何

沿用 $A=\begin{bmatrix}4 & 1\\ 1 & 3\end{bmatrix}$、$b=(1,2)^T$、$x_0=0$。左圖在參數空間畫搜尋路徑；右圖在殘差空間畫 $r_k=b-Ax_k$。



每個面板內，水平與垂直方向使用相同尺度。

A-共軛不等於歐氏正交

令 $F(x)=\frac{1}{2}x^TAx-b^Tx$，$x_*=(1/11,7/11)^T$。本例的實際狀態是

k	x_k	r_k	$F(x_k)-F(x^*)$
0	(0,0)	(1,2)	15/22
1	(1/4,1/2)	(−1/2,1/4)	5/88
2	(1/11,7/11)	(0,0)	0

$p_0=(1,2)^T$、$p_1=(-7/16,3/8)^T$，所以

$$p_0^TAp_1=0,\qquad p_0^Tp_1=5/16\neq 0.$$

右圖卻有 $r_0^Tr_1=0$。殘差的直角不能移到左圖兩段搜尋路徑上。CG 極小化能量誤差 $F(x_k)-F(x_*)=\frac{1}{2}\|x_k-x_*\|_A^2$。

殘差二範數不一定每步下降

另取 $A=\mathrm{diag}(1,100)$、$b=(1,1/10)^T$、$x_0=0$。第一步

$$\alpha_0=\frac{101/100}{2}=\frac{101}{200},\quad x_1=(101/200,101/2000)^T,\quad r_1=(99/200,-99/20)^T.$$

真解為 $x_*=(1,1/1000)^T$。

k	$\|r_k\|_2^2$	$F(x_k)-F(x^*)$
0	101/100 = 1.01	10001/20000 = 0.50005
1	989901/40000 = 24.747525	9801/40000 = 0.245025

能量誤差下降，殘差二範數卻上升。這不違反精確算術的 CG 定理；殘差停止準則仍有用，但不能假設它逐步單調。

CG 的正確性：Krylov 空間與能量極小性

以下完全使用精確算術。令真解為 x_*，定義 $\mathcal{K}_0 = \{0\}$ 與

$$\mathcal{K}_k = \operatorname{span}\{r_0, Ar_0, \dots, A^{k-1}r_0\}.$$

第 k 輪開始時，歸納維持：舊方向 $p_0, \dots, p_{k-1}$ 張成 $\mathcal{K}_k$ 且兩兩 A-共軛；$x_k \in x_0 + \mathcal{K}_k$；$r_k = b - Ax_k \perp \mathcal{K}_k$。這也證明 x_k 是該仿射空間的唯一能量極小點，因為對 $z \in \mathcal{K}_k$，

$$\phi(x_k + z) - \phi(x_k) = -z^T r_k + \tfrac{1}{2} z^T A z = \tfrac{1}{2} z^T A z,$$

非零 z 時嚴格為正。$k = 0$ 時不變量直接成立。又 $r_k = r_0 - A(x_k - x_0) \in \mathcal{K}_{k+1}$；若 $r_k \neq 0$，它與 $\mathcal{K}_k$ 正交，必增加一個獨立方向。

$k = 0$ 取 $p_0 = r_0$；$k \geq 1$ 時令 $p_k = r_k + \beta_{k-1} p_{k-1}$。對 $i \leq k-2$，$Ap_i \in \mathcal{K}_{i+2} \subseteq \mathcal{K}_k$，故 $p_i^T A r_k = (Ap_i)^T r_k = 0$；配合舊方向的共軛性，只需消去與上一個方向的 A-內積：

$$\beta_{k-1} = -\frac{p_{k-1}^T A r_k}{p_{k-1}^T A p_{k-1}}.$$

因 $r_k = r_{k-1} - \alpha_{k-1} A p_{k-1}$，而 $r_{k-1} \in \mathcal{K}_k$，得

$$\|r_k\|^2 = -\alpha_{k-1} r_k^T A p_{k-1}.$$

代入 $\alpha_{k-1} = \|r_{k-1}\|^2 / (p_{k-1}^T A p_{k-1})$，正好得到 $\beta_{k-1} = \|r_k\|^2 / \|r_{k-1}\|^2$。因此這個短遞推確實使新方向與所有舊方向共軛。新方向與非零殘差只差舊方向的倍數，故加入它後恰張成 $\mathcal{K}_{k+1}$。

CG 的正確性：Krylov 空間與能量極小性 （續）

沿新方向最小化能量，導數為 $-p_k^T r_k + \alpha p_k^T A p_k$。由 $p_k^T r_k = \|r_k\|^2$ 得到演算法的 α_k。更新後 $p_k^T r_{k+1} = 0$；對 $i < k$，

$$p_i^T r_{k+1} = p_i^T r_k - \alpha_k p_i^T A p_k = 0.$$

故 $r_{k+1} \perp \mathcal{K}_{k+1}$，不變量延續。每個舊殘差 $r_i \in \mathcal{K}_{i+1}$，所以殘差兩兩正交。若 $\sum c_i p_i = 0$，左乘 $p_j^T A$ 得 $c_j p_j^T A p_j = 0$，故非零共軛方向必獨立，至多 n 個。若未提早終止，第 n 步殘差與整個 $\mathbb{R}^n$ 正交，只能為零。這完成有限終止的證明。

CG 的條件數誤差界從哪裡來

令 $e_k = x_* - x_k$。由能量極小性，CG 在 $x_0 + \mathcal{K}_k$ 中使 $\|e_k\|_A$ 最小。因 $r_0 = Ae_0$，這裡的每個誤差可寫為 $p(A)e_0$，其中 $\deg p \le k, p(0) = 1$。在 $A = Q\Lambda Q^T$ 的特徵座標展開，得到

$$\|e_k\|_A \le \min_{\deg p \le k,\, p(0)=1} \max_i |p(\lambda_i)| \, \|e_0\|_A.$$

設 $a = \lambda_{\min} > 0$、$b = \lambda_{\max} > a$。Chebyshev 多項式滿足 $T_k(\cos\theta) = \cos(k\theta)$，故在 $[-1, 1]$ 上絕對值至多 1。選

$$p(t) = \frac{T_k((b + a - 2t)/(b - a))}{T_k((b + a)/(b - a))}.$$

它有 $p(0) = 1$，且把 $[a, b]$ 送入分子的 $[-1, 1]$。由餘弦加法公式得到遞推 $T_{k+1}(z) = 2zT_k(z) - T_{k-1}(z)$，配合 $T_0 = 1, T_1 = z$，可驗證下式。對 $z > 1$，$T_k(z) = (\rho^k + \rho^{-k})/2$，其中 $\rho = z + \sqrt{z^2 - 1}$。令 $\kappa = b/a$，代入 $z = (b + a)/(b - a)$ 得 $\rho = (\sqrt{\kappa} + 1)/(\sqrt{\kappa} - 1)$，所以

$$\|e_k\|_A \le 2 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|e_0\|_A.$$

$a = b$ 時 $A = aI$，非零殘差一次步長 $1/a$ 即解出，需另外處理而非除以 $b - a = 0$。利用特徵值群集可選更好的多項式；此區間界不一定緊。證明依賴精確正交性，浮點實作仍以真實殘差驗收。

延伸補充：複 Hermitian 正定系統的 CG

本頁是原書 11.3 節之外的嚴謹延伸；原書 CG 段落要求實對稱正定矩陣，不能把同一套 $r^T r$ 公式直接套到複矩陣。若

$$A^H = A, \qquad z^H A z > 0 \quad (z \neq 0),$$

則 A 是 Hermitian 正定矩陣。複內積固定為 $u^H v$，所以例行的實數公式改成

$$r_k = b - Ax_k, \qquad \alpha_k = \frac{r_k^H r_k}{p_k^H A p_k},$$

$$x_{k+1} = x_k + \alpha_k p_k, \qquad r_{k+1} = r_k - \alpha_k A p_k,$$

$$\beta_k = \frac{r_{k+1}^H r_{k+1}}{r_k^H r_k}, \qquad p_{k+1} = r_{k+1} + \beta_k p_k.$$

因為 A 是 Hermitian，$p_k^H A p_k$ 是實數；正定性使非零方向的分子、分母都為正。容差仍使用 $\|r_k\|_2 = \sqrt{r_k^H r_k}$，而且必須先計算 r_0。若 $r_0 = 0$，立即回傳 x_0，不得計算 $0/0$。若使用預條件子，M 也必須是 Hermitian 正定，並採保持對稱性的等價變數變換。實數證明改以共軛內積後仍成立，所有能量與步長為實正數。檢查 $A^T = A$ 不能代替 $A^H = A$；複對稱的 $[i]$ 就沒有實正能量。

實對稱正定矩陣是上述公式的特例，此時 conjugate 不改變實數。這一區分正是避免把實 SPD 與複 Hermitian PD 混用的必要條件。

非對稱系統的 GMRES

本節先令 $A \in \mathbb{R}^{n\times n}$。複數版本的 Arnoldi 內積須改用共軛轉置。GMRES 在 Krylov 子空間

$$\mathcal{K}_k(A, r_0) = \operatorname{span}\{r_0, Ar_0, \dots, A^{k-1}r_0\}$$

上最小化 residual：

$$\min_{x \in x_0 + \mathcal{K}_k} \|b - Ax\|_2.$$

Arnoldi 從 $v_1 = r_0/\|r_0\|$ 開始，對 $w = Av_j$ 逐一減去 $h_{ij}v_i$，其中 $h_{ij} = v_i^T w$，最後以 $h_{j+1,j} = \|w\|$ 正規化，得到 $AV_k = V_{k+1}\overline{H}_k$。寫 $x = x_0 + V_k y$，則 residual norm 等於 $\|\|r_0\|e_1 - \overline{H}_k y\|_2$，解此小型 least-squares 即得到 GMRES iterate。若 $r_0 = 0$ 直接完成；Arnoldi 零剩餘方向需判斷收斂或 breakdown。Restart 限制 storage，但丟棄舊方向而可能停滯。

非正規矩陣的特徵值大小不足以單獨預測 GMRES 暫態；field of values、pseudospectra 與實際殘差歷程更有資訊。應監控真實殘差，不只遞迴殘差。未重啟的 GMRES 每個 Arnoldi 步驟多做一次矩陣向量乘法與對所有既有方向的正交化工作。$k \le n$ 步後，不含儲存原矩陣的額外空間為 $O(kn)$，時間為 $O(k\,\mathrm{nnz}(A) + k^2 n)$；稠密矩陣的矩陣向量乘法部分是 $O(kn^2)$，不能省略；以 GMRES(m) 重啟會把空間固定在 $O(mn)$，但可能失去收斂性而停滯。

GMRES 第一輪：Arnoldi 與殘差最小化

取非對稱可逆矩陣與初值

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad x_0 = 0.$$

初始殘差為 $r_0 = b$，$\beta = \|r_0\|_2 = 1$，故 $v_1 = e_2 = (0,1)^T$。第一輪 Arnoldi 逐步得到

$$w = Av_1 = (1,1)^T, \quad h_{11} = v_1^T w = 1,$$
$$w \leftarrow w - h_{11}v_1 = (1,0)^T, \quad h_{21} = 1, \quad v_2 = e_1.$$

因此 $\overline{H}_1 = (1,1)^T$。小型最小平方只有一個未知數：

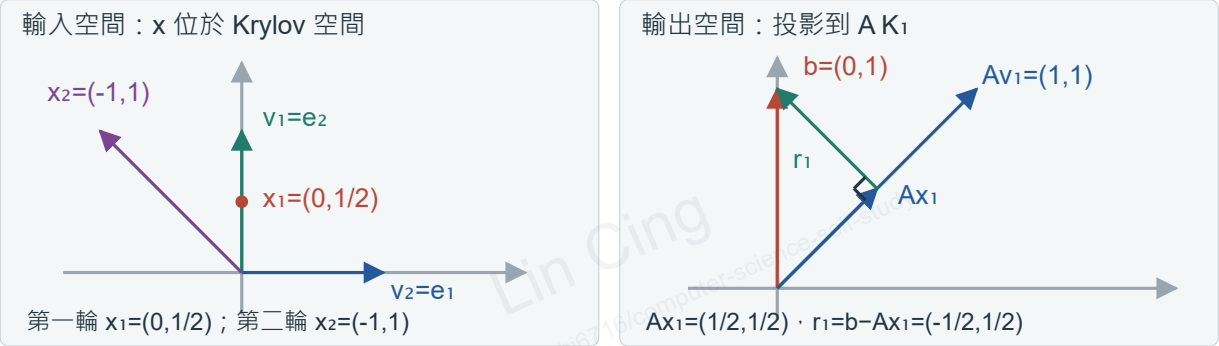
$$\min_{y} \left\| \begin{bmatrix} 1 \\ 0 \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \end{bmatrix} y \right\|_2^2 = \min_y \big((1-y)^2 + y^2\big).$$

由 $4y - 2 = 0$ 得 $y = 1/2$。重建 $x_1 = V_1 y = (0, 1/2)^T$，真實殘差為 $r_1 = b - Ax_1 = (-1/2, 1/2)^T$，所以 $\|r_1\|_2 = 1/\sqrt{2}$。實際檢查 $(Av_1)^T r_1 = 0$；殘差垂直於 **輸出方向** $A\mathcal{K}_1$，不是要求垂直於輸入方向 $\mathcal{K}_1$。

GMRES 的輸入搜尋與輸出投影

本例輸入空間與輸出空間雖都為 $\mathbb{R}^2$，角色不同。左圖追蹤未知數 x；右圖把 b 投影到 $A\mathcal{K}_1 = \text{span}\{(1,1)^T\}$。兩圖座標各自同尺度，右圖的直角對應 $(Av_1)^T r_1 = 0$。

GMRES：輸入中的搜尋向量，輸出中的殘差投影



$r_1 \perp A\mathcal{K}_1$；不必垂直於輸入空間 $\mathcal{K}_1$

GMRES 第二輪：零 Arnoldi 餘項與精確終止

已有 $V_2 = [v_1, v_2] = [e_2, e_1]$。第二輪從 $w = Av_2 = e_1$ 開始：

運算	數值結果
$h_{12} = v_1^T w$	0；w 不變
$h_{22} = v_2^T w = 1$	減去 $h_{22}v_2$ 後，$w = (0,0)^T$
$h_{32} = \|w\|_2$	0；不可再除以此值建立 v_3

此時 Krylov 空間已是整個 $\mathbb{R}^2$，且 $AV_2 = V_2 H_2$，其中

$$H_2 = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}, \qquad H_2 y = \beta e_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

第一列得 $y_1 = 1$，第二列得 $y_1 + y_2 = 0$，故 $y = (1,-1)^T$，重建

$$x_2 = V_2 y = e_2 - e_1 = (-1,1)^T, \qquad Ax_2 = (0,1)^T = b.$$

真實殘差為零，故為 happy breakdown（找到精確解的正常終止）。一般零餘項只表示搜尋空間不再擴張，仍須以原方程的殘差判定收斂。

預條件子

預條件子 $M \approx A$ 要便宜、可平行，而且讓 $M^{-1}A$ 較容易迭代。左預條件為

$$M^{-1}Ax = M^{-1}b.$$

右預條件先令

$$AM^{-1}y = b, \qquad x = M^{-1}y$$

它改變變數，但保留原殘差的解釋。

常見選擇：

- diagonal/Jacobi；
- block Jacobi；
- incomplete LU 或 incomplete Cholesky；
- algebraic multigrid；
- domain decomposition；
- physics-informed approximation。

預條件子的價值需比較設定、每輪與通訊總成本，不能只看迭代數。左預處理殘差是 $M^{-1}(b - Ax)$，應另算原問題的真實殘差；用 CG 時應採保持 SPD 的等價對稱變數變換，而非把任意非對稱 $M^{-1}A$ 當成 SPD 矩陣。

停止準則與重現性

每次求解至少記錄：

1. 初始殘差；
2. 相對殘差下降量；
3. 所用的範數與尺度；
4. 最大迭代次數與 timeout；
5. 函式庫回報的收斂／breakdown 狀態；
6. 最終真實殘差；
7. 條件數或誤差估計；
8. 可重現的 seed 與第二次執行核對。

後向誤差應相對 $\|A\|\|x\| + \|b\|$ 評估。迭代遞迴殘差可能因捨入變得很小，真實殘差卻沒有同步變小。

本章重點

- 選主元影響演算法穩定性；條件數衡量問題本身對擾動的敏感度。
- 小絕對殘差須考慮尺度；後向誤差與前向誤差各回答不同問題。
- 截斷偽逆通常求最小平方解；CG 在求步長前先檢查初始殘差。
- 迭代方法需檢查適用條件、真實殘差與停止狀態。

參考資料與署名

Lin Cing，《線性代數》手寫筆記。 Gilbert Strang, Introduction to Linear Algebra, 5th ed., Chapter 11.

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study