## 樣本與期望值

在離散或具有密度的情形，令樣本空間為 $\Omega$，可測事件 $E \subseteq \Omega$ 的機率 $P(E)$ 滿足 $P(E) \geq 0$、$P(\Omega) = 1$，且對可數個互斥事件滿足機率可數可加性。隨機變數 $X \colon \Omega \to \mathbb{R}$ 把樣本結果映成數字；$P(X \leq x)$ 就是事件 $\{\omega : X(\omega) \leq x\}$ 的機率。本章只使用離散機率質量函數與一般機率密度函數兩種表示，不引入進階測度理論。期望值是依分布加權的平均；若一階絕對矩不有限，這個期望可能不存在。

樣本觀測值 $x_1, \ldots, x_N$ 是已觀察到的數值，$N \geq 1$。涉及期望值時假設一階絕對矩有限；變異數、共變異數與本章的線性變換公式假設所有分量二階矩有限。樣本平均數：

$$\overline{x} = \frac{1}{N} \sum_{i=1}^{N} x_i.$$

隨機變數 $X$ 的理論平均數：

$$\mu = \mathbb{E}[X].$$

離散結果 $a_i$ 與機率 $p_i$：

$$\mathbb{E}[X] = \sum_{i=1}^{k} p_i a_i.$$

連續型密度 $f_X$：

$$\mathbb{E}[X] = \int x f_X(x)\, dx.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study



## 樣本與期望值 （續）

蒐集後的樣本平均數是數值摘要，蒐集前則是隨機統計量；期望值是機率模型的性質。兩者公式相似，解釋不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

## 變異數與 $N-1$

固定的樣本觀測值：

$$\overline{x} = \frac{1}{N}\sum_{i=1}^{N} x_i.$$

常用的不偏樣本變異數：

$$s^2 = \frac{1}{N-1}\sum_{i=1}^{N}(x_i - \overline{x})^2.$$

母體變異數：

$$\operatorname{Var}(X) = \mathbb{E}[(X-\mu)^2] = \mathbb{E}[X^2] - \mu^2.$$

$N \geq 2$ 才能使用 $N-1$ 分母。對 i.i.d. 有限變異數樣本，用恆等式 $\sum_i (X_i - \overline{X})^2 = \sum_i (X_i - \mu)^2 - N(\overline{X}-\mu)^2$，兩邊取期望得到 $N\sigma^2 - N(\sigma^2/N) = (N-1)\sigma^2$。因此

$$\mathbb{E}[s^2] = \sigma^2.$$

若只想描述完整有限母體的平均離差平方，除以 $N$ 可能才符合目的。報告時要標明是描述統計量或估計量。



## 線性轉換後的平均與變異數

對常數 $a, b$：

$$\mathbb{E}[aX + b] = a\mathbb{E}[X] + b,$$
$$\operatorname{Var}(aX + b) = a^2 \operatorname{Var}(X).$$

平移改變中心，不改變分散程度；負的 $a$ 仍使變異數乘上 $a^2$，但反轉方向。

獨立 $X, Y$：

$$\operatorname{Var}(X + Y) = \operatorname{Var} X + \operatorname{Var} Y.$$

不獨立時：

$$\operatorname{Var}(X + Y) = \operatorname{Var} X + \operatorname{Var} Y + 2\operatorname{Cov}(X, Y).$$

這是共變異矩陣的純量形式。獨立性在有限變異數下推出零共變異數；零共變異數一般不推出獨立性。

## 機率密度、累積分布與均勻分布例子

累積分布函數（cumulative distribution function, CDF）定義為 $F_X(x) = P(X \le x)$。對具有密度的絕對連續隨機變數，CDF 的導數幾乎處處存在且為密度；僅 CDF 連續不充分。此時

$$F_X(x) = \mathbb{P}(X \le x), \qquad f_X(x) = F_X'(x).$$

區間機率：

$$\mathbb{P}(a \le X \le b) = F_X(b) - F_X(a) = \int_a^b f_X(x)\,dx.$$

對 $X \sim U(0, L)$ 且 $L > 0$，密度在 $[0, L]$ 是 $1/L$，平均數

$$\mathbb{E}[X] = \frac{L}{2}.$$

變異數：

$$\operatorname{Var}(X) = \int_0^L \left(x - \frac{L}{2}\right)^2 \frac{1}{L}\,dx = \frac{L^2}{12}.$$

$L = 3$ 時平均數是 $1.5$，變異數是 $9/12 = 3/4$。均勻分布平移 $a$ 後平均數加 $a$，變異數不變。



## 常態分布、標準化與中央極限定理

標準常態：

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}.$$

常態分布（Gaussian distribution）$X \sim N(\mu, \sigma^2)$，其中 $\sigma > 0$：

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

標準化：

$$Z = \frac{X - \mu}{\sigma}$$

使平均數變 0、變異數變 1。

獨立同分布（IID）且 $0 < \sigma^2 < \infty$ 時，中央極限定理（CLT）給出

$$\frac{\sqrt{N}(\overline{X} - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

它描述標準化樣本平均的分布近似，不代表原始資料會變成 Gaussian。時間序列相依、異分布或重尾都可能違反顯示的前提。

## CLT 的證明：獨立乘積與二階展開

以下援引 Lévy 連續性定理完成分布收斂步驟；其一般機率論證明超出本章範圍。先中心化並除以標準差，令 $U_i = (X_i - \mu)/\sigma$，則 $\mathbb{E}[U_i] = 0$、$\mathrm{Var}(U_i) = 1$，且

$$Z_N = \frac{\sqrt{N}(\overline{X} - \mu)}{\sigma} = \frac{1}{\sqrt{N}} \sum_{i=1}^{N} U_i .$$

令 $\varphi_N(t) = \mathbb{E}[e^{itZ_N}]$。獨立性使特徵函數相乘；同分布使每個因子的函數相同：

$$\varphi_N(t) = \left[ \varphi_U\left( \frac{t}{\sqrt{N}} \right) \right]^N .$$

有限二階矩保證 $\varphi_U$ 在 $0$ 附近可微兩次，且

$$\varphi_U(s) = 1 - \frac{1}{2}s^2 + o(s^2).$$

這裡不需要第三階矩。理由是 $e^{iy} = 1 + iy - y^2/2 + R(y)$，其中 $R(y)/y^2 \to 0$，且可取固定常數 $C$ 使 $|R(y)| \le Cy^2$。所以 $R(sU)/s^2 \to 0$ 幾乎必然，並由可積的 $CU^2$ 控制；支配收斂定理給 $\mathbb{E}[R(sU)] = o(s^2)$。期望值的線性性再用 $\mathbb{E}[U] = 0, \mathbb{E}[U^2] = 1$ 得到展開。

因此

$$N \log \varphi_U(t/\sqrt{N}) = N \log\left( 1 - \frac{t^2}{2N} + o(1/N) \right) \longrightarrow -\frac{t^2}{2}.$$



## CLT 的證明：獨立乘積與二階展開 （續）

所以 $\varphi_N(t) \to e^{-t^2/2}$，也就是 $N(0,1)$ 的特徵函數。由 Lévy 連續性定理：特徵函數逐點收斂到一個在零點連續的特徵函數時，對應分布依分布收斂；因此 $Z_N$ 收斂到標準常態。僅有特徵函數的唯一性，不能單獨推出這個收斂結論。這不是「大樣本一定是常態」；它只說明平均量的極限。

上式對固定 $t$ 且充分大的 $N$，在 $1$ 附近取同一個複數對數分支，再將極限取指數；不能對一般複數乘積任意套用主值對數加法律。有限變異數 CLT 沒有提供對所有分布一致的有限樣本誤差界。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

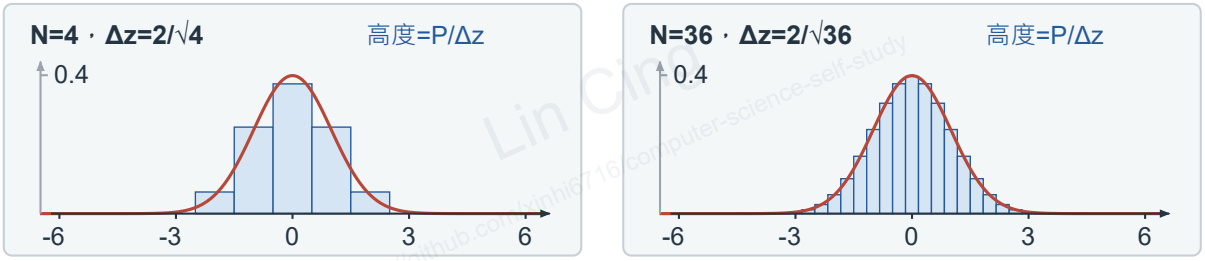
## 二項分布的標準化與圖形比較

令 $B_i$ 為獨立公平的 0/1 觀測值，$S_N = \sum_i B_i$。則

$$P(S_N = k) = \binom{N}{k} 2^{-N}, \quad \mathbb{E}[S_N] = N/2, \quad \mathrm{Var}(S_N) = N/4.$$

標準化變數 $Z_N = (S_N - N/2)/(\sqrt{N}/2)$ 的相鄰取值距離是 $\Delta z = 2/\sqrt{N}$。$N = 4$ 時，取值為 $-2, -1, 0, 1, 2$，機率依序是 $(1, 4, 6, 4, 1)/16$；$\mathbb{E}[Z_4] = 0$、$\mathrm{Var}(Z_4) = 1$，但它仍是離散分布。

標準化二項分布：長條面積是機率，紅線為 N(0,1) 密度




每根長條的寬為 $\Delta z$、高度為 $P(S_N = k)/\Delta z$，所以面積才是機率，所有長條總面積為 1；紅線是標準常態密度。不能把點機率直接當成密度與紅線比高度。這個圖只比較有限的兩個例子，一般收斂由前面的定理保證。



## Monte Carlo 平均的誤差從哪裡來

若獨立同分布的模擬輸出 $Y_1, \ldots, Y_N$ 有均值 $\mu$ 與有限變異數 $\tau^2$，則估計量 $\widehat{\mu} = N^{-1} \sum_i Y_i$ 滿足

$$\mathbb{E}[\widehat{\mu}] = \mu, \qquad \mathrm{Var}(\widehat{\mu}) = \frac{\tau^2}{N}, \qquad P(|\widehat{\mu} - \mu| \geq \varepsilon) \leq \frac{\tau^2}{N\varepsilon^2}.$$

最後一步是 Chebyshev 不等式，因此標準誤按 $N^{-1/2}$ 縮小。它是抽樣誤差的機率敘述，不是每次模擬都遵守的決定性誤差。

例如 $X \sim U(-1, 1)$、$Y = X^2$，積分給 $\mathbb{E}[Y] = 1/3$、$\mathbb{E}[Y^2] = 1/5$，所以 $\tau^2 = 4/45$。$N = 1000$ 時，標準誤為 $\sqrt{4/45000} \approx 0.00943$，且 $P(|\widehat{\mu} - 1/3| \geq 0.1) \leq 4/450 \approx 0.00889$。模擬若有相關性，變異數還要加上所有交叉共變異數；不能繼續套用 $\tau^2/N$。

## 聯合機率表

離散變數的聯合機率質量函數：

$$P_{ij} = \mathbb{P}(X = x_i, Y = y_j),$$
$$P_{ij} \geq 0, \qquad \sum_{i,j} P_{ij} = 1.$$

邊際機率：

$$\mathbb{P}(X = x_i) = \sum_j P_{ij}, \qquad \mathbb{P}(Y = y_j) = \sum_i P_{ij}.$$

獨立性要求每一對都滿足

$$P_{ij} = \mathbb{P}(X = x_i)\mathbb{P}(Y = y_j).$$

只知道兩組邊際機率，通常不足以重建聯合分布。只比較平均數或單一共變異數也不能判定獨立性。



## 聯合機率表 （續）

Joint table：marginals 與 covariance

| X \ Y | Y=0 | Y=1 |
|---|---|---|
| X=0 | 0.2 | 0.1 |
| X=1 | 0.3 | 0.4 |
| PX=(0.3,0.7) | PY=(0.5,0.5) | |

總機率=0.2+0.1+0.3+0.4=1

E(X)=0.7 · E(Y)=0.5

E(XY)=0.4

**Cov=0.4-0.7×0.5=0.05**

VarX=0.21 · VarY=0.25

**ρ=0.05/√0.0525=1/√21**

圖下核對：$P_X = (0.3, 0.7)$、$P_Y = (0.5, 0.5)$、$\mathbb{E}(XY) = 0.4$，因此 $\mathrm{Cov}(X, Y) = 0.05$、$\rho_{XY} = 1/\sqrt{21}$。表格四格總和為 1。

## 條件機率、Bayes 與零相關的界線

若 $P(X=x_i)=p_i>0$，條件機率是

$$P(Y=y_j\mid X=x_i)=\frac{P_{ij}}{p_i}.$$

以同一張表 $P=\begin{bmatrix}0.2 & 0.1\\ 0.3 & 0.4\end{bmatrix}$，rows 為 $X=0,1$，columns 為 $Y=0,1$，則

$$P(Y=1\mid X=0)=\frac{1}{3},\quad P(Y=1\mid X=1)=\frac{4}{7}.$$

全機率公式 $P(Y=1)=\sum_i P(Y=1\mid X=i)P(X=i)$ 給 $(1/3)(0.3)+(4/7)(0.7)=0.5$。Bayes 公式交換已知與未知的角色：

$$P(X=1\mid Y=1)=\frac{P(Y=1\mid X=1)P(X=1)}{P(Y=1)}=\frac{(4/7)(0.7)}{0.5}=0.8.$$

零共變異數仍可能依賴。取 $X$ 在 $-1,0,1$ 等機率、$Y=X^2$。則 $\mathbb{E}[X]=\mathbb{E}[XY]=0$，故 $\operatorname{Cov}(X,Y)=0$；但 $P(Y=0\mid X=0)=1\neq P(Y=0)=1/3$。若兩變數聯合常態，零共變異數足以推出獨立；一般分布不能僅由零共變異數判定獨立。



## 共變異數與相關係數

相關係數只摘要線性共同變動。先從完整聯合分布定義條件機率，才能分辨「相關」與「獨立」。

$$\operatorname{Cov}(X,Y)=\mathbb{E}[(X-\mu_X)(Y-\mu_Y)].$$

離散聯合分布的寫法：

$$\operatorname{Cov}(X,Y)=\sum_{i,j}P_{ij}(x_i-\mu_X)(y_j-\mu_Y).$$

共變異數的大小依單位，相關係數去除尺度：

$$\rho_{XY}=\frac{\sigma_{XY}}{\sigma_X\sigma_Y}.$$

兩變異數為正時，

$$-1\le\rho_{XY}\le 1.$$

證明：

$$\operatorname{Var}\left(\frac{X}{\sigma_X}-\frac{Y}{\sigma_Y}\right)=2(1-\rho_{XY})\ge 0,$$

改用加號則得 $1+\rho_{XY}\ge 0$。零相關只表示線性共變異為零，不一般等於獨立性。

## 共變異矩陣與半正定性

隨機欄向量：

$$\mu = \mathbb{E}[X], \qquad V = \mathbb{E}[(X-\mu)(X-\mu)^T].$$

$V_{ij} = \sigma_{ij}$，對角線是變異數，且 $V = V^T$。

任一係數向量 $c$：

$$c^T V c = \mathrm{Var}(c^T X) = \mathbb{E}[(c^T(X-\mu))^2] \geq 0.$$

所以 $V$ 半正定。離散聯合分布也有構造性證明：

$$V = \sum_{i,j} P_{ij} u_{ij} u_{ij}^T, \qquad u_{ij} = \begin{bmatrix} x_i \\ y_j \end{bmatrix} - \mu.$$

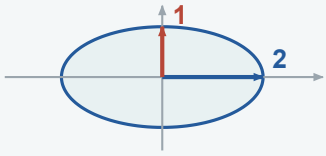
正定表示沒有任何非零線性組合 $c^T X$ 是幾乎必然為常數。秩不足表示某些變數的線性方向完全決定其他方向。



## 共變異矩陣與半正定性 （續）

共變異幾何：V=diag(4,1)，等密度線 xᵀV⁻¹x=1

**λ₁=4，λ₂=1；半軸 2、1**

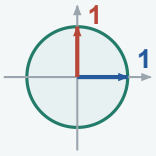



(2,0) 與 (0,1) 的加權平方長均為 1

**J=eᵀV⁻¹e**

白化 z=(x₁/2,x₂)

**J=‖z‖²**




同尺度：半軸 (2,1) → 半徑 (1,1)

圖中考慮聯合常態，採 $V = \mathrm{diag}(4,1)$、$\mu = 0$，所以等密度線 $x^T V^{-1} x = 1$ 為 $x_1^2/4 + x_2^2 = 1$，半軸恰為 2 與 1。它描述共變異尺度；一般分布的等密度線不必是橢圓。聯合常態的情形才由此二次型完整決定密度。

## 隨機向量的線性轉換

令

$$Y = AX + b.$$

平均數：

$$\mu_Y = A\mu_X + b.$$

共變異數：

$$V_Y = \mathbb{E}[(AX + b - \mu_Y)(\cdots)^T] = AV_XA^T.$$

平移 $b$ 在中心化時消去。$V_Y$ 是否奇異取決於 $\operatorname{rank}(AV_X^{1/2})$。若 $V_X \succ 0$ 且 $A$ 滿 row rank，即使輸出維度降低，$AV_XA^T$ 仍正定；重複的 rows 則造成秩不足。

純量線性組合 $a^TX$ 的變異數是 $a^TVa$；兩個線性組合的共變異數是 $a^TVb$。共變異矩陣因此表示一個對稱雙線性形式。



## 樣本共變異矩陣

假設樣本數 $n \geq 2$，把樣本放在 columns：

$$X_{\text{data}} \in \mathbb{R}^{M \times n}.$$

各 row 的平均數：

$$\widehat{\mu}_j = \frac{1}{n}\sum_{k=1}^{n}(X_{\text{data}})_{jk}.$$

逐 row 中心化得 $X_c$。不偏樣本共變異矩陣：

$$\widehat{V}_{n-1} = \frac{1}{n-1}X_cX_c^T.$$

母體／描述統計版本：

$$\widehat{V}_n = \frac{1}{n}X_cX_c^T.$$

兩者特徵向量相同，特徵值只差 $n/(n-1)$。PCA 的文獻可能用其中任一分母，必須說明。

$n \geq 2$、樣本 i.i.d. 且二階矩有限時，上式才具有不偏意義。中心化使 $X_c\mathbf{1} = 0$，故 rank 至多 $\min(M, n-1)$。非零奇異值平方成共變異數的非零特徵值，非零譜的條件數平方；秩不足時一般反問題的條件數已無限。大型資料通常直接用 SVD。

## 噪聲白化

若誤差 $E$ 的共變異矩陣 $V$ 對稱正定（SPD），$V^{-1}$ 會依變異數反向加權。白化：

$$W = V^{-1/2}E.$$

則

$$\mathrm{Cov}(W) = V^{-1/2}VV^{-1/2} = I.$$

Mahalanobis 長度：

$$\|e\|_{V^{-1}}^2 = e^T V^{-1} e.$$

$V$ 是對角矩陣時，就是每個殘差除以對應的標準差。$V$ 由樣本估計且維度高於樣本數時，估計共變異數可能奇異，必須收縮估計、降維或結構模型。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study



## 多變量 Gaussian 分布

SPD $V$ 的多變量常態密度：

$$p(x) = \frac{1}{(2\pi)^{M/2}\det(V)^{1/2}} \exp\left[-\frac{1}{2}(x-\mu)^T V^{-1}(x-\mu)\right].$$

指數的等位集合：

$$(x-\mu)^T V^{-1}(x-\mu) = r^2$$

在 $r > 0$ 時是橢球面；$r = 0$ 時退化為中心點 $\mu$。譜分解：

$$V = Q\Lambda Q^T, \qquad \Lambda = \mathrm{diag}(\lambda_i).$$

令

$$Y = Q^T(X-\mu).$$

則 $Y$ 的共變異矩陣是對角矩陣 $\Lambda$。聯合常態下互不相關的分量也獨立，這是譜定理的統計解釋。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

## 多變量 Gaussian 正規化

由

$$V = Q\Lambda Q^T$$

與 $Q^TQ = I$：

$$(x-\mu)^T V^{-1}(x-\mu) = \sum_i \frac{y_i^2}{\lambda_i}, \qquad y = Q^T(x-\mu).$$

正交變換的體積倍率是 1，所以 $dx = dy$。積分分解成一維常態積分的乘積：

$$\int_{\mathbb{R}^M} \exp\left(-\frac{1}{2}\sum_i \frac{y_i^2}{\lambda_i}\right) dy = (2\pi)^{M/2} \prod_i \lambda_i^{1/2}.$$

而

$$\prod_i \lambda_i^{1/2} = \det(V)^{1/2},$$

一維 Gaussian 積分可由平方轉為二維極座標證明：$I = \int e^{-t^2/2} dt > 0$，則 $I^2 = \int_0^{2\pi}\int_0^{\infty} e^{-r^2/2} r\, dr\, d\theta = 2\pi$，故 $I = \sqrt{2\pi}$。縮放每個座標得到上式，正規化正確。$V$ 奇異時，Gaussian 位於較低維的仿射子空間，在 $\mathbb{R}^M$ 中不存在相對於全空間體積的普通密度。



## 加權最小平方

令 $A \in \mathbb{R}^{m\times n}$、$b, e \in \mathbb{R}^m$、$x \in \mathbb{R}^n$，模型為：

$$b = Ax + e, \qquad \mathbb{E}[e] = 0, \qquad \mathrm{Cov}(e) = V \succ 0.$$

普通最小平方法（OLS） 最小化

$$\|b - Ax\|_2^2,$$

對固定設計矩陣、零均值誤差，OLS 仍可無偏；要它成為最佳線性不偏估計量（BLUE），等變異且不相關的共變異數 $\sigma^2 I$ 已充分，不要求獨立性。一般已知 SPD 共變異數使用 Mahalanobis 加權殘差：

$$J(x) = (b-Ax)^T V^{-1}(b-Ax).$$

梯度：

$$\nabla J = -2A^T V^{-1}(b-Ax).$$

設為零，得加權正規方程：

$$A^T V^{-1} A x = A^T V^{-1} b.$$

滿 column rank 時，

$$\hat{x} = (A^T V^{-1} A)^{-1} A^T V^{-1} b.$$

這個駐點是全局最小值。令 $h \neq 0$，展開：

$$J(x+h) - J(x) = -2h^T A^T V^{-1}(b-Ax) + h^T A^T V^{-1} A h.$$

## 加權最小平方 （續）

在加權正規方程的解 $\hat{x}$，第一項為零；滿 column rank 給出 $Ah \neq 0$，而 $V \succ 0$ 給出 $h^T A^T V^{-1} A h > 0$。因此每個非零位移都增加目標函數，唯一最小值就是 $\hat{x}$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study



## 完整數例：三筆異變異測量

令 $A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$、$b = (2, 5, 4)^T$，誤差共變異矩陣為 $V = \mathrm{diag}(1, 4, 9)$。白化後三式依序為

$$x_1 \approx 2, \quad \tfrac{1}{2}x_1 + \tfrac{1}{2}x_2 \approx \tfrac{5}{2}, \quad \tfrac{1}{3}x_2 \approx \tfrac{4}{3}.$$

因此

$$A^T V^{-1} A = \begin{bmatrix} 5/4 & 1/4 \\ 1/4 & 13/36 \end{bmatrix}, \quad A^T V^{-1} b = \begin{bmatrix} 13/4 \\ 61/36 \end{bmatrix}.$$

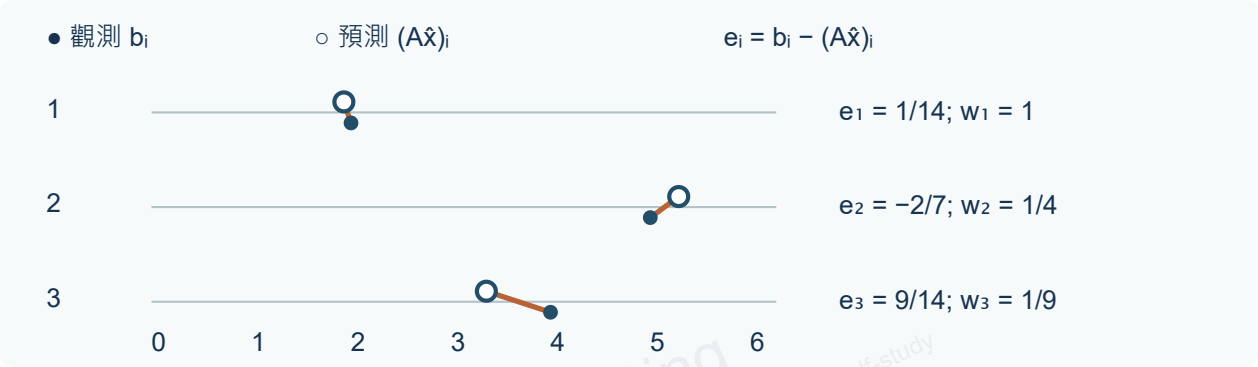
第一列乘 4 得 $5x_1 + x_2 = 13$，第二列乘 36 得 $9x_1 + 13x_2 = 61$。代入 $x_2 = 13 - 5x_1$ 得 $-56x_1 = -108$，所以

$$\hat{x} = (27/14, 47/14)^T, \qquad A\hat{x} = (27/14, 37/7, 47/14)^T.$$

| 測量 | 殘差 $e_i = b_i - (A\hat{x})_i$ | 加權平方 $e_i^2/\sigma_i^2$ |
|---|---|---|
| 1 | $1/14$ | $1/196$ |
| 2 | $-2/7$ | $4/196$ |
| 3 | $9/14$ | $9/196$ |

合計 $J = 14/196 = 1/14$。驗證 $V^{-1}e = (1/14, -1/14, 1/14)^T$，故 $A^T V^{-1} e = 0$。普通歐氏殘差不必滿足 $A^T e = 0$；正交的是白化後的殘差與白化設計矩陣。

## 三筆測量：觀測、預測與加權殘差




實心圓為觀測，空心圓為預測。圖中 $w_i = 1/\sigma_i^2$，殘差的正負按 $e_i = b_i - (A\hat{x})_i$ 判定。三項加權平方和是 $1/196 + 4/196 + 9/196 = 1/14$，且 $A^T V^{-1} e = 0$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study



## 同一組資料：普通與加權最小平方

令 $A = \begin{bmatrix} 1 & 1 \\ -1 & 1 \\ 1 & 4 \end{bmatrix}$、$b = (4, 3, 4)^T$。普通最小平方給 $\hat{x}_{OLS} = (-1/19, 49/38)^T$，第 2 筆殘差為 $63/38$。

若固定誤差共變異數 $V = \mathrm{diag}(1, 1/4, 1)$，權重 $W = V^{-1} = \mathrm{diag}(1, 4, 1)$。加權方程與右端分別為

$$A^T W A = \begin{bmatrix} 6 & 1 \\ 1 & 21 \end{bmatrix}, \qquad A^T W b = (-4, 32)^T.$$

解得 $\hat{x}_W = (-116/125, 196/125)^T$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

## 比較殘差：權重改變取捨

代入得到 $r_W = (84/25, 63/125, -168/125)^T$，第 2 筆殘差從 $63/38$ 降為 $63/125$。逐欄驗證

$$A^T W r_W = 0, \qquad r_W^T W r_W = 1764/125.$$

權重提高使解更重視第二筆，但其他殘差可能變大；權重必須由誤差模型或可靠度支持，不代表每筆觀測都改善。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study



## 獨立異變異誤差

若誤差有有限正變異數且互不相關（獨立性亦充分）：

$$V = \mathrm{diag}(\sigma_1^2, \dots, \sigma_m^2),$$

則最小化

$$J(x) = \sum_{i=1}^{m} \frac{(b_i - a_i^T x)^2}{\sigma_i^2}.$$

高變異數測量的權重小，低變異數測量的權重大。

重複量同一個純量 $x$：

$$A = (1, 1)^T, \qquad b = (b_1, b_2)^T.$$

正規方程：

$$\left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right) x = \frac{b_1}{\sigma_1^2} + \frac{b_2}{\sigma_2^2}.$$

所以

$$\widehat{x} = \frac{b_1/\sigma_1^2 + b_2/\sigma_2^2}{1/\sigma_1^2 + 1/\sigma_2^2},$$

它是精度加權平均數。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

## 估計量的共變異數

估計量是線性：

$$\widehat{x} = Gb, \qquad G = (A^T V^{-1} A)^{-1} A^T V^{-1}.$$

若 $b$ 的共變異數是 $V$：

$$\mathrm{Cov}(\widehat{x}) = GVG^T.$$

代入 G：

$$\mathrm{Cov}(\widehat{x}) = (A^T V^{-1} A)^{-1}.$$

對角線元素是各參數估計量的變異數，非對角元素是估計量間的共變異數；須再除以相應標準差乘積才是相關係數。此公式假設固定滿 column rank $A$、固定已知 SPD $V$；若 $V$ 以同一批資料估計，$G$ 也是隨機，不能直接把代入估計後的逆矩陣當成 精確抽樣共變異矩陣。

BLUE 的證明：$GA = I$，所以 $\mathbb{E}[Gb] = x$。任何另一個對所有參數都無偏的線性估量可寫 $Hb = (G + D)b$，且 $DA = 0$。因 $GV = (A^T V^{-1} A)^{-1} A^T$，有 $GVD^T = 0$，所以 $HVH^T - GVG^T = DVD^T \succeq 0$。此處共變異數最小是 PSD 次序，不是逐元素比較。常態性不必要；精確信賴區間與檢定另需分布假設。



## 加權最小平方的條件數

不要顯式求逆 $V$。若誤差互相獨立，先逐式白化：

$$\tilde{A} = V^{-1/2} A, \qquad \tilde{b} = V^{-1/2} b.$$

再對 $\tilde{A}, \tilde{b}$ 做普通最小平方法（OLS）。

形成白化後的正規矩陣 $\tilde{A}^T \tilde{A}$ 會將 $\tilde{A}$ 的二範數條件數平方；不是求逆運算本身才造成平方。穩定流程以 SPD $V = LL^T$ 的三角求解求 $\tilde{A} = L^{-1} A, \tilde{b} = L^{-1} b$，再做 QR 或 SVD。大型稀疏問題可用不顯式形成矩陣的方法。

樣本共變異矩陣估計不確定或奇異時，可使用收縮估計、正則化或降維，但要報告這些方法如何改變統計模型。

## 新觀測到來：遞迴最小平方

設舊資料的加權最小平方估計為 $\hat{x}_0$，其誤差共變異矩陣為 $W_0 \succ 0$。新的測量為 $b_1 = Hx + \eta$，其中 $\mathbb{E}[\eta] = 0$、$\mathrm{Cov}(\eta) = R \succ 0$，且新誤差與舊資料誤差互不相關。將兩批加權正規方程相加：

$$W_1^{-1} = W_0^{-1} + H^T R^{-1} H,$$
$$W_1^{-1}\hat{x}_1 = W_0^{-1}\hat{x}_0 + H^T R^{-1} b_1.$$

第二式減去第一式乘 $\hat{x}_0$，得更新式

$$\hat{x}_1 = \hat{x}_0 + K(b_1 - H\hat{x}_0), \quad K = W_1 H^T R^{-1}.$$

$b_1 - H\hat{x}_0$ 是 innovation（新觀測與舊預測的差）。為避免反覆求逆，可改算

$$S = R + HW_0H^T, \quad K = W_0H^TS^{-1}, \quad W_1 = W_0 - W_0H^TS^{-1}HW_0.$$

驗證兩種增益相同：$(W_0^{-1} + H^TR^{-1}H)W_0H^TS^{-1} = H^TR^{-1}(R + HW_0H^T)S^{-1} = H^TR^{-1}$。再乘 $W_1$ 即得 $K = W_1H^TR^{-1}$。同理左乘 $W_1^{-1}$ 可驗證最後一個共變異數公式。減去的矩陣半正定，所以 $W_1 \preceq W_0$，新資料不增加此模型下線性估計的不確定性。

這是固定狀態的遞迴最小平方，也是原書簡化 Kalman 更新的內容；完整動態濾波還需要狀態轉移、過程誤差與預測步驟，不能直接用此式替代。



## 遞迴更新的數值核對

估計同一常數 $x$，舊觀測為 $b_0 = 10$、變異數 $1$，所以 $\hat{x}_0 = 10, W_0 = 1$。取 $H = 1$，依序加入兩個不相關的新觀測：

| 步驟 | 新觀測及變異數 | $S = R + W$ | $K = W/S$ | 新估計值 | 新變異數 |
|---|---|---|---|---|---|
| 1 | $b_1 = 13, R_1 = 9$ | $10$ | $1/10$ | $10 + (1/10)(3) = 103/10$ | $9/10$ |
| 2 | $b_2 = 9, R_2 = 1$ | $19/10$ | $9/19$ | $103/10 + (9/19)(9 - 103/10) = 184/19$ | $9/19$ |

一次解全部資料的精度加權平均為

$$\hat{x} = \frac{10 + 13/9 + 9}{1 + 1/9 + 1} = \frac{184}{19}, \quad \mathrm{Var}(\hat{x}) = \frac{1}{1 + 1/9 + 1} = \frac{9}{19}.$$

兩種算法精確相同。若新觀測只是舊觀測的複製，它與舊誤差相關；再當成獨立資料加一次權重，便會低估不確定性。

## 穩健性與模型假設

WLS 不是普遍適用的誤差模型。關鍵假設：

- 誤差平均數已知或為零；
- 共變異數 $V$ 已知或有可信估計；
- 條件平均的線性模型 $Ax$ 正確；
- 聯合共變異矩陣確實捕捉相依性；
- 滿 column rank，參數唯一可識別。

無有限二階矩的重尾使共變異數模型失效；離群值或遺漏非線性也可能使 WLS 與需求不合。相關誤差若已正確納入 $V$，並不違反廣義最小平方法。$L_1$ 損失函數對大殘差的懲罰為線性，對垂直離群值較不敏感，但不自動抵抗高槓桿的設計點；線性模型的 最小絕對離差可改寫為 LP，無需聲稱必須非線性最佳化。

時間序列的誤差共變異數常有非對角結構；直接令 $V = I$ 會同時改變加權方式與不確定性。相關係數也不等於因果效果。



## 本章重點

- 區分樣本摘要、隨機估計量與分布參數；無偏性需列前提。
- 共變異數為零一般不足以推得獨立；共變異矩陣是半正定的。
- 加權最小平方對應誤差共變異數，白化後才是普通歐氏投影。
- 遞迴更新依賴新舊誤差的相關性假設，不能重複計算同一資訊。

### 參考資料與署名

Lin Cing，《線性代數》手寫筆記。 Gilbert Strang, Introduction to Linear Algebra, 5th ed., Chapter 12.

Lin Cing 原創教學整理，原創內容以 CC BY 4.0 授權。

https://github.com/xinhi6716/computer-science-self-study