參考用書：Introduction to Linear Algebra, 5th Edition
Gilbert Strang

線性代數

完整版講義

A4 直式・上下兩張・Lin Cing

目錄

第 1 章：向量與線性組合 2
第 2 章：解線性方程 13
第 3 章：向量空間與子空間 32
第 4 章：正交性 45
第 5 章：行列式 61
第 6 章：特徵值與特徵向量 77
第 7 章：奇異值分解 93
第 8 章：線性轉換 112
第 9 章：複數向量與矩陣 126
第 10 章：應用 141
第 11 章：數值線性代數 158
第 12 章：機率與統計中的線性代數 184

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

本章要解決什麼

線性代數處理兩件事：

$$\text{加法：}\ v+w, \qquad \text{純量乘法：}\ cv.$$

把兩者合併，得到 linear combination（線性組合）

$$cv+dw.$$

矩陣只是把「使用哪些係數組裝哪些 column vectors（欄向量）」整理成

$$Ax = x_1a_1 + \cdots + x_na_n.$$

本章的幾何問題是「組合能到達哪裡」，代數問題是「指定目標需要哪些係數」。

矩陣乘法沿用同一組係數與向量；它是線性組合的緊湊記法。

向量、分量與相等

實 n 維向量可寫成 column vector（欄向量）

$$v = (v_1, \ldots, v_n)^T \in \mathbb{R}^n.$$

上標 T 把橫寫的 tuple 轉成直立欄。向量只能在維度相同時相加：

$$(v+w)_i = v_i + w_i.$$

純量乘法逐分量作用：

$$(cv)_i = cv_i.$$

向量尺寸 n 描述資料維度，不代表其中有 n 個「真正獨立方向」。這是後面 span 與 rank 才會回答的問題。

這裡的 T 表示 transpose（轉置），不是變數。維度不同時，$v+w$ 沒有定義。

零向量與係數不是同一事

$$0 = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$$

是向量加法的單位元，而純量 0 是純量加法的單位元；純量乘法的單位元是 1。兩種零的型別不同，只在資料上用相同符號。

向量減法也是逐分量：

$$v - w = v + (-1)w.$$

平面上常用有向線段表示 vector。若 $p, q \in \mathbb{R}^n$，從 p 到 q 的 displacement（位移）是 $q - p$。從原點指向 q 的箭頭與 q 同值；從 p 出發的箭頭只是把同一向量搬移。

避免把向量的起點當成向量本身的一部分。向量值只記錄方向與大小。

線性組合與 span

給定 $v = (2, 1)^T$、$w = (1, 2)^T$，所有組合為

$$cv + dw = \begin{bmatrix} 2c + d \\ c + 2d \end{bmatrix}.$$

若目標 $b = (3, 3)^T$，解

$$2c + d = 3, \qquad c + 2d = 3,$$

得到 $c = d = 1$。

所有 $cv + dw$ 形成的集合稱為

$$\operatorname{span}\{v, w\}.$$

此例的係數矩陣行列式是 $2 \cdot 2 - 1 \cdot 1 = 3 \neq 0$，所以兩個方向不重合，span 是整個 $\mathbb{R}^2$。

幾何上，$v, w, v + w$ 是以原點為一頂點之平行四邊形的兩條邊與對角線。

線性組合與 span （續）

線性組合的平行四邊形：v=(2,1)，w=(1,2)，v+w=(3,3)

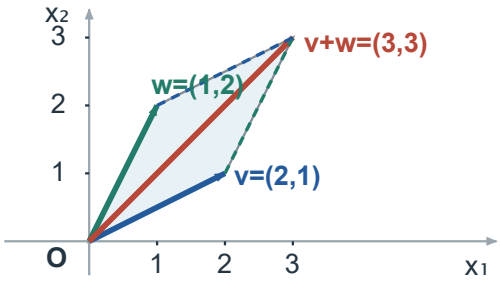

同一組數值

v=(2,1)，w=(1,2)

c=d=1

cv+dw=(3,3)

det[[2,1],[1,2]]=3≠0

span 問的是「容許所有實係數後能到達哪裡」，不是固定一組係數能得到什麼。

相依、獨立與不可達目標

若 $w = 2v$，則 $\text{span}\{v, w\} = \text{span}\{v\}$。當 $v \neq 0$ 時，在 $\mathbb{R}^2$ 中得到一條直線；若 $v = 0$，span 只有零向量。

取 $v = (1, 2)^T$、$w = (2, 4)^T$、$b = (3, 5)^T$。任何組合的兩分量必滿足 $y = 2x$，但 b 的 $5 \neq 2 \cdot 3$，所以方程組

$$\begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} c \\ d \end{bmatrix} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}$$

無解。

若純量 $c_1, \ldots, c_k$ 滿足

$$c_1 v_1 + \cdots + c_k v_k = 0$$

且其中至少一個 $c_i \neq 0$，這組 vectors 稱為 linearly dependent（線性相依）。不存在這種非零組合時，稱為 linearly independent。

不可解不表示計算失敗，而是幾何上 b 不在可達子空間。

獨立性的方程式判準

$v_1, \dots, v_k$ 獨立等價於齊次方程

$$Vc = 0, \qquad V = \begin{bmatrix} v_1 & \cdots & v_k \end{bmatrix}$$

只有 $c = 0$。

對 $k = n$ 的方陣，若每欄都拿來做 basis（基底），則 V 可逆，$Vc = 0$ 只可能有零解。若 $k > n$，$\mathbb{R}^n$ 中不可能有超過 n 個獨立向量。

反例：三個 $\mathbb{R}^2$ 向量必有

$$c_1 v_1 + c_2 v_2 + c_3 v_3 = 0$$

的非零解。能否找到非零解與「有沒有任何係數組合等於某個 b」是不同問題。

$Vc = 0$ 是齊次方程；$Vc = b$ 是否有解，稱為一致性（consistency）。

dot product 與長度

對 $u, v \in \mathbb{R}^n$，inner product（內積，也稱 dot product）定義為

$$u \cdot v = u^T v = \sum_{i=1}^{n} u_i v_i.$$

Euclidean norm（歐氏長度）是

$$\|v\|_2 = \sqrt{v^T v}.$$

$\|v\|_2 = 1$ 的向量是 unit vector。非零 v 可正規化為

$$\frac{v}{\|v\|_2}.$$

例：$v = (3, 4)^T$ 的長度是 5，單位向量是 $(3/5, 4/5)^T$。

在複數空間，$u^H v$ 的 conjugate 必須放左側；第 9 章會修正此處的實數公式。

角度與正交

對非零實向量 u, v，若 θ 是夾角，則

$$\cos\theta = \frac{u^T v}{\|u\|_2 \|v\|_2}.$$

因此對非零向量，$u^T v = 0$ 等價於 $\theta = 90^\circ$，稱為 orthogonal（正交）。零向量與任何向量皆正交，因為內積為零；但零向量沒有方向，夾角公式不適用。

例：

$$u = (3, 4)^T, \quad v = (4, 3)^T, \quad \cos\theta = \frac{24}{5 \cdot 5} = \frac{24}{25}.$$

若 $w = (4, -3)^T$，則 $u^T w = 12 - 12 = 0$。

零向量的方向未定義，處理正交基底時先要求 vectors 非零。

Cauchy–Schwarz 與三角不等式

對所有 $u, v \in \mathbb{R}^n$，

$$|u^T v| \le \|u\|_2 \|v\|_2.$$

證明：若 $v = 0$，不等式立即成立。若 $v \neq 0$，令 $t = (u^T v)/(v^T v)$，則 $0 \le \|u - tv\|^2 = u^T u - (u^T v)^2/(v^T v)$。移項即得不等式；等號恰在 $u = tv$ 時成立。平方後，等價於

$$(u^T v)^2 \le (u^T u)(v^T v).$$

等號成立若且唯若 u, v 線性相依。因為 $|u^T v| \le \|u\|\|v\|$，

$$\begin{aligned} \|u + v\|_2^2 &= \|u\|_2^2 + 2u^T v + \|v\|_2^2 \\ &\le (\|u\|_2 + \|v\|_2)^2. \end{aligned}$$

所以 $\|u + v\|_2 \le \|u\|_2 + \|v\|_2$。三角不等式等號出現在同向的非負倍數，而不是任意相依向量。

平方可以消去非負長度，但等號條件要另外保留方向。

矩陣乘法就是欄組合

設

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n}.$$

對 $x \in \mathbb{R}^n$：

$$Ax = x_1 \begin{bmatrix} a_{11} \\ \vdots \\ a_{m1} \end{bmatrix} + \cdots + x_n \begin{bmatrix} a_{1n} \\ \vdots \\ a_{mn} \end{bmatrix}.$$

輸出位於 $\mathbb{R}^m$。計算 Ax 有兩個等價觀點：

- column view：A 的各欄依 x_i 加權後相加。
- row view：每個輸出分量是 A 的一列與 x 的內積。

矩陣乘法就是欄組合 （續）

例：

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = 2 \begin{bmatrix} 1 \\ 3 \end{bmatrix} - \begin{bmatrix} 2 \\ 4 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}.$$

後續章的基礎是 column view；row view 適合逐條理解 equations。

$Ax = b$ 的三種問法

$$Ax = b$$

可以讀成：

1. 哪些欄向量線性組合會產生 b？
2. 哪些 rows（列）同時和 x 做內積後得到 b_i？
3. 線性映射 $x \mapsto Ax$ 是否把某個輸入映射到 b？

對 $b = (0, 2)^T$ 和前頁矩陣，解

$$x_1 + 2x_2 = 0, \qquad 3x_1 + 4x_2 = 2.$$

第一式給 $x_1 = -2x_2$，代回得 $-2x_2 = 2$，所以 $x = (2, -1)^T$。

同一答案 $x = (2, -1)^T$ 不是碰巧，三種觀點只是不同投影角度的同一等式。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

無限多解與唯一解

方陣 $A \in \mathbb{R}^{n \times n}$ 對每個 b 有唯一解，等價於 $Ax = 0$ 只有 $x = 0$。此時 A 可逆。

若存在非零 z 使 $Az = 0$，而 x_p 是某個 $Ax = b$ 的解，則

$$A(x_p + cz) = b + cAz = b$$

對任何純量 c 成立，因此解不唯一。

例：

$$\begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} x = 0$$

的解為 $x_2 = t,\ x_1 = -2t$，形成一條線。

先把 homogeneous solution 找出來，後續第 3 章再把 complete solution 寫成特解加 nullspace。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

2×2 逆矩陣與條件檢驗

對

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}, \quad ad - bc \neq 0,$$

有

$$A^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}.$$

例：

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad A^{-1} = \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}.$$

直接相乘：

$$\frac{1}{3} \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} = I_2.$$

使用逆矩陣前必須先檢查 det 條件。求數值解時，direct elimination 通常比形成 A^{-1} 更有效率。 A^{-1} 是矩陣型別的物件；$1/\det A$ 只是純量。

跨章遷移：多項式與矩陣空間的座標化

以下跨章題不屬於原書 1.1–1.3 的節次；它檢驗讀者能否把「向量」的運算遷移到函數與矩陣空間，而不是背誦 $\mathbb{R}^n$ 的格式。

在 $\mathcal{P}_2$ 取單項式基底 $B = (1, t, t^2)$，定義

$$p_1 = 1 + t, \qquad p_2 = 1 - t, \qquad p_3 = 1 + t^2.$$

座標映射是線性同構，故

$$[p_1]_B = (1, 1, 0)^T, \quad [p_2]_B = (1, -1, 0)^T, \quad [p_3]_B = (1, 0, 1)^T.$$

把這些座標當 columns，得

$$D = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \qquad \det D = (1 \cdot (-1) - 1 \cdot 1) \cdot 1 = -2 \neq 0.$$

因此 p_1, p_2, p_3 是 $\mathcal{P}_2$ 的基底。若 $q(t) = 3 + 2t + t^2$，解 $Dc = [q]_B = (3, 2, 1)^T$，可得 $c = (2, 0, 1)^T$，所以

$$q = 2p_1 + p_3.$$

矩陣空間也相同。對 $M_2(\mathbb{R})$ 使用 column-major 座標

跨章遷移：多項式與矩陣空間的座標化 （續）

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix} \longmapsto (a, c, b, d)^T.$$

令 $A_1 = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$、$A_2 = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$、$A_3 = \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix}$。座標 columns 為

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}.$$

若 $c_1A_1 + c_2A_2 + c_3A_3 = 0$，逐元素比較先得 $c_1 + c_2 = 0$、$c_2 + c_3 = 0$、$c_3 = 0$，所以三個係數全為零；三矩陣線性獨立。基底不是「看起來像數字列」才存在；它由一個可逆的座標映射判斷。

跨章遷移：不對角化時的多項式譜映射

設 $r(t) = \sum_{k=0}^{d} c_k t^k$，且 $Av = \lambda v$、$v \neq 0$。由 $A^k v = \lambda^k v$，

$$r(A)v = \sum_{k=0}^{d} c_k A^k v = \sum_{k=0}^{d} c_k \lambda^k v = r(\lambda)v.$$

因此 $r(A)$ 的 eigenvalue 包含所有 $r(\lambda)$，而相同 eigenvector 仍保留；不需要假設 A 可對角化。等價地，多項式恆等式

$$r(t) - r(\lambda) = (t - \lambda)s_\lambda(t)$$

代回 A 得

$$r(A) - r(\lambda)I = (A - \lambda I)s_\lambda(A),$$

故 eigenvector 方向的推論與對角化無關。

若要主張「全部特徵值恰好如此」，還需證明反向。設 $A \in \mathbb{C}^{n \times n}$，且 r 非常數。若 μ 是 $r(A)$ 的特徵值，將多項式在複數體分解為

跨章遷移：不對角化時的多項式譜映射 （續）

$$r(t)-\mu = c\prod_{j=1}^{d}(t-\zeta_j), \qquad c\neq 0.$$

代入矩陣並取行列式：

$$0=\det(r(A)-\mu I)=c^n\prod_{j=1}^{d}\det(A-\zeta_j I).$$

至少一個因子為零，故某個 ζ_j 是 A 的特徵值，且 $r(\zeta_j)=\mu$。所以

$$\operatorname{spec}(r(A))=r(\operatorname{spec}(A)).$$

常數多項式 $r=c$ 時，$r(A)=cI$ 直接成立。實矩陣的完整譜也在 $\mathbb{C}$ 中理解；只列實特徵值可能漏掉複數共軛對。這個證明給出特徵值的集合；若要計代數重數，可用複數 Schur 上三角化：$r(T)$ 的對角線是 $r(T_{ii})$，不需 T 為對角矩陣。

非對角化例子取

跨章遷移：不對角化時的多項式譜映射 （續）

$$A=\begin{bmatrix}2&1\\0&2\end{bmatrix}=2I+N, \qquad N=\begin{bmatrix}0&1\\0&0\end{bmatrix},$$

以及 $r(t)=t^2+t+1$。因為 $N^2=0$，

$$r(A)=r(2)I+r'(2)N=7I+5N=\begin{bmatrix}7&5\\0&7\end{bmatrix}.$$

直接計算也會得到同一矩陣，且特徵值為 $r(2)=7$。Jordan 鏈的 off-diagonal 可由導數項保留；這正是不能只寫「把特徵值代入」卻沒有說明理由的地方。

本章收束與常見誤解

必須能回答：

- $cv + dw$ 與 $\text{span}\{v, w\}$ 的差別。
- $Ax = b$ 的 column view 與 row view。
- 非零齊次解、無限多解與無解之間的關係。
- dot product 為零與線性相依不是等同條件。
- 方陣「某個 b 可解」未必可推出「所有 b 可解」。

離開本章前的檢查題：在 $\mathbb{R}^2$ 中，若 $\text{span}\{v, w\} = \mathbb{R}^2$，$v, w$ 是否必獨立？答案為是；任一向量都能被組合，0 也不例外，但非零組合不能得到 0，否則 span 會塌成一條線。

下一章把這些判斷變成系統化 elimination 流程。

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

本章的問題

給定 $A \in \mathbb{R}^{m \times n}$、$b \in \mathbb{R}^m$，研究

$$Ax = b.$$

需要分開回答：

1. 是否存在解？
2. 解是否唯一？
3. 如何用有限步驟求出所有解？
4. 計算量與數值風險是什麼？

本章直接處理前 3 問。第 11 章會加入有限精度、穩定性與條件數。

不要把「消去後無矛盾」誤寫成「有唯一解」。存在與唯一是兩個層次。

本章符號、體與 row/column 用語

- m：輸出空間維度，等於方程數與 A 的 row 數。
- n：輸入空間維度，等於未知數與 A 的 column 數。
- A_{ij}：第 i row、第 j column 的元素。
- e_i：第 i 個標準 basis vector。
- P：permutation matrix（排列矩陣）。
- $\mathbb{R}$ 或 $\mathbb{C}$：本階段矩陣元素所在的 field（體）。

若 A 是 $m \times n$，x 必須是 $n \times 1$，b 必須是 $m \times 1$。任何乘法或加法前先檢查這些形狀。

中文教材對 row 與 column 的翻譯不統一，本文固定：

- row（列）：水平方向；
- column（欄）：垂直方向。

有些書把 column 寫成「行」，因此看到中文「行」時必須從上下文確認。本文保留英文 row/column 於容易混淆處，所有矩陣運算都以這裡的定義為準。

本章符號、體與 row/column 用語 （續）

維度不匹配是可先排除的錯誤，不需要進到數值計算才發現。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

兩種同時成立的圖像

考慮

$$x + 3y = 7, \qquad 2x - y = 0.$$

Row picture：兩個方程分別是 xy 平面的直線，交點是 $(x, y) = (1, 2)$。

Column picture：

$$x \begin{bmatrix} 1 \\ 2 \end{bmatrix} + y \begin{bmatrix} 3 \\ -1 \end{bmatrix} = \begin{bmatrix} 7 \\ 0 \end{bmatrix}.$$

係數 $(1, 2)$ 使欄向量組合成目標。這兩張圖都在描述同一組數字，但凸顯不同結構：row view 看限制，column view 看可達方向。

第三維或更多方程時，row picture 由 lines 變成 planes 或 hyperplanes，column view 仍保留「係數組合」。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

兩種同時成立的圖像 （續）

同一系統：x+3y=7，2x−y=0；解 (x,y)=(1,2)

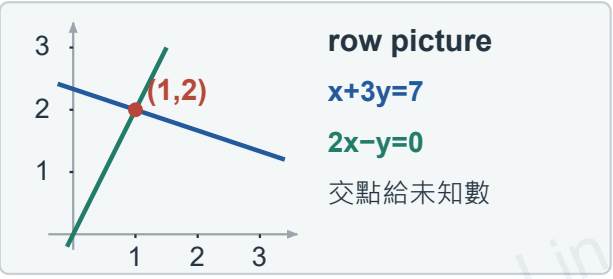

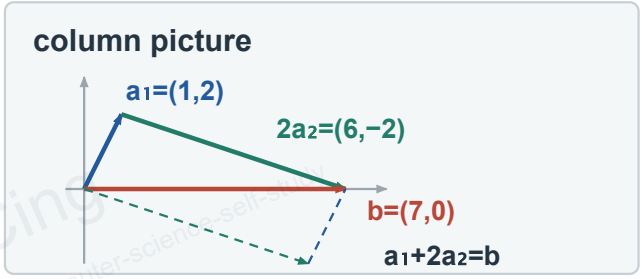

存在性與唯一性

方程組可能有：

- 唯一解：pivot 覆蓋每個未知數且沒有矛盾列。
- 無限多解：一致，但至少一個 free variable。
- 無解：出現 $[0 \cdots 0 \mid c]$，其中 $c \neq 0$。

對 $A \in \mathbb{R}^{m \times n}$：

- $m < n$ 時，齊次方程 $Ax = 0$ 必有非零解，但 $Ax = b$ 仍可能無解。
- 每個 $b \in \mathbb{R}^m$ 都能解，等價於 column space（欄空間）是 $\mathbb{R}^m$。
- 對每個可解的 b 解都唯一，等價於 nullspace（零空間）只有零向量。

rank-nullity 會在下一章正式使用；此刻可用 free variable 的數目理解。

例子中的完整判定

解

$$\begin{aligned} x &+ 2y &&= 4, \\ 2x &+ 4y &&= 9. \end{aligned}$$

第二列減去第一列的 2 倍，得到

$$0x + 0y = 1.$$

這是矛盾列，因此無解。Column view 中，目標 $(4, 9)^T$ 不在 $\text{span}\{(1, 2)^T, (2, 4)^T\}$，該 span 只有直線 $v_2 = 2v_1$。

若右端改為 $(4, 8)^T$，消去後得到 $0 = 0$。限制只剩一條，解是

$$x + 2y = 4 \quad \Rightarrow \quad (x, y) = (4, 0) + t(-2, 1),\ t \in \mathbb{R}.$$

free variable 不是計算殘餘，而是真正描述解集方向的parameter。

Gaussian elimination（高斯消去）

消去法用可逆 row operations（列運算）保持解集：

1. 交換兩列。
2. 將一列乘非零純量。
3. 將某列的純量倍加到另一列。

從第一欄選非零 pivot（主元），以它清除該欄下方元素。接著移到右側下一欄，直到無列可處理。

示例：

$$\left[\begin{array}{ccc|c} 1 & 2 & 1 & 8 \\ 3 & 8 & 4 & 24 \\ 0 & 4 & 3 & 17 \end{array}\right]$$

先用 row 1 清除 row 2 的第一欄，再處理第二欄。每一步都不改變 equations 的解集。

row operation 是在方程左右的同時運算；不是任意改動單一資料格。

pivot 與 multiplier 的意義

若使用第 k 個 pivot p 清除位置 (i,k)，multiplier（乘數）是

$$\ell_{ik} = \frac{A_{ik}}{p},$$

並執行 $R_i \leftarrow R_i - \ell_{ik} R_k$。

前頁例子第一欄的 multiplier 是 $3/1 = 3$，消去後得

$$\left[\begin{array}{ccc|c} 1 & 2 & 1 & 8 \\ 0 & 2 & 1 & 0 \\ 0 & 4 & 3 & 17 \end{array}\right].$$

接著第二欄 pivot 為 2，multiplier 為 $4/2 = 2$。

小 pivot 在精確算術中還可用；有限精度時可能放大誤差，第 11 章會用 partial pivoting 處理。

回代與 rank 的初步

前頁完成消去：

$$\left[\begin{array}{ccc|c} 1 & 2 & 1 & 8 \\ 0 & 2 & 1 & 0 \\ 0 & 0 & 1 & 17 \end{array}\right].$$

由下而上：

$$z = 17, \quad 2y + 17 = 0 \Rightarrow y = -17/2,$$
$$x + 2(-17/2) + 17 = 8 \Rightarrow x = 8.$$

有三個非零 pivots，方陣 rank 為 3，因此解唯一。若有 zero row 且右端相同為 zero，那一列不提供新限制；若有 rank-deficient 欄，會產生自由變數。

rank 等於非零 pivot 數目。一般列階梯形已可辨認 pivot column 的索引；取基底時應取原矩陣中對應的欄，而不是消去後改變的欄。

消去流程的完整決策順序

對 $A \in \mathbb{F}^{m \times n}$ 與 $b \in \mathbb{F}^m$，流程如下：

1. 固定體與未知數順序。精確算術可選任一非零 pivot；有限精度通常選目前欄中絕對值最大的元素作 pivot。
2. 從左到右掃描 columns。若目前 column 在 pivot row 以下全為零，跳過該 column；它對應的未知數通常成為 free variable。
3. 若找到非零元素，交換它到 pivot row，消去下方同 column 的元素，再向右移動。每一步左乘可逆初等矩陣。
4. 完成 row echelon form 後，先找 $[0 \ \cdots \ 0 \mid c]$。若有 $c \neq 0$，系統無解；若所有矛盾列都不存在，系統一致。
5. 求零空間時，必須另解齊次系統：保留同一個階梯形係數矩陣，把右端全部改為 0。對每個 free column，設對應 free variable 為 1、其餘 free variables 為 0，再回代 pivot variables，得到 $As_j = 0$ 的 special solutions。不能沿用非齊次右端，否則得到的是原系統的解，而非零空間向量。
6. 為求一個 particular solution，令全部 free variables 為 0，回代 pivot variables；完整解為

消去流程的完整決策順序 （續）

$$x = x_p + \sum_{\text{free } j} t_j s_j.$$

這個流程也需要「在指定體上」的前提。若 pivot 在某個體中為零，不能只因它在另一個體中非零就沿用同一消去；檢查 consistency 時也必須同步套用 row operations 到 augmented column。

例如 $x_1 + 2x_2 = 4$：特解為 $x_p = (4, 0)^T$；齊次式 $x_1 + 2x_2 = 0$ 在 $x_2 = 1$ 時給 $s = (-2, 1)^T$，故全解 $x = (4, 0)^T + t(-2, 1)^T$。若錯用原右端，會得到 $(2, 1)^T$，其像為 4，並不在零空間中。

用矩陣乘積執行列運算

若要把第二列加上第一列的 2 倍，對單位矩陣做此運算得到：

$$E = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}, \qquad EI_2 = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}.$$

左乘 E 對 rows 作用，右乘 E 對 columns 作用。這是一個關鍵的側別：

$$EA \text{ 改 rows}, \qquad AF \text{ 改 columns}.$$

初等矩陣 E 可逆，且逆矩陣撤銷相應 row operation。例如上面 E 的逆是

$$E^{-1} = \begin{bmatrix} 1 & 0 \\ -2 & 1 \end{bmatrix}.$$

題目若要求先乘哪個運算，符號順序不能對調。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

消去矩陣的乘法順序

若先施加 E_1，再施加 E_2，最後矩陣是

$$E_2(E_1A) = (E_2E_1)A.$$

Left multiplication 的順序是由右往左對應時間，但矩陣本身先合併成 E_2E_1。若交換 E_1, E_2，row operations 的結果可能不同。

若對方陣不換列、也不縮放 pivot row，只用下方列減去 pivot row 的倍數，從多步消去得到

$$E_k \cdots E_2E_1A = U.$$

因此

$$A = (E_k \cdots E_1)^{-1}U = LU.$$

這個關係將在「從消去到 $A = LU$」整理為 LU 分解。第一欄消去所得的 ℓ_{ik} 將直接進入 L。

正確公式是 $(E_k \cdots E_1)^{-1} = E_1^{-1} \cdots E_k^{-1}$；逆矩陣的乘積必須反轉順序。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

何時需要 row swap

若第一欄 pivot 位置為零，可以把下方非零元素交換上來：

$$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} b \\ a \end{bmatrix}.$$

最後一列若為

$$[0 \ \cdots \ 0 \mid c],$$

且 $c \neq 0$，方程組無解。若 row exchange 能把非零項帶入 pivot 位置，便繼續消去；若整欄下方皆零，就必須跳到下一欄。

pivot 位置並非永遠在對角線；對矩形矩陣尤其必須依欄搜尋。

矩陣乘法與 dimension

若 $A \in \mathbb{F}^{m \times n}$、$B \in \mathbb{F}^{n \times p}$，則

$$(AB)_{ij} = \sum_{k=1}^{n} A_{ik} B_{kj}, \qquad AB \in \mathbb{F}^{m \times p}.$$

中間維度 n 必須相同；輸出維度由左矩陣 rows、右矩陣 columns 決定。

「AB」只有在上述形狀符合時才存在。即使 AB 存在，BA 也可能沒有定義。即使兩者都存在，通常

$$AB \neq BA.$$

矩陣乘法代表先施加右側轉換、再施加左側轉換；不交換正好反映作用順序。

Column 與 row 組合觀點

$$AB = A\begin{bmatrix} b_1 & \cdots & b_p \end{bmatrix} = \begin{bmatrix} Ab_1 & \cdots & Ab_p \end{bmatrix}.$$

所以 AB 的每一欄是 A 各欄依 B 對應欄係數的組合。也能按 rows 分解：

$$AB = \begin{bmatrix} a_1^T \\ \vdots \\ a_m^T \end{bmatrix} B = \begin{bmatrix} a_1^T B \\ \vdots \\ a_m^T B \end{bmatrix}.$$

例：

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}\begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} = \begin{bmatrix} 1 & -2 \\ 3 & -4 \end{bmatrix},$$

這是右乘對角符號矩陣，只將第二欄乘以 -1，沒有交換欄位置。

block multiplication 合法的前提是每個 block 介面維度一致。

不可交換與分配律

取

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

計算得

$$AB = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}, \qquad BA = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

所以 $AB \neq BA$。可用的律包括

$$A(B + C) = AB + AC, \quad (A + B)C = AC + BC,$$

以及當尺寸配合時 $A(BC) = (AB)C$。若 A 可逆，可左消去 $AB = AC$ 得 $B = C$；純量加法消去不可直接套用到一般矩陣乘法。

不要把實數的 commutative law 自動套到矩陣。

逆矩陣的定義

對 $A \in \mathbb{F}^{n\times n}$，若存在 B 使

$$AB = BA = I_n,$$

則 A 可逆，並寫 $B = A^{-1}$。方陣是為避免 left inverse 與 right inverse 混淆，但即使形狀相同，仍須兩側都檢查定義。

逆矩陣若存在則唯一。若 $AB = I$ 且 $CA = I$，則

$$B = IB = (CA)B = C(AB) = CI = C.$$

因此左右逆在方陣可逆情況下沒有不同。

第 2 章以方陣為主；長方矩陣的 one-sided inverse 需要額外假設。

若 $A \in \mathbb{R}^{m\times n}$ 且 $m \neq n$，不能同時有 $AB = I_m$、$BA = I_n$ 這組雙邊逆。滿 column rank $n \leq m$ 時，A^TA 可逆，

$$A_L = (A^TA)^{-1}A^T, \qquad A_LA = I_n,$$

逆矩陣的定義 （續）

稱為 left inverse，但不是 A 的雙邊 inverse，且可能有其他 left inverses。滿 row rank $m \leq n$ 時，對稱地有

$$A_R = A^T(AA^T)^{-1}, \qquad AA_R = I_m.$$

兩個公式都把 dimension 與 rank 條件放在前面；行列式只對方陣可談，不能用它把長方矩陣直接判成可逆。若 rank 不足，需要 Moore–Penrose pseudoinverse 或最小平方模型，而不是硬套上述 inverse。

消去時只對 rows 做 row operations 可直接保留同一個 x；若在 columns 上做運算，實際上是在重排或混合未知數，必須同步改變 variable ordering。這是解方程式時只用 row operations 的關鍵原因。

Gauss–Jordan 求逆

要對 A 求逆，把 A 與 I 並排：

$$[A \mid I],$$

只做 row operations，直到左側成為 I：

$$[I \mid A^{-1}].$$

例：

$$\left[\begin{array}{cc|cc} 2 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{array}\right] \xrightarrow{R_1 \leftarrow R_1 - R_2} \left[\begin{array}{cc|cc} 1 & 0 & 1 & -1 \\ 1 & 1 & 0 & 1 \end{array}\right] \xrightarrow{R_2 \leftarrow R_2 - R_1} \left[\begin{array}{cc|cc} 1 & 0 & 1 & -1 \\ 0 & 1 & -1 & 2 \end{array}\right].$$

所以 $A^{-1} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}$。

這個結果可用 $AA^{-1} = I$ 驗算；初等 rows 若造成左側 zero row，則 A 不可逆。

可逆性的等價條件

對方陣 $A \in \mathbb{F}^{n \times n}$，下列命題在指定體上等價：

1. $Ax = 0$ 只有 $x = 0$。
2. A^{-1} 存在。
3. A 的 n 個 columns 線性獨立。
4. A 的 columns span $\mathbb{F}^n$。
5. elimination 得到 n 個非零 pivots。
6. $\det A \neq 0$。

前五項可由消去證明：零空間只有零解等價於沒有自由變數，方陣因而有 n 個主元，每個右端皆可唯一回代；逐一以標準基底為右端求解，即可組成逆矩陣。反過來，左乘逆矩陣立刻給出齊次方程只有零解。第 6 項需先定義 determinant，將於第 5 章完整處理。矩形矩陣不可照搬全部條件。

命題中的「在指定體上」有實質作用。例如某些矩陣在實數體上可逆，在有限體上可能不可逆。

從消去到 $A = LU$

若不需 row exchange，且 Gaussian elimination 的 pivots 不為零，則

$$A = LU,$$

其中 L 是 unit lower triangular，U 是 upper triangular。L_{ik} 記下第 i 列減去第 k 列的乘數。

例：

$$A = \begin{bmatrix} 2 & 1 \\ 4 & 3 \end{bmatrix}.$$

第一欄 multiplier 是 $4/2 = 2$：

$$L = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

檢查 $LU = A$。對同一個 A 解多個右端 b，分解後只需重複 forward/back substitution。

L 的乘數是「消去時做了什麼」，不是最後的原始資料。

需要交換時的 $PA = LU$

若 pivot 位置為零，消去時必須先交換 rows。把交換集中成 permutation matrix P，可寫成

$$PA = LU.$$

對可逆方陣，總可選出讓每一步 pivot 非零的列，再得到此分解。P 左乘 A 表示預先排列 A 的 rows。

不要直接把 P 與 L, U 的順序交換。$PA = LU$ 的解讀是：先排列 A，再做沒有交換的 LU 消去。

有限精度演算法通常連「不為零」都不夠，而會選欄中絕對值最大者作為 pivot。

例如

$$A = \begin{bmatrix} 0 & 2 \\ 1 & 3 \end{bmatrix}, \quad b = \begin{bmatrix} 4 \\ 7 \end{bmatrix}, \quad P = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}.$$

先交換兩個 rows：$PA = \begin{bmatrix} 1 & 3 \\ 0 & 2 \end{bmatrix} = U$，因此 $L = I$。右端也交換成 $Pb = (7, 4)^T$；回代給 $y = 2, x = 1$，原式驗算為 $(4, 7)^T$。不能只交換 A 而保留原來的 b。多步分解在後期交換 rows 時，也須交換已存入 L 的舊乘數位置；否則即使 U 正確，$PA = LU$ 仍會失效。

成本與使用時機

對 dense $n \times n$ 方陣：

- Gaussian elimination 約需 $O(n^3)$ 次算術。
- forward/back substitution 約需 $O(n^2)$。
- 直接形成 inverse 後乘 b，還要額外做 matrix inverse，通常不划算。

所以常見策略是

$$A \longrightarrow PA = LU$$

一次，之後對多個 b 做 substitution。若只需要檢查某個系統的 consistency，elimination 比求 inverse 更直接。

精確代數可考慮 determinants 或 symbolic inverse，但一般數值計算仍以 factorized solve 為主。

成本的來源可直接求和：第 k 個 pivot 需更新約 $(n-k)^2$ 個尾端元素，每次一乘一減，共

$$2\sum_{k=1}^{n-1}(n-k)^2 = \frac{n(n-1)(2n-1)}{3} = \frac{2}{3}n^3 + O(n^2)$$

成本與使用時機 （續）

次浮點加乘；乘數除法與右端更新只增加 $O(n^2)$。三角回代只需處理 $n(n-1)/2$ 個非對角項，故為 $O(n^2)$。此模型計算算術次數，未包括資料搬移、稀疏填入或大整數位元成本。

不換列 LU 的條件與唯一性

對可逆方陣 A，存在不換列、每一步主元非零的 $A = LU$，若且唯若每個左上角主子矩陣 A_k 都可逆。若已有分解，因三角結構 $A_k = L_k U_k$，故

$$\det A_k = \prod_{j=1}^{k} u_{jj} \neq 0.$$

反向由消去歸納：第一個主元 $a_{11} = \det A_1 \neq 0$。前 $k-1$ 步已完成時，左上 k 階的行列式是前面主元乘上新主元；所以

$$u_{kk} = \frac{\det A_k}{\det A_{k-1}} \neq 0, \qquad \det A_0 = 1.$$

每一步都合法。此條件比「整個 A 可逆」更強；例如 $\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ 可逆，卻需先交換 rows。

在固定的 P 下，若 $PA = LU = \widetilde{L}\widetilde{U}$，且兩個下三角因子的對角線皆為 1，則 $\widetilde{L}^{-1}L = \widetilde{U}U^{-1}$ 同時為單位下三角與上三角，只能是 I。所以這種正規化後的 L, U 唯一；不同選列規則的 P 不必相同。

Transpose 與 permutation

Transpose（轉置）定義為

$$(A^T)_{ij} = A_{ji}.$$

若 $A \in \mathbb{F}^{m \times n}$，則 $A^T \in \mathbb{F}^{n \times m}$。

Permutation matrix P 每列每欄恰有一個 1，其餘為 0。例：

$$P = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}.$$

PA 排列 A 的 rows，AP 排列 columns。若 P 是 permutation，則 $P^T P = I$。

P^T 就是 undo 的交換；交換不改變方程組的解集，只改變列順序。

Inner product 與 outer product

對 $x, y \in \mathbb{R}^n$：

$$x^T y \in \mathbb{R}$$

是一個 inner product（內積），即純量。

若 $u \in \mathbb{R}^m$、$v \in \mathbb{R}^n$，則

$$uv^T \in \mathbb{R}^{m \times n},$$

稱為 outer product（外積型矩陣）。若 $u \neq 0$ 且 $v \neq 0$，它的第 j 個 column 是 $v_j u$，其中至少一欄非零，且全部落在 $\text{span}\{u\}$，因此 rank 為 1；若 $u = 0$ 或 $v = 0$，所有 entries 都是 0，rank 反而是 0。

例：

$$\begin{bmatrix} 1 \\ 2 \end{bmatrix} \begin{bmatrix} 3 & -1 \end{bmatrix} = \begin{bmatrix} 3 & -1 \\ 6 & -2 \end{bmatrix},$$

第二個 row 是第一個 row 的 2 倍，rank 為 1。

若把 u 改成零向量，

Lin Cing https://github.com/xinhi6716/computer-science-self-study

Inner product 與 outer product （續）

$$\begin{bmatrix} 0 \\ 0 \end{bmatrix} \begin{bmatrix} 3 & -1 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix},$$

則沒有非零 column 可張成 image，$\text{rank} = 0$。同理，$v = 0$ 也得到零矩陣。因此

$$\text{rank}(uv^T) = \begin{cases} 1, & u \neq 0 \text{ 且 } v \neq 0, \\ 0, & u = 0 \text{ 或 } v = 0. \end{cases}$$

Lin Cing https://github.com/xinhi6716/computer-science-self-study

Inner product 與 outer product （續）

外積 uvᵀ 的秩：只有兩向量皆非零時才是 rank 1

u≠0, v≠0	u=0, v≠0	u≠0, v=0
u=(1,2)ᵀ, v=(3,-1)ᵀ	u=(0,0)ᵀ, v=(3,-1)ᵀ	u=(1,2)ᵀ, v=(0,0)ᵀ
uvᵀ=[[3,-1],[6,-2]]	uvᵀ=[[0,0],[0,0]]	uvᵀ=[[0,0],[0,0]]
每個欄都沿 u 伸展	每個欄都是零向量	所有元素都是零
rank(uvᵀ)=1	**rank(uvᵀ)=0**	**rank(uvᵀ)=0**

$x^T y$ 與 xy^T 不只是左右順序不同，輸出型別也完全不同。

跨章遷移：積分內積的 Gram 系統

以下內容不是原書 2.1–2.7 的節次，而是把消去法遷移到函數空間。取實連續函數空間 $C([-1,1],\mathbb{R})$，定義

$$\langle f, g\rangle = \int_{-1}^{1} f(t)g(t)\,dt.$$

連續性保證積分存在，且非零連續函數在某個小區間上絕對值有正下界，所以 $\int f^2 > 0$，這才給出內積的正定性。若容許任意逐點函數，「只在一點非零」的函數積分平方仍為零；不能直接在該集合上宣稱這是內積。使用 L^2 時則須把幾乎處處相等的函數視為同一個向量。

取不完全正交的基底 $p_1 = 1$、$p_2 = 1 + t$。Gram matrix 的每個 entry 是 $G_{ij} = \langle p_i, p_j\rangle$：

$$G = \begin{bmatrix} \int 1 & \int (1+t) \\ \int (1+t) & \int (1+t)^2 \end{bmatrix} = \begin{bmatrix} 2 & 2 \\ 2 & 8/3 \end{bmatrix}.$$

若 $f = 1 + 3t$，right-hand side 是

$$b = \begin{bmatrix} \langle p_1, f\rangle \\ \langle p_2, f\rangle \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

跨章遷移：積分內積的 Gram 系統 （續）

要求 $f = c_1 p_1 + c_2 p_2$，不必猜係數；正交投影與完整展開都化為 Gram system

$$G \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} = b.$$

第一個方程給 $c_1 + c_2 = 1$，第二個方程在代入後給 $c_2 = 3$，所以 $c_1 = -2$。回代：

$$-2(1) + 3(1 + t) = 1 + 3t.$$

$\det G = 2(8/3) - 2 \cdot 2 = 4/3 > 0$，所以係數唯一。更一般地，$c^T G c = \| \sum_i c_i p_i \|^2$；函數獨立時它正定。若函數相依，$G$ 可能奇異，但由內積產生的右端 $b_i = \langle p_i, f \rangle$ 仍在 $\mathrm{Col}(G)$：對每個 $z \in \ker G$，$\sum_i z_i p_i = 0$，故 $z^T b = 0$。因此投影存在；係數可不唯一，而所表示的投影函數唯一。f 不在 span 時只會有非零正交殘差，不會使這個 Gram 系統無解。

在 $C([0, 2\pi], \mathbb{R})$ 使用相同的積分內積。若改用正交 basis $\{1, \cos x, \sin x\}$，投影係數可用除法直接得到。以 $f(x) = 1 + x$、$x \in [0, 2\pi]$ 為例：

$$a_0 = \frac{\int_0^{2\pi} (1 + x)\, dx}{2\pi} = 1 + \pi,$$

跨章遷移：積分內積的 Gram 系統 （續）

$$a_1 = \frac{\langle \cos x, f \rangle}{\langle \cos x, \cos x \rangle} = 0, \qquad b_1 = \frac{\langle \sin x, f \rangle}{\langle \sin x, \sin x \rangle} = -2.$$

所以有限 Fourier 投影是 $f_1(x) = 1 + \pi - 2 \sin x$。殘差 $e = x - \pi + 2 \sin x$ 與 1、$\cos x$、$\sin x$ 都正交；這正是有限維 least-squares projection，而不是把任意係數代入就算完成。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

跨章遷移：帶參數 Toeplitz 矩陣

對 $a \in \mathbb{R}$、正整數 n，再考慮

$$T_n(a) = \begin{bmatrix} a & 1 & & 0 \\ 1 & a & \ddots & \\ & \ddots & \ddots & 1 \\ 0 & & 1 & a \end{bmatrix}.$$

令 $D_n = \det T_n(a)$，並定義 $D_0 = 1$。沿第一 row 展開：

$$D_n = aD_{n-1} - D_{n-2}.$$

第二項來自第一 row 的 1 與下一 row 的 1，其結構正好是 D_{n-2}；此遞迴適用於 $n \geq 2$，配合 $D_0 = 1, D_1 = a$ 即可手算。前三項是

$$D_1 = a, \qquad D_2 = a^2 - 1, \qquad D_3 = a(a^2-1) - a = a(a^2-2).$$

也可用 eigenvectors。對 $k = 1, \dots, n$，令 $\theta_k = k\pi/(n+1)$、$(v_k)_j = \sin(j\theta_k)$，並把 boundary 值設為 $v_0 = v_{n+1} = 0$。三角恆等式給

$$(v_k)_{j-1} + (v_k)_{j+1} = 2\cos(\theta_k)(v_k)_j,$$

跨章遷移：帶參數 Toeplitz 矩陣 （續）

故 $T_n(a)v_k = (a + 2\cos\theta_k)v_k$。這些 vectors 非零且對應不同 eigenvalues，構成獨立集合；因此

$$D_n(a) = \prod_{k=1}^{n} (a + 2\cos(k\pi/(n+1))).$$

$n = 3$ 時 eigenvalues 是 $a + \sqrt{2}, a, a - \sqrt{2}$，乘積回 $a(a^2-2)$。在 $\mathbb{R}$ 上 $T_3(a)$ 可逆若且唯若 $a \notin \{-\sqrt{2}, 0, \sqrt{2}\}$。這類題必須把 parameter 代入 determinant 的一般結構，不能只選一個數值算完就宣稱參數結論。

章末檢查

必須能：

- 以 rows 與 columns 解釋同一個 $Ax = b$。
- 從 pivot 與 free variable 判定無解、唯一解與無限多解。
- 寫出 row operation 對應的 elementary matrix。
- 說明 left multiplication 與 right multiplication 的差異。
- 判斷 inverse 的成立條件。
- 從 multipliers 重建 L，必要時寫 $PA = LU$。
- 分清 $x^T y$ 與 xy^T。

章末練習的重點是保留每一步的前提，尤其是「在哪個體上」與「是否需要 row exchange」。

下一章將以 column space、nullspace 與 basis 解釋本章的 pivot 結構。

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

從計算走到結構

對 $A \in \mathbb{R}^{m\times n}$，第 2 章的消去法回答某個 b 是否有解。本章改問整組可能結果：

$$\{Ax : x \in \mathbb{R}^n\} \subseteq \mathbb{R}^m.$$

另一組要研究的向量是使結果為零的輸入：

$$\{x \in \mathbb{R}^n : Ax = 0\} \subseteq \mathbb{R}^n.$$

前者是 column space（欄空間）$C(A)$，後者是 nullspace（零空間）$N(A)$。兩者都是 vector subspace（向量子空間），因此加法與純量乘法不會把它們帶出集合。

先固定體。若未特別說明，本章使用實數體 $\mathbb{R}$；換成 $\mathbb{C}$ 或有限體時，span 與 rank 的規則仍成立，但幾何與「非零純量」的細節須重新交代。

向量空間與子空間的判準

集合 V 在體 $\mathbb{F}$ 上稱為 vector space，需對純量乘法與向量加法封閉，向量加法構成交換群，並有 $1v = v$、$(ab)v = a(bv)$、$a(u+v) = au + av$、$(a+b)v = av + bv$。對子集 $S \subseteq V$，不必逐條重驗全部公理。只要

$$0 \in S, \qquad u, v \in S \Rightarrow u + v \in S, \qquad u \in S,\ c \in \mathbb{F} \Rightarrow cu \in S,$$

則 S 是 V 的 subspace。第三條有時與第二條合寫成 $cu + dv \in S$。

$\{0\}$ 與 V 本身永遠是子空間。$\varnothing$ 不是子空間。只包含非零純量的集合不是子空間，因為它不包含 additive identity 0。

檢查「非空且對線性組合封閉」最省步驟。也要注意：集合若根本不是 $\mathbb{R}^n$ 的線性子集，例如單位圓，即使包含一些好向量也不是子空間。

span、交集與 column space

對 $v_1, \dots, v_k$，span 定義為所有有限線性組合：

$$\operatorname{span}\{v_1, \dots, v_k\} = \left\{ \sum_{j=1}^{k} c_j v_j : c_j \in \mathbb{F} \right\}.$$

張成空間是包含這些向量的最小子空間。兩個子空間的交集 $S \cap T$ 仍是子空間；聯集 $S \cup T$ 通常不是。例如 $\mathbb{R}^2$ 的 x-axis 與 y-axis 各自是子空間，但分別取一個軸上的非零向量後，其和不在兩軸的聯集中。

設 $A = [a_1 \ \cdots \ a_n] \in \mathbb{R}^{m \times n}$。column view 給

$$C(A) = \{Ax : x \in \mathbb{R}^n\} = \operatorname{span}\{a_1, \dots, a_n\}.$$

因此 $Ax = b$ 有解，若且唯若 $b \in C(A)$。這個判準同時適用方陣與矩形矩陣。

span 會自動允許所有有限相加，所以「多取一個已經位於 span 內的向量」不會擴大該 span。

同一個方程組的三種結構

考慮

$$A = \begin{bmatrix} 1 & 2 & 0 & 1 \\ 2 & 4 & 1 & 3 \\ 1 & 2 & 1 & 2 \end{bmatrix}.$$

消去後得到

$$R = \begin{bmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

第 1、3 欄含主元，秩 $r = 2$。欄空間由兩個原始 pivot columns 生成：

$$C(A) = \operatorname{span}\left\{ \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \right\}.$$

列空間由 R 的兩個非零列張成，位於 $\mathbb{R}^4$；欄空間位於 $\mathbb{R}^3$。兩者維度同為 2，卻不是同一個集合。RREF 保留列空間與零空間，通常改變欄空間；因此欄空間基底必取原始 A 的 pivot columns。

函數與矩陣也能是向量

「向量」不限定為有限個數的一欄。次數至多 2 的實係數多項式構成

$$P_2 = \{a + bx + cx^2 : a, b, c \in \mathbb{R}\}.$$

它與 $\mathbb{R}^3$ 透過坐標 (a, b, c) 同構，因為多項式加法和純量乘法逐係數作用。2×2 實矩陣也構成向量空間；其「向量」是矩陣，而其純量仍是實數。

區分兩種乘法：

- 矩陣空間中的 vector 可以相加，也可以乘純量。
- 矩陣與矩陣相乘是額外的 bilinear product（雙線性乘法），不是讓矩陣空間成為向量空間的必要條件。

若沒有指定定義域，函數集合不一定成空間。例如所有函數 $f : \mathbb{R} \to \mathbb{R}$ 在逐點加法與純量乘法下形成向量空間。連續函數與可微函數也各自形成子空間，因為兩個連續或可微函數的和仍連續或可微，乘上常數後也保有相同性質。

從有限維結構開始，能避免「座標向量才有加法」的誤解；後續線性轉換章會大量使用多項式與函數空間。

nullspace 為何是子空間

定義

$$N(A) = \{x \in \mathbb{R}^n : Ax = 0\}.$$

若 $x, y \in N(A)$、$c \in \mathbb{R}$，則

$$A(x + y) = Ax + Ay = 0, \qquad A(cx) = cAx = 0.$$

又有 $A0 = 0$，所以 $N(A)$ 是 $\mathbb{R}^n$ 的子空間。注意 $N(A)$ 的 vectors 與 x 同維度，位於 domain $\mathbb{R}^n$，不在 output $\mathbb{R}^m$。

對本章矩陣，$N(A) \subseteq \mathbb{R}^4$。column space $C(A) \subseteq \mathbb{R}^3$。這兩個子空間的 ambient spaces（所在空間）不同，不能直接比較向量是否相等。

$N(A)$ 是「所有零解的集合」，不是「某一次求解留下的 zero row」。即使消去後出現 zero rows，nullspace 的大小由 free columns 控制。

從 RREF 建構特殊解

前頁矩陣的 RREF 方程式為

$$x_1 + 2x_2 + x_4 = 0, \qquad x_3 + x_4 = 0.$$

pivot variables 是 x_1, x_3，free variables 是 x_2, x_4。依序把一個 free variable 設為 1、其餘設為 0：

$$x_2 = 1, x_4 = 0 \Rightarrow s_1 = (-2, 1, 0, 0)^T,$$
$$x_2 = 0, x_4 = 1 \Rightarrow s_2 = (-1, 0, -1, 1)^T.$$

任何零解都可唯一寫成

$$x = x_2 s_1 + x_4 s_2.$$

所以 $N(A) = \text{span}\{s_1, s_2\}$，且 $\dim N(A) = 2$。$n - r = 4 - 2 = 2$ 在這裡得到第一個具體檢核。

特殊解不是任意挑兩組零解。依 free-variable 標準化後，special solutions 對 free coordinates 形成 identity，因此必獨立，且所有零解都能由它們表示。

消去不改變 nullspace

若 E 是可逆的 elementary matrix，則

$$Ax = 0 \iff EAx = 0.$$

右推左時使用 E^{-1}：

$$EAx = 0 \Rightarrow Ax = E^{-1}0 = 0.$$

有限次可逆 row operations 合併成可逆矩陣 M，因此

$$N(A) = N(MA).$$

對任何 A，可用交換列、將一列乘非零純量，以及加上另一列的純量倍得到 RREF R，故

$$N(A) = N(R).$$

這只需以可逆列運算化簡。若不允許把 pivot row 除以 pivot 的 scale operation，仍可得到 echelon form；special solutions 的公式會多一個非零係數比例。

column space 一般不保留，因為 left multiplication 會把 output vectors 一起改掉。row space 與 nullspace 保留，原因是 row operations 不改 rows 所生成的集合，也逐式保留齊次解。

rank 與自由度的第一個公式

設 $A \in \mathbb{F}^{m \times n}$ 的 RREF 有 r 個 pivot columns。每個 pivot column 提供一個 basic variable（基本變數），其餘 $n - r$ 個 columns 是 free columns。每個 free variable 可選參數，得到一個特殊解。

特殊解的數目是 $n - r$，它們構成 nullspace 的一組 basis。於是

$$\dim N(A) = n - r.$$

若 $n > r$，必有非零零解；若 $r = n$，nullspace 只有零向量。rank 不可能超過 $\min(m, n)$，因為 pivot 最多一列一個、一欄一個。

例如一個 2×4 矩陣最多 rank 2，必有至少兩個自由參數。即便每列都非零，也不能由列數直接推論 nullspace 只有 $\{0\}$。

不要用「非零 rows 數」目測初學時期的原矩陣；先化到 row echelon form，數實際非零 pivots。

非齊次系統的完整解

設 x_p 是 $Ax = b$ 的一個 particular solution（特解），$x_n \in N(A)$。那麼

$$A(x_p + x_n) = b + 0 = b.$$

反過來，若 x 與 x_p 都是解，則

$$A(x - x_p) = Ax - Ax_p = b - b = 0.$$

因此完整解集是 affine set（仿射集合）

$$\{x_p + x_n : x_n \in N(A)\} = x_p + N(A).$$

它不是子空間，除非 $0 \in x_p + N(A)$，也就是 $b = 0$。若 nullspace 非零，解集是一條線、平面或其高維平移。

兩個特解之差一定落在 nullspace；但兩個特解相加通常不再解原方程，因為右端會成為 $2b$。

本章例子的 complete solution

取 $b = (2, 5, 3)^T$。augmented matrix 經 row operations 得

$$\left[\begin{array}{cccc|c} 1 & 2 & 0 & 1 & 2 \\ 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 & 0 \end{array}\right].$$

沒有 $0 = c$ 的矛盾列，所以系統一致。令所有 free variables 為 0，可得

$$x_p = (2, 0, 1, 0)^T.$$

代入前節的 nullspace basis，

$$x = \begin{bmatrix} 2 \\ 0 \\ 1 \\ 0 \end{bmatrix} + s \begin{bmatrix} -2 \\ 1 \\ 0 \\ 0 \end{bmatrix} + t \begin{bmatrix} -1 \\ 0 \\ -1 \\ 1 \end{bmatrix}, \quad s, t \in \mathbb{R}.$$

檢查：$Ax_p = (2, 5, 3)^T$，兩個特殊解經 A 作用後都是 0。

特解不唯一。例如令 $x_2 = 3$ 會得到另一個特解；只要仍落在同一個 affine set，都是合法選擇。

四種 rank 情形

設 A 是 $m \times n$、rank r，則最多有以下四種結構：

條件	結構	$Ax = b$ 的結論
$r = m = n$	方陣且滿秩	每個 b 恰有一解
$r = m < n$	列滿秩	每個 b 至少一解，有 $n - m$ 個自由度
$r = n < m$	欄滿秩	最多一解；部分 b 無解
$r < m,\ r < n$	列與欄皆未滿秩	某些 b 無解；可解時有 $n - r$ 個自由度

第二列中「每個 b」成立是因為 $C(A) = \mathbb{R}^m$。第三列中 nullspace 是 $\{0\}$，所以可解時解唯一，但 $C(A)$ 只是 $\mathbb{R}^m$ 的真子空間。

列滿秩與欄滿秩是相對於列數和欄數的；若 $m \neq n$，兩者不可能同時成立。

線性相依與獨立

向量 $v_1, \dots, v_k$ 稱為線性獨立（linearly independent），若

$$c_1 v_1 + \cdots + c_k v_k = 0$$

只在所有 $c_i = 0$ 時成立。若存在至少一個非零係數使上式成立，就稱為 dependent。

等價地，以這些向量作欄的 V，其零空間只有零向量。對 $V \in \mathbb{F}^{m \times k}$：

$$V \text{ 的 columns 獨立} \iff N(V) = \{0\}.$$

$\mathbb{F}^m$ 中最多有 m 個獨立向量；若 $k > m$，必線性相依。零向量只要出現在集合中，整組就線性相依，因為取該零向量的係數為 1、其餘為 0，得到非平凡線性關係。

沒有零向量並不足以保證線性獨立；任意兩個同向非零向量也線性相依。獨立性要求零向量只能有一種表示，即所有係數均為零。

span、basis 與 dimension

vectors $v_1, \dots, v_k$ 構成 subspace S 的 basis，若它們

1. 都在 S 中；
2. span S；
3. 線性獨立。

生成性保證空間中每個 vector 至少有一種係數表示；獨立性保證表示唯一。若

$$w = \sum c_i v_i = \sum d_i v_i,$$

則 $\sum (c_i - d_i) v_i = 0$，獨立性迫使 $c_i = d_i$。

一個空間的所有 bases 含相同數目，這個不變量稱為 dimension。零空間 $\dim\{0\} = 0$，其空集選為 basis。$\mathbb{R}^n$ 的標準 basis 有 n 個 vectors。

basis 不是唯一，所有 basis 的大小才是不變的。多放一個向量常破壞獨立；少放一個常失去生成。

dimension 的證明與函數例子

設 S 有含 d 個向量的基底。座標映射

$$\varphi_S(c_1,\dots,c_d)=\sum_{i=1}^{d} c_i u_i$$

是 $\mathbb{F}^d \to S$ 的雙射：生成性給存在性，獨立性給唯一性。若 S 中某組 d 個向量 $w_1,\dots,w_d$ 線性獨立，將它們用原基底表示：

$$w_j=\sum_{i=1}^{d} b_{ij}u_i.$$

令 $B=(b_{ij})$。由基底表示的唯一性，

$$\sum_{j=1}^{d} c_j w_j = 0 \quad\Longleftrightarrow\quad Bc=0.$$

dimension 的證明與函數例子 （續）

因此 w_j 線性獨立等價於 $N(B)=\{0\}$。方陣 B 沒有自由變數，故可逆；對任一 $v\in S$，其原座標 y 滿足 $Bc=y$，所以 v 能由 w_j 表示。這證明線性獨立的 d 個向量也生成 S。若 k 個向量線性獨立而 d 個向量生成，係數矩陣是 $d\times k$；零空間只有零要求 $k\le d$。兩組基底互相比較即得大小相等。

函數集合

$$\{1,\cos(2x),\sin^2 x\}$$

是 dependent，因為

$$\sin^2 x=\frac{1}{2}-\frac{1}{2}\cos(2x).$$

但 $\{1,\cos x,\sin x\}$ 在某些函數空間中可獨立。要證明函數獨立，通常需使用任意的 x、係數比較、微分或其他結構。

同一組公式在不同定義域或不同函數空間中，span 與獨立條件要重新檢查；不要把「函數形式看起來不同」直接當作獨立證明。

四個基本子空間

對 $A \in \mathbb{R}^{m \times n}$，定義

子空間	定義	所在空間
column space	$C(A) = \{Ax : x \in \mathbb{R}^n\}$	$\mathbb{R}^m$
row space	$C(A^T) = \{A^T y : y \in \mathbb{R}^m\}$	$\mathbb{R}^n$
nullspace	$N(A) = \{x : Ax = 0\}$	$\mathbb{R}^n$
left nullspace	$N(A^T) = \{y : A^T y = 0\}$	$\mathbb{R}^m$

「左零空間」（left nullspace）的名稱來自把 $A^T y = 0$ 轉置成 $y^T A = 0$。

RREF 的非零列生成列空間；原始 A 的 pivot 欄生成欄空間。零空間與左零空間由各自的特殊解生成。

列運算保留列空間與 $N(A)$，但會改寫欄空間的表示法。四個子空間要一起追蹤；相同 rank 不代表位於相同 ambient space。

rank-nullity 與左零空間

對 $A \in \mathbb{R}^{m \times n}$，設 RREF 為 R、pivot 數為 r。有限次可逆列運算可合併成可逆矩陣 M，使 $R = MA$。先證 column rank：$C(R) = MC(A)$ 是線性同構的像，維度不變。RREF 的每個 pivot 欄都是某個標準座標向量，pivot 欄線性獨立；其他欄可由 pivot 欄表示，所以 $\dim C(R) = r$，再得 $\dim C(A) = r$。

列運算也保留 row space：$R = MA$ 的每個 row 都是 A 的 rows 的線性組合，故 $C(R^T) \subseteq C(A^T)$；再由 $A = M^{-1}R$ 得反向包含，兩個 row spaces 相等。各列的特定相依係數不必保持不變。另一方面 $Ax = 0 \iff MAx = 0$，所以 $N(A) = N(R)$。RREF 的 r 個非零列線性獨立並生成原矩陣的 row space，故 $\dim C(A^T) = r$。這證明 column rank 與 row rank 相等。

對 R 讀方程時有 r 個 pivot variables 與 $n - r$ 個 free variables。每個 free variable 設為 1、其餘設為 0，所得特殊解的 free coordinates 形成 I_{n-r}，所以線性獨立；任一解又由自由參數唯一決定，故它們生成 $N(A)$。基本維度關係為

$$\dim C(A) = \dim C(A^T) = r,$$
$$\dim N(A) = n - r, \qquad \dim N(A^T) = m - r.$$

rank-nullity 與左零空間 （續）

對 A^T 套用同一證明，右側所在空間是 $\mathbb{R}^m$，故左零度為 $m-r$。每一組維度相加：

$$r+(n-r)=n, \qquad r+(m-r)=m.$$

對本章 3×4 範例，$r=2$，所以 $\dim C(A)=2$、$\dim N(A)=2$、$\dim N(A^T)=1$。令 $y=(a,b,c)^T$，直接解 $A^Ty=0$：

$$a+2b+c=0, \quad 2a+4b+2c=0, \quad b+c=0, \quad a+3b+2c=0.$$

第二式是第一式的兩倍，第四式是第一式加第三式，故只需第一與第三式。先得 $c=-b$，再得 $a=-b$；所有解為 $b(-1,1,-1)^T$，所以 left-null basis 是

$$\{(-1,1,-1)^T\}.$$

這些是維度關係，不是把四個子空間全部放進同一個直接和。每個公式只配同一 ambient space 的一對子空間。

Fundamental Theorem 的內容

四基本子空間的維度定理常寫成

$$\mathbb{R}^n=C(A^T)\oplus N(A), \qquad \mathbb{R}^m=C(A)\oplus N(A^T).$$

$\oplus$ 表示 direct sum。第二章的 row space 與 nullspace 位於 domain，dimensions r 與 $n-r$；column space 與 left nullspace 位於 codomain，dimensions r 與 $m-r$。下一章會證明兩個配對互相 orthogonal，並推得它們是 orthogonal complements（正交補空間）。

例如 $x\in\mathbb{R}^n$ 可拆成 row-space component 加 nullspace component。這裡的重要前提是 inner product 與補空間的定義已固定；對一般抽象向量空間，需要內積或 dual pairing 才能談正交。

只有維度相加等於 n 尚不足以推出 direct sum，還須排除非零交集。若 $z\in C(A^T)\cap N(A)$，可寫 $z=A^Ty$，且 $Az=0$，因此

$$z^Tz=(A^Ty)^Tz=y^TAz=0.$$

在實數空間中 $z^Tz=\sum_i z_i^2=0$ 強迫 $z=0$。兩個子空間的基底合起來因而線性獨立：若兩側組合相加為零，它們各自是交集中的同一向量，故兩者皆零。合併基底共有 $r+(n-r)=n$ 個獨立向量，必生成 $\mathbb{R}^n$，得到第一個 direct sum。對 A^T 重複此證明即得第二個。下一章再完整證明正交補空間與投影公式。

Fundamental Theorem 的內容 （續）

這一步使用實數內積的正定性。複數版須用 A^* 和 z^*z；不能把普通轉置版本直接搬到任意體。例如在 $\mathbb{F}_2$ 上 $A = [1\ 1]$，$C(A^T) = N(A) = \text{span}\{(1,1)^T\}$，雖然兩維度和為2，交集仍非零。rank-nullity 在該體上依然成立，失效的是這個普通轉置的 direct-sum 結論。

本章實矩陣的限制映射 $A : C(A^T) \to C(A)$ 是同構。其核是前述零交集，所以單射；任取 $b = Ax \in C(A)$，把 x 分解為 $x_{\text{row}} + x_{\text{null}}$，便有 $b = Ax_{\text{row}}$，所以滿射。

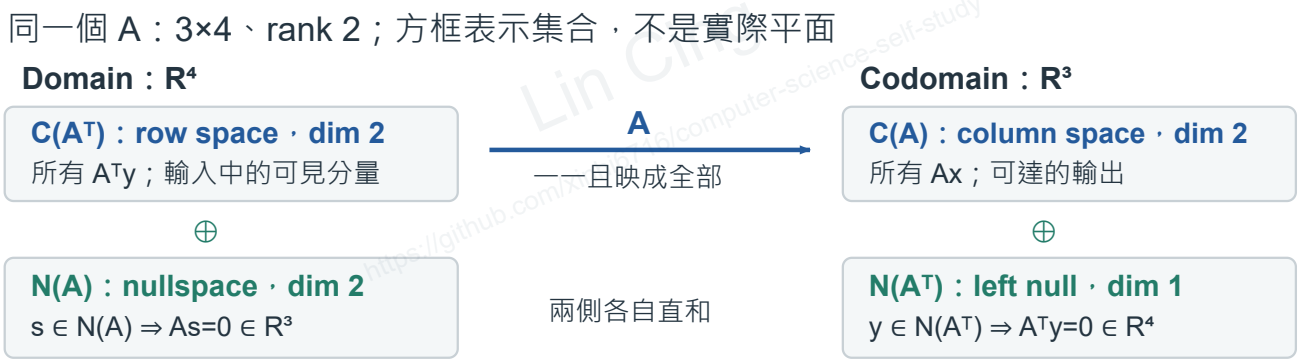

Direct sum 的數值重建

沿用本章的 A，四個基本子空間的一組基底是

$$u_1 = (1,2,0,1)^T, \quad u_2 = (0,0,1,1)^T,$$
$$s_1 = (-2,1,0,0)^T, \quad s_2 = (-1,0,-1,1)^T.$$

前兩個張成 $C(A^T)$，後兩個張成 $N(A)$。若 $\alpha u_1 + \beta u_2 + \gamma s_1 + \delta s_2 = 0$，逐座標得到

$$\gamma = -2\alpha, \quad \delta = \beta, \quad 5\alpha - \beta = 0, \quad \alpha + 2\beta = 0.$$

因此 $\alpha = \beta = \gamma = \delta = 0$。四個向量在 $\mathbb{R}^4$ 中線性獨立，構成 $\mathbb{R}^4$ 的基底。

取

$$x = (-2,3,0,3)^T = u_1 + u_2 + s_1 + s_2,$$

則

$$x_{\text{row}} = (1,2,1,2)^T, \qquad x_{\text{null}} = (-3,1,-1,1)^T.$$

兩式相加回到 x。因為四個基底向量線性獨立，這個分解唯一。此處不用內積也可建立 direct sum；下一章再證明兩分量正交。

Direct sum 的數值重建 （續）

數值上 $Ax_{\text{row}} = (7, 17, 10)^T = 7(1, 2, 1)^T + 3(0, 1, 1)^T \in C(A)$，而 $Ax_{\text{null}} = 0$。又 $x_{\text{row}}^T x_{\text{null}} = -3 + 2 - 1 + 2 = 0$，所以兩分量在實內積下確實正交，$\|x\|^2 = 22 = 10 + 12$。

四維向量的兩個分量：在其張成的二維平面中作圖

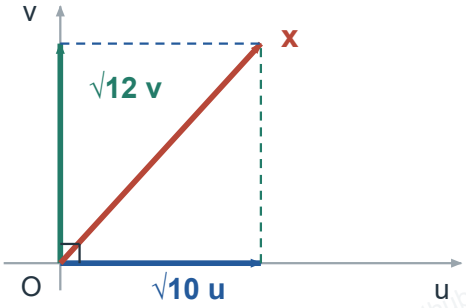

x_row = (1,2,1,2)ᵀ

x_null = (−3,1,−1,1)ᵀ

x = (−2,3,0,3)ᵀ = x_row + x_null

u=x_row/√10 · v=x_null/√12

uᵀv=0；‖x‖²=10+12=22

Ax=Ax_row=(7,17,10)ᵀ；Ax_null=0

此圖的兩軸不是原始四個座標軸，而是 $u = x_{\text{row}}/\sqrt{10}$、$v = x_{\text{null}}/\sqrt{12}$。它只畫出這兩向量張成的二維平面，不把整個 $\mathbb{R}^4$ 誤當平面。

章末檢查與常見錯誤

離開本章前，應能用本章例子的 A 回答：

- $C(A)$ 的 basis 為什麼取原始 pivot columns，而不是 RREF 的全部 columns？
- $N(A)$ 為什麼可由 free variables 設為 0 或 1 得到 basis？
- $Ax = b$ 為何是 affine set $x_p + N(A)$，而不是一個 subspace？
- rank 相同為何不代表 column space 與 row space 是同一集合？
- full column rank 與 full row rank 分別排除哪一種解的不確定性？

常見錯誤包括：把 $N(A)$ 寫在 $\mathbb{R}^m$、把欄空間的維度當成 n、用 RREF 的欄生成原始的 $C(A)$，以及在秩不足系統中只檢查 $A^TAx = A^Tb$ 就宣稱原系統可解。

章末練習刻意要求算子空間所在空間與 basis，而不只要求 rank 數字；這是後續正交投影與最小平方的必要基礎。

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

為何四個子空間要配對

對 $A \in \mathbb{R}^{m \times n}$，有兩組位於同一 ambient space 的子空間：

$$C(A^T), N(A) \subseteq \mathbb{R}^n,$$
$$C(A), N(A^T) \subseteq \mathbb{R}^m.$$

每組 dimensions 相加後分別是 n 與 m：

$$\dim C(A^T) + \dim N(A) = r + (n - r) = n,$$
$$\dim C(A) + \dim N(A^T) = r + (m - r) = m.$$

本章證明每組不是只有維度互補，向量之間也互相垂直。這使任何 input x 都能唯一拆成 row-space 與 nullspace 成分，任何 output b 也能拆成 column-space 與 left-nullspace 成分。

先分清向量住在哪個空間。若 $b \in \mathbb{R}^m$，它不可能直接和 $x \in \mathbb{R}^n$ 比較內積，除非 $m = n$ 且已在同一座標空間。

row space 與 nullspace 為何正交

若 $x \in N(A)$，則 $Ax = 0$。展開成 rows 的內積：

$$\begin{bmatrix} r_1^T \\ \vdots \\ r_m^T \end{bmatrix} x = \begin{bmatrix} r_1^T x \\ \vdots \\ r_m^T x \end{bmatrix} = 0.$$

所以 x 與 A 的每一個 row 都正交。row space 的任一 vector 是 rows 的線性組合；內積對線性組合線性，因此它也與 x 正交：

$$x^T(c_1 r_1 + \cdots + c_m r_m) = 0.$$

反之，若 x 與所有 rows 正交，則 $Ax = 0$，故 $x \in N(A)$。這先證明 $N(A) = C(A^T)^\perp$。row space 與 nullspace 正交且維度和為 n，故互為正交補空間，因而

$$C(A^T) = N(A)^\perp.$$

同樣把 A 換成 A^T，可得 $C(A) = N(A^T)^\perp$。

row space 與 nullspace 為何正交 （續）

這裡證明了 orthogonal complements，強於只有 dimensions 相加。∪^⊥ 是所有與 U 中每個 vector 都有零內積的 vectors。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

orthogonal 與 complement 的分別

若兩個 subspaces U, W 的每一對 $u \in U, w \in W$ 都滿足 $u^T w = 0$，寫成 $U \perp W$。若 $z \in U \cap W$，則 $z^T z = 0$，必有 $z = 0$，所以 $U \cap W = \{0\}$。反之，「交集只有 0」本身不足以推出正交。

在有限維 inner-product space 中，若

$$U \cap W = \{0\}, \qquad \dim U + \dim W = \dim V,$$

則 $V = U \oplus W$ 是 direct sum，但 U, W 仍可能斜交。若再證明 $U \perp W$，才是 orthogonal direct sum。

例：在 $\mathbb{R}^2$ 中，$U = \mathrm{span}\{(1,0)^T\}$ 與 $W = \mathrm{span}\{(1,1)^T\}$ 交集只有 0，dimensions 相加為 2；但它們不垂直。將 W 改成 $\mathrm{span}\{(0,1)^T\}$ 才成為 orthogonal complement。

orthogonal complement 由 inner product 決定。有限維歐氏空間討論清楚後，延伸到複數空間需用 conjugate transpose。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

分解的維度與例子

因為 $C(A^T) \oplus N(A) = \mathbb{R}^n$，每個 $x \in \mathbb{R}^n$ 可唯一寫成

$$x = x_{\text{row}} + x_{\text{null}}, \qquad x_{\text{row}}^T x_{\text{null}} = 0.$$

取

$$A = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \end{bmatrix}.$$

rank 為 2。兩 rows 本身獨立，構成 row space 的 basis；nullspace 由

$$(-2, 1, -1)^T$$

生成。直接檢查

$$(1, 2, 0)(-2, 1, -1)^T = 0, \qquad (0, 1, 1)(-2, 1, -1)^T = 0.$$

所以 $\mathbb{R}^3 = C(A^T) \oplus N(A)$。另一方面 A 是 full row rank，$N(A^T) = \{0\}$，因此 $C(A) = \mathbb{R}^2$ 也是整個 output space。

一個子空間為整個空間時，它的 orthogonal complement 自然是零空間。這與「不能分解」不同；零成分的分解仍唯一。

投影到一條直線

給非零 $a \in \mathbb{R}^n$，要從 b 去掉垂直於 line $L = \text{span}\{a\}$ 的部分。投影

$$p = \lambda a$$

須使 residual $e = b - p$ 垂直於整條 line：

$$a^T e = a^T (b - \lambda a) = 0.$$

因 $a^T a > 0$，解得

$$\lambda = \frac{a^T b}{a^T a}, \qquad p = a \frac{a^T b}{a^T a}.$$

投影矩陣是

$$P = \frac{a a^T}{a^T a}, \qquad p = Pb.$$

例如 $a = (1, 1, 1)^T$、$b = (2, 1, 4)^T$，則 $a^T b = 7$、$a^T a = 3$，

$$p = \frac{7}{3}(1, 1, 1)^T, \quad e = b - p = \frac{1}{3}(-1, -4, 5)^T.$$

投影到一條直線 （續）

直接代回可得

$$p + e = (2, 1, 4)^T = b, \qquad a^T e = \frac{1(-1) + 1(-4) + 1(5)}{3} = 0.$$

因此 $p^T e = 0$，且

$$\|e\|_2 = \frac{\sqrt{(-1)^2 + (-4)^2 + 5^2}}{3} = \frac{\sqrt{42}}{3}.$$

同一組數值滿足 normal equation

$$a^T a\,\lambda = a^T b, \qquad 3 \cdot \frac{7}{3} = 7.$$

圖採用平面 $\mathrm{span}\{a, e\}$ 中的正交單位基底 $f_1 = a/\sqrt{3}$、$f_2 = e/(\sqrt{42}/3)$。因此圖上的兩維座標是

$$[a] = (\sqrt{3}, 0), \quad [p] = (7/\sqrt{3}, 0), \quad [e] = (0, \sqrt{42}/3), \quad [b] = (7/\sqrt{3}, \sqrt{42}/3).$$

這是該平面到 $\mathbb{R}^2$ 的等距座標表示，兩軸使用相同尺度；直角是原內積的真正正交關係。黑色短向量 a 與藍色較長向量 $p = (7/3)a$ 的端點不同；綠色殘差畫成從 p 到 b 的平移向量。

投影到一條直線 （續）

精確投影：在 span{a,e} 的正交座標中畫 b=p+e

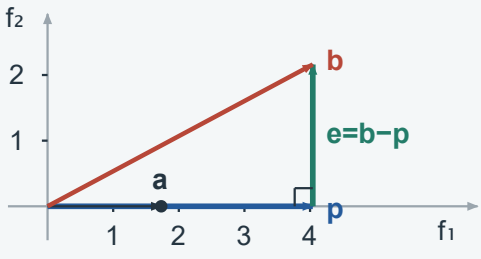

正交單位基底；兩軸同尺度

f₁=a/√3 · f₂=e/(√42/3)

a=(√3,0) · p=(7/√3,0)

e=(0,√42/3) · b=p+e

原座標 a=(1,1,1) · b=(2,1,4)

在奇異值分解中，線性映射的最大成長方向也由正交性控制；本章先建立最小 residual 的投影觀點。

subspace projection 的公式

設 $A \in \mathbb{R}^{m \times n}$ 的 columns 線性獨立，令

$$S = C(A).$$

若 b 要投影到 S，唯一最小 residual 條件是 $e = b - Ax$ 與 S 的每個 basis vector 正交：

$$A^T(b - Ax) = 0.$$

得到 normal equations

$$A^T Ax = A^T b.$$

在 full column rank 時 $A^T A$ 可逆，所以

$$p = A(A^T A)^{-1} A^T b.$$

投影矩陣為

$$P = A(A^T A)^{-1} A^T.$$

注意 P 不是 A^{-1}；A 通常不是方陣。也不能把 $(A^T A)^{-1}$ 改寫成 $A^{-1}(A^T)^{-1}$，除非 A 本身是可逆方陣。

直線公式是 $n = 1$ 的特例。若 columns 獨立，$A^T A$ 的正定性和可逆性可由 $z^T A^T Az = \|Az\|^2$ 證明。

為何 $A^T A$ 的可逆性需要獨立

對任意 $z \in \mathbb{R}^n$，

$$z^T A^T Az = (Az)^T (Az) = \|Az\|^2 \geq 0.$$

若 A 的 columns 獨立，$Az = 0$ 只在 $z = 0$ 時成立，因此對 $z \neq 0$，$\|Az\|^2 > 0$。這表示 $A^T A$ 是 positive definite（正定），也必可逆。

反過來，若 columns dependent，存在 $z \neq 0$ 使 $Az = 0$，故

$$A^T Az = A^T 0 = 0,$$

所以 $A^T A$ 不可逆。此推論使用實數體與 Euclidean inner product；在複數空間要把轉置改為 conjugate transpose。

對 rank-deficient A，projection onto $C(A)$ 仍唯一，但 axes 或 columns 有冗餘；最小平方參數有 non-unique minimizers。作業中會看到同一個 p 可由多個 x 求得。

`A has independent columns` 是公式中 $A^T A$ inverse 的充分且必要條件。`A` full row rank 也不能使 $A^T A$ 在 $m < n$ 時可逆。

投影矩陣的三個代數性質

對 full column rank 的 A，令

$$P = A(A^TA)^{-1}A^T.$$

則 P 是 symmetric（對稱）且 idempotent（冪等）：

$$P^T = A((A^TA)^{-1})^TA^T = A(A^TA)^{-1}A^T = P,$$
$$P^2 = A(A^TA)^{-1}(A^TA)(A^TA)^{-1}A^T = P.$$

$P^2 = P$ 表示第二次投影不會再改變向量；$P^T = P$ 表示是 orthogonal projection，而不是任意 oblique projection。其 complementary projector

$$I - P$$

投影到 $C(A)^\perp = N(A^T)$，且 $P(I-P) = 0$。

$P^2 = P$ 本身只證明 idempotent，不自動證明 orthogonal。symmetric 條件不可省略。

最近點與誤差界線

若 $p = Pb$、$e = (I-P)b$，則

$$b = p + e, \qquad p^Te = 0.$$

對 $p + e$ 應用 Pythagorean theorem：

$$\|b\|^2 = \|p\|^2 + \|e\|^2.$$

對任意 $q \in C(A)$，$p - q \in C(A)$，而 $e \perp C(A)$。由平方展開，

$$\|b - q\|^2 = \|e + (p-q)\|^2 = \|e\|^2 + \|p-q\|^2.$$

右側在 $q = p$ 時最小。這是投影「最近點」的完整幾何理由，不需要先假設微積分。

Pythagoras 在實內積空間成立，因為交叉項 $e^T(p-q) = 0$。換成一般內積或複數空間時，需使用 conjugate transpose 的實值 norm。

least squares 的定義

當 $Ax = b$ 無解，仍可選擇

$$x^\star \in \arg\min_x \|b - Ax\|_2^2.$$

令 $p = Ax^\star$。這是 b 在 $C(A)$ 上的投影。欄滿秩時，p 與 $x^\star$ 都唯一；秩不足時，投影 p 仍唯一，但極小參數 $x^\star$ 可能有無窮多個。

最小化平方範數與最小化範數得到同一極小點，因為平方函數在 $[0, \infty)$ 上嚴格遞增。使用平方可避免平方根，並使殘差的導數成為線性式。

常見誤解是要求殘差向量 $b - Ax$ 本身最短。真正最小化的是殘差範數；投影點 p 一般不等於 b。

least squares（最小平方）名稱來自最小化各座標誤差平方和。它不是沒有誤差，而是 residual 與可達 subspace 正交。

normal equations 的推導

定義

$$E(x) = (b - Ax)^T (b - Ax).$$

取任意位移 h。直接展開平方得

$$\begin{aligned} E(x + h) - E(x) = & -2h^T A^T (b - Ax) \\ & + h^T A^T A h. \end{aligned}$$

因此梯度為

$$\nabla_x E = -2A^T (b - Ax).$$

若 $x^\star$ 是無限制極小點，沿任意 h 的一階變化都必須為零，所以

$$A^T (b - Ax) = 0 \iff A^T A x = A^T b.$$

在欄滿秩時 $h^T A^T A h = \|Ah\|^2 > 0$ 對所有 $h \neq 0$ 成立，故二次項嚴格為正，$x^\star$ 是唯一全域極小點。normal equations 的左端與右端維度都是 $n \times 1$。

normal equations 的推導 （續）

若欄線性相依，normal equations 可有多個解。若 x, z 都滿足 normal equations，令 $q = x - z$。兩式相減得 $A^T Aq = 0$，左乘 q^T 得

$$0 = q^T A^T Aq = \|Aq\|^2.$$

所以 $Ax = Az$；參數可重複，但投影點仍相同。

A^T 並不是投影矩陣。$A^T e = 0$ 是同時檢查殘差與每個欄向量正交，等價於 $e \in N(A^T)$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

單變數線性迴歸例子

以 $y = c + mt$ 擬合

$$(t, y) = (0, 1), (1, 2), (2, 2).$$

設計矩陣是

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad x = \begin{bmatrix} c \\ m \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

計算

$$A^T A = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}, \qquad A^T b = \begin{bmatrix} 5 \\ 6 \end{bmatrix}.$$

解得

$$m = \frac{1}{2}, \qquad c = \frac{7}{6}.$$

預測為

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

單變數線性迴歸例子 (續)

$$p = \left(\frac{7}{6}, \frac{5}{3}, \frac{13}{6}\right)^T.$$

殘差

$$e = b - p = \left(-\frac{1}{6}, \frac{1}{3}, -\frac{1}{6}\right)^T.$$

可見 e 的總和為 0，且 $A^T e = 0$。前者只表示設計矩陣含 constant column；後者同時捕捉 constant 與 t 兩個方向。

把原始殘差直接相加得到零，並不等於最小平方；必須檢查殘差與每一欄的內積，包括表示時間趨勢的 t 欄。

rank-deficient least squares

取

$$A = \begin{bmatrix}1\\2\end{bmatrix}\begin{bmatrix}1 & 1\end{bmatrix} = \begin{bmatrix}1 & 1\\2 & 2\end{bmatrix}, \quad b = \begin{bmatrix}1\\3\end{bmatrix}.$$

A 的兩欄相同，rank 為 1。投影到 column line：

$$p = \frac{a^T b}{a^T a} a = \frac{7}{5}\begin{bmatrix}1\\2\end{bmatrix} = \begin{bmatrix}7/5\\14/5\end{bmatrix}.$$

normal equations 是

$$\begin{bmatrix}5 & 5\\5 & 5\end{bmatrix} x = \begin{bmatrix}7\\7\end{bmatrix},$$

因此只有

$$x_1 + x_2 = \frac{7}{5}.$$

所有滿足此式的 x 都給相同 $Ax = p$，也都是 minimizers。residual

rank-deficient least squares （續）

$$e = \left(-\frac{2}{5}, \frac{1}{5}\right)^T$$

與 column $(1,2)^T$ 正交。此例清楚分開「projection 唯一」與「參數唯一」。

遇到 rank deficiency 時，要改用 pseudoinverse 的 minimum-norm solution 或額外正則化，不能擅自對 A^TA 求逆。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

同一個矩陣的四個子空間

取 $A = \begin{bmatrix} 1 & 1 & 0 \\ 2 & 2 & 0 \end{bmatrix}$，秩為 1。輸入在 $\mathbb{R}^3$，輸出在 $\mathbb{R}^2$；兩邊的正交分解不能混在同一個空間裡。

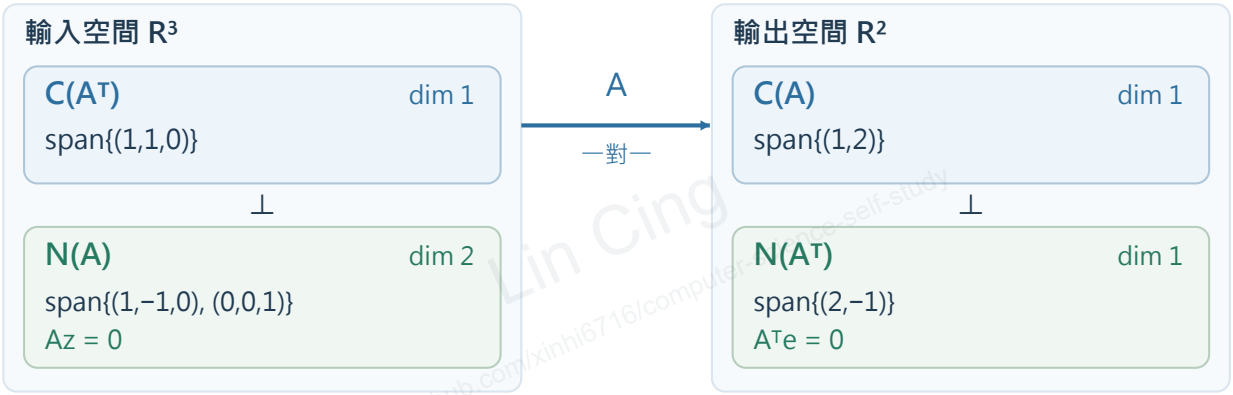

矩形記子空間與維度；圖上的位置不是向量座標。

A 在 row space 上一對一地映到 column space，並把整個 nullspace 送到零；left nullspace 則描述輸出中與 column space 正交的方向。

唯一的投影，不等於唯一的參數

沿用同一個 A，取 $b=(3,1)^T$。因 $C(A)=\text{span}\{c\}$、$c=(1,2)^T$，

$$p=\frac{c^Tb}{c^Tc}c=c=(1,2)^T,\qquad e=b-p=(2,-1)^T.$$

$c^Te=0$。任取參數 x，$p-Ax$ 都在 column space，因此

$$\|b-Ax\|^2=\|e\|^2+\|p-Ax\|^2=5+\|p-Ax\|^2.$$

最小殘差範數為 $\sqrt{5}$，且等號恰在 $Ax=p$ 時成立。這個條件只要求 $x_1+x_2=1$，不限制 x_3，所以全部最小平方解是

$$x=\begin{pmatrix}1/2+t\\1/2-t\\s\end{pmatrix},\qquad t,s\in\mathbb{R}.$$

參數有無窮多組，最小範數解仍只有一組

$\hat{x}=(1/2,1/2,0)^T$ 在 row space，而 $z=(t,-t,s)^T$ 在 nullspace。兩者正交，所以

$$x=\hat{x}+z,\qquad \|x\|^2=\tfrac{1}{2}+2t^2+s^2.$$

輸出空間：正交單位座標

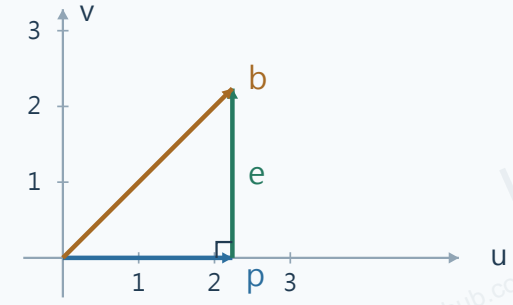

[p]=(√5,0), [e]=(0,√5), [b]=(√5,√5)

全部最小平方解

x = (1/2+t, 1/2−t, s)

Ax = p = (1,2)

||x||² = 1/2 + 2t² + s²

t=s=0: x̂ = (1/2,1/2,0)

投影 p 唯一；參數 x 不一定唯一。

其中最小範數參數 x̂ 仍唯一。

圖的正交單位基底為 $u=(1,2)^T/\sqrt{5}$、$v=(2,-1)^T/\sqrt{5}$。最小範數恰在 $t=s=0$ 取到；第 7 章的 pseudoinverse 會選出這個 $\hat{x}$。

orthonormal basis 與 Q

一組向量 $q_1, \dots, q_k$ 若

$$q_i^T q_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j, \end{cases}$$

稱為標準正交（orthonormal）。以它們作欄的 $Q \in \mathbb{R}^{m \times k}$ 滿足

$$Q^T Q = I_k.$$

若 Q 是方陣，則各欄構成 $\mathbb{R}^n$ 的標準正交基底。$Q^T Q = I_n$ 的 n 個欄線性獨立，因此 Q 可逆，且 $Q^{-1} = Q^T$。這時才稱 Q 為正交矩陣。

若 Q 是長方矩陣，$Q^T Q = I_k$ 只能推出 full column rank，不能推出 $QQ^T = I_m$。兩個 dimensions 不同，不能當成同一個 identity。

正交矩陣的各欄其實是標準正交。名稱沿用已久；不要將長方矩陣誤稱可逆方陣。

Gram-Schmidt 的幾何步驟

給獨立 $a_1, \dots, a_n$。先正規化

$$q_1 = \frac{a_1}{\|a_1\|}.$$

對 a_j，先減去既有方向上的投影：

$$z_j = a_j - \sum_{i=1}^{j-1} (q_i^T a_j) q_i,$$

再正規化

$$q_j = \frac{z_j}{\|z_j\|}.$$

線性獨立保證 $z_j \neq 0$：若 $z_j = 0$，則 a_j 已在前 $j-1$ 個向量的 span 中，與整組線性獨立矛盾。對 $i < j$，將 $q_i^T z_j$ 展開可得

$$q_i^T z_j = q_i^T a_j - \sum_{\ell=1}^{j-1} (q_\ell^T a_j)(q_i^T q_\ell) = q_i^T a_j - q_i^T a_j = 0.$$

Gram-Schmidt 的幾何步驟 （續）

歸納假設前 $j-1$ 個 q 已標準正交且張成 $\operatorname{span}\{a_1,\dots,a_{j-1}\}$。因 a_j 等於 z_j 加上前 $j-1$ 個方向的線性組合，而 $q_j = z_j/\|z_j\|$，加入 q_j 後張成的空間不變。故每一步都有

$$\operatorname{span}\{q_1,\dots,q_j\} = \operatorname{span}\{a_1,\dots,a_j\}.$$

以 $a_1=(1,1,0)^T, a_2=(1,0,1)^T$：

$$q_1 = \frac{1}{\sqrt{2}}(1,1,0)^T,$$

$$z_2 = a_2 - (q_1^T a_2)q_1 = \left(\frac{1}{2},-\frac{1}{2},1\right)^T,$$

$$q_2 = \frac{1}{\sqrt{6}}(1,-1,2)^T.$$

有限精度下，極小的 $\|z_j\|$ 表示接近線性相依；直接除以此數會放大誤差。數值章會說明更穩定的替代做法。

$A=QR$ 與 least squares 的簡化

把 Gram-Schmidt 的表示式整理成

$$A = QR,$$

其中 Q 的各欄標準正交，R 是上三角矩陣。由 Gram-Schmidt 係數 $R_{ij}=q_i^T a_j$（$i<j$）且 $R_{jj}=\|z_j\|$，兩邊逐欄乘開即可得到 $A=QR$。前頁例中

$$R = \begin{bmatrix} \sqrt{2} & 1/\sqrt{2} \\ 0 & \sqrt{3/2} \end{bmatrix}.$$

在 full column rank 時，least-squares equation 變成

$$R^T Q^T Q R x = R^T Q^T b \Longrightarrow Rx = Q^T b.$$

R 可逆，兩側再解上三角系統。這比形成 A^TA 再解更穩定；對長方 A，Q 是 $m\times n$。

不要把 Q^T 隨便消去；只有 R^T 可逆或方陣 full rank 時，才可由左側出現的 matrix 相乘消去。若 A 是 full column rank，R 正是可逆。

$A = QR$ 與 least squares 的簡化 （續）

classical Gram-Schmidt 便於書寫證明；有限精度實作常用 modified Gram-Schmidt 或 Householder QR。兩者得到的數學 QR 結構相同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

QR least-squares 完整例

沿用前頁

$$Q = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{6} \\ 1/\sqrt{2} & -1/\sqrt{6} \\ 0 & 2/\sqrt{6} \end{bmatrix}, \quad R = \begin{bmatrix} \sqrt{2} & 1/\sqrt{2} \\ 0 & \sqrt{3/2} \end{bmatrix}.$$

取 $b = (1, 2, 0)^T$。先算

$$Q^T b = \left(\frac{3}{\sqrt{2}}, -\frac{1}{\sqrt{6}} \right)^T.$$

解 $Rx = Q^T b$。第二式給

$$\sqrt{\frac{3}{2}}\, x_2 = -\frac{1}{\sqrt{6}} \quad \Longrightarrow \quad x_2 = -\frac{1}{3}.$$

第一式為

$$\sqrt{2}\, x_1 + \frac{1}{\sqrt{2}} \left(-\frac{1}{3} \right) = \frac{3}{\sqrt{2}},$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

QR least-squares 完整例 （續）

故 $x_1 = 5/3$。投影為

$$p = Ax = \left(\frac{4}{3}, \frac{5}{3}, -\frac{1}{3}\right)^T,$$

residual 為

$$e = b - p = \frac{1}{3}(-1, 1, 1)^T.$$

直接檢查

$$a_1^T e = 0, \qquad a_2^T e = 0,$$

所以 $A^T e = 0$，最小平方誤差為 $\|e\|^2 = 1/3$。這個例保留非零 residual，能實際檢查 normal equations 的正交條件，而不只是算出精確解。

章末檢查

必須能區分：

- $U \perp W$、$U \cap W = \{0\}$ 與 $V = U \oplus W$。
- line projection、subspace projection 與 projection matrix。
- full column rank 時的唯一 least-squares solution，與 rank-deficient 時可能不唯一的 minimizer。
- $P^2 = P = P^T$ 與 complement $I - P$。
- $Q^T Q = I$（可能長方）與 $QQ^T = I$（只對 full square orthogonal matrix）。
- Gram-Schmidt 對應的 $A = QR$，以及為何它不改變 columns 的 span。

章末請以 $A^T e = 0$ 檢查 projection 或 least-squares 結果。若只看到 residual 很小就宣稱答案正確，可能還沒證明它在正確的 orthogonal direction。

下一章用 determinant 判斷方陣可逆性與體積。本章 $A^T A$ 的可逆性要求 columns 獨立；薄型 Q 一般不是方陣，不能假定具有雙邊逆。有限精度的可靠性還需另外分析條件數與演算法穩定性。

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

行列式回答什麼問題

對 square matrix $A \in \mathbb{R}^{n \times n}$，determinant $\det A$ 是可定向的體積倍率，也是 invertibility indicator：

$$A \text{ invertible} \iff \det A \neq 0.$$

2×2

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

的 signed area 是 $ad - bc$。Columns 獨立時，方向決定正負；columns 共線時 area 為零。

n 維時，$\det A$ 是有向體積。絕對值給 physical volume ratio，符號記錄 orientation 是否翻轉。這個數同時出現在 inverse、pivot、cofactor 與 coordinate volume formula。

Zero determinant 是 exact singularity criterion，不能直接當有限精度的 conditioning measure。第 11 章會處理 scale 與 numerical rank。

三個基本公理

把 determinant 視為 column-vector function

$$D(a_1, \dots, a_n).$$

它滿足：

1. Normalization：

$$D(e_1, \dots, e_n) = 1.$$

2. Alternation：交換兩 columns 變號：

$$D(\dots, a_j, \dots, a_k, \dots) = -D(\dots, a_k, \dots, a_j, \dots).$$

3. Multilinearity：對每個 column separately linear：

$$D(\dots, \alpha a_j + \beta b_j, \dots) = \alpha D(\dots, a_j, \dots) + \beta D(\dots, b_j, \dots).$$

三個基本公理 （續）

這三條公理唯一決定 determinant。將每個欄向量展成標準基底並逐欄使用多線性，重複基底的項因交錯性為零；剩下恰是標準基底的排列，值由排列符號決定，得到「Permutation formula」的排列公式。該公式也直接滿足三公理，故存在且唯一。本章固定在 $\mathbb{R}$ 或 $\mathbb{C}$；特徵 2 的體需以重複欄值為零定義交錯性，不能只靠交換變號。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

由公理推出的 row effects

若兩個 columns 相同，交換前後是同一 matrix：

$$D = -D,$$

所以 $D = 0$。在 characteristic $\neq 2$ 的 field 中得到 repeated-column determinant 為零。

把一個 column 加上另一個 column 的倍數：

$$D(\dots, a_j + ca_k, \dots) = D(\dots, a_j, \dots) + cD(\dots, a_k, \dots).$$

第二項有兩個相同的 columns，故為 zero。因此 column addition 不改變 determinant。Row addition 的版本可由 $\det A = \det A^T$ 得到。

這也表示線性相依的欄向量必使 $\det A = 0$。任一欄可寫成其他欄的線性組合，逐次使用多線性後，每一項都含兩個相同的欄。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Scaling、exchange 與 triangular matrices

對一個 column 乘 λ：

$$\det(\dots, \lambda a_j, \dots) = \lambda \det(\dots, a_j, \dots).$$

所以

$$\det(cA) = c^n \det A.$$

這與 n-dimensional volume 每條 edge 乘 c 得 c^n 倍一致。

Row exchange 乘 -1。Upper triangular matrix：

$$\det U = u_{11} u_{22} \cdots u_{nn}.$$

任一 zero pivot 均使 matrix singular，因而 determinant 為 zero。這是 elimination 與 determinant 的第一個連接。

實作列縮放與列交換時必須記錄運算，否則分解後的行列式正負號會錯。

$\det A = \det A^T$

Permutation formula：

$$\det A = \sum_{\sigma \in S_n} \operatorname{sgn}(\sigma) \prod_{i=1}^{n} a_{i,\sigma(i)}.$$

Transpose 後，令 $\tau = \sigma^{-1}$：

$$a_{\sigma(i),i}$$

成為 $a_{j,\tau(j)}$，且

$$\operatorname{sgn}(\tau) = \operatorname{sgn}(\sigma).$$

所以

$$\det A^T = \det A.$$

列運算與欄運算遵守相同的行列式規則。以下非負性要求 $A \in \mathbb{R}^{n \times n}$：

$$\det(A^T A) = (\det A)^2 \geq 0.$$

$\det A = \det A^T$ （續）

對任意實矩陣 $A \in \mathbb{R}^{m\times n}$，$A^TA$ 是半正定；它正定若且唯若 $\operatorname{rank} A = n$。方陣可逆時兩個條件同時成立。對複數矩陣，轉置不取共軛，平方也不再有非負次序。例如 $A = [i]$ 給 $A^TA = [-1]$，且對 $z = 1$ 有 $z^TA^TAz = -1$。

複數情形改用共軛轉置 $A^* = \overline{A}^T$：

$$\det(A^*A) = \overline{\det A}\det A = |\det A|^2 \geq 0, \qquad z^*A^*Az = \|Az\|_2^2 \geq 0.$$

此時 A^*A 是 Hermitian 半正定矩陣，且恰在 A 欄滿秩時正定。長方形 $A \in \mathbb{C}^{m\times n}$ 仍有後一能量恆等式，但沒有 $\det A$ 可用，不能套用方陣的行列式乘積。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

$\det A = \det A^T$ （續）

實矩陣 Gram：A^TA 對稱半正定

$A \in \mathbb{R}^{m\times n}$，$z^TA^TAz = \|Az\|_2^2 \geq 0$	**$A = [[1,1],[1,2]]$**
A^TA 恆為對稱半正定	$\det A = 1$
$\operatorname{rank}(A) = n \Leftrightarrow A^TA$ 正定	$\det(A^TA) = 1^2 = 1$

實方陣均滿足 $\det(A^TA) = \det(A)^2$；不需可逆。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

$\det A = \det A^T$ (續)

複數 Gram：轉置不共軛；A* = 共軛轉置

A=[i]

$A^TA=[-1]$，$\det=-1$

$z=1$：$z^TA^TAz=-1$

轉置 Gram 可能不是 PSD

A*=[$-i$]，A*A=[1]

$\det(A^*A)=|\det A|^2=1$

$z^*A^*Az=\|Az\|_2^2\geq 0$

A*A 是 Hermitian 半正定

Lin Cing https://github.com/xinhi6716/computer-science-self-study

Product rule 與 inverse

固定 B，函數

$$F(A) = \det(AB)$$

對 A 的 rows multilinear、alternating，且

$$F(I) = \det B.$$

由 determinant 的公理唯一性，

$$\det(AB) = \det A \det B.$$

若 A invertible：

$$1 = \det(A^{-1}A) = \det(A^{-1}) \det A,$$

所以

$$\det(A^{-1}) = 1/\det A.$$

若其中一個 matrix singular，乘積 rank 不足，兩側 determinant 都為 zero。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

Product rule 與 inverse （續）

常見錯誤：$\det(A+B)$ 一般不等於 $\det A + \det B$。Determinant 是 multilinear in rows 或 columns，不是 matrix-space additive。

具體反例取 $A = I_2$、$B = \operatorname{diag}(2,3)$。則 $\det A = 1$、$\det B = 6$，但

$$\det(A+B) = \det \operatorname{diag}(3,4) = 12 \neq 1 + 6.$$

多線性只允許固定其他行或列，對單一行或列拆成線性組合；它不允許把整個矩陣拆成兩矩陣之和。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Elimination 與 pivots

若不需 row exchange 就能消成 upper triangular U：

$$\det A = \det U = u_{11}u_{22}\cdots u_{nn}.$$

做過 q 次 row exchanges 時：

$$\det(PA) = (-1)^q \det A,$$

所以先算 PA 的 pivot product，再乘 $(-1)^q$。

例：

$$A = \begin{bmatrix} 0 & 2 \\ 3 & 4 \end{bmatrix}.$$

Swap rows：

$$PA = \begin{bmatrix} 3 & 4 \\ 0 & 2 \end{bmatrix}, \qquad \det(PA) = 6.$$

故 $\det A = -6$，與 $ad - bc = 0 \cdot 4 - 2 \cdot 3 = -6$ 相符。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Elimination 與 pivots （續）

判斷 invertibility 時 rank 通常比 determinant 更直接；需要 signed volume 時才一定要保留 exchange sign。

完整推論如下。若方陣 A 的欄向量線性相依，至少一欄是其他欄的線性組合；逐次使用欄多線性時會出現重複欄的行列式為零，所以 $\det A = 0$。反過來，若 $\det A \neq 0$，欄向量不可能線性相依，因而構成 $\mathbb{R}^n$ 的基底，映射可逆。若 A 可逆，則

$$\det A \det(A^{-1}) = \det(AA^{-1}) = 1.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Permutation formula

Permutation σ 的逆序數 $N(\sigma)$ 是使 $i < j$ 但 $\sigma(i) > \sigma(j)$ 的 pairs 數：

$$\operatorname{sgn}(\sigma) = (-1)^{N(\sigma)}.$$

Big formula：

$$\det A = \sum_{\sigma \in S_n} \operatorname{sgn}(\sigma) a_{1,\sigma(1)} \cdots a_{n,\sigma(n)}.$$

每一項從每條 row 與每條 column 各取一個 entry。3×3 展開：

$$\begin{aligned} &a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} \\ &- a_{13}a_{22}a_{31} - a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33}. \end{aligned}$$

前三個 permutations even，後三個 odd。只有 $n = 3$ 時的 Sarrus pattern 特別簡單；$n > 3$ 不能照抄。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Cofactor expansion

刪除第 i row 與第 j column 得 minor matrix M_{ij}。Cofactor：

$$C_{ij} = (-1)^{i+j} \det M_{ij}.$$

沿第 i row：

$$\det A = \sum_{j=1}^{n} a_{ij} C_{ij}.$$

沿任一 column 亦成立。

例：

$$A = \begin{bmatrix} 2 & 1 & 0 \\ -1 & 3 & 1 \\ 0 & 2 & 4 \end{bmatrix}.$$

第一 row：

$$\det A = 2(12 - 2) - 1(-4) + 0 = 24.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Cofactor expansion （續）

第二 row：

$$(-1)(-4) + 3(8) + 1(-4) = 24.$$

不同 row 得到相同結果，是 cofactor formula 的結構性質。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Cofactor formula 的推導

把第 i row 展開為

$$r_i = \sum_{j=1}^{n} a_{ij} e_j^T.$$

由 row multilinearity：

$$\det A = \sum_{j=1}^{n} a_{ij} D(A_{i \leftarrow e_j}).$$

在 $A_{i \leftarrow e_j}$ 中，第 i row 只有第 j column 是 1。將第 i 列以 $i-1$ 次相鄰交換移到最上，再將第 j 欄以 $j-1$ 次相鄰交換移到最左。第 $(1,1)$ 項為 1，第一列其餘為零；列相加消去第一欄其餘元素後，右下區塊就是 M_{ij}。

因此

$$D(A_{i \leftarrow e_j}) = (-1)^{i+j} \det M_{ij} = C_{ij}.$$

逐項加總就是 cofactor expansion。Checkerboard signs 來自 corridor exchanges 的 parity。

Pivot formula 與 tridiagonal recurrence

若 pivoted elimination 得到 $PA = LU$：

$$\det(PA) = \prod_i u_{ii},$$

$$\det A = (-1)^q \prod_i u_{ii}.$$

Leading principal minor 為零不必然 singular；可能只需 row exchange。

三對角：

$$T_n = \begin{bmatrix} 2 & -1 & 0 & \cdots \\ -1 & 2 & -1 & \ddots \\ 0 & -1 & 2 & \ddots \\ \vdots & \ddots & \ddots & \ddots \end{bmatrix}.$$

沿第一 row：

$$D_n = 2D_{n-1} - D_{n-2}.$$

Pivot formula 與 tridiagonal recurrence （續）

初值 $D_0 = 1, D_1 = 2$，解得

$$D_n = n + 1.$$

這也證明 T_n positive definite，因所有 leading minors positive。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Adjugate matrix

Cofactor matrix $C = [C_{ij}]$，adjugate：

$$\operatorname{adj} A = C^T.$$

Cofactor identities：

$$\sum_{j=1}^{n} a_{ij} C_{kj} = \begin{cases} \det A, & i = k, \\ 0, & i \neq k. \end{cases}$$

當 $i \neq k$，右側是把第 k row 換成第 i row 的 determinant；two rows identical，故 zero。

所以

$$A(\operatorname{adj} A) = (\det A) I.$$

$\det A \neq 0$ 時：

$$A^{-1} = \frac{1}{\det A} \operatorname{adj} A.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Adjugate matrix （續）

2×2：

$$A^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}.$$

大矩陣需計算 n^2 個 minors，因此 adjugate 主要用於公式與小矩陣。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Cramer's rule

若 A invertible，$Ax = b$。以 x 取代 I 的第 j column，由該欄線性與重複欄為零得：

$$x_j = \det(e_1, \dots, e_{j-1}, x, e_{j+1}, \dots, e_n).$$

由 $x = A^{-1}b$ 與 determinant product rule：

$$(\det A) x_j = \det(a_1, \dots, a_{j-1}, b, a_{j+1}, \dots, a_n).$$

所以

$$x_j = \frac{\det A_j}{\det A},$$

其中 A_j 是把 A 的第 j column 換成 b。

例：

$$\begin{bmatrix} 3 & 4 \\ 5 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

$\det A = -2$、$\det A_1 = -4$、$\det A_2 = 2$，得

$$x_1 = 2, \qquad x_2 = -1.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Cramer's rule 的邊界

Cramer's rule 顯示 x_j 對 b 是 linear 的，因 $\det A_j(b)$ 對 b 的各 component linear。

但它不適合大量 numerical solve：n 個 determinants 的成本遠高於一次 pivoted LU。$\det A$ 很小時，也不能只因 denominator 非零就宣稱結果可靠。

$\det A = 0$ 時 Cramer's rule invalid。Singular system 仍需第 2 章的 rank 與 augmented matrix 判斷：

- no solution；
- infinitely many solutions。

Determinant zero 只表示 square coefficient matrix singular，不表示 right-hand side 不相容。

Determinant 作為有向面積

令

$$u = (a, c)^T, \qquad v = (b, d)^T,$$

$$P = [u\ v] = \begin{bmatrix} a & b \\ c & d \end{bmatrix}.$$

Parallelogram area：

$$|\det P| = |ad - bc|.$$

不取 absolute value 時，sign 由 $u \to v$ 的 orientation 決定。

若

$$u = (2, 1)^T, \qquad v = (1, 3)^T,$$

則

$$\det P = 6 - 1 = 5,$$

signed area 與 area 都是 5。

Determinant 作為有向面積 (續)

對 linear map $x \mapsto Px$：

$$\text{area}(P(S)) = |\det P| \, \text{area}(S).$$

$\det P = 0$ 時 image 最多一維，面積為 zero。

下圖把單位正方形的兩條邊 $(1,0)^T, (0,1)^T$ 送到 $u = (2,1)^T$、$v = (1,3)^T$。兩個平行四邊形面積依序為

$$|\det I| = 1, \qquad |\det P| = |2 \cdot 3 - 1 \cdot 1| = 5.$$

有向面積：det([[2,1],[1,3]])=5

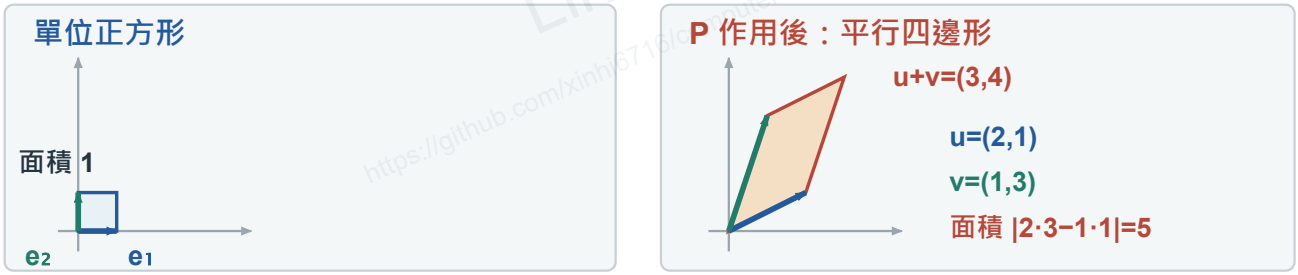

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

n 維體積與 orientation

若 $a_1, \ldots, a_n$ 是 box edges，以它們為 columns：

$$\text{volume} = |\det A|.$$

在 standard axes 的 unit scale 下成立；不同 units 必須先換算。

交換兩條 edges 只翻轉 orientation，signed volume 變號，physical volume 不變。把一條 edge 加上另一條的倍數是 shear，兩者都不改變。

Gaussian elimination 的 row scalings 與 exchanges 可逐步追蹤 volume；Pivot product 提供另一條計算路徑。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Cross product 與 determinant

$\mathbb{R}^3$ 中

$$w = u \times v$$

同時垂直於 u, v，長度是 parallelogram area：

$$w_1 = u_2v_3 - u_3v_2,$$
$$w_2 = u_3v_1 - u_1v_3,$$
$$w_3 = u_1v_2 - u_2v_1.$$

因此

$$w^T u = 0, \qquad w^T v = 0.$$

Cross product 的 antisymmetry：

$$v \times u = -u \times v$$

正是 determinant row exchange 的 effect。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Cross product 與 determinant （續）

正式行列式寫法需要把 i, j, k 看成 cofactor directions，不能把 symbolic basis vectors 和 scalar determinant 混為同一 field。最安全的定義是先寫三條 component formulas。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

完整 numerical example

$$A = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \\ 2 & 1 & 1 \end{bmatrix}.$$

第一 row cofactor expansion：

$$\det A = 1(1-3) - 2(0-6) = -2 + 12 = 10.$$

第二 column 加第一 column 的兩倍得到 B，determinant 仍為 10，因 column addition 是 shear。

Three columns 的 parallelepiped signed volume 是 10。交換 columns 會變號；columns dependent 時體積為 zero。

Adjugate 與 Cramer path 可交叉檢查 inverse，但 numerical implementation 不應對 large matrix 計算 n^2 minors。

章末檢查

讀者應能：

- 由 alternation 與 multilinearity 推 repeated-column determinant；
- 證明 $\det(AB) = \det A \det B$；
- 由 permutation formula 推 cofactor expansion；
- 區分 pivot product 與 leading principal minors；
- 在 inverse 與 Cramer 中保留 $\det A \neq 0$；
- 區分 signed area 與 physical area；
- 對小矩陣用 cofactor，大型 dense solver 用 stable elimination。

$\det A = 0$ 是 exact singularity 的 algebraic sign；它不表示 entries 很小，也不提供完整的 numerical stability conclusion。

下一章用 determinant 建 characteristic polynomial，開始研究 eigenvectors 與 dynamics。

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Eigenproblem

對 $A \in \mathbb{C}^{n\times n}$，若存在 scalar λ 與 nonzero vector x 使

$$Ax = \lambda x,$$

則 λ 是 eigenvalue，x 是 eigenvector。

改寫：

$$(A - \lambda I)x = 0.$$

因 $x \neq 0$，matrix $A - \lambda I$ 必須 singular，於是

$$p_A(\lambda) = \det(\lambda I - A) = 0.$$

幾何上，A 把 line $\operatorname{span}\{x\}$ 映到自身，並沿該方向乘上 λ。負 eigenvalue 將方向翻轉，但 line 不變。

Characteristic polynomial、trace 與 determinant

對 $n \times n$ matrix：

$$p_A(\lambda) = \lambda^n - a_1\lambda^{n-1} + \cdots + (-1)^n \det A.$$

重複 eigenvalues 計次後：

$$\sum_i \lambda_i = \operatorname{tr} A, \qquad \prod_i \lambda_i = \det A.$$

例：

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Trace 是 6，det 是 8：

$$p_A(\lambda) = \lambda^2 - 6\lambda + 8 = (\lambda - 4)(\lambda - 2).$$

Eigenvalues $4, 2$。Trace 與 det 可交叉檢查，但不足以單獨確定全部 spectrum。

Eigenvectors 在運算中的演化

若 $Ax = \lambda x$：

$$A^k x = \lambda^k x,$$
$$A^{-1}x = \lambda^{-1}x \quad (A \text{ invertible}),$$
$$q(A)x = q(\lambda)x.$$

Shift：

$$(A + cI)x = (\lambda + c)x.$$

Eigenspace：

$$E_\lambda = N(A - \lambda I).$$

它是 subspace，dimension 是 geometric multiplicity。Triangular matrix 的 diagonal entries 就是 eigenvalues，但仍要計算 multiplicity。

Algebraic 與 geometric multiplicity

Characteristic polynomial 中 root multiplicity 是 algebraic multiplicity a_λ。

$$g_\lambda = \dim N(A - \lambda I)$$

是 geometric multiplicity。取該 eigenspace 的一組基底並擴充全空間基底，矩陣成為左上 λI_{g_λ} 的區塊上三角形；特徵多項式含 $(t - \lambda)^{g_\lambda}$，故恆有

$$1 \le g_\lambda \le a_\lambda.$$

若某個 λ 滿足 $g_\lambda < a_\lambda$，matrix defective。

例：

$$A = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}.$$

Algebraic multiplicity 是 2。解

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} x = 0$$

只得到 $x_2 = 0$，故

Algebraic 與 geometric multiplicity （續）

$$E_2 = \text{span}\{(1,0)^T\}, \qquad g_2 = 1.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

二維完整例子

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

$\lambda = 4$：

$$\begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} x = 0,$$

取 $x_1 = (1,1)^T$。

$\lambda = 2$：

$$\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} x = 0,$$

取 $x_2 = (1,-1)^T$。

兩 vectors orthogonal，因 A symmetric。若

$$u_0 = c_1 x_1 + c_2 x_2,$$

則

二維完整例子 (續)

$$u_k = A^k u_0 = c_1 4^k x_1 + c_2 2^k x_2.$$

若 $c_1 \neq 0$，長期 direction 由 $\lambda = 4$ mode 支配。

取 $c_1 = c_2 = 1$，則

$$u_0 = x_1 + x_2 = (2,0)^T, \quad u_1 = (6,2)^T, \quad u_2 = (20,12)^T.$$

圖中同時畫出 $c_1 4^k x_1$、$c_2 2^k x_2$ 與兩項相加的 u_k。若改取 $c_1 = 0, c_2 = 1$，得到

$$u_0 = (1,-1)^T, \quad u_1 = (2,-2)^T, \quad u_2 = (4,-4)^T,$$

軌跡始終落在 x_2 的特徵方向，沒有可由較大 eigenvalue 主導的分量。使用單位特徵向量時可令 c_1, c_2 取實數係數；圖採用本頁的非單位 x_1, x_2，係數就是其線性組合係數。

二維完整例子 (續)

特徵模態：真向量分量、和向量與軌跡

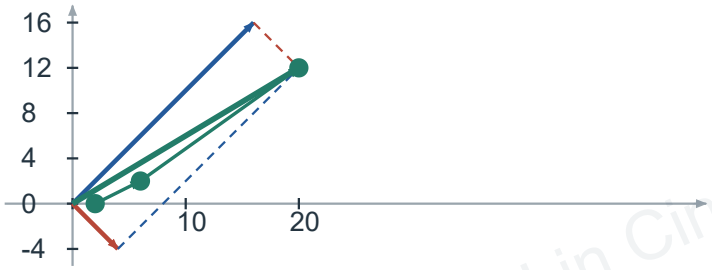

A=[[3,1],[1,3]]

λ₁=4，x₁=(1,1)

λ₂=2，x₂=(1,-1)

藍：4²x₁=(16,16)

紅：2²x₂=(4,-4)

綠：u₂=(20,12)

u₀,u₁,u₂=(2,0),(6,2),(20,12)

二維完整例子 （續）

$c_1=0$ 的例外軌跡：始終沿 $x_2=(1,-1)$

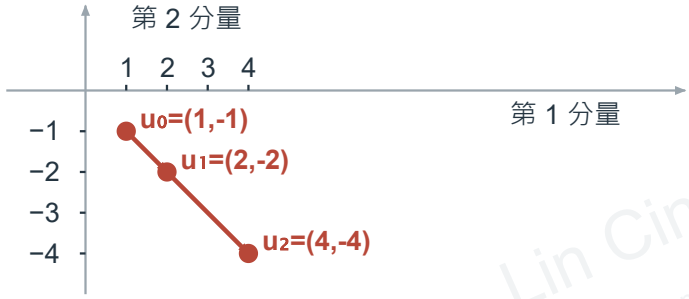

$c_1=0$，$c_2=1$

$u_k=2^k(1,-1)$

所有 u_k 都沿同一個特徵方向。

比例固定，並無 4^k 主導項。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Complex eigenvalues 與 rotation

$$R_\theta = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}.$$

$$p(\lambda) = \lambda^2 - 2\cos\theta\,\lambda + 1,$$

$$\lambda = e^{\pm i\theta}.$$

除非 $\theta \equiv 0 \pmod{\pi}$，rotation 沒有 nontrivial real eigenvector。

Real matrix 的 complex eigenvalues 成 conjugate pairs。若

$$Ax = \lambda x,$$

取 conjugate：

$$A\overline{x} = \overline{\lambda}\,\overline{x}.$$

Real solution 必須組合 conjugate eigenvectors。不能只留下一個 complex mode 就宣稱它是 real physical solution。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Diagonalization

若 A 有 n 個線性獨立特徵向量 x_i：

$$X = [x_1 \ \cdots \ x_n].$$
$$AX = X\Lambda, \qquad \Lambda = \operatorname{diag}(\lambda_i),$$
$$A = X\Lambda X^{-1}, \qquad X^{-1}AX = \Lambda.$$

充要條件是所有 eigenspace dimensions 的總和為 n。相異特徵值的特徵向量獨立：若最短非平凡關係 $\sum c_i x_i = 0$，施加 $A - \lambda_k I$ 消去第 k 項，會產生更短關係，矛盾。因此 n 個相異特徵值保證可對角化。重複特徵值也可能有完整特徵空間，例如 $2I$。

反向同樣成立。若 $A = X\Lambda X^{-1}$ 且 X 可逆，把 X 的欄寫成 $x_1, \dots, x_n$。由 $AX = X\Lambda$ 的第 j 欄得到 $Ax_j = \lambda_j x_j$。可逆矩陣的欄線性獨立，故這些欄提供完整特徵向量基底，所有 eigenspaces 的維數和恰為 n。這完成兩方向的證明。

Powers 與 difference equations

$$A^k = X\Lambda^k X^{-1}.$$

Recurrence

$$u_{k+1} = Au_k$$

的解：

$$u_k = \sum_{j=1}^{n} c_j \lambda_j^k x_j.$$

若所有

$$|\lambda_j| < 1,$$

zero solution asymptotically stable。Spectral radius：

$$\rho(A) = \max_j |\lambda_j|.$$

若 $\rho(A) < 1$，每個 bounded initial vector 都 decaying。$|\lambda| = 1$ 時可能是 bounded、periodic 或 defective polynomial growth，不能只看 modulus。

Similarity invariants

若

$$C = B^{-1}AB,$$

則

$$C - \lambda I = B^{-1}(A - \lambda I)B,$$

所以 characteristic polynomial、eigenvalues、trace、determinant、rank 與 Jordan block structure 不變。

若 $Ax = \lambda x$，令 $y = B^{-1}x$：

$$Cy = \lambda y.$$

Similarity 改變 coordinates，不改變 intrinsic spectrum。

Defective matrix 與 Jordan preview

$$A = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}$$

只有一條 eigen-direction。任何 similarity 都無法把它變 diagonal。

寫

$$A = 2I + N, \qquad N = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, \qquad N^2 = 0.$$

$2I$ 與 N commute，所以

$$A^k = 2^k I + k2^{k-1}N = \begin{bmatrix} 2^k & k2^{k-1} \\ 0 & 2^k \end{bmatrix}.$$

令 $e_1 = (1,0)^T, e_2 = (0,1)^T$。則

$$(A - 2I)e_1 = 0, \qquad (A - 2I)e_2 = e_1.$$

Defective matrix 與 Jordan preview （續）

所以 e_1 是特徵向量，e_2 是 generalized eigenvector，且 (e_1, e_2) 是長度 2 的 Jordan chain。對角項描述沿 e_1 的放大，非對角項使 e_2 同時混入 e_1，在 powers 中產生 $k2^{k-1}$ 的多項式因子。這正是 Jordan block $J_2(2)$；只要缺少 generalized vector，就無法把整個空間分解成特徵直線。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Spectral decomposition

若 X^{-1} 的 rows 是 y_j^T：

$$A = \sum_{j=1}^{n} \lambda_j x_j y_j^T.$$

每個 $x_j y_j^T$ 的秩為一。實對稱矩陣可選實正交矩陣 Q：

$$A = Q\Lambda Q^T = \sum_j \lambda_j q_j q_j^T.$$

沿每個 orthonormal direction 獨立縮放。Non-normal matrix 的 eigenvectors 一般不 orthogonal，單看 eigenvalues 不足以刻畫 transient amplification。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Scalar 到 matrix ODE

Scalar：

$$u' = \lambda u \quad \Longrightarrow \quad u(t) = Ce^{\lambda t}.$$

System：

$$u' = Au, \qquad u(0) = u_0.$$

若 A diagonalizable：

$$u(t) = \sum_j c_j e^{\lambda_j t} x_j.$$

$$c = X^{-1} u_0.$$

$\lambda = \alpha + i\beta$ 時

$$e^{\lambda t} = e^{\alpha t}(\cos \beta t + i \sin \beta t).$$

Real part 控制 growth/decay，imaginary part 控制 oscillation。

Matrix exponential

$$e^{At} = I + At + \frac{A^2 t^2}{2!} + \cdots.$$

由 $\|A^k t^k / k!\| \le (\|A\||t|)^k / k!$，在任一有界的 t 區間，原級數與導數級數都一致收斂，因此可逐項求導：

$$\frac{d}{dt} e^{At} = Ae^{At} = e^{At} A.$$

Diagonalizable：

$$e^{At} = X e^{\Lambda t} X^{-1} = \sum_j e^{\lambda_j t} x_j y_j^T.$$

Defective $A = 2I + N$、$N^2 = 0$：

$$e^{At} = e^{2t}(I + tN).$$

此解對所有方陣成立。若另一個函數 u 滿足 $u' = Au$，則 $\frac{d}{dt}(e^{-At}u) = 0$，所以 $u(t) = e^{At}u(0)$，同時得到存在與唯一性。長期穩定性由下面的特徵值與 Jordan 結構判斷；非正規暫態放大則另需範數或 resolvent 資訊。

Stability 與完整例子

$$\begin{bmatrix} u_1' \\ u_2' \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix}.$$

Use eigenbasis：

$$u(t) = c_1 e^{4t}(1,1)^T + c_2 e^{2t}(1,-1)^T.$$

兩 eigenvalues 都正，每個非零初始向量的解皆增長。

一般線性系統的零解漸近穩定，若且唯若所有特徵值的實部皆負。對大小 m 的 Jordan 分塊 $J = \lambda I + N$，有 $e^{Jt} = e^{\lambda t}\sum_{\ell=0}^{m-1} t^\ell N^\ell/\ell!$。實部為負時，每個有限次多項式乘衰減指數都趨零；若有實部為正的特徵值，沿其模態便不穩定。

邊界也可精確區分：若所有實部非正，且虛軸上各特徵值的 Jordan 分塊皆為一階，則 e^{At} 有界，零解 Lyapunov 穩定，但只要還有虛軸模態，就不漸近穩定。例：$A = 0$ 的解保持初值；反對稱旋轉矩陣的解保持長度。相反地，$J = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$ 給 $e^{Jt} = I + tJ$，初值 e_2 產生 $(t,1)^T$，故有實部為零的重根仍可能不穩定。這是純線性系統的結論，不需引入未給定的非線性模型。

二階 ODE 轉一階系統

$$u'' + Bu' + Cu = 0.$$

令 $v = u'$：

$$\frac{d}{dt}\begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -C & -B \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix}.$$

Characteristic polynomial：

$$\det \begin{bmatrix} -\lambda & 1 \\ -C & -B-\lambda \end{bmatrix} = \lambda^2 + B\lambda + C.$$

Complex conjugate eigenvalues 給振盪；real part 決定 decay。Initial condition $(u(0), u'(0))$ 變成二維 vector initial data。

實對稱矩陣的實特徵值

令 $S \in \mathbb{R}^{n\times n}$、$S = S^T$，並取非零特徵向量 $x \in \mathbb{C}^n$，使 $Sx = \lambda x$。實係數與對稱性共同給 $S^* = \overline{S}^T = S$。使用共軛轉置：

$$x^* S x = \lambda x^* x.$$

因為

$$\overline{x^* S x} = x^* S^* x = x^* S x,$$

左端 real。又 $x^* x > 0$，所以

$$\lambda = \frac{x^* S x}{x^* x} \in \mathbb{R}.$$

第一個等號是純量取共軛的規則，第二個等號使用 $S^* = S$，不能僅由複數矩陣的 $S^T = S$ 推出。分母 $x^* x = \sum_j |x_j|^2 > 0$，所以實性結論成立。

反例 $S = [i]$ 滿足 $S^T = S$，但 $S^* = [-i] \neq S$，唯一特徵值為 i。複數空間的正確前提是 Hermitian（厄米）條件 $S^* = S$；同一證明給實特徵值，且分解使用酉矩陣 U：$S = U\Lambda U^*$。

實對稱矩陣的實特徵值 (續)

正交特徵基：$Q^TSQ=diag(4,2)$

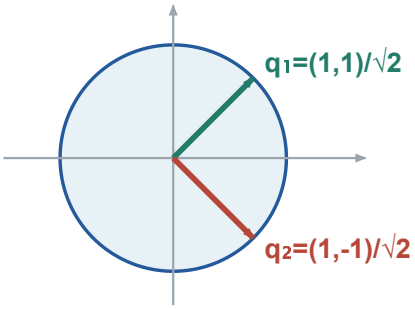

S=[[3,1],[1,3]]

Q=(1/√2)[[1,1],[1,-1]]

$Q^TSQ=diag(4,2)$

$S=Q\Lambda Q^T$；兩軸互相垂直。

未正規化 (1,1),(1,-1) 只能當方向，不能直接稱 Q。

實對稱矩陣的實特徵值 (續)

普通複對稱不等於 Hermitian

S=[i]，$S^T=S$

唯一 eigenvalue=i

$S^*=[-i]\neq S$

缺 Hermitian 前提會失敗。

Hermitian：$S^*=S$

$x^*Sx=\lambda x^*x$

$x^*x>0 \Rightarrow \lambda\in R$

$S=U\Lambda U^*$，U 為酉矩陣

Lin Cing https://github.com/xinhi6716/computer-science-self-study

不同 eigenspaces 正交

本頁先限定 $S\in\mathbb{R}^{n\times n}$ 為實對稱矩陣，並選實特徵向量 x,y。若 $Sx=\lambda x$、$Sy=\mu y$：

$$\lambda x^Ty=(Sx)^Ty=x^TS^Ty=\mu x^Ty.$$

因此

$$(\lambda-\mu)x^Ty=0.$$

$\lambda\neq\mu$ 時 $x\perp y$。完整正交特徵基底可用歸納證明：單位球上連續的 x^TSx 有最大值，其極值條件給實單位特徵向量 q；對 $v\perp q$，$q^TSv=(Sq)^Tv=0$，故 $q^\perp$ 在 S 下不變。限制到此較低維空間仍對稱，反覆歸納得到完整正交特徵基底。重複特徵空間內可用 Gram-Schmidt。

Spectral theorem：

$$S=Q\Lambda Q^T.$$

例：

$$S=\begin{bmatrix}3&1\\1&3\end{bmatrix},\qquad Q=\frac{1}{\sqrt{2}}\begin{bmatrix}1&1\\1&-1\end{bmatrix}.$$

Lin Cing https://github.com/xinhi6716/computer-science-self-study

不同 eigenspaces 正交 （續）

因 $Q^TQ = I$，且

$$Q^TSQ = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix},$$

所以 $S = Q\Lambda Q^T$。未正規化的 $(1,1)^T, (1,-1)^T$ 只描述特徵方向；若要直接寫成 Q，必須先除以 $\sqrt{2}$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Positive definite 等價判準

Real symmetric S positive definite，若下列任一成立且全部等價：

1. $x^TSx > 0$ 對所有 $x \neq 0$；
2. 所有 eigenvalues positive；
3. 所有 leading principal minors positive；
4. 不交換列的對稱消去中所有 pivots positive；
5. 存在 full column rank A 使 $S = A^TA$；
6. 存在對角元素為正的可逆下三角矩陣 R，使 $S = RR^T$（Cholesky）。

各判準的連接：對稱消去是配方法，給 $S = LDL^T$，而 $x^TSx = (L^Tx)^TD(L^Tx)$，故正主元與正能量等價。前 k 階主子式 $\Delta_k = d_1 \cdots d_k$，所以主子式全正等價於主元全正。取 $R = LD^{1/2}$ 得 Cholesky，亦可取 $A = R^T$；反向由平方長度證正能量。只知 $\det S > 0$ 仍不足，例如 $-I_2$ 的行列式為 1 卻負定。

2×2：

$$S = \begin{bmatrix} a & b \\ b & c \end{bmatrix}$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Positive definite 等價判準 (續)

positive definite，若且唯若 $a > 0, ac - b^2 > 0$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Energy 證明與反例

$$x^T S x = \sum_i \lambda_i (q_i^T x)^2.$$

所有 $\lambda_i > 0$ 時，任何 $x \neq 0$ 至少有某個 $q_i^T x \neq 0$，故 energy positive。反之，若有 $\lambda_i \leq 0$，取相應的非零特徵向量，能量便為負或零，都不滿足嚴格正定。

反例：

$$S_1 = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$$

eigenvalues $3, -1$，not positive definite。

若 A 的 columns independent：

$$x^T A^T A x = \|Ax\|^2 > 0$$

對 $x \neq 0$ 成立，故 $A^T A$ positive definite。Full row rank 不能替代 column independence。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Positive semidefinite boundary

$$S = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.$$

$x = (1, -1)^T$ 給 $x^T S x = 0$，eigenvalues $2, 0$。所以 positive semidefinite，不是 positive definite。

若 $S = A^T A$，columns dependent 時存在 $x \neq 0$ 使 $Ax = 0$，故 $x^T S x = 0$。反之，energy zero 也給 $Ax = 0$。

Semidefinite matrix 可有 LDL^T，但若要做 Cholesky，需 handling zero pivots。Pseudoinverse 不能讓 semidefinite boundary system 變成 arbitrary inverse。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Ellipse 與 conditioning

Positive definite S：

$$x^T S x = 1$$

是以 origin 為中心的 ellipsoid。Eigen-coordinates：

$$y = Q^T x,$$
$$\sum_i \lambda_i y_i^2 = 1.$$

第 i 個半軸長度：

$$1/\sqrt{\lambda_i}.$$

Longest axis 對應 smallest eigenvalue。

$$\kappa_2(S) = \frac{\lambda_{\max}}{\lambda_{\min}}.$$

Positive definite 只保證 exact inverse；很小的 $\lambda_{\min}$ 仍造成 ill-conditioning。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

章末檢查

讀者應能：

- 由 characteristic equation 求 eigenvalues；
- 分辨 algebraic/geometric multiplicity；
- 找 defective matrix 反例；
- 用 $A = X\Lambda X^{-1}$ 解 powers 與 ODE；
- 配對 complex conjugates 成 real solutions；
- 證明 symmetric eigenvalues real、不同 eigenspaces orthogonal；
- 用 energy、minors、pivots、Cholesky、A^TA 判斷 positive definiteness；
- 使用 ellipsoid axes 解釋 conditioning。

下一章以 SVD 移除 eigen-analysis 必須 square 且不一定有完整 eigenbasis 的限制。

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Matrix as data

灰階影像可表示成 $A \in \mathbb{R}^{m \times n}$，entry 是 pixel intensity。彩色影像通常是 tensor；處理時要明示如何拆成 matrices。

外積型矩陣的秩至多為 1；只有兩個向量皆非零時才是 rank-one matrix：

$$uv^T = \begin{bmatrix} u_1 \\ \vdots \\ u_m \end{bmatrix} \begin{bmatrix} v_1 & \cdots & v_n \end{bmatrix},$$

$$(uv^T)_{ij} = u_i v_j.$$

只需 $m + n$ 個 scalars，而不是 mn 個 entries。SVD 把一般 matrix 寫成 rank-one pieces 的加權和；大的 singular values 常攜帶主要結構。

SVD statement

任一

$$A \in \mathbb{R}^{m \times n}, \qquad \operatorname{rank} A = r,$$

皆有 full SVD：

$$A = U \Sigma V^T.$$

$$U \in \mathbb{R}^{m \times m}, \qquad V \in \mathbb{R}^{n \times n},$$

正交 columns。Σ 的 nonzero diagonals：

$$\sigma_1 \geq \cdots \geq \sigma_r > 0.$$

Reduced SVD：

$$A = U_r \Sigma_r V_r^T,$$

$$U_r \in \mathbb{R}^{m \times r}, \quad \Sigma_r \in \mathbb{R}^{r \times r}, \quad V_r \in \mathbb{R}^{n \times r}.$$

Rank deficient 時 zero singular values 補滿 full Σ。

SVD statement （續）

完整 Σ 的尺寸是 $m \times n$，共列 $q = \min(m, n)$ 個奇異值，後 $q - r$ 個為零。這裡的 reduced SVD 採秩 r 的精簡形式；另一種常見的 thin SVD 會保留 q 個方向，包括零奇異值，閱讀不同軟體介面時需辨明尺寸。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

由 $A^T A$ 建 right singular vectors

$$x^T A^T A x = \|Ax\|^2 \geq 0.$$

因此 $A^T A$ symmetric positive semidefinite。Spectral decomposition：

$$A^T A = V \Lambda V^T.$$

取

$$\lambda_1 \geq \cdots \geq \lambda_r > 0,$$

$$\sigma_i = \sqrt{\lambda_i}.$$

對 $i \leq r$：

$$\|Av_i\|^2 = v_i^T A^T A v_i = \sigma_i^2,$$

所以 $Av_i \neq 0$。

$v_1, \ldots, v_r$ 是 row space 的 orthonormal basis；$v_{r+1}, \ldots, v_n$ 是 nullspace 的 orthonormal basis。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Left singular vectors

定義

$$u_i = \frac{Av_i}{\sigma_i}.$$

對 $i \neq j$，Orthogonality：

$$\sigma_i \sigma_j u_i^T u_j = v_i^T A^T A v_j = \lambda_j v_i^T v_j = 0.$$

長度：

$$\|u_i\|^2 = \frac{\|Av_i\|^2}{\sigma_i^2} = 1.$$

因此

$$Av_i = \sigma_i u_i.$$

$u_1, \ldots, u_r$ 是 column space 的 orthonormal basis；其餘 $u_{r+1}, \ldots, u_m$ 是 left nullspace 的 orthonormal basis。

現在補齊 SVD 存在性。令 $V = [v_1, \ldots, v_n]$ 為 $A^T A$ 的完整標準正交特徵基底。對 $i > r$，

Left singular vectors (續)

$$\|Av_i\|^2 = v_i^T A^T A v_i = 0$$

故 $Av_i = 0$。再用任意標準正交基底把 $u_1, \ldots, u_r$ 補成 $\mathbb{R}^m$ 的完整基底。寫任意 $x = \sum_{j=1}^{n} c_j v_j$，得

$$Ax = \sum_{j=1}^{r} c_j Av_j = \sum_{j=1}^{r} c_j \sigma_j u_j = U \Sigma V^T x.$$

這逐個驗證了右奇異向量、左奇異向量、奇異值及分解本身，不只是宣稱存在。

A^TA 與 AA^T

$$AA^T = U\Sigma\Sigma^TU^T.$$

因此 A^TA 與 AA^T 有相同的正特徵值 σ_i^2，也有相同 rank；兩者的零特徵值重數可不同。A 本身的正奇異值是 Gram 矩陣正特徵值的平方根，不能把 σ_i^2 直接叫作 A 的奇異值。

這說明 SVD 的 universal structure：

- A^TA 給 V；
- AA^T 給 U；
- 兩個 Gram 矩陣共享正特徵值 σ_i^2，不能和 A 的奇異值混用；
- rectangular、rank-deficient matrices 都有 SVD。

實作通常不形成 A^TA，因會平方 conditioning，甚至 overflow。Stable routines 使用 bidiagonalization 與 Golub-Kahan-type methods。

Rank-one expansion

Reduced SVD：

$$A = \sum_{i=1}^{r} \sigma_i u_i v_i^T.$$

Frobenius 內積定義為 $\langle B, C\rangle_F = \operatorname{tr}(B^TC) = \sum_{ij} B_{ij}C_{ij}$，範數為 $\|B\|_F = \sqrt{\sum_{ij} B_{ij}^2}$。不同 terms 在此內積下 orthogonal：

$$\langle u_i v_i^T, u_j v_j^T\rangle_F = 0, \quad i \neq j.$$

所以

$$\|A\|_F^2 = \sum_i \sigma_i^2.$$

截斷到 k terms 保留的能量比例：

$$\frac{\sum_{i=1}^{k} \sigma_i^2}{\sum_{i=1}^{r} \sigma_i^2}.$$

Rank-one expansion （續）

此比例要求 $A \neq 0$，否則分母為零。另定義核範數 $\|A\|_* = \sum_i \sigma_i$，它與 Frobenius 範數不同。Energy fraction 只表示 squared singular values 的比例；實際影像品質仍取決於重建誤差與下游任務。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Truncated SVD 與 Eckart-Young

$$A_k = \sum_{i=1}^{k} \sigma_i u_i v_i^T.$$

Remainder：

$$A - A_k = \sum_{i=k+1}^{r} \sigma_i u_i v_i^T.$$

對任何 rank 至多 k 的 B：

$$\|A - B\|_2 \geq \sigma_{k+1},$$

$$\|A - B\|_F \geq \sqrt{\sum_{i=k+1}^{r} \sigma_i^2}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Truncated SVD 與 Eckart-Young （續）

證明 spectral bound：B 在 $\operatorname{span}\{v_1,\dots,v_{k+1}\}$ 上必有非零核向量 z，取 $\|z\|=1$，則 $\|(A-B)z\| = \|Az\| \geq \sigma_{k+1}$。證明 Frobenius bound：令 P 投影到 $C(B)$，則 $\|A-B\|_F^2 \geq \|(I-P)A\|_F^2 = \|A\|_F^2 - \operatorname{tr}(PAA^T)$。此處將左奇異向量擴充成完整的正交歸一基底 $u_1,\dots,u_m$，並對 $i>r$ 設 $\sigma_i=0$。寫 $\alpha_i = u_i^T P u_i$，有 $0\leq\alpha_i\leq 1$、$\sum_{i=1}^m \alpha_i = \operatorname{tr} P = \operatorname{rank} P \leq k$，故 $\operatorname{tr}(PAA^T) = \sum_{i=1}^m \sigma_i^2\alpha_i \leq \sum_{i=1}^k \sigma_i^2$。$A_k$ 的餘項奇異值恰是尾端項，同時達到兩個下界。此處 $0\leq k<r$；$k\geq r$ 時最佳誤差為零。

若 $\sigma_k=\sigma_{k+1}$，optimal subspace 不唯一；individual axes 可 rotate，但 tied subspace 仍 well-defined。

以奇異值 $9,4,1,0$ 的矩陣為例，rank 為 3。取 $k=1$，最佳誤差為

$$\|A-A_1\|_2 = 4, \qquad \|A-A_1\|_F = \sqrt{4^2+1^2} = \sqrt{17}.$$

取 $k=2$ 後兩種誤差都變成 1，取 $k=3$ 則為零。這個同一組數值同時核對 spectral bound 是最大被刪奇異值、Frobenius bound 是剩餘奇異值平方和開根。

Low-rank compression cost

Rank-k factors 需要：

$$mk + nk + k = k(m+n+1)$$

個 raw scalars，加上 finite-precision metadata。只有這個 count 小於 mn 時，raw storage 才可能下降。

1000×1000 影像、rank 10 約有 2.001×10^4 個 numbers，替代 10^6 entries。實際 format 還需 quantized coefficients、headers 與 error handling。

Random full-rank data 通常不易壓縮；compressibility 是 data property，不是 SVD 自動產生的 property。

PCA 的資料方向

令

$$A_0 \in \mathbb{R}^{m \times n},$$

rows 是 variables，columns 是 samples。Row means μ_j，centered matrix：

$$A_{js} = (A_0)_{js} - \mu_j.$$

第一 principal direction u_1 最大化 scores

$$s_1 = u_1^T A$$

的 squared sum：

$$\|u_1^T A\|^2 = u_1^T A A^T u_1.$$

在 $\|u_1\| = 1$ 下，由 spectral theorem，最大值是 σ_1^2，u_1 是 AA^T 的 dominant eigenvector，也是 first left singular vector。

PCA scores 與 sign ambiguity

由

$$A = U \Sigma V^T$$

得 principal scores：

$$S = \Sigma V^T = U^T A.$$

第 i row 是 sample 在 component i 的 score；squared norm 與 σ_i^2 相關。

若同時把 u_i, v_i 都乘 -1，factorization 不變；單獨翻轉其中一個則改變重建。Individual sign 沒有 intrinsic meaning。

Repeated singular values 時，subspace 內 axes 不唯一。比較兩次 PCA 應比較 subspace angle，不能硬配 column number。

Covariance denominator

Rows 為 variables、n samples：

$$\widehat{C}_{n-1} = \frac{1}{n-1} AA^T,$$

或 population/descriptive：

$$\widehat{C}_n = \frac{1}{n} AA^T.$$

Eigenvectors 相同，eigenvalues 只差 $n/(n-1)$。$n = 1$ 時 $n - 1 = 0$，sample variance 無定義。

Variable units 不同時，raw PCA 會偏向大 variance 或大 unit 的 features。Standardization 可得到 correlation-based PCA，但會改變原始 geometry，屬 modeling decision。

二維 PCA 例子

Samples：

$$(-1, -1), \quad (0, 1), \quad (1, 0).$$

Centered matrix：

$$A = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 1 & 0 \end{bmatrix}.$$

$$AA^T = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

$$u_1 = (1, 1)^T/\sqrt{2}, \qquad u_2 = (1, -1)^T/\sqrt{2}.$$

Scores：

$$s_1 = \begin{bmatrix} -\sqrt{2} & 1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix},$$
$$s_2 = \begin{bmatrix} 0 & -1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}.$$

s_1, s_2 orthogonal，squared sums 是 $3, 1$。

奇異向量如何決定橢圓的軸

輸入與輸出各用一組標準正交基底，兩組方向一般不同。取

$$V = \frac{1}{5}\begin{bmatrix} 4 & -3 \\ 3 & 4 \end{bmatrix}, \qquad U = \frac{1}{5}\begin{bmatrix} 3 & -4 \\ 4 & 3 \end{bmatrix}, \qquad \Sigma = \operatorname{diag}(3, 2).$$

這裡 $V^TV = U^TU = I$，而

$$A = U\Sigma V^T = \frac{1}{5}\begin{bmatrix} 12 & -1 \\ 6 & 12 \end{bmatrix}.$$

下圖所有面板使用相同座標比例。先以 V^T 把輸入方向 v_i 送到 e_i，再伸縮，最後以 U 改變輸出方向。圓集合經旋轉仍是同一個圓，但標記的向量方向確實改變；不能因圓的外觀不變就省略這一步。

奇異向量如何決定橢圓的軸 （續）

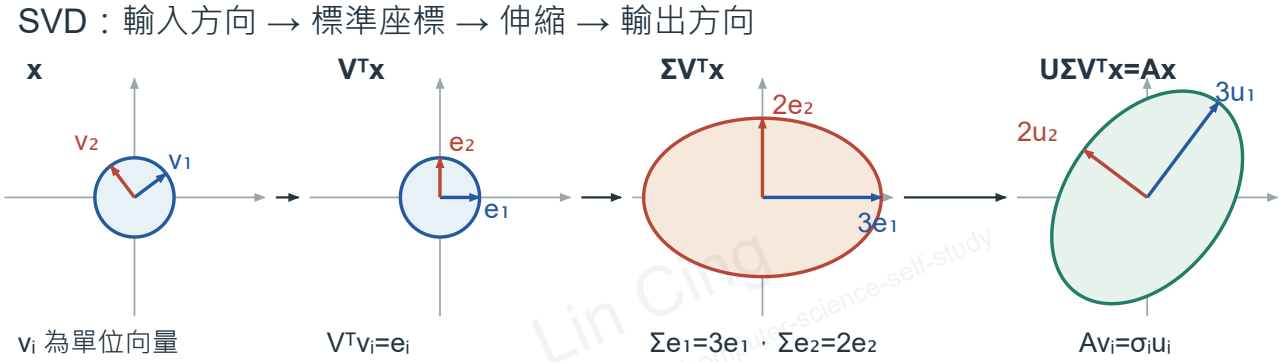

兩條軸可逐項驗算：

$$v_1 = (4/5, 3/5)^T, \quad Av_1 = (9/5, 12/5)^T = 3u_1,$$
$$v_2 = (-3/5, 4/5)^T, \quad Av_2 = (-8/5, 6/5)^T = 2u_2.$$

所以圖中的半軸向量是 $3u_1$、$2u_2$，單位向量 u_1, u_2 只決定方向。圖形以圓周映射呈現邊界；本例滿秩，單位圓盤則映成填滿的橢圓盤。

追蹤一個不沿奇異方向的單位向量

沿用前例的 U, V, Σ，取 $x = (1, 0)^T$。這個 x 不是 v_1 或 v_2。綠色箭頭追蹤同一點，背景曲線是單位圓在各步的像。

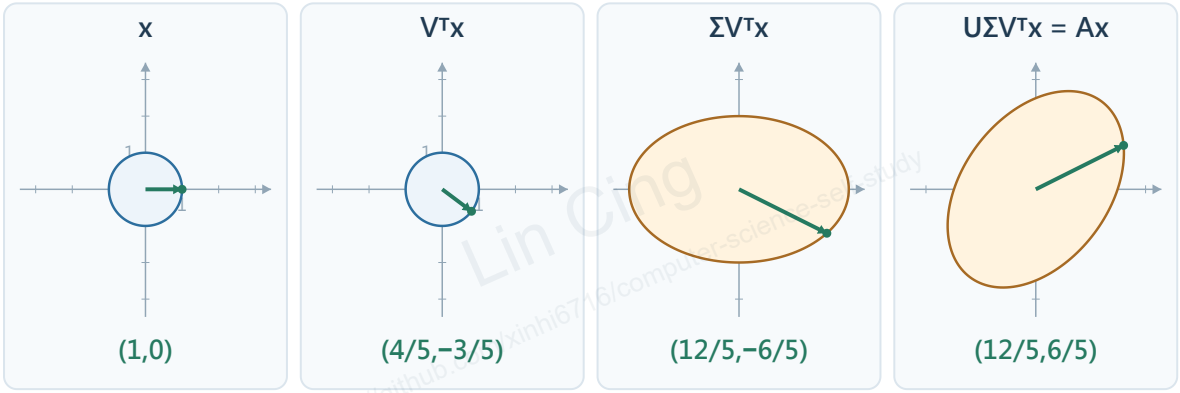

四面板同尺度；綠色向量追蹤同一個輸入的逐步變化。

算值與長度變化要分開核對

步驟	代入後的座標	範數平方
輸入 x	(1,0)	1
VᵀX	(4/5,−3/5)	1
ΣVᵀx	(12/5,−6/5)	36/5
UΣVᵀx=Ax	(12/5,6/5)	36/5

V^T、U 只改變方向；伸縮由 Σ 產生。本例 $\|Ax\| = 6/\sqrt{5}$，不是任何一個奇異值。

對任意單位輸入，令 $w = V^T x$，則 $w_1^2 + w_2^2 = 1$，且

$$\|Ax\|^2 = 9w_1^2 + 4w_2^2 = 4 + 5w_1^2 \in [4, 9].$$

所以 $2 \le \|Ax\| \le 3$；上界在 $x = \pm v_1$ 取到，下界在 $x = \pm v_2$ 取到。這是對所有單位輸入的證明，不是由單一數例推論。

SVD 幾何：可重算的直角旋轉例

對單位球 $\|x\| \le 1$：

$$y = Ax = U\Sigma V^T x.$$

三步對應同一組 v_i, u_i。本頁取

$$V = I, \quad \Sigma = \operatorname{diag}(3,2), \quad U = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}, \qquad A = U\Sigma V^T = \begin{bmatrix} 0 & -2 \\ 3 & 0 \end{bmatrix}.$$

依序作用：

1. $V^T x = Ix$：輸入座標不變，圓盤與座標軸重疊；
2. $\Sigma(V^T x) = (3x_1, 2x_2)$：沿正交座標方向伸縮，圓盤成為半軸 $3, 2$ 的橢圓；
3. $U\Sigma V^T x$：把橢圓旋轉，並將標準軸送到 $u_1 = (0,1)^T, u_2 = (-1,0)^T$。

由定義可逐項核對：

$$v_1 = (1,0)^T, \quad Av_1 = (0,3)^T = 3u_1,$$
$$v_2 = (0,1)^T, \quad Av_2 = (-2,0)^T = 2u_2.$$

SVD 幾何：可重算的直角旋轉例 （續）

因此像是 $C(A)$ 內的填滿橢球，半軸長為正奇異值；二維滿秩時邊界為橢圓。單位球面在具有零空間時可能映到填滿橢球，不能一概稱為橢球面。最大 singular value：

$$\|Av_1\| = \sigma_1.$$

Matrix norm：

$$\|A\|_2 = \sigma_1.$$

Image ellipse 的 semi-axis lengths 是 singular values。最小 positive σ_r 控制 row space 到 column space 的最弱 growth。

SVD 幾何：可重算的直角旋轉例 （續）

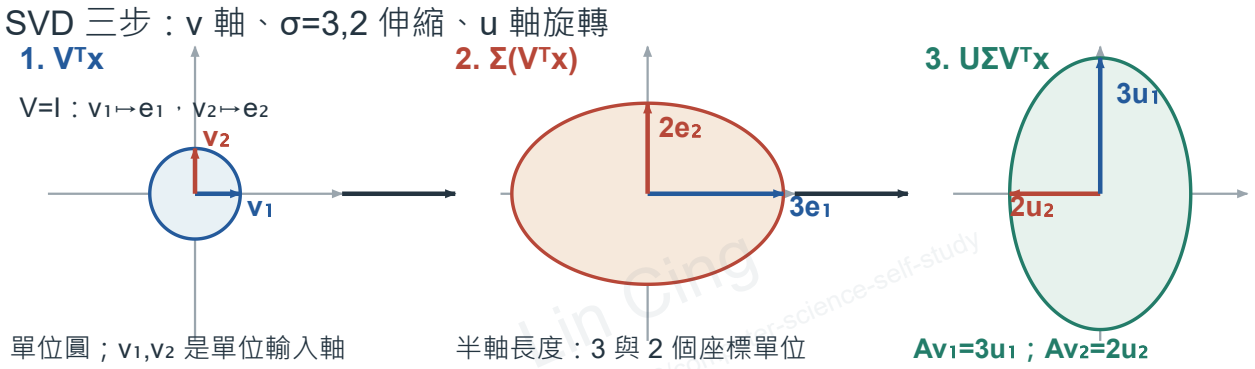

秩不足示例取

$$B = \begin{bmatrix} 0 & 0 \\ 3 & 0 \end{bmatrix} = U\,\mathrm{diag}(3,0)V^T.$$

此時 $Bv_1 = (0,3)^T$，而 $Bv_2 = 0$。單位圓盤的像不是橢圓盤；v_2 方向塌縮成原點後，其餘點落在從 $(0,-3)^T$ 到 $(0,3)^T$ 的完整線段。

SVD 幾何：可重算的直角旋轉例 （續）

秩不足 SVD：B=[[0,0],[3,0]]，σ2=0 塌縮

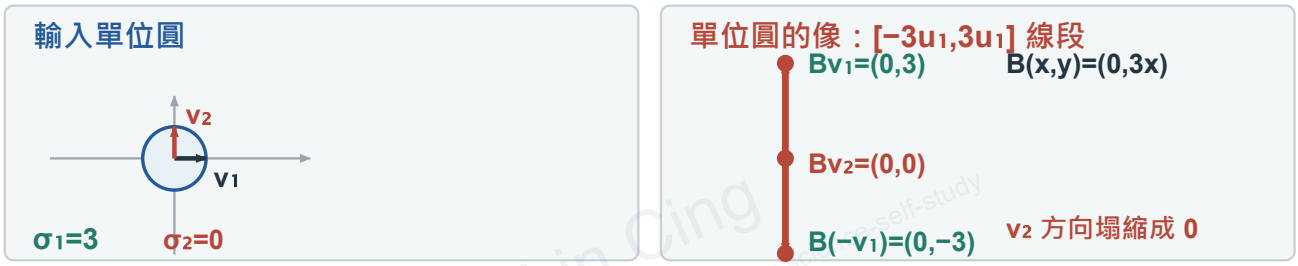

rank(B)=1；整個像為直線，單位圓的像才是線段

Spectral norm 與 condition number

$$\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

對

$$x = \sum_i c_i v_i,$$

$$\|Ax\|^2 = \sum_i \sigma_i^2 |c_i|^2 \leq \sigma_1^2 \|x\|^2.$$

$x = v_1$ 時等號成立，所以

$$\|A\|_2 = \sigma_1.$$

對可逆方陣，或明確把長方矩陣的條件數定義為 $\|A\|_2 \|A^+\|_2$ 且 A 滿 column rank 時：

$$\kappa_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Spectral norm 與 condition number （續）

正交矩陣的奇異值全為 1，所以 $\kappa_2 = 1$。秩不足時，原來要求逆的全空間映射已非單射；不能把略去零奇異值後的有限比值當成原問題的可逆條件數。固定限制在 row space 到 column space 的可逆映射可另談正奇異值比，但那是已限制子空間的不同問題。一般最小平方解對資料的相對敏感度還受殘差與投影角度影響，不只由這個比值決定。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Distance to singularity 與 numerical rank

本頁先限定可逆方陣 $A \in \mathbb{R}^{n\times n}$。把 smallest singular value 對應的 $\sigma_n u_n v_n^T$ 刪掉：

$$\|A - A_0\|_2 = \sigma_n.$$

因此 σ_n 是 spectral norm 下到 singular matrices 的 distance。rank 至多 k 的最近 matrix 是 A_k，distance σ_{k+1}。

Numerical rank 用 tolerance τ：

$$\sigma_i > \tau \|A\|.$$

Tolerance 要反映 noise、dimension 與 downstream sensitivity。Singular values stable 不代表 close singular vectors stable；close values 附近尤需小心。

擾動半徑如何限制數值秩

對相同尺寸矩陣 A, B，令 $\delta = \|A - B\|_2$。由前面的 Eckart–Young 定理，$\sigma_i(A) = \min_{\operatorname{rank} C < i} \|A - C\|_2$。取 B 的最佳低秩近似，三角不等式給

$$\sigma_i(A) \le \|A - B\|_2 + \sigma_i(B).$$

交換 A, B 即得 Weyl 界 $|\sigma_i(A) - \sigma_i(B)| \le \delta$。它是奇異值的絕對擾動界；極小奇異值的相對誤差仍可很大。

設資料 A 與未知真矩陣 B 的距離至多 δ，令 $r_\delta = \#\{i : \sigma_i(A) > \delta\}$。任何這樣的 B 都必有 $\operatorname{rank} B \ge r_\delta$，因前 r_δ 個奇異值仍嚴格為正；同時截斷 A_{r_δ} 的誤差 $\sigma_{r_\delta+1} \le \delta$，所以至少存在一個秩 r_δ 的相容模型。若 $r_\delta = q$，便用 $A_q = A$。

因此 r_δ 是擾動球中可保證的最小秩，不表示所有相容模型的真秩都等於它。例如 $A = \operatorname{diag}(1, 10^{-8}, 10^{-12})$、$\delta = 10^{-10}$，秩 2 的截斷模型相容，原來秩 3 的 A 也相容，資料精度不足以分辨第三個方向是否真的為零。

若應用另固定絕對門檻 t，只有 $\sigma_i(A) > t + \delta$ 或 $\sigma_i(A) < t - \delta$ 的分類才對此擾動穩健；靠近門檻的方向應列為不確定。相對門檻 $t = \tau\|A\|_2$ 還要記錄尺度與雜訊假設。

QR 的主元不是奇異值

精確算術下，$A = Q_1 R$、$Q_1^T Q_1 = I$ 給 $A^T A = R^T R$，故 A 與 R 的奇異值相同。但 R 的對角元素不是奇異值。取

$$R = \begin{bmatrix} 1 & K \\ 0 & 1 \end{bmatrix}, \qquad K \geq 1.$$

兩個對角元素都是 1，卻有 $\|Re_2\|_2 = \sqrt{K^2+1}$，所以 $\sigma_{\max} \geq K$。又 $\sigma_{\max}\sigma_{\min} = |\det R| = 1$，故 $\sigma_{\min} \leq 1/K$、$\kappa_2(R) \geq K^2$。大非對角元素會讓普通 QR 的對角線無法單獨反映接近相依的程度。

列出 R_{ii} 的大小可作啟發式檢查，不能當成奇異值擾動定理。選 column pivot 的 QR 常用來估計數值秩，但若要保證精度，仍需其明確的秩揭露界或以 SVD 核對。也不能因某個浮點主元非零，就宣稱它代表可信的資料方向。

Polar decomposition

$$A = U\Sigma V^T = (UV^T)(V\Sigma V^T).$$

本頁限定方陣 $A \in \mathbb{R}^{n\times n}$，因此 U, V, Σ 均為 $n \times n$。令

$$Q = UV^T, \qquad S = V\Sigma V^T.$$

Q orthogonal、S symmetric positive semidefinite。所以

$$A = QS.$$

A invertible 時 Σ 全正，S positive definite。$\det Q$ 的正負反映 orientation。Q 類比 rotation 或 reflection，S 類比 stretch。

Pseudoinverse

Reduced SVD：

$$A = U_r \Sigma_r V_r^T.$$

Moore-Penrose pseudoinverse：

$$A^+ = V_r \Sigma_r^{-1} U_r^T.$$

$$AA^+ = U_r U_r^T, \qquad A^+ A = V_r V_r^T.$$

兩者分別是 column space 與 row space 的 orthogonal projection。

Full column rank：

$$A^+ = (A^T A)^{-1} A^T.$$

Full row rank：

$$A^+ = A^T (AA^T)^{-1}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Pseudoinverse （續）

$A^+ b$ 是 minimum-norm least-squares solution。證明：以完整 V 展開 $x = \sum_i c_i v_i$，則 $\|b - Ax\|^2 = \sum_{i=1}^{r} (u_i^T b - \sigma_i c_i)^2 + \sum_{i=r+1}^{m} (u_i^T b)^2$。最小值要求 $c_i = u_i^T b / \sigma_i$（$i \le r$），其餘零空間係數任意；令其餘係數為零使 $\|x\|^2 = \sum_i c_i^2$ 唯一最小，即得 $A^+ b$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Rank-deficient least squares 結構

$$A = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix} = (1,2)^T (1,1).$$

Normalize：

$$u_1 = (1,2)^T/\sqrt{5}, \qquad v_1 = (1,1)^T/\sqrt{2}.$$
$$A = \sqrt{10}\, u_1 v_1^T.$$

u_1 是輸出方向、v_1 是輸入方向。此例兩者均以 $\mathbb{R}^2$ 座標表示，但不同數值；一般矩形矩陣甚至連所在維度也不同，不能因 rank one 就假設 $u_1 = v_1$。

對 $b = (1,3)^T$：

$$A^T A = \begin{bmatrix} 5 & 5 \\ 5 & 5 \end{bmatrix}, \qquad A^T b = \begin{bmatrix} 7 \\ 7 \end{bmatrix}.$$

所有

$$x_1 + x_2 = 7/5$$

都是 minimizers；$A^T A$ singular，不能直接 invert。

Minimum-norm 解

$$\sigma_1 u_1^T b = \sqrt{10}\frac{1+6}{\sqrt{5}} = 7\sqrt{2}.$$
$$x^+ = A^+ b = \frac{1}{\sigma_1} v_1 u_1^T b = \frac{7}{10}(1,1)^T.$$

Projection：

$$AA^+ b = u_1 u_1^T b = \frac{7}{5}(1,2)^T.$$

Residual：

$$e = b - AA^+ b = \left(-\frac{2}{5}, \frac{1}{5}\right)^T.$$
$$e^T (1,2) = 0,$$

所以 residual 與 column space 正交。

Numerical workflow

SVD workflow：

1. 檢查 shape、missing values、units；
2. PCA 要先 center，必要時 standardize；
3. 使用 stable SVD，不形成 normal equations；
4. 看 singular-value gaps 與 numerical rank；
5. 依 error budget 選 k；
6. 在 held-out data 或 downstream task 驗證。

Sign 可翻轉，repeated singular values 的 axes 可 rotate。SVD 是 linear reconstruction，不自動提供 causal importance 或 fairness guarantee。

Four subspaces

空間	Ambient space	SVD basis	Dimension
row space	$\mathbb{R}^n$	$v_1, \dots, v_r$	r
nullspace	$\mathbb{R}^n$	$v_{r+1}, \dots, v_n$	$n - r$
column space	$\mathbb{R}^m$	$u_1, \dots, u_r$	r
left nullspace	$\mathbb{R}^m$	$u_{r+1}, \dots, u_m$	$m - r$

u_i 與 v_i 位於不同 spaces，不直接比較 inner product，除非 $m = n$ 且明確做 coordinate identification。SVD 的 role 是 matched bases：

$$Av_i = \sigma_i u_i.$$

章末檢查

讀者應能：

- 由 A^TA 建 v_i，令 $u_i = Av_i/\sigma_i$；
- 補齊 null directions 得到 full SVD；
- 使用 rank-one terms 計算 spectral/Frobenius errors；
- 解釋 PCA 的 center、scores、variance 與 denominator；
- 區分 input/output singular bases；
- 推導 $\|A\|_2$、condition number、distance to singularity；
- 建 polar decomposition 與 pseudoinverse；
- 處理 sign ambiguity、tied singular values 與 numerical rank。

下一章用 basis 和 coordinates 重新解釋 linear transformations。

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。
https://github.com/xinhi6716/computer-science-self-study

抽象映射與座標表示

線性轉換（linear transformation）是向量空間之間的映射

$$T\colon V \to W,$$

本章的維度公式先限定有限維空間；線性映射的定義本身不需此限制。它保持向量加法與純量乘法。T 本身不依賴基底；選定輸入與輸出基底後，才得到矩陣。

旋轉矩陣

$$R_\theta = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$

是某組標準座標下的表示。換基底會改變矩陣元素，但不會改變旋轉本身。

核（kernel）、像（image）、秩、單射與滿射是映射本身的不變性質；矩陣元素與行列式的解讀則取決於輸入、輸出座標之間的換算。

線性性

$T\colon V \to W$ 是線性映射，若

$$T(\alpha u + \beta v) = \alpha T(u) + \beta T(v)$$

對所有 u, v 與純量成立。等價地，

$$T(u+v) = T(u) + T(v), \qquad T(cu) = cT(u).$$

取 $c = 0$：

$$T(0) = 0.$$

所以把原點移走的平移

$$T(x) = Ax + b, \qquad b \neq 0$$

是仿射映射（affine map），不是向量空間意義下的線性映射。它在電腦圖學中使用，但須改用齊次座標，才能寫成擴維後的線性矩陣。

線性性 （續）

線性性保持所有線性組合：

$$T\left(\sum_i c_i v_i\right) = \sum_i c_i T(v_i).$$

因此只要知道基底向量的像，就知道整個映射。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

核、像與秩—零度定理

核與像定義為

$$N(T) = \{v \in V : T(v) = 0\},$$
$$C(T) = \{T(v) : v \in V\}.$$

它們分別是 V 與 W 的子空間。秩—零度定理為

$$\dim V = \dim N(T) + \dim C(T).$$

證明：取 $N(T)$ 的一組基底

$$v_1, \dots, v_k,$$

擴充成 V 的一組基底

$$v_1, \dots, v_k, u_1, \dots, u_r.$$

$T(u_1), \dots, T(u_r)$ 張成像；其線性獨立性來自：若 $\sum c_i T(u_i) = 0$，則 $\sum c_i u_i \in N(T)$，在完整基底中所有 c_i 必為零。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

單射、滿射與維度

線性映射 T 是單射，若且唯若

$$N(T) = \{0\}.$$

先證充分性：假設 $N(T) = \{0\}$。若 $T(u) = T(v)$，線性性給 $T(u - v) = 0$，故 $u - v \in N(T)$，由零核假設得 $u = v$，所以 T 單射。再證必要性：若 T 單射且 $v \in N(T)$，則 $T(v) = 0 = T(0)$，單射性推出 $v = 0$；又線性性給 $0 \in N(T)$，故核恰為 $\{0\}$。

滿射表示

$$C(T) = W.$$

對同一有限維空間上的線性映射 $T \colon V \to V$，可逆、$N(T) = \{0\}$、$\operatorname{rank} T = \dim V$ 與座標矩陣可逆四個條件等價。

定義域與對應域維度不同時，單射與滿射不必同時成立。$\mathbb{R}^2 \to \mathbb{R}^3$ 可以是單射，但像最多只有二維，不可能滿射。

線性映射的例子

旋轉：

$$T(x, y) = (-y, x)$$

核只有零向量，像則是整個平面。

投影：

$$P(x, y) = (x, 0)$$

核是 y 軸，像是 x 軸。

多項式微分：

$$D(p) = p'$$

在 $\mathcal{P}_k$ 上，核是常數多項式，像是次數至多 $k - 1$ 的多項式。

積分：

$$I(p)(t) = \int_0^t p(s)\, ds$$

線性映射的例子 （續）

核只有零多項式，像是常數項為零且次數至多 $k+1$ 的多項式。

伸縮映射 $S(x)=cx$ 在 $c\neq 0$ 時可逆；$c=0$ 會把整個空間映到零。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

線性映射與仿射映射

仿射映射：

$$T(x)=Ax+b.$$

它保持仿射組合 $T((1-t)x+ty)=(1-t)T(x)+tT(y)$。若直線方向被 A 消去，整條線可塌成一點；否則沿線比例保持。當 $b\neq 0$ 時

$$T(0)=b\neq 0,$$

所以它在向量空間意義下不是線性的。

即使圖形是一條直線，映射也不一定線性。例如

$$f(x)=2x+1$$

不滿足 $f(0)=0$，也不滿足 $f(cx)=cf(x)$。

二次映射 $T(x)=x^2$ 也不是線性映射；它不保持向量加法或純量乘法。判定線性性時，先檢查 $T(0)=0$，再檢查線性組合。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

由基底向量的像建立矩陣

輸入基底：

$$B_{\text{in}} = \{v_1, \dots, v_n\},$$

輸出基底：

$$B_{\text{out}} = \{w_1, \dots, w_m\}.$$

將 $T(v_j)$ 用輸出基底展開：

$$T(v_j) = \sum_{i=1}^{m} M_{ij} w_i.$$

矩陣的各個 columns（欄）就是這些座標向量：

$$M = \begin{bmatrix} [T(v_1)]_{B_{\text{out}}} & \cdots & [T(v_n)]_{B_{\text{out}}} \end{bmatrix}.$$

若

$$x = \sum_j c_j v_j,$$

由基底向量的像建立矩陣 （續）

則

$$[T(x)]_{B_{\text{out}}} = M[x]_{B_{\text{in}}}.$$

column 數等於輸入維度，row 數等於輸出維度；輸入與輸出的座標排序必須前後一致。

標準矩陣的完整例子

令

$$T(x,y) = (x+y,\, x-y,\, 2x).$$

標準基底的像：

$$T(e_1) = (1,1,2)^T, \qquad T(e_2) = (1,-1,0)^T.$$

故

$$A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 2 & 0 \end{bmatrix}.$$

這是 3×2 矩陣。核為

$$x+y=0, \quad x-y=0, \quad 2x=0$$

只得到 $x=y=0$，所以 T 是單射。像是 $\mathbb{R}^3$ 中秩為 2 的平面，而不是整個 $\mathbb{R}^3$。

再取 $S\colon \mathbb{R}^3 \to \mathbb{R}^2$，

標準矩陣的完整例子 (續)

$$S(x,y,z) = (x+z,\, y-2z), \qquad N = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -2 \end{bmatrix}.$$

組合映射定義為 $(S \circ T)(v) = S(T(v))$。當 T 的輸出基底與 S 的輸入基底一致，

$$[S \circ T]_{\text{std}} = NA = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 2 & 0 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ -3 & -1 \end{bmatrix}.$$

對 $v = (1,2)^T$，$T(v) = (3,-1,2)^T$，因此

$$S(T(v)) = (5,-5)^T = (NA)v.$$

先作用最右邊的 A，再作用 N；若基底不同，必須先插入座標換算。

換基底公式

若 A 是標準基底下的矩陣，而新的輸入、輸出基底分別為 $B_{\text{in}}, B_{\text{out}}$：

$$[x]_{\text{std}} = B_{\text{in}}[x]_{B_{\text{in}}},$$
$$[y]_{B_{\text{out}}} = B_{\text{out}}^{-1} y_{\text{std}}.$$

依序：

1. 用 B_{in} 把輸入座標轉成標準座標；
2. 套用 A；
3. 用 B_{out}^{-1} 把輸出的標準座標轉成輸出基底座標。

因此

$$[T(x)]_{B_{\text{out}}} = B_{\text{out}}^{-1} A B_{\text{in}} [x]_{B_{\text{in}}},$$
$$M = B_{\text{out}}^{-1} A B_{\text{in}}.$$

B_{in} 是定義域基底，B_{out} 是對應域基底，兩者維度可以不同。

換基底公式 （續）

換基底方向：Bin 輸入，Bout⁻¹ 輸出

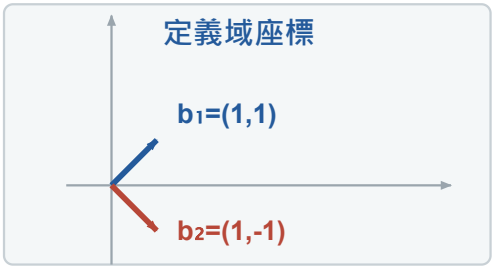

A=[[2,1],[1,2]]

Bin=[[1,1],[1,-1]]

Bout=Bin

M=[[3,0],[0,1]]

M=Bout⁻¹ A Bin

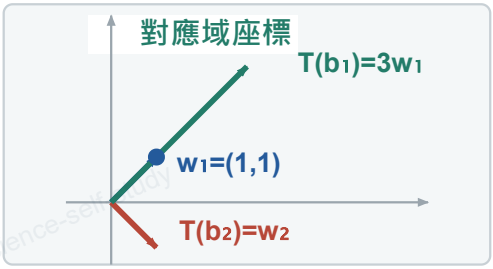

同一個二維例子取

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \qquad B_{\text{in}} = B_{\text{out}} = B = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

因 $Ab_1 = (3,3)^T = 3b_1$、$Ab_2 = (1,-1)^T = b_2$，

換基底公式 （續）

$$M = B^{-1}AB = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

取 $x = (2,0)^T$，輸入座標是 $B^{-1}x = (1,1)^T$。先在基底座標下套用 M，得到 $(3,1)^T$，再用 B 轉回標準座標：

$$B(3,1)^T = (4,2)^T = A(2,0)^T.$$

輸入端先用 B_{in} 把基底座標轉成標準座標；輸出端再用 B_{out}^{-1} 把標準座標轉成輸出基底座標。這兩個方向不能顛倒。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

同一空間上的相似變換

當 $V = W$，且輸入、輸出使用同一個基底 B：

$$[T]_B = B^{-1}AB.$$

若 $Av = \lambda v$，且 $y = B^{-1}v$：

$$B^{-1}AB\,y = B^{-1}Av = \lambda y.$$

所以 A 與 $B^{-1}AB$ 有相同的特徵多項式與特徵值；跡與行列式也不變：

$$\operatorname{tr}(B^{-1}AB) = \operatorname{tr} A,$$
$$\det(B^{-1}AB) = \det A.$$

但輸入基底與輸出基底不同時，矩陣可為長方形，不能直接稱為相似矩陣。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

特徵基底例子

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

特徵基底：

$$B = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

$$B^{-1} = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

因此

$$B^{-1}AB = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

同一個映射在特徵基底下只在各方向獨立伸縮。若 B 的條件數很大，座標誤差也可能被放大；理論上可對角化，不代表數值上的基底好用。

微分映射的兩組基底

$D\colon \mathcal{P}_2 \to \mathcal{P}_1$，輸入使用單項式基底

$$(1, t, t^2),$$

輸出基底為 $(1, t)$。

$$D(1) = 0, \qquad D(t) = 1, \qquad D(t^2) = 2t.$$

所以

$$M = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix}.$$

若輸入基底改成 $1, s, s^2$、$s = t - 1$，則

$$D(s^2) = 2s = -2 + 2t,$$

新矩陣為

$$\begin{bmatrix} 0 & 1 & -2 \\ 0 & 0 & 2 \end{bmatrix}.$$

換基底只改變表示，不改變微分映射本身。

不變子空間

子空間 $U \subseteq V$ 稱為不變子空間，若

$$T(U) \subseteq U.$$

每條特徵向量所張成的一維空間，都是最小的非零不變子空間。若

$$V = U \oplus W$$

且 U, W 都不變，則選用適當基底後，矩陣呈分塊對角。

只有 U 不變時，取 U 的基底後，可得到上三角分塊：

$$\begin{bmatrix} A_1 & B \\ 0 & A_2 \end{bmatrix}.$$

不變子空間把大型映射拆成較小的分塊；這個想法是 Schur 形式與 Jordan 形式共同的結構來源。

特徵基底與對角化

若 $b_1, \dots, b_n$ 構成一組特徵向量基底：

$$B = [b_1 \ \cdots \ b_n],$$

則

$$B^{-1} A B = \operatorname{diag}(\lambda_1, \dots, \lambda_n).$$

特徵基底把互相耦合的系統拆成獨立模式，因此矩陣冪、指數與差分方程都能逐個模式計算。

實對稱矩陣可選用正交歸一的特徵基底 Q，使

$$Q^{-1} = Q^{T}.$$

此時基底矩陣的逆等於轉置，條件數為 1。非對稱矩陣的特徵基底可能接近線性相依，因此不能只檢查特徵值的個數。

Jordan 形式與廣義特徵向量

每個複方陣 A 都有 Jordan 形式：

$$J = B^{-1}AB.$$

其中一個分塊為

$$J_k(\lambda) = \begin{bmatrix} \lambda & 1 & & 0 \\ 0 & \lambda & \ddots & \\ & \ddots & \ddots & 1 \\ 0 & & 0 & \lambda \end{bmatrix}.$$

對角線放特徵值，上方的 1 表示廣義特徵向量鏈。非零向量 w 若滿足

$$(A - \lambda I)^m w = 0$$

對某個 $m \geq 1$ 成立，就是廣義特徵向量。Jordan 鏈滿足 $(A-\lambda I)w_1 = 0$、$(A-\lambda I)w_{j+1} = w_j$，因此其基底表示的超對角線是 1。Jordan 定理的完整一般證明不在本章範圍；本章只在練習中用二階冪零分塊實算。

Jordan 形式與廣義特徵向量 （續）

Jordan 定理給出理論上的標準形式；實務演算法通常不直接計算容易不穩定的 Jordan 分解，而更常使用 Schur 形式、SVD 或具結構的方法。

循環矩陣與 Fourier 基底

$n = 4$ 時，左移一個位置的循環排列矩陣為

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

把 $(x_0, x_1, x_2, x_3)^T$ 映到 $(x_1, x_2, x_3, x_0)^T$。

取四次單位根

$$\lambda \in \{1, i, -1, -i\},$$
$$v_\lambda = (1, \lambda, \lambda^2, \lambda^3)^T.$$

最後一個座標繞回第一列時使用 $\lambda^4 = 1$，所以

$$Pv_\lambda = \lambda v_\lambda.$$

四個單位根給出四個線性獨立的特徵向量。Fourier 矩陣不僅對角化 P，也對角化所有循環矩陣

$$C = c_0 I + c_1 P + c_2 P^2 + c_3 P^3.$$

函數空間中的良好基底

函數空間常用的基底包括：

- 單項式 $1, x, x^2, \ldots$：適合符號式的多項式運算；
- 三角函數：適合表示週期訊號；
- Fourier 複指數：適合處理平移與卷積；
- Legendre 多項式：適合在區間 $[-1, 1]$ 做正交逼近；
- Chebyshev 多項式：適合數值插值與逼近。

良好基底取決於任務：若要對角化微分算子，可選特徵函數；若要穩定做數值逼近，可選條件良好的正交基底；若要壓縮光滑函數，可選係數快速衰減的基底。

同一個張成空間只表示描述的是同一個函數空間；不同基底會改變稀疏性、條件數與係數解讀。

基底的條件數

若

$$X = [x_1 \ \cdots \ x_n]$$

且

$$x = Xc,$$

座標映射的擾動可被

$$\|X^{-1}\|_2$$

放大。當 $\kappa_2(X)$ 很大時，幾何向量的小變化可能造成很大的座標變化。

這不代表 X 在精確算術下奇異；它可能只是數值性質很差的基底。正交歸一基底滿足

$$\kappa_2(X) = 1.$$

大區間上的高次單項式可能極不穩定，因此常使用尺度化、正交化或 Chebyshev 基底。任何換基底都應明確記錄正規化與條件數。

整合例子

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, \qquad B = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

$$B^{-1}AB = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

對

$$x = (2, 0)^T,$$

eigenbasis coordinates：

$$c = B^{-1}x = (1, 1)^T.$$

$$[T^5 x]_B = \begin{bmatrix} 4^5 & 0 \\ 0 & 2^5 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1024 \\ 32 \end{bmatrix}.$$

回到標準座標：

$$T^5 x = B \begin{bmatrix} 1024 \\ 32 \end{bmatrix} = \begin{bmatrix} 1056 \\ 992 \end{bmatrix}.$$

特徵基底把兩個模式分開。若 B 的條件數很差，還必須另外分析座標誤差。

章末檢查

讀者應能：

- 用 $T(0)=0$ 與線性公理判斷映射；
- 證明核與像是子空間，並運用秩—零度定理；
- 由基底向量的像建立矩陣的 columns；
- 正確使用 $M=B_{\text{out}}^{-1}AB_{\text{in}}$；
- 區分同一空間的相似變換與不同輸入、輸出基底下的座標矩陣；
- 以不變子空間、特徵基底、Jordan 形式與 Fourier 基底簡化映射；
- 區分理論上的基底存在性與數值條件數。

下一章加入複純量、Hermitian 內積、unitary 矩陣與 FFT。

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

為什麼需要複數

實旋轉矩陣

$$R_\theta = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$

當 $\theta \not\equiv 0 \pmod{\pi}$ 時，它沒有實特徵向量。特徵值為

$$\lambda = e^{\pm i\theta}.$$

複特徵向量讓振盪動態、單位根與週期訊號有自然表示。實矩陣的複特徵值成共軛對；實解由共軛特徵向量組合而成。

本章使用 $i^2 = -1$。電機工程常以 j 表示虛數單位，這只是記號慣例。

複數體的運算

$z = a + bi$，其中 $a, b \in \mathbb{R}$。加減法逐分量進行：

$$(a + bi) + (c + di) = (a + c) + (b + d)i.$$

乘法：

$$(a + bi)(c + di) = (ac - bd) + (ad + bc)i.$$

$\mathbb{C}$ 是一個體（field）。非零複數的乘法反元素為

$$\frac{1}{a + bi} = \frac{a - bi}{a^2 + b^2}.$$

複數乘法可交換，且非負的模使每個非零複數都有乘法反元素。$\mathbb{C}^n$ 可以直接使用標準基底，但係數是複數。

共軛、模與實維度

共軛為

$$\overline{a+bi} = a - bi.$$

模為

$$|z| = \sqrt{z\overline{z}} = \sqrt{a^2+b^2}.$$

共軛運算保持加法與乘法：

$$\overline{z+w} = \overline{z} + \overline{w}, \qquad \overline{zw} = \overline{z}\,\overline{w}.$$

$|zw| = |z||w|$，且三角不等式成立。

$\mathbb{C}^n$ 作為複向量空間的維度是 n；作為實向量空間的維度是 $2n$，因為每個座標都有實部與虛部。討論秩以前，必須先指明所用的體。

極式與 Euler 公式

非零

$$z = a + bi$$

有

$$r = |z|, \qquad \theta = \operatorname{atan2}(b, a),$$
$$z = re^{i\theta} = r(\cos\theta + i\sin\theta).$$

Euler 公式為

$$e^{i\theta} = \cos\theta + i\sin\theta.$$

複數相乘時，模相乘而幅角相加：

$$(re^{i\theta})(se^{i\phi}) = rse^{i(\theta+\phi)}.$$

整數次冪為

$$(re^{i\theta})^k = r^k e^{ik\theta}.$$

極式與 Euler 公式 （續）

例：

$$1+i=\sqrt{2}e^{i\pi/4},$$
$$(1+i)^8=16e^{2\pi i}=16.$$

幅角加上 2π 仍表示同一個複數；分支的選擇會影響對數等多值函數。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

單位根

解

$$z^n=1.$$

令

$$\omega=e^{2\pi i/n}.$$

所有單位根為

$$1,\omega,\omega^2,\dots,\omega^{n-1}.$$

它們等距落在單位圓上，形成正 n 邊形。

若 $z=re^{i\theta}$ 且 $z^n=1$，則

$$r=1,\qquad n\theta=2\pi k.$$

$n=4$ 時，單位根是 $1,i,-1,-i$。這些根構成 Fourier 基底與循環排列特徵向量的核心。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

單位根 (續)

八次單位根：$z^8=1$ 等距落在單位圓

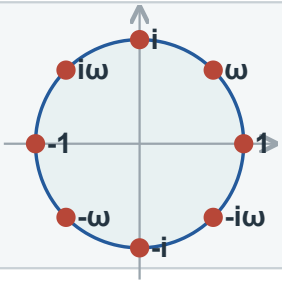

$\omega=e^{(2\pi i/8)}$

roots：$1,\omega,\ldots,\omega^7$

$F_8F_8^H=8I$

columns 正交；Fourier basis

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

複數內積

本章固定

$$\langle u,v\rangle = u^H v = \sum_j \overline{u_j} v_j,$$

其中

$$u^H = \overline{u^T}.$$

若 $u=(1,i)^T$：

$$\|u\|^2 = u^H u = |1|^2 + |i|^2 = 2,$$

不是 $1^2+i^2=0$。

內積具有以下性質：

$$\langle u,v\rangle = \overline{\langle v,u\rangle},$$
$$\langle u,v+w\rangle = \langle u,v\rangle + \langle u,w\rangle,$$
$$\langle u,\alpha v\rangle = \alpha\langle u,v\rangle,$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

複數內積 （續）

$$\langle \alpha u, v \rangle = \overline{\alpha}\, \langle u, v \rangle.$$

本章把共軛固定在第一個引數。若改用其他慣例，所有公式必須同步調整。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

正交性與四個基本子空間

$u \perp v$ 表示

$$u^H v = 0.$$

例：

$$u = (1, i)^T, \qquad v = (1, -i)^T,$$
$$u^H v = (1, -i)(1, -i)^T = 1 + (-i)(-i) = 1 - 1 = 0.$$

複數空間的四個基本子空間改用共軛轉置描述：

$$C(A) \perp N(A^H), \qquad C(A^H) \perp N(A).$$

一般轉置 A^T 不適用，因為它不保證給出複內積下的正交補空間。

維度關係為

$$\dim C(A) = \dim C(A^H) = r,$$
$$\dim N(A) = n - r, \qquad \dim N(A^H) = m - r.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Hermitian 矩陣

方陣 S 是 Hermitian，若

$$S^H = S.$$

逐元素條件為

$$s_{ji} = \overline{s_{ij}}.$$

對角元素必須是實數。對任何 z，

$$(z^H S z)^H = z^H S^H z = z^H S z.$$

1×1 純量等於自己的共軛，故

$$z^H S z \in \mathbb{R}.$$

例：

$$S = \begin{bmatrix} 2 & 1+i \\ 1-i & 3 \end{bmatrix}$$

是 Hermitian。

Hermitian 矩陣的實特徵值與正交特徵向量

若

$$Sz = \lambda z,$$

左乘 z^H：

$$z^H S z = \lambda z^H z.$$

左端是實數，且 $z^H z > 0$，所以 λ 是實數。

若

$$Su = \lambda u, \qquad Sv = \mu v,$$

則

$$\lambda u^H v = (Su)^H v = u^H S v = \mu u^H v.$$

當 $\lambda \neq \mu$，

$$(\lambda - \mu) u^H v = 0,$$

所以 $u \perp v$。

Hermitian 矩陣的實特徵值與正交特徵向量 （續）

完整正交特徵基底的證明與實對稱情形相同：在複單位球上最大化實值 $z^H S z$，由實部、虛部方向的極值條件得到 $Sq = \lambda q$。$q^\perp$ 因 $q^H S v = (Sq)^H v = 0$ 而不變；限制到 $q^\perp$ 的映射仍為 Hermitian，歸納可得完整基底。各重複特徵空間內部再用 Gram-Schmidt，即得譜定理：

$$S = Q \Lambda Q^H,$$

其中 $Q^H Q = I$，且 Λ 為實對角矩陣。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Unitary 矩陣

方陣 $Q \in \mathbb{C}^{n \times n}$ 稱為 unitary，若

$$Q^H Q = I.$$

方陣亦滿足 $QQ^H = I$，所以

$$Q^{-1} = Q^H.$$

它保持內積：

$$\langle Qu, Qv \rangle = (Qu)^H (Qv) = u^H v.$$

因此 $\|Qu\| = \|u\|$。

若 $Qu = \lambda u$：

$$\|u\| = \|Qu\| = |\lambda| \|u\|,$$

所以

$$|\lambda| = 1.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Unitary 矩陣 （續）

行列式也直接反映長度保持：

$$1 = \det(Q^H Q) = (\det Q)^H \det Q = |\det Q|^2,$$

故 $|\det Q| = 1$。實正交矩陣是 unitary 矩陣的實數特例。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

正規矩陣

方陣 A 稱為正規矩陣（normal matrix），若

$$AA^H = A^H A.$$

複方陣可用 unitary 矩陣對角化，若且唯若它是正規矩陣。充分性可用 Schur 形式歸納證明：先取單位特徵向量並擴充為正交歸一基底，矩陣變成 $\begin{bmatrix} \lambda & b^H \\ 0 & C \end{bmatrix}$。正規條件比較 $(1,1)$ 元素，給出 $|\lambda|^2 + \|b\|^2 = |\lambda|^2$，故 $b = 0$；C 仍為正規矩陣，歸納即得 unitary 對角化。必要性可直接由 $A = Q\Lambda Q^H$ 左右相乘驗證。三個常見類別為

- Hermitian：特徵值為實數；
- 反 Hermitian 矩陣 $K^H = -K$：特徵值為純虛數；
- unitary：特徵值的模為 1。

一般可對角化只要求特徵向量基底；unitary 可對角化則要求正交歸一特徵基底。後者是譜幾何中更強的條件。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Hermitian 對角化例子

$$S = \begin{bmatrix} 2 & i \\ -i & 2 \end{bmatrix} = S^H.$$

特徵多項式為

$$\det(S - \lambda I) = (2-\lambda)^2 - |i|^2 = (\lambda - 1)(\lambda - 3).$$

特徵值為 $1, 3$。

對 $\lambda = 3$：

$$\begin{bmatrix} -1 & i \\ -i & -1 \end{bmatrix} z = 0$$

給 $z_1 = iz_2$，取

$$q_1 = (i, 1)^T / \sqrt{2}.$$

對 $\lambda = 1$，取

$$q_2 = (-i, 1)^T / \sqrt{2}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Hermitian 對角化例子 （續）

兩個向量都是單位向量，且 $q_1^H q_2 = 0$。因此

$$S = Q \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} Q^H,$$

$$Q = \frac{1}{\sqrt{2}} \begin{bmatrix} i & -i \\ 1 & 1 \end{bmatrix}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Fourier 矩陣

令

$$\omega = e^{2\pi i/n}.$$

正向 Fourier 矩陣為

$$(F_n)_{jk} = \omega^{jk}, \qquad 0 \le j, k < n.$$

正向轉換為

$$y = F_n c.$$

F_n 是對稱矩陣；當 $n > 2$ 時一般不為 Hermitian，只有 $n = 1, 2$ 時是實對稱矩陣。各 columns 彼此正交：

$$\sum_{j=0}^{n-1} (\omega^{jk})^H \omega^{j\ell} = \sum_{j} \omega^{j(\ell-k)} = n\delta_{k\ell}.$$

所以

$$F_n F_n^H = nI, \qquad F_n^{-1} = F_n^H / n.$$

反 DFT 與 Parseval 恆等式

反轉換為

$$c_j = \frac{1}{n} \sum_{k=0}^{n-1} \omega^{-jk} y_k.$$

若軟體定義

$$\omega = e^{-2\pi i/n},$$

這只表示軟體交換了正向與反向轉換的符號慣例。

Parseval：

$$\|y\|^2 = (F_n c)^H (F_n c) = n\|c\|^2.$$

正規化的 unitary Fourier 矩陣為

$$Q = F_n / \sqrt{n}$$

它滿足 $Q^H Q = I$，故 $\|Qc\| = \|c\|$。正規化不改變轉換所承載的資訊，但會改變 Parseval 公式中的常數。

DFT 與循環卷積

定義循環卷積 $h_j = \sum_{k=0}^{n-1} a_k b_{(j-k) \bmod n}$。它在 Fourier 域中變成逐點相乘：

$$F_n h = (F_n a) \odot (F_n b)$$

證明：將 h_j 代入 $\sum_j \omega^{\ell j} h_j$，令 $s = (j-k) \bmod n$，雙重和分離成 $(\sum_k a_k \omega^{\ell k})(\sum_s b_s \omega^{\ell s})$。此公式使用未正規化 forward DFT；若 forward 除以 $\sqrt{n}$，右端需再乘 $\sqrt{n}$。

FFT、逐點相乘與逆 FFT 合計需 $O(n \log n)$，低於直接計算一般卷積的 $O(n^2)$。若兩序列長度分別為 p, q，線性卷積共有 $p + q - 1$ 項，必須補零到至少這個長度，才不會發生循環繞回。

若公式中的係數順序或符號與卷積定義不一致，結果會悄然改變，因此實作時應寫清楚 NTT／FFT 的慣例。

Radix-2 FFT 的奇偶分解

設 $n = 2m$、$0 \le j < m$。把序列分成

$$c' = (c_0, c_2, \dots, c_{2m-2}),$$
$$c'' = (c_1, c_3, \dots, c_{2m-1}).$$

將 $y_j = \sum_{k=0}^{n-1} c_k \omega_n^{jk}$ 分成偶數 $k = 2s$ 與奇數 $k = 2s+1$ 的兩個和。因 $\omega_n^2 = \omega_m$ 且 $\omega_n^m = -1$，

$$y_j = y'_j + \omega_n^j y''_j,$$
$$y_{j+m} = y'_j - \omega_n^j y''_j.$$

其中 y'、y'' 是兩個大小為 $m = n/2$ 的 DFT。

這就是蝶形（butterfly）運算：把大小為 n 的問題拆成兩個半尺寸子問題，再加上 m 次 twiddle 乘法。遞迴到大小為 1 即完成 FFT。

以 $n = 4$、$c = (1, 2, 0, -1)^T$ 逐步計算。位元反轉先得到

$$(c_0, c_2, c_1, c_3) = (1, 0, 2, -1).$$

Radix-2 FFT 的奇偶分解 （續）

第一層執行兩次兩點蝶形：

$$(1,0) \mapsto (1,1), \qquad (2,-1) \mapsto (1,3).$$

第二層的 twiddle 因數是 $\omega_4^0 = 1, \omega_4^1 = i$：

$$(1,1) \mapsto (2,0), \qquad (1,3) \mapsto (1+3i, 1-3i).$$

因此

$$y = F_4 c = (2, 1+3i, 0, 1-3i)^T.$$

直接代公式亦得 $y_1 = 1 + 2i + (-1)(-i) = 1 + 3i$、$y_3 = 1 - 2i + (-1)i = 1 - 3i$。蝶形的加、減兩支共用同一個乘以 twiddle 的中間值。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Radix-2 FFT 的奇偶分解 （續）

四點 FFT 第一層：分別計算偶序與奇序的兩點 DFT

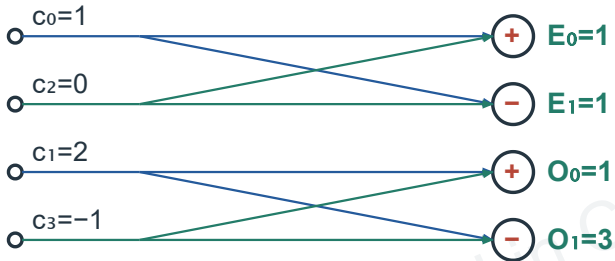

偶序 $(c_0, c_2) = (1, 0)$

$E_0 = c_0 + c_2$，$E_1 = c_0 - c_2$

奇序 $(c_1, c_3) = (2, -1)$

$O_0 = c_1 + c_3$，$O_1 = c_1 - c_3$

各蝶形的上支相加、下支以藍色值減去綠色值；下一圖再組合同索引 E_j、O_j。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

四點 FFT 的重組：哪兩個中間值相配

第一層的陣列位置依序為 $(E_0, E_1, O_0, O_1) = (1, 1, 1, 3)$。第二層必須配對位置 $(0, 2)$ 與 $(1, 3)$：同索引的 E_j、O_j 才能組成 y_j 與 y_{j+2}。圖將兩個重組蝶形分開，以免交叉連線遮住配對關係。

四點 FFT 第二層：同索引的 E_j、O_j 分組重建 y

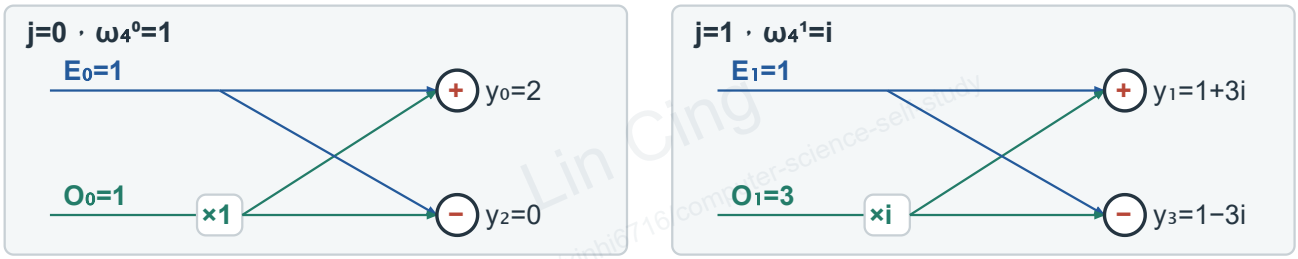

藍支 $u = E_j$，綠支 $\omega v = \omega_4^j O_j$：上支 $u + \omega v$，下支 $u - \omega v$；最後依 y_0, y_1, y_2, y_3 排列。

原例前三個中間值恰巧相等，會掩蓋錯接線。改用 $c = (2, 5, 7, -1)$，第一層為 $(9, -5, 4, 6)$，正確輸出為 $(13, -5 + 6i, 5, -5 - 6i)$。如果錯把 E_0, E_1 配在一起，第一個輸出會變成 $9 + (-5) = 4$，而不是 13。配對索引是演算法的一部分，不能只看一組巧合數值驗證。

遞迴與成本

$n = 2^\ell$：

$$T(n) = 2T(n/2) + \Theta(n).$$

共有 $\ell = \log_2 n$ 層，每層做線性工作量，因此

$$T(n) = \Theta(n \log n).$$

直接以 Fourier 矩陣相乘需要

$$n^2$$

次乘法。

$n = 1024 = 2^{10}$ 時，

$$n^2 = 1,048,576,$$
$$\frac{n}{2} \log_2 n = 5,120.$$

在此乘法成本模型下，兩者比值約為 205。實際執行時間仍受加法、快取、記憶體頻寬、平行化與 twiddle 因數生成影響。

迭代式 FFT 與位元反轉

遞迴 FFT 可改寫為由下而上的階段。$n = 8$ 時，radix-2 輸入通常先排成位元反轉順序：

$$0, 4, 2, 6, 1, 5, 3, 7.$$

再依序執行長度 $2, 4, 8$ 的蝶形：

$$(a, b) \mapsto (a + \omega b, a - \omega b).$$

反轉換可用共軛技巧：先對輸入取共軛、執行正向 FFT、對輸出取共軛，最後除以 n。

當 n 不是 2 的冪時，可使用混合基底（mixed radix）；結構不適合時可用 Bluestein 演算法。實輸入可使用實數 FFT 節省部分工作，但不能假設一般複數 API 會自動完成這些最佳化。

數值注意事項

DFT 的實務問題包括：

- 使用穩定的 twiddle 遞推或預先計算單位根；
- 不要累積大量相位誤差；
- 明確標示使用 F、$F/\sqrt{n}$ 以及反向轉換的符號；
- 補零會改變頻率格點與插值，不會創造新資訊；
- 窗函數能降低 leakage，但也會改變訊號；
- 頻率格點由 $k/(n\Delta t)$ 決定，取決於取樣間隔。

浮點頻譜峰值可能同時包含真實訊號、leakage 與雜訊。不能把一個非零頻格直接當成精確的物理頻率。

章末檢查

讀者應能：

- 計算複數乘積、模、極式冪與單位根；
- 固定 $u^H v$ 的共軛位置慣例，推導正交性；
- 證明 Hermitian 矩陣的特徵值為實數，且不同特徵空間互相正交；
- 建構 $S = Q\Lambda Q^H$；
- 驗證 unitary 矩陣保持長度，且特徵值的模為 1；
- 建 F_n，推導 $F_n F_n^H = nI$；
- 實作 radix-2 蝶形，計算 $\Theta(n \log n)$；
- 解讀符號、正規化、補零與數值極限。

下一章把這些結構應用到網路、工程、Markov 動態、最佳化、Fourier 級數、電腦圖學與密碼學。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

共同結構

本章七個主題反覆使用差分、能量或通量、非負演化、正交投影與座標轉換。下列投影式要求 v_i 是目標子空間的非零正交基底：

$$\text{difference } A, \qquad \text{energy } A^T C A, \qquad u_{k+1} = A u_k,$$

$$\operatorname{proj}_U b = \sum_i \frac{\langle v_i, b \rangle}{\langle v_i, v_i \rangle} v_i.$$

應用題要交代三件事：每個矩陣元素的單位與正負號；哪些等式依賴連通性、正性或邊界條件；以及代數上的可逆性是否足以保證物理存在性與數值可靠性。建立模型時，至少要有守恆律、材料或元件本構關係、適當邊界條件與能量核驗，不能先套矩陣再替係數任意命名。

有向圖與關聯矩陣

圖的節點為 $v_1, \dots, v_n$，邊為 $e_1, \dots, e_m$。本節先排除 self-loop（自迴圈），平行邊則可各自記錄為一個 row。先替每條邊選定方向。關聯矩陣（incidence matrix）$A \in \mathbb{R}^{m \times n}$ 定義為

$$a_{ij} = \begin{cases} -1, & e_i \text{ leaves } v_j, \\ +1, & e_i \text{ enters } v_j, \\ 0, & \text{otherwise}. \end{cases}$$

每條 edge row 的和為零。對 node potential x，

$$(Ax)_i = x_{\text{head}} - x_{\text{tail}}.$$

因此 A 是離散差分算子。反轉一條邊的方向只把該 row 乘上 -1，會改變差分的符號，但平方和與能量不變。

連通圖的 kernel 與 rank

此處的連通指忽略任選方向後的底層無向圖連通，不要求強連通。此時所有邊差分為零，若且唯若全部節點電位相等：

$$N(A) = \operatorname{span}\{\mathbf{1}\}, \qquad \dim N(A) = 1.$$

每條邊所對應的列元素和為零，即 $A\mathbf{1} = 0$，故秩小於 n；這不表示所有列相加的係數都相同。沿連通路徑逐邊使用相等電位，可證核恰為常數向量；再由秩—零度定理得秩 $n-1$。也可用生成樹的 $n-1$ 條獨立邊 rows 證明。因此

$$\operatorname{rank} A = n - 1, \qquad \dim N(A^T) = m - n + 1.$$

欄空間（column space）$C(A) \subseteq \mathbb{R}^m$ 描述可實現的邊電位差；列空間（row space）$C(A^T) \subseteq \mathbb{R}^n$ 位於節點空間，等於常數向量的正交補空間。左零空間 $N(A^T) \subseteq \mathbb{R}^m$ 對應循環流。每條 edge 是矩陣的一個 row，每個 node 是一個 column；這些空間的維度反映圖的拓撲。

循環、流量與 Kirchhoff 定律

$Ax = b$ 有解，若且唯若 $b \in C(A)$。等價條件是：每個循環流 $j \in N(A^T)$ 都滿足

$$j^T b = 0.$$

所以沿封閉迴路的帶號電位差必相加為零；這是 Kirchhoff 電壓定律的線性代數版本。

左零空間包含滿足

$$A^T j = 0.$$

這是邊流量形式。在每個節點，流入減去流出的淨量必須平衡，也就是 Kirchhoff 電流定律。固定一棵生成樹。每條非樹邊與樹上唯一連接路徑形成一個基本循環，依邊方向給予分量 +1、−1 或 0，得到 $A^T j = 0$。每個基本循環只含自己的那一條非樹邊，因此比較非樹邊座標即可證明這些向量獨立。它們共有 $m - n + 1$ 個，等於左零度，故構成循環空間基底。不能任取幾個看來較小的循環就假定獨立或生成全部空間。

對電阻網路，以下固定 $e = Ax$ 為頭端減尾端的電位差，$y = Ce$ 為加權電位差。若 j 表示沿所選邊箭頭的實際電流，Ohm 定律給 $j = -y$；節點的外部注入 f 以正值表示加入，守恆式為 $-A^T j = f$，所以仍有 $A^T y = f$。不能一面使用頭端減尾端，一面把正的 y 說成沿箭頭由低電位流往高電位的電流。

Laplacian 與網路方程

把 conductance $c_e > 0$ 放入 diagonal C，定義 graph Laplacian

$$L = A^T C A.$$

對 potentials x，

$$x^T L x = (Ax)^T C (Ax) = \sum_e c_e (\Delta x_e)^2 \geq 0.$$

因此 L 是對稱半正定矩陣。圖連通且所有 $c_e > 0$ 時，$N(L)$ 只含常數電位。沒有參考電位時，解可加任意常數；電位沒有絕對零點。

選一個節點接地，例如 $x_n = 0$，刪除該 row 與 column，得到 L_{red}。連通性使降階後的矩陣正定。

網路的基本關係為

$$e = Ax, \qquad y = Ce, \quad j = -y, \qquad f = -A^T j = A^T y,$$

合併得

$$A^T C A x = f.$$

Laplacian 與網路方程 （續）

邊的方向選擇不影響 L。若把每條邊相對原方向乘以 $s_e \in \{-1, 1\}$，令

$$D = \operatorname{diag}(s_1, \ldots, s_m), \qquad A' = DA.$$

因為 $D^T = D$、$D^2 = I$，且 C 是對角矩陣，

$$(A')^T C A' = A^T D\, C\, D A = A^T C A.$$

同一條邊的新差分與流量也同步變號 $e' = De$、$y' = Dy$，因此

$$(A')^T y' = A^T D^2 y = A^T y = f.$$

所以方向只改變該邊差分與有號電流的表示正負，不改變 Laplacian、能量、物理通量或節點平衡。

此外，

$$\mathbf{1}^T f = \mathbf{1}^T A^T C A x = (A\mathbf{1})^T C A x = 0,$$

因此沒有外部跨網源時，注入向量 f 的元素總和必須為零。總和不為零屬於模型或資料不一致，不是更換求解器就能修正。

Laplacian 與網路方程 （續）

下圖以三角形 $1 \to 2, 2 \to 3, 1 \to 3$ 固定方向，並把每一列寫成「頭端電位減尾端電位」：

三角形網路的 incidence、定向與電位差

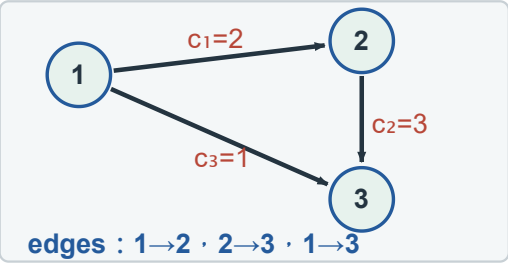

A 的列

[-1, 1, 0]

[0,-1, 1]

[-1, 0, 1]

x=(1,4,7)ᵀ

e₁=4-1=3

e₂=7-4=3

e₃=7-1=6

e=Ax=(3,3,6)ᵀ

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

加權三角形 network

三節點三角形的邊固定為 $1 \to 2, 2 \to 3, 1 \to 3$，電導依序為 $2, 3, 1$。關聯矩陣的每一列是一條定向邊：

$$A = \begin{bmatrix} -1 & 1 & 0 \\ 0 & -1 & 1 \\ -1 & 0 & 1 \end{bmatrix}.$$

定向約定是 $e_i = (Ax)_i = x_{\text{head}} - x_{\text{tail}}$。取 potentials $x = (1, 4, 7)^T$，逐列得到

$$Ax = \begin{bmatrix} 4 - 1 \\ 7 - 4 \\ 7 - 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \\ 6 \end{bmatrix} = e.$$

以 $C = \operatorname{diag}(2, 3, 1)$ 乘上 edge differences：

$$y = Ce = (6, 9, 6)^T.$$

沿既定箭頭的實際電流為 $j = (-6, -9, -6)^T$，即分別反向流動。再乘 A^T 求外部注入，三列分別累加到 node $1, 2, 3$：

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

加權三角形 network （續）

$$f = A^T y = \begin{bmatrix} -6-6 \\ 6-9 \\ 9+6 \end{bmatrix} = \begin{bmatrix} -12 \\ -3 \\ 15 \end{bmatrix}.$$

分量和為 $-12-3+15=0$，這是沒有外部跨網流時的必要守恒。加權 Laplacian 則是

$$L = A^T C A = \begin{bmatrix} 3 & -2 & -1 \\ -2 & 5 & -3 \\ -1 & -3 & 4 \end{bmatrix}, \qquad Lx = f, \quad L\mathbf{1} = 0.$$

A 的 rank 為 2，kernel 是常數向量。若接地令 node 1 的 potential 為 0，刪除第一列與第一欄後，解 $x_2 = 3, x_3 = 6$；把常數 1 平移回去就得到原例 $x = (1,4,7)^T$。固定 source 與 ground 的選取改變 potentials 的零點，不改變 edge differences 與 flows。

加權三角形 network （續）

電流與節點注入：y=CAx，j=−y，f=−A^Tj=A^Ty

加權電位差

C=diag(2,3,1)

e=Ax=(3,3,6)^T

y=Ce=(6,9,6)^T

沿箭頭的電流 j=−y

到節點累加

f=A^Ty=−A^Tj

node 1：-6-6=-12

node 2： 6-9= -3

node 3： 9+6= 15

Σf_i=0

Laplacian

L=[[3,-2,-1],
[-2,5,-3],
[-1,-3,4]]

Lx=f，L1=0

彈簧與 A^TCA

令位移為 u，彈簧伸長量為 $e = Au$，本構關係為

$$y = Ce, \qquad C = \mathrm{diag}(c_i).$$

平衡或節點力平衡為

$$A^T y = f.$$

合併得

$$A^T C A u = f.$$

勁度矩陣 $K = A^TCA$ 對稱半正定。在所有彈簧剛度皆正時，K 正定若且唯若邊界處理後 $N(A) = \{0\}$。對一維連通彈簧鏈，固定足夠參考位移可排除其平移零模態；一般多維結構可能另有轉動或機構零模態，不能只排除平移就宣稱正定。應變能為

$$\frac{1}{2} u^T K u = \frac{1}{2} \sum_i c_i e_i^2.$$

自由平移會使所有 $e_i = 0$，因此常數位移落在 $N(K)$。這正是必須加入邊界條件或參考位移的原因。

彈簧與 A^TCA （續）

有限元素組裝也使用同一模式，把元素矩陣 $A_e^T C_e A_e$ 累加到全域 K。

二階差分與邊界條件

一維桿件有 N 個內部節點、網格寬 h，兩端固定。差分矩陣 A 是 $(N+1)\times N$，作用為 $(u_1, u_2-u_1, \dots, u_N-u_{N-1}, -u_N)^T$，給出

$$K = A^TA = \begin{bmatrix} 2 & -1 & 0 & \cdots \\ -1 & 2 & -1 & \ddots \\ 0 & -1 & 2 & \ddots \end{bmatrix}.$$

忽略 $1/h^2$ 因數，

$$(Ku)_i = 2u_i - u_{i-1} - u_{i+1} \approx -h^2 u''(x_i).$$

固定邊界的已知值移到右端。左固定、右自由時，最後一個對角元素會改變，因為缺少最末端的彈簧。邊界條件屬於矩陣結構，不是排完版後才附加的說明。

兩端自由時，常數位移落在 K 的零空間，因此 K 奇異。外力必須與剛體模式相容，或加入參考位移與反作用力才可解。

工程建模檢查表

建立 $Ku=f$ 前，依序確認：

1. 自由度與單位；
2. 位移、力與伸長量的正負號；
3. 差分矩陣 A；
4. 本構關係的對角矩陣 C；
5. 邊界條件與接地模式；
6. 對稱性與正定性；
7. 能量非負與剛體模式；
8. 隨網格細化變化的條件數。

缺少邊界條件常表現成零特徵值與平移模式。細長元素或係數差異過大，也可能讓本來正定的矩陣有極大條件數。

Markov matrices

欄隨機矩陣（column-stochastic matrix）P 滿足

$$P_{ij} \geq 0, \qquad \sum_i P_{ij} = 1.$$

若 u_k 是機率向量，

$$u_{k+1} = P u_k,$$

則

$$\mathbf{1}^T u_{k+1} = \mathbf{1}^T u_k.$$

Total probability 保持 1。又

$$\mathbf{1}^T P = \mathbf{1}^T,$$

所以 1 是左特徵值，亦在 P 與 P^T 共有的 spectrum 中；一般不代表 $P\mathbf{1} = \mathbf{1}$。Stationary distribution 是右特徵向量，滿足

$$P u_\infty = u_\infty.$$

收斂與 spectral radius

若 P 每個元素嚴格為正，令 $\alpha = n \min_{ij} P_{ij} > 0$。當 $\alpha < 1$，寫 $P = \alpha \mathbf{1}\mathbf{1}^T/n + (1-\alpha)R$，$R$ 仍為 column-stochastic，故對機率向量 u, v，$\|Pu - Pv\|_1 \leq (1-\alpha)\|u - v\|_1$。機率單純形在 ℓ_1 下完備，壓縮映射定理給出唯一 stationary vector 與幾何收斂；$\alpha = 1$ 時一步映成均勻分布。固定點每個分量亦嚴格為正。

允許零元素時，Perron-Frobenius 定理的收斂版本要求轉移圖不可約且非週期。兩條件成立時，仍有唯一的正 stationary distribution，且任意初始機率向量都收斂到它。若週期，例如 $P = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$，則 $P^2 = I$，只有週期二的循環而不收斂；若可約，例如 $P = I$，每個標準基向量都是 stationary vector，極限依初值而異。

若可 diagonalize，eigenvalues 排序為

$$1 = \lambda_1 > |\lambda_2| \geq \cdots,$$

則

$$u_k = P^k u_0 = \sum_i c_i \lambda_i^k v_i.$$

收斂與 spectral radius （續）

第二特徵值控制混合速度：

$$\|u_k - u_\infty\| \le C|\lambda_2|^k.$$

例：

$$P = \begin{bmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{bmatrix}$$

特徵值為 $1, 0.5$。Stationary 向量 $u_\infty = (0.6, 0.4)^T$，非平穩模態每步減半。若矩陣不能對角化，Jordan 分塊會多出 k^{m-1} 因子；此時仍以 spectral radius 判斂，但最簡單的 $C|\lambda_2|^k$ 形式需改寫。

Leslie population 與 consumption economy

Leslie 矩陣把人口分齡：

$$n_{k+1} = L n_k.$$

第一列是生育率，次對角線是存活率。若 Leslie 矩陣的非負有向圖不可約且非週期，Perron-Frobenius 定理保證存在唯一的正 dominant eigenvalue $\lambda > 0$，其特徵向量可正規化成 stable age distribution。長期成長倍率是 λ；若缺少不可約或非週期條件，可能出現週期、多個極限或不同出生群組彼此隔離，不能直接宣稱單一長期分布。

消耗矩陣 A_{ij} 表示部門 j 生產每單位產出所需部門 i 的投入。總產出 p 扣除被消耗的 Ap 後留下

$$(I - A)p = y.$$

若 $\rho(A) < 1$，Neumann 級數收斂：

$$(I - A)^{-1} = I + A + A^2 + \cdots.$$

證明可直接看有限和

$$(I - A)(I + A + \cdots + A^N) = I - A^{N+1}.$$

Leslie population 與 consumption economy （續）

$\rho(A) < 1$ 等價於 $A^N \to 0$，故有限和趨近 $(I - A)^{-1}$。當 $A \geq 0$ 時每一項都非負，所以逆矩陣也非負；任何非負需求 y 都可由

$$p = (I - A)^{-1} y$$

解釋成直接與間接投入所累積的產量。反之，若某個 $|\lambda| \geq 1$，級數不收斂；$I - A$ 在數值上仍可能可逆，但不能保證非負供給與長期可持續性。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

線性規劃的幾何

標準形式為

$$\begin{aligned} &\min\ c^T x, \\ &\text{s.t. } Ax = b, \quad x \geq 0. \end{aligned}$$

例：

$$\min\ 5x_1 + 3x_2 + 8x_3$$

subject to

$$x_1 + x_2 + 2x_3 = 4, \qquad x_1, x_2, x_3 \geq 0.$$

等式在三維空間中是一個平面，非負限制切出三角形，目標函數的水平集是平行平面。可行集非空且目標在可行集上有有限最小值時，至少有一個頂點達到最小值；若可行方向使目標任意下降，則問題 unbounded，不能只檢查頂點就宣稱完成。

在 $A \in \mathbb{R}^{m \times n}$ 已去除冗餘等式、rank 為 m 時，basic feasible solution 選 m 個獨立 columns 作方陣 B，把其餘非基變數設為零，解 $Bx_B = b$，並要求 $x_B \geq 0$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

單體法、對偶與數值注意事項

在基底 B 下，目標值是

$$c_B^T B^{-1} b.$$

非基 column a_j 的 reduced cost 為

$$\bar{c}_j = c_j - c_B^T B^{-1} a_j.$$

若所有 $\bar{c}_j \geq 0$，因可行方向使 x_B 的變化量為 $-B^{-1}a_j t$，目標變化為 $\bar{c}_j t \geq 0$，故目前基本可行解最優。若有 $\bar{c}_j < 0$，令變數 x_j 進入基底，並以 ratio test

$$t = \min_{i:\,(B^{-1}a_j)_i > 0} \frac{x_{Bi}}{(B^{-1}a_j)_i}$$

在所有會限制增加的正分母中，取最小非負比值，選第一個降到零的基本變數離開，才能保持非負；基本值為零也必須參與，結果可以是零步長。若所有分母皆非正，沿此方向可無限增加且目標持續下降，得到無界證書。單體法改變基本可行表示；非退化步驟移到相鄰頂點，退化步驟的點可不動。對具有嚴格可行原問題與對偶的模型，內點法可沿中央路徑逼近最優解；缺乏嚴格可行點時還需前處理或其他可行性處理，不能直接套用下列正的中央路徑。

單體法、對偶與數值注意事項 （續）

Primal 與 dual：

$$\min c^T x \quad \text{s.t. } Ax = b,\ x \geq 0,$$

$$\max b^T y \quad \text{s.t. } A^T y \leq c.$$

可行 primal/dual 配對滿足 weak duality，因

$$c^T x - b^T y = x^T(c - A^T y) \geq 0.$$

只要 primal 與 dual 都可行，雙方可達值相等就是最優證書。有限維 LP 若至少一方可行且最優值有限，strong duality 保證另一方也可達同一值；本章例子更直接，已找到同值的可行 primal 與 dual，所以不必依賴未展示的演算法收斂。最佳 primal 與 dual 還滿足 complementary slackness：

$$x_j(c_j - A_j^T y) = 0.$$

也就是變數為正時其 reduced cost 為零。對偶變數可讀成需求變動的邊際價格，但只在目前最優基底仍有效的局部範圍內。

退化（degeneracy）是某個基本變數為零，可使多個基底對應同一頂點；極小 pivot 是數值風險，不等同於退化。內點法常用

單體法、對偶與數值注意事項 (續)

$$Ax = b, \qquad A^T y + s = c, \qquad x_j s_j = \mu > 0$$

描述中央路徑，再以 Newton 法解線性化修正並讓 $\mu \downarrow 0$。輸出時須同時報告 solver 狀態、原問題／對偶 residual、duality gap 與 conditioning，不能只貼一個最優向量。

一次完整換基與對偶證書

沿用 $\min 5x_1 + 3x_2 + 8x_3$，限制為 $x_1 + x_2 + 2x_3 = 4$、$x \geq 0$。初始基底選 x_3，有 $B = [2]$、$c_B = 8$，因此

$$x_3 = 2 - \tfrac{1}{2}x_1 - \tfrac{1}{2}x_2, \qquad z = 16 + x_1 - x_2.$$

x_2 的 reduced cost 為 -1，讓它進入。方向分母為 $B^{-1}a_2 = 1/2 > 0$，比值 $2/(1/2) = 4$，所以 x_2 增加到 4，x_3 恰降為零。換基後：

$$x_2 = 4 - x_1 - 2x_3, \qquad z = 12 + 2x_1 + 2x_3.$$

所有非基變數的係數皆非負，所以 $x = (0, 4, 0)^T$、$z = 12$ 最優。一般的證明也是將 $x_B = B^{-1}b - \sum_{j \notin B} B^{-1}a_j x_j$ 代回目標，得到 $z = c_B^T B^{-1} b + \sum_{j \notin B} \bar{c}_j x_j$；當 $x_j \geq 0, \bar{c}_j \geq 0$，整個可行域都不會有更小值。

對偶選 $y = 3$，則 $A^T y = (3, 3, 6)^T \leq (5, 3, 8)^T$，對偶值 $4y = 12$。原問題與對偶皆可行且同值，提供獨立的最優證書。正的 x_2 對應緊束的第二個對偶限制；其餘兩項鬆弛量皆為 2。

零比值是合法的退化換基

考慮 $\min -x_1$，限制 $x_1 + s_1 = 0$、$x_1 + s_2 = 1$，所有變數非負。以 (s_1, s_2) 為初始基底時，$(x_1, s_1, s_2) = (0, 0, 1)$。讓 x_1 增加 t：

限制	基本變數隨 t 的變化	正分母	非負比值
1	$s_1 = 0 - t$	1	0
2	$s_2 = 1 - t$	1	1

最小比值是 0，所以 s_1 離開、x_1 進入，但點仍停在同一個可行頂點。若排除零比值而取 $t = 1$，便使 $s_1 = -1$，立即違反可行性。

換基後 $x_1 = -s_1$、$s_2 = 1 + s_1$、目標為 $s_1 \geq 0$，所以原點的目標 0 最優。退化換基可能不改善目標；多次退化甚至可能循環。精確單體法可採 Bland 規則：在所有可改善的非基變數中選索引最小者進入；最小比值平手時選基本變數索引最小者離開。這個規則用於避免循環，不能以忽略零比值取代。

函數作為向量

在 $L^2([0, 2\pi])$ 定義

$$\langle f, g \rangle = \int_0^{2\pi} f(x) g(x)\, dx.$$

複函數要把第一個引數取共軛。L^2 的元素嚴格說是「幾乎處處相等」的函數等價類；若不取等價類，只在單一點非零的函數也會有零範數，違反正定性。可積條件為

$$\|f\|^2 = \int_0^{2\pi} |f(x)|^2\, dx < \infty.$$

$1, \cos nx, \sin nx$ 在此內積下互相正交。例如

$$\int_0^{2\pi} \sin x \cos x\, dx = 0.$$

無限三角系統還要討論完備性（closure）與收斂，才成為 Hilbert 空間的基底。逐點收斂需要額外條件；L^2 收斂是本節使用的自然框架。

Fourier 係數是投影

先看有限截斷：

$$f_N(x) = a_0 + \sum_{n=1}^{N} (a_n \cos nx + b_n \sin nx).$$

與每個基底函數取內積；正交性會消去其他項：

$$a_0 = \frac{1}{2\pi} \int_0^{2\pi} f(x)\, dx,$$
$$a_n = \frac{1}{\pi} \int_0^{2\pi} f(x) \cos nx\, dx,$$
$$b_n = \frac{1}{\pi} \int_0^{2\pi} f(x) \sin nx\, dx.$$

這些公式就是投影到所選三角子空間的最小平方係數。以 2π-週期延拓理解，奇函數的 cosine 係數為零；偶函數的 sine 係數為零。這裡的奇偶性相對於原點，不能只看函數在 $[0, 2\pi]$ 上的局部外形。

令 $e_N = f - f_N$。由於 e_N 與每個已投影的基底函數正交，

Fourier 係數是投影 （續）

$$\|f\|^2 = \|f_N\|^2 + \|e_N\|^2.$$

因此加入下一個獨立正交模態只會把該模態的能量從誤差移到截斷；係數為零的模態不會改變結果。這個 Bessel／Parseval 關係不保證逐點或均勻收斂。收斂速度取決於平滑性、跳躍與邊界條件；有跳躍時，有限截斷會在跳躍附近產生 Gibbs 振盪。

齊次座標

$\mathbb{R}^3$ 的仿射轉換

$$y = Rx + t$$

可在齊次座標中寫成線性矩陣：

$$\begin{bmatrix} y \\ 1 \end{bmatrix} = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ 1 \end{bmatrix}.$$

平移矩陣為

$$T(t) = \begin{bmatrix} I & t \\ 0 & 1 \end{bmatrix}.$$

縮放矩陣為

$$S(s_x, s_y, s_z) = \begin{bmatrix} \operatorname{diag}(s_x, s_y, s_z) & 0 \\ 0 & 1 \end{bmatrix}.$$

齊次座標把

$$(x_0, x_1, x_2, w) \sim (\lambda x_0, \lambda x_1, \lambda x_2, \lambda w)$$

齊次座標 （續）

在 $\lambda \neq 0$ 且齊次向量不是全零時，視為同一個射影點。有限點可正規化為 $w = 1$；方向向量使用 $w = 0$，所以平移不改變方向。

組合圖學轉換

繞點 p 旋轉的步驟是：先把 p 平移到原點，旋轉，再平移回去。以 column vector（欄向量）書寫：

$$T(p)R_\theta T(-p)x.$$

矩陣乘法的順序很重要，最右邊的轉換先作用。

通過原點、單位法向量 n 的平面投影與反射為

$$P = I - nn^T, \qquad M = I - 2nn^T.$$

平面有位移量時，使用齊次平移把它移到原點，投影或反射後再移回。透視投影會先保留非零的齊次分量，再做除法；例如眼睛位於原點、影像平面為 $z = d > 0$ 時，可寫成

$$P_{\text{persp}} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1/d & 0 \end{bmatrix}.$$

對點 $[x, y, z, 1]^T$，得到 $[x, y, z, z/d]^T$，再除以 z/d 就是以眼睛為透視中心的二維影像座標。這是射影轉換，除非齊次座標的除法恰好為常數，否則不保持仿射幾何。裁剪與深度慣例依圖學 API。

有限體與 Hill cipher

質數 p 對應的有限體為

$$\mathbb{F}_p = \{0, 1, \dots, p-1\},$$

加、乘都以 p 取模。每個非零元素都有乘法反元素。矩陣 $K \in \mathbb{F}_p^{n \times n}$ 可逆，若且唯若

$$\det K \not\equiv 0 \pmod{p}.$$

編碼為

$$y = Kx \pmod{p}.$$

解碼為

$$x = K^{-1}y \pmod{p}.$$

這就是 Hill cipher。例如取 $p = 29$、

$$K = \begin{bmatrix} 1 & 2 \\ 3 & 5 \end{bmatrix},$$

則 $\det K = -1 \equiv 28 \pmod{29}$，所以可逆。仿射版本再加上 b，等於在訊息空間中作平移。

安全性與章末檢查

Hill cipher 是線性密碼。已知明文可建立 K 的線性方程；key 很小時也可暴力搜尋。它只適合示範有限體上的線性代數，沒有現代密碼安全性。

本章應能：

- 由連通性決定關聯矩陣的秩與零空間；
- 用接地消除 Laplacian 的 constant nullspace；
- 從 A^TCA 建立 network 或 stiffness equation；
- 計算 Markov steady state 與 second eigenvalue 的收斂速度；
- 以 spectral radius 判斷 productive economy；
- 把 LP 的 constraints、vertices、simplex 與 duality 連起來；
- 以 orthogonal projection 求 Fourier coefficients；
- 維持 homogeneous point 與 direction 的 w convention；
- 在有限體先檢查 modular determinant 再解碼。

下一章把上述 identities 變成可執行 algorithms，並量化它們的 numerical error。

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

三個不能混淆的目標

數值線性代數同時追求：

1. **速度**：flops、記憶體、communication 與 parallelism。
2. **準確度**：計算結果離精確解多遠。
3. **穩定性**：演算法的捨入誤差是否可解釋為輸入的小擾動；這要與問題本身對擾動的敏感性分開。

精確公式不等於穩定演算法；$\det A = 1$ 也不保證逆映射對擾動不敏感。數學上非奇異的矩陣仍可能有很差的數值條件。

誤差必須指定度量：

$$\text{absolute error } \|x - \widehat{x}\|, \qquad \text{relative error } \frac{\|x - \widehat{x}\|}{\|x\|},$$
$$\text{residual } \|b - A\widehat{x}\|.$$

沒有範數、尺度與容差的「誤差很小」無法驗證。

浮點運算與後向誤差

浮點運算的基本模型是

$$\mathrm{fl}(x \circ y) = (x \circ y)(1 + \delta), \qquad |\delta| \le u,$$

其中 u 是單位捨入誤差，假設輸入為已表示的數值、採正常捨入，且未溢位或進入需另處理的下溢範圍。相消不必破壞單次操作的相對模型，但會暴露輸入先前的誤差。累積誤差也受成長因子與條件數影響。

接近相等的數相減會失去有效位數：

$$1.0000001 - 1.0000000 = 1 \cdot 10^{-7}.$$

後向誤差問計算值 $\widehat{x}$ 是否精確解出附近問題：

$$(A + \Delta A)\widehat{x} = b + \Delta b.$$

後向穩定只保證 $\Delta A, \Delta b$ 小；前向誤差仍可能被條件數放大。

Gaussian elimination 與 multipliers

對 pivot d 與下方元素 a_{ik}，乘數為

$$\ell_{ik} = \frac{a_{ik}}{d}.$$

小 pivot 可能產生大乘數，放大既有的捨入誤差。部分選主元在目前 column 選絕對值最大的元素：

$$|d| = \max_{i \geq k} |a_{ik}|.$$

因此 $|\ell_{ik}| \leq 1$，可控制一個常見的成長來源。部分選主元不保證所有矩陣的 growth 最小；特殊結構可能需要完整選主元或 rook pivoting。

消去結果寫成

$$PA = LU.$$

置換矩陣 P 必須與乘數一起處理。實作時只交換 U 的 rows，卻沒有同步交換下三角部分儲存的乘數，是常見錯誤。

Factorization 與 solve workflow

稠密矩陣 $A \in \mathbb{R}^{n \times n}$ 的主要成本為

- 帶選主元的 LU：$\frac{2}{3}n^3 + O(n^2)$ flops；
- 前代 $Ly = Pb$：$O(n^2)$；
- 回代 $Ux = y$：$O(n^2)$。

分解建好後，多個右端向量可重複使用，比每次重做三次方的消去便宜。

安全的求解流程：

1. 帶選主元做分解；
2. 估計範數與條件數；
3. 求解；
4. 計算真實殘差；
5. 需要時做迭代改進；
6. 記錄誤差界與尺度假設。

Factorization 與 solve workflow （續）

不要只看 $\det A$ 或 pivot 是否等於零。行列式可能溢位／下溢，且其大小本身不是尺度不變的條件數指標。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

稀疏矩陣與填入

大型工程矩陣通常稀疏。直接儲存 n^2 個零元素會浪費記憶體，乘法也浪費工作量。

消去是否能保持零元素，取決於排序。星形圖若先消除中央變數，會把所有葉節點連成稠密團；先消除 leaves 可大幅降低填入。

稀疏圖的判讀方式是

- 變數是節點；
- 非零的非對角元素是邊；
- 消除一個節點時，尚未消除的鄰居之間會產生填入邊。

最小度排序、巢狀剖分與反向 Cuthill-McKee 等方法可降低填入或頻寬。平行系統還要考慮通訊與負載平衡，填入數量不是唯一成本。

以下固定同一個小型消去例，

$$A = \begin{bmatrix} 0.001 & 1 \\ 1 & 1 \end{bmatrix}, \qquad b = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

不交換列時，第一個 multiplier 是 $1/0.001 = 1000$，消去後得到

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

稀疏矩陣與填入 （續）

$$U = \begin{bmatrix} 0.001 & 1 \\ 0 & -999 \end{bmatrix}.$$

交換兩列後，multiplier 只有 0.001，且

$$U = \begin{bmatrix} 1 & 1 \\ 0 & 0.999 \end{bmatrix}.$$

兩條路徑在精確算術都給同一解

$$x = \left(\frac{1000}{999}, \frac{998}{999} \right)^T, \qquad Ax - b = 0.$$

圖下半部另以 star graph 顯示 ordering 的稀疏效果。中心先消去時，三個 leaves 兩兩形成三條 fill edges；葉節點先消去時新增 fill edges 為零。數值 growth 與 sparse fill 是兩種不同成本，不能只看同一個 multiplier 或同一個 edge count。

若矩陣的上下頻寬分別為 p, q，只保存 band 內元素可用 $O(n(p+q))$ 記憶體；無 pivot 的 band elimination 約需 $O(npq)$ 工作量，三角求解約 $O(n(p+q))$。三對角矩陣是 $p = q = 1$，因此 LU 與求解都只需 $O(n)$。這些成本結果要求 pivot 不破壞頻寬；需要選主元時，必須把置換與更新後的頻寬一併分析。

稀疏矩陣與填入 （續）

Pivoting：multiplier 大小與同一解

不交換列

A=[[0.001,1],[1,1]]

ℓ_{21}=1000

U=[[0.001,1],[0,-999]]

x=(1000/999,998/999)，Ax-b=0

部分選主元

先交換兩列

ℓ_{21}=0.001

U=[[1,1],[0,0.999]]

稀疏矩陣與填入 （續）

消去排序：星形稀疏圖的 fill edges

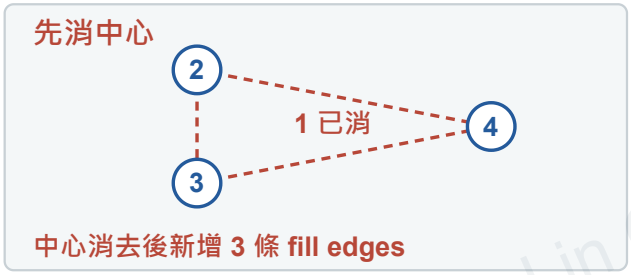

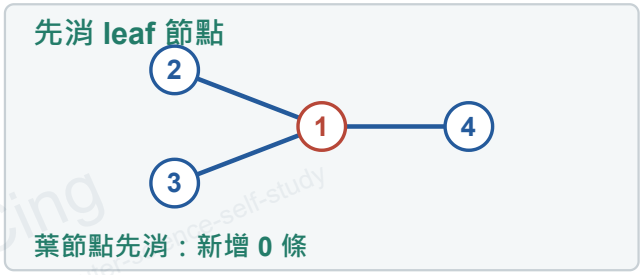

正定消去與 Cholesky

若 $A = A^T$ 正定，對稱消去可寫成

$$A = LDL^T,$$

其中 L 是單位下三角矩陣，D 是正對角矩陣。取

$$R = LD^{1/2}, \qquad A = RR^T$$

得到 Cholesky 分解。它只儲存一個三角部分，約需 $n(n+1)/2$ 個數值元素，領先項成本 $n^3/3$，是一般 LU 的一半。存在性也可由歸納證明：正定矩陣的第一主元 $a_{11} > 0$，消去後

$$S = A_{22} - \frac{1}{a_{11}} a_{21} a_{21}^T$$

仍是正定 Schur 補矩陣，因為對任意 $y \neq 0$，把 $[-(a_{21}^T y)/a_{11};\ y]$ 代入 $x^T A x > 0$ 即得 $y^T S y > 0$。歸納後所有對角 pivots 都正。

正 pivots 同時提供正定性檢查。為 least squares 先形成 $A^T A$ 會使 $\kappa_2(A^T A) = \kappa_2(A)^2$，並可能造成溢位；較佳做法是直接對 A 做穩定 QR。

穩定 QR 與 Householder 反射

Householder 反射矩陣為

$$H = I - 2\frac{vv^T}{v^Tv}.$$

當 $v \neq 0$，它是對稱正交矩陣，故 $H^TH = I$。對非零 x，取 $\alpha = -\operatorname{sign}(x_1)\|x\|$（$x_1 = 0$ 時取 sign 為 1），$v = x - \alpha e_1$。由 $v^Tx = \|x\|^2 - \alpha x_1$、$v^Tv = 2(\|x\|^2 - \alpha x_1)$，得 $Hx = \alpha e_1$。此符號選擇避免 v_1 相減消去有效位數。連續反射 matrices 給

$$R = H_k \cdots H_1 A, \qquad Q = H_1 \cdots H_k,$$

所以 $A = QR$。

Householder QR 通常比古典 Gram-Schmidt 更能保持 Q 的正交性，是稠密最小平方的標準方法。

對滿 column rank 的超定系統 $A \in \mathbb{R}^{m\times n}$，$m \geq n$，rank n，使用完整正交矩陣 $Q \in \mathbb{R}^{m\times m}$：

$$Q^TA = \begin{bmatrix} R \\ 0 \end{bmatrix}, \qquad Q^Tb = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix},$$

穩定 QR 與 Householder 反射 （續）

其中 R 是 $n \times n$ 可逆上三角矩陣。最小平方解解前 n 列：

$$Rx = c_1.$$

若改用薄型分解 $A = Q_1R$，則 $Q_1 \in \mathbb{R}^{m\times n}$，此時才寫 $Rx = Q_1^Tb$。完整 Q^Tb 有 m 個分量，不能直接放在 n 個方程的右端。

最小殘差平方是 $\|c_2\|_2^2$。不要形成 A^TA 或顯式 R^{-1}。稠密 Householder QR 的領先成本約 $2mn^2 - \frac{2}{3}n^3$ flops；形成 Q 會再增加儲存與成本，若只求解則可只套用 reflectors。

Givens 旋轉 G_{ij} 除了第 i, j 列與行交叉的 2×2 區塊外都與單位矩陣相同；一次可將選定的一個元素消成零：

$$G_{ij} = \begin{bmatrix} c & s \\ -s & c \end{bmatrix}, \qquad c^2 + s^2 = 1.$$

它精確保持正交且容易局部平行化，適合 sparse 或帶狀結構；稠密矩陣通常用 Householder，因為每個反射能一次清除整段 column，成本較低。

特徵值的冪法與 QR 迭代

稠密非對稱特徵值問題通常採 QR 迭代，不以高次特徵多項式求根。先在可得的主導特徵值上比較冪法：若

$$A = X\,\mathrm{diag}(\lambda_1,\dots,\lambda_n)X^{-1}, \qquad |\lambda_1| > |\lambda_2| \geq \cdots,$$

且初始向量在 λ_1 的特徵向量方向有非零分量，則 $A^k v_0$ 的方向趨近 λ_1 的特徵向量，速度由 $|\lambda_2/\lambda_1|^k$ 控制。每一步應正規化，避免溢位或下溢。若最大模 eigenvalue 有相同大小，例如旋轉矩陣，方向不會唯一收斂。

反冪法解

$$(A-\mu I)w_{k+1} = w_k$$

再正規化，會放大最接近位移 μ 的特徵向量。Rayleigh quotient

$$\mu_k = \frac{w_k^T A w_k}{w_k^T w_k}$$

常作下一次位移；若 $A-\mu I$ 幾乎奇異，需檢查 solver 狀態，不能把 breakdown 誤當精確收斂。

特徵值的冪法與 QR 迭代 (續)

反冪法的方向收斂敘述承接可對角化假設，還要求 μ 不是特徵值、唯一的 λ_j 與 μ 距離最小，且初始向量在該特徵方向的係數非零。因 $(A-\mu I)^{-1}$ 的特徵值是 $(\lambda_i-\mu)^{-1}$，條件正好化為冪法的唯一最大模條件；兩個特徵值等距時不保證收斂到唯一方向。實對稱矩陣的 Rayleigh 商可用實向量；複數問題應使用 $w^H A w/(w^H w)$。

QR 方法的 unshifted step 為

$$A_k = Q_k R_k, \qquad A_{k+1} = R_k Q_k.$$

因

$$A_{k+1} = Q_k^T A_k Q_k,$$

所以每一步都是 similarity transform，eigenvalues 不變。適當 shift 與 deflation 可收斂到 Schur form。複數算術下是上三角；實算術下可能是含 2×2 共軛特徵值區塊的準上三角，不能只讀每個對角項。未位移 QR 不保證任意矩陣收斂到三角形，例如平面旋轉。

Shifted QR：

$$A_k - \mu_k I = Q_k R_k, \qquad A_{k+1} = R_k Q_k + \mu_k I$$

特徵值的冪法與 QR 迭代 （續）

可加速收斂。實作常先化為 Hessenberg，再做 implicit QR；對稱矩陣則先做三對角縮減。Hessenberg 結構把每一步 QR 的領先工作從 $O(n^3)$ 降到 $O(n^2)$；對稱三對角版本更便宜。大型稀疏矩陣可能需要 Lanczos（Hermitian）或 Arnoldi（general），只保留低維投影再解小特徵值問題；若目標是少數極端特徵值，通常比形成完整分解划算。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

依矩陣結構選擇演算法

演算法選擇取決於結構、條件數與所需輸出：

- 一般稠密 $Ax = b$：帶選主元的 LU；
- 對稱正定：Cholesky；
- overdetermined least squares：Householder QR；
- 大 sparse SPD：preconditioned CG；
- 大 nonsymmetric sparse：GMRES 或 BiCGStab 類方法；
- 長方形矩陣的低秩分析：SVD；
- 稠密非對稱特徵值問題：Hessenberg QR 迭代；
- 對稱特徵值問題：三對角縮減與對稱 QR；
- 奇異值：雙對角 SVD 演算法。

沒有普遍最佳的演算法。分塊與硬體會改變常數，但數學結構先決定方法。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

向量與矩陣範數

常用向量範數為

$$\|x\|_1 = \sum_i |x_i|, \qquad \|x\|_2 = \left(\sum_i |x_i|^2 \right)^{1/2}, \qquad \|x\|_\infty = \max_i |x_i|.$$

誘導矩陣範數定義為

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

二範數下，由 SVD $A = U\Sigma V^T$ 可知

$$\|A\|_2 = \sigma_{\max}(A).$$

其他常用形式為

$$\|A\|_1 = \max_j \sum_i |a_{ij}|, \qquad \|A\|_\infty = \max_i \sum_j |a_{ij}|.$$

Frobenius 範數為

向量與矩陣範數 （續）

$$\|A\|_F = \left(\sum_{ij} |a_{ij}|^2 \right)^{1/2}.$$

它把矩陣視為長向量計量，通常不是誘導算子範數。所有誘導範數都滿足次乘法性 $\|AB\| \le \|A\|\|B\|$：對每個 x，先用 $\|ABx\| \le \|A\|\|Bx\| \le \|A\|\|B\|\|x\|$，再對所有單位向量取最大值。Frobenius 範數也滿足此不等式，但一般不是這個誘導最大成長率。

條件數

可逆矩陣 A 的條件數為

$$\kappa(A) = \|A\|\|A^{-1}\|.$$

右端擾動的相對誤差界為

$$\frac{\|\Delta x\|}{\|x\|} \le \kappa(A)\frac{\|\Delta b\|}{\|b\|}.$$

矩陣擾動的一階近似（精確界見下文）為

$$\frac{\|\Delta x\|}{\|x\|} \lesssim \kappa(A)\frac{\|\Delta A\|}{\|A\|}.$$

二範數下，

$$\kappa_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}}.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

條件數 （續）

右端界由 $\Delta x = A^{-1}\Delta b$ 與 $\|b\| \le \|A\|\|x\|$ 相乘得到，要求 $b \neq 0$。若只擾動矩陣，令 $\epsilon_A = \|\Delta A\|/\|A\|$，並要求 $\kappa(A)\epsilon_A < 1$，則 $(I + A^{-1}\Delta A)\Delta x = -A^{-1}\Delta A x$，Neumann 級數給精確界 $\|\Delta x\|/\|x\| \le \kappa(A)\epsilon_A/[1 - \kappa(A)\epsilon_A]$。大 condition number 表示問題本身敏感，不代表演算法一定寫錯。縮放會改變所用的擾動度量。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

逆矩陣本身的條件數與精確擾動界

設 A 可逆，$B = A + E$，使用相容的誘導範數。若 $\nu = \|A^{-1}E\| < 1$，Neumann 級數給 $(I + A^{-1}E)^{-1}$，因此 B 仍可逆，且

$$B^{-1} = (I + A^{-1}E)^{-1}A^{-1}, \qquad B^{-1} - A^{-1} = -B^{-1}EA^{-1}.$$

由 $\|B^{-1}\| \le \|A^{-1}\|/(1-\nu)$，令 $\varepsilon = \|E\|/\|A\|$，在 $\kappa(A)\varepsilon < 1$ 時得到

$$\frac{\|B^{-1} - A^{-1}\|}{\|A^{-1}\|} \le \frac{\kappa(A)\varepsilon}{1 - \kappa(A)\varepsilon}.$$

逆矩陣映射的一階變化是 $D\,\mathrm{inv}_A[E] = -A^{-1}EA^{-1}$，而不是逐元素取倒數。二範數下，這個相對條件數恰為 $\kappa_2(A)$，不只是上界：寫 $A = U\Sigma V^T$，沿最小奇異值方向取 $E = -\delta u_n v_n^T$，其中 $0 < \delta < \sigma_n$。其餘奇異方向不變，最小方向由 σ_n 減為 $\sigma_n - \delta$，所以

$$\frac{\|(A+E)^{-1} - A^{-1}\|_2}{\|A^{-1}\|_2} = \frac{\delta}{\sigma_n - \delta} = \frac{\kappa_2(A)(\delta/\sigma_1)}{1 - \kappa_2(A)(\delta/\sigma_1)}.$$

這個擾動使上界取等號；$\delta \uparrow \sigma_n$ 時接近奇異邊界。固定 b 的解向量敏感度、逆矩陣整體敏感度與演算法後向穩定性，是三個不同的敘述。

殘差、誤差與可驗證檢查

令真解為 x、計算解為 $\widehat{x}$：

$$e = x - \widehat{x}, \qquad r = b - A\widehat{x} = Ae.$$

所以

$$e = A^{-1}r, \qquad \|e\| \le \|A^{-1}\|\|r\|.$$

小殘差只有在 $\|A^{-1}\|$ 可控時，才保證小的前向誤差。

例：$A = 10^{-12}$、真解 $x = 1$、計算解 $\widehat{x} = 1 + \delta$，則

$$r = -10^{-12}\delta$$

可以極小，relative error 卻仍是 δ。

這個一維例子的相對條件數其實是 1；它展示絕對殘差受尺度影響，不是展示相對病態。相對殘差 $|r|/|b| = |\delta|$ 與相對解誤差仍相同。

正規化後向誤差為

殘差、誤差與可驗證檢查 （續）

$$\eta = \frac{\|r\|}{\|A\|\|\widehat{x}\| + \|b\|}.$$

η 小表示此計算結果具有小的 normwise 後向誤差，不能單憑一次結果宣稱整個演算法對所有輸入都後向穩定。此處分母使用已算出的 $\widehat{x}$，不是未知真解。前向誤差仍由條件數控制。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

特徵值與奇異向量的條件

若矩陣可對角化：

$$A = X\Lambda X^{-1},$$

特徵值擾動可能被 $\kappa(X) = \|X\|\|X^{-1}\|$ 放大。正規矩陣有正交歸一特徵基底，特徵值的條件通常較好。

非正規矩陣可能特徵值聚在一起，卻有敏感的特徵向量與很大的暫態放大。

奇異值的擾動較穩定。Weyl 不等式為

$$|\sigma_i(A + E) - \sigma_i(A)| \le \|E\|_2.$$

但奇異值彼此很接近時，奇異向量仍可能敏感。Numerical rank 需要容差與應用背景。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

數值秩與偽逆門檻

若

$$\sigma_1 \geq \cdots \geq \sigma_r \gg \sigma_{r+1} \geq \cdots,$$

常用門檻

$$\sigma_i > \tau \sigma_1$$

來判斷數值秩。τ 需考慮機器精度、維度與資料雜訊。

截斷偽逆為

$$A_\tau^+ = V_r \operatorname{diag}(\sigma_1^{-1}, \ldots, \sigma_r^{-1}) U_r^T.$$

它精確解出截斷模型，不是原完整矩陣的精確逆。報告時要附 τ、rank、residual 與誤差度量。

定常迭代的分割

選定分割

$$A = S - T,$$

其中求解 S 較便宜。原方程等價於

$$Sx = Tx + b.$$

迭代為

$$Sx_{k+1} = Tx_k + b.$$

令

$$G = S^{-1}T, \qquad c = S^{-1}b,$$

則

$$x_{k+1} = Gx_k + c.$$

與精確解相減，得

$$x - x_{k+1} = G^{k+1}(x - x_0).$$

定常迭代的分割 （續）

對可逆 S 且 $Ax = b$ 有唯一解時，所有初始猜測都收斂，若且唯若

$$\rho(G) < 1.$$

證明：若所有初始誤差皆衰減，取複特徵向量可知每個特徵值模必小於 1。反之，Jordan 分塊的 G^k 項是有限次多項式乘 λ^k，$|\lambda| < 1$ 使其趨零。因此 $G^k \to 0$。這是 spectral-radius 條件，不是逐元素比較 S 與 T。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Jacobi、Gauss-Seidel 與 SOR

固定 $A = D + L + U$，其中 L, U 是原矩陣的嚴格下、上三角部分，且假設所有 $a_{ii} \neq 0$。Jacobi 方法取

$$S = D, \qquad T = -(L + U),$$

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right).$$

所有更新使用舊值，容易平行化。

Gauss-Seidel 方法取

$$S = D + L, \qquad T = -U,$$

新算出的下三角數值立即使用：

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)} \right).$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Jacobi、Gauss-Seidel 與 SOR （續）

嚴格列對角優勢使 Jacobi 的 $\|G_J\|_\infty < 1$，亦可保證 Gauss-Seidel 收斂。SPD 保證 Gauss-Seidel 收斂，但不保證 Jacobi；例如對角為 1、其餘項為 0.9 的 3×3 SPD 矩陣，其 Jacobi 迭代矩陣有特徵值 -1.8，故發散。

SOR 逐分量 relaxation，必須使用本輪已更新的 relaxed lower components：

$$x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \frac{\omega}{a_{ii}}\left(b_i - \sum_{j<i} a_{ij}x_j^{(k+1)} - \sum_{j>i} a_{ij}x_j^{(k)}\right).$$

對 SPD，$0 < \omega < 2$ 保證 SOR 收斂，$\omega = 1$ 即 Gauss-Seidel。不可先完成一整輪未鬆弛的 GS 再將整個向量平均，因為那是不同的迭代矩陣。收斂可由每次座標能量改變 $\phi(x_{\text{new}}) - \phi(x_{\text{old}}) = -\omega(2-\omega)r_i^2/(2a_{ii}) \le 0$ 證明；若一輪仍有非零殘差則嚴格下降，SPD 使能量有下界，故各座標的能量下降量趨零，進而每次更新量 $\omega r_i/a_{ii}$ 趨零。固定有限個座標下，同一輪各中間點的差也趨零，故各座標更新前的殘差趨零推出輪首整個殘差向量趨零。由 $x_* - x = A^{-1}r$，迭代收斂到唯一解。

收斂與失敗例子

對

$$A = \begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix},$$

Jacobi 矩陣

$$G_J = -D^{-1}(L+U) = \begin{bmatrix} 0 & -1/4 \\ -1/3 & 0 \end{bmatrix}.$$

因

$$G_J^2 = \begin{bmatrix} 1/12 & 0 \\ 0 & 1/12 \end{bmatrix},$$

故

$$\rho(G_J) = 1/\sqrt{12} < 1,$$

Jacobi 收斂。

對角為零的矩陣

收斂與失敗例子 （續）

$$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

無法直接套 Jacobi，因為會除以零。置換變數有時可修正，但非零對角線本身不保證收斂。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

對稱正定系統的共軛梯度法

實對稱正定 A 的 A-內積為

$$\langle u, v \rangle_A = u^T A v.$$

二次能量為

$$\phi(x) = \frac{1}{2} x^T A x - b^T x.$$

其唯一最小值點就是 $Ax = b$ 的解。CG 在 Krylov 子空間中選擇 A-正交搜尋方向；精確算術下最多 n 步到達精確解。

共軛梯度法（CG）要求實對稱正定 A，並指定初值 x_0（未指定時取零向量）、非負容許值 $\mathrm{atol}, \mathrm{rtol}$ 與迭代上限。令 $\tau = \max(\mathrm{atol}, \mathrm{rtol}\|b\|_2)$，先算 $r_0 = b - Ax_0$。若 $\|r_0\|_2 \le \tau$，立即回傳 x_0，不計算任何步長；否則令 $p_0 = r_0$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

對稱正定系統的共軛梯度法 （續）

第 k 輪計算 $q_k = Ap_k$、$\alpha_k = (r_k^T r_k)/(p_k^T q_k)$，再更新 $x_{k+1} = x_k + \alpha_k p_k$、$r_{k+1} = r_k - \alpha_k q_k$。新殘差達門檻時，用原方程重算 $b - Ax_{k+1}$ 確認後回傳。否則算 $\beta_k = (r_{k+1}^T r_{k+1})/(r_k^T r_k)$，令 $p_{k+1} = r_{k+1} + \beta_k p_k$。精確算術的非零搜尋方向滿足 $p_k^T A p_k > 0$；浮點計算若分母非正或非有限數，應回報數值失敗，不能當成收斂。若遞迴殘差已過門檻、真實殘差卻未過，則以真實殘差取代遞迴殘差，重新令 $p = r$ 開始新一輪方向建構，不能沿用幾乎為零的舊殘差。達迭代上限但真實殘差仍超標，回報未收斂。

CG 初始化：先算 r_0，再決定是否進入迭代

若未達門檻，才建立 $p_0=r_0$ 並進入迭代。

對稱正定系統的共軛梯度法 （續）

CG 迭代：分母檢查、更新與真實殘差

真實殘差達標：收斂；未達且已到上限：iteration_limit

遞迴殘差達標、真實未達：$r \leftarrow b-Ax$，$p \leftarrow r$（重啟）

其餘未達標情形：計算 β、更新 p，再回到 $q=Ap$

基例 $A = [1], b = [0], x_0 = [0]$ 的初始殘差為零，零輪返回；直接算步長會得到 $0/0$。非零例取 $A = \begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix}, b = (1,2)^T, x_0 = 0$。第零輪 $r_0 = p_0 = (1,2)^T$、$Ap_0 = (6,7)^T$，故 $\alpha_0 = 5/20 = 1/4$，$x_1 = (1/4, 1/2)^T$、$r_1 = (-1/2, 1/4)^T$。再得 $\beta_0 = 1/16$、$p_1 = (-7/16, 3/8)^T$、$\alpha_1 = 4/11$，所以 $x_2 = (1/11, 7/11)^T$，直接代回得 $Ax_2 = b$。

對稱正定系統的共軛梯度法 （續）

精確線搜尋與上述 β_k 使殘差兩兩正交、搜尋方向兩兩 A-共軛。非零共軛方向線性獨立，至多 n 個，故精確算術在至多 n 個非平凡步驟終止。浮點算術可能失去正交性，因此有限終止定理不能取代殘差準則。每輪一次矩陣向量乘法與常數次向量內積，時間為 $O(\mathrm{nnz}(A)+n)$，記憶體只保留固定數量的長度 n 向量，不形成逆矩陣。

在標準誤差能量範數下，有

$$\|x-x_k\|_A \le 2\left(\frac{\sqrt{\kappa_2(A)}-1}{\sqrt{\kappa_2(A)}+1}\right)^k \|x-x_0\|_A.$$

這個界顯示 ill-conditioned 系統可能很慢，但 eigenvalue 聚集成少數群時，通常比只依 κ_2 的估計更快。CG 的標準形式要求 A 和 preconditioner 都維持 SPD。

CG 的正確性：Krylov 空間與能量極小性

以下完全使用精確算術。令真解為 x_*，定義 $\mathcal{K}_0=\{0\}$ 與

$$\mathcal{K}_k=\mathrm{span}\{r_0,Ar_0,\dots,A^{k-1}r_0\}.$$

第 k 輪開始時，歸納維持：舊方向 $p_0,\dots,p_{k-1}$ 張成 $\mathcal{K}_k$ 且兩兩 A-共軛；$x_k\in x_0+\mathcal{K}_k$；$r_k=b-Ax_k\perp\mathcal{K}_k$。這也證明 x_k 是該仿射空間的唯一能量極小點，因為對 $z\in\mathcal{K}_k$，

$$\phi(x_k+z)-\phi(x_k)=-z^Tr_k+\tfrac12 z^TAz=\tfrac12 z^TAz,$$

非零 z 時嚴格為正。$k=0$ 時不變量直接成立。又 $r_k=r_0-A(x_k-x_0)\in\mathcal{K}_{k+1}$；若 $r_k\neq0$，它與 $\mathcal{K}_k$ 正交，必增加一個獨立方向。

$k=0$ 取 $p_0=r_0$；$k\ge1$ 時令 $p_k=r_k+\beta_{k-1}p_{k-1}$。對 $i\le k-2$，$Ap_i\in\mathcal{K}_{i+2}\subseteq\mathcal{K}_k$，故 $p_i^TAr_k=(Ap_i)^Tr_k=0$；配合舊方向的共軛性，只需消去與上一個方向的 A-內積：

$$\beta_{k-1}=-\frac{p_{k-1}^TAr_k}{p_{k-1}^TAp_{k-1}}.$$

因 $r_k=r_{k-1}-\alpha_{k-1}Ap_{k-1}$，而 $r_{k-1}\in\mathcal{K}_k$，得

CG 的正確性：Krylov 空間與能量極小性 （續）

$$\|r_k\|^2 = -\alpha_{k-1} r_k^T A p_{k-1}.$$

代入 $\alpha_{k-1} = \|r_{k-1}\|^2 / (p_{k-1}^T A p_{k-1})$，正好得到 $\beta_{k-1} = \|r_k\|^2 / \|r_{k-1}\|^2$。因此這個短遞推確實使新方向與所有舊方向共軛。新方向與非零殘差只差舊方向的倍數，故加入它後恰張成 $\mathcal{K}_{k+1}$。

沿新方向最小化能量，導數為 $-p_k^T r_k + \alpha p_k^T A p_k$。由 $p_k^T r_k = \|r_k\|^2$ 得到演算法的 α_k。更新後 $p_k^T r_{k+1} = 0$；對 $i < k$，

$$p_i^T r_{k+1} = p_i^T r_k - \alpha_k p_i^T A p_k = 0.$$

故 $r_{k+1} \perp \mathcal{K}_{k+1}$，不變量延續。每個舊殘差 $r_i \in \mathcal{K}_{i+1}$，所以殘差兩兩正交。若 $\sum c_i p_i = 0$，左乘 $p_j^T A$ 得 $c_j p_j^T A p_j = 0$，故非零共軛方向必獨立，至多 n 個。若未提早終止，第 n 步殘差與整個 $\mathbb{R}^n$ 正交，只能為零。這完成有限終止的證明。

CG 的條件數誤差界從哪裡來

令 $e_k = x_* - x_k$。由能量極小性，CG 在 $x_0 + \mathcal{K}_k$ 中使 $\|e_k\|_A$ 最小。因 $r_0 = A e_0$，這裡的每個誤差可寫為 $p(A) e_0$，其中 $\deg p \le k, p(0) = 1$。在 $A = Q \Lambda Q^T$ 的特徵座標展開，得到

$$\|e_k\|_A \le \min_{\deg p \le k,\, p(0)=1} \max_{i} |p(\lambda_i)| \, \|e_0\|_A.$$

設 $a = \lambda_{\min} > 0$、$b = \lambda_{\max} > a$。Chebyshev 多項式滿足 $T_k(\cos\theta) = \cos(k\theta)$，故在 $[-1, 1]$ 上絕對值至多 1。選

$$p(t) = \frac{T_k\big((b + a - 2t)/(b - a)\big)}{T_k\big((b + a)/(b - a)\big)}.$$

它有 $p(0) = 1$，且把 $[a, b]$ 送入分子的 $[-1, 1]$。由餘弦加法公式得到遞推 $T_{k+1}(z) = 2 z T_k(z) - T_{k-1}(z)$，配合 $T_0 = 1, T_1 = z$，可驗證下式。對 $z > 1$，$T_k(z) = (\rho^k + \rho^{-k})/2$，其中 $\rho = z + \sqrt{z^2 - 1}$。令 $\kappa = b/a$，代入 $z = (b + a)/(b - a)$ 得 $\rho = (\sqrt{\kappa} + 1)/(\sqrt{\kappa} - 1)$，所以

$$\|e_k\|_A \le 2 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|e_0\|_A.$$

CG 的條件數誤差界從哪裡來 （續）

$a=b$ 時 $A=aI$，非零殘差一次步長 $1/a$ 即解出，需另外處理而非除以 $b-a=0$。利用特徵值群集可選更好的多項式；此區間界不一定緊。證明依賴精確正交性，浮點實作仍以真實殘差驗收。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

延伸補充：複 Hermitian 正定系統的 CG

本頁是原書 11.3 節之外的嚴謹延伸；原書 CG 段落要求實對稱正定矩陣，不能把同一套 r^Tr 公式直接套到複矩陣。若

$$A^H=A,\qquad z^HAz>0\quad (z\neq 0),$$

則 A 是 Hermitian 正定矩陣。複內積固定為 u^Hv，所以例行的實數公式改成

$$r_k=b-Ax_k,\qquad \alpha_k=\frac{r_k^Hr_k}{p_k^HAp_k},$$

$$x_{k+1}=x_k+\alpha_kp_k,\qquad r_{k+1}=r_k-\alpha_kAp_k,$$

$$\beta_k=\frac{r_{k+1}^Hr_{k+1}}{r_k^Hr_k},\qquad p_{k+1}=r_{k+1}+\beta_kp_k.$$

因為 A 是 Hermitian，$p_k^HAp_k$ 是實數；正定性使非零方向的分子、分母都為正。容差仍使用 $\|r_k\|_2=\sqrt{r_k^Hr_k}$，而且必須先計算 r_0。若 $r_0=0$，立即回傳 x_0，不得計算 $0/0$。若使用預條件子，M 也必須是 Hermitian 正定，並採保持對稱性的等價變數變換。實數證明改以共軛內積後仍成立，所有能量與步長為實正數。檢查 $A^T=A$ 不能代替 $A^H=A$；複對稱的 $[i]$ 就沒有實正能量。

延伸補充：複 Hermitian 正定系統的 CG （續）

實對稱正定矩陣是上述公式的特例，此時 conjugate 不改變實數。這一區分正是避免把實 SPD 與複 Hermitian PD 混用的必要條件。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

非對稱系統的 GMRES

本節先令 $A \in \mathbb{R}^{n \times n}$。複數版本的 Arnoldi 內積須改用共軛轉置。原書提及非對稱系統可用 GMRES；本頁的 Arnoldi 與最小平方 reconstruction 屬本教材補充，不冒充原書節次。GMRES 在 Krylov 子空間

$$\mathcal{K}_k(A, r_0) = \operatorname{span}\{r_0, Ar_0, \dots, A^{k-1} r_0\}$$

上最小化 residual：

$$\min_{x \in x_0 + \mathcal{K}_k} \|b - Ax\|_2.$$

Arnoldi 從 $v_1 = r_0 / \|r_0\|$ 開始，對 $w = Av_j$ 逐一減去 $h_{ij} v_i$，其中 $h_{ij} = v_i^T w$，最後以 $h_{j+1,j} = \|w\|$ 正規化，得到 $AV_k = V_{k+1} \overline{H}_k$。寫 $x = x_0 + V_k y$，則 residual norm 等於 $\|\|r_0\| e_1 - \overline{H}_k y\|_2$，解此小型 least-squares 即得到 GMRES iterate。若 $r_0 = 0$ 直接完成；Arnoldi 零剩餘方向需判斷收斂或 breakdown。Restart 限制 storage，但丟棄舊方向而可能停滯。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

非對稱系統的 GMRES （續）

非正規矩陣的特徵值大小不足以單獨預測 GMRES 暫態；field of values、pseudospectra 與實際殘差歷程更有資訊。應監控真實殘差，不只遞迴殘差。未重啟的 GMRES 每個 Arnoldi 步驟多做一次矩陣向量乘法與對所有既有方向的正交化工作。$k \le n$ 步後，不含儲存原矩陣的額外空間為 $O(kn)$，時間為 $O(k\,\mathrm{nnz}(A) + k^2 n)$；稠密矩陣的矩陣向量乘法部分是 $O(kn^2)$，不能省略；以 GMRES(m) 重啟會把空間固定在 $O(mn)$，但可能失去收斂性而停滯。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

GMRES 第一輪：Arnoldi 與殘差最小化

取非對稱可逆矩陣與初值

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad x_0 = 0.$$

初始殘差為 $r_0 = b$，$\beta = \|r_0\|_2 = 1$，故 $v_1 = e_2 = (0,1)^T$。第一輪 Arnoldi 逐步得到

$$w = A v_1 = (1,1)^T, \quad h_{11} = v_1^T w = 1,$$
$$w \leftarrow w - h_{11} v_1 = (1,0)^T, \quad h_{21} = 1, \quad v_2 = e_1.$$

因此 $\overline{H}_1 = (1,1)^T$。小型最小平方只有一個未知數：

$$\min_{y} \left\| \begin{bmatrix} 1 \\ 0 \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \end{bmatrix} y \right\|_2^2 = \min_{y} \big((1-y)^2 + y^2 \big).$$

由 $4y - 2 = 0$ 得 $y = 1/2$。重建 $x_1 = V_1 y = (0, 1/2)^T$，真實殘差為 $r_1 = b - A x_1 = (-1/2, 1/2)^T$，所以 $\|r_1\|_2 = 1/\sqrt{2}$。實際檢查 $(A v_1)^T r_1 = 0$；殘差垂直於 **輸出方向** $A\mathcal{K}_1$，不是要求垂直於輸入方向 $\mathcal{K}_1$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

GMRES 的輸入搜尋與輸出投影

本例輸入空間與輸出空間雖都為 $\mathbb{R}^2$，角色不同。左圖追蹤未知數 x；右圖把 b 投影到 $A\mathcal{K}_1 = \text{span}\{(1,1)^T\}$。兩圖座標各自同尺度，右圖的直角對應 $(Av_1)^T r_1 = 0$。

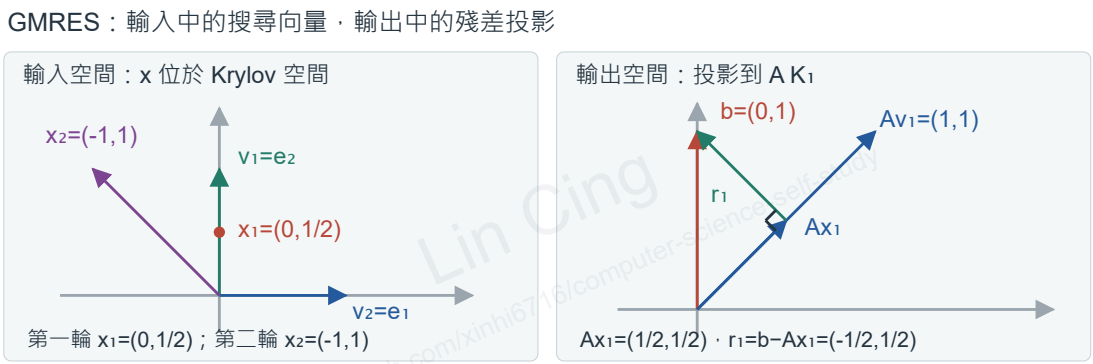

r₁ ⊥ A K₁；不必垂直於輸入空間 K₁

GMRES 第二輪：零 Arnoldi 餘項與精確終止

已有 $V_2 = [v_1, v_2] = [e_2, e_1]$。第二輪從 $w = Av_2 = e_1$ 開始：

運算	數值結果
$h_{12} = v_1^T w$	0；w 不變
$h_{22} = v_2^T w = 1$	減去 $h_{22}v_2$ 後，$w = (0,0)^T$
$h_{32} = \|w\|_2$	0；不可再除以此值建立 v_3

此時 Krylov 空間已是整個 $\mathbb{R}^2$，且 $AV_2 = V_2 H_2$，其中

$$H_2 = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}, \qquad H_2 y = \beta e_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

第一列得 $y_1 = 1$，第二列得 $y_1 + y_2 = 0$，故 $y = (1,-1)^T$，重建

$$x_2 = V_2 y = e_2 - e_1 = (-1,1)^T, \qquad Ax_2 = (0,1)^T = b.$$

真實殘差為零，故為 happy breakdown（找到精確解的正常終止）。一般零餘項只表示搜尋空間不再擴張，仍須以原方程的殘差判定收斂。

預條件子

預條件子 $M \approx A$ 要便宜、可平行，而且讓 $M^{-1}A$ 較容易迭代。左預條件為

$$M^{-1}Ax = M^{-1}b.$$

右預條件先令

$$AM^{-1}y = b, \qquad x = M^{-1}y$$

它改變變數，但保留原殘差的解釋。

常見選擇：

- diagonal/Jacobi；
- block Jacobi；
- incomplete LU 或 incomplete Cholesky；
- algebraic multigrid；
- domain decomposition；
- physics-informed approximation。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

預條件子 （續）

預條件子的價值需比較設定、每輪與通訊總成本，不能只看迭代數。左預處理殘差是 $M^{-1}(b - Ax)$，應另算原問題的真實殘差；用 CG 時應採保持 SPD 的等價對稱變數變換，而非把任意非對稱 $M^{-1}A$ 當成 SPD 矩陣。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

停止準則與重現性

每次求解至少記錄：

1. 初始殘差；
2. 相對殘差下降量；
3. 所用的範數與尺度；
4. 最大迭代次數與 timeout；
5. 函式庫回報的收斂／breakdown 狀態；
6. 最終真實殘差；
7. 條件數或誤差估計；
8. 可重現的 seed 與第二次執行核對。

後向誤差應相對 $\|A\|\|x\| + \|b\|$ 評估。迭代遞迴殘差可能因捨入變得很小，真實殘差卻沒有同步變小。

章末檢查

讀者應能：

- 解釋部分選主元，並區分乘數成長與條件數；
- 估算 LU、QR、Cholesky 的成本，利用 ordering 降低 fill；
- 推導條件數誤差界，並區分 residual 與前向誤差；
- 計算向量／矩陣範數，使用 SVD 分析二範數 conditioning；
- 以 $\rho(S^{-1}T)$ 判斷定常迭代；
- 寫出 Jacobi、Gauss-Seidel、SOR，並說明適用條件；
- 解釋 CG、複 Hermitian 延伸、GMRES、Krylov 子空間、restart 與預條件；
- 報告 rank tolerance、residual、收斂狀態與數值假設。

最後一章把 covariance、Gaussian model 與 weighted least squares 接到機率統計。

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

樣本與期望值

在離散或具有密度的情形，令樣本空間為 Ω，可測事件 $E \subseteq \Omega$ 的機率 $P(E)$ 滿足 $P(E) \geq 0$、$P(\Omega) = 1$，且對可數個互斥事件滿足機率可數可加性。隨機變數 $X \colon \Omega \to \mathbb{R}$ 把樣本結果映成數字；$P(X \leq x)$ 就是事件 $\{\omega : X(\omega) \leq x\}$ 的機率。本章只使用離散機率質量函數與一般機率密度函數兩種表示，不引入進階測度理論。期望值是依分布加權的平均；若一階絕對矩不有限，這個期望可能不存在。

樣本觀測值 $x_1, \ldots, x_N$ 是已觀察到的數值，$N \geq 1$。涉及期望值時假設一階絕對矩有限；變異數、共變異數與本章的線性變換公式假設所有分量二階矩有限。樣本平均數：

$$\overline{x} = \frac{1}{N} \sum_{i=1}^{N} x_i.$$

隨機變數 X 的理論平均數：

$$\mu = \mathbb{E}[X].$$

樣本與期望值 （續）

離散結果 a_i 與機率 p_i：

$$\mathbb{E}[X] = \sum_{i=1}^{k} p_i a_i.$$

連續型密度 f_X：

$$\mathbb{E}[X] = \int x f_X(x)\, dx.$$

蒐集後的樣本平均數是數值摘要，蒐集前則是隨機統計量；期望值是機率模型的性質。兩者公式相似，解釋不同。

變異數與 $N-1$

固定的樣本觀測值：

$$\overline{x} = \frac{1}{N}\sum_{i=1}^{N} x_i.$$

常用的不偏樣本變異數：

$$s^2 = \frac{1}{N-1}\sum_{i=1}^{N}(x_i - \overline{x})^2.$$

母體變異數：

$$\operatorname{Var}(X) = \mathbb{E}[(X-\mu)^2] = \mathbb{E}[X^2] - \mu^2.$$

$N \geq 2$ 才能使用 $N-1$ 分母。對 i.i.d. 有限變異數樣本，用恆等式 $\sum_i (X_i - \overline{X})^2 = \sum_i (X_i-\mu)^2 - N(\overline{X}-\mu)^2$，兩邊取期望得到 $N\sigma^2 - N(\sigma^2/N) = (N-1)\sigma^2$。因此

$$\mathbb{E}[s^2] = \sigma^2.$$

變異數與 $N-1$ （續）

若只想描述完整有限母體的平均離差平方，除以 N 可能才符合目的。報告時要標明是描述統計量或估計量。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

線性轉換後的平均與變異數

對常數 a, b：

$$\mathbb{E}[aX + b] = a\mathbb{E}[X] + b,$$
$$\operatorname{Var}(aX + b) = a^2 \operatorname{Var}(X).$$

平移改變中心，不改變分散程度；負的 a 仍使變異數乘上 a^2，但反轉方向。

獨立 X, Y：

$$\operatorname{Var}(X + Y) = \operatorname{Var} X + \operatorname{Var} Y.$$

不獨立時：

$$\operatorname{Var}(X + Y) = \operatorname{Var} X + \operatorname{Var} Y + 2\operatorname{Cov}(X, Y).$$

這是共變異矩陣的純量形式。獨立性在有限變異數下推出零共變異數；零共變異數一般不推出獨立性。

機率密度、累積分布與均勻分布例子

累積分布函數（cumulative distribution function, CDF）定義為 $F_X(x) = P(X \le x)$。對具有密度的絕對連續隨機變數，CDF 的導數幾乎處處存在且為密度；僅 CDF 連續不充分。此時

$$F_X(x) = \mathbb{P}(X \le x), \qquad f_X(x) = F_X'(x).$$

區間機率：

$$\mathbb{P}(a \le X \le b) = F_X(b) - F_X(a) = \int_a^b f_X(x)\,dx.$$

對 $X \sim U(0, L)$ 且 $L > 0$，密度在 $[0, L]$ 是 $1/L$，平均數

$$\mathbb{E}[X] = \frac{L}{2}.$$

變異數：

$$\operatorname{Var}(X) = \int_0^L \left(x - \frac{L}{2}\right)^2 \frac{1}{L}\,dx = \frac{L^2}{12}.$$

$L = 3$ 時平均數是 1.5，變異數是 $9/12 = 3/4$。均勻分布平移 a 後平均數加 a，變異數不變。

常態分布、標準化與中央極限定理

標準常態：

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}.$$

常態分布（Gaussian distribution）$X \sim N(\mu, \sigma^2)$，其中 $\sigma > 0$：

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

標準化：

$$Z = \frac{X - \mu}{\sigma}$$

使平均數變 0、變異數變 1。

獨立同分布（IID）且 $0 < \sigma^2 < \infty$ 時，中央極限定理（CLT）給出

$$\frac{\sqrt{N}(\overline{X} - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

常態分布、標準化與中央極限定理 （續）

它描述標準化樣本平均的分布近似，不代表原始資料會變成 Gaussian。時間序列相依、異分布或重尾都可能違反顯示的前提。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

CLT 的證明：獨立乘積與二階展開

以下援引 Lévy 連續性定理完成分布收斂步驟；其一般機率論證明超出本章範圍。先中心化並除以標準差，令 $U_i = (X_i - \mu)/\sigma$，則 $\mathbb{E}[U_i] = 0$、$\operatorname{Var}(U_i) = 1$，且

$$Z_N = \frac{\sqrt{N}(\overline{X} - \mu)}{\sigma} = \frac{1}{\sqrt{N}} \sum_{i=1}^{N} U_i .$$

令 $\varphi_N(t) = \mathbb{E}[e^{itZ_N}]$。獨立性使特徵函數相乘；同分布使每個因子的函數相同：

$$\varphi_N(t) = \left[\varphi_U\!\left(\frac{t}{\sqrt{N}} \right) \right]^N .$$

有限二階矩保證 φ_U 在 0 附近可微兩次，且

$$\varphi_U(s) = 1 - \frac{1}{2}s^2 + o(s^2).$$

這裡不需要第三階矩。理由是 $e^{iy} = 1 + iy - y^2/2 + R(y)$，其中 $R(y)/y^2 \to 0$，且可取固定常數 C 使 $|R(y)| \le C y^2$。所以 $R(sU)/s^2 \to 0$ 幾乎必然，並由可積的 CU^2 控制；支配收斂定理給 $\mathbb{E}[R(sU)] = o(s^2)$。期望值的線性性再用 $\mathbb{E}[U] = 0, \mathbb{E}[U^2] = 1$ 得到展開。

CLT 的證明：獨立乘積與二階展開 （續）

因此

$$N \log \varphi_U(t/\sqrt{N}) = N \log\left(1 - \frac{t^2}{2N} + o(1/N)\right) \longrightarrow -\frac{t^2}{2}.$$

所以 $\varphi_N(t) \to e^{-t^2/2}$，也就是 $N(0,1)$ 的特徵函數。由 Lévy 連續性定理：特徵函數逐點收斂到一個在零點連續的特徵函數時，對應分布依分布收斂；因此 Z_N 收斂到標準常態。僅有特徵函數的唯一性，不能單獨推出這個收斂結論。這不是「大樣本一定是常態」；它只說明平均量的極限。

上式對固定 t 且充分大的 N，在 1 附近取同一個複數對數分支，再將極限取指數；不能對一般複數乘積任意套用主值對數加法律。有限變異數 CLT 沒有提供對所有分布一致的有限樣本誤差界。

二項分布的標準化與圖形比較

令 B_i 為獨立公平的 0/1 觀測值，$S_N = \sum_i B_i$。則

$$P(S_N = k) = \binom{N}{k} 2^{-N}, \quad \mathbb{E}[S_N] = N/2, \quad \mathrm{Var}(S_N) = N/4.$$

標準化變數 $Z_N = (S_N - N/2)/(\sqrt{N}/2)$ 的相鄰取值距離是 $\Delta z = 2/\sqrt{N}$。$N = 4$ 時，取值為 $-2, -1, 0, 1, 2$，機率依序是 $(1, 4, 6, 4, 1)/16$；$\mathbb{E}[Z_4] = 0$、$\mathrm{Var}(Z_4) = 1$，但它仍是離散分布。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

二項分布的標準化與圖形比較 （續）

標準化二項分布：長條面積是機率，紅線為 N(0,1) 密度

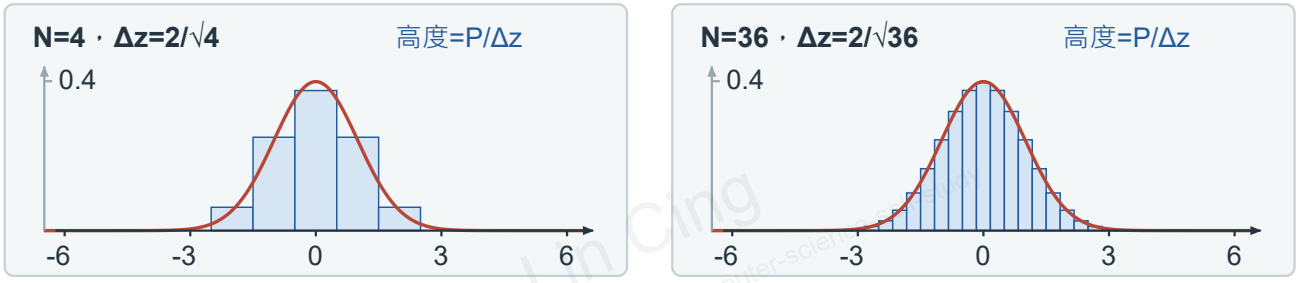

每根長條的寬為 Δz、高度為 $P(S_N = k)/\Delta z$，所以面積才是機率，所有長條總面積為 1；紅線是標準常態密度。不能把點機率直接當成密度與紅線比高度。這個圖只比較有限的兩個例子，一般收斂由前面的定理保證。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

Monte Carlo 平均的誤差從哪裡來

若獨立同分布的模擬輸出 $Y_1, \dots, Y_N$ 有均值 μ 與有限變異數 τ^2，則估計量 $\widehat{\mu} = N^{-1} \sum_i Y_i$ 滿足

$$\mathbb{E}[\widehat{\mu}] = \mu, \qquad \operatorname{Var}(\widehat{\mu}) = \frac{\tau^2}{N}, \qquad P(|\widehat{\mu} - \mu| \ge \varepsilon) \le \frac{\tau^2}{N \varepsilon^2}.$$

最後一步是 Chebyshev 不等式，因此標準誤按 $N^{-1/2}$ 縮小。它是抽樣誤差的機率敘述，不是每次模擬都遵守的決定性誤差。

例如 $X \sim U(-1, 1)$、$Y = X^2$，積分給 $\mathbb{E}[Y] = 1/3$、$\mathbb{E}[Y^2] = 1/5$，所以 $\tau^2 = 4/45$。$N = 1000$ 時，標準誤為 $\sqrt{4/45000} \approx 0.00943$，且 $P(|\widehat{\mu} - 1/3| \ge 0.1) \le 4/450 \approx 0.00889$。模擬若有相關性，變異數還要加上所有交叉共變異數；不能繼續套用 τ^2/N。

聯合機率表

離散變數的聯合機率質量函數：

$$P_{ij} = \mathbb{P}(X = x_i, Y = y_j),$$
$$P_{ij} \ge 0, \qquad \sum_{i,j} P_{ij} = 1.$$

邊際機率：

$$\mathbb{P}(X = x_i) = \sum_j P_{ij}, \qquad \mathbb{P}(Y = y_j) = \sum_i P_{ij}.$$

獨立性要求每一對都滿足

$$P_{ij} = \mathbb{P}(X = x_i)\mathbb{P}(Y = y_j).$$

只知道兩組邊際機率，通常不足以重建聯合分布。只比較平均數或單一共變異數也不能判定獨立性。

聯合機率表 （續）

Joint table：marginals 與 covariance

X \ Y	Y=0	Y=1
X=0	0.2	0.1
X=1	0.3	0.4

PX=(0.3,0.7) **PY=(0.5,0.5)**

總機率=0.2+0.1+0.3+0.4=1

E(X)=0.7 · E(Y)=0.5

E(XY)=0.4

Cov=0.4-0.7×0.5=0.05

VarX=0.21 · VarY=0.25

ρ=0.05/√0.0525=1/√21

圖下核對：$P_X = (0.3, 0.7)$、$P_Y = (0.5, 0.5)$、$\mathbb{E}(XY) = 0.4$，因此 $\mathrm{Cov}(X, Y) = 0.05$、$\rho_{XY} = 1/\sqrt{21}$。表格四格總和為 1。

條件機率、Bayes 與零相關的界線

若 $P(X = x_i) = p_i > 0$，條件機率是

$$P(Y = y_j \mid X = x_i) = \frac{P_{ij}}{p_i}.$$

以同一張表 $P = \begin{bmatrix} 0.2 & 0.1 \\ 0.3 & 0.4 \end{bmatrix}$，rows 為 $X = 0, 1$，columns 為 $Y = 0, 1$，則

$$P(Y = 1 \mid X = 0) = \frac{1}{3}, \quad P(Y = 1 \mid X = 1) = \frac{4}{7}.$$

全機率公式 $P(Y = 1) = \sum_i P(Y = 1 \mid X = i) P(X = i)$ 給 $(1/3)(0.3) + (4/7)(0.7) = 0.5$。Bayes 公式交換已知與未知的角色：

$$P(X = 1 \mid Y = 1) = \frac{P(Y = 1 \mid X = 1) P(X = 1)}{P(Y = 1)} = \frac{(4/7)(0.7)}{0.5} = 0.8.$$

零共變異數仍可能依賴。取 X 在 $-1, 0, 1$ 等機率、$Y = X^2$。則 $\mathbb{E}[X] = \mathbb{E}[XY] = 0$，故 $\mathrm{Cov}(X, Y) = 0$；但 $P(Y = 0 \mid X = 0) = 1 \neq P(Y = 0) = 1/3$。聯合常態才有「零共變異數推出獨立」這個額外結論。

共變異數與相關係數

相關係數只摘要線性共同變動。先從完整聯合分布定義條件機率，才能分辨「相關」與「獨立」。

$$\operatorname{Cov}(X,Y)=\mathbb{E}[(X-\mu_X)(Y-\mu_Y)].$$

離散聯合分布的寫法：

$$\operatorname{Cov}(X,Y)=\sum_{i,j}P_{ij}(x_i-\mu_X)(y_j-\mu_Y).$$

共變異數的大小依單位，相關係數去除尺度：

$$\rho_{XY}=\frac{\sigma_{XY}}{\sigma_X\sigma_Y}.$$

兩變異數為正時，

$$-1\le\rho_{XY}\le 1.$$

證明：

$$\operatorname{Var}\left(\frac{X}{\sigma_X}-\frac{Y}{\sigma_Y}\right)=2(1-\rho_{XY})\ge 0,$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

共變異數與相關係數 （續）

改用加號則得 $1+\rho_{XY}\ge 0$。零相關只表示線性共變異為零，不一般等於獨立性。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

共變異矩陣與半正定性

隨機欄向量：

$$\mu = \mathbb{E}[X], \qquad V = \mathbb{E}[(X-\mu)(X-\mu)^T].$$

$V_{ij} = \sigma_{ij}$，對角線是變異數，且 $V = V^T$。

任一係數向量 c：

$$c^T V c = \mathrm{Var}(c^T X) = \mathbb{E}[(c^T(X-\mu))^2] \geq 0.$$

所以 V 半正定。離散聯合分布也有構造性證明：

$$V = \sum_{i,j} P_{ij} u_{ij} u_{ij}^T, \qquad u_{ij} = \begin{bmatrix} x_i \\ y_j \end{bmatrix} - \mu.$$

正定表示沒有任何非零線性組合 $c^T X$ 是幾乎必然為常數。秩不足表示某些變數的線性方向完全決定其他方向。

共變異矩陣與半正定性 (續)

共變異幾何：V=diag(4,1)，等密度線 $x^TV^{-1}x=1$

$\lambda_1=4$，$\lambda_2=1$；半軸 2、1

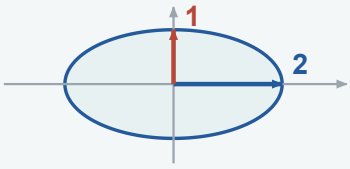

(2,0) 與 (0,1) 的加權平方長均為 1

$J=e^TV^{-1}e$

白化 $z=(x_1/2, x_2)$

$J=\|z\|^2$

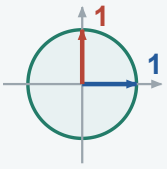

同尺度：半軸 (2,1) → 半徑 (1,1)

圖中考慮聯合常態，採 $V = \mathrm{diag}(4,1)$、$\mu = 0$，所以等密度線 $x^TV^{-1}x = 1$ 為 $x_1^2/4 + x_2^2 = 1$，半軸恰為 2 與 1。它描述共變異尺度；一般分布的等密度線不必是橢圓。聯合常態的情形才由此二次型完整決定密度。

隨機向量的線性轉換

令

$$Y = AX + b.$$

平均數：

$$\mu_Y = A\mu_X + b.$$

共變異數：

$$V_Y = \mathbb{E}[(AX + b - \mu_Y)(\cdots)^T] = AV_XA^T.$$

平移 b 在中心化時消去。V_Y 是否奇異取決於 $\operatorname{rank}(AV_X^{1/2})$。若 $V_X \succ 0$ 且 A 滿 row rank，即使輸出維度降低，AV_XA^T 仍正定；重複的 rows 則造成秩不足。

純量線性組合 a^TX 的變異數是 a^TVa；兩個線性組合的共變異數是 a^TVb。共變異矩陣因此表示一個對稱雙線性形式。

樣本共變異矩陣

把樣本放在 columns：

$$X_{\text{data}} \in \mathbb{R}^{M\times n}.$$

各 row 的平均數：

$$\widehat{\mu}_j = \frac{1}{n}\sum_{k=1}^{n}(X_{\text{data}})_{jk}.$$

逐 row 中心化得 X_c。不偏樣本共變異矩陣：

$$\widehat{V}_{n-1} = \frac{1}{n-1}X_cX_c^T.$$

母體／描述統計版本：

$$\widehat{V}_n = \frac{1}{n}X_cX_c^T.$$

兩者特徵向量相同，特徵值只差 $n/(n-1)$。PCA 的文獻可能用其中任一分母，必須說明。

樣本共變異矩陣 （續）

$n \geq 2$、樣本 i.i.d. 且二階矩有限時，上式才具有不偏意義。中心化使 $X_c\mathbf{1} = 0$，故 rank 至多 $\min(M, n-1)$。非零奇異值平方成共變異數的非零特徵值，非零譜的條件數平方；秩不足時一般反問題的條件數已無限。大型資料通常直接用 SVD。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

噪聲白化

若誤差 E 的共變異矩陣 V 對稱正定（SPD），V^{-1} 會依變異數反向加權。白化：

$$W = V^{-1/2}E.$$

則

$$\mathrm{Cov}(W) = V^{-1/2}VV^{-1/2} = I.$$

Mahalanobis 長度：

$$\|e\|_{V^{-1}}^2 = e^T V^{-1} e.$$

V 是對角矩陣時，就是每個殘差除以對應的標準差。V 由樣本估計且維度高於樣本數時，估計共變異數可能奇異，必須收縮估計、降維或結構模型。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

多變量 Gaussian 分布

SPD V 的多變量常態密度：

$$p(x) = \frac{1}{(2\pi)^{M/2}\det(V)^{1/2}} \exp\left[-\frac{1}{2}(x-\mu)^T V^{-1}(x-\mu)\right].$$

指數的等位集合：

$$(x-\mu)^T V^{-1}(x-\mu) = r^2$$

是橢球面。譜分解：

$$V = Q\Lambda Q^T, \qquad \Lambda = \mathrm{diag}(\lambda_i).$$

令

$$Y = Q^T(X-\mu).$$

則 Y 的共變異矩陣是對角矩陣 Λ。聯合常態下互不相關的分量也獨立，這是譜定理的統計解釋。

多變量 Gaussian 正規化

由

$$V = Q\Lambda Q^T$$

與 $Q^TQ = I$：

$$(x-\mu)^T V^{-1}(x-\mu) = \sum_i \frac{y_i^2}{\lambda_i}, \qquad y = Q^T(x-\mu).$$

正交變換的體積倍率是 1，所以 $dx = dy$。積分分解成一維常態積分的乘積：

$$\int_{\mathbb{R}^M} \exp\left(-\frac{1}{2}\sum_i \frac{y_i^2}{\lambda_i}\right) dy = (2\pi)^{M/2}\prod_i \lambda_i^{1/2}.$$

而

$$\prod_i \lambda_i^{1/2} = \det(V)^{1/2},$$

多變量 Gaussian 正規化 （續）

一維 Gaussian 積分可由平方轉為二維極座標證明：$I = \int e^{-t^2/2} dt > 0$，則 $I^2 = \int_0^{2\pi} \int_0^{\infty} e^{-r^2/2} r \, dr \, d\theta = 2\pi$，故 $I = \sqrt{2\pi}$。縮放每個座標得到上式，正規化正確。V 奇異時，Gaussian 位於較低維的仿射子空間，在 $\mathbb{R}^M$ 中不存在相對於全空間體積的普通密度。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

加權最小平方

令 $A \in \mathbb{R}^{m \times n}$、$b, e \in \mathbb{R}^m$、$x \in \mathbb{R}^n$，模型為：

$$b = Ax + e, \qquad \mathbb{E}[e] = 0, \qquad \mathrm{Cov}(e) = V \succ 0.$$

普通最小平方法（OLS） 最小化

$$\|b - Ax\|_2^2,$$

對固定設計矩陣、零均值誤差，OLS 仍可無偏；要它成為最佳線性不偏估計量（BLUE），等變異且不相關的共變異數 $\sigma^2 I$ 已充分，不要求獨立性。一般已知 SPD 共變異數使用 Mahalanobis 加權殘差：

$$J(x) = (b - Ax)^T V^{-1} (b - Ax).$$

梯度：

$$\nabla J = -2A^T V^{-1} (b - Ax).$$

設為零，得加權正規方程：

$$A^T V^{-1} A x = A^T V^{-1} b.$$

滿 column rank 時，

加權最小平方 （續）

$$\widehat{x} = (A^T V^{-1} A)^{-1} A^T V^{-1} b.$$

這個駐點是全局最小值。令 $h \neq 0$，展開：

$$J(x+h) - J(x) = -2h^T A^T V^{-1}(b - Ax) + h^T A^T V^{-1} A h.$$

在加權正規方程的解 $\widehat{x}$，第一項為零；滿 column rank 給出 $Ah \neq 0$，而 $V \succ 0$ 給出 $h^T A^T V^{-1} A h > 0$。因此每個非零位移都增加目標函數，唯一最小值就是 $\widehat{x}$。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

完整數例：三筆異變異測量

令 $A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$、$b = (2, 5, 4)^T$，誤差共變異矩陣為 $V = \operatorname{diag}(1, 4, 9)$。白化後三式依序為

$$x_1 \approx 2, \quad \tfrac{1}{2}x_1 + \tfrac{1}{2}x_2 \approx \tfrac{5}{2}, \quad \tfrac{1}{3}x_2 \approx \tfrac{4}{3}.$$

因此

$$A^T V^{-1} A = \begin{bmatrix} 5/4 & 1/4 \\ 1/4 & 13/36 \end{bmatrix}, \quad A^T V^{-1} b = \begin{bmatrix} 13/4 \\ 61/36 \end{bmatrix}.$$

第一列乘 4 得 $5x_1 + x_2 = 13$，第二列乘 36 得 $9x_1 + 13x_2 = 61$。代入 $x_2 = 13 - 5x_1$ 得 $-56x_1 = -108$，所以

$$\widehat{x} = (27/14, 47/14)^T, \qquad A\widehat{x} = (27/14, 37/7, 47/14)^T.$$

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

完整數例：三筆異變異測量 （續）

測量	殘差 $e_i = b_i - (A\widehat{x})_i$	加權平方 e_i^2/σ_i^2
1	$1/14$	$1/196$
2	$-2/7$	$4/196$
3	$9/14$	$9/196$

合計 $J = 14/196 = 1/14$。驗證 $V^{-1}e = (1/14, -1/14, 1/14)^T$，故 $A^TV^{-1}e = 0$。普通歐氏殘差不必滿足 $A^Te = 0$；正交的是白化後的殘差與白化設計矩陣。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

獨立異變異誤差

若誤差有有限正變異數且互不相關（獨立性亦充分）：

$$V = \operatorname{diag}(\sigma_1^2, \dots, \sigma_m^2),$$

則最小化

$$J(x) = \sum_{i=1}^{m} \frac{(b_i - a_i^T x)^2}{\sigma_i^2}.$$

高變異數測量的權重小，低變異數測量的權重大。

重複量同一個純量 x：

$$A = (1, 1)^T, \qquad b = (b_1, b_2)^T.$$

正規方程：

$$\left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right) x = \frac{b_1}{\sigma_1^2} + \frac{b_2}{\sigma_2^2}.$$

所以

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

獨立異變異誤差 （續）

$$\widehat{x} = \frac{b_1/\sigma_1^2 + b_2/\sigma_2^2}{1/\sigma_1^2 + 1/\sigma_2^2},$$

它是精度加權平均數。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

估計量的共變異數

估計量是線性：

$$\widehat{x} = Gb, \qquad G = (A^T V^{-1} A)^{-1} A^T V^{-1}.$$

若 b 的共變異數是 V：

$$\mathrm{Cov}(\widehat{x}) = G V G^T.$$

代入 G：

$$\mathrm{Cov}(\widehat{x}) = (A^T V^{-1} A)^{-1}.$$

對角線元素是各參數估計量的變異數，非對角元素是估計量間的共變異數；須再除以相應標準差乘積才是相關係數。此公式假設固定滿 column rank A、固定已知 SPD V；若 V 以同一批資料估計，G 也是隨機，不能直接把代入估計後的逆矩陣當成 精確抽樣共變異矩陣。

BLUE 的證明：$GA = I$，所以 $\mathbb{E}[Gb] = x$。任何另一個對所有參數都無偏的線性估量可寫 $Hb = (G + D)b$，且 $DA = 0$。因 $GV = (A^T V^{-1} A)^{-1} A^T$，有 $GVD^T = 0$，所以 $HVH^T - GVG^T = DVD^T \succeq 0$。此處共變異數最小是 PSD 次序，不是逐元素比較。常態性不必要；精確信賴區間與檢定另需分布假設。

加權最小平方的條件數

不要顯式求逆 V。若誤差互相獨立，先逐式白化：

$$\tilde{A} = V^{-1/2}A, \qquad \tilde{b} = V^{-1/2}b.$$

再對 $\tilde{A}, \tilde{b}$ 做普通最小平方法（OLS）。

形成白化後的正規矩陣 $\tilde{A}^T\tilde{A}$ 會將 $\tilde{A}$ 的二範數條件數平方；不是求逆運算本身才造成平方。穩定流程以 SPD $V = LL^T$ 的三角求解求 $\tilde{A} = L^{-1}A, \tilde{b} = L^{-1}b$，再做 QR 或 SVD。大型稀疏問題可用不顯式形成矩陣的方法。

樣本共變異矩陣估計不確定或奇異時，可使用收縮估計、正則化或降維，但要報告這些方法如何改變統計模型。

新觀測到來：遞迴最小平方

設舊資料的加權最小平方估計為 $\hat{x}_0$，其誤差共變異矩陣為 $W_0 \succ 0$。新的測量為 $b_1 = Hx + \eta$，其中 $\mathbb{E}[\eta] = 0$、$\mathrm{Cov}(\eta) = R \succ 0$，且新誤差與舊資料誤差互不相關。將兩批加權正規方程相加：

$$W_1^{-1} = W_0^{-1} + H^T R^{-1} H,$$
$$W_1^{-1}\hat{x}_1 = W_0^{-1}\hat{x}_0 + H^T R^{-1} b_1.$$

第二式減去第一式乘 $\hat{x}_0$，得更新式

$$\hat{x}_1 = \hat{x}_0 + K(b_1 - H\hat{x}_0), \quad K = W_1 H^T R^{-1}.$$

$b_1 - H\hat{x}_0$ 是 innovation（新觀測與舊預測的差）。為避免反覆求逆，可改算

$$S = R + HW_0H^T, \quad K = W_0H^TS^{-1}, \quad W_1 = W_0 - W_0H^TS^{-1}HW_0.$$

驗證兩種增益相同：$(W_0^{-1} + H^TR^{-1}H)W_0H^TS^{-1} = H^TR^{-1}(R + HW_0H^T)S^{-1} = H^TR^{-1}$。再乘 W_1 即得 $K = W_1H^TR^{-1}$。同理左乘 W_1^{-1} 可驗證最後一個共變異數公式。減去的矩陣半正定，所以 $W_1 \preceq W_0$，新資料不增加此模型下線性估計的不確定性。

新觀測到來：遞迴最小平方 （續）

這是固定狀態的遞迴最小平方，也是原書簡化 Kalman 更新的內容；完整動態濾波還需要狀態轉移、過程誤差與預測步驟，不能直接用此式替代。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

遞迴更新的數值核對

估計同一常數 x，舊觀測為 $b_0 = 10$、變異數 1，所以 $\hat{x}_0 = 10, W_0 = 1$。取 $H = 1$，依序加入兩個不相關的新觀測：

步驟	新觀測及變異數	$S = R + W$	$K = W/S$	新估計值	新變異數
1	$b_1 = 13, R_1 = 9$	10	$1/10$	$10 + (1/10)(3) = 103/10$	$9/10$
2	$b_2 = 9, R_2 = 1$	$19/10$	$9/19$	$103/10 + (9/19)(9 - 103/10) = 184/19$	$9/19$

一次解全部資料的精度加權平均為

$$\hat{x} = \frac{10 + 13/9 + 9}{1 + 1/9 + 1} = \frac{184}{19}, \quad \operatorname{Var}(\hat{x}) = \frac{1}{1 + 1/9 + 1} = \frac{9}{19}.$$

兩種算法精確相同。若新觀測只是舊觀測的複製，它與舊誤差相關；再當成獨立資料加一次權重，便會低估不確定性。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

穩健性與模型假設

WLS 不是普遍適用的誤差模型。關鍵假設：

- 誤差平均數已知或為零；
- 共變異數 V 已知或有可信估計；
- 條件平均的線性模型 Ax 正確；
- 聯合共變異矩陣確實捕捉相依性；
- 滿 column rank，參數唯一可識別。

無有限二階矩的重尾使共變異數模型失效；離群值或遺漏非線性也可能使 WLS 與需求不合。相關誤差若已正確納入 V，並不違反廣義最小平方法。L_1 損失函數對大殘差的懲罰為線性，對垂直離群值較不敏感，但不自動抵抗高槓桿的設計點；線性模型的 最小絕對離差可改寫為 LP，無需聲稱必須非線性最佳化。

時間序列的誤差共變異數常有非對角結構；直接令 $V = I$ 會同時改變加權方式與不確定性。相關係數也不等於因果效果。

章末檢查

讀者應能：

- 區分樣本統計量、模型期望值與連續型密度；
- 推導變異數恆等式，說明 $N - 1$；
- 從聯合機率表算邊際機率、共變異數與相關係數；
- 以 $c^T V c = \mathrm{Var}(c^T X)$ 證明共變異矩陣 PSD；
- 推導 $V_{AX+b} = A V_X A^T$；
- 使用譜定理與行列式正規化 Gaussian；
- 從 Mahalanobis 損失函數推導加權正規方程；
- 推導 $\mathrm{Cov}(\hat{x})$，辨明 BLUE 與常態性；
- 使用穩定白化、QR 或 SVD，並報告條件數與誤差敏感度。

至此 12 章的概念路徑由向量空間、投影、矩陣分解、應用連到數值可靠性與 統計推論。

參考資料與署名

Gilbert Strang. Introduction to Linear Algebra, 5th Edition, 2016.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study