本章路線

這章要回答的核心問題是：在什麼 workload 與保證條件下，一個排程政策能把有限 CPU 配得正確、可預測且有效率？

前置知識。 process 狀態與佇列、context switch、機率與期望值。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

學習目標

- 推導等待、周轉與回應時間
- 比較 FCFS、SJF、SRTF、RR、priority 與多級回饋佇列
- 檢查搶占、飢餓、優先權倒置與即時可排程性

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.1 基本概念

- process 在 CPU execution 與 I/O wait 間交替。CPU burst 是一段不中斷的執行需求，I/O burst 是等待外部完成的區間。
- short-term scheduler 由 ready queue 選出 kernel thread；dispatcher 完成 context switch、模式切換與跳回目標程式。dispatch latency 是這段無用工作的時間。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.1.1 排程器的三種時間尺度

- long-term scheduler 控制哪些工作可進入系統，影響多程式度；short-term scheduler 只選下一個執行者；medium-term scheduler 可把工作換出以降低記憶體壓力。
- 批次系統的 admission 決定可改變後續 workload；互動系統更在意回應時間，而非只追求 CPU 忙碌。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.1.2　搶占與非搶占

- nonpreemptive 排程只在 running 完成、自願讓出或阻塞時切換；preemptive 可在時間片到期或更高優先權者到來時切換。
- 搶占改善回應與公平，但每次切換都要保存狀態、維護 run queue，並防止共享核心資料被交錯破壞。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.1　模型、時序與反例：基本概念

模型假設。 每個工作有可描述 arrival、CPU burst 與 I/O burst；排程器可保存/恢復執行上下文，queue 狀態轉移具原子性。

不變量與時序。 running 任務每 CPU 至多一個，ready/blocked queue 不重複入列；任意時間表滿足資源釋放與 arrival 順序。

反例或邊界。 忽略 context switch 成本時，極短 quantum 看似公平，實際可能大部分 CPU 都在切換。

完整算例。 P1 burst=5後等待I/O，P2 burst=2；單CPU、switch cost=1，FCFS為P1[0,5)、switch[5,6)、P2[6,8)。有用工作占比是7/8=87.5%，切換開銷占1/8=12.5%。CPU整段都在執行工作或核心切換，沒有idle，因此若CPU utilization定義為busy/elapsed，仍是8/8=100%。有用工作效率與CPU忙碌率不是同一個量；省略switch會把總時間錯算為7。

思考題。 哪條時間線事件能同時破壞 queue 不重複與工作完成順序？

6.2 排程準則

- CPU utilization 是 CPU 忙碌時間占觀察區間的比例；throughput 是單位時間完成的工作數。這兩個效率指標可能提高，但個別工作的 waiting、response 或 turnaround 仍變差。
- waiting time 是任務在 ready state 的累積時間，不含實際 CPU service 與 blocked I/O。turnaround time 從 arrival 到 completion。排程課本把 response time 定為 arrival 到第一次取得 CPU；若服務契約要看首次可見輸出，必須另量 output time。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.2.1　唯一公式與首輸出語義

- 令 task i 的 arrival 為 a_i、ready intervals 的總和為 W_i、completion 為 f_i。turnaround_i=f_i-a_i，waiting_i=W_i。blocked time 既不屬 CPU service，也不屬 ready waiting。
- 排程 response_i=s_i-a_i，其中 s_i 是第一次取得 CPU 的時刻。若產品指標定義為首次可見輸出 o_i，則 user-visible response_i=o_i-a_i。兩個 response 都可能有價值，但名稱與量測點必須明示。
- 固定例 a=2、s=5、o=9、f=14，且 2 至 5 位於 ready queue：waiting=3、排程 response=3、首輸出 response=7、turnaround=12。waiting 不可改寫成 turnaround 減 burst 而忽略 blocked 時段。

Lin Ching
https://github.com/xinhi6716/computer-science-self-study

6.2　模型、時序與反例：排程準則

模型假設。 時間單位一致；arrival、first CPU、first visible output、completion 均有可觀測事件；ready 與 blocked intervals 分開記錄。

不變量與時序。 waiting_i 只累加 ready intervals；turnaround_i=completion_i-arrival_i；排程 response 與首輸出 response 各自使用唯一指定的事件。

反例或邊界。 a=2、s=5、o=9、f=14 的工作若把 blocked 等待算入 waiting，會得到錯誤的 waiting=12，把周轉時間重新命名成 waiting。

完整算例。 上述固定例得到 waiting=3、排程 response=3、首輸出 response=7、turnaround=12；四個數值回答不同問題，且 waiting/response 不由 completion 再重複定義。

思考題。 互動服務若回報 response=0，必須同時揭露它量的是第一次 CPU 還是首次使用者可見輸出。

6.2　waiting、first CPU 與 first visible output

本節只保留一組定義。令 task i 的 arrival 為 a_i，ready state intervals 的總和為 W_i，第一次取得 CPU 的時間為 s_i，第一次產生使用者可見輸出的時間為 o_i，完成時間為 f_i。

$$\text{waiting}_i = W_i, \quad \text{turnaround}_i = f_i - a_i$$

排程課本的 response time 使用第一次取得 CPU：

$$\text{schedule response}_i = s_i - a_i$$

若介面契約量的是首次可見輸出，必須另記：

$$\text{visible response}_i = o_i - a_i$$

固定案例的 arrival $a = 2$、第一次取得 CPU $s = 5$、首次輸出 $o = 9$、完成 $f = 14$，且 2 至 5 都在 ready queue。結果是 waiting=3、schedule response=3、visible response=7、turnaround=12。這些值回答四個不同問題，不能相加。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.2 blocked time 為何不能算 waiting

若同一任務在完成前另有 4 個時間單位等待 I/O，則 blocked time 增加完成時間，但 ready waiting 不增加。等待 I/O 的 task 不在 ready queue，不能與 CPU dispatch 的 waiting 混算。

設task A arrival0，完整時間線為ready[0,2)、CPU[2,4)、blocked[4,8)、ready[8,11)、CPU[11,12)。完成時間f=12，turnaround=12−0=12，ready waiting=2+3=5，CPU service=2+1=3，blocked=4，且5+3+4=12。若把blocked4也算waiting會誤得9，與ready waiting的定義不符。

平均 waiting 相同也不代表最大 response 相同。工作 A 與 B 都等待 4 units，但 A 的第一次 CPU 在第 4 unit、B 在第 8 unit；若 B 另外要等到輸出才可見，visible response 還會更晚。報告排程品質時，至少要同時標出定義、量測事件與 percentile。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.3 排程演算法

- 演算法需明確比較鍵、搶占時機、tie-break 與 queue 管理。平均等待較低不代表每個工作都有上限。
- 對同時可用、單一 CPU burst、已知長度且忽略切換成本的一組工作，非搶占 SJF 最小化平均等待；SRTF 是它的可搶占版本。實務無法完美預知未來 burst，只能用歷史估計。
- SJF 的交換論證：若同時可用的相鄰兩工作長度 x>y，先 x 後 y 對兩者等待和貢獻為 x，交換後為 y，其餘工作等待不變，故每次消去逆序都不增加等待總和。不同 arrival、允許刻意 idle 或有估計誤差時不能直接沿用此最適性結論。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.3.1 FCFS 與 convoy effect

- FCFS 依 arrival 順序執行，實作簡單且無搶占。長工作先到時，後方短工作一起等待，形成 convoy effect。
- 例：P1 burst 120、P2/P3 各 burst 10，arrival 都為 0，FCFS 等待為 0、120、130，平均 83.33；若短工作先做，等待分布完全不同。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.3.2 SJF 與 SRTF

- 非搶占 SJF 在 CPU 空閒時選最短 burst；SRTF 在更短工作抵達時搶占。兩者都以已知 burst 為前提。
- 長工作有飢餓風險：源源不絕的短工作會使長工作延後。tie-break 影響具體時間表但不等於公平保證。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.3.3 Round Robin

- RR 以固定 time quantum 輪流執行。所有工作 burst 不超過 q 時近似 FCFS；q 太小則切換成本占比上升。
- 例：P1/P2/P3 arrival 0、burst 24/3/3、q=4，時間線為 P1[0,4)、P2[4,7)、P3[7,10)、P1[10,14)、P1[14,18)、P1[18,22)、P1[22,26)、P1[26,30)，三份 burst 總和為 30。後段只有 P1 可執行時，時間片邊界不必造成跨 thread context switch；timer／排程檢查與實際切換需分開計算。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.3.4 Priority 與多級佇列

- priority 排程可選最高優先權；低優先權工作可能 starve。aging 隨等待時間提高有效 priority，避免無限延後。
- multilevel queue 區分 foreground/background，multilevel feedback queue 允許工作依行為換級；時間片與升級規則本身就是 policy。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.3　模型、時序與反例：排程演算法

模型假設。 每種演算法要說明 burst 已知或估計、arrival 可同時、preemption 與 tie-break 規則。

不變量與時序。 CPU 時間表不重疊且每段長度不超過該工作剩餘 burst；每次 arrival 與完成都被更新。

反例或邊界。 SJF 在 burst 不斷被低估的 workload 中可能讓長工作反覆被延後。

完整算例。 P1/P2/P3 burst=8/4/2、arrival=0。FCFS wait=0、8、12，平均 20/3≈6.67；SJF order 2、4、8，wait=0、2、6，平均 8/3≈2.67。RR q=2 的 completion依P1/P2/P3為14/10/6，三份 burst 的總 CPU 時間仍是14。

思考題。 如果 burst 只是估計值，哪個演算法保證需要被改寫？

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

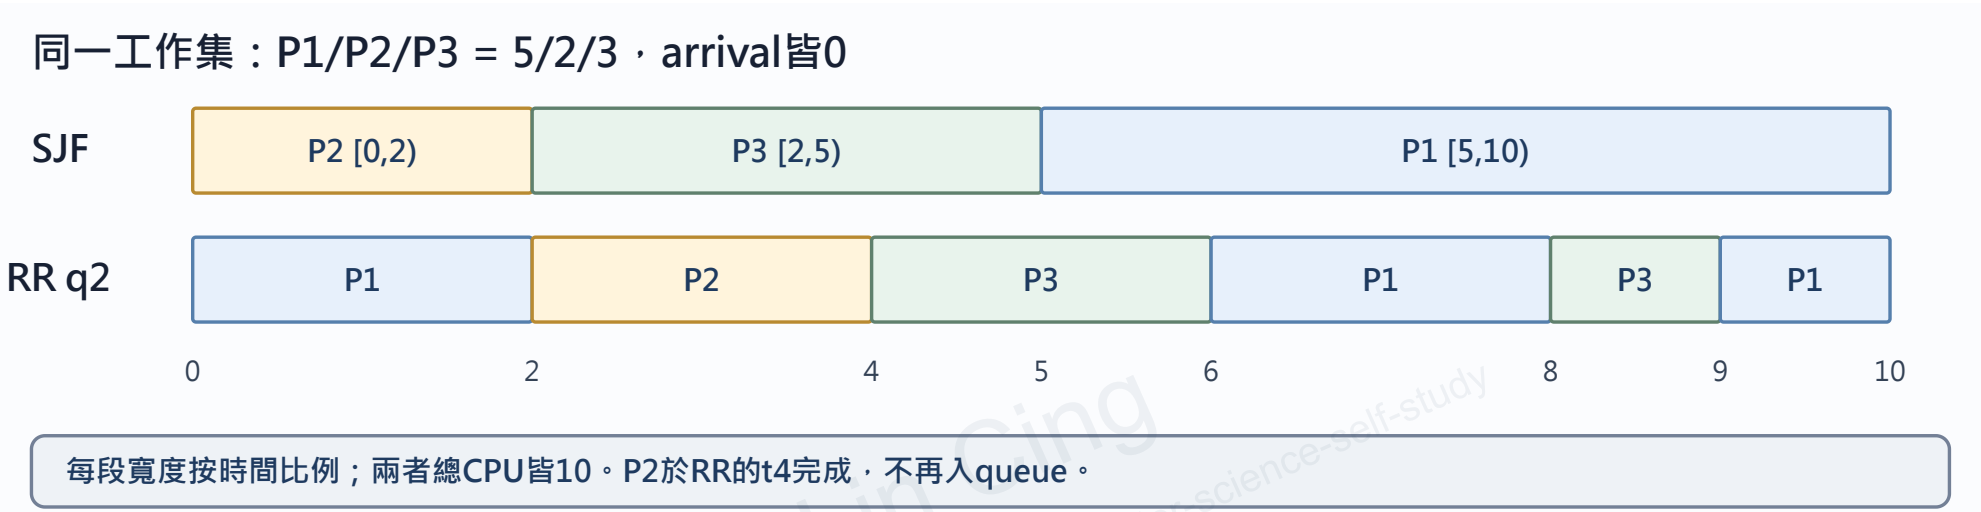
6.3　SJF與RR：同一個5/2/3工作集

固定P1/P2/P3皆arrival0，CPU bursts5/2/3，切換成本0。非搶占SJF依序P2[0,2)、P3[2,5)、P1[5,10)，completion依P1/P2/P3為10/2/5，waiting為5/0/2。

RR q2的ready queue初序P1,P2,P3；依序為P1[0,2)、P2[2,4)、P3[4,6)、P1[6,8)、P3[8,9)、P1[9,10)，共6段。P2在t4已完成，不可再次入列；completion為10/4/9，waiting為5/2/6，first response為0/2/4。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.3　SJF與RR：同一個5/2/3工作集 （續）



兩者useful CPU總量都是10，但SJF平均waiting=7/3，RR為13/3；response分布亦不同。前段8/4/2的另一個固定案例則有RR q2的P1[0,2)、P2[2,4)、P3[4,6)、P1[6,8)、P2[8,10)、P1[10,12)、P1[12,14)，completion為14/10/6。不得把不同輸入的completion混到同一個表。

6.4 Thread scheduling

- user-level thread 由 thread library 在 process-contention scope 內競爭；kernel thread 由 kernel 在 system-contention scope 中競爭 CPU。
- one-to-one 模型通常讓每個 user thread 對應可被核心排程的 thread；many-to-one 的阻塞 system call 可能卡住整個 process。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.4　模型、時序與反例：Thread scheduling

模型假設。 thread library 與 kernel 的映射已知；阻塞 system call 是否釋放 kernel execution entity 已明確。

不變量與時序。 同一 kernel execution entity 不能同時執行兩個 context；user thread 阻塞不應在映射允許時阻塞無關 thread。

反例或邊界。 many-to-one 中一個阻塞 I/O 可讓 process 內其他 runnable threads 全停。

完整算例。 兩個 user threads：T1 等 network、T2 計算 4 units。one-to-one 下 T1 blocked 時 T2 可在時間0開始並在4完成；many-to-one 只有1 kernel execution entity，若 T1 的 blocking call 不讓出，T2 的開始時間未知，不能保證在4完成。

思考題。 thread API 的並行承諾在何種映射與阻塞模型下成立？

Lin Cing https://github.com/xinhi6716/computer-science-self-study

6.5　多處理器排程

- processor affinity 可保留快取與 TLB 的溫暖狀態，但過度綁定會造成負載不均；load balancing 與 locality 形成取捨。
- SMP 需避免同一 runnable thread 被兩個 CPU 同時執行。run queue 設計、migration 與 stealing 都需原子同步。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.5　模型、時序與反例：多處理器排程

模型假設。 多核心共享或分區 run queue；migration 有鎖定與 memory/cache 一致性成本。

不變量與時序。 同一 runnable thread 不得同時被兩個 processors 執行；負載平衡後仍保留必要 affinity。

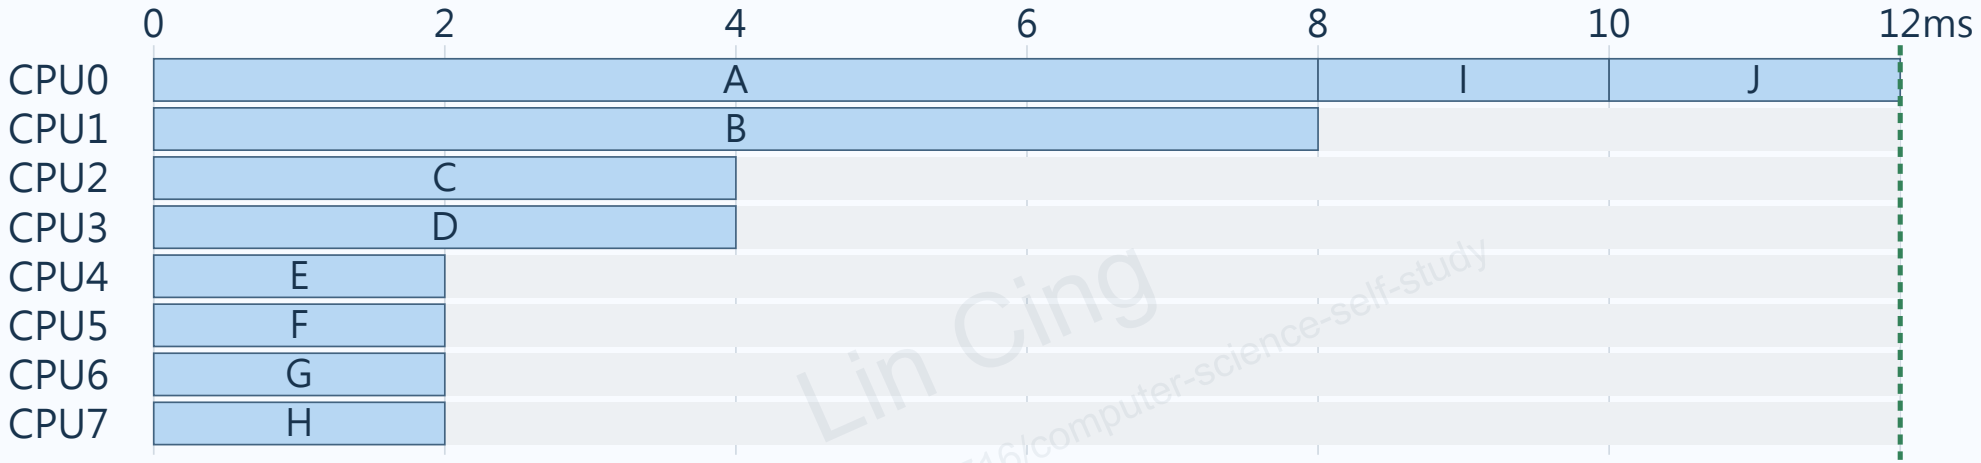
反例或邊界。 全體任務綁在一個核心以保快取，雖然 data locality 好，其他核心卻閒置。

完整算例。 固定8cores、所有jobs在t=0就緒、不可切分、單job不得同時跑在兩core。Jobs A/B各8ms、C/D各4ms、E/F/G/H/I/J各2ms，共36ms有用工作。初始CPU0 queue=[A,I,J]；CPU1至7分別只有B、C、D、E、F、G、H。

不遷移時CPU0依序A[0,8)、I[8,10)、J[10,12)，makespan=12ms。t=2時CPU4/5已做完E/F；在queue lock下各移除尚未執行的I/J，移交其唯一owner。每次遷移明定0.5ms queue/transfer加0.5ms cache warmup，故兩core各在[2,3)付成本、[3,5)執行I/J。CPU0只執行A至8，makespan降為8ms，speedup=12/8=1.5；有用工作仍36ms，新增成本共2ms。這是給定成本的教學模型，不是實機測量。

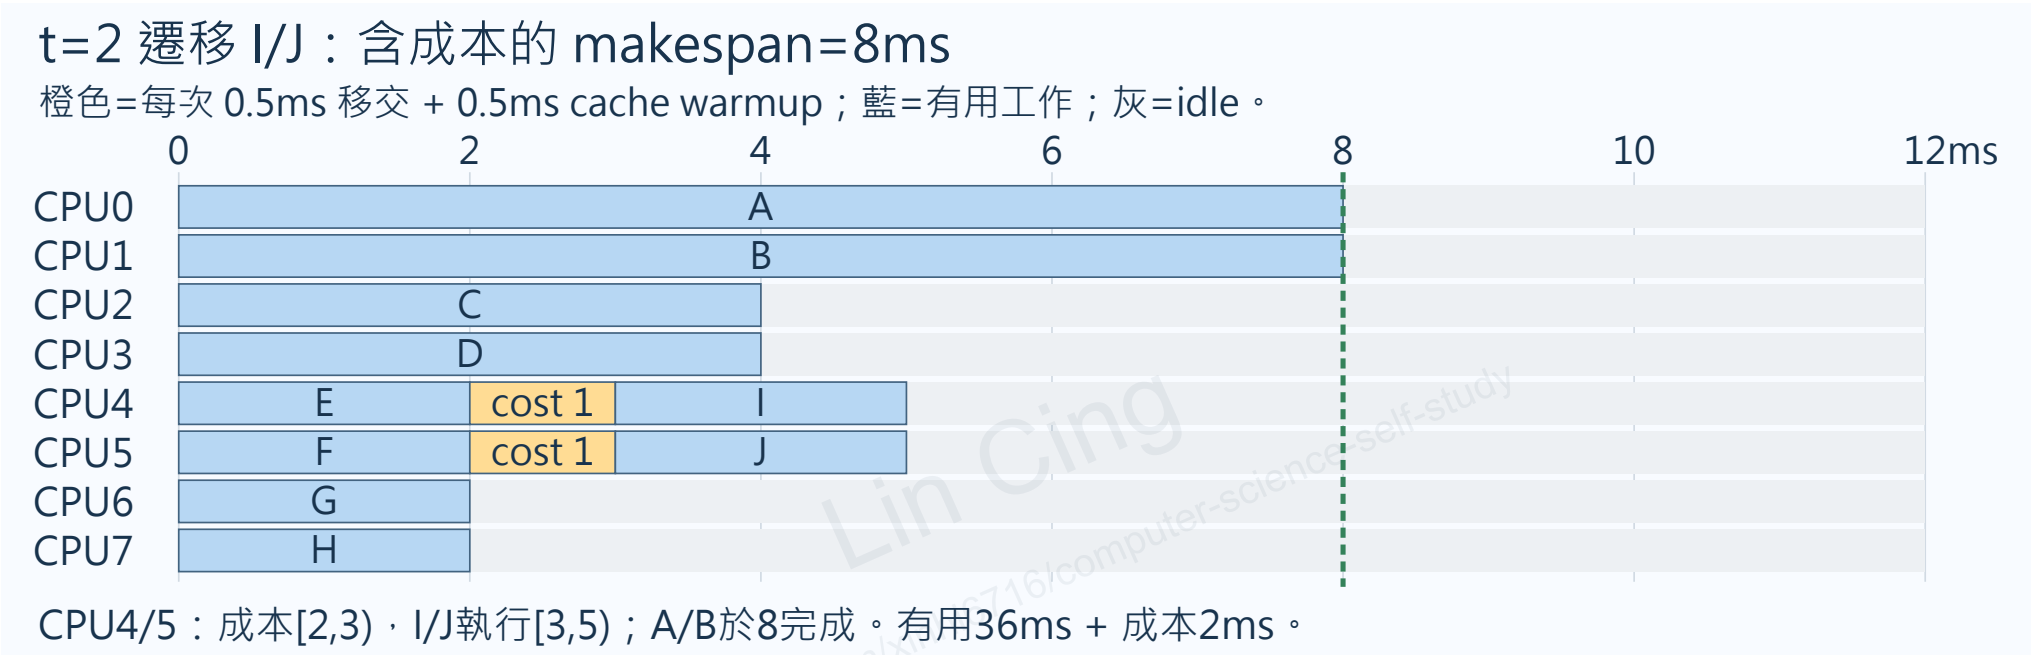
不遷移：CPU0 的 A→I→J 決定 makespan=12ms

藍=有用工作；灰=idle。所有 jobs 在 t=0 ready；同一時間軸 0–12ms。



t=2 時 CPU4/5 已完成 E/F，但 I/J 仍在 CPU0 queue 等 A 完成。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study



單job A長8ms給下界T≥8，所以本例達到此下界。若每次遷移成本改為c，makespan=max(8,2+c+2)=max(8,4+c)；c<8才比12ms嚴格改善。資料相依、硬性affinity或不同cache成本會改變模型，不能只因core閒置就宣稱遷移一定有益。

6.6　即時 CPU 排程

- real-time 系統要求工作期限，而非只追求平均回應。soft real-time 允許偶爾超時，hard real-time 的超時可能造成災難。
- periodic task 以 period p、execution time e 與 deadline d 描述。利用率 U = Σ(e_i/p_i) 是基本負載量；單 CPU 可搶占、獨立週期工作、相對期限等於 period 且無額外成本時，RM 有充分條件 U ≤ n(2^(1/n)−1)，EDF 的可排程條件為 U ≤ 1。期限、blocking 與 overhead 改變時不可直接套用。
- 例 e1=2,p1=d1=5，e2=3,p2=d2=10：U=0.4+0.3=0.7，小於兩工作 RM bound 2(√2−1)≈0.828，在獨立可搶占、無 blocking/overhead 模型下可排程。第一個 hyperperiod 的 RM 時間線為 T1[0,2)、T2[2,5)、T1[5,7)、idle[7,10)，各 job 皆在 deadline 完成。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.6.1 Rate-monotonic 與 Earliest Deadline First

- rate-monotonic priority 給 period 較短者較高 priority；在固定優先權、期限等於 period 等條件下有經典可排程充分條件。
- EDF 選最早絕對期限，動態優先權在單處理器理想模型常具更高利用率，但需可驗證的 deadline 與執行時間界線。
- priority inheritance 可降低高優先權工作被低優先權持鎖者間接阻塞的風險；它不是萬用即時保證。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.6　模型、時序與反例：即時 CPU 排程

模型假設。 工作有已知 period/deadline、執行時間上界，排程模型至多單核心或明確多核心；context switch 與 blocking 成本已指定。

不變量與時序。 每次工作完成不得超過其絕對 deadline；檢查 release、完成與剩餘 execution time，而不只開始時點。持鎖 blocking 必須納入上界分析；priority inheritance／ceiling 是可選協定，不能單憑名稱推出可排程。

反例或邊界。 只檢查 Σe/p <= 1 便宣稱 hard deadlines 全部保證，忽略實作 overhead、非週期工作與 blocking。

完整算例。 兩個週期工作 e1=2,p1=5；e2=3,p2=10，利用率 0.7，仍需依期限模型檢查實際時間表。

思考題。 哪個模型假設一旦不成立，利用率測試就不能單獨證明可排程？

Lin Cing https://github.com/xinhi6716/computer-science-self-study

6.7　作業系統例子

- Solaris 依 class-specific priority 轉成 global priority；TS/IA class 使用 multilevel feedback，priority 0 的 quantum 為 200 ms、priority 59 為 20 ms，CPU 用盡與 sleep 返回分別套用不同新 priority。Windows 7 的三十二級 queue 與 boost 保留原書版本界線。
- Linux 3.2 CFS 的 red-black tree 只排 ready entity；running task 暫離 tree。vruntime 增量為實際執行時間×1024/weight，選取最小 vruntime；nice 0 的 weight 為 1024，nice 5 為 335。
- v3.2 的 ideal_runtime 為 period×weight/runnable total weight；runnable 數不超過 8 時 period=6 ms。一般週期 tick 只在 delta_exec>ideal_runtime 時搶占，queued HRTICK 到達 slice 即重排。
- 睡醒位置為 max(舊 vruntime,min_vruntime−3 ms)。喚醒 task 要在 virtual-time lead 嚴格大於 1 ms 才搶占；last/next/skip buddy 只能在公平差距允許時影響候選。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.7　模型、時序與反例：作業系統例子

模型假設。 單 CPU；P1=8、P2=4 都在 t=0 runnable，P3=2 睡眠至 t=9；三者 nice=0、weight=1024。CFS 初始 vruntime 都正規化為 0，P1 先入 tree；GENTLE_FAIR_SLEEPERS=true、wakeup granularity=1 ms、CONFIG_SCHED_HRTICK=y；省略 timer jitter、interrupt、switch 與 cache 成本。

不變量與時序。 ready 集合不含 current；每次由 current 以外的 tree leftmost 選出最小 vruntime。$n \le 8$ 時 period=6 ms；兩 task 等權重時 ideal_runtime=3 ms。只有 HRTICK、期滿 wakeup 條件或 task completion 造成事件，不能憑圖硬插切換。

反例或邊界。 t=8 沒有 completion、tick 或 wakeup，所以 CFS 不會在 6–9 切成 6–8 與 8–9。另一情形的 1 ms 週期 tick 在 delta_exec=3 時不切換，因 v3.2 條件是嚴格大於；要等 delta_exec=4 才一般 tick 搶占。

完整算例。 HRTICK 軌跡：P1[0,3)、P2[3,6)、P1[6,9)、P3[9,11)、P2[11,12)、P1[12,14)。t=6 兩者 vruntime=3，先入 tree 的 P1 取左端；t=9 P1 已累積 6 ms，P3 以 min_vruntime=3、sleep credit=3 放回 vruntime=0，且 current−P3=6>1 ms，使 P3 立即搶占。完成時間 P1/P2/P3=14/12/11。

思考題。 關閉 HRTICK、保留 1 ms 週期 tick 並讓 P3 在 t=9 醒來時，第一個 3 ms slice 為何要到 t=4 才切換？

6.7　Linux 3.2 CFS 的事件模型

本頁只回答一個可核驗的問題：在固定的單 CPU 模型裡，v3.2 CFS 何時真正切換。P1、P2 的 burst 為 8、4 ms，P3 的 burst 為 2 ms；P1/P2 在 t=0 runnable，P3 睡眠至 t=9。三者 nice=0、weight=1024，CPU 切換、timer jitter 與 interrupt 成本均為 0。

教材把 P1/P2 初始 vruntime 正規化為 0，P3 睡眠前的 vruntime 也是 0；同值時依 P1、P2 的入樹順序取左端。這不冒充實際開機時 START_DEBIT 的絕對 offset，因為三者使用同一個選取鍵位移時，相對次序不變。模型另固定 GENTLE_FAIR_SLEEPERS=true、wakeup granularity=1 ms 與 CONFIG_SCHED_HRTICK=y。

ideal_runtime 是可執行的 wall-time slice，不是固定的全域 quantum。令 n 為 runnable entity 數：

$$period = \begin{cases} 6\ \text{ms}, & n \le 8, \\ 0.75n\ \text{ms}, & n > 8, \end{cases} \qquad ideal_i = period \times \frac{weight_i}{\sum_j weight_j}.$$

本題 n=2，因此 period=6 ms、每個 nice=0 task 的 ideal_runtime=3 ms。current 從 ready red-black tree 移除；重新選取時，舊 current 只有仍為 runnable 才依更新後的 vruntime 回樹。已阻塞或完成的 task 不在 ready tree，阻塞者須等喚醒才重新入樹。排程器依相應選取規則取得下一個 current，選定後的 ready 欄不含它。

6.7 Linux 3.2 CFS 的事件模型 (續)

Same workload, three ready structures

Solaris TS/IA

global priority

p20 → q120 ms

sleep return → p50

highest global priority

equal priority: round robin

IA favors window apps

Windows 7

32 ready queues

p1–15 variable / p16–31 RT

time quantum expires → lower

I/O / foreground → boost

foreground quantum ≈ 3×

scan highest nonempty queue

Linux 3.2 CFS

red-black tree

key = vruntime

nice 0/5 weight 1024/335

2 runnable → 3 ms slice

tick: delta_exec > slice

HRTICK queues exact slice

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.7　逐事件 CFS trace：t=8 沒有切換理由

下表的 ready 不含 current。min_vruntime 是當時 runqueue 的 virtual-time 基準；P3 睡眠時不在 ready tree。

時刻與事件	current	其他 ready	min vruntime	本次 ideal_runtime	選取理由
t=0 初始	P1	P2@0	0	3	P1/P2 同為 0；P1 先入樹
t=3 queued HRTICK	P1→P2	P1@3	0	3	P1 已跑滿 3 ms
t=6 queued HRTICK	P2→P1	P2@3	3	3	兩者同為 3；P1 是既有 leftmost
t=9 HRTICK 與 P3 wake	P1→P3	P2@3、P1@6	3	2	P3 放回 0；current 領先 6>1 ms
t=11 P3 完成	P3→P2	P1@6	3	3	P2 的 3 小於 P1 的 6；選定 P2 後將它移出 ready

Lin Cing https://github.com/xinhi6716/computer-science-self-study

6.7　逐事件 CFS trace：t=8 沒有切換理由 (續)

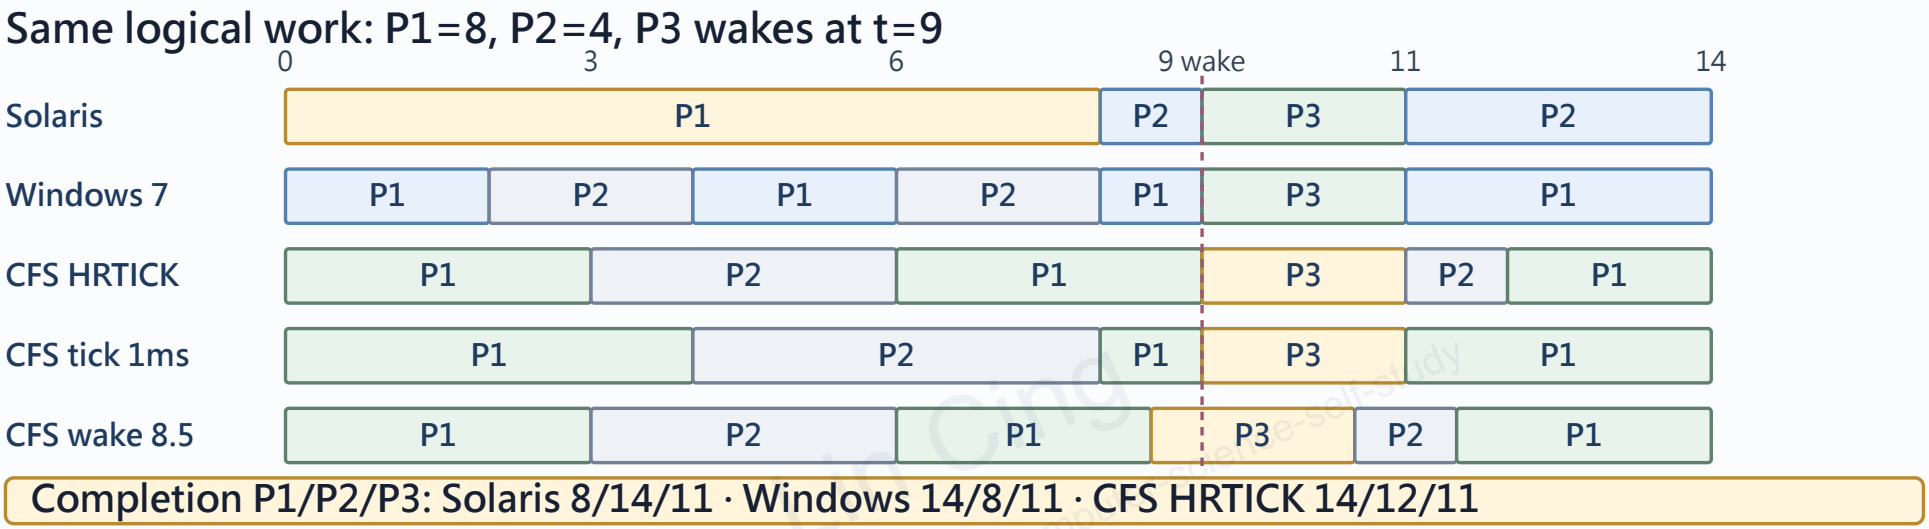
時刻與事件	current	其他 ready	min vruntime	本次 ideal_runtime	選取理由
t=12 P2 完成	P2→P1	無	6	6	只剩 current P1，剩餘 2 ms
t=14 P1 完成	P1→無	無	8	—	沒有 runnable task；保留最後 min_vruntime

關鍵事件是 t=9。P1 最後一次領到 CPU 是 t=6，ideal_runtime=3 ms，所以它在 6–9 可以一直跑到 HRTICK。P2 仍是 ready，min_vruntime=3 ms。P3 的放回值為

$$\max(v_{\mathrm{P3,sleep}}, min_vruntime - 3) = \max(0, 3 - 3) = 0.$$

current P1 在 t=9 的 vruntime=6，喚醒條件是 v_current−v_wakeup>1 ms；6−0=6，嚴格大於 1，所以 P3 立即取得 CPU。完成時間是 P1=14、P2=12、P3=11 ms，不是 14/9/11。

6.7　逐事件 CFS trace：t=8 沒有切換理由 （續）



Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.7　tick、HRTICK 與 sleep placement 的敏感度

同一個 workload 在不同 timer 模式下不能假裝只有一張答案。

設定	Gantt	completion P1/P2/P3	機制差異
HRTICK，P3 wake t=9	P1[0,3)、P2[3,6)、P1[6,9)、P3[9,11)、P2[11,12)、P1[12,14)	14/12/11	queued HRTICK 在 slice 邊界直接重排
無 HRTICK，1 ms tick，P3 wake t=9	P1[0,4)、P2[4,8)、P1[8,9)、P3[9,11)、P1[11,14)	14/8/11	delta_exec=4>3 才週期 tick 搶占
HRTICK，P3 wake t=8.5	P1[0,3)、P2[3,6)、P1[6,8.5)、P3[8.5,10.5)、P2[10.5,11.5)、P1[11.5,14)	14/11.5/10.5	wakeup lead 5.5>1 ms，真正發生喚醒搶占

check_preempt_tick 的 delta_exec > ideal_runtime 是嚴格不等號。沒有 HRTICK 時，1 ms tick 在 t=3 只看到 3>3 為 false，故 P1 到 t=4 才被一般 tick 搶占。HRTICK 由另一個高解析度 timer 在 slice 被排定的時刻觸發 queued 路徑，該路徑直接設定重排，不重新套用嚴格不等號。

6.7 tick、HRTICK 與 sleep placement 的敏感度 (續)

週期 tick 的第二個條件是：delta_exec≥minimum_granularity 後，若 current 的 vruntime 大於 leftmost 且差值超過 ideal_runtime，也可重排。這個條件處理錯過喚醒邊界的工作，不能取代喚醒比較。

last/next/skip buddy 是 cache locality 與避免過度排程的候選提示，不是另一個無視 vruntime 的 priority。此例在 P3 尚睡時 n<8，未形成一般 next buddy；真正 wakeup 超過 granularity 時才把 next buddy 指向 P3。若 buddy 與 leftmost 的 virtual-time 差距太大，仍不能越過公平界線。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.7　nice、weight 與跨案例比較

Linux 3.2 的 nice 不直接加減 priority queue；它改變 weight。v3.2 的 nice=0 weight 為 1024，nice=5 weight 為 335。若只有這兩個 task runnable 且 period=6 ms：

task	nice	weight	ideal_runtime	實體每 1 ms 增加的 vruntime
A	0	1024	6×1024/1359≈4.521 ms	1 ms
B	5	335	6×335/1359≈1.479 ms	1024/335≈3.057 ms

所以 nice 低者取得約 75.35% 的 CPU，nice 高者取得約 24.65%；權重並非線性 CPU percentage。n>8 時 period 隨 runnable 數延長，讓 minimum granularity 避免 slice 無限變短。

案例	固定版本規則	同一 logical workload 的 completion P1/P2/P3
Solaris TS/IA	p20/q120 ms；sleep 返回提升到 p50	8/14/11
Windows 7	32 級 queue；normalized 2/6 tick；I/O boost	14/8/11
Linux 3.2 CFS	HRTICK；nice=0；6 ms period；P3 t=9 wake	14/12/11

6.7　nice、weight 與跨案例比較 （續）

這張表比較的是事先明定的事件模型，不是三個產品的 benchmark。若 Linux 關閉 HRTICK，上述 completion 改為 14/8/11；若 P3 在 t=8.5 醒來，則為 14/11.5/10.5。可見「同一 workload」仍不足以推出唯一 Gantt，tick 模式與事件時刻必須先固定。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.8　演算法評估

- deterministic modeling 以代表性時間表精算指標；queueing model 以 arrival 與 service 分布估計平均；simulation 能加入更複雜政策；implementation 量測才有真實硬體成本。
- 模型必須揭露 workload 分布、CPU 數、context switch 成本與追蹤窗口。只報平均值容易隱藏 starvation 與尾端延遲。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.8　模型、時序與反例：演算法評估

模型假設。 模型輸入分布、arrival、service、CPU 數與 switch cost 一致；simulation 的 seed 與置信區間保留。

不變量與時序。 不同方法以同一簡化 workload 與成本假設做對照；若結論不同，要查明被省略的成本或分布差異，不能把一致方向當演算法不變量。比較結果保留相同量測窗口。

反例或邊界。 deterministic 例子顯示 SJF 較好，就直接推論所有 burst estimate 誤差下的實際系統也較好。

完整算例。 改以可完整重算的deterministic trace比較：單CPU、P1/P2/P3 arrival皆0、burst=5/2/3ms，無I/O與切換成本。Response固定為首次取得CPU；p99使用nearest-rank，三筆資料取第ceil(0.99×3)=3筆，即本批最大值。Waiting=completion−burst。

Lin Cing https://github.com/xinhi6716/computer-science-self-study

6.8　模型、時序與反例：演算法評估 （續）

政策	completion P1/P2/P3	waiting P1/P2/P3	平均 waiting	first response P1/P2/P3	本批p99 response
FCFS，初序 P1/P2/P3	5/7/10	0/5/7	4	0/5/7	7
SJF，P2/P3/P1	10/2/5	5/0/2	7/3	5/0/2	5
RR q=2，初序 P1/P2/P3	10/4/9	5/2/6	13/3	0/2/4	4

三者觀察窗口皆[0,10]，throughput=3/10 jobs/ms；SJF平均等待較小，RR本批首CPU尾端較小，不能用一個平均值替代另一指標。這是三個給定jobs的精算，不是隨機模擬或母體p99估計，沒有可憑空宣稱的95%置信區間。若改做隨機實驗，須另給arrival/service分布、seed、獨立重複單位與估計方法；平均值的置信區間也不是涵蓋95%個別等待的範圍。

思考題。 如何讓 benchmark 不只看平均吞吐而看見 tail？

6.9 總結

- 排程是 policy 問題。正確性包括所有 state 的 queue ownership 與 no double-run；服務品質還要看等待上限與回應分布。
- CPU utilization 高不保證使用者等待短；在共享資源競爭下，更多 runnable 工作反而可能降低有效吞吐。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

6.9　模型、時序與反例：總結

模型假設。 排程正確性、服務品質與成本模型都被分開驗證。

不變量與時序。 若服務契約要求 starvation freedom，須在 admission 與 arrival 假設下保證 runnable thread 最終前進；fixed-priority 本身可能不提供此性質，不能把所有政策都宣稱公平。

反例或邊界。 CPU 利用率 99% 的 batch 政策，若互動工作被永久延後，仍不符合互動系統目標。

完整算例。 沿用RR q=2、arrival全0、初序P1/P2/P3，只把三個bursts同乘k。每個時間片從ready queue取head，跑min(2,remaining)，未完成才入tail。逐段重播所得：

k；bursts	completion P1/P2/P3	waiting P1/P2/P3	throughput jobs/ms	本批p99首CPUresponse	最大waiting
1；5/2/3	10/4/9	5/2/6	3/10	4	6
2；10/4/6	20/10/16	10/6/10	3/20	4	10
3；15/6/9	30/16/25	15/10/16	1/10	4	16

6.9　模型、時序與反例：總結 （續）

例如k=2的執行順序為P1[0,2)、P2[2,4)、P3[4,6)、P1[6,8)、P2[8,10)、P3[10,12)、P1[12,14)、P3[14,16)、P1[16,18)、P1[18,20)。三列first response都0/2/4，busy utilization皆100%，最大ready等待卻6→10→16；所以首CPUresponse、總吞吐與等待必須一起看。這個有限batch不證明無限arrival下沒有starvation。

思考題。 哪個公平指標能補足平均利用率看不到的 starvation？

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

本章收束

- 演算法名稱不能脫離 burst 與 arrival 假設
- 回應與周轉時間不可混用
- 多處理器與即時排程要先界定 locality、期限與失敗模型

條件檢查。 使用本章任何模型前，先問它的假設是否仍成立。尤其是排程負載、同步保證、記憶體引用模式與硬體錯誤模型。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

練習與參考資料

練習題與詳解分別見本章獨立 PDF。

- Operating System Concepts, 9th Edition，第 6 章，印刷頁 261-312。
- *Operating System Concepts*, 9th Edition, Section 6.7, pp. 290-299：Linux CFS、Windows 7 與 Solaris class/priority/quantum 的版本案例。
- Linux v3.2 `kernel/sched_fair.c`：`__sched_period` 與 `sched_slice`、`place_entity`、`check_preempt_tick`、HRTICK 與 wakeup preemption。核心行段見 495-543、952-1015、1119-1153、1862-1905 與 2520-2662。
- Linux v3.2 `kernel/sched.c`：nice −20 至 19 的 `prio_to_weight`；nice=0 為 1024、nice=5 為 335。
- Microsoft Learn: Priority Boosts 與 Scheduling Priorities：Windows priority/quantum 與 foreground/I/O boost。
- Oracle Solaris Time-Sharing Class：time-sharing priority/quantum 與 sleep/CPU-use 調整。
- Windows normalized ticks 與跨 OS logical units 只供同工作量的選取比較，不構成產品效能量測。

練習與參考資料 （續）

- 教材把 P1/P2 初始 vruntime 正規化為 0；這避免把任務建立時的 `START_DEBIT` 絕對 offset誤當成本例的相對差異。HRTICK、週期 tick、喚醒時刻與 tie-break 都是模型輸入，不由 Gantt 反推。

Lin Cing
https://github.com/xinhi6716/computer-science-self-study

參考資料與署名

Abraham Silberschatz, Peter B. Galvin, Greg Gagne. Operating System Concepts, 9th Edition.

Lin Cing 原創教學整理。原創內容以 CC BY 4.0 授權；參考書籍不隨教材散布。

https://github.com/xinhi6716/computer-science-self-study

Lin Cing
https://github.com/xinhi6716/computer-science-self-study